




Fundamentos de Séries Temporais e Processos Estocásticos

Uma jornada pelos conceitos essenciais que fundamentam a análise de dados temporais e a modelagem de processos aleatórios ao longo do tempo.

Eduardo Ogasawara

eduardo.ogasawara@cefet-rj.br


<https://eic.cefet-rj.br/~eogasawara>

Série Temporal como Sequência de Observações

Uma série temporal é uma sequência ordenada de valores no tempo, onde cada observação está associada a um instante temporal específico.

$$x_1, x_2, \dots, x_T$$

Onde x_t é o valor observado no instante t , e T é o número total de observações. A série também pode ser representada como função do tempo: $x(t)$.



Sequência Original

A ordem natural preserva a estrutura temporal e o significado dos dados.

Após Permutação

Trocar a ordem destrói a estrutura temporal. Diferentemente de dados comuns, não podemos reorganizar os valores sem alterar o significado da informação.

Em dados tradicionais, a ordem não importa; em séries temporais, ela é fundamental. Métodos estatísticos usuais precisam ser adaptados, pois a dependência entre observações consecutivas é parte do fenômeno estudado.

Série Temporal como Função Discreta do Tempo

Função do Tempo

A série pode ser vista como uma função matemática que mapeia instantes de tempo em valores reais.

Matematicamente, definimos a série como uma função:

$$x : \mathcal{T} \rightarrow \mathbb{R}$$

Onde $\mathcal{T}$ é o conjunto de instantes de tempo (valores inteiros) e $\mathbb{R}$ é o conjunto dos números reais. Essa visão funcional permite tratar séries temporais com ferramentas matemáticas e probabilísticas.

Tempo Discreto

O tempo assume valores discretos, como dias, meses ou anos, não contínuos.


Valor Associado

Cada instante tem um único valor associado, formando a sequência temporal.

Processo Estocástico e Trajetória Observada

Pense no processo estocástico como um dado que ainda não foi lançado — ele contém todas as possibilidades. A série observada é o resultado de um único lançamento.

Processo estocástico e trajetória



Processo Estocástico

$$\{X_t\}_{t=1}^T$$

Todas as trajetórias possíveis, descritas por um modelo probabilístico.


Trajetoória Observada

$$x_t = X_t(\omega)$$


O caminho concreto que o processo tomou — os dados que temos em mãos.

Nunca vemos o processo diretamente. Só temos acesso a uma de suas realizações. Por isso, toda inferência sobre o processo é feita a partir dessa única trajetória. Modelar uma série temporal significa tentar reconstruir o mecanismo a partir de uma única trajetória observada.

Média constante



Média variável



Média do Processo Temporal

A média descreve o nível esperado da série em cada instante. É o ponto de referência em torno do qual os valores oscilam.

$$\mu_t = \mathbb{E}[X_t]$$

Na prática, estimamos a média teórica pela média amostral da série observada. Quando essa média não muda com o tempo, dizemos que o processo tem média estacionária — uma propriedade desejável para modelagem.

Variância do Processo Temporal

Se a média mede o nível, a variância mede a dispersão. Ela indica o quanto os valores se afastam do esperado em cada instante.

Variância Teórica

$$\sigma_t^2 = \text{Var}(X_t)$$

Dispersão do processo no instante t .


Variância Amostral

$$s^2 = \frac{1}{T-1} \sum_{t=1}^T (x_t - \bar{x})^2$$


Estimativa calculada a partir dos dados.

Quando a variância muda ao longo do tempo, a série é instável e mais difícil de modelar. Variância constante é outra condição de estacionariedade.

homocedasticidade



heterocedasticidade



Covariância e Autocovariância Temporal

Média e variância descrevem cada instante isoladamente. A covariância temporal vai além: mede a relação entre dois instantes diferentes.

Instante $t-h$

O valor passado, separado por h períodos.

Defasagem h

O intervalo entre os dois instantes comparados.

Instante t

O valor presente.

A covariância entre dois instantes depende do intervalo entre eles — não dos instantes em si. Isso nos permite resumir toda a estrutura de dependência em uma única função da defasagem h , chamada função de autocovariância:

$$\gamma(h) = \text{Cov}(X_t, X_{t-h})$$

- ❏ Quanto maior a defasagem, menor tende a ser a dependência. Processos com memória longa mantêm autocovariância significativa mesmo para h grande.

A função $\gamma(h)$ é a base para medir autocorrelação e identificar padrões estruturais na série.

Autocorrelação

A autocovariância depende da escala da série, o que dificulta comparações. A autocorrelação resolve isso: normaliza a dependência para um intervalo entre -1 e 1.

Autocovariância

Mede dependência, mas na escala original dos dados.

Normalização

Dividimos pela variância para eliminar o efeito da escala.


Autocorrelação

Resultado padronizado, comparável entre séries diferentes.

$$\rho(h) = \frac{\gamma(h)}{\gamma(0)}$$

A autocorrelação é uma das ferramentas mais usadas para entender a estrutura de dependência de uma série temporal.

ACF



Autocorrelação Amostral

O processo real não é observável. Na prática, estimamos a autocorrelação diretamente a partir dos dados — obtendo a ACF amostral.

Autocovariância Amostral


$$\hat{\gamma}(h) = \frac{1}{T} \sum_{t=h+1}^T (x_t - \bar{x})(x_{t-h} - \bar{x})$$

Autocorrelação Amostral


$$\hat{\rho}(h) = \frac{\hat{\gamma}(h)}{\hat{\gamma}(0)}$$

A ACF amostral é o ponto de partida para identificar padrões de dependência e escolher modelos adequados para a série.


Série simulada (AR(1), $\varphi = 0.6$)




ACF amostral (com bandas de confiança)



Ruído branco (estacionário)



Passeio aleatório (não estacionário)



Estacionariedade

Uma série é estacionária quando suas propriedades estatísticas — média, variância e estrutura de dependência — permanecem estáveis ao longo do tempo. Isso não significa que os valores são constantes, mas que o comportamento do processo não muda. Séries estacionárias são mais fáceis de modelar porque o passado informa o futuro de forma consistente.

Média Constante

$$\mathbb{E}[X_t] = \mu$$

A média não varia ao longo do tempo

Variância Constante

$$\text{Var}(X_t) = \sigma^2$$

A dispersão permanece estável

Autocovariância Dependente Apenas da Defasagem

$$\text{Cov}(X_t, X_{t-h}) = \gamma(h)$$

A dependência depende só do intervalo, não do tempo absoluto

Quando uma série não satisfaz essas condições, é preciso transformá-la antes de aplicar modelos clássicos como ARMA.

Exemplos: Processos Estacionários e Não Estacionários

Processo Estacionário Ruído Branco

$$X_t = \varepsilon_t$$

Sem memória temporal, propriedades constantes no tempo


Processo Não Estacionário Passeio Aleatório

$$X_t = X_{t-1} + \varepsilon_t$$


Acumula choques, variância crescente ao longo do tempo

Onde ε_t é um termo aleatório com média zero e variância constante. O ruído branco representa um processo simples, mas com propriedades constantes. Já o passeio aleatório acumula choques, gerando variância crescente e ausência de estacionariedade. Esse contraste ajuda a entender por que muitas séries reais precisam ser transformadas antes da modelagem.

Ruído branco (estacionário)



Passeio aleatório (não estacionário)




Diferenciação como Transformação para Estacionariedade

Séries temporais não estacionárias apresentam média ou variância que variam ao longo do tempo, tornando-as inadequadas para modelagem direta. A diferenciação é a transformação mais comum para resolver esse problema: ela subtrai cada observação da anterior, removendo tendências sistemáticas e estabilizando a série.


$$Y_t = X_t - X_{t-1}$$

- ❏ Esse procedimento é fundamental em modelos como ARIMA, onde a ordem de diferenciação é representada pelo parâmetro d .

Antes: passeio aleatório (não estacionário)



Depois: série diferenciada $\Delta X_t = X_t - X_{t-1}$



Modelo Autorregressivo de Ordem 1

A Ideia Central

$$X_t = \phi X_{t-1} + \varepsilon_t$$

Memória Temporal

O valor atual carrega informação do passado.

Parâmetro ϕ

Controla a intensidade da dependência. Quanto maior $|\phi|$, mais forte a memória.

Ruído ε_t

Choque aleatório que impede a série de ser determinística.

AR(1) — Autorregressivo de Ordem 1

ENTRADA: x (série temporal, comprimento T)

PRÉ-CONDIÇÃO: série aproximadamente estacionária

PASSO 1 — Estimar o parâmetro

$$\phi \leftarrow \text{Cov}(x_t, x_{t-1}) / \text{Var}(x_{t-1})$$


PASSO 2 — Gerar valores ajustados

PARA t de 2 até T:


$$\hat{x}_t \leftarrow \phi \cdot x_{t-1} + \varepsilon_t$$

SAÍDA: $\hat{x}$ (valores ajustados pelo modelo AR(1))

Série AR(1) simulada ($\phi = 0.8$)



ACF amostral do AR(1)



AR(1): Condições e Propriedades

Estacionariedade

O processo AR(1) é estacionário quando $|\phi| < 1$. Nesse caso, os efeitos de choques passados diminuem ao longo do tempo e as propriedades estatísticas se estabilizam.

$$|\phi| < 1$$


O AR(1) é o modelo mais simples que captura memória temporal. Modelos como ARMA e ARIMA são extensões naturais dessa estrutura.

Autocorrelação

A autocorrelação do AR(1) decai exponencialmente com a defasagem. Essa "assinatura" permite identificar o modelo a partir dos dados observados.


$$\rho(h) = \phi^h$$

Referências Bibliográficas




Event Detection in Time Series

Ogasawara, E.; Salles, R.; Porto, F.; Pacitti, E.
Springer Nature Switzerland, 2025.



Time Series Analysis: With Applications in R

Cryer, J. D.; Chan, K.-S. Springer, 2008.



Data Mining: Concepts and Techniques

Han, J.; Pei, J.; Tong, H. Morgan Kaufmann, 4^a ed., 2022.