

# Fundamentos de Séries Temporais e Processos Estocásticos

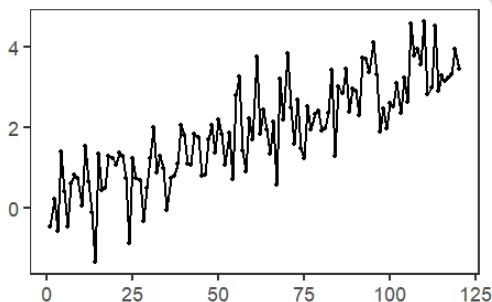
Uma jornada pelos conceitos essenciais que fundamentam a análise de dados temporais e a modelagem de processos aleatórios ao longo do tempo.

**Eduardo Ogasawara**

[eduardo.ogasawara@cefet-rj.br](mailto:eduardo.ogasawara@cefet-rj.br)

<https://eic.cefet-rj.br/~eogasawara>

# Série Temporal como Sequência de Observações



Uma série temporal é uma sequência ordenada de valores no tempo, onde cada observação está associada a um instante temporal específico. A ordem das observações é parte essencial da informação.

A série pode ser representada como:

$$x_1, x_2, \dots, x_T$$

Onde  $x_t$  é o valor observado no instante  $t$ , e  $T$  é o número total de observações.

Também podemos representar como função do tempo:  $x(t)$



## Por que a ordem importa?

Diferentemente de dados comuns, não podemos reorganizar os valores sem alterar o significado da informação. Cada observação está ligada a um momento específico do tempo.

# Série Temporal como Função Discreta do Tempo

## Função do Tempo

A série pode ser vista como uma função matemática que mapeia instantes de tempo em valores reais.

## Tempo Discreto

O tempo assume valores discretos, como dias, meses ou anos, não contínuos.

## Valor Associado

Cada instante tem um único valor associado, formando a sequência temporal.

Matematicamente, definimos a série como uma função:

$$x : \mathcal{T} \rightarrow \mathbb{R}$$


Onde  $\mathcal{T}$  é o conjunto de instantes de tempo (valores inteiros) e  $\mathbb{R}$  é o conjunto dos números reais. Essa visão funcional permite tratar séries temporais com ferramentas matemáticas e probabilísticas.

# A Importância Crítica da Ordem Temporal

## Sequência Original

$$(x_1, x_2, \dots, x_T)$$

A ordem natural preserva a estrutura temporal e o significado dos dados.




## Após Permutação

$$(x_{\pi(1)}, x_{\pi(2)}, \dots, x_{\pi(T)})$$

Trocar a ordem destrói a estrutura temporal e altera completamente o significado.



---

Se trocarmos a ordem das observações, perdemos a estrutura temporal. Em dados tradicionais, a ordem não importa; em séries temporais, ela é fundamental. Isso significa que métodos estatísticos usuais precisam ser adaptados, pois a dependência entre observações consecutivas é parte do fenômeno estudado.



# Dependência Temporal entre Observações

Ruído branco

AR(1):  $\varphi = 0.8$ 

1

## Valor Passado

Observações anteriores influenciam o presente

2

## Valor Presente

Depende dos valores em instantes anteriores

3

## Valor Futuro

Será influenciado pelo presente e passado

Em séries temporais, observações ao longo do tempo tendem a ser dependentes. O valor presente pode depender de valores passados, e a hipótese de independência geralmente não é válida.

A dependência pode ser expressa como:

$$X_t \text{ depende de } X_{t-1}, X_{t-2}, \dots$$

Por exemplo, preços, temperaturas ou demanda raramente mudam de forma totalmente aleatória entre períodos consecutivos. Essa dependência temporal é a razão pela qual precisamos de modelos específicos, diferentes dos usados em estatística clássica.

# Série Observada e Processo Estocástico

## Conceitos Fundamentais

### Processo Estocástico

Conjunto de variáveis aleatórias ao longo do tempo:  $\{X_t\}$

### Série Observada

Uma realização específica do processo:  $x_t$


### Variável Aleatória

Cada instante  $t$  corresponde a uma variável aleatória  $X_t$

A ideia central é separar "processo" e "dados". O processo estocástico representa o mecanismo gerador dos dados, enquanto a série observada é apenas uma trajetória desse processo. Essa distinção é fundamental: modelar séries temporais significa tentar descrever matematicamente o processo que gerou os dados observados.

# Processo Estocástico e Trajetória Observada

A série temporal é modelada como um processo aleatório, onde cada instante corresponde a uma variável aleatória. A série observada é apenas uma trajetória possível desse processo.



## Processo Estocástico

$$\{X_t\}_{t=1}^T$$

Todas as trajetórias possíveis



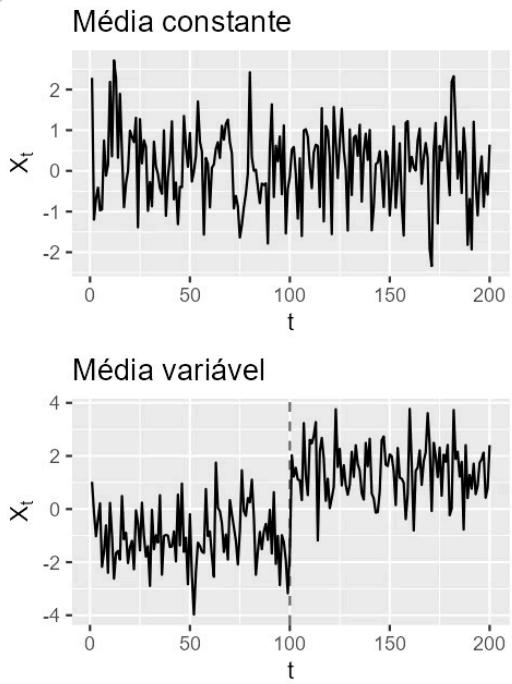
## Trajetória Observada

$$x_t = X_t(\omega)$$

Uma realização específica

Aqui formalizamos a ideia de que os dados observados são apenas uma realização possível de um processo aleatório. O símbolo  $\omega$  representa um elemento do espaço probabilístico (resultado possível). Essa visão é essencial para justificar o uso de probabilidades e modelos estatísticos em séries temporais.

# Média do Processo Temporal



## Média Teórica

Cada instante possui uma média teórica que pode variar ao longo do tempo:

$$\mu_t = \mathbb{E}[X_t]$$

Onde  $\mu_t$  é a média do processo no instante  $t$ , e  $\mathbb{E}[X_t]$  é o valor esperado.

## Média Amostral

A média observada é uma estimativa da média teórica:

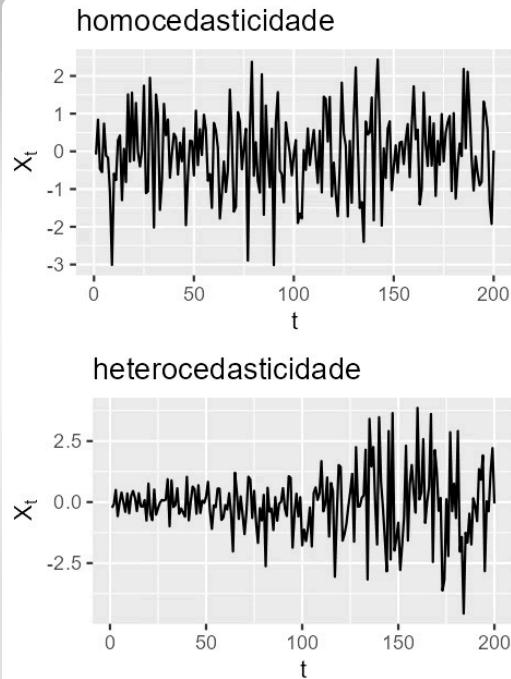
$$\bar{x} = \frac{1}{T} \sum_{t=1}^T x_t$$

Onde  $\bar{x}$  é a média da série observada.

---

A média do processo descreve o comportamento esperado da série em cada instante do tempo. Como essa média não é observável diretamente, usamos a média da série observada como estimativa. Em muitos modelos, assume-se que a média não depende do tempo, o que simplifica a análise e leva ao conceito de estacionariedade.

# Variância do Processo Temporal



## Variância Teórica

$$\sigma_t^2 = \text{Var}(X_t)$$

Mede a dispersão da série no instante  $t$

## Variância Amostral

$$s^2 = \frac{1}{T-1} \sum_{t=1}^T (x_t - \bar{x})^2$$

Estimativa calculada a partir dos dados observados

A variância descreve o grau de variabilidade da série ao longo do tempo. Em alguns processos, a variância é constante; em outros, ela muda, indicando instabilidade. Essa diferença é crucial para a modelagem, pois muitos modelos clássicos assumem variância constante.

# Covariância Temporal

A covariância temporal mede a relação entre valores em instantes diferentes, expressando a dependência temporal. É uma função do tempo e da defasagem.



A covariância entre dois instantes é definida como:

$$\text{Cov}(X_t, X_{t-h})$$

Onde  $h$  representa a defasagem temporal (lag). Se a covariância é diferente de zero, existe dependência temporal. Esse conceito é a base para entender autocorrelação e para construir modelos que capturam a estrutura de dependência ao longo do tempo.

# Função de Autocovariância

A função de autocovariância descreve a dependência em função da defasagem, sendo central na análise de séries temporais:

$$\gamma(h) = \text{Cov}(X_t, X_{t-h})$$


Onde  $\gamma(h)$  é a autocovariância para defasagem  $h$ .

- Em processos simples, a dependência diminui à medida que o intervalo entre observações aumenta.

A função de autocovariância mostra como a dependência entre observações varia com a defasagem temporal. É a base para definir a autocorrelação e identificar padrões estruturais na série.

# Autocorrelação

ACF



01

## Autocovariância

Medida de dependência que depende da escala dos dados

02

## Normalização

Dividimos pela variância para remover o efeito da escala

03

## Autocorrelação

Medida padronizada que varia entre -1 e 1

A função de autocorrelação é definida como:

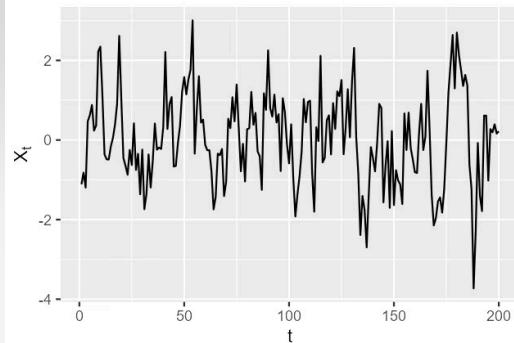
$$\rho(h) = \frac{\gamma(h)}{\gamma(0)}$$

Onde  $\rho(h)$  é a autocorrelação na defasagem  $h$ ,  $\gamma(h)$  é a autocovariância na defasagem  $h$ , e  $\gamma(0)$  é a variância do processo.


A autocovariância depende da escala da série, dificultando comparações. Por isso, normalizamos pela variância, obtendo a autocorrelação. Esta mede a força da relação entre valores separados por uma defasagem temporal e é uma das ferramentas mais importantes para entender a estrutura de uma série temporal.

# Autocorrelação Amostral

Série simulada (AR(1),  $\varphi = 0.6$ )



ACF amostral (com bandas de confiança)



## Autocovariância Amostral

$$\hat{\gamma}(h) = \frac{1}{T} \sum_{t=h+1}^T (x_t - \bar{x})(x_{t-h} - \bar{x})$$

## Autocorrelação Amostral

$$\hat{\rho}(h) = \frac{\hat{\gamma}(h)}{\hat{\gamma}(0)}$$

Como não conhecemos o processo gerador dos dados, calculamos a autocorrelação a partir da série observada. A ACF amostral fornece uma aproximação da dependência temporal do processo e é usada na prática para identificar modelos e padrões na série.

# Conceito de Estacionariedade

## Estacionária

Média, variância e autocorrelação constantes ao longo do tempo

## Não estacionária

Propriedades mudam; tendência, variância e autocorrelação variáveis

As propriedades estatísticas de uma série podem variar no tempo.

Estacionariedade significa invariância ao longo do tempo e é um conceito central da modelagem de séries temporais.

Um processo é estacionário se suas propriedades estatísticas não dependem do instante temporal.

A estacionariedade é uma hipótese fundamental em séries temporais. Se a média, variância e dependência temporal mudam ao longo do tempo, muitos modelos clássicos deixam de ser válidos. Por isso, grande parte da análise consiste em verificar ou induzir estacionariedade na série.

✓ ESTACIONARIEDADE FRACA

## Condições de Estacionariedade Fraca

1

### Média Constante

$$\mathbb{E}[X_t] = \mu$$

A média não varia ao longo do tempo

2

### Variância Constante

$$\text{Var}(X_t) = \sigma^2$$

A dispersão permanece estável

3

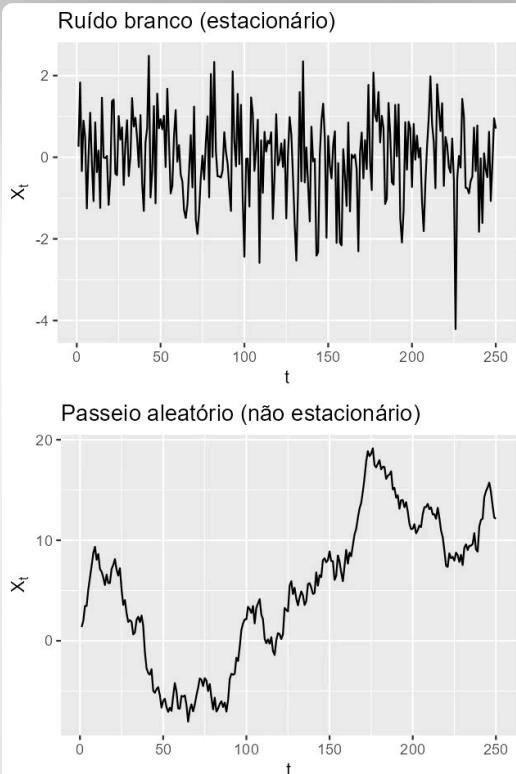
### Autocovariância Dependente Apenas da Defasagem

$$\text{Cov}(X_t, X_{t-h}) = \gamma(h)$$

A dependência depende só do intervalo, não do tempo absoluto

A estacionariedade fraca é a forma mais usada na prática. Ela exige apenas que média, variância e estrutura de dependência sejam invariantes no tempo. Modelos clássicos como ARMA são construídos sob essa hipótese, o que explica sua importância teórica e prática.

# Exemplos: Processos Estacionários e Não Estacionários



## Processo Estacionário Ruído Branco

$$X_t = \varepsilon_t$$

Sem memória temporal, propriedades constantes no tempo

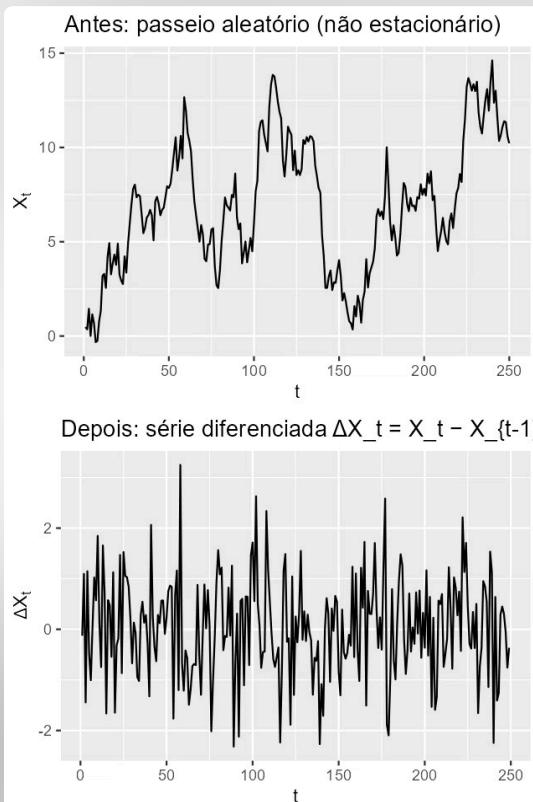
## Processo Não Estacionário Passeio Aleatório

$$X_t = X_{t-1} + \varepsilon_t$$

Acumula choques, variância crescente ao longo do tempo

Onde  $\varepsilon_t$  é um termo aleatório com média zero e variância constante. O ruído branco representa um processo simples, mas com propriedades constantes. Já o passeio aleatório acumula choques, gerando variância crescente e ausência de estacionariedade. Esse contraste ajuda a entender por que muitas séries reais precisam ser transformadas antes da modelagem.

# Transformações para Induzir Estacionariedade



## Série Original

Não estacionária, com tendência ou variância crescente

## Diferenciação

$$Y_t = X_t - X_{t-1}$$

Remove variações sistemáticas de longo prazo

## Série Transformada

Estacionária, adequada para modelagem

Séries reais frequentemente não são estacionárias. Transformações podem estabilizar média e variância, sendo a diferenciação a mais comum. Quando uma série apresenta tendência ou crescimento ao longo do tempo, a diferenciação remove essas variações sistemáticas, transformando a série original em uma nova série mais estável. Esse procedimento é fundamental em modelos como ARIMA.

# Interpretação da Diferenciação

A diferenciação mede a variação entre períodos consecutivos, eliminando tendência determinística simples e alterando a estrutura de dependência temporal.

A diferença de primeira ordem é representada por:

$$Y_t = \Delta X_t$$

Onde  $\Delta X_t$  representa a variação da série entre  $t$  e  $t - 1$ .

## Por que diferenciar?

Muitas séries econômicas, financeiras e ambientais apresentam crescimento acumulativo que impede a estacionariedade.

A diferenciação transforma a série em variações ao longo do tempo. Em vez de analisar níveis absolutos, passamos a analisar mudanças entre períodos consecutivos.

# Modelo Autorregressivo de Ordem 1

O modelo AR(1) descreve situações onde o valor atual depende linearmente do valor passado. É um modelo linear simples de dependência temporal e serve como base para modelos mais complexos.

## Estrutura do Modelo

$$X_t = \phi X_{t-1} + \varepsilon_t$$


## Componentes

- $X_t$ : valor no instante  $t$
- $\phi$ : parâmetro de dependência
- $X_{t-1}$ : valor no instante anterior
- $\varepsilon_t$ : termo aleatório com média zero

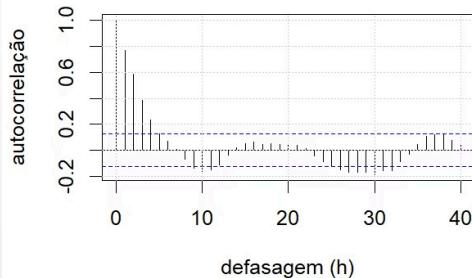
O parâmetro  $\phi$  mede a intensidade da dependência temporal. Esse modelo é a estrutura mais simples capaz de capturar memória temporal e serve como ponto de partida para modelos ARMA e ARIMA.

# Condição de Estacionariedade no AR(1) e Autocorrelação

Série AR(1) simulada ( $\phi = 0.8$ )



ACF amostral do AR(1)



## Condição de Estacionariedade

A estacionariedade depende do parâmetro do modelo. Valores altos de dependência geram instabilidade.

$$|\phi| < 1$$

Quando  $|\phi| < 1$ , os efeitos de choques passados diminuem ao longo do tempo, garantindo estabilidade estatística.

## Padrão de Autocorrelação

Modelos geram padrões específicos de autocorrelação. A ACF revela a estrutura do processo.

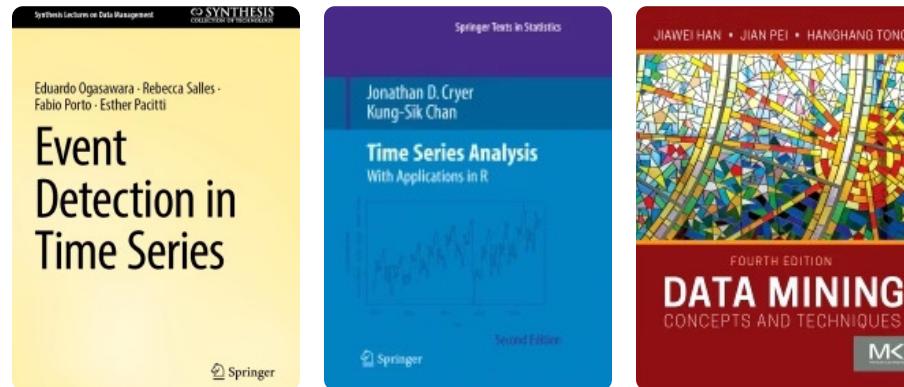
No modelo AR(1), a autocorrelação é:

$$\rho(h) = \phi^h$$

A autocorrelação decai exponencialmente com a defasagem  $h$ . Essa "assinatura" permite identificar modelos a partir dos dados observados.

# Referências Bibliográficas

Uma coleção cuidadosamente selecionada de obras fundamentais que abordam análise de séries temporais e mineração de dados.



## Event Detection in Time Series

**Ogasawara, E.; Salles, R.; Porto, F.; Pacitti,**

**E.** (2025). Publicação recente da Springer Nature Switzerland que explora técnicas avançadas de detecção de eventos em séries temporais.

## Time Series Analysis: With Applications in R

**Cryer, J. D.; Chan, K.-S.** (2008). Obra clássica da Springer que combina fundamentação teórica sólida com implementações práticas.

## Data Mining: Concepts and Techniques

**Han, J.; Pei, J.; Tong, H.** (2022). Quarta edição publicada pela Morgan Kaufmann que consolida conceitos fundamentais e técnicas avançadas de mineração de dados