CEFET/RJ

Introdução

Eduardo Ogasawara
eduardo.ogasawara@cefet-rj.br
https://eic.cefet-rj.br/~eogasawara

Por que detectar eventos em séries temporais?

- Eventos em séries temporais indicam mudanças significativas no comportamento dos dados
- Detectá-los é essencial em áreas como:
- Finanças (ex: quedas abruptas de mercado)
- Saúde (ex: surtos de doenças)
- Meio ambiente (ex: eventos climáticos extremos)
- Segurança (ex: tráfego incomum em redes)
- A detecção de eventos apoia a tomada de decisão, monitoramento e resposta proativa

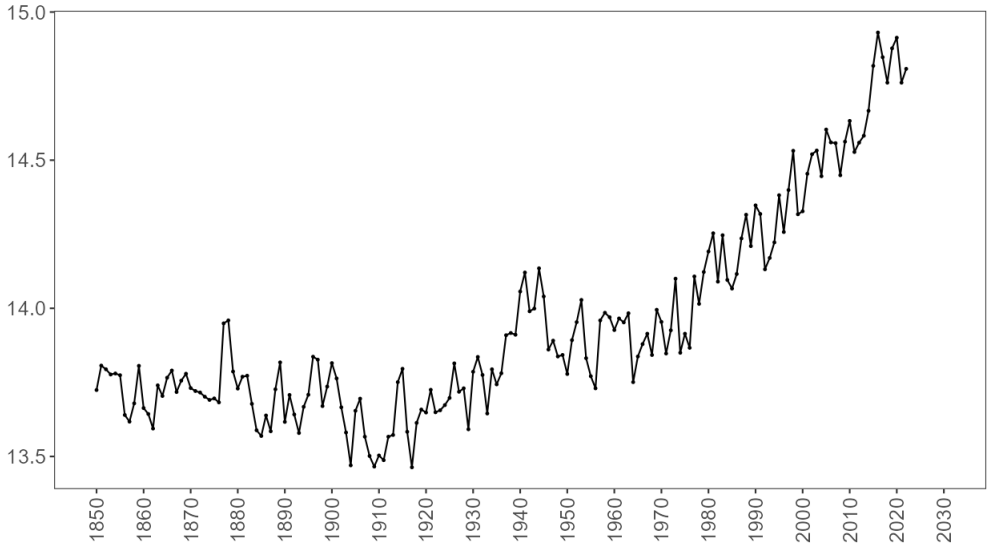

O que são eventos em séries temporais?

- Um evento é um instante ou intervalo que se destaca por um comportamento relevante
- Pode representar:
  - Quebra de padrão
  - Mudança de tendência
  - Ocorrência repetitiva ou atípica
- A interpretação depende do contexto do domínio

Objetivo do Capítulo

- Apresentar os fundamentos da detecção de eventos em séries temporais
- Classificar eventos e métodos de detecção
- Descrever os desafios de avaliação e os principais cenários de aplicação

Evento

- Componente de série temporal
- $tc(x_t) = \begin{cases} tc_o(x_t) = x_t \\ tc_{tr}(x_t) = tr(x_t) \\ tc_v(x_t) = v(x_t) \end{cases}$
- Valor esperado de termos autoregressivos prévios
  - $ep(tc(x_t), k) = E(tc(x_t) \mid tc(x_{t-1}), \ldots, tc(x_{t-\mathrm{k}}))$
- Valor esperado de termos autoregressivos posteriores
  - $ef(tc(x_t), k) = E(tc(x_t) \mid tc(x_{t+1}), \ldots, tc(x_{t+k}))$
- Evento
  - $e(X, k, \sigma) = \{t, \begin{array}{l} |tc(x_t) - ep(tc(x_t), k)| > \sigma \\ \vee\ |tc(x_t) - ef(tc(x_t), k)| > \sigma \\ \vee\ |ep(tc(x_t), k) - ef(tc(x_t), k)| > \sigma \end{array}$

Tipos de Eventos em Séries Temporais

- Anomalias: observações que se desviam do comportamento típico
- Pontos de mudança: mudanças abruptas em propriedades estatísticas
- Motifs: subsequências frequentes (ou raras, como *discords*)

Exemplos Visuais de Eventos

Anomalias

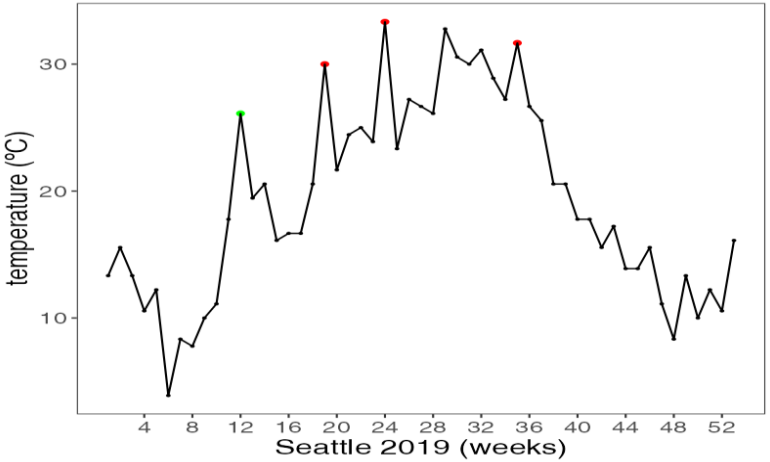

Ponto de Mudança

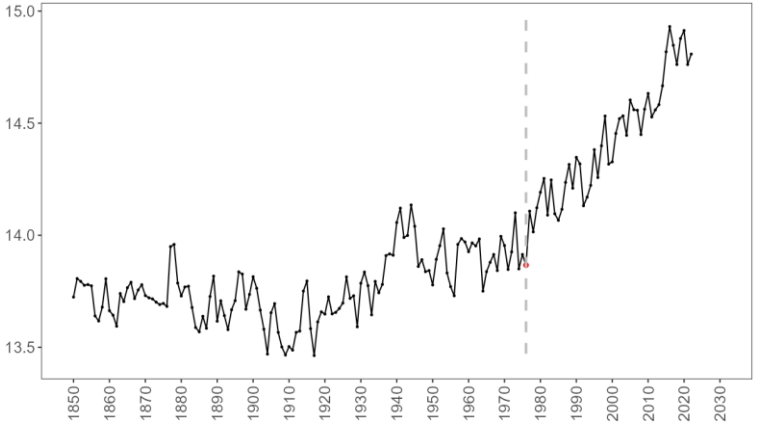

Motifs e Discords

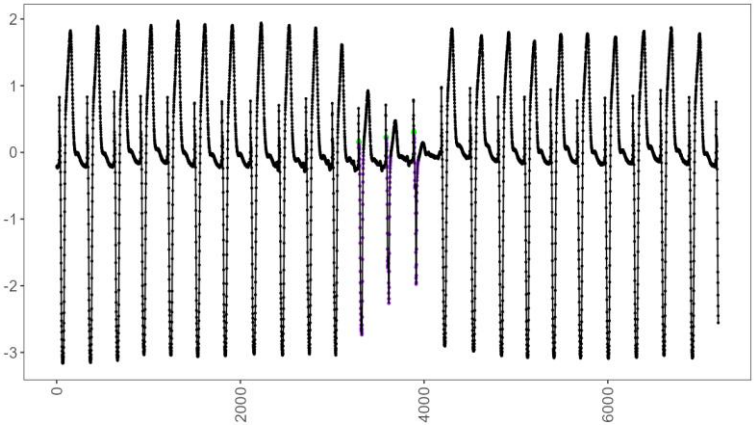

#1: série com picos anômalos (anomalias), #2: série com mudança de tendência (change point), #3: série com padrões repetitivos (motifs)

Estrutura dos Dados de Séries Temporais

- Granularidade:
  - Eventos Pontuais (ex: falha em 1 instante) e Por intervalo (ex: período de alta volatividade)
- Dimensionalidade:
  - Univariada: uma variável e Multivariada: várias variáveis (ex: temperatura, umidade, pressão)

Granularidade

year\month	1	2	3	4	5	6	7	8	9	10	11	12
1971	13.9	13.8	13.8	13.8	13.9	13.8	13.9	13.9	13.9	13.8	13.9	13.9
1972	13.7	13.7	14.0	14.0	13.9	14.0	14.0	14.0	13.9	14.0	14.0	14.0
1973	14.3	14.3	14.3	14.2	14.1	14.2	14.1	14.0	14.0	14.0	13.9	14.0
1974	13.8	13.7	13.9	13.9	13.9	13.8	13.9	14.0	13.9	13.8	13.8	13.8
1975	14.0	14.0	14.0	14.0	14.0	14.0	13.9	13.9	13.9	13.8	13.7	13.8
1976	13.9	13.8	13.8	13.9	13.8	13.9	13.9	13.9	13.9	13.7	13.9	14.0
1977	14.1	14.1	14.2	14.2	14.2	14.2	14.1	14.1	14.1	14.0	14.1	14.0
1978	14.1	14.1	14.1	14.0	14.0	14.0	14.0	13.9	14.0	14.0	14.1	14.0
1979	14.0	13.8	14.1	14.0	14.1	14.1	14.1	14.2	14.2	14.2	14.2	14.4
1980	14.3	14.3	14.2	14.2	14.3	14.2	14.2	14.1	14.1	14.1	14.2	14.1

(a)

year	value
1971	13.8
1972	13.9
1973	14.1
1974	13.8
1975	13.9
1976	13.9
1977	14.1
1978	14.0
1979	14.1
1980	14.2

(b)

Dimensionalidade

value
13.8
13.9
14.1
13.8
13.9
13.9
14.1
14.0
14.1
14.2

(a)

time	value
1971	13.8
1972	13.9
1973	14.1
1974	13.8
1975	13.9
1976	13.9
1977	14.1
1978	14.0
1979	14.1
1980	14.2

(b)

time	global temperature	crude oil production
1971	13.8	2491
1972	13.9	2634
1973	14.1	2870
1974	13.8	2875
1975	13.9	2740
1976	13.9	2966
1977	14.1	3069
1978	14.0	3108
1979	14.1	3229
1980	14.2	3111

(c)

Métodos de Detecção

- Estatísticos: regressão, testes de hipótese
- Aprendizado de Máquina: classificação, clustering
- Baseados em domínio: regras ou conhecimento especializado
- Divisão por abordagem:
  - Guiados por teoria
  - Orientados a dados

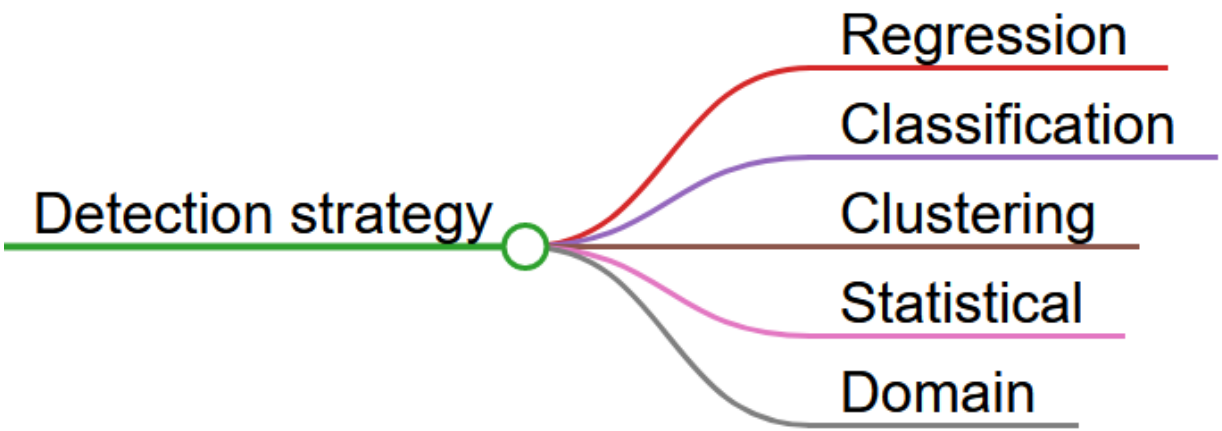

Cenários de Detecção

- Offline: análise após a coleta da série
- Online: detecção em tempo real, com chegada contínua de dados
- Predição de eventos: antecipação de eventos futuros com base no histórico

Offline

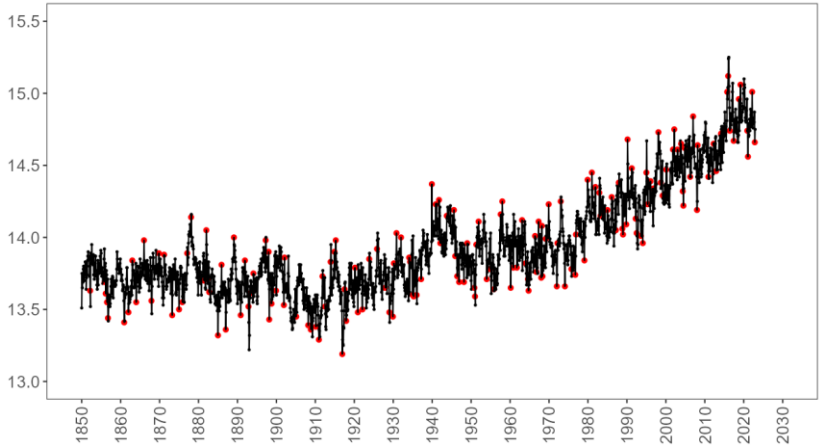

Online

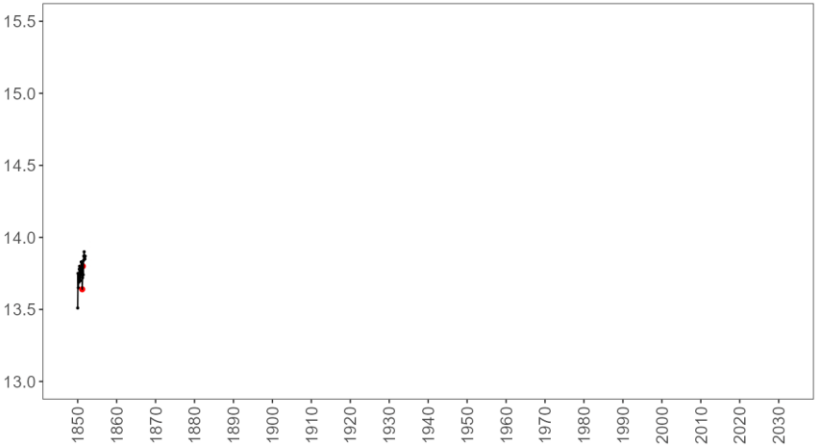

Avaliação de Métodos de Detecção

- Acurácia:
  - Precisão, Revocação (Recall), F1-score, AUC
- Desempenho Computacional:
  - Tempo de execução, uso de memória
- Desafios:
  - Falta de rótulos
  - Eventos com fronteiras temporais vagas
  - Vários tipos de eventos em uma mesma série

Visão Geral da Detecção de Eventos

- Processo de identificar intervalos significativos na série
- Aplicações em:
  - Diagnóstico industrial
  - Sismologia e petróleo
  - Clima e epidemias
  - Detecção de intrusos, fraudes, falhas
- Problemas atuais:
  - Foco em tipos específicos de eventos
  - Falta de abordagem unificada

Taxonomia da Detecção de Eventos

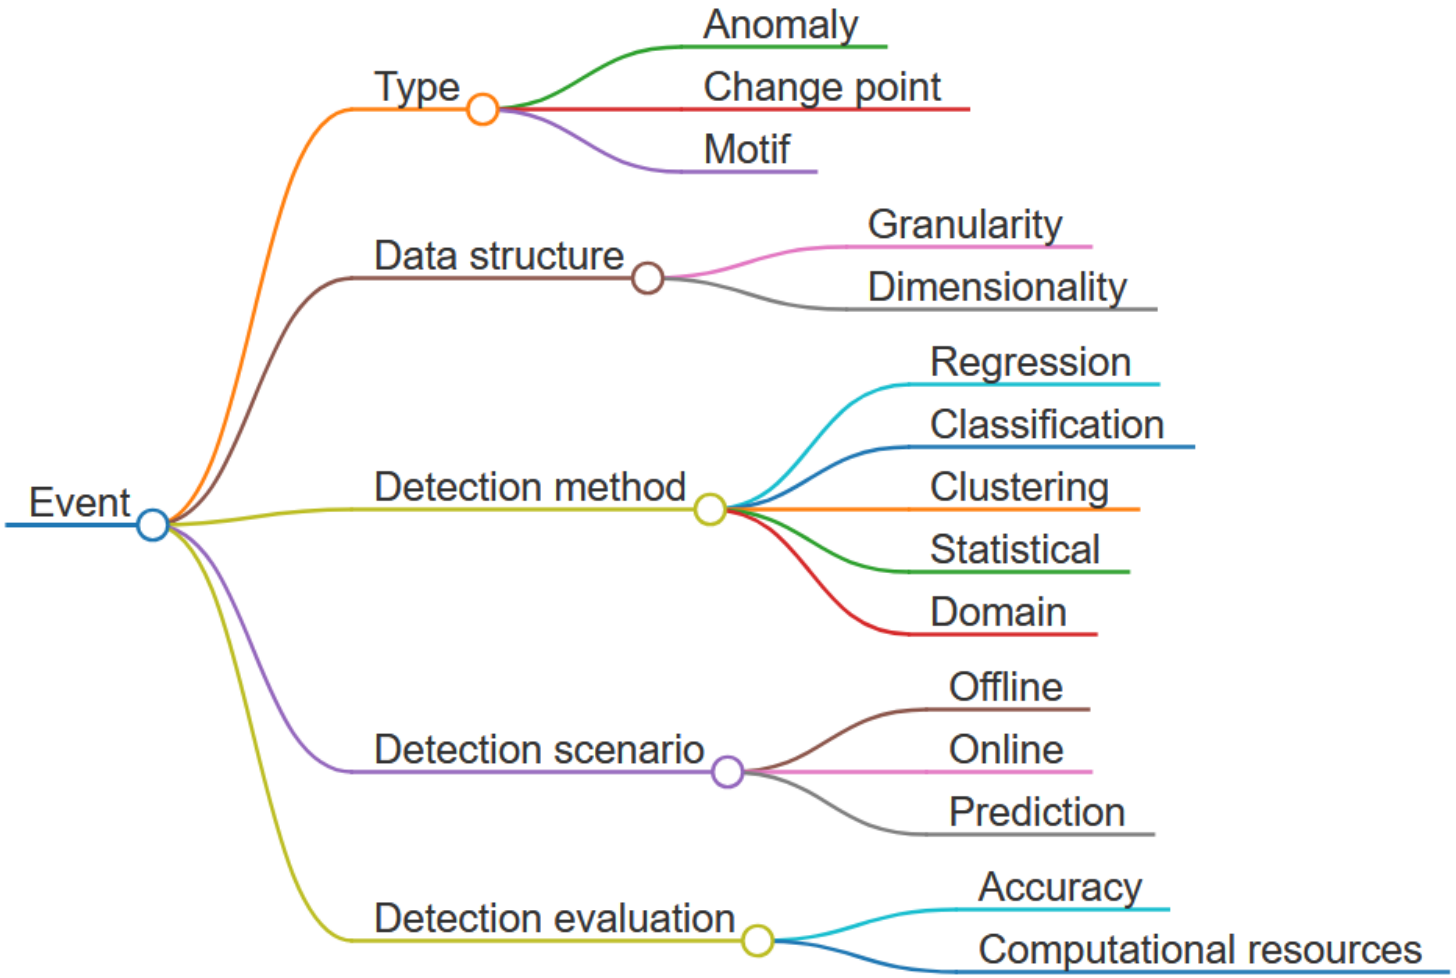

Resumo

- Eventos representam informações valiosas em séries temporais
- Existem múltiplas categorias e abordagens de detecção
- A detecção é desafiadora e envolve:
- Entendimento dos dados
- Escolha de métodos adequados
- Avaliação robusta
- O restante das aulas se aprofunda nos tipos e métodos de detecção

Referências

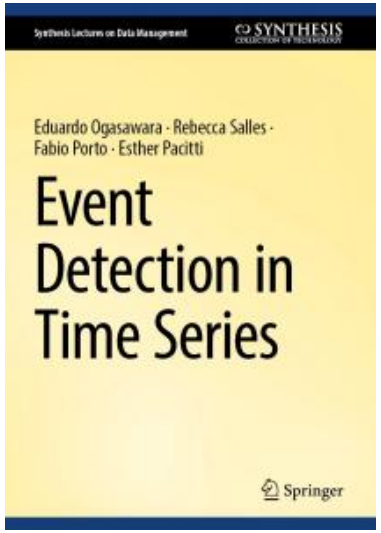

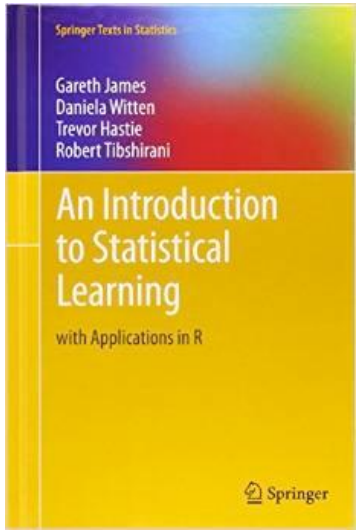

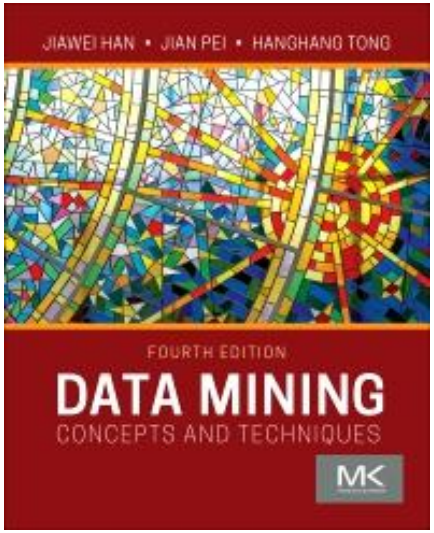

[1] Ogasawara, E.; Salles, R.; Porto, F.; Pacitti, E. Event Detection in Time Series. 1. ed. Cham: Springer Nature Switzerland, 2025.

[2] Cryer, J. D.; Chan, K.-S. Time Series Analysis: With Applications in R. Springer Science & Business Media, 2008.

[3] Han, J.; Pei, J.; Tong, H. Data Mining: Concepts and Techniques. 4th edition ed. Cambridge, MA: Morgan Kaufmann, 2022.

[4] James, G. M.; Witten, D.; Hastie, T.; Tibshirani, R. An Introduction to Statistical Learning: With Applications in R. [s.l.] Springer Nature, 2021.