




Séries Temporais para Predição e Detecção de Eventos

As Duas Perguntas do Curso

Dada uma série temporal, queremos responder duas perguntas: o que acontecerá depois? e quando algo relevante aconteceu ou está acontecendo?

Predição

Estimar valores futuros usando dependência temporal. O passado estrutura o futuro — modelos aprendem padrões para antecipar o que ainda não foi observado.

Detecção de Eventos

Identificar instantes ou intervalos em que o comportamento se desvia, muda ou se repete de forma relevante. Eventos são sinais que quebram ou confirmam padrões.

Todos os fundamentos desta aula — média, variância, autocorrelação, estacionariedade — servem a essas duas tarefas.

Série Temporal como Sequência de Observações

Uma série temporal é uma sequência ordenada de valores no tempo, onde cada observação está associada a um instante temporal específico. A ordem importa: o passado informa o futuro e define o contexto em que eventos ocorrem.

$$x_1, x_2, \dots, x_T$$

Onde x_t é o valor observado no instante t , e T é o número total de observações. A série também pode ser representada como função do tempo: $x(t)$.


Sequência Original

A ordem natural preserva a estrutura temporal: cada valor carrega a história do que veio antes e condiciona o que pode vir depois.

Após Permutação

Trocar a ordem destrói a estrutura temporal. Diferentemente de dados comuns, não podemos reorganizar os valores sem alterar o significado da informação.

Em dados tradicionais, a ordem não importa; em séries temporais, ela é fundamental. É a dependência entre observações consecutivas que torna possível prever valores futuros e detectar quando o comportamento muda.



Série Temporal como Função Discreta do Tempo

Função do Tempo

A série pode ser vista como uma função matemática que mapeia instantes de tempo em valores reais.

Matematicamente, definimos a série como uma função:

$$x : \mathcal{T} \rightarrow \mathbb{R}$$

Onde $\mathcal{T}$ é o conjunto de instantes de tempo (valores inteiros) e $\mathbb{R}$ é o conjunto dos números reais. Essa visão funcional permite tratar séries temporais com ferramentas matemáticas e probabilísticas.

Tempo Discreto

O tempo assume valores discretos, como dias, meses ou anos, não contínuos.

Valor Associado

Cada instante tem um único valor associado, formando a sequência temporal.

Processo Estocástico e Trajetória Observada

Pense no processo estocástico como um mecanismo gerador que nunca observamos diretamente — ele contém todas as trajetórias possíveis. A série observada é apenas uma delas: o caminho concreto que o processo tomou.

Processo Estocástico

$$\{X_t\}_{t=1}^T$$

Todas as trajetórias possíveis, descritas por um modelo probabilístico.


Trajetoória Observada

$$x_t = X_t(\omega)$$


O caminho concreto que o processo tomou — os dados que temos em mãos.

Nunca temos acesso ao processo gerador — só à trajetória que ele produziu. É por isso que predição e detecção de eventos são tarefas de inferência: a partir de uma única realização observada, tentamos reconstruir a estrutura do mecanismo subjacente e usá-la para antecipar o futuro ou identificar quando algo relevante aconteceu.


Processo estocástico e trajetória



Média constante



Média variável



Média do Processo Temporal

A média descreve o nível esperado da série em cada instante — é a referência em torno da qual os valores oscilam. Para predição, a média define o patamar que o modelo deve antecipar. Para detecção, desvios persistentes da média são sinais de que algo mudou.

$$\mu_t = \mathbb{E}[X_t]$$

Na prática, estimamos a média teórica pela média amostral da série observada. Quando essa média não muda com o tempo, o processo tem média estacionária — condição que permite usar o passado como referência confiável para o futuro.

Variância do Processo Temporal

Se a média mede o nível, a variância mede a incerteza. Ela indica o quanto os valores se afastam do esperado — e define a largura dos intervalos de predição. Variância elevada significa previsões menos precisas; variância que muda no tempo pode ser, ela própria, um sinal de evento.

Variância Teórica

$$\sigma_t^2 = \text{Var}(X_t)$$

Dispersão do processo no instante t .


Variância Amostral

$$s^2 = \frac{1}{T-1} \sum_{t=1}^T (x_t - \bar{x})^2$$


Estimativa calculada a partir dos dados.

Quando a variância muda ao longo do tempo, a série é instável e mais difícil de modelar. Variância constante é uma das condições de estacionariedade — e sua violação pode indicar mudança de regime ou evento relevante na série.

homocedasticidade



heterocedasticidade



Covariância e Autocovariância Temporal

Média e variância descrevem cada instante isoladamente. A autocovariância vai além: mede a memória temporal do processo — o quanto o valor em um instante depende do que aconteceu antes. Essa memória é o que modelos preditivos exploram para antecipar o futuro.

Instante $t-h$

O valor passado, separado por h períodos.

Defasagem h

O intervalo entre os dois instantes comparados.

Instante t

O valor presente.

A covariância entre dois instantes depende do intervalo entre eles — não dos instantes em si. Isso nos permite resumir toda a estrutura de dependência em uma única função da defasagem h , chamada função de autocovariância:

$$\gamma(h) = \text{Cov}(X_t, X_{t-h})$$

- ❏ Quanto maior a defasagem, menor tende a ser a dependência. Processos com memória longa mantêm autocovariância significativa mesmo para h grande.

A função $\gamma(h)$ é a base para medir autocorrelação e identificar padrões estruturais na série. Mudanças nessa estrutura ao longo do tempo são sinais potenciais de eventos — momentos em que a dinâmica do processo se alterou.

Autocorrelação

A autocovariância depende da escala da série, o que dificulta comparações. A autocorrelação resolve isso: normaliza a dependência para um intervalo entre -1 e 1, tornando a memória temporal comparável entre séries diferentes e interpretável diretamente.

Autocovariância

Mede dependência, mas na escala original dos dados.

Normalização

Dividimos pela variância para eliminar o efeito da escala.


Autocorrelação

Resultado padronizado, comparável entre séries diferentes.

$$\rho(h) = \frac{\gamma(h)}{\gamma(0)}$$

A autocorrelação é a principal ferramenta para quantificar a memória temporal de uma série. Modelos preditivos como AR exploram essa estrutura para antecipar valores futuros. Padrões incomuns na ACF — picos abruptos, quebras, mudanças de sinal — podem indicar eventos relevantes na série.

ACF



Autocorrelação Amostral

O processo real não é observável. Na prática, estimamos a autocorrelação diretamente a partir dos dados — obtendo a ACF amostral. Ela é o ponto de partida para identificar a memória temporal da série e escolher modelos preditivos adequados.

Autocovariância Amostral


$$\hat{\gamma}(h) = \frac{1}{T} \sum_{t=h+1}^T (x_t - \bar{x})(x_{t-h} - \bar{x})$$

Autocorrelação Amostral


$$\hat{\rho}(h) = \frac{\hat{\gamma}(h)}{\hat{\gamma}(0)}$$

A ACF amostral revela a estrutura de dependência presente nos dados. Modelos de predição usam essa estrutura para antecipar valores futuros. Mudanças na ACF ao longo do tempo — detectadas por janelas deslizantes ou testes estatísticos — são indicadores de eventos que alteraram a dinâmica da série.

Série simulada (AR(1), $\varphi = 0.6$)



ACF amostral (com bandas de confiança)



Estacionariedade

Uma série é estacionária quando suas propriedades estatísticas — média, variância e estrutura de dependência — permanecem estáveis ao longo do tempo. Estacionariedade não é apenas uma condição matemática: ela é o que permite usar o passado como evidência confiável para o futuro. Sem ela, o que aprendemos de um período pode não valer para outro.

Média Constante

$$\mathbb{E}[X_t] = \mu$$

A média não varia ao longo do tempo

Variância Constante

$$\text{Var}(X_t) = \sigma^2$$

A dispersão permanece estável


Autocovariância Dependente Apenas da Defasagem

$$\text{Cov}(X_t, X_{t-h}) = \gamma(h)$$


A dependência depende só do intervalo, não do tempo absoluto

Quando uma série não satisfaz essas condições, o passado não é uma guia confiável para o futuro — e a detecção de eventos fica comprometida, pois não há uma referência estável de comportamento normal. Por isso, verificar e garantir estacionariedade é o primeiro passo antes de modelar.

Ruído branco (estacionário)



Passeio aleatório (não estacionário)



Exemplos: Processos Estacionários e Não Estacionários

Processo Estacionário Ruído Branco

$$X_t = \varepsilon_t$$

Sem memória temporal, propriedades constantes no tempo


Processo Não Estacionário Passeio Aleatório

$$X_t = X_{t-1} + \varepsilon_t$$


Acumula choques, variância crescente ao longo do tempo

Onde ε_t é um termo aleatório com média zero e variância constante. O ruído branco representa um processo simples, mas com propriedades constantes. Já o passeio aleatório acumula choques, gerando variância crescente e ausência de estacionariedade. Esse contraste ajuda a entender por que muitas séries reais precisam ser transformadas antes da modelagem.

Ruído branco (estacionário)



Passeio aleatório (não estacionário)




Diferenciação como Transformação para Estacionariedade

Séries não estacionárias têm média ou variância que variam ao longo do tempo, tornando-as inadequadas para modelagem direta. A diferenciação é a transformação mais comum para estabilizar a série: ela subtrai cada observação da anterior, removendo tendências sistemáticas e tornando a série mais modelável.


$$Y_t = X_t - X_{t-1}$$

A diferenciação é uma ferramenta de preparação — ela transforma a série para que os fundamentos de estacionariedade se apliquem. Os detalhes operacionais de quando e como diferenciar, incluindo a escolha da ordem de diferenciação, serão aprofundados nas próximas apresentações.

Antes: passeio aleatório (não estacionário)



Depois: série diferenciada $\Delta X_t = X_t - X_{t-1}$



AR(1): Primeiro Modelo de Dependência Temporal

A Ideia

$$X_t = \phi X_{t-1} + \varepsilon_t$$

Memória Temporal

O valor atual carrega informação do passado.

Parâmetro ϕ

Controla a intensidade da dependência. Quanto maior $|\phi|$, mais forte a memória.

Ruído ε_t

Choque aleatório que impede a série de ser determinística.

AR(1) — Autorregressivo de Ordem 1

ENTRADA: x (série temporal, comprimento T)

PRÉ-CONDIÇÃO: série aproximadamente estacionária

PASSO 1 — Estimar o parâmetro

$$\phi \leftarrow \text{Cov}(x_t, x_{t-1}) / \text{Var}(x_{t-1})$$


PASSO 2 — Gerar valores ajustados

PARA t de 2 até T :


$$\hat{x}_t \leftarrow \phi \cdot x_{t-1} + \varepsilon_t$$

SAÍDA: $\hat{x}$ (valores ajustados pelo modelo AR(1))

Série AR(1) simulada ($\phi = 0.8$)



ACF amostral do AR(1)



AR(1): Condições e Propriedades

Estacionariedade

O processo AR(1) é estacionário quando $|\phi| < 1$. Nesse caso, os efeitos de choques passados diminuem ao longo do tempo e as propriedades estatísticas se estabilizam.

$$|\phi| < 1$$


Autocorrelação

A autocorrelação do AR(1) decai exponencialmente com a defasagem. Essa "assinatura" permite identificar o modelo a partir dos dados observados.

$$\rho(h) = \phi^h$$


O AR(1) é o primeiro exemplo concreto de como a dependência temporal pode ser formalizada e estimada. Ele ilustra os princípios que sustentam modelos mais complexos — AR de ordem superior, MA, ARMA e ARIMA — que serão aprofundados na apresentação 04.

Referências Bibliográficas




Event Detection in Time Series

Ogasawara, E.; Salles, R.; Porto, F.; Pacitti, E.
Springer Nature Switzerland, 2025.



Time Series Analysis: With Applications in R

Cryer, J. D.; Chan, K.-S. Springer, 2008.



Data Mining: Concepts and Techniques

Han, J.; Pei, J.; Tong, H. Morgan Kaufmann, 4^a ed., 2022.