

Séries Temporais: Previsão, Eventos e Estacionariedade



Eduardo Ogasawara

eogasawara@cefet-rj.br | <https://eic.cefet-rj.br/~eogasawara>



As Duas Perguntas do Curso

Dada uma série temporal, queremos responder duas perguntas: o que acontecerá depois? e quando algo relevante aconteceu ou está acontecendo?

Predição

Estimar valores futuros usando dependência temporal. O passado estrutura o futuro — modelos aprendem padrões para antecipar o que ainda não foi observado.

Todos os fundamentos desta aula — média, variância, autocorrelação, estacionariedade — servem a essas duas tarefas.

Detecção de Eventos

Identificar instantes ou intervalos em que o comportamento se desvia, muda ou se repete de forma relevante. Eventos são sinais que quebram ou confirmam padrões.

Série Temporal como Sequência de Observações

Uma série temporal é uma sequência ordenada de valores no tempo, onde cada observação está associada a um instante temporal específico. A ordem importa: o passado informa o futuro e define o contexto em que eventos ocorrem.

$$x_1, x_2, \dots, x_T$$

Onde x_t é o valor observado no instante t , e T é o número total de observações. A série também pode ser representada como função do tempo: $x(t)$.


Sequência Original

A ordem natural preserva a estrutura temporal: cada valor carrega a história do que veio antes e condiciona o que pode vir depois.

Após Permutação

Trocar a ordem destrói a estrutura temporal. Diferentemente de dados comuns, não podemos reorganizar os valores sem alterar o significado da informação.

Em dados tradicionais, a ordem não importa; em séries temporais, ela é fundamental. É a dependência entre observações consecutivas que torna possível prever valores futuros e detectar quando o comportamento muda.



Série Temporal como Função Discreta do Tempo

Função do Tempo

A série pode ser vista como uma função matemática que mapeia instantes de tempo em valores reais.

Matematicamente, definimos a série como uma função:

$$x : \mathcal{T} \rightarrow \mathbb{R}$$

Onde $\mathcal{T}$ é o conjunto de instantes de tempo (valores inteiros) e $\mathbb{R}$ é o conjunto dos números reais. Essa visão funcional permite tratar séries temporais com ferramentas matemáticas e probabilísticas.

Tempo Discreto

O tempo assume valores discretos, como dias, meses ou anos, não contínuos.

Valor Associado

Cada instante tem um único valor associado, formando a sequência temporal.

Processo Estocástico e Trajetória Observada

Pense no processo estocástico como um mecanismo gerador que nunca observamos diretamente — ele contém todas as trajetórias possíveis. A série observada é apenas uma delas: o caminho concreto que o processo tomou.

Processo Estocástico

$$\{X_t\}_{t=1}^T$$

Todas as trajetórias possíveis, descritas por um modelo probabilístico.


Trajetoória Observada

$$x_t = X_t(\omega)$$


O caminho concreto que o processo tomou — os dados que temos em mãos.

Nunca temos acesso ao processo gerador — só à trajetória que ele produziu. É por isso que predição e detecção de eventos são tarefas de inferência: a partir de uma única realização observada, tentamos reconstruir a estrutura do mecanismo subjacente e usá-la para antecipar o futuro ou identificar quando algo relevante aconteceu.


Processo estocástico e trajetória



Média constante



Média variável



Média do Processo Temporal

A média descreve o nível esperado da série em cada instante — é a referência em torno da qual os valores oscilam. Para predição, a média define o patamar que o modelo deve antecipar. Para detecção, desvios persistentes da média são sinais de que algo mudou.

$$\mu_t = \mathbb{E}[X_t]$$

Na prática, estimamos a média teórica pela média amostral da série observada. Quando essa média não muda com o tempo, o processo tem média estacionária — condição que permite usar o passado como referência confiável para o futuro.

Variância do Processo Temporal

Se a média mede o nível, a variância mede a incerteza. Ela indica o quanto os valores se afastam do esperado — e define a largura dos intervalos de predição. Variância elevada significa previsões menos precisas; variância que muda no tempo pode ser, ela própria, um sinal de evento.

Variância Teórica

$$\sigma_t^2 = \text{Var}(X_t)$$

Dispersão do processo no instante t .


Variância Amostral

$$s^2 = \frac{1}{T-1} \sum_{t=1}^T (x_t - \bar{x})^2$$


Estimativa calculada a partir dos dados.

Quando a variância muda ao longo do tempo, a série é instável e mais difícil de modelar. Variância constante é uma das condições de estacionariedade — e sua violação pode indicar mudança de regime ou evento relevante na série.

homocedasticidade



heterocedasticidade



Covariância e Autocovariância Temporal

Média e variância descrevem cada instante isoladamente. A autocovariância vai além: mede a memória temporal do processo — o quanto o valor em um instante depende do que aconteceu antes. Essa memória é o que modelos preditivos exploram para antecipar o futuro.

Instante $t-h$

O valor passado, separado por h períodos.

Defasagem h

O intervalo entre os dois instantes comparados.

Instante t

O valor presente.

A covariância entre dois instantes depende do intervalo entre eles — não dos instantes em si. Isso nos permite resumir toda a estrutura de dependência em uma única função da defasagem h , chamada função de autocovariância:

$$\gamma(h) = \text{Cov}(X_t, X_{t-h})$$

- ❏ Quanto maior a defasagem, menor tende a ser a dependência. Processos com memória longa mantêm autocovariância significativa mesmo para h grande.

A função $\gamma(h)$ é a base para medir autocorrelação e identificar padrões estruturais na série. Mudanças nessa estrutura ao longo do tempo são sinais potenciais de eventos — momentos em que a dinâmica do processo se alterou.

Autocorrelação

A autocovariância depende da escala da série, o que dificulta comparações. A autocorrelação resolve isso: normaliza a dependência para um intervalo entre -1 e 1, tornando a memória temporal comparável entre séries diferentes e interpretável diretamente.

Autocovariância

Mede dependência, mas na escala original dos dados.

Normalização

Dividimos pela variância para eliminar o efeito da escala.


Autocorrelação

Resultado padronizado, comparável entre séries diferentes.

$$\rho(h) = \frac{\gamma(h)}{\gamma(0)}$$

A autocorrelação é a principal ferramenta para quantificar a memória temporal de uma série. Modelos preditivos como AR exploram essa estrutura para antecipar valores futuros. Padrões incomuns na ACF — picos abruptos, quebras, mudanças de sinal — podem indicar eventos relevantes na série.

ACF



Autocorrelação Amostral

O processo real não é observável. Na prática, estimamos a autocorrelação diretamente a partir dos dados — obtendo a ACF amostral. Ela é o ponto de partida para identificar a memória temporal da série e escolher modelos preditivos adequados.

Autocovariância Amostral


$$\hat{\gamma}(h) = \frac{1}{T} \sum_{t=h+1}^T (x_t - \bar{x})(x_{t-h} - \bar{x})$$

Autocorrelação Amostral


$$\hat{\rho}(h) = \frac{\hat{\gamma}(h)}{\hat{\gamma}(0)}$$

A ACF amostral revela a estrutura de dependência presente nos dados. Modelos de predição usam essa estrutura para antecipar valores futuros. Mudanças na ACF ao longo do tempo — detectadas por janelas deslizantes ou testes estatísticos — são indicadores de eventos que alteraram a dinâmica da série.

Série simulada (AR(1), $\varphi = 0.6$)



ACF amostral (com bandas de confiança)



Estacionariedade

Uma série é estacionária quando suas propriedades estatísticas — média, variância e estrutura de dependência — permanecem estáveis ao longo do tempo. Estacionariedade não é apenas uma condição matemática: ela é o que permite usar o passado como evidência confiável para o futuro. Sem ela, o que aprendemos de um período pode não valer para outro.

Média Constante

$$\mathbb{E}[X_t] = \mu$$

A média não varia ao longo do tempo

Variância Constante

$$\text{Var}(X_t) = \sigma^2$$

A dispersão permanece estável


Autocovariância Dependente Apenas da Defasagem

$$\text{Cov}(X_t, X_{t-h}) = \gamma(h)$$


A dependência depende só do intervalo, não do tempo absoluto

Quando uma série não satisfaz essas condições, o passado não é uma guia confiável para o futuro — e a detecção de eventos fica comprometida, pois não há uma referência estável de comportamento normal. Por isso, verificar e garantir estacionariedade é o primeiro passo antes de modelar.

Ruído branco (estacionário)



Passeio aleatório (não estacionário)



Exemplos: Processos Estacionários e Não Estacionários

Processo Estacionário Ruído Branco

$$X_t = \varepsilon_t$$

Sem memória temporal, propriedades constantes no tempo


Processo Não Estacionário Passeio Aleatório

$$X_t = X_{t-1} + \varepsilon_t$$


Acumula choques, variância crescente ao longo do tempo

Onde ε_t é um termo aleatório com média zero e variância constante. O ruído branco representa um processo simples, mas com propriedades constantes. Já o passeio aleatório acumula choques, gerando variância crescente e ausência de estacionariedade. Esse contraste ajuda a entender por que muitas séries reais precisam ser transformadas antes da modelagem.

Ruído branco (estacionário)




Passeio aleatório (não estacionário)




Tipos de não estacionaridade


- Tendência determinística desloca a média ao longo do tempo.
- Quebras estruturais produzem mudanças de nível.
- Heteroscedasticidade altera a variância.
- Raiz unitária produz comportamento difference stationary.




(a) stationary




(b) trend stationary



(c) level stationary



(d) heteroscedastic




(e) random walk

Impacto na detecção de eventos


- Não estacionaridade pode parecer anomalia.
- Mudanças de nível podem ser confundidas com outliers persistentes.
- Sazonalidade não tratada pode gerar falsos positivos periódicos.
- Pré-processamento adequado reduz essas ambiguidades.

Referências Bibliográficas




Event Detection in Time Series

Ogasawara, E.; Salles, R.; Porto, F.; Pacitti, E.
Springer Nature Switzerland, 2025.



Time Series Analysis: With Applications in R

Cryer, J. D.; Chan, K.-S. Springer, 2008.



Data Mining: Concepts and Techniques

Han, J.; Pei, J.; Tong, H. Morgan Kaufmann, 4^a ed., 2022.