



# Estrutura Temporal em Séries Temporais

Séries temporais raramente são aleatórias. Elas apresentam padrões sistemáticos que revelam propriedades ao longo do tempo. A estrutura temporal é composta por componentes fundamentais: média, periodicidade, dependência e ruído.


Eduardo Ogasawara

[eduardo.ogasawara@cefet-rj.br](mailto:eduardo.ogasawara@cefet-rj.br)

<https://eic.cefet-rj.br/~eogasawara>

# Decomposição de Séries Temporais

A decomposição de séries temporais é um método fundamental para entender a estrutura subjacente dos dados ao longo do tempo, separando-os em componentes sistemáticos e irregulares.



## Decomposição Aditiva

Utilizada quando os componentes (tendência, sazonalidade, cíclico e ruído) têm uma magnitude constante, ou seja, suas flutuações não aumentam nem diminuem com o nível da série.

$$X_t = T_t + S_t + C_t + \varepsilon_t$$

Adequada para séries onde a variabilidade e a amplitude das flutuações sazonais são constantes ao longo do tempo.

A escolha entre a decomposição aditiva e multiplicativa depende da natureza da variabilidade observada na série: se a amplitude das flutuações permanece constante ou muda proporcionalmente com o nível da série.

## Decomposição Multiplicativa

Aplicada quando os componentes interagem de forma proporcional, o que significa que a magnitude das flutuações sazonais e do ruído aumenta ou diminui com o nível da série.

$$X_t = T_t \times S_t \times C_t \times \varepsilon_t$$

Adequada para séries com variabilidade crescente ou decrescente ao longo do tempo. Uma transformação logarítmica pode converter este modelo em aditivo, facilitando a análise.

 TENDÊNCIA

# Tendência: Conceito e Definição


A tendência representa a variação sistemática de longo prazo em uma série temporal. Ela indica mudanças estruturais na média ao longo do tempo, associadas a processos de crescimento ou declínio.

Matematicamente, a tendência pode ser definida como o valor esperado da série:

$$T_t = \mathbb{E}[X_t]$$

Em séries não estacionárias, essa média varia com o tempo, refletindo transformações estruturais do processo gerador dos dados. Identificar a tendência é essencial para separar movimentos permanentes de flutuações transitórias.

# Modelos de Tendência



## Tendência Linear

Crescimento ou declínio constante ao longo do tempo

$$T_t = \alpha + \beta t$$



## Tendência Polinomial

Variações não lineares descritas por funções polinomiais



## Tendência Estocástica


Evolução aleatória acumulativa

$$T_t = T_{t-1} + u_t$$

Modelos de tendência podem ser determinísticos, quando definidos por funções explícitas do tempo, ou estocásticos, quando evoluem de forma aleatória. Essa distinção é fundamental para definir métodos adequados de estimação e transformação da série.

# Sazonalidade: Padrões Periódicos

Sazonalidade: padrão periódico ( $s = 12$ )



A sazonalidade corresponde a padrões que se repetem regularmente ao longo do tempo, como variações mensais, trimestrais ou semanais. Diferentemente da tendência, não representa mudança estrutural permanente.

A condição formal de periodicidade é expressa por:

$$S_{t+s} = S_t$$


Onde  $s$  representa o período sazonal. Essa propriedade distingue a sazonalidade de outros componentes temporais.

# Períodos Sazonais Comuns



**Dados Mensais**

Sazonalidade anual em séries com observações mensais



**Dados Trimestrais**

Padrão anual em séries trimestrais



**Dados Semanais**

Padrão semanal em dados diários

O período sazonal  $s$  depende da frequência de observação da série. Esses valores formalizam a periodicidade e permitem incorporar a sazonalidade nos modelos estatísticos de forma precisa.

## COMPONENTES ESTRUTURAIS

# Componente Cíclica

### Oscilações de Médio e Longo Prazo

A componente cíclica descreve oscilações que não se repetem em intervalos regulares, diferentemente da sazonalidade.

### Sem Periodicidade Fixa


Associada a fenômenos como ciclos econômicos ou tecnológicos, sem padrão temporal constante.

### Modelagem Complexa

Por não possuir periodicidade constante, requer abordagens estatísticas e econômicas específicas.

A componente cíclica pode ser representada por  $C_t \approx f(t)$ , onde  $f(t)$  é uma função do tempo sem periodicidade fixa.

# Componente Aleatória: O Ruído




A componente aleatória representa flutuações imprevisíveis que não podem ser explicadas por tendência, sazonalidade ou ciclos. É o ruído inerente ao processo observado.

Em modelos clássicos, assume-se que o ruído tem média zero e variância constante:

$$\mathbb{E}[\varepsilon_t] = 0, \quad \text{Var}(\varepsilon_t) = \sigma^2$$


Essas hipóteses simplificam a análise, mas podem ser relaxadas em modelos mais sofisticados que capturam heterocedasticidade e dependência temporal no ruído.

# Interação de Componentes



## Tendência

Movimento de longo prazo



## Sazonalidade

Padrões periódicos


## Ciclos

Oscilações não periódicas

A estrutura temporal emerge da interação entre componentes sistemáticas e aleatórias. A decomposição  $X_t = T_t + S_t + C_t + \varepsilon_t$  mostra que a série observada resulta de movimentos persistentes e flutuações transitórias.

Essa visão estrutural é o ponto de partida para a modelagem estatística, permitindo separar fenômenos de diferentes naturezas temporais.

# Tendência Determinística vs. Estocástica



## Tendência Determinística

Descrita por uma função explícita do tempo:

$$X_t = f(t) + \varepsilon_t$$

Representa crescimento ou declínio previsível e sistemático. Pode ser removida por regressão no tempo.

## Tendência Estocástica

Evolui de forma aleatória, acumulando choques:

$$X_t = X_{t-1} + u_t$$

Representa mudanças imprevisíveis que se acumulam ao longo do tempo. Requer diferenciação para remoção.


Essa distinção é central na análise de séries temporais, pois determina os métodos de remoção da tendência e influencia diretamente a modelagem e inferência estatística.

⚠ NÃO ESTACIONARIEDADE


# Estrutura Temporal e Não Estacionariedade

Mesmo que o ruído seja estacionário, a presença de tendência ou sazonalidade torna a série observada não estacionária. Isso ocorre porque a média ou a estrutura da série muda ao longo do tempo.

Série original: tendência e sazonalidade



Após diferenças (sazonal e regular)



1

## Série Original

$$X_t = T_t + S_t + \varepsilon_t$$

2

## Componentes Variáveis

Se  $T_t$  ou  $S_t$  varia no tempo

3

## Não Estacionariedade

$X_t$  não é estacionária


Por esse motivo, a análise de séries temporais frequentemente começa com transformações destinadas a remover componentes estruturais antes da modelagem.

# Remoção da Tendência

01

## Ajuste de Tendência

Estimação da componente de tendência  $\hat{T}_t$  por regressão



02

## Subtração

Remoção da tendência:  $Y_t = X_t - \hat{T}_t$

03

## Diferenciação

Alternativa:  $Y_t = X_t - X_{t-1}$


04

## Série Transformada

Aproximação da estacionariedade

A subtração da tendência estimada elimina movimentos de longo prazo, enquanto a diferenciação elimina variações acumulativas. Essas transformações são fundamentais para aproximar a série de um comportamento estacionário.

# Remoção da Sazonalidade



A dessazonalização consiste em remover padrões periódicos da série, isolando variações não explicadas pela sazonalidade. Este procedimento permite analisar a dinâmica subjacente do processo.



A dessazonalização pode ser expressa por:

$$Y_t = X_t - \hat{S}_t$$

Onde  $Y_t$  é a série dessazonalizada,  $X_t$  é a série original e  $\hat{S}_t$  é a sazonalidade estimada.

Assim como na remoção da tendência, a dessazonalização é um passo preparatório essencial para a modelagem estatística.

# Autocovariância e Autocorrelação

**ACF: dependência temporal AR(1)****PACF: assinatura do AR(1)**

## Autocovariância

Mede a associação entre valores separados por uma defasagem temporal:

$$\gamma(h) = \text{Cov}(X_t, X_{t-h})$$


## Autocorrelação

Normaliza a autocovariância:


$$\rho(h) = \frac{\gamma(h)}{\gamma(0)}$$

A forma da função de autocorrelação revela a estrutura de dependência do processo e orienta a escolha de modelos temporais apropriados.

ACF: dependência temporal AR(1)



PACF: assinatura do AR(1)



# Dependência de Curta e Longa Duração

## Curta Duração

A autocorrelação decai rapidamente:

$$\rho(h) \rightarrow 0 \quad \text{rapidamente}$$

Caracteriza processos com memória limitada, onde o passado distante tem pouca influência sobre o presente.

Essa distinção é importante porque diferentes classes de modelos são necessárias para capturar esses padrões de dependência temporal.

## Longa Duração


O decaimento é lento e hiperbólico:

$$\rho(h) \sim h^{-\alpha}, \quad 0 < \alpha < 1$$


Indica persistência temporal elevada, onde eventos passados mantêm influência prolongada.

# Modelos Autoregressivos (AR)

Decaimento rápido (AR(1),  $\phi = 0.5$ )



Decaimento muito lento (AR(1),  $\phi = 0.98$ )



O modelo autoregressivo expressa que o valor atual da série depende de valores passados. É uma formalização matemática da dependência temporal observada nos dados.

Um modelo autoregressivo de ordem 1 é dado por:

$$X_t = \phi X_{t-1} + \varepsilon_t$$

---

## Parâmetro Autoregressivo

O coeficiente  $\phi$  controla o grau de persistência temporal da série

---


## Termo Aleatório

$\varepsilon_t$  representa choques não explicados por valores passados

---

## Estabilidade

A condição  $|\phi| < 1$  garante que o processo seja estacionário



## Modelos de Médias Móveis (MA)

Nos modelos de médias móveis, a dependência temporal surge da influência de choques passados sobre o valor atual da série.

Um modelo MA de ordem 1 é representado por:


$$X_t = \varepsilon_t + \theta \varepsilon_{t-1}$$

Diferentemente dos modelos AR, a dependência não ocorre diretamente entre observações, mas entre termos aleatórios. O parâmetro  $\theta$  controla a memória do ruído.

A combinação de modelos AR e MA permite representar uma ampla variedade de estruturas temporais complexas.

# Estrutura Temporal e Eventos

Eventos em séries temporais podem ser entendidos como desvios em relação à estrutura temporal estimada. Esses desvios podem ocorrer na média, na variância ou na dependência temporal.



## Rupturas na Tendência

Mudanças abruptas no comportamento de longo prazo da série

## Mudanças na Dependência

Alterações na estrutura de autocorrelação temporal

## Anomalias Locais

Observações que se desviam significativamente do padrão esperado

Um evento pode ser interpretado como  $X_t \neq \hat{X}_t$ , onde  $\hat{X}_t$  é o valor esperado segundo a estrutura temporal. A identificação de eventos depende da existência de um modelo estrutural que funcione como referência.

# Referências Bibliográficas

Uma coleção cuidadosamente selecionada de obras fundamentais que abordam análise de séries temporais e mineração de dados.



## Event Detection in Time Series

**Ogasawara, E.; Salles, R.; Porto, F.; Pacitti,**

**E.** (2025). Publicação recente da Springer Nature Switzerland que explora técnicas avançadas de detecção de eventos em séries temporais.

## Time Series Analysis: With Applications in R

**Cryer, J. D.; Chan, K.-S.** (2008). Obra clássica da Springer que combina fundamentação teórica sólida com implementações práticas.

## Data Mining: Concepts and Techniques

**Han, J.; Pei, J.; Tong, H.** (2022). Quarta edição publicada pela Morgan Kaufmann que consolida conceitos fundamentais e técnicas avançadas de mineração de dados