



**CEFET/RJ**

# **Séries Temporais**



**Eduardo Ogasawara**


eduardo.ogasawara@cefet-rj.br

<https://eic.cefet-rj.br/~eogasawara>


# Introdução às Séries Temporais

- Sequência de observações ordenadas no tempo
  - $X = \langle x_1, x_2, \dots, x_n \rangle$
- Pode ser univariada ou multivariada
- Representa fenômenos dinâmicos em domínios como economia, saúde, clima etc.
- Frequência (regularidade de coleta)

Mensal




Anual




# Componentes de Séries Temporais

- Tendência: variação de longo prazo ( $\beta_t$ )
- Sazonalidade: padrões que se repetem em intervalos regulares ( $\pi_t$ )
- Ruído: variações aleatórias não explicadas pelos outros componentes ( $\omega_t$ )
- $x_t = \beta_t + \pi_t + \omega_t$




# Estacionariedade


- Média e variância constante independente do tempo
- Autocovariância  $\gamma(X_s, X_t)$  só depende de  $|s - t|$




(a) stationary




(b) trend stationary



(c) level stationary



(d) heteroscedastic



(e) random walk


## *Testes de Estacionariedade*

- Testes comuns: ADF (Dickey-Fuller), Phillips–Perron test, Breusch–Pagan test


Time series	ADFT	PPT	BPT
stationary			
trend stationary			
level stationary	X		
heteroscedastic			X
difference stationary	X	X	X
YGT			X

# Autocorrelação


- Mede a relação entre valores atuais e seus defasados
- Utilizada para identificar padrões temporais, como periodicidade e dependência
- Representada por gráficos de autocorrelação (ACF)




(a) - stationary




(b) - trend stationary




(c) - level stationary



(d) - heteroscedastic



(e) - random walk



(f) - YGT


## ***Pré-processamento de Séries Temporais***

---

- Etapa crítica para garantir qualidade dos dados
- Envolve:
  - Suavização
  - Diferenciação
  - Normalização/padronização
  - Agregação temporal

# Suavização de Séries Temporais

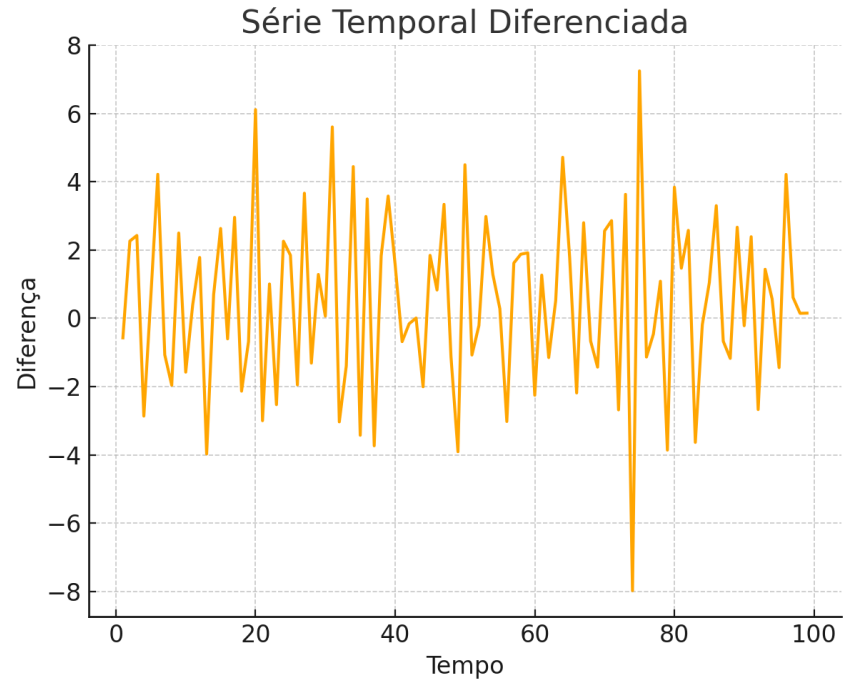

- Reduz a variabilidade de curto prazo
- Evidencia padrões de longo prazo
- Exemplos:
  - Média móvel
  - Média móvel exponencialmente ponderada






# ***Diferenciação e Estacionariedade***

- Subtrai o valor anterior do atual
- Remove tendência ou ciclo, tornando a série mais estacionária
- Muito usada em modelos ARIMA



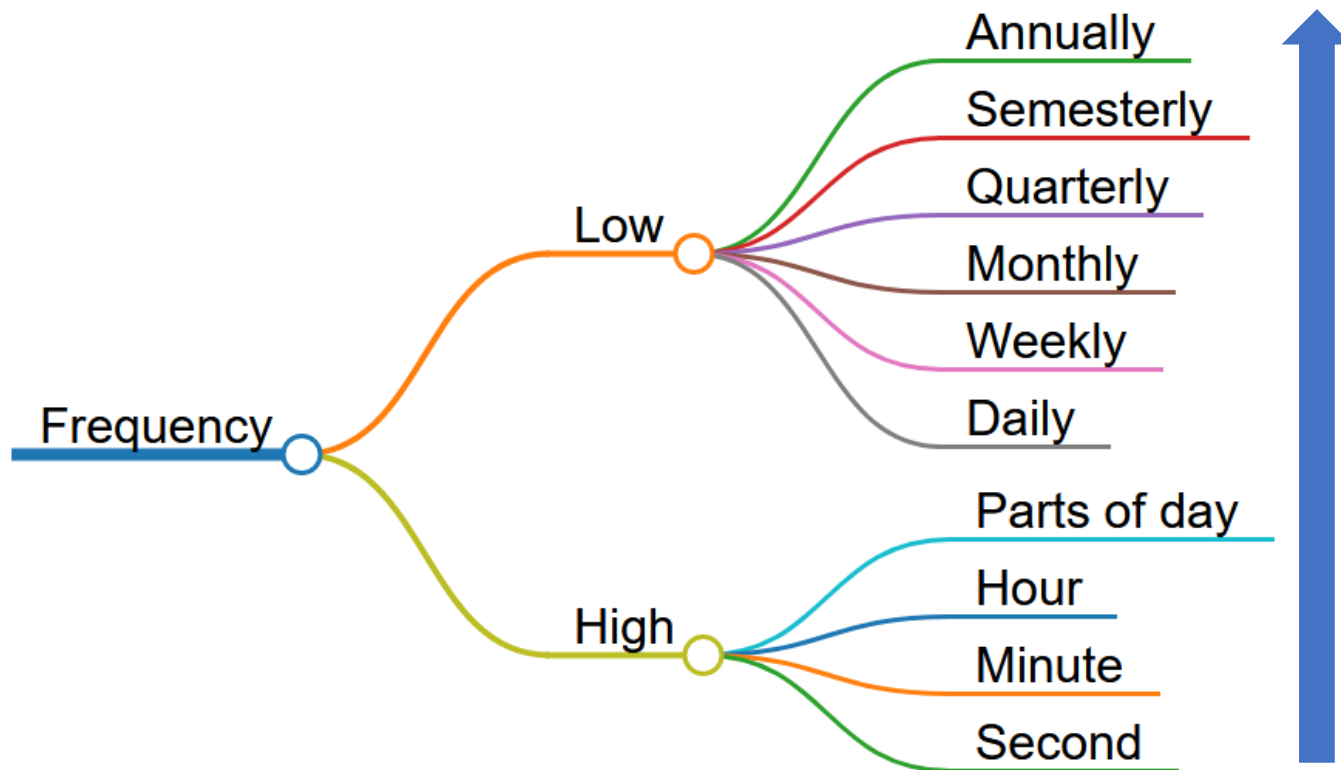
# Normalização e Padronização

- Normalização: reescala os dados para intervalo [0, 1]
- Padronização: transforma dados para média 0 e desvio padrão 1
  - Min-Max:  $y_t = \frac{x_t - x_{min}}{x_{max} - x_{min}}$  e Z-Score:  $y_t = \frac{x_t - \bar{X}}{\sigma_X}$
  - Global vs. SW
    - Normalização adaptativa





## ***Agregação temporal***

- Converte dados de maior para menor frequência (ex: minuto → hora)
- Reduz granularidade e facilita análise
- Permite análise em múltiplos níveis temporais




## *Modelagem Simples de Tendência*

- Regressão linear: ajusta uma reta à série
- Média móvel: suaviza ruído para destacar tendência
- Auxilia na identificação do comportamento de longo prazo




# Tratamento de tendência


- Estratégias para remover tendência antes da modelagem:
  - Resíduo da regressão linear
  - Resíduo da média móvel
  - Diferenciação
  - Variação percentual




(a) LR trend removal



(b) MAS trend removal





(c) First order differencing



(d) PCT


## *Tratamento de variância*

- Transforma séries com variância crescente ou decrescente
- Técnicas:
  - Logaritmo natural
  - Transformação Box-Cox (BCT)




# Decomposição no domínio da frequência


## FFT



(a): 90 harmonics




(c): 9 harmonics




(d)


## Wavelet



(a) using all  $\zeta$  and  $\psi$  components




(b)  $3\zeta$  components




(c)  $3\psi$  components


## EMD



(a) EMD with 7 components




(b) last IMF + residual



(c) first five IMF

## Janelas deslizantes




- Divide a série em subsequências fixas ao longo do tempo
- Base para entrada em modelos de aprendizado de máquina
- Útil para extração de padrões locais






# Predição em Séries Temporais

- Objetivo: prever valores futuros com base no histórico
- Estratégias:
  - Predição passo a passo (rolling)
  - Predição de múltiplos passos à frente
  - Requer validação temporal adequada



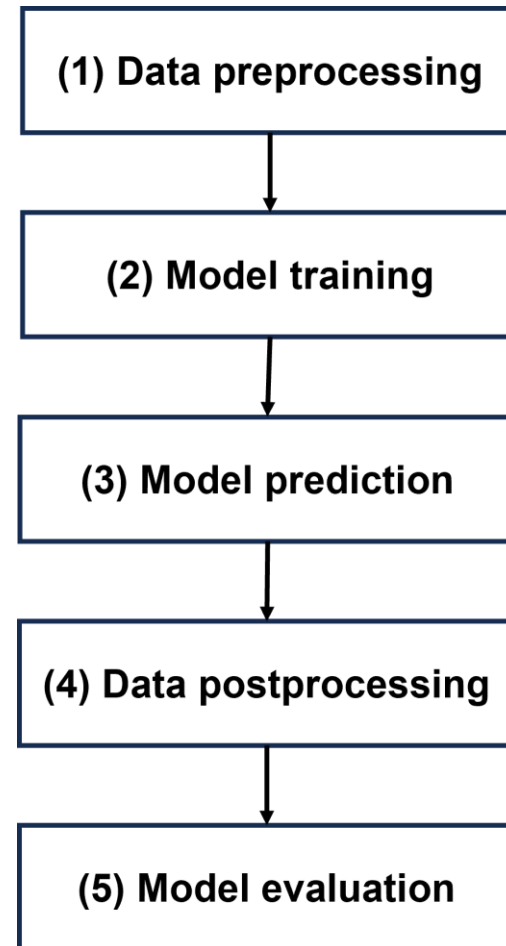
# *Separação Temporal de Treino e Teste*

- Manter a ordem cronológica dos dados
- Técnicas:
  - Holdout temporal
  - Validação cruzada com janelas (TimeSeriesSplit)
- Evita vazamento de informação do futuro para o passado




# ***Workflow de predição em Séries Temporais***

- Etapas típicas de predição:
  - Pré-processamento: limpeza, transformação, diferenciação
  - Treinamento do modelo: ARIMA, redes neurais, regressão etc.
  - Predição do modelo: geração de valores futuros
  - Pós-processamento: dessazonalização, inversão de escala
  - Avaliação: erro quadrático médio (RMSE), MAE, MAPE




# Modelagem com ARIMA

- Modelo estatístico tradicional:  $ARIMA(p, d, q)$
- $p$ : autorregressão
- $d$ : diferenciação
- $q$ : média móvel
- Requer estacionariedade
- Boas práticas: identificar parâmetros via ACF/PACF, validação cruzada




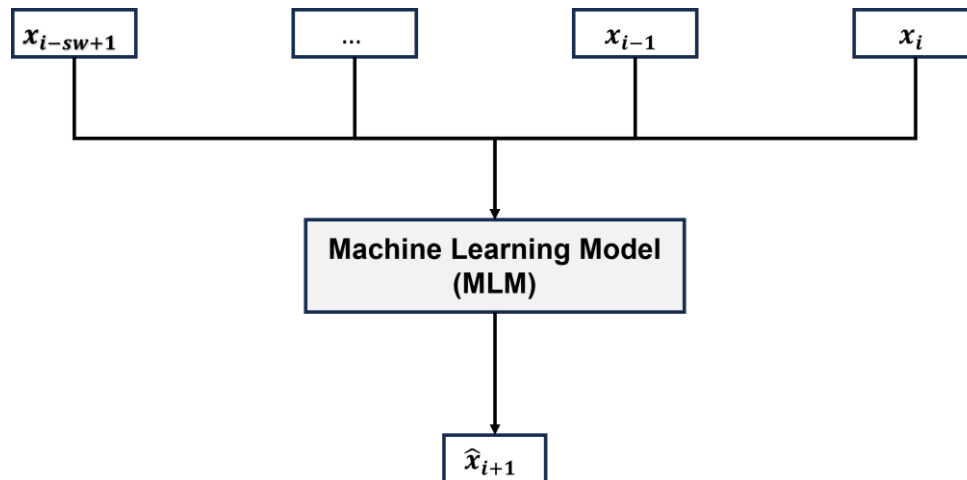
(a) ARIMA(1, 1, 3) four-step-ahead prediction




(b) ARIMA(1, 1, 3) model adjustment

# Modelagem com Aprendizado de Máquina

- Capturam padrões não lineares e alta complexidade
- Métodos comuns para predição de séries temporais:
  - ELM (Extreme Learning Machines), MLP (Perceptron Multicamadas)
  - RRF (Random Rotation Forests), SVR (Support Vector Regression)
  - Conv1D (Convolutacional 1D) , LSTM (Long Short-Term Memory)



(a) LSTM four-step-ahead prediction





(b) LSTM model adjustment

## ***Resumo do Capítulo***

---

- Revisamos:
- Conceitos, tipos e componentes de séries temporais
- Estratégias de pré-processamento
- Fundamentos de modelagem e predição
- O entendimento desses fundamentos é essencial para tarefas de detecção de eventos e mineração de dados temporais

# Referências



- [1] Ogasawara, E.; Salles, R.; Porto, F.; Pacitti, E. Event Detection in Time Series. 1. ed. Cham: Springer Nature Switzerland, 2025.
- [2] Cryer, J. D.; Chan, K.-S. Time Series Analysis: With Applications in R. Springer Science & Business Media, 2008.
- [3] Han, J.; Pei, J.; Tong, H. Data Mining: Concepts and Techniques. 4th edition ed. Cambridge, MA: Morgan Kaufmann, 2022.
- [4] James, G. M.; Witten, D.; Hastie, T.; Tibshirani, R. An Introduction to Statistical Learning: With Applications in R. [s.l.] Springer Nature, 2021.

