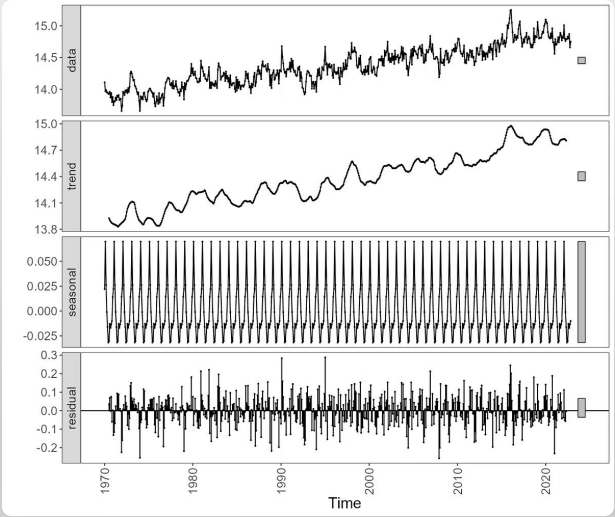
Decomposição de Séries Temporais: Tendência, Sazonalidade e Ruído

CEFET/RJ

Eduardo Ogasawara

eogasawara@cefet-rj.br | https://eic.cefet-rj.br/~eogasawara

Decomposição de Séries Temporais



A Ideia Central

A decomposição separa X_t em componentes interpretáveis. Cada componente representa um aspecto distinto do comportamento temporal. A forma de combinação depende do comportamento das amplitudes ao longo do tempo.

$$X_t = T_t + S_t + \varepsilon_t$$

- T_t — **tendência**: comportamento de longo prazo
- S_t — **sazonalidade**: padrões cíclicos regulares de período s
- ε_t — **resíduo**: variações não explicadas pelos demais componentes

Modelo aditivo: amplitudes constantes ao longo do tempo. **Modelo multiplicativo:** amplitudes proporcionais ao nível — equivalente ao aditivo após $\log(X_t)$.

O resíduo ε_t concentra o que não foi capturado pela estrutura — é nele que podem se manifestar eventos e anomalias.

ENTRADA: x_t (t = 1,...,T), s (período sazonal), modelo ∈ {aditivo, multiplicativo}
PRÉ-CONDIÇÃO: s conhecido; modelo escolhido com base no gráfico da série

PASSO 1 — Estimar tendência
T̂_t ← média móvel de x_t com janela s

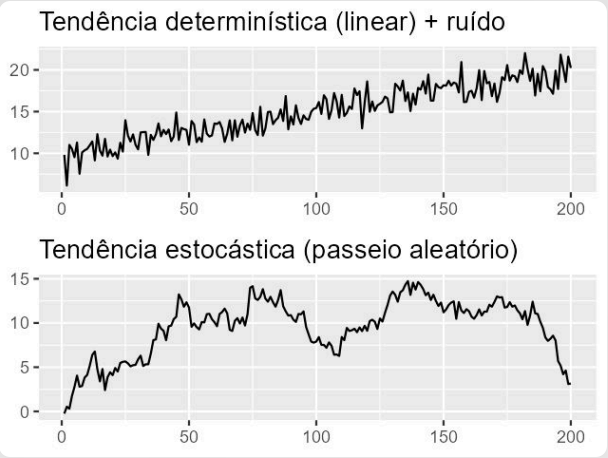
PASSO 2 — Estimar sazonalidade
r_t ← x_t − T̂_t (aditivo) | x_t / T̂_t (multiplicativo)
Ŝ_p ← média de r_t com (t mod s) = p, p = 1,...,s
Normalizar Ŝ: soma zero (aditivo) ou produto 1 (multiplicativo)

PASSO 3 — Obter resíduo
ε_t ← x_t − T̂_t − Ŝ_t (aditivo) | x_t / (T̂_t · Ŝ_t) (multiplicativo)

SAÍDA: T̂_t, Ŝ_t, ε_t para cada t
PÓS-CONDIÇÃO: ε_t sem padrão sistemático e aproximadamente estacionário

Modelos de Tendência

A tendência representa a variação sistemática de longo prazo em uma série temporal — o valor esperado $T_t = \mathbb{E}[X_t]$ que muda ao longo do tempo em séries não estacionárias. Identificá-la é essencial para separar movimentos permanentes de flutuações transitórias.



Tendência Linear

Crescimento ou declínio constante ao longo do tempo

$$T_t = \alpha + \beta t$$

Tendência Polinomial

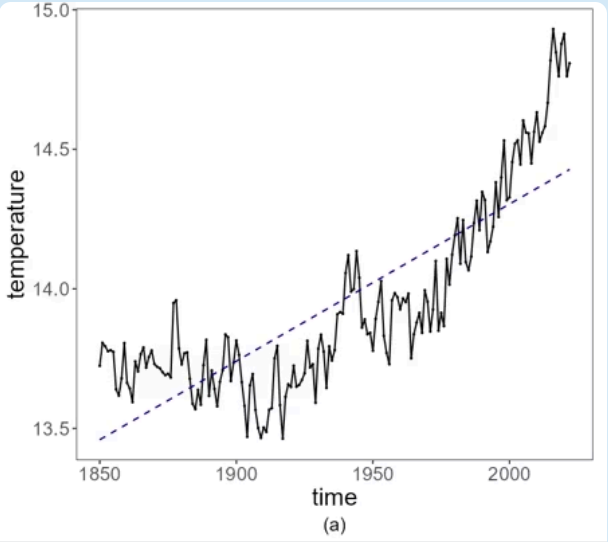
Variações não lineares descritas por funções polinomiais

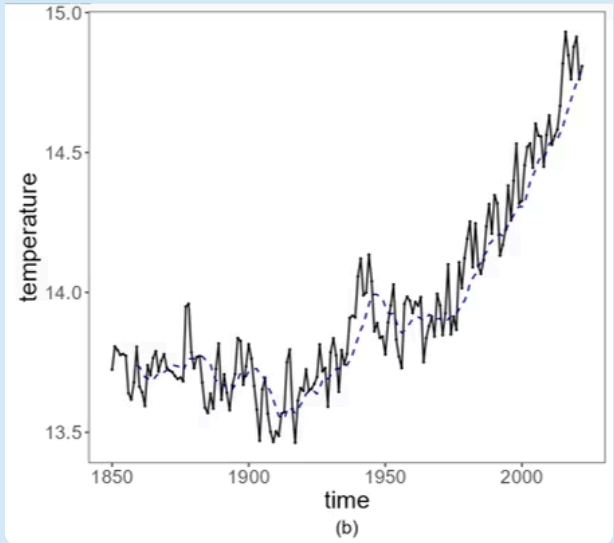
Tendência Estocástica

Evolução aleatória acumulativa

$$T_t = T_{t-1} + u_t$$

Modelos de tendência podem ser determinísticos, quando definidos por funções explícitas do tempo, ou estocásticos, quando evoluem de forma aleatória. Essa distinção é fundamental para definir métodos adequados de estimação e transformação da série.





Regressão linear e média móvel

Regressão linear

- Assume uma forma global simples.
- Boa para tendência aproximadamente linear.
- Facilita interpretação.

Média móvel

- Usa vizinhança local.
- Suaviza ruído de curto prazo.
- Depende do tamanho da janela.



Sazonalidade: Padrões Periódicos

A sazonalidade corresponde a padrões que se repetem regularmente ao longo do tempo, como variações mensais, trimestrais ou semanais. Diferentemente da tendência, não representa mudança estrutural permanente.

A condição formal de periodicidade é expressa por:

$$S_{t+s} = S_t$$

Onde s representa o período sazonal. Essa propriedade distingue a sazonalidade de outros componentes temporais.

Períodos Sazonais Comuns

Dados Mensais

Sazonalidade anual em séries com observações mensais — período s = 12

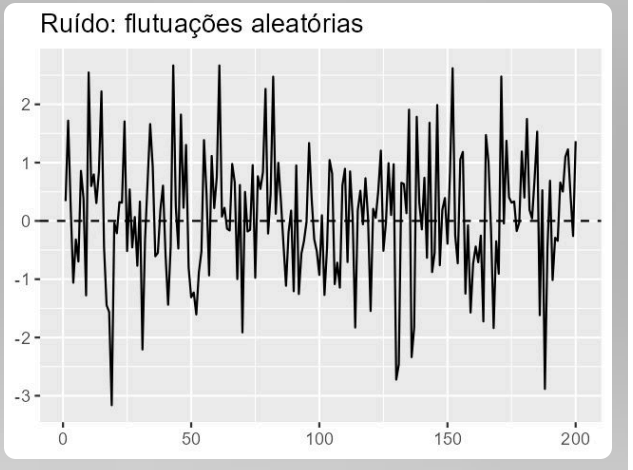
Dados Trimestrais

Padrão anual em séries trimestrais — período s = 4

Dados Semanais

Padrão semanal em dados diários — período s = 7

O período sazonal s depende da frequência de observação da série. Esses valores formalizam a periodicidade e permitem incorporar a sazonalidade nos modelos estatísticos de forma precisa.



Componente Aleatória: O Ruído

A componente aleatória representa flutuações imprevisíveis que não podem ser explicadas por tendência, sazonalidade ou ciclos. É o ruído inerente ao processo observado.

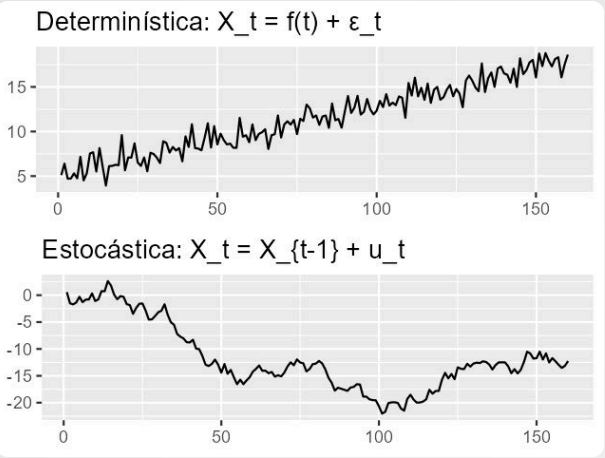
Em modelos clássicos, assume-se que o ruído tem média zero e variância constante:

$$\mathbb{E}[\varepsilon_t] = 0, \quad \mathrm{Var}(\varepsilon_t) = \sigma^2$$

Essas hipóteses simplificam a análise, mas podem ser relaxadas em modelos mais sofisticados que capturam heterocedasticidade e dependência temporal no ruído.

Tendência Determinística vs. Estocástica

A tendência pode ter origem determinística — seguindo uma trajetória previsível — ou estocástica — evoluindo de forma aleatória e acumulativa. Essa distinção define como ela deve ser removida.



Determinística

Trajetória previsível e sistemática

A série segue uma função conhecida do tempo — linear, quadrática ou exponencial. O futuro é previsível a partir do padrão passado.

$$X_t = f(t) + \varepsilon_t$$

Remoção por regressão: ajusta-se $f(t)$ e subtrai-se da série.

Estocástica

Deriva aleatória e acumulativa

A série acumula choques aleatórios ao longo do tempo, sem retornar a um nível fixo. O futuro é imprevisível mesmo conhecendo o passado.

$$X_t = X_{t-1} + u_t$$

Remoção por diferenciação: calcula-se $\Delta X_t = X_t - X_{t-1}$.

Identificar o tipo de tendência é o primeiro passo antes de qualquer modelagem — o método errado pode distorcer toda a análise.

Remoção da Tendência

A Ideia Central

O método de remoção depende do tipo de tendência. Aplicar o método errado distorce toda a análise subsequente.

Determinística: ajusta $f(t)$ por regressão → $Y_t = X_t - \hat{T}_t$

Estocástica: diferenciação → $Y_t = X_t - X_{t-1}$

Verificar estacionariedade após a remoção (ex.: teste ADF).

ENTRADA: x_t (t = 1,...,T), tipo ∈ {determinística, estocástica}
PRÉ-CONDIÇÃO: tipo de tendência identificado previamente

PASSO 1 — Remoção conforme o tipo
  SE tipo = determinística:
    T̂_t ← regressão de x_t sobre t (linear, polinomial etc.)
    Y_t ← x_t − T̂_t

  SE tipo = estocástica:
    Y_t ← x_t − x_{t−1}   (t = 2,...,T)

PASSO 2 — Verificação
  Testar estacionariedade de Y_t (ex.: teste ADF)
  SE não estacionária: repetir diferenciação

SAÍDA: Y_t (série sem tendência)
PÓS-CONDIÇÃO: Y_t aproximadamente estacionária em média

Remoção da Sazonalidade

A Ideia Central

A dessazonalização remove o padrão periódico S_t da série, isolando a dinâmica não explicada pela sazonalidade.

Aditivo: $Y_t = X_t - \hat{S}_t$

Multiplicativo: $Y_t = X_t / \hat{S}_t$

Y_t é a série dessazonalizada — base para modelagem da tendência e do ruído.

ENTRADA: x_t (t = 1,...,T), s (período sazonal), modelo ∈ {aditivo, multiplicativo}
PRÉ-CONDIÇÃO: s conhecido; tendência removida ou controlada

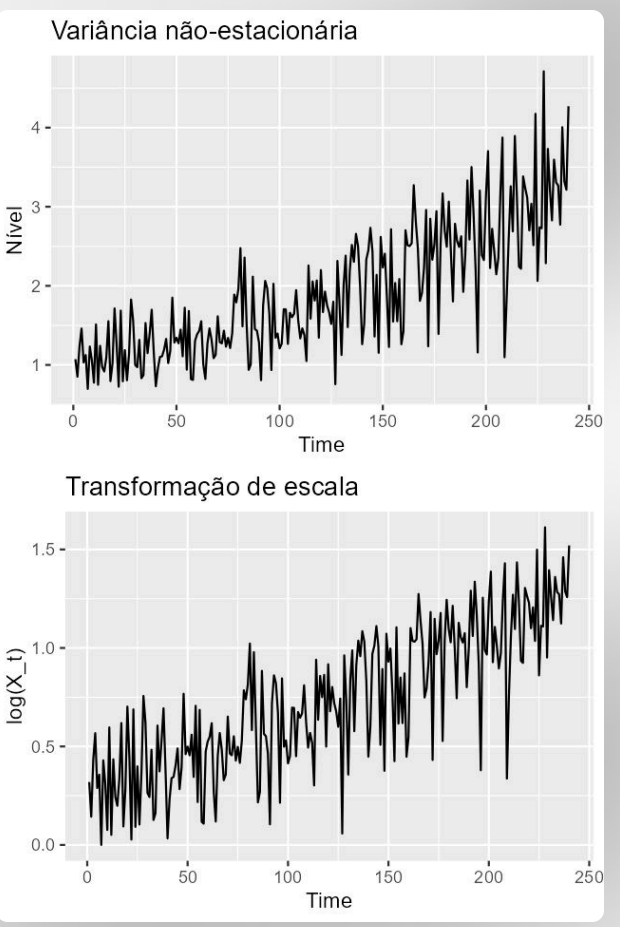
PASSO 1 — Identificar período sazonal s
 (mensal: s=12 | trimestral: s=4 | diário: s=7)

PASSO 2 — Estimar componente sazonal
 PARA p = 1,...,s:
  Ŝ_p ← média de x_t com (t mod s) = p
 Normalizar: soma zero (aditivo) | produto 1 (multiplicativo)

PASSO 3 — Remover sazonalidade
 Y_t ← x_t − Ŝ_{(t mod s)} (aditivo)
 Y_t ← x_t / Ŝ_{(t mod s)} (multiplicativo)

PASSO 4 — Verificar resíduo
 Y_t não deve exibir autocorrelação sazonal significativa

SAÍDA: Y_t (série dessazonalizada)
PÓS-CONDIÇÃO: ausência de padrão periódico em Y_t



Estabilização da Variância

Algumas séries apresentam variância condicional $\sigma_t^2 = \mathrm{Var}(X_t \mid \mathcal{F}_{t-1})$ que muda ao longo do tempo — fenômeno chamado **heterocedasticidade**. Transformações buscam tornar essa variância aproximadamente constante antes de modelar ou prever.

$$\mathrm{Var}(Y_t \mid \mathcal{F}_{t-1}) \approx \text{constante}$$

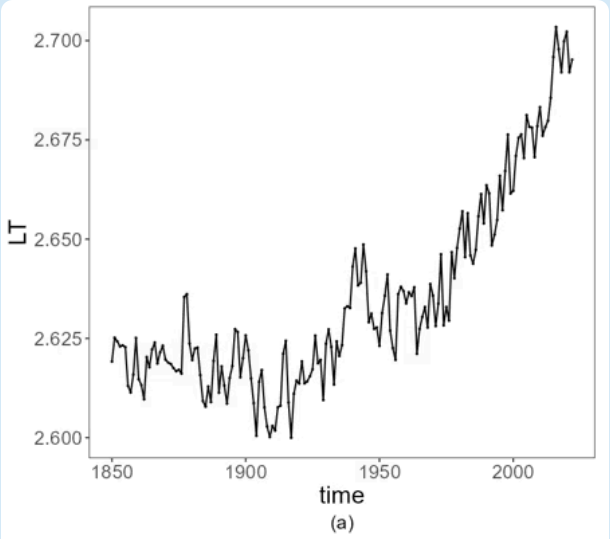
Transformação Logarítmica

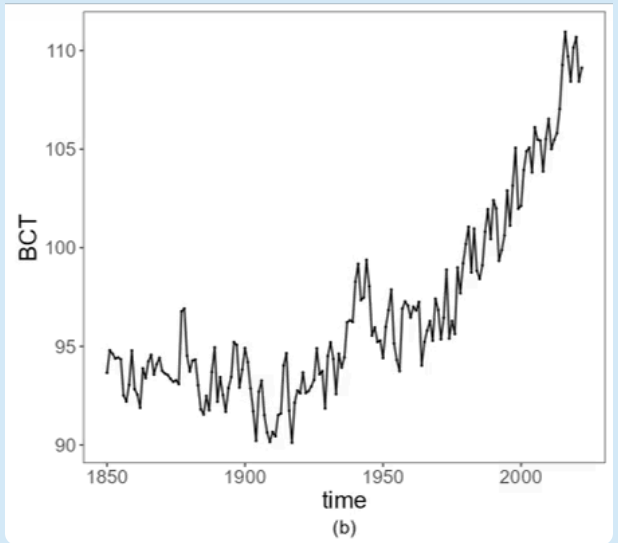
Quando a variância cresce proporcionalmente ao nível: $Y_t = \log(X_t)$. Estabiliza séries com amplitudes crescentes.

Transformação de Box-Cox

Família paramétrica: $Y_t = (X_t^\lambda - 1)/\lambda$. Para $\lambda = 0$ equivale ao logaritmo; $\lambda = 1$ mantém a série original.

⚠ Variância instável afeta diretamente os **intervalos de predição**: bandas de confiança ficam mal calibradas. Além disso, períodos de alta volatilidade podem ser confundidos com eventos reais, gerando **falsos positivos na detecção**. Estabilizar a variância é um pré-requisito para análise confiável.





Log transform e Box-Cox

Log transform

- Reduz amplitude de valores altos.
- Útil para crescimento multiplicativo.
- Exige valores positivos.

Box-Cox

- Família de transformações parametrizada.
- Escolhe λ para estabilizar variância.
- Mais flexível que log simples.

Decomposição e Análise

Cada método de decomposição gera uma representação diferente da série temporal. A escolha do método não é neutra: ela define o que será visto como padrão, o que ficará no resíduo e, portanto, o que poderá ser detectado como desvio.

Um mesmo ponto pode ser ruído em uma decomposição e anomalia em outra. O resíduo não é um dado bruto — é o resultado de uma decisão analítica.

Não há resíduo neutro. A decomposição define o que é considerado "normal". Escolher o método é escolher o que será visto.

Método define o normal

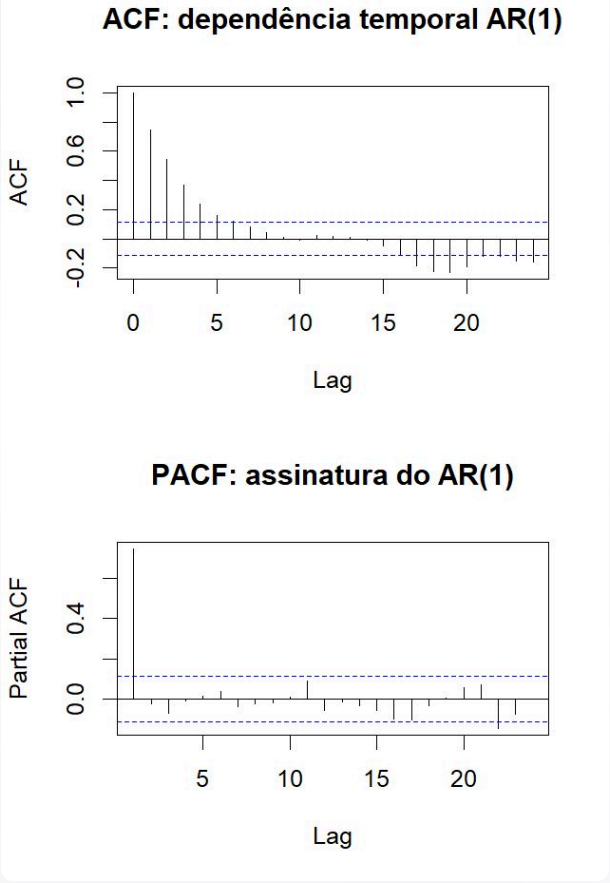
A estrutura extraída (T_t, S_t, C_t) determina o que é esperado. O resíduo ε_t é o que sobra dessa expectativa.

Resíduo como espaço de análise

É no ε_t que eventos, anomalias e desvios podem se manifestar. A qualidade da decomposição determina a qualidade da análise.

Ponte para modelos

Compreender a estrutura da série é o pré-requisito para modelagem, previsão e detecção. Pipeline, features e modelos são tratados na aula seguinte.



Autocovariância e Autocorrelação

Séries temporais têm memória: observações próximas tendem a ser mais parecidas do que observações distantes. Autocovariância e autocorrelação quantificam essa memória.

Autocovariância γ(h)

Associação linear entre X_t e X_{t-h}.

$$\gamma(h) = \mathrm{Cov}(X_t,\, X_{t-h})$$

Autocorrelação ρ(h)

Versão padronizada de γ(h), sempre em [−1, 1].

$$\rho(h) = \frac{\gamma(h)}{\gamma(0)}$$

Dependência de Curta Duração

ρ(h) decai rapidamente para zero — memória limitada.

Ex.: ruído branco.

Dependência de Longa Duração

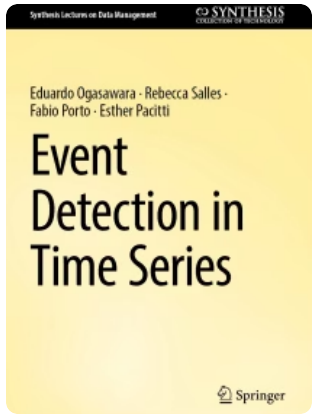
ρ(h) decai lentamente (hiperbolicamente) — eventos antigos ainda influenciam o presente.

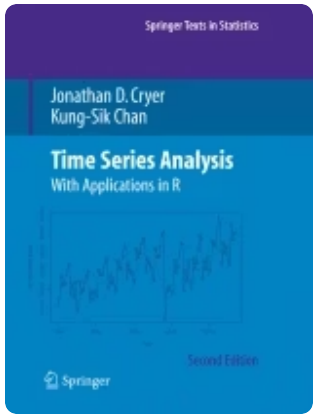
Nota: $\rho(h) \sim h^{-\alpha}, 0 < \alpha < 1.$

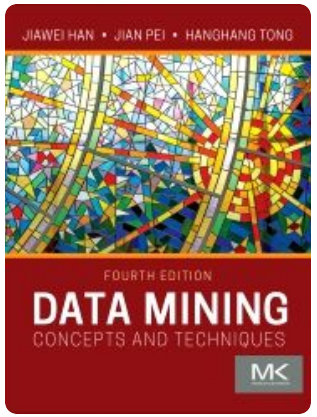
Ex.: séries climáticas e financeiras.

A função de autocorrelação (FAC) é a principal ferramenta diagnóstica para identificar o tipo de dependência e orientar a escolha do modelo.

Referências Bibliográficas







Event Detection in Time Series

Ogasawara, E.; Salles, R.; Porto, F.; Pacitti, E. Springer Nature Switzerland, 2025.

Time Series Analysis: With Applications in R

Cryer, J. D.; Chan, K.-S. Springer, 2008.

Data Mining: Concepts and Techniques

Han, J.; Pei, J.; Tong, H. Morgan Kaufmann, 4ª ed., 2022.