



Estrutura Temporal e Componentes da Série

Uma série temporal raramente é aleatória. Antes de qualquer tarefa de predição ou detecção de eventos, é necessário compreender sua estrutura: tendência, sazonalidade, ciclo e ruído. Esta aula apresenta os componentes fundamentais e as ferramentas para decompô-los.

Eduardo Ogasawara

eduardo.ogasawara@cefet-rj.br

<https://eic.cefet-rj.br/~eogasawara>

Decomposição de Séries Temporais

A Ideia Central

A decomposição separa X_t em componentes interpretáveis. Cada componente representa um aspecto distinto do comportamento temporal. A forma de combinação depende do comportamento das amplitudes ao longo do tempo.

$$X_t = T_t + S_t + C_t + \varepsilon_t$$

- T_t — **tendência**: comportamento de longo prazo
- S_t — **sazonalidade**: padrões cíclicos regulares de período s
- C_t — **ciclo**: oscilações de médio prazo sem período fixo
- ε_t — **resíduo**: variações não explicadas pelos demais componentes

Modelo aditivo: amplitudes constantes ao longo do tempo.

Modelo multiplicativo: amplitudes proporcionais ao nível — equivalente ao aditivo após $\log(X_t)$.

- ❏ O resíduo ε_t concentra o que não foi capturado pela estrutura — é nele que podem se manifestar eventos e anomalias.

ENTRADA: x_t ($t = 1, \dots, T$), s (período sazonal), modelo $\in \{\text{aditivo}, \text{multiplicativo}\}$

PRÉ-CONDIÇÃO: s conhecido; modelo escolhido com base no gráfico da série

PASSO 1 — Estimar tendência

$\hat{t}_t \leftarrow$ média móvel de x_t com janela s

PASSO 2 — Estimar sazonalidade

$r_t \leftarrow x_t - \hat{t}_t$ (aditivo) | $x_t / \hat{t}_t$ (multiplicativo)

$\hat{S}_p \leftarrow$ média de r_t com $(t \bmod s) = p$, $p = 1, \dots, s$

Normalizar $\hat{S}$: soma zero (aditivo) ou produto 1 (multiplicativo)

PASSO 3 — Obter resíduo

$\varepsilon_t \leftarrow x_t - \hat{t}_t - \hat{S}_t$ (aditivo) | $x_t / (\hat{t}_t \cdot \hat{S}_t)$ (multiplicativo)


SAÍDA: $\hat{t}_t, \hat{S}_t, \varepsilon_t$ para cada t

PÓS-CONDIÇÃO: ε_t sem padrão sistemático e aproximadamente estacionário


Modelos de Tendência

A tendência representa a variação sistemática de longo prazo em uma série temporal — o valor esperado $T_t = \mathbb{E}[X_t]$ que muda ao longo do tempo em séries não estacionárias. Identificá-la é essencial para separar movimentos permanentes de flutuações transitórias.

Tendência determinística (linear) + ruído



Tendência estocástica (passeio aleatório)



Tendência Linear

Crescimento ou declínio constante ao longo do tempo

$$T_t = \alpha + \beta t$$

Tendência Polinomial

Variações não lineares descritas por funções polinomiais


Tendência Estocástica

Evolução aleatória acumulativa

$$T_t = T_{t-1} + u_t$$

Modelos de tendência podem ser determinísticos, quando definidos por funções explícitas do tempo, ou estocásticos, quando evoluem de forma aleatória. Essa distinção é fundamental para definir métodos adequados de estimação e transformação da série.

Sazonalidade: padrão periódico (s = 12)



Sazonalidade: Padrões Periódicos

A sazonalidade corresponde a padrões que se repetem regularmente ao longo do tempo, como variações mensais, trimestrais ou semanais. Diferentemente da tendência, não representa mudança estrutural permanente.

A condição formal de periodicidade é expressa por:

$$S_{t+s} = S_t$$

Onde s representa o período sazonal. Essa propriedade distingue a sazonalidade de outros componentes temporais.

Períodos Sazonais Comuns

Dados Mensais

Sazonalidade anual em séries com observações mensais — período $s = 12$

Dados Trimestrais

Padrão anual em séries trimestrais — período $s = 4$

Dados Semanais

Padrão semanal em dados diários — período $s = 7$

O período sazonal s depende da frequência de observação da série. Esses valores formalizam a periodicidade e permitem incorporar a sazonalidade nos modelos estatísticos de forma precisa.

Componente Cíclica

Oscilações de Médio e Longo Prazo

A componente cíclica descreve oscilações que não se repetem em intervalos regulares, diferentemente da sazonalidade.

Sem Periodicidade Fixa


Associada a fenômenos como ciclos econômicos ou tecnológicos, sem padrão temporal constante.

Modelagem Complexa

Por não possuir periodicidade constante, requer abordagens estatísticas e econômicas específicas.

A componente cíclica pode ser representada por $C_t \approx f(t)$, onde $f(t)$ é uma função do tempo sem periodicidade fixa.

Ruído: flutuações aleatórias



Componente Aleatória: O Ruído

A componente aleatória representa flutuações imprevisíveis que não podem ser explicadas por tendência, sazonalidade ou ciclos. É o ruído inerente ao processo observado.

Em modelos clássicos, assume-se que o ruído tem média zero e variância constante:

$$\mathbb{E}[\varepsilon_t] = 0, \quad \text{Var}(\varepsilon_t) = \sigma^2$$

Essas hipóteses simplificam a análise, mas podem ser relaxadas em modelos mais sofisticados que capturam heterocedasticidade e dependência temporal no ruído.

Tendência Determinística vs. Estocástica

A tendência pode ter origem determinística — seguindo uma trajetória previsível — ou estocástica — evoluindo de forma aleatória e acumulativa. Essa distinção define como ela deve ser removida.

Determinística

Trajetória previsível e sistemática

A série segue uma função conhecida do tempo — linear, quadrática ou exponencial. O futuro é previsível a partir do padrão passado.

$$X_t = f(t) + \varepsilon_t$$

Remoção por regressão: ajusta-se $f(t)$ e subtrai-se da série.

Identificar o tipo de tendência é o primeiro passo antes de qualquer modelagem — o método errado pode distorcer toda a análise.

Estocástica


Deriva aleatória e acumulativa

A série acumula choques aleatórios ao longo do tempo, sem retornar a um nível fixo. O futuro é imprevisível mesmo conhecendo o passado.


$$X_t = X_{t-1} + u_t$$

Remoção por diferenciação: calcula-se $\Delta X_t = X_t - X_{t-1}$.

Determinística: $X_t = f(t) + \varepsilon_t$



Estocástica: $X_t = X_{t-1} + u_t$



Remoção da Tendência

A Ideia Central

O método de remoção depende do tipo de tendência. Aplicar o método errado distorce toda a análise subsequente.

Determinística: ajusta $f(t)$ por regressão $\rightarrow$

$$Y_t = X_t - \hat{T}_t$$

Estocástica: diferenciação $\rightarrow Y_t = X_t - X_{t-1}$

Verificar estacionariedade após a remoção (ex.: teste ADF).

ENTRADA: x_t ($t = 1, \dots, T$), $\text{tipo} \in \{\text{determinística, estocástica}\}$

PRÉ-CONDIÇÃO: tipo de tendência identificado previamente

PASSO 1 — Remoção conforme o tipo

SE tipo = determinística:

$\hat{T}_t \leftarrow$ regressão de x_t sobre t (linear, polinomial etc.)

$$Y_t \leftarrow x_t - \hat{T}_t$$

SE tipo = estocástica:

$$Y_t \leftarrow x_t - x_{t-1} \quad (t = 2, \dots, T)$$

PASSO 2 — Verificação

Testar estacionariedade de Y_t (ex.: teste ADF)

SE não estacionária: repetir diferenciação

SAÍDA: Y_t (série sem tendência)

PÓS-CONDIÇÃO: Y_t aproximadamente estacionária em média

Remoção da Sazonalidade

A Ideia Central

A dessazonalização remove o padrão periódico S_t da série, isolando a dinâmica não explicada pela sazonalidade.

Aditivo: $Y_t = X_t - \hat{S}_t$

Multiplicativo: $Y_t = X_t / \hat{S}_t$

Y_t é a série dessazonalizada — base para modelagem da tendência e do ruído.

ENTRADA: x_t ($t = 1, \dots, T$), s (período sazonal), modelo $\in \{\text{aditivo}, \text{multiplicativo}\}$

PRÉ-CONDIÇÃO: s conhecido; tendência removida ou controlada

PASSO 1 — Identificar período sazonal s

(mensal: $s=12$ | trimestral: $s=4$ | diário: $s=7$)

PASSO 2 — Estimar componente sazonal

PARA $p = 1, \dots, s$:

$\hat{S}_p \leftarrow$ média de x_t com $(t \bmod s) = p$

Normalizar: soma zero (aditivo) | produto 1 (multiplicativo)

PASSO 3 — Remover sazonalidade

$Y_t \leftarrow x_t - \hat{S}_{\{(t \bmod s)\}}$ (aditivo)

$Y_t \leftarrow x_t / \hat{S}_{\{(t \bmod s)\}}$ (multiplicativo)

PASSO 4 — Verificar resíduo

Y_t não deve exibir autocorrelação sazonal significativa

SAÍDA: Y_t (série dessazonalizada)

PÓS-CONDIÇÃO: ausência de padrão periódico em Y_t

Estabilização da Variância

Algumas séries apresentam variância condicional $\sigma_t^2 = \text{Var}(X_t | \mathcal{F}_{t-1})$ que muda ao longo do tempo — fenômeno chamado **heterocedasticidade**. Transformações buscam tornar essa variância aproximadamente constante antes de modelar ou prever.

$$\text{Var}(Y_t | \mathcal{F}_{t-1}) \approx \text{constante}$$

Transformação Logarítmica


Quando a variância cresce proporcionalmente ao nível: $Y_t = \log(X_t)$. Estabiliza séries com amplitudes crescentes.

Transformação de Box-Cox


Família paramétrica: $Y_t = (X_t^\lambda - 1)/\lambda$. Para $\lambda = 0$ equivale ao logaritmo; $\lambda = 1$ mantém a série original.

⚠ Variância instável afeta diretamente os **intervalos de predição**: bandas de confiança ficam mal calibradas. Além disso, períodos de alta volatilidade podem ser confundidos com eventos reais, gerando **falsos positivos na detecção**. Estabilizar a variância é um pré-requisito para análise confiável.

Variância não-estacionária



Transformação de escala



Decomposição e Análise

Cada método de decomposição gera uma representação diferente da série temporal. A escolha do método não é neutra: ela define o que será visto como padrão, o que ficará no resíduo e, portanto, o que poderá ser detectado como desvio.

Um mesmo ponto pode ser ruído em uma decomposição e anomalia em outra. O resíduo não é um dado bruto — é o resultado de uma decisão analítica.

❏ Não há resíduo neutro. A decomposição define o que é considerado "normal". Escolher o método é escolher o que será visto.

Método define o normal

A estrutura extraída (T_t, S_t, C_t) determina o que é esperado. O resíduo ε_t é o que sobra dessa expectativa.

Resíduo como espaço de análise

É no ε_t que eventos, anomalias e desvios podem se manifestar. A qualidade da decomposição determina a qualidade da análise.


Ponte para modelos

Compreender a estrutura da série é o pré-requisito para modelagem, previsão e detecção. Pipeline, features e modelos são tratados na aula seguinte.


Autocovariância e Autocorrelação

Séries temporais têm memória: observações próximas tendem a ser mais parecidas do que observações distantes. Autocovariância e autocorrelação quantificam essa memória.

ACF: dependência temporal AR(1)



PACF: assinatura do AR(1)



Autocovariância $\gamma(h)$

Associação linear entre X_t e X_{t-h} .

$$\gamma(h) = \text{Cov}(X_t, X_{t-h})$$

Autocorrelação $\rho(h)$

Versão padronizada de $\gamma(h)$, sempre em $[-1, 1]$.

$$\rho(h) = \frac{\gamma(h)}{\gamma(0)}$$

Dependência de Curta Duração

$\rho(h)$ decai rapidamente para zero — memória limitada.

Ex.: ruído branco.

Dependência de Longa Duração


$\rho(h)$ decai lentamente (hiperbolicamente) — eventos antigos ainda influenciam o presente.

Nota: $\rho(h) \sim h^{-\alpha}$, $0 < \alpha < 1$.

Ex.: séries climáticas e financeiras.


A função de autocorrelação (FAC) é a principal ferramenta diagnóstica para identificar o tipo de dependência e orientar a escolha do modelo.

Referências Bibliográficas




Event Detection in Time Series

Ogasawara, E.; Salles, R.; Porto, F.; Pacitti, E.
Springer Nature Switzerland, 2025.



Time Series Analysis: With Applications in R

Cryer, J. D.; Chan, K.-S. Springer, 2008.



Data Mining: Concepts and Techniques

Han, J.; Pei, J.; Tong, H. Morgan Kaufmann, 4^a ed., 2022.