CEFET/RJ

Detecção de anomalias

Eduardo Ogasawara
eduardo.ogasawara@cefet-rj.br
https://eic.cefet-rj.br/~eogasawara

Conceito de Anomalia

- Anomalias são observações que se desviam significativamente do padrão esperado
- Podem indicar falhas, fraudes, mudanças de comportamento ou eventos raros
- A detecção de anomalias é essencial em sistemas de monitoramento e vigilância automática
- $a(X, k, \sigma) = \{t, |tc(x_t) - ep(tc(x_t), k)| > \sigma \wedge |tc(x_t) - ef(tc(x_t), k)| > \sigma$

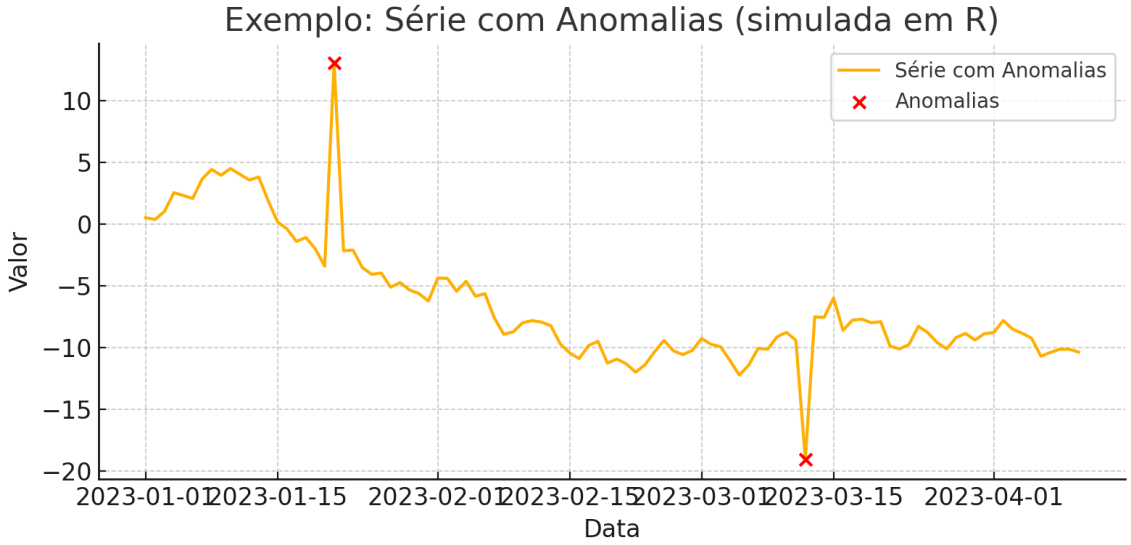

Taxonomia de Anomalia

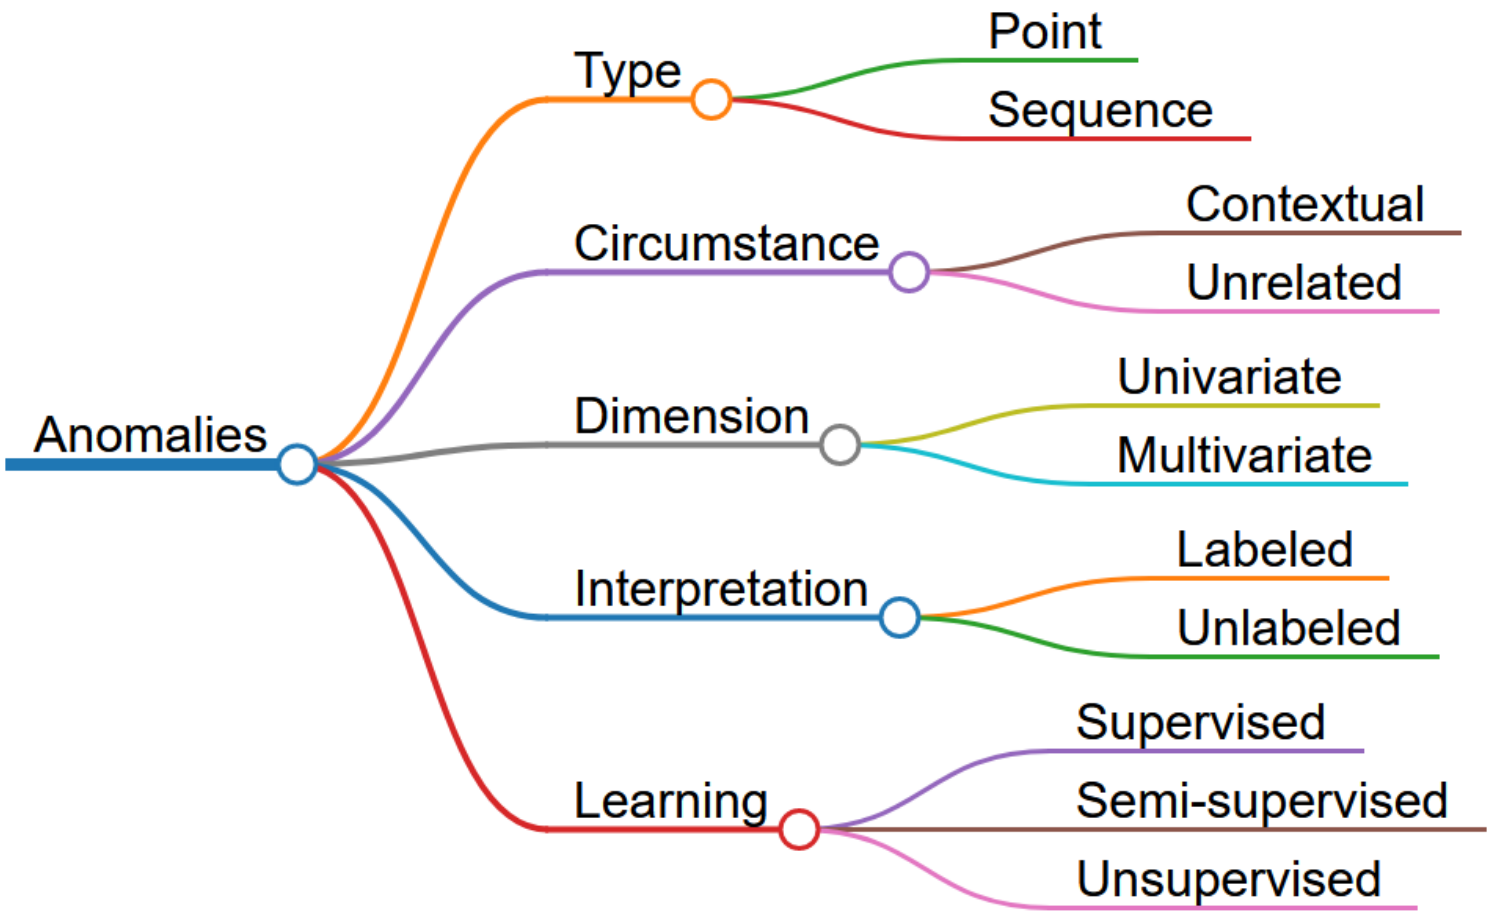

Tipos de Anomalias

- Pontual (point anomaly): um único valor se destaca do padrão
- Contextual (ou condicional): valor aparentemente normal, mas anômalo em determinado contexto (ex: temperatura alta à noite)
- Coletiva (ou sequencial): um grupo de valores que, em conjunto, compõem um comportamento anômalo

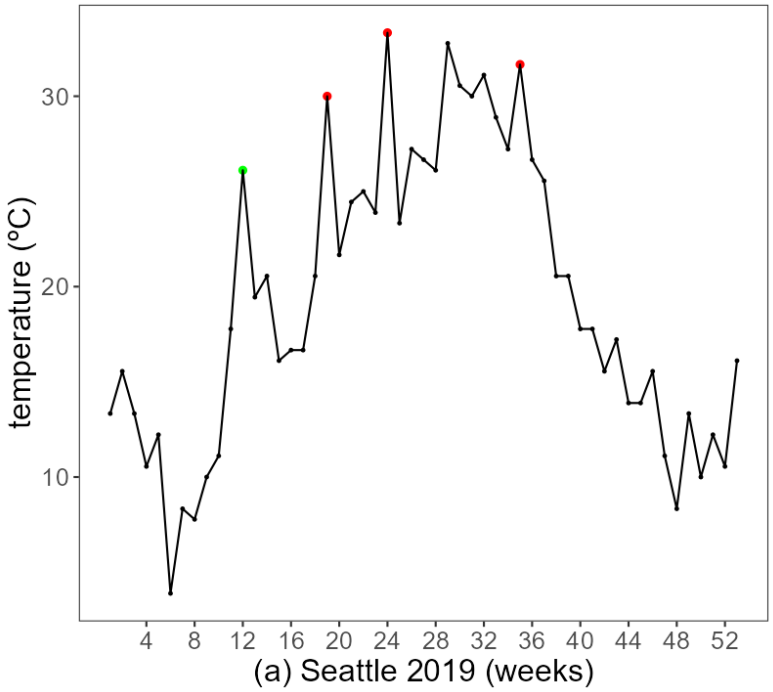

Anomalia pontual e de sequência
Anomalia contextual e não-relacionada

- <descrição curta>

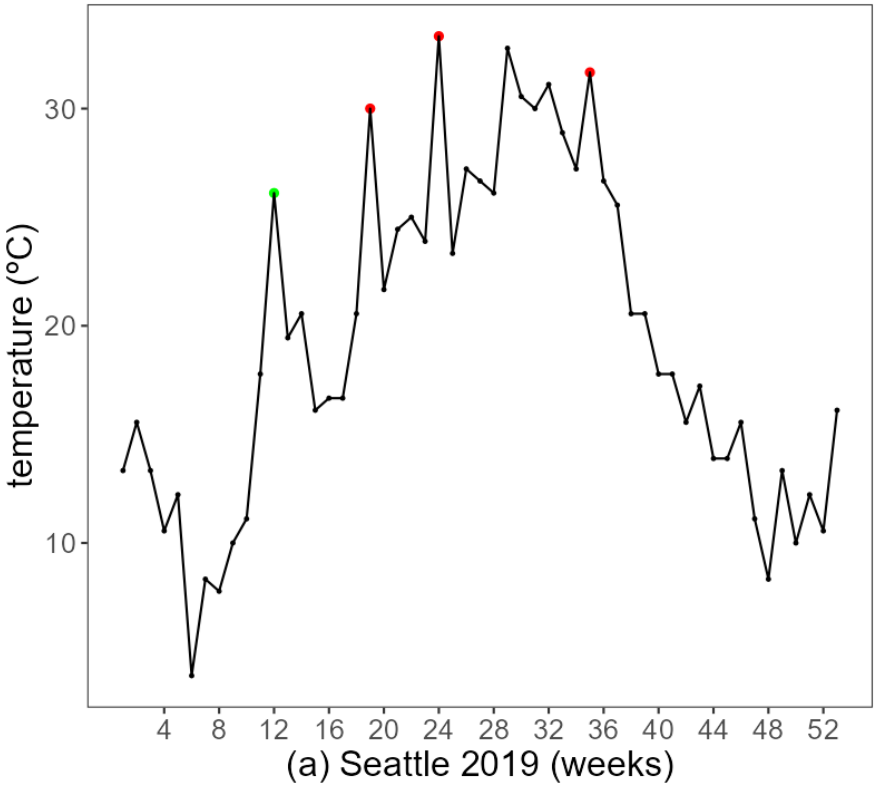

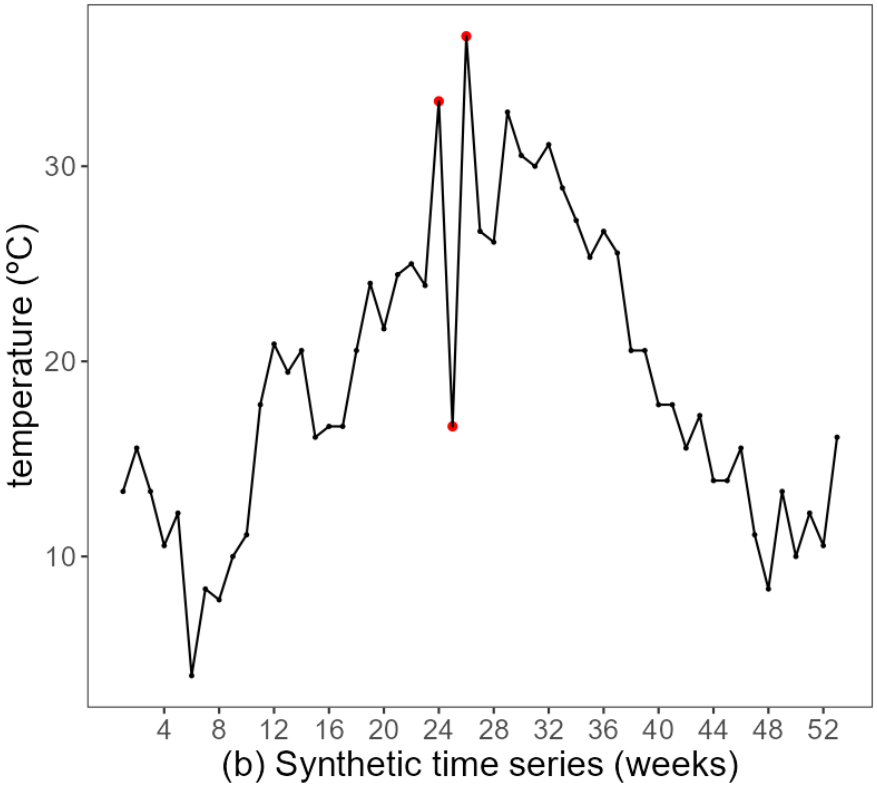

Anomalia em séries univariadas e multivariadas

- Univariadas: baseadas em uma única variável ao longo do tempo
- Multivariadas: envolvem a correlação entre várias variáveis (ex: temperatura, pressão e umidade)
- A detecção em séries multivariadas é mais complexa e requer métodos que capturam relações cruzadas

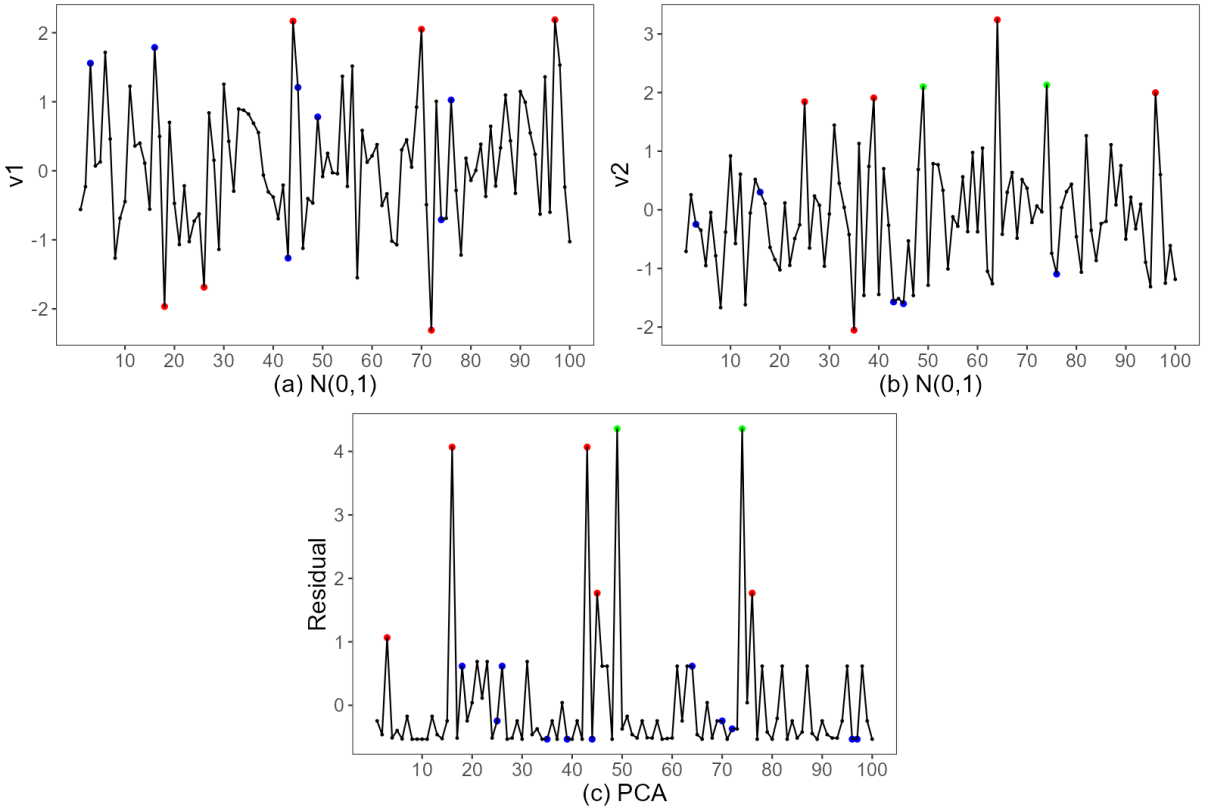

Rotulagem de Anomalias

- Rotulada: anomalias conhecidas e marcadas nos dados
- Não rotulada: o modelo precisa inferir o que é anômalo
- Riscos: rótulos podem conter viés humano ou ser incompletos, afetando a aprendizagem supervisionada

Abordagens de Aprendizado

- Supervisionado: usa rótulos explícitos (classificação)
- Não supervisionado: identifica padrões anômalos sem rótulos (clustering, autoencoders)
- Semi-supervisionado: combina pequenos conjuntos rotulados com grandes não rotulados

Separação Temporal de Treino e Teste

- A separação entre treino e teste deve respeitar a ordem temporal
- Técnicas comuns:
  - Holdout temporal: divisão única por tempo
  - Validação cruzada para séries temporais: blocos crescentes (TimeSeriesSplit)
- Evita vazamento de informações do futuro para o passado

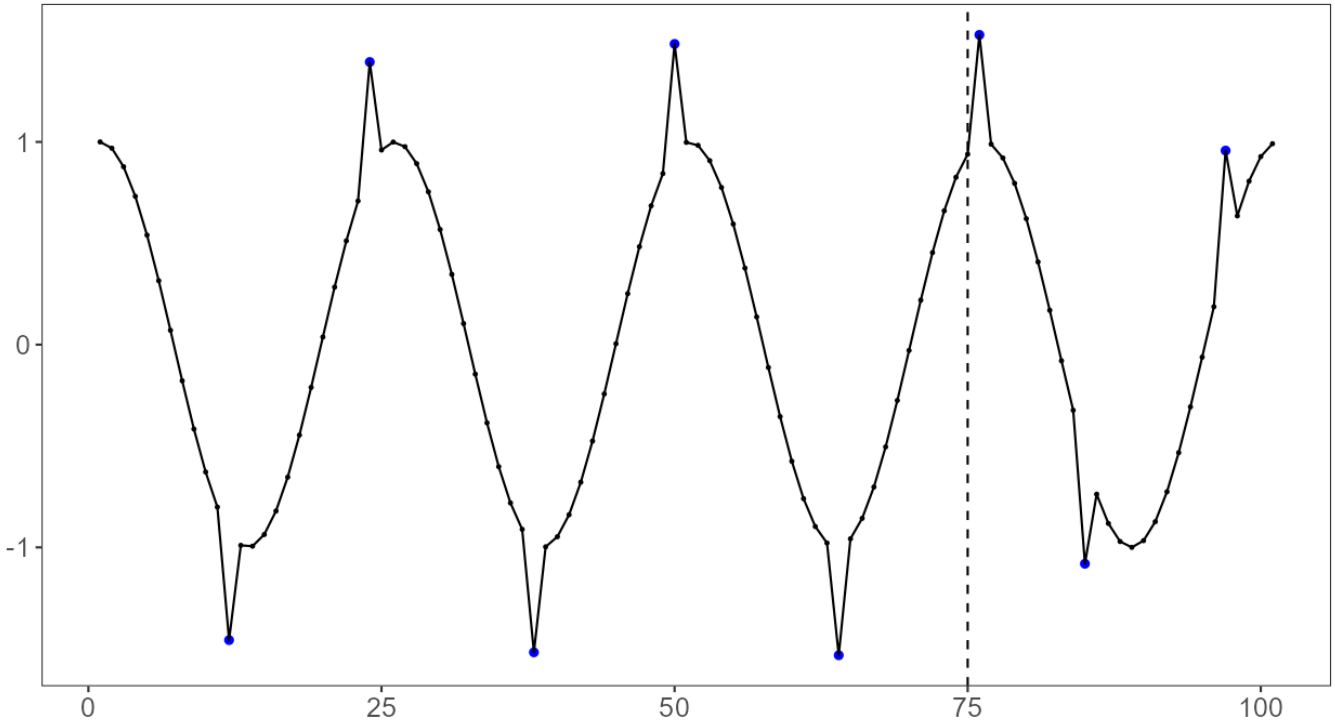

Detecção com Regressão (ex: ARIMA)

- Ajusta modelos preditivos (ex: ARIMA) para prever o próximo valor
- Se o erro de previsão for alto, o ponto pode ser considerado anômalo
- Exige séries estacionárias e bom ajuste do modelo

ω_t

t	x_{t-4}	x_{t-3}	x_{t-2}	x_{t-1}	$\hat{x}_t$	x_t
5	v_1	v_2	v_3	v_4	$\hat{v}_5$	v_5
6	v_2	v_3	v_4	v_5	$\hat{v}_6$	v_6
7	v_3	v_4	v_5	v_6	$\hat{v}_7$	v_7
8	v_4	v_5	v_6	v_7	$\hat{v}_8$	v_8
9	v_5	v_6	v_7	v_8	$\hat{v}_9$	v_9
10	v_6	v_7	v_8	v_9	$\hat{v}_{10}$	v_{10}
11	v_7	v_8	v_9	v_{10}	$\hat{v}_{11}$	v_{11}
12	v_8	v_9	v_{10}	v_{11}	$\hat{v}_{12}$	v_{12}
13	v_9	v_{10}	v_{11}	v_{12}	$\hat{v}_{13}$	v_{13}
14	v_{10}	v_{11}	v_{12}	v_{13}	$\hat{v}_{14}$	v_{14}

(a)

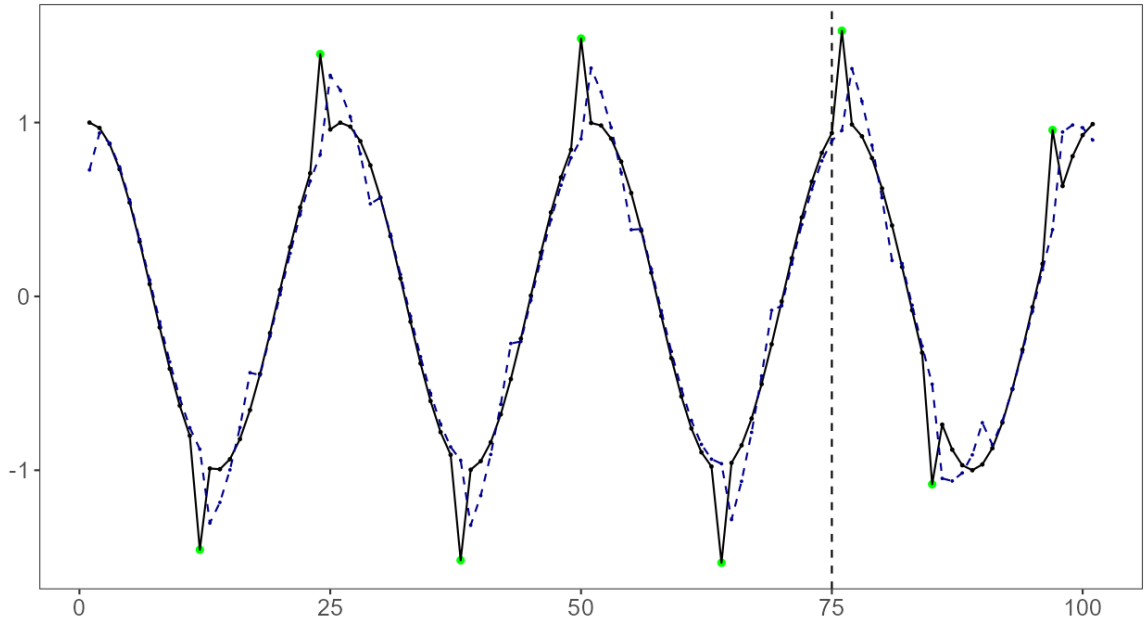

Detecção com Classificação (Ex: SVM)

- Treina um modelo com exemplos rotulados de normal/anômalo
- Classificadores comuns: SVM, decision trees, redes neurais
- Requer conjunto de treino rotulado e balanceado

f_1

t	x_{t-4}	x_{t-3}	x_{t-2}	x_{t-1}	x_t	$\hat{e}_t$	e_t
5	v_1	v_2	v_3	v_4	v_5	$\hat{b}_5$	b_5
6	v_2	v_3	v_4	v_5	v_6	$\hat{b}_6$	b_6
7	v_3	v_4	v_5	v_6	v_7	$\hat{b}_7$	b_7
8	v_4	v_5	v_6	v_7	v_8	$\hat{b}_8$	b_8
9	v_5	v_6	v_7	v_8	v_9	$\hat{b}_9$	b_9
10	v_6	v_7	v_8	v_9	v_{10}	$\hat{b}_{10}$	b_{10}
11	v_7	v_8	v_9	v_{10}	v_{11}	$\hat{b}_{11}$	b_{11}
12	v_8	v_9	v_{10}	v_{11}	v_{12}	$\hat{b}_{12}$	b_{12}

t	x_{t-4}	x_{t-3}	x_{t-2}	x_{t-1}	x_t	$\hat{e}_t$
13	v_9	v_{10}	v_{11}	v_{12}	v_{13}	$\hat{b}_{13}$
14	v_{10}	v_{11}	v_{12}	v_{13}	v_{14}	$\hat{b}_{14}$

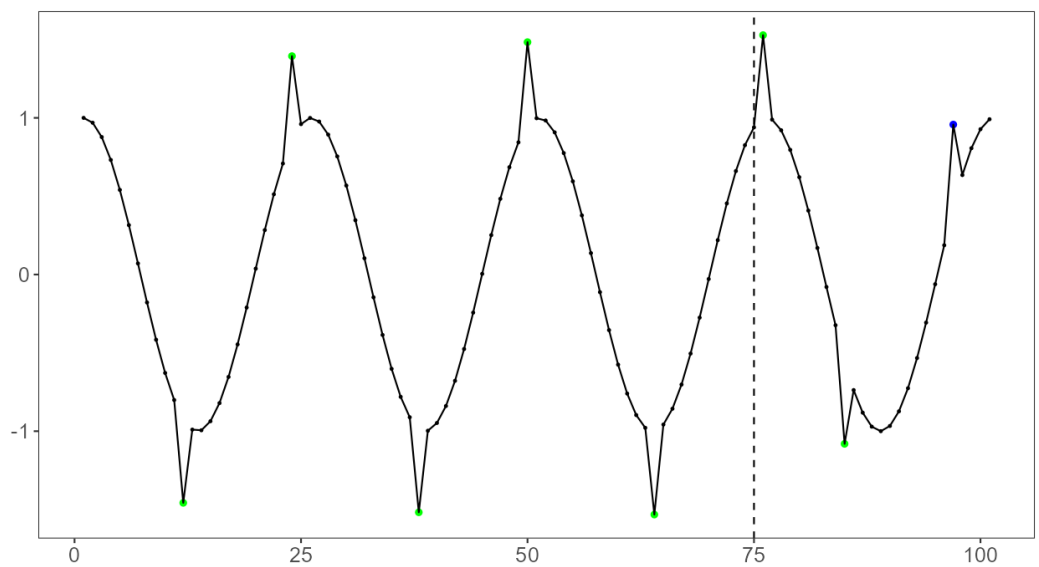

Detecção com Agrupamento (Clustering) (Ex.: kmeans)

- Modelos de clustering (ex: k-means, DBSCAN) detectam padrões e outliers
- Observações que não se encaixam bem em nenhum cluster são tratadas como anômalas
- Útil para aprendizado não supervisionado

t	x_{t-4}	x_{t-3}	x_{t-2}	x_{t-1}	x_t	$\ddot{r}_c$	d_t
5	v_1	v_2	v_3	v_4	v_5	$\ddot{r}_1$	d_5
6	v_2	v_3	v_4	v_5	v_6	$\ddot{r}_1$	d_6
7	v_3	v_4	v_5	v_6	v_7	$\ddot{r}_1$	d_7
8	v_4	v_5	v_6	v_7	v_8	$\ddot{r}_2$	d_8
9	v_5	v_6	v_7	v_8	v_9	$\ddot{r}_2$	d_9
10	v_6	v_7	v_8	v_9	v_{10}	$\ddot{r}_1$	d_{10}
11	v_7	v_8	v_9	v_{10}	v_{11}	$\ddot{r}_1$	d_{11}
12	v_8	v_9	v_{10}	v_{11}	v_{12}	$\ddot{r}_2$	d_{12}
13	v_9	v_{10}	v_{11}	v_{12}	v_{13}	$\ddot{r}_2$	d_{13}
14	v_{10}	v_{11}	v_{12}	v_{13}	v_{14}	$\ddot{r}_2$	d_{14}

$\ddot{r}_t$	x_{t-4}	x_{t-3}	x_{t-2}	x_{t-1}	x_t
$\ddot{r}_1$	$\ddot{v}_{1,4}$	$\ddot{v}_{1,3}$	$\ddot{v}_{1,2}$	$\ddot{v}_{1,1}$	$\ddot{v}_{1,0}$
$\ddot{r}_2$	$\ddot{v}_{2,4}$	$\ddot{v}_{2,3}$	$\ddot{v}_{2,2}$	$\ddot{v}_{2,1}$	$\ddot{v}_{2,0}$

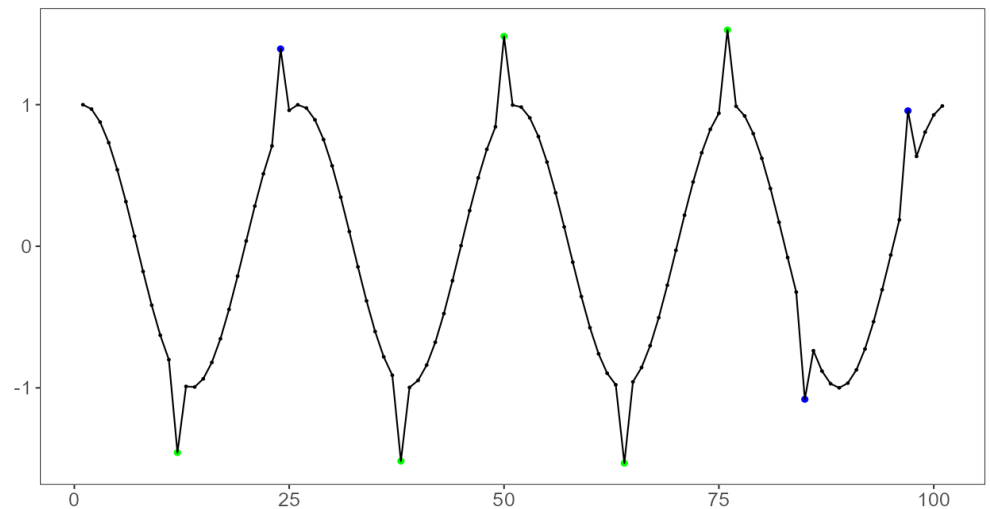

Slide 14: Detecção Estatística (Histograma, Z-score, IQR)

- Métodos clássicos de detecção:
  - Z-score: desvio em relação à média
  - IQR: limites baseados em quartis
  - Histograma: densidade de ocorrência de valores
- Simples, rápidos, mas sensíveis a distribuição

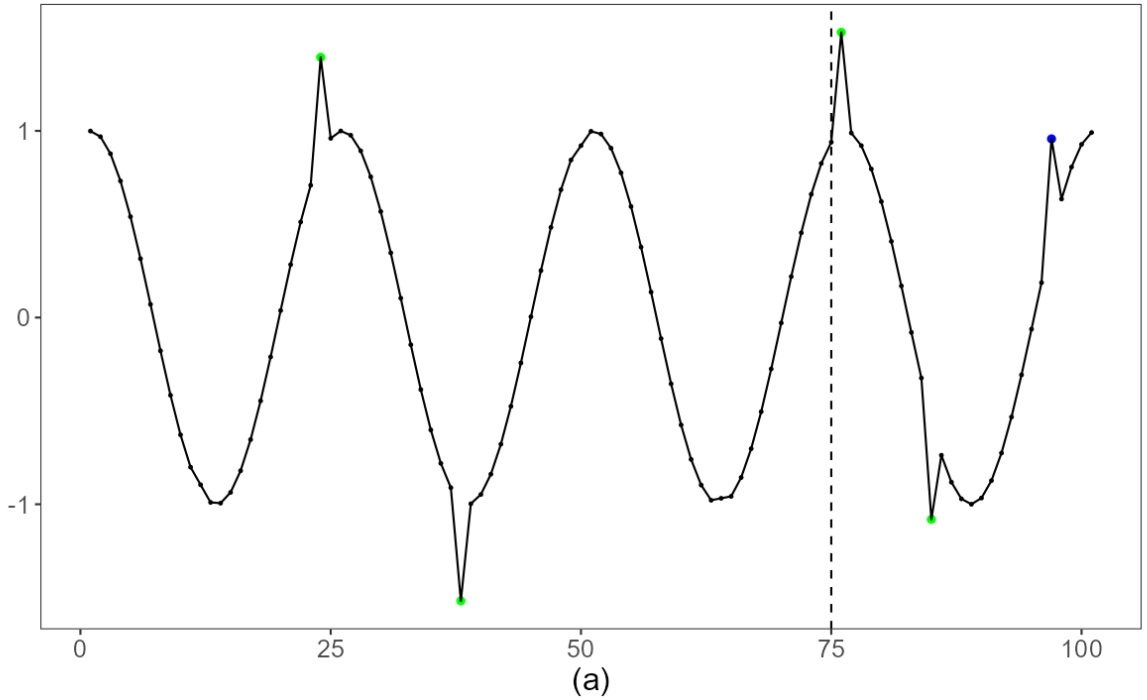

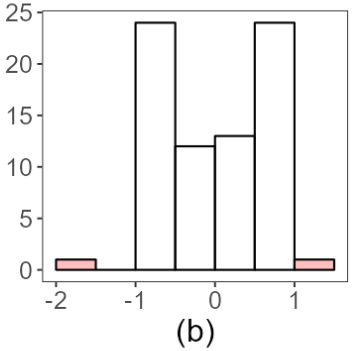

Detecção com Autoencoders (Espectral)

- Autoencoders aprendem a reconstruir o padrão normal
- Erros de reconstrução elevados indicam anomalias
- Abordagem eficiente para séries complexas e multivariadas

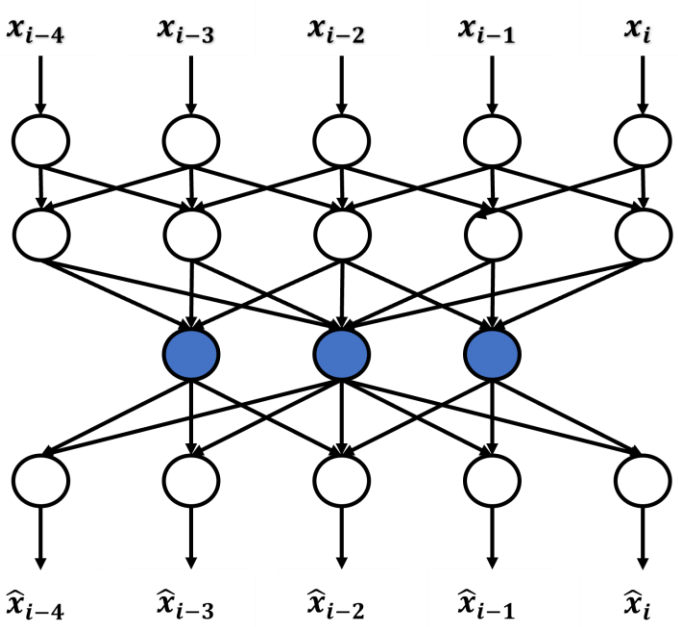

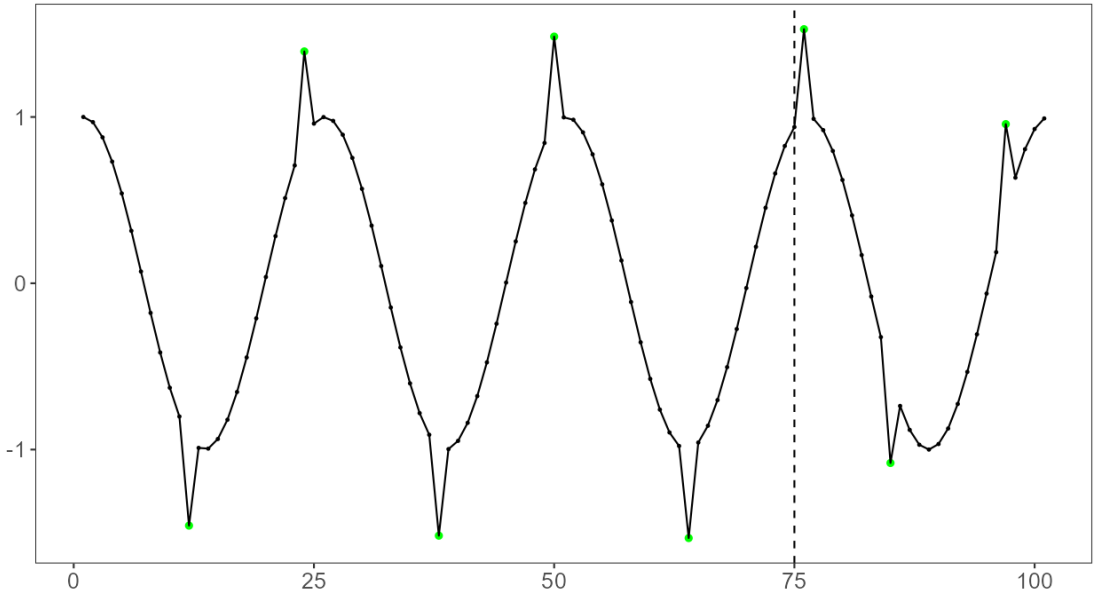

Anomalia de volatilidade

- Em alguns domínios, o foco não está no valor em si, mas em sua variabilidade
- Exemplo: modelo GARCH detecta mudanças no comportamento da variância ao longo do tempo
- Importante em finanças e séries com flutuações erráticas

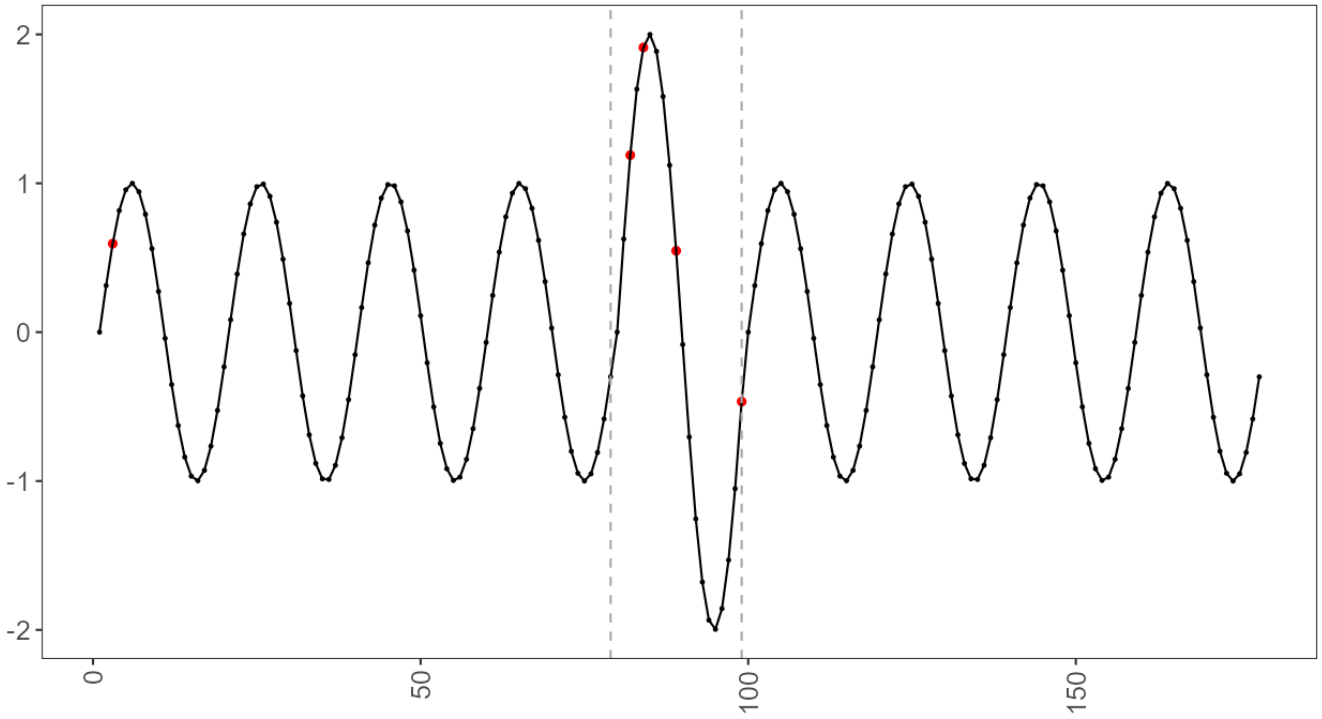

Comparação de detecções

- Comparações visuais destacam as diferenças entre métodos de detecção
- Cores indicam acertos (verde), falsos positivos (vermelho) e falsos negativos (azul)
- Facilitam a análise qualitativa dos resultados

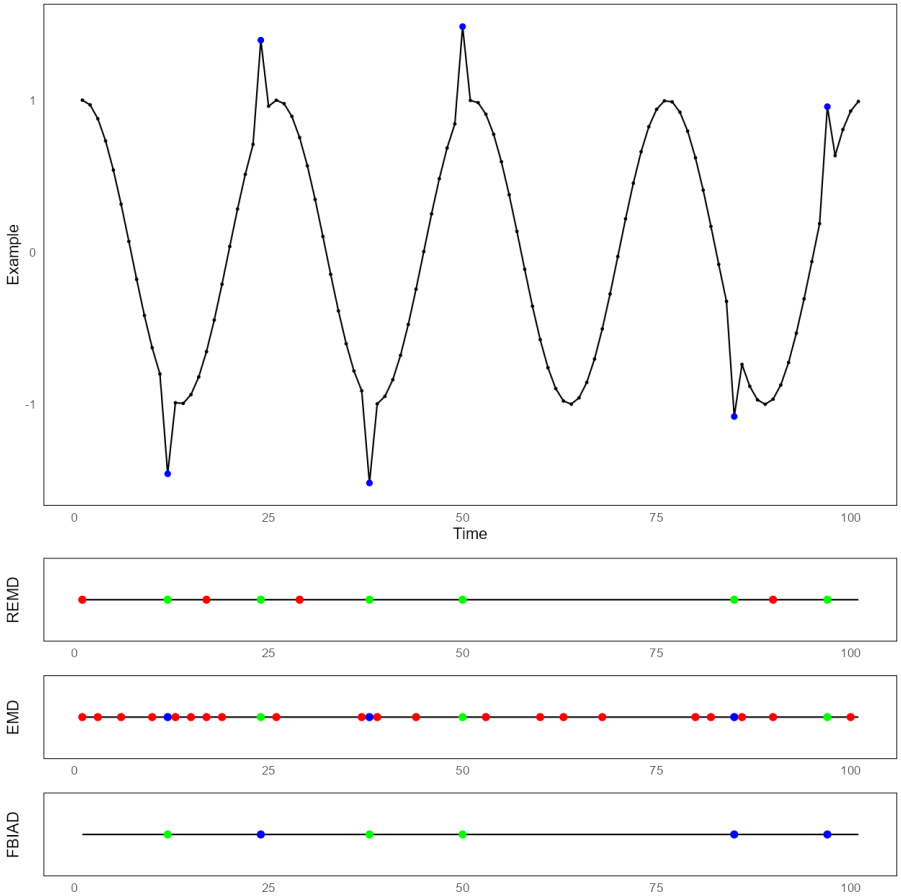

Resumo do Capítulo

- Anomalias são elementos-chave em sistemas de detecção e predição
- Podem ser pontuais, contextuais ou coletivas
- Diferentes métodos são aplicáveis:
  - Estatísticos
  - Baseados em distância
  - Regressão, classificação, clustering, autoencoders
- A escolha do método depende da natureza da série e da disponibilidade de rótulos

Exercício Harbinger

- Explore a página do Harbinger
  - https://cefet-rj-dal.github.io/harbinger/
- Execute todos os exemplos de anomalias
- Escolha uma série temporal e refaça os exemplos com esta nova série
  - Eventualmente será necessário olhar os exemplos gerais

Referências

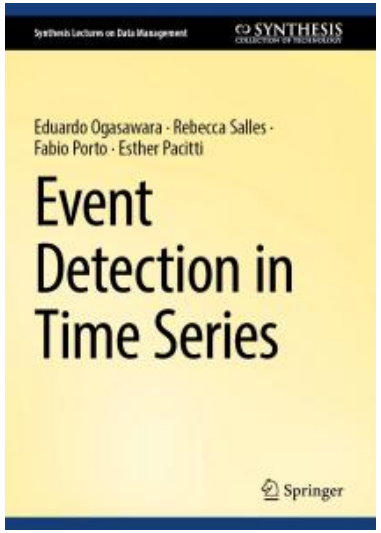

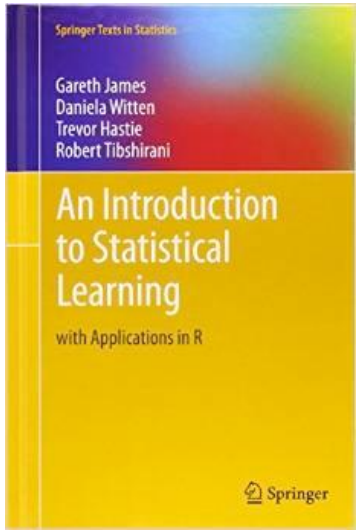

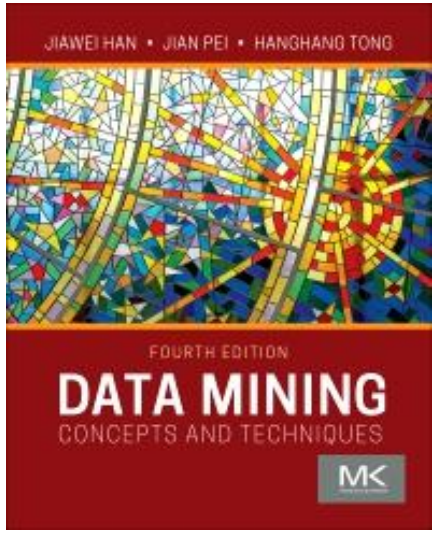

[1] Ogasawara, E.; Salles, R.; Porto, F.; Pacitti, E. Event Detection in Time Series. 1. ed. Cham: Springer Nature Switzerland, 2025.

[2] Cryer, J. D.; Chan, K.-S. Time Series Analysis: With Applications in R. Springer Science & Business Media, 2008.

[3] Han, J.; Pei, J.; Tong, H. Data Mining: Concepts and Techniques. 4th edition ed. Cambridge, MA: Morgan Kaufmann, 2022.

[4] James, G. M.; Witten, D.; Hastie, T.; Tibshirani, R. An Introduction to Statistical Learning: With Applications in R. [s.l.] Springer Nature, 2021.