




Preparação de Séries Temporais: Transformações, Fourier e Janelas



Eduardo Ogasawara

eogasawara@cefet-rj.br | <https://eic.cefet-rj.br/~eogasawara>



Processamento de Séries Temporais

Transformar a série bruta em um objeto analisável, pronto para predição e detecção de eventos.

Antes de modelar, a série passa por uma transformação $\mathcal{T}$ que a converte em uma nova representação:

$$Y_t = \mathcal{T}(X_t)$$

Onde X_t é o valor observado no tempo t , Y_t é a representação transformada, e $\mathcal{T}$ é a transformação escolhida. A escolha de $\mathcal{T}$ determina quais padrões e desvios se tornam visíveis — e, portanto, o que pode ser predito ou detectado.

- ❏ Esta aula é a **ponte operacional** entre compreender uma série e utilizá-la para predição e detecção de eventos. As transformações são o mecanismo que converte conhecimento estrutural da série em representações acionáveis para modelagem.

Agregação temporal

- Agrupa observações em uma frequência mais baixa.
- Reduz ruído e simplifica a análise.
- Também pode remover detalhes importantes para eventos curtos.


Formalmente, dado um fator de agregação m :

$$Y_k = \mathcal{A}(X_{(k-1)m+1}, \dots, X_{km})$$

onde m é o fator de agregação, k é o índice do período agregado, e $\mathcal{A}$ é a função de agregação (ex: média, soma, máximo).

Para agregação por média:

$$Y_k = \frac{1}{m} \sum_{j=1}^m X_{(k-1)m+j}$$



A agregação temporal muda o nível de frequência usado na análise.

Pré-processamento Temporal

Transformações operacionais que ajustam **escala** e **estrutura** da série antes da análise — alterando como desvios e eventos aparecem nos dados, sem alterar sua sequência temporal.

Normalização

$$X_t^{(norm)} = \frac{X_t - \mu}{\sigma}$$

Onde μ é a média da série e σ é o desvio padrão.

Requer $\sigma > 0$; se $\sigma = 0$, a normalização z-score não é definida.

Diferenciação

$$\Delta X_t = X_t - X_{t-1}$$

Variação entre instantes consecutivos.

ENTRADA: X (série temporal de comprimento T)

PRÉ-CONDIÇÃO: série observada; valores ausentes tratados ou removidos antes das transformações numéricas

PASSO 1 — Normalização

$\mu \leftarrow \text{média}(X)$

$\sigma \leftarrow \text{desvio_padrão}(X)$

SE $\sigma = 0$: interromper — normalização não definida

PARA t de 1 até T :

$X_t^{(norm)} \leftarrow (X_t - \mu) / \sigma$

PASSO 2 — Diferenciação

PARA t de 2 até T :

$\Delta X_t \leftarrow X_t - X_{t-1}$

SAÍDA: $X^{(norm)}$ (série normalizada), ΔX (série diferenciada)

PÓS-CONDIÇÃO: $X^{(norm)}$ tem média ≈ 0 e $\sigma \approx 1$;

ΔX remove tendências lineares

Engenharia Temporal e Modelagem de Desvios

Modelos geram uma representação da série, e desvios são identificados em relação ao modelo. A escolha da representação é decisiva.

Cálculo do Resíduo

$$R_t = X_t - \hat{X}_t$$

Onde X_t é o valor observado e $\hat{X}_t$ é o valor estimado pelo modelo.

Primeiro definimos o comportamento esperado da série por meio de um modelo. Em seguida, medimos o quanto os dados reais se afastam desse comportamento.

Identificação de Desvios

$$|R_t| > h$$

Um desvio ocorre quando o resíduo R_t ultrapassa o limiar h .


Diferenciação como Transformação para Estacionariedade

Séries não estacionárias têm média ou variância que variam ao longo do tempo, tornando-as inadequadas para modelagem direta. A diferenciação é a transformação mais comum para estabilizar a série: ela subtrai cada observação da anterior, removendo tendências sistemáticas e tornando a série mais modelável.


$$Y_t = X_t - X_{t-1}$$

A diferenciação é uma ferramenta de preparação — ela transforma a série para que os fundamentos de estacionariedade se apliquem. Os detalhes operacionais de quando e como diferenciar, incluindo a escolha da ordem de diferenciação, serão aprofundados nas próximas apresentações.

Antes: passeio aleatório (não estacionário)



Depois: série diferenciada $\Delta X_t = X_t - X_{t-1}$



Transformações Temporais

Em vez de trabalhar com níveis, muitas análises operam sobre **variações**: retornos simples e logarítmicos destacam mudanças relativas entre períodos consecutivos.

Retorno Simples

$$R_t = \frac{X_t - X_{t-1}}{X_{t-1}}$$

Mede a variação percentual entre períodos consecutivos. Requer $X_{t-1} \neq 0$.

Retorno Logarítmico

$$r_t = \log(X_t) - \log(X_{t-1})$$

Propriedades matemáticas mais convenientes para análise. Requer $X_t > 0$ para todo t .

Transformada de Fourier

Toda série temporal pode ser vista de dois ângulos: no domínio do tempo, observamos valores ao longo de instantes; no domínio da frequência, enxergamos quais ciclos compõem a série — e com que intensidade.

A transformada discreta de Fourier realiza essa mudança de perspectiva:

$$C_k = \sum_t X_t e^{-i2\pi kt/n}$$

Cada coeficiente C_k captura a energia associada à frequência k , revelando padrões periódicos invisíveis na série bruta.

Fourier mostra quais frequências existem na série, mas não preserva **quando** cada oscilação ocorre — a localização temporal é perdida na transformação.

Domínio do Tempo

Mostra **quando** algo acontece. Útil para detectar mudanças pontuais e tendências.

Domínio da Frequência

Mostra **como** a série oscila. Útil para isolar ciclos regulares e separar sinal de ruído.

- ❏ Cada representação revela um tipo diferente de padrão. A perda de localização temporal em Fourier — não saber **quando** cada frequência ocorre — motiva o uso de wavelets, que combinam resolução temporal e espectral.

Decomposição por Wavelets

Wavelets oferecem uma representação alternativa da série que combina tempo e frequência simultaneamente. Ao contrário de Fourier, que dissolve a informação temporal, wavelets tornam visíveis desvios localizados — anomalias que ocorrem em momentos específicos e em escalas específicas.

$$W(a, b) = \int X(t) \psi_{a,b}(t) dt$$

O parâmetro a controla a escala (largura da wavelet) e b controla a posição temporal.

Wavelets preservam simultaneamente informação de tempo e escala — o que Fourier não consegue. A escolha da representação determina o que é detectável.

Localização Temporal

Revela *quando* um desvio ocorre — algo que a representação de Fourier não preserva

Análise Multi-escala

Revela *em que escala* o desvio se manifesta — distinguindo flutuações rápidas de mudanças lentas


Decomposição por EMD

A EMD decompõe um sinal em componentes oscilatórias chamadas IMFs (Intrinsic Mode Functions):


$$X(t) = \sum_{i=1}^n \text{IMF}_i(t) + r(t)$$

onde $\text{IMF}_i(t)$ são as funções de modo intrínseco e $r(t)$ é o resíduo (tendência de longo prazo).

Cada IMF representa uma escala de oscilação distinta. O resíduo $r(t)$ captura a tendência global da série.



(a) temperature and EMD trend



(c) residual (sum of IMFs)

EMD aplicada à YGT: componente residual de tendência e primeira IMF.

Representação Local da Série

Dividir a série em subsequências torna visíveis **padrões locais** invisíveis na perspectiva global. A subsequência $X_{t:t+w-1}$ define um recorte de comprimento w iniciado em t :

$$X_{t:t+w-1} = (X_t, X_{t+1}, \dots, X_{t+w-1})$$

Cada subsequência transforma um trecho da série em um objeto comparável: é possível medir similaridade, distância, forma local ou desvio local entre janelas. Isso permite detectar mudanças de comportamento confinadas a intervalos específicos — e é a base do mecanismo de janelas deslizantes.

Janelas Deslizantes

O tamanho da janela w define **qual escala de comportamento fica visível** — cada escolha induz uma representação local diferente da série.

$$\mathcal{W}_w(X_t) = \{X_{t:t+w-1}\} \text{ para cada posição } t$$

Janelas Curtas

Anomalias pontuais e mudanças abruptas

Janelas Médias

Padrões transitórios e mudanças de regime

Janelas Longas

Tendências e ciclos de larga escala

ENTRADA: X (série de comprimento T), w (tamanho da janela), h (limiar)
PRÉ-CONDIÇÃO: $w \geq 2$; $T > w$; cenário de detecção **online** (one-step-ahead)

PASSO 1 — Deslizamento da janela passada

PARA t de $w+1$ até T :

$W_t \leftarrow X[t-w : t-1]$ // janela de w pontos anteriores a t

PASSO 2 — Cálculo de estatística da janela passada

PARA cada t :

$\mu_t \leftarrow \text{média}(W_t)$

$\sigma_t \leftarrow \text{desvio_padrão}(W_t)$

SE $\sigma_t = 0$: $\sigma_t \leftarrow 1$ // proteção contra divisão por zero

PASSO 3 — Avaliação **do** ponto corrente

PARA cada t :


SE $|X_t - \mu_t| > h \cdot \sigma_t$:

marcar t como desvio // X_t não pertence à janela de referência

SAÍDA: lista de instantes t marcados como desvio

PÓS-CONDIÇÃO: desvios detectados sem vazamento temporal; X_t avaliado apenas com informação anterior a t

Subseqüências e janelas deslizantes



Uma série pode ser decomposta em janelas que se deslocam ao longo do tempo.

Workflow Temporal

O processamento de séries temporais segue um **pipeline de transformações**. As etapas são tipicamente sequenciais, mas podem envolver escolhas, alternativas e retornos — cada decisão muda o tipo de padrão ou desvio que fica visível.

Série Bruta

X_t — sinal original, com ruído e escala arbitrária

Transformação

$X_t^{(tr)}$ — normalização, diferenciação ou decomposição

Representação

$X_t^{(rep)}$ — janela deslizante ou características extraídas da série

Modelo


$\hat{X}_t$ — ajuste ou previsão sobre a representação

Análise

$R_t = X_t - \hat{X}_t$ (resíduo); $E_t = \mathbf{1}\{|R_t| > h\}$ (indicador de desvio)


📌 **A escolha do pipeline determina o que é detectável.** Esta aula fornece as ferramentas para construir esse pipeline — desde a transformação inicial até a geração de previsões e a detecção de eventos. Cada etapa é uma decisão sobre o que importa observar.

Referências Bibliográficas




Event Detection in Time Series

Ogasawara, E.; Salles, R.; Porto, F.; Pacitti, E.
Springer Nature Switzerland, 2025.



Time Series Analysis: With Applications in R

Cryer, J. D.; Chan, K.-S. Springer, 2008.



Data Mining: Concepts and Techniques

Han, J.; Pei, J.; Tong, H. Morgan Kaufmann, 4^a ed., 2022.