


Modelos Lineares em Séries Temporais

Modelos lineares representam séries temporais como combinações lineares de valores passados e choques aleatórios. A base fundamental é o ruído branco, que captura a parte imprevisível do processo. A dependência temporal é modelada através da acumulação de choques ao longo do tempo.


Eduardo Ogasawara

eduardo.ogasawara@cefet-rj.br


<https://eic.cefet-rj.br/~eogasawara>



Ruído branco (realização)



ACF do ruído branco (esperado ~ 0)



Fundamentos do Ruído Branco

Média Zero

A esperança do ruído branco é sempre zero, representando ausência de viés sistemático.

$$\mathbb{E}[\varepsilon_t] = 0$$

Variância Constante

A variância permanece constante ao longo do tempo, garantindo homoscedasticidade.


$$\text{Var}(\varepsilon_t) = \sigma^2$$

Não Correlacionado

Choques em diferentes momentos são independentes entre si.

$$\text{Cov}(\varepsilon_t, \varepsilon_{t-h}) = 0$$

Essas três propriedades definem o ruído branco como o componente fundamental imprevisível em modelos de séries temporais.



Processo Linear Causal

Um processo linear causal expressa o valor atual da série como função de choques aleatórios passados e presentes:

$$X_t = \mu + \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j}$$

Onde μ representa a média do processo, ε_t são os choques aleatórios, e ψ_j são os pesos que determinam como cada choque defasado influencia o presente.

A causalidade garante que o presente depende apenas do passado, não do futuro. Os pesos ψ_j tipicamente decrescem com j , refletindo que choques mais antigos têm menor impacto.

Choque Atual

Impacto imediato ψ_0

Choques Recentes

Influência moderada

Choques Antigos

Efeito decrescente

Operador de Defasagem

O operador de defasagem B é uma ferramenta algébrica que desloca a série no tempo. Sua definição fundamental é $BX_t = X_{t-1}$, e aplicações sucessivas produzem $B^k X_t = X_{t-k}$.

Polinômio Autoregressivo

$$\phi(B) = 1 - \phi_1 B - \dots - \phi_p B^p$$

Representa a estrutura de dependência dos valores passados da série.

Polinômio de Média Móvel

$$\theta(B) = 1 + \theta_1 B + \dots + \theta_q B^q$$

Captura a propagação de choques aleatórios ao longo do tempo.

Esses polinômios transformam modelos temporais em expressões algébricas compactas, simplificando análise matemática e formulação de condições de estacionariedade.

Modelo Autoregressivo AR(p)

No modelo autoregressivo, a série é explicada por seus próprios valores passados mais um ruído branco que representa inovação imprevisível:

$$X_t = c + \phi_1 X_{t-1} + \dots + \phi_p X_{t-p} + \varepsilon_t$$

Forma Expandida

Combinação linear explícita de p valores defasados

Forma Compacta


Representação usando operador: $\phi(B)X_t = c + \varepsilon_t$

Média do Processo


Determinada pela constante c e pelos coeficientes autoregressivos ϕ_i

A constante c define o nível médio da série, enquanto os coeficientes ϕ_i determinam a intensidade da dependência temporal.


Série AR(2) simulada



AR(1) estacionário ($|\phi| < 1$)



Passeio aleatório (raiz unitária, $\phi=1$)



Estacionariedade do AR(p)

A estacionariedade de um processo AR(p) depende fundamentalmente dos coeficientes autoregressivos. A condição é expressa através das raízes do polinômio característico:

$$\phi(z) = 1 - \phi_1 z - \dots - \phi_p z^p$$

Para estacionariedade, todas as raízes devem satisfazer $|z| > 1$, ou seja, estar fora do círculo unitário no plano complexo.

Caso Especial: AR(1)

Para o modelo $X_t = c + \phi X_{t-1} + \varepsilon_t$, a condição simplifica para $|\phi| < 1$.

Propriedades do AR(1)

O modelo autoregressivo de primeira ordem é o mais simples e ilustrativo, com dependência temporal controlada por um único parâmetro:

$$X_t = c + \phi X_{t-1} + \varepsilon_t$$

Média

Calculada como $\mu = \frac{c}{1-\phi}$

Variância

Dada por $\text{Var}(X_t) = \frac{\sigma^2}{1-\phi^2}$


Autocorrelação

Decai exponencialmente: $\rho(h) = \phi^h$


Interpretação do Coeficiente

Quanto maior $|\phi|$, mais persistente é a série. Valores próximos de 1 indicam alta memória temporal, enquanto valores próximos de 0 sugerem comportamento próximo ao ruído branco.

ACF (AR(2): decaimento)



PACF (AR(2): corte após a defasagem 2)



Autocorrelação Parcial (PACF)

A autocorrelação parcial mede a dependência direta entre X_t e X_{t-h} , removendo o efeito de todas as defasagens intermediárias.

Matematicamente, $\alpha(h)$ é o coeficiente de X_{t-h} na regressão:

$$X_t = \beta_1 X_{t-1} + \cdots + \beta_h X_{t-h} + u_t$$

A PACF é uma ferramenta essencial para identificação de modelos, complementando a análise da ACF.

Propriedade Fundamental

Para um processo AR(p), a PACF satisfaz $\alpha(h) = 0$ para todo $h > p$

Identificação de Ordem

O corte abrupto da PACF identifica diretamente a ordem p do modelo autoregressivo

Modelo de Média Móvel MA(q)

No modelo de média móvel, a série é explicada por choques aleatórios presentes e passados, sem dependência direta de valores passados da própria série:

$$X_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}$$

Forma Compacta

Usando operador de defasagem:

$$X_t = \mu + \theta(B)\varepsilon_t$$

Estrutura

Combinação linear de $q + 1$ choques aleatórios consecutivos

Memória Finita

Apenas os últimos q choques influenciam o presente

Diferentemente do AR, não há regressão sobre valores passados da série. O comportamento temporal é determinado exclusivamente pela acumulação de choques aleatórios.

Modelo ARMA(p,q)

O modelo ARMA combina componentes autoregressivos e de média móvel, representando a forma linear mais geral para séries temporais estacionárias:

$$X_t = c + \sum_{i=1}^p \phi_i X_{t-i} + \varepsilon_t + \sum_{j=1}^q \theta_j \varepsilon_{t-j}$$

Parte AR

Captura persistência temporal através de p valores defasados

Parte MA

Modela propagação de choques através de q termos de erro

Forma Compacta

Expressa como $\phi(B)X_t = c + \theta(B)\varepsilon_t$

O ARMA é a base dos modelos clássicos de séries temporais estacionárias, oferecendo flexibilidade para capturar diversos padrões de dependência temporal com parcimônia de parâmetros.

Condições de Estacionariedade e Invertibilidade

Duas condições garantem que o ARMA(p,q) seja bem definido e interpretável.

Estacionariedade (parte AR)

Condição: $\phi(z) = 0 \Rightarrow |z| > 1$

Raízes do polinômio AR fora do círculo unitário. Garante que a série não explode e que suas propriedades estatísticas são estáveis no tempo.


Sob essas condições, o ARMA admite representações equivalentes como $MA(\infty)$ e $AR(\infty)$, revelando a dualidade estrutural dos modelos lineares.

Invertibilidade (parte MA)


Condição: $\theta(z) = 0 \Rightarrow |z| > 1$

Raízes do polinômio MA fora do círculo unitário. Assegura unicidade da representação e que choques passados podem ser recuperados.


ACF — AR(2): PACF corta; ACF decai



ACF — MA(2): ACF corta; PACF decai



ACF — ARMA(1,1): nenhum corta



ACF e PACF no ARMA

AR(p)

PACF: Corta após lag p

ACF: Decai gradualmente

MA(q)

ACF: Corta após lag q

PACF: Decai gradualmente

ARMA(p,q)

ACF: Decai sem corte abrupto

PACF: Decai sem corte abrupto

No ARMA, a ausência de cortes abruptos exige critérios de informação para identificação das ordens.

Método Box-Jenkins

Procedimento iterativo para identificação, estimação e validação de modelos ARMA(p,q).

$$\phi(B)X_t = c + \theta(B)\varepsilon_t$$

Critérios AIC e BIC penalizam modelos com mais parâmetros, favorecendo parcimônia.

ENTRADA: Série temporal $\{X_t\}$, ordens máximas $p_{\max}$, $q_{\max}$

PRÉ-CONDIÇÃO: Série estacionária (ou previamente diferenciada)

PASSO 1 — Identificação

Calcular ACF e PACF empíricas

Propor ordens candidatas (p, q) com $p \leq p_{\max}$, $q \leq q_{\max}$

PASSO 2 — Estimação

Para cada (p, q) candidato:

Estimar parâmetros por máxima verossimilhança

Calcular AIC e BIC

PASSO 3 — Diagnóstico

Calcular resíduos: $\hat{\varepsilon}_t = X_t - \hat{X}_t$

SE autocorrelação nos resíduos detectada:

Retornar ao PASSO 1

PASSO 4 — Seleção

Escolher modelo com menor AIC ou BIC

Registrar ordens finais p^* e q^*

SAÍDA: Modelo ARMA(p^* , q^*) estimado e validado

PÓS-CONDIÇÃO: Resíduos sem autocorrelação significativa

Não Estacionariedade e Raiz Unitária

Quando o modelo AR possui raiz unitária, o processo torna-se não estacionário. O caso limite é o passeio aleatório:

$$X_t = X_{t-1} + \varepsilon_t$$

Processo Estacionário

Modelo $X_t = \phi X_{t-1} + \varepsilon_t$ com $|\phi| < 1$

Raiz Unitária


Caso limite quando $\phi = 1$, gerando não estacionariedade

Ordem de Integração


Número d de diferenciações necessárias: $\Delta^d X_t$ é estacionário

A não estacionariedade surge quando choques têm efeito permanente sobre o nível da série. A ordem de integração d mede quantas diferenciações são necessárias para restaurar a estacionariedade.

Passeio aleatório (raiz unitária)



Primeira diferença: $\Delta X_t = X_t - X_{t-1}$



Modelo ARIMA

O modelo ARIMA integra diferenciação e estrutura ARMA, representando a extensão natural para séries não estacionárias:

$$\phi(B)(1 - B)^d X_t = c + \theta(B)\varepsilon_t$$

Ordem AR (p)

Captura dependência de valores passados da série diferenciada

Ordem de Integração (d)

Número de diferenciações para alcançar estacionariedade

Ordem MA (q)


Modela propagação de choques aleatórios

Aplicações do ARIMA


O ARIMA define o comportamento esperado da série, servindo como modelo de referência. Eventos, anomalias e mudanças estruturais são identificados como desvios sistemáticos em relação ao padrão previsto pelo modelo.

Os modelos lineares formam o núcleo da teoria clássica de séries temporais, fornecendo a base conceitual e metodológica para previsão, análise estrutural e detecção de eventos em dados temporais.



Série não estacionária



Resíduos do ARIMA (ideal: ~ ruído branco)



Referências Bibliográficas



Event Detection in Time Series

Ogasawara, E.; Salles, R.; Porto, F.; Pacitti, E.
Springer Nature Switzerland, 2025.

Time Series Analysis: With Applications in R

Cryer, J. D.; Chan, K.-S. Springer, 2008.

Data Mining: Concepts and Techniques

Han, J.; Pei, J.; Tong, H. Morgan Kaufmann, 4^a ed., 2022.