AR, MA, ARMA e ARIMA: Como Prever Séries Temporais?

CEFET/RJ

Eduardo Ogasawara

eogasawara@cefet-rj.br | https://eic.cefet-rj.br/~eogasawara

Modelagem Preditiva

O modelo define o comportamento esperado da série; desvios são identificados onde a previsão e o valor observado divergem além de um limiar h.

$$E_t = \begin{cases} 1, & |X_t - \hat{X}_t| > h \\ 0, & \text{caso contrário} \end{cases}$$

O resíduo $R_t = X_t - \hat{X}_t$ tem **duplo papel**: avalia a qualidade da previsão (quão bem o modelo ajusta a série) e serve de base para a detecção de desvios (quando $|R_t| > h$, um evento é sinalizado).

Valor Observado

X_t — dado real no tempo t

Valor Previsto

$\hat{X}_t$ — referência de normalidade gerada pelo modelo

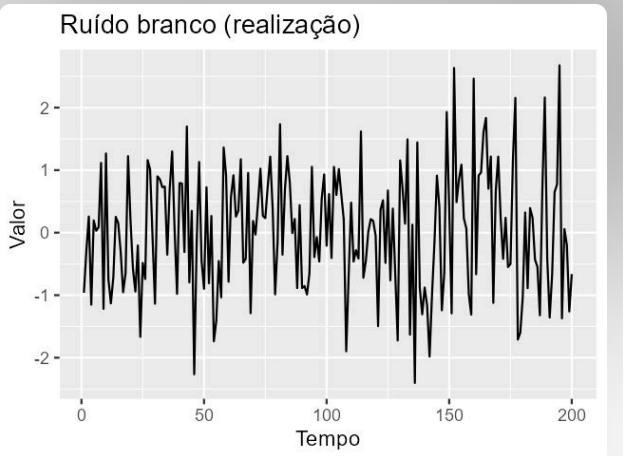
Limiar

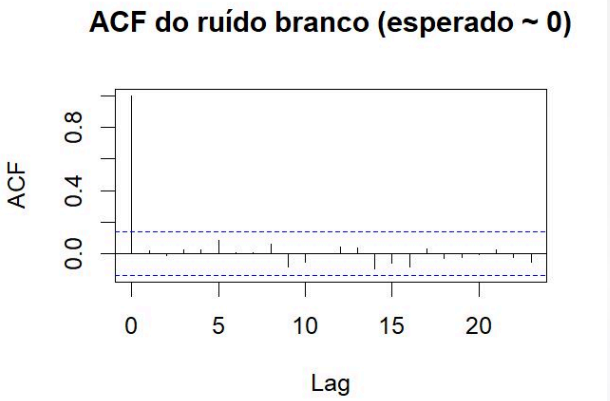
h — define o que é considerado desvio significativo

```
ENTRADA: X (série de comprimento T), modelo M, h (limiar)
PRÉ-CONDIÇÃO: modelo M ajustado sobre X[1:W]; W definido antes do início do loop

PASSO 1 — Período inicial de treinamento
  W ← tamanho mínimo da janela de treinamento
  Ajustar M sobre X[1 : W]
PASSO 2 — Geração de previsões one-step-ahead
  PARA t de W+1 até T:
    X̂_t ← M.prever(X[1 : t-1])   // apenas informação anterior a t
PASSO 3 — Cálculo do resíduo
  PARA t de W+1 até T:
    R_t ← X_t - X̂_t
PASSO 4 — Aplicação do limiar
  PARA t de W+1 até T:
    SE |R_t| > h:
      E_t ← 1   // desvio detectado
    SENÃO:
      E_t ← 0   // comportamento normal

SAÍDA: E (indicador binário de desvio por instante)
PÓS-CONDIÇÃO: E_t = 1 identifica instantes onde o
  modelo não explica o comportamento observado
```





Fundamentos do Ruído Branco

Média Zero

A esperança do ruído branco é sempre zero, representando ausência de viés sistemático.

$$\mathbb{E}[\varepsilon_t] = 0$$

Variância Constante

A variância permanece constante ao longo do tempo, garantindo homoscedasticidade.

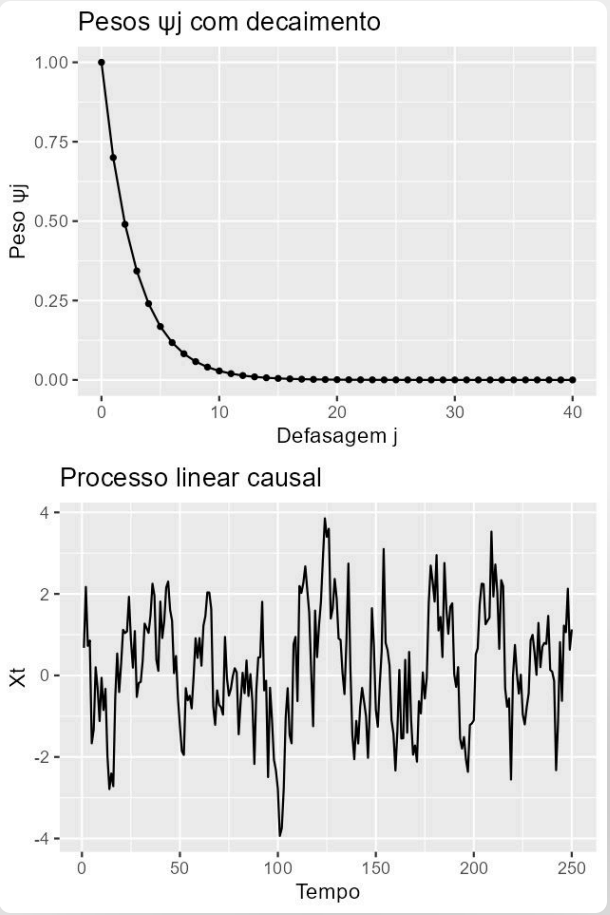
$$\mathrm{Var}(\varepsilon_t) = \sigma^2$$

Não Correlacionado

Choques em diferentes momentos são independentes entre si.

$$\mathrm{Cov}(\varepsilon_t, \varepsilon_{t-h}) = 0$$

Essas três propriedades definem o ruído branco como o componente fundamental imprevisível em modelos de séries temporais.



Processo Linear Causal

Um processo linear causal expressa o valor atual da série como função de choques aleatórios passados e presentes:

$$X_t = \mu + \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j}$$

Onde μ representa a média do processo, ε_t são os choques aleatórios, e ψ_j são os pesos que determinam como cada choque defasado influencia o presente.

A causalidade garante que o presente depende apenas do passado, não do futuro. Os pesos ψ_j tipicamente decrescem com j, refletindo que choques mais antigos têm menor impacto.

Choque Atual

Impacto imediato ψ_0

Choques Recentes

Influência moderada

Choques Antigos

Efeito decrescente

Operador de Defasagem

O operador de defasagem B é uma ferramenta algébrica que desloca a série no tempo. Sua definição fundamental é $BX_t = X_{t-1}$, e aplicações sucessivas produzem $B^k X_t = X_{t-k}$.

Polinômio Autoregressivo

$$\phi(B) = 1 - \phi_1 B - \cdots - \phi_p B^p$$

Representa a estrutura de dependência dos valores passados da série.

Polinômio de Média Móvel

$$\theta(B) = 1 + \theta_1 B + \cdots + \theta_q B^q$$

Captura a propagação de choques aleatórios ao longo do tempo.

Esses polinômios transformam modelos temporais em expressões algébricas compactas, simplificando análise matemática e formulação de condições de estacionariedade.

AR(1): Primeiro Modelo de Dependência Temporal

O Modelo

$$X_t - \mu = \phi\,(X_{t-1} - \mu) + \varepsilon_t$$

$$\hat{X}_t = \mu + \phi\,(X_{t-1} - \mu)$$

Memória Temporal

O valor atual carrega informação do passado.

Parâmetro φ

Controla a intensidade da dependência. Quanto maior |φ|, mais forte a memória.

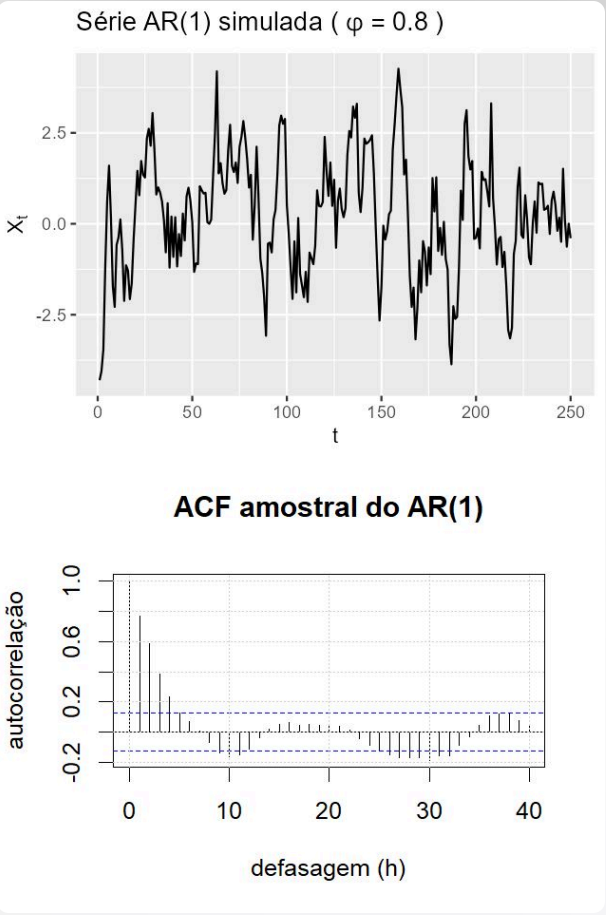
Resíduo ε_t

Choque aleatório observado APÓS x_t ser conhecido: ε_t = x_t − x̂_t. Não entra na fórmula operacional da previsão.

ENTRADA: série X = <x1, ..., xn>
PRÉ-CONDIÇÃO: série estacionária ou centrada; n >= 2

PASSO 1 — Estimar a média mu da série
PASSO 2 — Centralizar a série:
 y_t <- x_t - mu
PASSO 3 — Estimar phi:
 phi <- sum_{t=2..n}(y_t * y_{t-1}) /
  sum_{t=2..n}(y_{t-1}^2)
PASSO 4 — Para t = 2 até n:
 yhat_t <- phi * y_{t-1}
 xhat_t <- mu + yhat_t
 epsilon_t <- x_t - xhat_t
PASSO 5 — Diagnosticar resíduos epsilon_t

SAÍDA: phi, valores ajustados xhat_t e resíduos epsilon_t
PÓS-CONDIÇÃO: resíduos devem se comportar como ruído branco



AR(1): Condições e Propriedades

Estacionariedade

O processo AR(1) é estacionário quando $|\phi| < 1$. Nesse caso, os efeitos de choques passados diminuem ao longo do tempo e as propriedades estatísticas se estabilizam.

$$|\phi| < 1$$

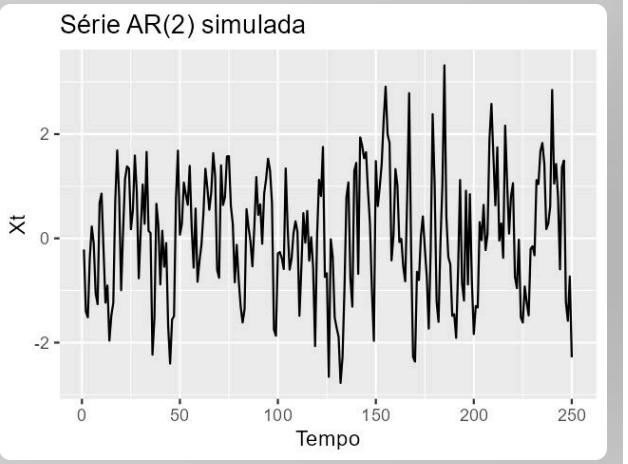
Autocorrelação

A autocorrelação do AR(1) decai exponencialmente com a defasagem. Essa "assinatura" permite identificar o modelo a partir dos dados observados.

$$\rho(h) = \phi^h$$

O AR(1) é o primeiro exemplo concreto de como a dependência temporal pode ser formalizada e estimada. Ele ilustra os princípios que sustentam modelos mais complexos — AR de ordem superior, MA, ARMA e ARIMA — que serão aprofundados na apresentação 04.

Modelo Autoregressivo AR(p)



No modelo autoregressivo, a série é explicada por seus próprios valores passados mais um ruído branco que representa inovação imprevisível:

$$X_t = c + \phi_1 X_{t-1} + \cdots + \phi_p X_{t-p} + \varepsilon_t$$

Forma Expandida

Combinação linear explícita de p valores defasados

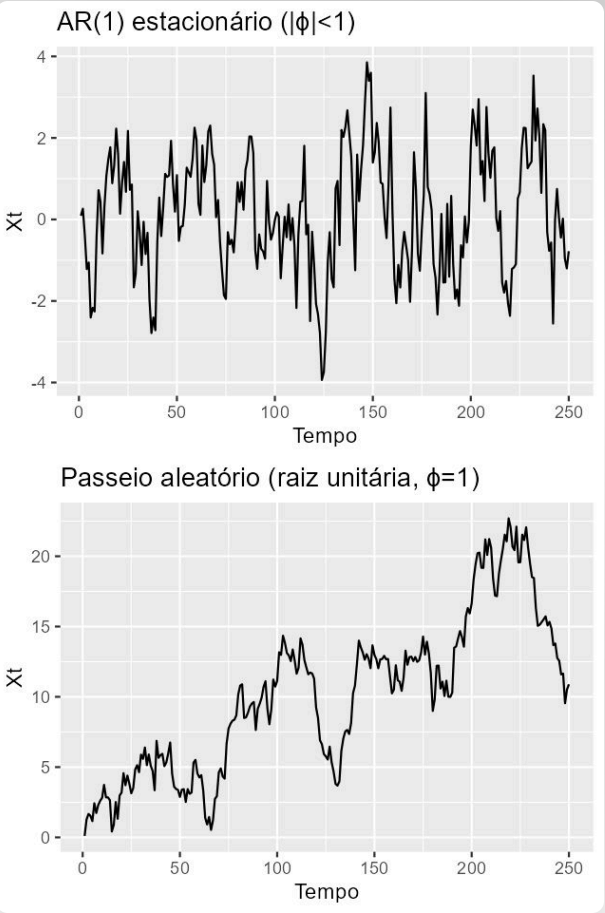
Forma Compacta

Representação usando operador: $\phi(B)X_t = c + \varepsilon_t$

Média do Processo

Determinada pela constante c e pelos coeficientes autoregressivos ϕ_i

A constante c define o nível médio da série, enquanto os coeficientes ϕ_i determinam a intensidade da dependência temporal.



Estacionariedade do AR(p)

A estacionariedade de um processo AR(p) depende fundamentalmente dos coeficientes autoregressivos. A condição é expressa através das raízes do polinômio característico:

$$\phi(z) = 1 - \phi_1 z - \cdots - \phi_p z^p$$

Para estacionariedade, todas as raízes devem satisfazer $|z| > 1$, ou seja, estar fora do círculo unitário no plano complexo.

Caso Especial: AR(1)

Para o modelo $X_t = c + \phi X_{t-1} + \varepsilon_t$, a condição simplifica para $|\phi| < 1$.

Propriedades do AR(1)

Como caso particular do AR(p) com $p = 1$, o AR(1) ilustra de forma direta as propriedades gerais do modelo:

$$X_t = c + \phi X_{t-1} + \varepsilon_t$$

Média

Caso particular de $\mu = (I - \Phi)^{-1} c$: $\mu = \frac{c}{1-\phi}$

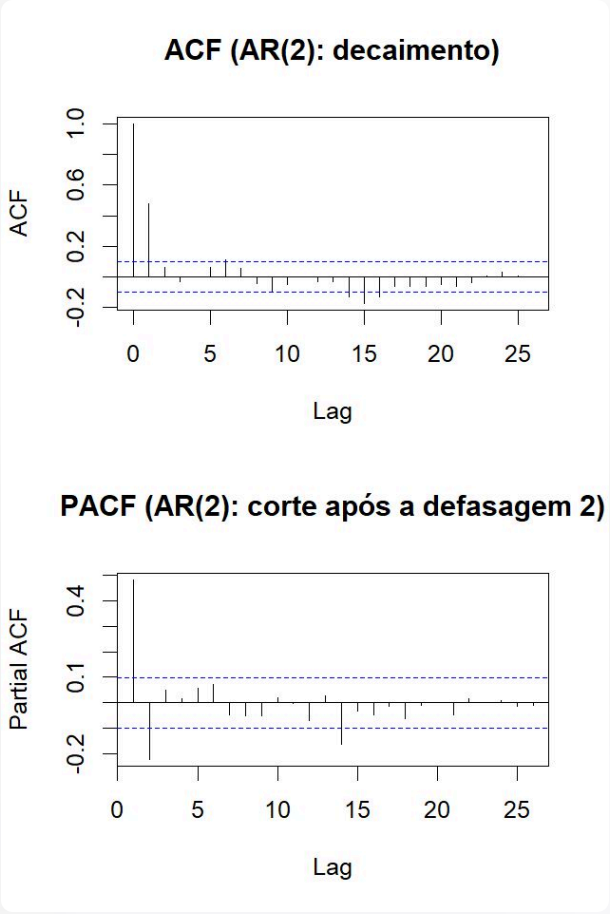
Variância

Caso particular da equação de Yule-Walker: $\text{Var}(X_t) = \frac{\sigma^2}{1-\phi^2}$

Autocorrelação

Decaimento exponencial da ACF geral: $\rho(h) = \phi^h$

A estrutura de decaimento exponencial da ACF do AR(1) antecipa o comportamento da previsão multi-passo: $\phi^h \to 0$ quando $|\phi| < 1$.



Autocorrelação Parcial (PACF)

A autocorrelação parcial mede a dependência direta entre X_t e X_{t-h}, removendo o efeito de todas as defasagens intermediárias.

Matematicamente, $\alpha(h)$ é o coeficiente de X_{t-h} na regressão:

$$X_t = \beta_1 X_{t-1} + \cdots + \beta_h X_{t-h} + u_t$$

Propriedade Fundamental

Para um processo AR(p), a PACF satisfaz $\alpha(h) = 0$ para todo $h > p$

Identificação de Ordem

O corte abrupto da PACF identifica diretamente a ordem p do modelo autoregressivo

A PACF é uma ferramenta essencial para identificação de modelos, complementando a análise da ACF.

Modelo de Média Móvel MA(q)

No modelo de média móvel, a série é explicada por choques aleatórios presentes e passados, sem dependência direta de valores passados da própria série:

$$X_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}$$

Forma Compacta

Usando operador de defasagem:
$X_t = \mu + \theta(B)\varepsilon_t$

Estrutura

Combinação linear de $q+1$ choques aleatórios consecutivos

Memória Finita

Apenas os últimos q choques influenciam o presente

Diferentemente do AR, não há regressão sobre valores passados da série. O comportamento temporal é determinado exclusivamente pela acumulação de choques aleatórios.

Modelo ARMA(p,q)

O modelo ARMA combina componentes autoregressivos e de média móvel, representando a forma linear mais geral para séries temporais estacionárias:

$$X_t = c + \sum_{i=1}^{p} \phi_i X_{t-i} + \varepsilon_t + \sum_{j=1}^{q} \theta_j \varepsilon_{t-j}$$

Parte AR

Captura persistência temporal através de p valores defasados

Parte MA

Modela propagação de choques através de q termos de erro

Forma Compacta

Expressa como $\phi(B)X_t = c + \theta(B)\varepsilon_t$

O ARMA é a base dos modelos clássicos de séries temporais estacionárias, oferecendo flexibilidade para capturar diversos padrões de dependência temporal com parcimônia de parâmetros.

Condições de Estacionariedade e Invertibilidade

Duas condições garantem que o ARMA(p,q) seja bem definido e interpretável.

Estacionariedade (parte AR)

Condição: $\phi(z) = 0 \Rightarrow |z| > 1$

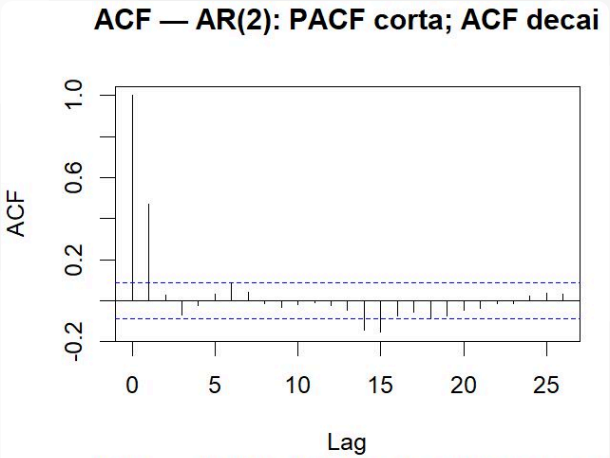
Raízes do polinômio AR fora do círculo unitário. Garante que a série não explode e que suas propriedades estatísticas são estáveis no tempo.

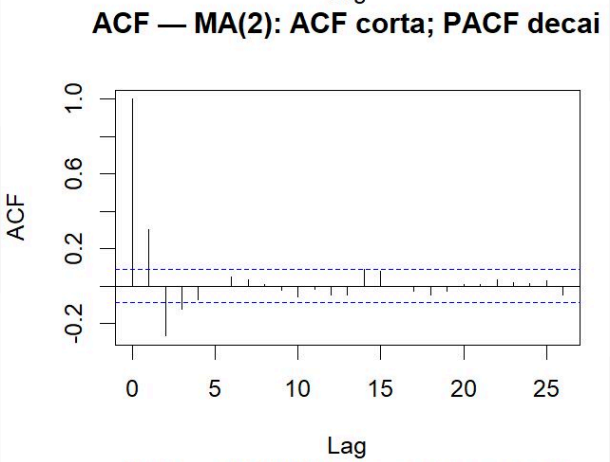
Invertibilidade (parte MA)

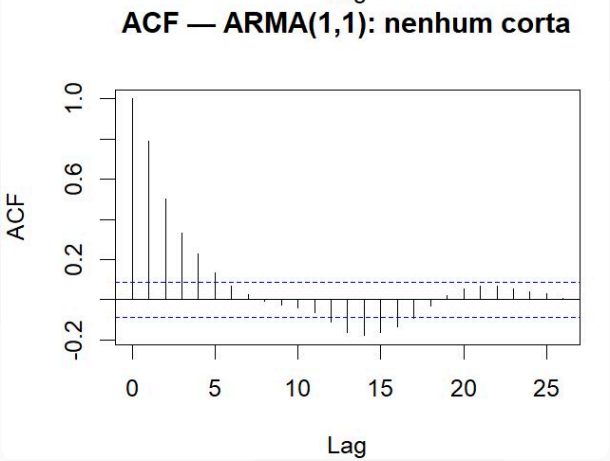
Condição: $\theta(z) = 0 \Rightarrow |z| > 1$

Raízes do polinômio MA fora do círculo unitário. Assegura unicidade da representação e que choques passados podem ser recuperados.

Sob essas condições, o ARMA admite representações equivalentes como MA(∞) e AR(∞), revelando a dualidade estrutural dos modelos lineares.







ACF e PACF no ARMA

AR(p)

PACF: Corta após lag p

ACF: Decai gradualmente

MA(q)

ACF: Corta após lag q

PACF: Decai gradualmente

ARMA(p,q)

ACF: Decai sem corte abrupto

PACF: Decai sem corte abrupto

No ARMA, a ausência de cortes abruptos exige critérios de informação para identificação das ordens.

Método Box-Jenkins

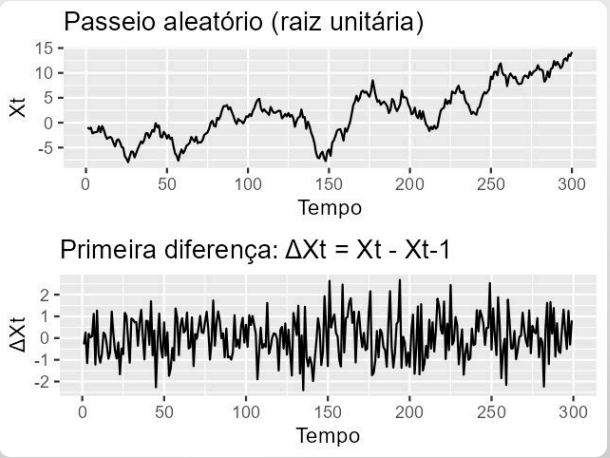
Procedimento iterativo em quatro etapas para construir um modelo ARMA(p,q) pronto para previsão.

$$\phi(B)X_t = c + \theta(B)\varepsilon_t$$

Critérios AIC e BIC penalizam modelos com mais parâmetros, favorecendo parcimônia.

```
ENTRADA: Série temporal {X_t}, ordens máximas p_max, q_max
PRÉ-CONDIÇÃO: Série estacionária (ou previamente diferenciada)

PASSO 1 — Identificação
  Calcular ACF e PACF empíricas
  Propor ordens candidatas (p, q) com p ≤ p_max, q ≤ q_max
PASSO 2 — Estimação
  Para cada (p, q) candidato:
    Estimar parâmetros por máxima verossimilhança
    Calcular AIC e BIC
PASSO 3 — Diagnóstico
  Calcular resíduos: ε̂_t = X_t − X̂_t
  SE autocorrelação nos resíduos detectada:
    Retornar ao PASSO 1
PASSO 4 — Previsão
  Escolher modelo com menor AIC ou BIC
  Gerar previsões: X̂_{t+h|t} = E[X_{t+h} | F_t]
  Calcular intervalos de previsão para cada horizonte h
SAÍDA: Modelo ARMA(p*, q*) validado e previsões X̂_{t+h|t}
PÓS-CONDIÇÃO: Resíduos sem autocorrelação significativa
```



Não Estacionariedade e Raiz Unitária

Quando o modelo AR possui raiz unitária, o processo torna-se não estacionário. O caso limite é o passeio aleatório:

$$X_t = X_{t-1} + \varepsilon_t$$

Processo Estacionário

Modelo $X_t = \phi X_{t-1} + \varepsilon_t$ com $|\phi| < 1$

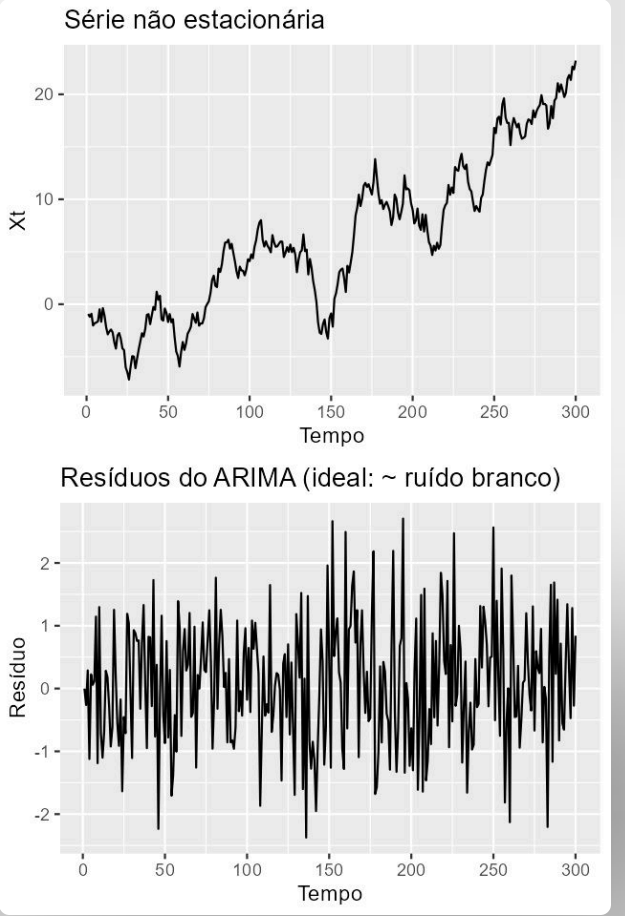
Raiz Unitária

Caso limite quando $\phi = 1$, gerando não estacionariedade

Ordem de Integração

Número d de diferenciações necessárias: $\Delta^d X_t$ é estacionário

A não estacionariedade surge quando choques têm efeito permanente sobre o nível da série. A ordem de integração d mede quantas diferenciações são necessárias para restaurar a estacionariedade.



Modelo ARIMA

O modelo ARIMA integra diferenciação e estrutura ARMA, representando a extensão natural para séries não estacionárias:

$$\phi(B)(1-B)^d X_t = c + \theta(B)\varepsilon_t$$

Ordem AR (p)

Captura dependência de valores passados da série diferenciada

Ordem de Integração (d)

Número de diferenciações para alcançar estacionariedade

Ordem MA (q)

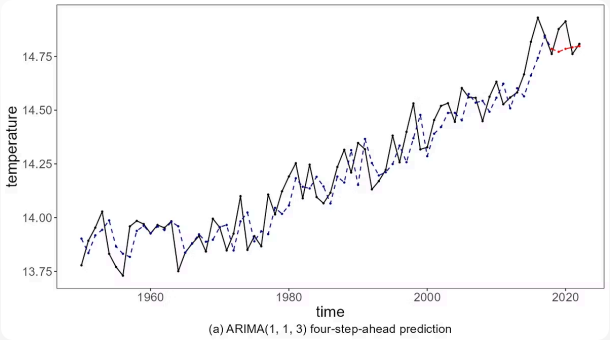
Modela propagação de choques aleatórios

Aplicações do ARIMA

O ARIMA define o comportamento esperado da série, servindo como modelo de referência. Eventos, anomalias e mudanças estruturais podem aparecer como desvios sistemáticos em relação ao padrão previsto pelo modelo.

Os modelos lineares formam o núcleo da teoria clássica de séries temporais, fornecendo a base conceitual e metodológica para previsão, análise estrutural e detecção de eventos em dados temporais.

A Matemática da Previsão



(a) ARIMA(1, 1, 3) four-step-ahead prediction

Previsão é estimar o futuro

$$\hat{X}_{t+h|t} = \mathbb{E}[X_{t+h} \mid \mathcal{F}_t]$$

Usamos toda a informação disponível até o momento presente.

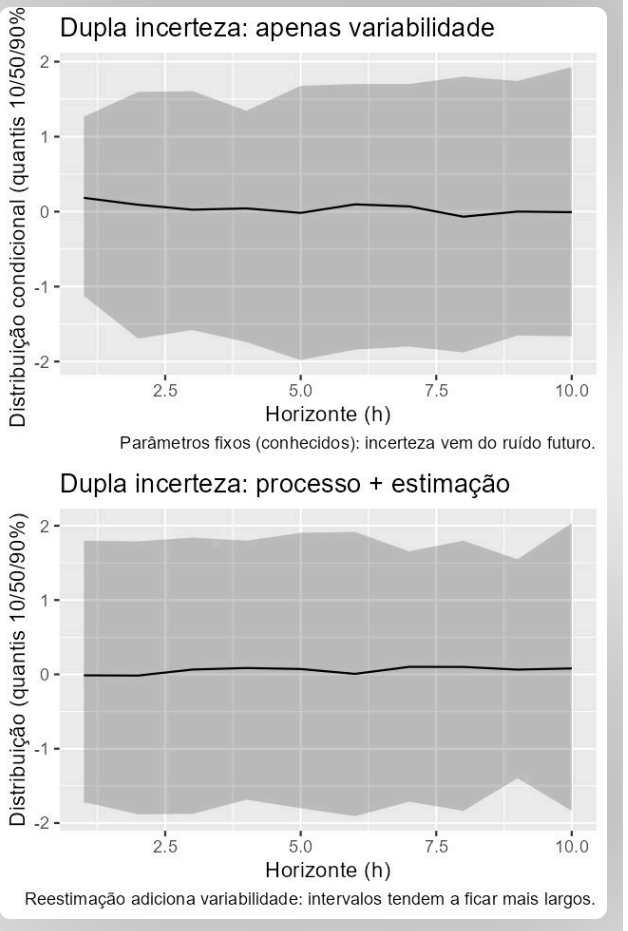
O modelo transforma passado em previsão

A estrutura do modelo define como o histórico se traduz em estimativas futuras.

O erro mede a diferença entre previsto e observado

$$e_{t+h} = X_{t+h} - \hat{X}_{t+h|t}$$

Avaliar o erro é avaliar a qualidade da previsão.



Previsão como Problema de Inferência

A previsão depende de um modelo ajustado aos dados observados. Este modelo possui parâmetros que precisam ser estimados, criando duas fontes de incerteza: a variabilidade natural do processo e a incerteza na estimação dos parâmetros.

Função de Previsão

A previsão é uma função dos dados observados e dos parâmetros estimados

Parâmetros Estimados

Usamos $\hat{\theta}$ para representar as estimativas dos parâmetros do modelo

Dupla Incerteza

Incerteza vem do comportamento aleatório da série e da estimação dos parâmetros

$$\hat{X}_{t+h|t} = g(X_t, X_{t-1}, \ldots; \hat{\theta})$$

Previsão para Múltiplos Horizontes

Modelo AR(1)

$$X_t = \phi X_{t-1} + \varepsilon_t$$

Previsão 1 passo

$$\hat{X}_{t+1|t} = \phi X_t$$

Previsão h passos

$$\hat{X}_{t+h|t} = \phi^h X_t$$

A previsão multi-passo é obtida por substituição recursiva: previsões anteriores alimentam as seguintes. A incerteza se acumula a cada passo.

$$\hat{X}_{t+h|t} = \phi^h \cdot X_t$$

ϕ é o parâmetro autoregressivo. Quando $|\phi| < 1$, a previsão $\hat{x}[k]$ converge para zero em séries centradas (sem intercepto). Se o modelo incluir intercepto μ, a previsão converge para μ.

```
ENTRADA: x (série observada), ϕ (parâmetro AR), h (horizonte)
PRÉ-CONDIÇÃO: modelo AR(1) ajustado, |ϕ| < 1

PASSO 1 — Inicialização
  x_prev ← x[T]   // último valor observado
  σ² ← variância estimada dos resíduos do modelo
PASSO 2 — Geração recursiva das previsões
  PARA k de 1 até h:
    x̂[k] ← ϕ · x_prev
    x_prev ← x̂[k]   // previsão vira entrada do próximo passo
PASSO 3 — Cálculo da variância acumulada
  PARA k de 1 até h:
    Var[k] ← σ² · SOMA(ϕ^(2j), j=0..k-1)

SAÍDA: x̂[1..h] (previsões), Var[1..h] (variâncias)
PÓS-CONDIÇÃO: x̂[k] → 0 quando k → ∞ (série centrada em zero);
              Var[k] cresce monotonicamente com k.
```

Previsão como Distribuição Condicional

A previsão não é apenas um número. O futuro é incerto, e essa incerteza pode ser quantificada.

Previsão Pontual

Um único valor resumindo a distribuição, geralmente a média ou mediana condicional.

$$\hat{X}_{t+h|t} = E[X_{t+h} \mid \mathcal{F}_t]$$

Intervalo de Previsão

Uma faixa de valores plausíveis com determinada probabilidade de conter o valor real.

$$\hat{X}_{t+h|t} \pm z_{\alpha/2}\sqrt{\mathrm{Var}(e_{t+h})}$$

Onde $z_{\alpha/2}$ é o quantil da distribuição normal e α é o nível de significância.

Incerteza

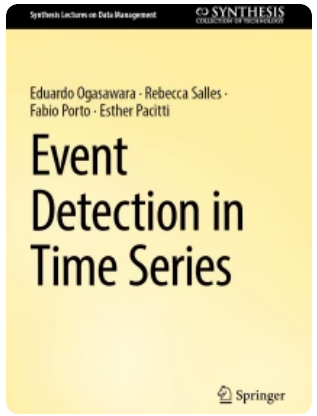
A variância do erro de previsão, que cresce com o horizonte *h*.

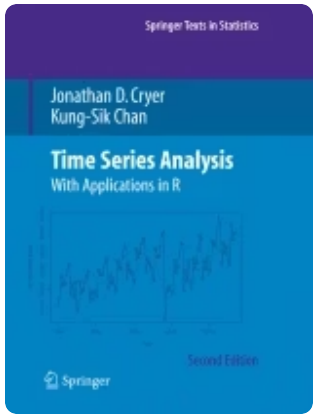
$$\mathrm{Var}(e_{t+h}) \text{ cresce com } h$$

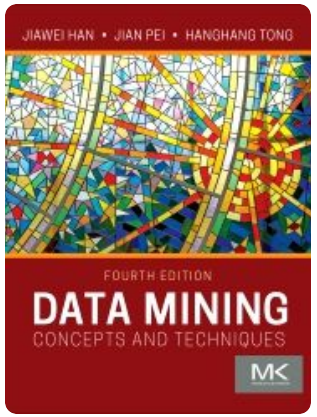
Quanto maior o horizonte, mais larga a faixa de incerteza. Reportar apenas a previsão pontual esconde informação essencial sobre o risco da previsão.

Propriedade fundamental: a esperança condicional do erro de previsão é zero — $\mathbb{E}[e_{t+h} \mid \mathcal{F}_t] = 0$ — mas a variância cresce com o horizonte *h*, refletindo a incerteza crescente no futuro distante.

Referências Bibliográficas







Event Detection in Time Series

Ogasawara, E.; Salles, R.; Porto, F.; Pacitti, E. Springer Nature Switzerland, 2025.

Time Series Analysis: With Applications in R

Cryer, J. D.; Chan, K.-S. Springer, 2008.

Data Mining: Concepts and Techniques

Han, J.; Pei, J.; Tong, H. Morgan Kaufmann, 4ª ed., 2022.