


Modelos Lineares e Previsão Temporal




Eduardo Ogasawara


eogasawara@cefet-rj.br | <https://eic.cefet-rj.br/~eogasawara>



Ruído branco (realização)



ACF do ruído branco (esperado ~ 0)



Fundamentos do Ruído Branco

Média Zero

A esperança do ruído branco é sempre zero, representando ausência de viés sistemático.

$$\mathbb{E}[\varepsilon_t] = 0$$

Variância Constante

A variância permanece constante ao longo do tempo, garantindo homoscedasticidade.


$$\text{Var}(\varepsilon_t) = \sigma^2$$

Não Correlacionado

Choques em diferentes momentos são independentes entre si.

$$\text{Cov}(\varepsilon_t, \varepsilon_{t-h}) = 0$$

Essas três propriedades definem o ruído branco como o componente fundamental imprevisível em modelos de séries temporais.



Processo Linear Causal

Um processo linear causal expressa o valor atual da série como função de choques aleatórios passados e presentes:

$$X_t = \mu + \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j}$$

Onde μ representa a média do processo, ε_t são os choques aleatórios, e ψ_j são os pesos que determinam como cada choque defasado influencia o presente.

A causalidade garante que o presente depende apenas do passado, não do futuro. Os pesos ψ_j tipicamente decrescem com j , refletindo que choques mais antigos têm menor impacto.

Choque Atual

Impacto imediato ψ_0

Choques Recentes

Influência moderada

Choques Antigos

Efeito decrescente

Operador de Defasagem

O operador de defasagem B é uma ferramenta algébrica que desloca a série no tempo. Sua definição fundamental é $BX_t = X_{t-1}$, e aplicações sucessivas produzem $B^k X_t = X_{t-k}$.

Polinômio Autoregressivo

$$\phi(B) = 1 - \phi_1 B - \dots - \phi_p B^p$$

Representa a estrutura de dependência dos valores passados da série.

Polinômio de Média Móvel

$$\theta(B) = 1 + \theta_1 B + \dots + \theta_q B^q$$

Captura a propagação de choques aleatórios ao longo do tempo.

Esses polinômios transformam modelos temporais em expressões algébricas compactas, simplificando análise matemática e formulação de condições de estacionariedade.

Modelo Autoregressivo AR(p)

No modelo autoregressivo, a série é explicada por seus próprios valores passados mais um ruído branco que representa inovação imprevisível:

$$X_t = c + \phi_1 X_{t-1} + \cdots + \phi_p X_{t-p} + \varepsilon_t$$

Forma Expandida

Combinação linear explícita de p valores defasados

Forma Compacta


Representação usando operador: $\phi(B)X_t = c + \varepsilon_t$

Média do Processo


Determinada pela constante c e pelos coeficientes autoregressivos ϕ_i

A constante c define o nível médio da série, enquanto os coeficientes ϕ_i determinam a intensidade da dependência temporal.


Série AR(2) simulada



AR(1) estacionário ($|\phi| < 1$)



Passeio aleatório (raiz unitária, $\phi=1$)



Estacionariedade do AR(p)

A estacionariedade de um processo AR(p) depende fundamentalmente dos coeficientes autoregressivos. A condição é expressa através das raízes do polinômio característico:

$$\phi(z) = 1 - \phi_1 z - \dots - \phi_p z^p$$

Para estacionariedade, todas as raízes devem satisfazer $|z| > 1$, ou seja, estar fora do círculo unitário no plano complexo.

Caso Especial: AR(1)

Para o modelo $X_t = c + \phi X_{t-1} + \varepsilon_t$, a condição simplifica para $|\phi| < 1$.

Propriedades do AR(1)

Como caso particular do AR(p) com $p = 1$, o AR(1) ilustra de forma direta as propriedades gerais do modelo:

$$X_t = c + \phi X_{t-1} + \varepsilon_t$$

Média

Caso particular de $\mu = (I - \Phi)^{-1}c$: $\mu = \frac{c}{1-\phi}$

Variância

Caso particular da equação de Yule-Walker:

$$\text{Var}(X_t) = \frac{\sigma^2}{1-\phi^2}$$


Autocorrelação

Decaimento exponencial da ACF geral:


$$\rho(h) = \phi^h$$

- A estrutura de decaimento exponencial da ACF do AR(1) antecipa o comportamento da previsão multi-passo: $\phi^h \rightarrow 0$ quando $|\phi| < 1$.

ACF (AR(2): decaimento)



PACF (AR(2): corte após a defasagem 2)



Autocorrelação Parcial (PACF)

A autocorrelação parcial mede a dependência direta entre X_t e X_{t-h} , removendo o efeito de todas as defasagens intermediárias.

Matematicamente, $\alpha(h)$ é o coeficiente de X_{t-h} na regressão:

$$X_t = \beta_1 X_{t-1} + \cdots + \beta_h X_{t-h} + u_t$$

A PACF é uma ferramenta essencial para identificação de modelos, complementando a análise da ACF.

Propriedade Fundamental

Para um processo AR(p), a PACF satisfaz $\alpha(h) = 0$ para todo $h > p$

Identificação de Ordem

O corte abrupto da PACF identifica diretamente a ordem p do modelo autoregressivo

Modelo de Média Móvel MA(q)

No modelo de média móvel, a série é explicada por choques aleatórios presentes e passados, sem dependência direta de valores passados da própria série:

$$X_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}$$

Forma Compacta

Usando operador de defasagem:

$$X_t = \mu + \theta(B)\varepsilon_t$$

Estrutura

Combinação linear de $q + 1$ choques aleatórios consecutivos

Memória Finita

Apenas os últimos q choques influenciam o presente

Diferentemente do AR, não há regressão sobre valores passados da série. O comportamento temporal é determinado exclusivamente pela acumulação de choques aleatórios.

Modelo ARMA(p,q)

O modelo ARMA combina componentes autoregressivos e de média móvel, representando a forma linear mais geral para séries temporais estacionárias:

$$X_t = c + \sum_{i=1}^p \phi_i X_{t-i} + \varepsilon_t + \sum_{j=1}^q \theta_j \varepsilon_{t-j}$$

Parte AR

Captura persistência temporal através de p valores defasados

Parte MA

Modela propagação de choques através de q termos de erro

Forma Compacta

Expressa como $\phi(B)X_t = c + \theta(B)\varepsilon_t$

O ARMA é a base dos modelos clássicos de séries temporais estacionárias, oferecendo flexibilidade para capturar diversos padrões de dependência temporal com parcimônia de parâmetros.

Condições de Estacionariedade e Invertibilidade

Duas condições garantem que o ARMA(p,q) seja bem definido e interpretável.

Estacionariedade (parte AR)

Condição: $\phi(z) = 0 \Rightarrow |z| > 1$

Raízes do polinômio AR fora do círculo unitário. Garante que a série não explode e que suas propriedades estatísticas são estáveis no tempo.


Sob essas condições, o ARMA admite representações equivalentes como $MA(\infty)$ e $AR(\infty)$, revelando a dualidade estrutural dos modelos lineares.

Invertibilidade (parte MA)


Condição: $\theta(z) = 0 \Rightarrow |z| > 1$

Raízes do polinômio MA fora do círculo unitário. Assegura unicidade da representação e que choques passados podem ser recuperados.


ACF — AR(2): PACF corta; ACF decai



ACF — MA(2): ACF corta; PACF decai



ACF — ARMA(1,1): nenhum corta



ACF e PACF no ARMA

AR(p)

PACF: Corta após lag p

ACF: Decai gradualmente

MA(q)

ACF: Corta após lag q

PACF: Decai gradualmente

ARMA(p,q)

ACF: Decai sem corte abrupto

PACF: Decai sem corte abrupto

No ARMA, a ausência de cortes abruptos exige critérios de informação para identificação das ordens.

Método Box-Jenkins

Procedimento iterativo em quatro etapas para construir um modelo ARMA(p,q) pronto para previsão.

$$\phi(B)X_t = c + \theta(B)\varepsilon_t$$

Critérios AIC e BIC penalizam modelos com mais parâmetros, favorecendo parcimônia.

ENTRADA: Série temporal $\{X_t\}$, ordens máximas $p_{\max}$, $q_{\max}$
PRÉ-CONDIÇÃO: Série estacionária (ou previamente diferenciada)

PASSO 1 — Identificação

- Calcular ACF e PACF empíricas
- Propor ordens candidatas (p, q) com $p \leq p_{\max}$, $q \leq q_{\max}$

PASSO 2 — Estimação

- Para cada (p, q) candidato:
 - Estimar parâmetros por máxima verossimilhança
 - Calcular AIC e BIC

PASSO 3 — Diagnóstico

- Calcular resíduos: $\hat{\varepsilon}_t = X_t - \hat{X}_t$
- SE autocorrelação nos resíduos detectada:
 - Retornar ao PASSO 1

PASSO 4 — Previsão

- Escolher modelo com menor AIC ou BIC
- Gerar previsões: $\hat{X}_{t+h|t} = E[X_{t+h} | F_t]$
- Calcular intervalos de previsão para cada horizonte h

SAÍDA: Modelo ARMA(p^* , q^*) validado e previsões $\hat{X}_{t+h|t}$

PÓS-CONDIÇÃO: Resíduos sem autocorrelação significativa

Não Estacionariedade e Raiz Unitária

Quando o modelo AR possui raiz unitária, o processo torna-se não estacionário. O caso limite é o passeio aleatório:

$$X_t = X_{t-1} + \varepsilon_t$$

Processo Estacionário

Modelo $X_t = \phi X_{t-1} + \varepsilon_t$ com $|\phi| < 1$

Raiz Unitária


Caso limite quando $\phi = 1$, gerando não estacionariedade

Ordem de Integração


Número d de diferenciações necessárias: $\Delta^d X_t$ é estacionário

A não estacionariedade surge quando choques têm efeito permanente sobre o nível da série. A ordem de integração d mede quantas diferenciações são necessárias para restaurar a estacionariedade.

Passeio aleatório (raiz unitária)



Primeira diferença: $\Delta X_t = X_t - X_{t-1}$



Modelo ARIMA

O modelo ARIMA integra diferenciação e estrutura ARMA, representando a extensão natural para séries não estacionárias:

$$\phi(B)(1 - B)^d X_t = c + \theta(B)\varepsilon_t$$

Ordem AR (p)

Captura dependência de valores passados da série diferenciada

Ordem de Integração (d)

Número de diferenciações para alcançar estacionariedade

Ordem MA (q)


Modela propagação de choques aleatórios

Aplicações do ARIMA


O ARIMA define o comportamento esperado da série, servindo como modelo de referência. Eventos, anomalias e mudanças estruturais podem aparecer como desvios sistemáticos em relação ao padrão previsto pelo modelo.

Os modelos lineares formam o núcleo da teoria clássica de séries temporais, fornecendo a base conceitual e metodológica para previsão, análise estrutural e detecção de eventos em dados temporais.

Série não estacionária



Resíduos do ARIMA (ideal: ~ ruído branco)



A Matemática da Previsão

Previsão é estimar o futuro

$$\hat{X}_{t+h|t} = \mathbb{E}[X_{t+h} \mid \mathcal{F}_t]$$

Usamos toda a informação disponível até o momento presente.

O modelo transforma passado em previsão

A estrutura do modelo define como o histórico se traduz em estimativas futuras.

O erro mede a diferença entre previsto e observado

$$e_{t+h} = X_{t+h} - \hat{X}_{t+h|t}$$

Avaliar o erro é avaliar a qualidade da previsão.

Previsão como Problema de Inferência

A previsão depende de um modelo ajustado aos dados observados. Este modelo possui parâmetros que precisam ser estimados, criando duas fontes de incerteza: a variabilidade natural do processo e a incerteza na estimação dos parâmetros.

Função de Previsão

A previsão é uma função dos dados observados e dos parâmetros estimados

Parâmetros Estimados


Usamos $\hat{\theta}$ para representar as estimativas dos parâmetros do modelo

Dupla Incerteza

Incerteza vem do comportamento aleatório da série e da estimação dos parâmetros


$$\hat{X}_{t+h|t} = g(X_t, X_{t-1}, \dots; \hat{\theta})$$

Dupla incerteza: apenas variabilidade



Parâmetros fixos (conhecidos): incerteza vem do ruído futuro.

Dupla incerteza: processo + estimação



Reestimação adiciona variabilidade: intervalos tendem a ficar mais largos.

Previsão Ótima e Erro Quadrático

A qualidade da previsão é medida pelo erro quadrático médio.

A previsão ótima minimiza:

$$\mathbb{E}[e_{t+h}^2]$$

Se queremos minimizar o erro quadrático médio, a melhor previsão possível é a esperança condicional. Este é um resultado fundamental da teoria de previsão.

Previsão em Modelos Autoregressivos

Em modelos autoregressivos, a previsão é obtida substituindo valores futuros por suas esperanças condicionais de forma recursiva. A estrutura resultante é elegante: o efeito do passado decai com potências sucessivas de ϕ .

Modelo AR(1)

$$X_t = \phi X_{t-1} + \varepsilon_t$$

Previsão 1 passo

$$\hat{X}_{t+1|t} = \phi X_t$$

Previsão h passos

$$\hat{X}_{t+h|t} = \phi^h X_t$$

Previsão para Múltiplos Horizontes

A previsão multi-passo é obtida por substituição recursiva: previsões anteriores alimentam as seguintes. A incerteza se acumula a cada passo.

$$\hat{X}_{t+h|t} = \phi^h \cdot X_t$$

ϕ é o parâmetro autoregressivo. Quando $|\phi| < 1$, a previsão $\hat{x}[k]$ converge para zero em séries centradas (sem intercepto). Se o modelo incluir intercepto μ , a previsão converge para μ .

ENTRADA: x (série observada), ϕ (parâmetro AR), h (horizonte)

PRÉ-CONDIÇÃO: modelo AR(1) ajustado, $|\phi| < 1$

PASSO 1 — Inicialização

$x_prev \leftarrow x[T]$ // último valor observado

$\sigma^2 \leftarrow$ variância estimada dos resíduos do modelo

PASSO 2 — Geração recursiva das previsões

PARA k de 1 até h :

$\hat{x}[k] \leftarrow \phi \cdot x_prev$

$x_prev \leftarrow \hat{x}[k]$ // previsão vira entrada do próximo passo

PASSO 3 — Cálculo da variância acumulada

PARA k de 1 até h :

$Var[k] \leftarrow \sigma^2 \cdot \text{SOMA}(\phi^{2j}, j=0..k-1)$

SAÍDA: $\hat{x}[1..h]$ (previsões), $Var[1..h]$ (variâncias)

PÓS-CONDIÇÃO: $\hat{x}[k] \rightarrow 0$ quando $k \rightarrow \infty$ (série centrada em zero);

$Var[k]$ cresce monotonicamente com k .

Propriedades do Erro de Previsão

Uma propriedade fundamental da previsão ótima é que a esperança condicional do erro é zero.

$$\mathbb{E}[e_{t+h} \mid \mathcal{F}_t] = 0$$

Porém, a variância do erro aumenta com o horizonte de previsão, refletindo maior incerteza no futuro distante.

📌 **Interpretação:** Se a previsão é a esperança condicional, o erro médio condicionado à informação presente é zero. A incerteza, no entanto, cresce com o tempo.

Previsão como Distribuição Condicional

A previsão não é apenas um número. O futuro é incerto, e essa incerteza pode ser quantificada.

Previsão Pontual

Um único valor resumindo a distribuição, geralmente a média ou mediana condicional.

$$\hat{X}_{t+h|t} = E[X_{t+h} \mid \mathcal{F}_t]$$

Intervalo de Previsão

Uma faixa de valores plausíveis com determinada probabilidade de conter o valor real.

$$\hat{X}_{t+h|t} \pm z_{\alpha/2} \sqrt{\text{Var}(e_{t+h})}$$

Onde $z_{\alpha/2}$ é o quantil da distribuição normal e α é o nível de significância.

Incerteza

A variância do erro de previsão, que cresce com o horizonte h .

$\text{Var}(e_{t+h})$ cresce com h

Quanto maior o horizonte, mais larga a faixa de incerteza. Reportar apenas a previsão pontual esconde informação essencial sobre o risco da previsão.

Validação Temporal

Em séries temporais, o tempo é uma restrição: o modelo só pode usar o passado para prever o futuro. A validação deve respeitar essa ordem.

Janela Deslizante

Tamanho fixo de treino; a janela avança no tempo a cada iteração.

Janela Expansiva

O treino cresce acumulando todo o histórico disponível até o momento.

ENTRADA: série $x[1..T]$, janela W , horizonte h

PRÉ-CONDIÇÃO: $T > W + h$

PASSO 1 — Para cada ponto de avaliação $t = W+1, \dots, T-h$:

// Janela deslizante:

$\text{treino} \leftarrow x[t-W .. t-1]$

// Janela expansiva (alternativa):

$\text{treino} \leftarrow x[1 .. t-1]$

PASSO 2 — Ajustar e prever

$\text{modelo} \leftarrow \text{ajustar}(\text{treino})$

$\hat{x}[t+h] \leftarrow \text{prever}(\text{modelo}, h)$


PASSO 3 — Registrar erro

$e[t] \leftarrow x[t+h] - \hat{x}[t+h]$

SAÍDA: erros $e[W+1 .. T-h]$


PÓS-CONDIÇÃO: nenhum dado futuro usado no treino

Referências Bibliográficas




Event Detection in Time Series

Ogasawara, E.; Salles, R.; Porto, F.; Pacitti, E.
Springer Nature Switzerland, 2025.



Time Series Analysis: With Applications in R

Cryer, J. D.; Chan, K.-S. Springer, 2008.



Data Mining: Concepts and Techniques

Han, J.; Pei, J.; Tong, H. Morgan Kaufmann, 4^a ed., 2022.