

Previsão de Séries Temporais: SARIMAX, GARCH e Deep Learning

Mudança de Regime como Ponte para Detecção de Eventos

O que são mudanças de regime?

Muitas séries temporais exibem **quebras estruturais** — momentos em que a dinâmica muda abruptamente:

→ Mudança de regime

O processo salta entre estados com parâmetros distintos (μ_k, ϕ_k).

→ Change points

A estrutura da série muda em um instante específico e permanece diferente.

→ Drift

Deriva gradual nos parâmetros ao longo do tempo.

A limitação dos modelos clássicos

ARIMA, SARIMA e GARCH assumem **parâmetros fixos ao longo do tempo** — são incapazes de representar dinâmicas que mudam de regime.

Quando a série exhibe quebras estruturais, esses modelos ficam mal especificados: os resíduos deixam de ser ruído branco e o poder preditivo cai.

❏ A detecção de **change points, quebras estruturais e drift** será tratada em profundidade no bloco dedicado a **Detecção de Eventos**.

Limitações dos Modelos Lineares

Modelos ARIMA descrevem dependência temporal linear e supõem estacionariedade após diferenciação. Eles assumem variância constante ao longo do tempo, mas não capturam estruturas temporais complexas.

Séries reais exibem sazonalidade, não linearidade e variância variável. Modelos lineares são um ponto de partida poderoso, mas limitado. Quando a série apresenta padrões mais ricos — como ciclos, mudanças de variância ou relações não lineares — precisamos ampliar o modelo.

SARIMA: Extensão Sazonal do ARIMA

O ARIMA captura dependência de curto prazo. O SARIMA vai além ao incorporar padrões que se repetem a cada período sazonal — como meses ou trimestres. Os dois mecanismos operam em paralelo no mesmo modelo.

$$\text{SARIMA}(p, d, q)(P, D, Q)(s)$$

Escala regular

Captura dependência entre observações próximas

Escala sazonal

Captura padrões que se repetem a cada s períodos

O resultado é um modelo que descreve simultaneamente a dinâmica local e o ritmo periódico da série.

Identificação e Ajuste de Modelos SARIMA

O processo de modelagem SARIMA combina duas etapas interdependentes: identificar a estrutura adequada e ajustar o modelo aos dados.

Identificação

Estacionarizar a série aplicando diferenças regulares (ordem d) e sazonais (ordem D):

$$Y_t = \Delta^d \Delta_s^D X_t$$

Com Y_t estacionária, analisar FAC e FACP:

- **Lags regulares** $(1, 2, \dots) \rightarrow$ ordens p e q
- **Lags sazonais** $(s, 2s, \dots) \rightarrow$ ordens P e Q
- **Critérios de informação** AIC e BIC para comparar modelos candidatos

Ajuste e Diagnóstico

Com as ordens definidas, estimar os parâmetros e validar o modelo:

- **Estimação** por máxima verossimilhança
- **Teste de Ljung-Box** para verificar ausência de autocorrelação nos resíduos
- **Normalidade dos resíduos** (QQ-plot, teste de Shapiro-Wilk)
- **Seleção final** do modelo com melhor equilíbrio entre ajuste e parcimônia

A lógica é a mesma do ARIMA — mas aplicada em duas escalas temporais ao mesmo tempo.

Regressão com Erros Temporais

Quando a série depende de variáveis externas Z_t , o modelo separa dois mecanismos distintos:

$$X_t = \underbrace{\beta_0 + \beta \cdot Z_t}_{\text{efeito externo}} + \underbrace{u_t}_{\text{dependência temporal}}$$

Efeito Externo (Regressão)

O termo $\beta_0 + \beta \cdot Z_t$ captura a influência de variáveis exógenas sobre X_t . É a parte explicada por fatores externos à série.

Dependência Temporal (Erro)

O termo u_t **não é ruído branco** — ele segue um processo ARMA ou ARIMA, capturando toda a estrutura temporal remanescente após controlar por Z_t .

 **Por que a separação é fundamental?** Ignorar a estrutura temporal de u_t invalida a inferência: os erros-padrão do OLS ficam viesados e os testes de significância tornam-se espúrios. OLS é inconsistente nesse cenário — é necessário usar **GLS** ou **MLE conjunta** para estimar os parâmetros corretamente.

Modelos Dinâmicos

Uma variável externa pode afetar a série imediatamente ou com atraso. O modelo de defasagens distribuídas captura esse efeito ao longo do tempo:

$$X_t = \alpha + \beta_0 Z_t + \beta_1 Z_{t-1} + \dots + \beta_k Z_{t-k} + u_t$$

Efeito Imediato

Impacto de $\beta_0 Z_t$ no tempo presente

Efeitos Defasados

Impactos de $\beta_1 Z_{t-1}$, $\beta_2 Z_{t-2}$, etc.

Propagação Temporal

Efeitos acumulados ao longo do tempo

SARIMAX: SARIMA com Regressão

O SARIMAX estende o SARIMA incorporando variáveis exógenas Z_t , separando dois efeitos distintos em um único modelo:

$$X_t = \beta \cdot Z_t + u_t, \quad u_t \sim \text{SARIMA}(p, d, q)(P, D, Q)_s$$

Efeito Externo

O termo $\beta \cdot Z_t$ captura o impacto direto das variáveis regressoras exógenas sobre a série

Dependência Serial

O erro u_t segue uma estrutura SARIMA, capturando a dinâmica temporal interna restante

Separação Fundamental

A regressão explica efeitos externos; o SARIMA explica a estrutura temporal dos resíduos

Heterocedasticidade Temporal

Em muitas séries, a média permanece estável, mas a variância oscila ao longo do tempo — formando períodos alternados de baixa e alta volatilidade. A variância condicional depende da informação passada:

$$\text{Var}(X_t \mid \mathcal{F}_{t-1}) = \sigma_t^2$$

onde $\mathcal{F}_{t-1}$ representa toda a informação disponível até o instante $t - 1$. Quando σ_t^2 não é constante, o processo é heterocedástico.

Mercados financeiros

Volatilidade se concentra em períodos de crise ou incerteza

Sensores industriais

Variância aumenta sob condições operacionais extremas

Demanda e consumo

Dispersão maior em datas sazonais ou eventos atípicos

Modelos ARCH e GARCH foram desenvolvidos para capturar e prever essa estrutura variável da variância.

Estimação ARCH/GARCH

Ideia Central

A variância condicional é modelada como função dos choques e variâncias passadas. O GARCH generaliza o ARCH ao incluir memória da própria variância.

ARCH:

$$\sigma_t^2 = \alpha_0 + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2$$

GARCH(1,1):

$$\sigma_t^2 = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2 + \beta_1 \sigma_{t-1}^2$$

Para o GARCH(1,1), a condição $\alpha_1 + \beta_1 < 1$ garante estacionariedade da variância.

Estimação ARCH/GARCH

ENTRADA: ε_t (resíduos do modelo da média), ordens (p, q)

PRÉ-CONDIÇÃO: teste ARCH significativo sobre ε_t

PASSO 1 — Inicialização

$\sigma^2_1 \leftarrow$ variância amostral de ε

PASSO 2 — Modelagem da variância condicional

PARA cada t de 2 até T:

$\sigma^2_t \leftarrow \alpha_0 + \sum \alpha_i \cdot \varepsilon_{t-i}^2 + \sum \beta_j \cdot \sigma_{t-j}^2$

PASSO 3 — Estimação dos parâmetros

Maximizar log-verossimilhança condicional $L(\alpha, \beta \mid \varepsilon)$

PASSO 4 — Diagnóstico

$z_t \leftarrow \varepsilon_t / \sigma_t$ (resíduos padronizados)

Verificar: z_t sem autocorrelação e sem efeito ARCH residual

PASSO 5 — Previsão

[nota técnica] σ^2_{T+h} converge para a variância incondicional

à taxa $(\alpha_1 + \beta_1)^h$ conforme h cresce

SAÍDA: sequência σ^2_t estimada para todo t

PÓS-CONDIÇÃO: z_t aproximadamente ruído branco

Persistência da Volatilidade no GARCH

O GARCH modela a **variância condicional** — não a média — capturando como a incerteza evolui ao longo do tempo. Um choque em ε_t eleva σ_t^2 , e esse efeito se propaga por vários períodos.

O grau de persistência é medido por $\alpha_1 + \beta_1$. Quanto mais próximo de 1, mais lentamente a volatilidade retorna ao nível incondicional:

$$\sigma_{T+h}^2 = \bar{\sigma}^2 + (\alpha_1 + \beta_1)^h (\sigma_T^2 - \bar{\sigma}^2)$$

onde $\bar{\sigma}^2 = \alpha_0 / (1 - \alpha_1 - \beta_1)$ é a variância incondicional de longo prazo.

$\alpha + \beta$ pequeno

Choque dissipa-se rapidamente. Intervalos de confiança retornam ao nível basal em poucos períodos.

$\alpha + \beta$ próximo de 1


Alta persistência. Incerteza permanece elevada — típico de crises. Intervalos de confiança alargam-se por semanas.

Isso posiciona o GARCH como ferramenta de **previsão do risco**: ele não prevê o nível da série, mas a largura dos intervalos de confiança futuros.

Aprendizado de Máquina para Séries Temporais

Modelos de ML são **aproximadores universais** — podem aproximar qualquer função contínua com precisão arbitrária. Ao contrário dos modelos estatísticos, não exigem especificação explícita da estrutura temporal: essa estrutura é aprendida a partir dos dados por meio de uma janela deslizante de observações defasadas.

O esquema geral de entrada e saída é:



Entrada

Janela deslizante de p valores defasados:

$$\langle x_{t-p+1}, \dots, x_{t-1}, x_t \rangle$$

Saída

Próximo valor previsto:

$$\hat{x}_{t+1}$$

Hiperparâmetro

O número de defasagens p (tamanho da janela) é definido como hiperparâmetro e ajustado via validação cruzada temporal.

Redes Neurais (MLP / ELM)

- MLP é a arquitetura mais comum para séries temporais
- ELM substitui o gradiente iterativo por determinação analítica dos pesos
- ELM é significativamente mais rápido no treinamento

SVM e Random Forest

- SVM mapeia entradas para um espaço de características induzido por kernel, permitindo regressão não linear
- Random Forest combina múltiplas árvores de decisão
- O erro de generalização converge com árvores suficientes, reduzindo overfitting

Deep Learning para Séries Temporais

Deep learning estende as redes neurais clássicas ao aprender representações hierárquicas de dados temporais. Duas arquiteturas se destacam para séries temporais: Conv1D e LSTM.

Conv1D (Redes Convolucionais 1D)

- Composta por camada de entrada, camada convolucional e camada de pooling
- Filtros de convolução atuam como extratores de características implícitos do sinal temporal
- Captura padrões temporais locais de forma eficiente

$$(g * h)[n] = \sum_{t=0}^k g[k-t] \cdot h[t]$$

$$a_n^{(l)} = \text{ReLU}(z_n^{(l)}) = \max(0, z_n^{(l)})$$

$$p_j = \max_{n \in \mathcal{R}_j} a_n^{(l)}$$

onde g é a entrada, h é um dos k filtros otimizados durante o treinamento, $a_n^{(l)}$ é a ativação na camada l e p_j é o valor do pool na janela $\mathcal{R}_j$.

LSTM (Long Short-Term Memory)

As portas e o estado da célula são governados pelas equações:


$$\begin{pmatrix} f_t \\ i_t \\ o_t \end{pmatrix} = \sigma \left(W \begin{pmatrix} h_{t-1} \\ x_t \end{pmatrix} + b \right)$$

$$C_t = f_t \odot C_{t-1} + i_t \odot \tanh(W_C[h_{t-1}, x_t] + b_C)$$

$$h_t = o_t \odot \tanh(C_t)$$

onde x_t é a entrada no instante t , h_{t-1} é o estado oculto anterior, C_{t-1} é o estado da célula anterior, σ é a função sigmoide e $\odot$ é o produto elemento a elemento.

- ❏ Modelos de ML — incluindo deep learning — devem ser comparados com baselines estatísticas (ARIMA, SARIMA) usando validação cruzada temporal. A complexidade adicional só se justifica quando o ganho no desempenho out-of-sample é consistente.



LLMs e Modelos Baseados em Grafos

O sucesso dos Large Language Models (LLMs) no PLN inspirou adaptações para séries temporais. Tanto modelos de linguagem quanto de séries temporais preveem padrões futuros a partir de estrutura sequencial. Nos LLMs, o próximo token; nas séries temporais, o próximo valor.

LLMs para Séries Temporais:

- Os valores da série temporal são mapeados para tokens via escalonamento e quantization (discretização em bins)
- Modelos transformer pré-treinados recebem a série tokenizada e preveem o próximo token
- Saída: distribuição probabilística sobre tokens → amostrada → desquantizada → valores previstos
- Principal vantagem: zero-shot learning — LLMs pré-treinados em séries diversas podem prever novas séries sem retreinamento específico
- Limitação: exige design de quantization; pode perder precisão numérica refinada

Modelos Baseados em Grafos (STGNNs):


- Representam dependências entre múltiplas séries temporais como um grafo: nós = séries individuais, arestas = relações entre pares
- Spatiotemporal Graph Neural Networks (STGNNs) utilizam message-passing para propagar informações temporais e espaciais
- Arquiteturas: time-then-space (TTS), space-then-time (STT), time-and-space (T&S)
- Modelos globais compartilham parâmetros entre todas as séries (escalabilidade); modelos locais adicionam embeddings específicos por nó (especificidade)
- Aplicações: previsão de tráfego, análise de energia, monitoramento de qualidade do ar

Essas são extensões de fronteira — vão além da previsão univariada e exploram pré-treinamento em larga escala ou estrutura relacional entre séries.


Métricas de Erro de Previsão

As métricas de erro permitem comparar modelos e avaliar qualidade preditiva. Cada métrica enfatiza um tipo de erro diferente, como magnitude média, variabilidade ou sensibilidade a valores extremos.

Holdout temporal: treino vs teste



Comparação de erros (teste)



MSE - Erro Quadrático Médio

$$\text{MSE} = \frac{1}{n} \sum_{t=1}^n e_t^2$$

Penaliza fortemente erros grandes

MAE - Erro Absoluto Médio

$$\text{MAE} = \frac{1}{n} \sum_{t=1}^n |e_t|$$

Mais robusto a outliers, trata todos os erros de forma linear

MAPE - Erro Percentual

$$\text{MAPE} = \frac{100}{n} \cdot \sum_{t=1}^n \left| \frac{e_t}{y_t} \right|$$

Expressa o erro como porcentagem do valor observado

Atenção: MAPE é instável quando y_t está próximo de zero.

A Escolha da Função de Perda

Escolher uma métrica de erro é escolher implicitamente uma função de perda. Se usamos MSE, buscamos a média condicional; se usamos MAE, buscamos a mediana condicional. Não existe uma única previsão "melhor" em todos os contextos.

Perda Quadrática

$$L(e) = e^2$$

Leva à média como previsão ótima

Perda Absoluta

$$L(e) = |e|$$

Leva à mediana como previsão ótima

Perda Assimétrica

Penaliza erros positivos e negativos de forma diferente

Validação Temporal

Em séries temporais, o tempo é uma restrição: o modelo só pode usar o passado para prever o futuro. A validação deve respeitar essa ordem.

Janela Deslizante

Tamanho fixo de treino; a janela avança no tempo a cada iteração.

Janela Expansiva

O treino cresce acumulando todo o histórico disponível até o momento.

ENTRADA: série $x[1..T]$, janela W , horizonte h

PRÉ-CONDIÇÃO: $T > W + h$

PASSO 1 — Para cada ponto de avaliação $t = W+1, \dots, T-h$:

// Janela deslizante:

$\text{treino} \leftarrow x[t-W .. t-1]$

// Janela expansiva (alternativa):

$\text{treino} \leftarrow x[1 .. t-1]$

PASSO 2 — Ajustar e prever

$\text{modelo} \leftarrow \text{ajustar}(\text{treino})$

$\hat{x}[t+h] \leftarrow \text{prever}(\text{modelo}, h)$

PASSO 3 — Registrar erro

$e[t] \leftarrow x[t+h] - \hat{x}[t+h]$

SAÍDA: erros $e[W+1 .. T-h]$

PÓS-CONDIÇÃO: nenhum dado futuro usado no treino

Comparação Estatística de Modelos

Comparar modelos exige cuidado. Em séries temporais, a ordem dos dados importa — e a avaliação precisa respeitar essa estrutura.

Mesma Base de Teste

Modelos diferentes só podem ser comparados se avaliados no mesmo período e com a mesma métrica de erro.

- ❏ Um modelo que parece melhor no treino pode ser pior no teste. A comparação válida é sempre feita fora do período de ajuste.

Overfitting em Séries Temporais

Overfitting ocorre quando o modelo ajusta ruído em vez de estrutura verdadeira. É um problema comum em modelos complexos e se manifesta quando o desempenho no treino é muito melhor que no teste.

Sintoma Principal

$$\text{Erro}_{\text{treino}} \ll \text{Erro}_{\text{teste}}$$

Causa

Modelo captura flutuações aleatórias do passado que não se repetem

Solução

Validação temporal rigorosa e regularização adequada

Os Limites da Previsão

Sempre existe uma componente imprevisível em qualquer série temporal. Mesmo o melhor modelo possível tem um erro residual que não pode ser eliminado. Parte da variabilidade é inerente ao processo e define um limite teórico para a previsibilidade.

Componente Previsível

Estrutura sistemática que pode ser modelada

Ruído Irredutível

Variabilidade aleatória inerente ao processo


Horizonte Temporal

Previsibilidade diminui com o tempo

Decomposição


$$X_t = \hat{X}_{t|t-1} + \varepsilon_t$$

Referências Bibliográficas




Event Detection in Time Series

Ogasawara, E.; Salles, R.; Porto, F.; Pacitti, E.
Springer Nature Switzerland, 2025.



Time Series Analysis: With Applications in R

Cryer, J. D.; Chan, K.-S. Springer, 2008.



Data Mining: Concepts and Techniques

Han, J.; Pei, J.; Tong, H. Morgan Kaufmann, 4^a ed., 2022.