



# Previsão em Séries Temporais

Uma série temporal é um processo aleatório que evolui ao longo do tempo. A previsão consiste em estimar valores futuros condicionados à informação disponível até o momento atual. O horizonte de previsão determina se estamos falando de curto, médio ou longo prazo.

**Eduardo Ogasawara**

[eduardo.ogasawara@cefet-rj.br](mailto:eduardo.ogasawara@cefet-rj.br)

<https://eic.cefet-rj.br/~eogasawara>

# A Matemática da Previsão

## Previsão é estimar o futuro

$$\hat{X}_{t+h|t} = \mathbb{E}[X_{t+h} \mid \mathcal{F}_t]$$

Usamos toda a informação disponível até o momento presente.

## O modelo transforma passado em previsão

A estrutura do modelo define como o histórico se traduz em estimativas futuras.

## O erro mede a diferença entre previsto e observado

$$e_{t+h} = X_{t+h} - \hat{X}_{t+h|t}$$

Avaliar o erro é avaliar a qualidade da previsão.

# Previsão como Problema de Inferência

A previsão depende de um modelo ajustado aos dados observados. Este modelo possui parâmetros que precisam ser estimados, criando duas fontes de incerteza: a variabilidade natural do processo e a incerteza na estimação dos parâmetros.

## Função de Previsão

A previsão é uma função dos dados observados e dos parâmetros estimados

## Parâmetros Estimados


Usamos  $\hat{\theta}$  para representar as estimativas dos parâmetros do modelo

## Dupla Incerteza

Incerteza vem do comportamento aleatório da série e da estimação dos parâmetros


$$\hat{X}_{t+h|t} = g(X_t, X_{t-1}, \dots; \hat{\theta})$$

Dupla incerteza: apenas variabilidade



Parâmetros fixos (conhecidos): incerteza vem do ruído futuro.

Dupla incerteza: processo + estimação



Reestimação adiciona variabilidade: intervalos tendem a ficar mais largos.

# Previsão Ótima e Erro Quadrático

A qualidade da previsão é medida pelo erro quadrático médio.

**A previsão ótima minimiza:**

$$\mathbb{E}[e_{t+h}^2]$$

Se queremos minimizar o erro quadrático médio, a melhor previsão possível é a esperança condicional. Este é um resultado fundamental da teoria de previsão.

# Previsão em Modelos Autoregressivos

Em modelos autoregressivos, a previsão é obtida substituindo valores futuros por suas esperanças condicionais de forma recursiva. A estrutura resultante é elegante: o efeito do passado decai com potências sucessivas de  $\phi$ .

---

## Modelo AR(1)

$$X_t = \phi X_{t-1} + \varepsilon_t$$

## Previsão 1 passo

$$\hat{X}_{t+1|t} = \phi X_t$$

## Previsão h passos

$$\hat{X}_{t+h|t} = \phi^h X_t$$

# Estrutura Temporal da Série

Uma série temporal é composta por componentes estruturais distintas: tendência, sazonalidade e ruído. A previsão consiste em extrapolar essas componentes para o futuro.

## Tendência

Movimento de longo prazo da série, representado por  $T_t$

## Sazonalidade

Padrões que se repetem em intervalos regulares, representado por  $S_t$

## Componente Aleatória

Parte imprevisível da série, representada por  $\varepsilon_t$

$$X_t = T_t + S_t + \varepsilon_t$$

$$\hat{X}_{t+h|t} = \hat{T}_{t+h} + \hat{S}_{t+h} + \hat{\varepsilon}_{t+h}$$

# Previsão para Múltiplos Horizontes

A previsão multi-passo é obtida por substituição recursiva: previsões anteriores alimentam as seguintes. A incerteza se acumula a cada passo.

$$\hat{X}_{t+h|t} = \phi^h \cdot X_t$$

$\phi$  é o parâmetro autoregressivo. Quando  $|\phi| < 1$ , a previsão  $\hat{x}[k]$  converge para zero em séries centradas (sem intercepto). Se o modelo incluir intercepto  $\mu$ , a previsão converge para  $\mu$ .

ENTRADA:  $x$  (série observada),  $\phi$  (parâmetro AR),  $h$  (horizonte)

PRÉ-CONDIÇÃO: modelo AR(1) ajustado,  $|\phi| < 1$

PASSO 1 — Inicialização

$x\_prev \leftarrow x[T]$  // último valor observado

$\sigma^2 \leftarrow$  variância estimada dos resíduos do modelo

PASSO 2 — Geração recursiva das previsões

PARA  $k$  de 1 até  $h$ :

$\hat{x}[k] \leftarrow \phi \cdot x\_prev$

$x\_prev \leftarrow \hat{x}[k]$  // previsão vira entrada do próximo passo

PASSO 3 — Cálculo da variância acumulada

PARA  $k$  de 1 até  $h$ :

$Var[k] \leftarrow \sigma^2 \cdot \text{SOMA}(\phi^{2j}, j=0..k-1)$

SAÍDA:  $\hat{x}[1..h]$  (previsões),  $Var[1..h]$  (variâncias)

PÓS-CONDIÇÃO:  $\hat{x}[k] \rightarrow 0$  quando  $k \rightarrow \infty$  (série centrada em zero);

$Var[k]$  cresce monotonicamente com  $k$ .

# Propriedades do Erro de Previsão

Uma propriedade fundamental da previsão ótima é que a esperança condicional do erro é zero.

$$\mathbb{E}[e_{t+h} \mid \mathcal{F}_t] = 0$$

Porém, a variância do erro aumenta com o horizonte de previsão, refletindo maior incerteza no futuro distante.

📌 **Interpretação:** Se a previsão é a esperança condicional, o erro médio condicionado à informação presente é zero. A incerteza, no entanto, cresce com o tempo.



# Previsão como Distribuição Condicional

A previsão não é apenas um número. O futuro é incerto, e essa incerteza pode ser quantificada.

## Previsão Pontual

Um único valor resumindo a distribuição, geralmente a média ou mediana condicional.

$$\hat{X}_{t+h|t} = E[X_{t+h} \mid \mathcal{F}_t]$$

## Intervalo de Previsão

Uma faixa de valores plausíveis com determinada probabilidade de conter o valor real.

$$\hat{X}_{t+h|t} \pm z_{\alpha/2} \sqrt{\text{Var}(e_{t+h})}$$

Onde  $z_{\alpha/2}$  é o quantil da distribuição normal e  $\alpha$  é o nível de significância.

## Incerteza

A variância do erro de previsão, que cresce com o horizonte  $h$ .


$\text{Var}(e_{t+h})$  cresce com  $h$

Quanto maior o horizonte, mais larga a faixa de incerteza. Reportar apenas a previsão pontual esconde informação essencial sobre o risco da previsão.


# Métricas de Erro de Previsão

As métricas de erro permitem comparar modelos e avaliar qualidade preditiva. Cada métrica enfatiza um tipo de erro diferente, como magnitude média, variabilidade ou sensibilidade a valores extremos.

Holdout temporal: treino vs teste



Comparação de erros (teste)



## MSE - Erro Quadrático Médio

$$\text{MSE} = \frac{1}{n} \sum_{t=1}^n e_t^2$$

Penaliza fortemente erros grandes

## MAE - Erro Absoluto Médio

$$\text{MAE} = \frac{1}{n} \sum_{t=1}^n |e_t|$$

Mais robusto a outliers, trata todos os erros de forma linear

## MAPE - Erro Percentual

$$\text{MAPE} = \frac{100}{n} \cdot \sum_{t=1}^n \left| \frac{e_t}{y_t} \right|$$

Expressa o erro como porcentagem do valor observado

Atenção: MAPE é instável quando  $y_t$  está próximo de zero.

# A Escolha da Função de Perda

Escolher uma métrica de erro é escolher implicitamente uma função de perda. Se usamos MSE, buscamos a média condicional; se usamos MAE, buscamos a mediana condicional. Não existe uma única previsão "melhor" em todos os contextos.

---

## Perda Quadrática

$$L(e) = e^2$$

Leva à média como previsão ótima

---

## Perda Absoluta

$$L(e) = |e|$$

Leva à mediana como previsão ótima

---

## Perda Assimétrica

Penaliza erros positivos e negativos de forma diferente

# Validação Temporal

Em séries temporais, o tempo é uma restrição: o modelo só pode usar o passado para prever o futuro. A validação deve respeitar essa ordem.

## Janela Deslizante

Tamanho fixo de treino; a janela avança no tempo a cada iteração.

## Janela Expansiva

O treino cresce acumulando todo o histórico disponível até o momento.

ENTRADA: série  $x[1..T]$ , janela  $W$ , horizonte  $h$

PRÉ-CONDIÇÃO:  $T > W + h$

PASSO 1 — Para cada ponto de avaliação  $t = W+1, \dots, T-h$ :

// Janela deslizante:

$\text{treino} \leftarrow x[t-W .. t-1]$

// Janela expansiva (alternativa):

$\text{treino} \leftarrow x[1 .. t-1]$

PASSO 2 — Ajustar e prever

$\text{modelo} \leftarrow \text{ajustar}(\text{treino})$

$\hat{x}[t+h] \leftarrow \text{prever}(\text{modelo}, h)$

PASSO 3 — Registrar erro

$e[t] \leftarrow x[t+h] - \hat{x}[t+h]$

SAÍDA: erros  $e[W+1 .. T-h]$

PÓS-CONDIÇÃO: nenhum dado futuro usado no treino

# Comparação Estatística de Modelos

Comparar modelos exige cuidado. Em séries temporais, a ordem dos dados importa — e a avaliação precisa respeitar essa estrutura.

---

## Mesma Base de Teste

Modelos diferentes só podem ser comparados se avaliados no mesmo período e com a mesma métrica de erro.

- ❏ Um modelo que parece melhor no treino pode ser pior no teste. A comparação válida é sempre feita fora do período de ajuste.

# Overfitting em Séries Temporais

Overfitting ocorre quando o modelo ajusta ruído em vez de estrutura verdadeira. É um problema comum em modelos complexos e se manifesta quando o desempenho no treino é muito melhor que no teste.

---

## Sintoma Principal

$$\text{Erro}_{\text{treino}} \ll \text{Erro}_{\text{teste}}$$

## Causa

Modelo captura flutuações aleatórias do passado que não se repetem

## Solução

Validação temporal rigorosa e regularização adequada

# Os Limites da Previsão

Sempre existe uma componente imprevisível em qualquer série temporal. Mesmo o melhor modelo possível tem um erro residual que não pode ser eliminado. Parte da variabilidade é inerente ao processo e define um limite teórico para a previsibilidade.

## Componente Previsível

Estrutura sistemática que pode ser modelada

## Ruído Irredutível

Variabilidade aleatória inerente ao processo

## Horizonte Temporal

Previsibilidade diminui com o tempo

## Decomposição

$$X_t = \hat{X}_{t|t-1} + \varepsilon_t$$

- ☐ Nota técnica: em sistemas caóticos, pequenas perturbações nas condições iniciais crescem exponencialmente —  $|\delta X_t| \approx e^{\lambda t} |\delta X_0|$  — onde  $\lambda > 0$  é o expoente de Lyapunov. Isso impõe um horizonte de previsão fundamentalmente curto, independente do modelo escolhido.

# Abordagens Complementares

Apesar das diferenças metodológicas, estatística e machine learning resolvem o mesmo problema fundamental: aproximar a relação entre o passado e o futuro da série. A escolha depende do contexto e dos dados disponíveis.

---

## Modelos Estatísticos

- Base probabilística explícita
- Alta interpretabilidade
- Inferência formal
- Intervalos de confiança rigorosos

Ambas as abordagens aproximam a mesma quantidade:  $\mathbb{E}[X_{t+1} \mid \mathcal{F}_t]$ . A diferença está nos meios — modelos estatísticos privilegiam interpretabilidade, inferência formal e pressupostos explícitos; modelos de machine learning privilegiam flexibilidade e desempenho preditivo com menos suposições estruturais.


---

## Machine Learning

- Flexibilidade para não linearidades
- Capacidade de lidar com alta dimensionalidade
- Menos suposições sobre a estrutura
- Foco em desempenho preditivo




# Referências Bibliográficas



---

## Event Detection in Time Series


Ogasawara, E.; Salles, R.; Porto, F.; Pacitti, E.  
Springer Nature Switzerland, 2025.



---

## Time Series Analysis: With Applications in R

Cryer, J. D.; Chan, K.-S. Springer, 2008.



---

## Data Mining: Concepts and Techniques

Han, J.; Pei, J.; Tong, H. Morgan Kaufmann, 4<sup>a</sup> ed., 2022.