

Por que Estender os Modelos Lineares

Desvendando a complexidade das séries temporais para uma análise mais profunda e precisa.

Eduardo Ogasawara

eduardo.ogasawara@cefet-rj.br

<https://eic.cefet-rj.br/~eogasawara>

Limitações dos Modelos Lineares

Modelos ARIMA descrevem dependência temporal linear e supõem estacionariedade após diferenciação. Eles assumem variância constante ao longo do tempo, mas não capturam estruturas temporais complexas.

Séries reais exibem sazonalidade, não linearidade e variância variável. Modelos lineares são um ponto de partida poderoso, mas limitado. Quando a série apresenta padrões mais ricos — como ciclos, mudanças de variância ou relações não lineares — precisamos ampliar o modelo.

SARIMA: Extensão Sazonal do ARIMA

O ARIMA captura dependência de curto prazo. O SARIMA vai além ao incorporar padrões que se repetem a cada período sazonal — como meses ou trimestres. Os dois mecanismos operam em paralelo no mesmo modelo.

$$\text{SARIMA}(p, d, q)(P, D, Q)(s)$$

Escala regular

Captura dependência entre observações próximas

Escala sazonal

Captura padrões que se repetem a cada s períodos

O resultado é um modelo que descreve simultaneamente a dinâmica local e o ritmo periódico da série.

Identificação de Modelos SARIMA

A identificação começa pela estacionarização da série. Aplicam-se diferenças regulares (ordem d) para remover tendência e diferenças sazonais (ordem D) para remover padrões periódicos. O resultado é a série transformada:

$$Y_t = \Delta^d \Delta_s^D X_t$$

onde X_t é a série original, s é o período sazonal e Y_t é a série estacionarizada, pronta para análise.

Com Y_t estacionária, analisa-se ACF e PACF para identificar as ordens do modelo. Lags regulares ($1, 2, 3, \dots$) indicam os componentes AR e MA de curto prazo. Lags sazonais ($s, 2s, 3s, \dots$) indicam os componentes AR e MA sazonais.

A lógica é a mesma do ARIMA — mas aplicada em duas escalas temporais ao mesmo tempo.

Ajuste de Modelos SARIMA

Ideia Central

O SARIMA combina diferenciação regular e sazonal com componentes AR e MA em duas escalas. A identificação segue Box–Jenkins adaptado para sazonalidade.

$$\Phi_P(B^s)\phi_p(B)\Delta^d\Delta_s^D X_t = \Theta_Q(B^s)\theta_q(B)\varepsilon_t$$

onde B é o operador de retardo, s o período sazonal, X_t a série original e ε_t ruído branco. $Y_t = \Delta^d\Delta_s^D X_t$ denota a série estacionarizada.

Ajuste de Modelos SARIMA

ENTRADA: X_t (série temporal), s (período sazonal)

PRÉ-CONDIÇÃO: série com possível não estacionariedade regular e/ou sazonal

PASSO 1 — Estacionarização

Calcular $Y_t = \Delta^d \Delta_s^D X_t$

Escolher d e D pelo critério de estacionariedade

PASSO 2 — Identificação das ordens

Calcular ACF e PACF de Y_t

Lags regulares $\rightarrow$ ordens p, q

Lags sazonais (múltiplos de s) $\rightarrow$ ordens P, Q

PASSO 3 — Estimação

Ajustar SARIMA(p, d, q)(P, D, Q) $_s$ por máxima verossimilhança

PASSO 4 — Diagnóstico

Calcular resíduos $\hat{e}_t = X_t - \hat{X}_t$

Aplicar teste de Ljung-Box e inspecionar ACF dos resíduos

SE autocorrelação residual significativa: revisar p, q, P, Q

SAÍDA: modelo SARIMA ajustado com parâmetros estimados

PÓS-CONDIÇÃO: resíduos $\hat{e}_t$ sem autocorrelação significativa

Regressão com Erros Temporais

A série pode depender de variáveis explicativas externas. O modelo combina regressão com dependência temporal:

$$X_t = \beta_0 + \beta \cdot Z_t + u_t$$

O termo u_t não é ruído branco — ele segue um processo ARMA ou ARIMA, capturando a dependência temporal dos erros.

Modelos Dinâmicos

Uma variável externa pode afetar a série imediatamente ou com atraso. O modelo de defasagens distribuídas captura esse efeito ao longo do tempo:

$$X_t = \alpha + \beta_0 Z_t + \beta_1 Z_{t-1} + \dots + \beta_k Z_{t-k} + u_t$$

Efeito Imediato

Impacto de $\beta_0 Z_t$ no tempo presente

Efeitos Defasados

Impactos de $\beta_1 Z_{t-1}$, $\beta_2 Z_{t-2}$, etc.

Propagação Temporal

Efeitos acumulados ao longo do tempo

SARIMA com Regressão

SARIMAX

Combinação de SARIMA e regressão, conhecida como SARIMAX (SARIMA com variáveis exógenas)

O SARIMAX integra em um único modelo a dinâmica interna da série e o efeito de variáveis externas.

Duas Dimensões

ARIMA explica dependência interna, enquanto regressão explica efeitos externos

Heterocedasticidade Temporal

Em muitas séries, a média permanece estável, mas a variância oscila ao longo do tempo — formando períodos alternados de baixa e alta volatilidade. A variância condicional depende da informação passada:

$$\text{Var}(X_t \mid \mathcal{F}_{t-1}) = \sigma_t^2$$

onde $\mathcal{F}_{t-1}$ representa toda a informação disponível até o instante $t - 1$. Quando σ_t^2 não é constante, o processo é heterocedástico.

Mercados financeiros

Volatilidade se concentra em períodos de crise ou incerteza

Sensores industriais

Variância aumenta sob condições operacionais extremas

Demanda e consumo

Dispersão maior em datas sazonais ou eventos atípicos

Modelos ARCH e GARCH foram desenvolvidos para capturar e prever essa estrutura variável da variância.

Estimação ARCH/GARCH

Ideia Central

A variância condicional é modelada como função dos choques e variâncias passadas. O GARCH generaliza o ARCH ao incluir memória da própria variância.

ARCH:

$$\sigma_t^2 = \alpha_0 + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2$$

GARCH(1,1):

$$\sigma_t^2 = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2 + \beta_1 \sigma_{t-1}^2$$

Para o GARCH(1,1), a condição $\alpha_1 + \beta_1 < 1$ garante estacionariedade da variância.

Estimação ARCH/GARCH

ENTRADA: ε_t (resíduos do modelo da média), ordens (p, q)

PRÉ-CONDIÇÃO: teste ARCH significativo sobre ε_t

PASSO 1 — Inicialização

$\sigma^2_1 \leftarrow$ variância amostral de ε

PASSO 2 — Modelagem da variância condicional

PARA cada t de 2 até T:

$\sigma^2_t \leftarrow \alpha_0 + \sum \alpha_i \cdot \varepsilon_{t-i}^2 + \sum \beta_j \cdot \sigma_{t-j}^2$

PASSO 3 — Estimação dos parâmetros

Maximizar log-verossimilhança condicional $L(\alpha, \beta \mid \varepsilon)$

PASSO 4 — Diagnóstico

$z_t \leftarrow \varepsilon_t / \sigma_t$ (resíduos padronizados)

Verificar: z_t sem autocorrelação e sem efeito ARCH residual

PASSO 5 — Previsão

[nota técnica] σ^2_{T+h} converge para a variância incondicional

à taxa $(\alpha_1 + \beta_1)^h$ conforme h cresce

SAÍDA: sequência σ^2_t estimada para todo t

PÓS-CONDIÇÃO: z_t aproximadamente ruído branco

Persistência da Volatilidade no GARCH

No GARCH, um choque não afeta apenas a variância do próximo período — seu efeito se propaga. Quanto maior β_1 , mais lentamente a volatilidade retorna ao nível de longo prazo após um choque.

Memória curta

β_1 pequeno: volatilidade retorna rapidamente ao nível basal após o choque.

Memória longa

β_1 próximo de 1: períodos prolongados de alta volatilidade, típicos de crises financeiras.

Essa persistência é o que torna o GARCH útil para previsão de risco: o modelo sabe que um choque hoje ainda importa amanhã.

Modelos Não Lineares

Modelos lineares assumem que a relação da série com seu passado é constante ao longo do tempo. Modelos não lineares permitem que essa relação mude conforme o estado da série — capturando dinâmicas que um ARIMA não consegue representar.

$$X_t = f(\text{passado}) + \varepsilon_t$$

onde $f(\cdot)$ é uma função potencialmente não linear do histórico da série. A forma de f determina o tipo de não linearidade.

Modelos de Limiar

f muda quando a série cruza um valor crítico — a dinâmica depende do nível atual.

Em ambos os casos, identificar o regime ativo em cada instante equivale a detectar eventos — momentos em que o processo mudou de comportamento.

Modelos de Markov

f alterna entre K estados latentes com probabilidades de transição — o regime ativo não é diretamente observável.

Detecção de Mudança de Regime

Ideia Central

Em modelos de regime, o processo alterna entre K dinâmicas distintas. Um evento corresponde à transição $k_t \neq k_{t-1}$ entre estados.

$$X_t = \mu_{k_t} + \phi_{k_t} X_{t-1} + \varepsilon_t$$

onde $k_t \in \{1, \dots, K\}$ é o regime ativo no tempo t , com parâmetros μ_{k_t} , ϕ_{k_t} e $\sigma_{k_t}^2$ próprios para cada estado.

Detecção de Mudança de Regime

ENTRADA: X_t (série temporal), K (número de regimes)

PRÉ-CONDIÇÃO: série com comportamento heterogêneo ao longo do tempo

PASSO 1 — Inicialização

Definir K regimes com parâmetros iniciais: $\mu_k, \phi_k, \sigma_k^2$

Inicializar matriz de transição $P[k \rightarrow j]$ para $k, j = 1 \dots K$

PASSO 2 — Estimação das probabilidades de regime

PARA cada t de 1 até T :

Calcular $P(k_t | X_1 \dots X_t)$ via filtro forward

PARA t de T até 1:

Refinar $P(k_t | X_1 \dots X_T)$ via suavização backward

PASSO 3 — Atualização dos parâmetros (EM)

Atualizar $\mu_k, \phi_k, \sigma_k^2$ e P usando probabilidades suavizadas

Repetir PASSOS 2-3 até convergência da log-verossimilhança

PASSO 4 — Classificação e detecção


$\hat{k}_t \leftarrow \arg\max_k P(k_t | X_1 \dots X_T)$

Evento detectado em t quando $\hat{k}_t \neq \hat{k}_{t-1}$

SAÍDA: sequência $\hat{k}_t$ (regime estimado em cada instante)


PÓS-CONDIÇÃO: log-verossimilhança convergida; regimes interpretáveis

Referências Bibliográficas




Event Detection in Time Series

Ogasawara, E.; Salles, R.; Porto, F.; Pacitti, E.
Springer Nature Switzerland, 2025.



Time Series Analysis: With Applications in R

Cryer, J. D.; Chan, K.-S. Springer, 2008.



Data Mining: Concepts and Techniques

Han, J.; Pei, J.; Tong, H. Morgan Kaufmann, 4^a ed., 2022.