

Detecção de Eventos em Séries Temporais: Anomalias e Change Points


O que é um evento em uma série temporal?

Um evento é um instante ou intervalo em que a série exibe uma **mudança relevante** — uma ruptura, anomalia, padrão recorrente ou transição de regime.

A relevância é sempre relativa ao domínio: o que constitui um evento em clima pode não ter o mesmo significado em finanças, saúde ou segurança.

O objetivo da detecção de eventos é **identificar automaticamente** essas mudanças e extrair delas informação útil para análise ou decisão.

YGT obtida da NOAA: uma série univariada usada como exemplo recorrente.



Formalização básica de série temporal

Uma série temporal X é uma sequência ordenada de n observações.

Cada observação x_t é indexada pelo tempo t .

A ordem dos dados é parte do significado: permutar a sequência destrói informação temporal.

$$X = \langle x_1, x_2, x_3, \dots, x_n \rangle, \quad |X| = n, \quad t \in \{1, \dots, n\}$$

Taxonomia de eventos em séries temporais

- **Tipos de eventos pontuais** — anomalias, change points, motifs e discords
- **Estrutura dos dados** — granularidade temporal e dimensionalidade
- **Cenários de detecção** — offline, online e predição
- **Famílias de métodos** — regressão, classificação, clustering e estatísticos
- **Avaliação** — métricas de desempenho e custo computacional

Eventos pontuais: ideia geral

Um evento pontual ocorre quando uma característica temporal foge do esperado.

A expectativa pode ser estimada pelo passado, pelo futuro ou pela divergência entre os dois lados.

Essa visão permite unificar anomalias e pontos de mudança.

$tc(xt)$: valor, tendência ou volatilidade em t

Eventos pontuais: formalização

$ep(tc(xt), k)$: característica esperada a partir das k observações anteriores.

$ef(tc(xt), k)$: característica esperada a partir das k observações seguintes.

σ define a tolerância para considerar uma mudança significativa.

$$e(X, k, \sigma) = \{t : |tc(xt) - ep(tc(xt), k)| > \sigma \vee |tc(xt) - ef(tc(xt), k)| > \sigma \vee |ep(tc(xt), k) - ef(tc(xt), k)| > \sigma\}$$

Anomalias: intuição

Uma anomalia é uma observação que destoa do comportamento esperado da série — seja por valor extremo, padrão incomum ou desvio contextual.

Pode indicar erro de medição, falha de equipamento, incidente crítico ou perturbação externa.

Em análise aplicada, o que importa não é o valor absoluto, mas o desvio em relação ao contexto temporal: a mesma temperatura pode ser normal em julho e anômala em dezembro.

Anomalias: formalização

A observação é anômala quando escapa do esperado antes e depois do instante t .

Essa condição separa uma irregularidade local de uma transição de regime.

$$a(X, k, \sigma) = \{t : |tc(xt) - ep(tc(xt), k)| > \sigma \wedge |tc(xt) - ef(tc(xt), k)| > \sigma\}$$

Anomalias por resíduos

Resíduo como sinal de evento

Ajusta-se um modelo α para estimar a série esperada.

O resíduo mede o que o modelo não explicou.

Se o modelo estiver bem ajustado, resíduos extremos indicam candidatos a evento.

$$\omega_t = x_t - \hat{x}_t, \text{ com } \hat{x}_t = \alpha(x_t)$$


Limiar para resíduos extremos

Paramétrico: assume resíduos aproximadamente gaussianos e usa média ± 3 desvios.

Não paramétrico: evita suposição de distribuição e usa quartis e distância interquartil.

Gaussiano: $\omega_t \notin [\bar{W} - 3 \cdot \text{sd}(W), \bar{W} + 3 \cdot \text{sd}(W)]$

Boxplot: $\omega_t \notin [Q1(W) - 1.5 \cdot \text{IQR}(W), Q3(W) + 1.5 \cdot \text{IQR}(W)]$



Change points: intuição

Um **change point** marca uma transição entre regimes distintos da série — o comportamento antes e depois do ponto é estruturalmente diferente.

A mudança pode ocorrer na média, variância, correlação, tendência ou em combinação de parâmetros.

Diferente da anomalia, que é local e transitória, o change point **inaugura um novo estado que persiste** ao longo do tempo.


Essa distinção é fundamental para escolher o método de detecção adequado.

Change points: formalização

O instante t é compatível com um lado da vizinhança, mas não com ambos.

Também há mudança quando as expectativas antes e depois de t diferem acima de σ .

$$\text{cp}(X, k, \sigma) = \{t : (|tc(xt) - ep(tc(xt), k)| > \sigma \square |tc(xt) - ef(tc(xt), k)| > \sigma) \vee |ep(tc(xt), k) - ef(tc(xt), k)| > \sigma)\}$$



Change point como teste de hipótese


A ausência de mudança sugere distribuições semelhantes ao longo do tempo.

A presença de mudança sugere ao menos uma vizinhança com distribuição diferente.

Essa leitura conecta change point detection e concept drift.

$$H_0: P_n(t) \approx P_n(k) \quad H_A: \text{existe } k \text{ tal que } P_n(t) \neq P_n(k)$$

Change points no exemplo YGT



Linhas tracejadas indicam pontos de mudança detectados com estatística de Chow.

Motifs e Discords

Motifs: padrões que se repetem

Um **motif** é uma subsequência que se repete aproximadamente em diferentes posições da série temporal.

A recorrência revela **estrutura latente**: sazonalidade local, assinatura de processo ou comportamento cíclico não capturado por modelos globais.


Motifs são úteis para **classificação não supervisionada**, compressão, explicação de padrões e descoberta de regularidades em domínios como ECG, sensores industriais e séries climáticas.

Discords: padrões que não se repetem

Um discord é uma subsequência muito diferente das demais.

Ele pode ser visto como uma **anomalia intervalar**.

A dificuldade está em comparar subsequências sem explodir o custo computacional.



Motif: definição operacional

Dada uma sequência q e uma série X , q é motif se ocorre em X ao menos σ vezes.

A descoberta exige uma noção de distância ou similaridade entre subsequências.

A busca ingênua compara muitas subsequências e tende a custo $O(n^2)$.

$$q \text{ é motif em } X \Leftrightarrow \text{ocorrências}(q, X) \geq \sigma$$

Estrutura dos dados

Séries temporais podem ser vetores, tabelas, matrizes ou objetos especializados.

Eventos podem ser representados por rótulos, intervalos, timestamps ou escores.

A estrutura escolhida influencia diretamente o método e a avaliação.

Granularidade dos eventos

Eventos pontuais

Associados a um instante específico.

Representados por timestamp e atributos do evento.

Exemplo: pico de temperatura em um ano.

Eventos intervalares

Possuem início e fim.

Demandam análise de duração e sobreposição.

Exemplo: período prolongado de chuva intensa.

year\month	1	2	3	4	5	6	7	8	9	10	11	12	year	value
1971	13.9	13.8	13.8	13.8	13.9	13.8	13.9	13.9	13.9	13.8	13.9	13.9	1971	13.8
1972	13.7	13.7	14.0	14.0	13.9	14.0	14.0	14.0	13.9	14.0	14.0	14.0	1972	13.9
1973	14.3	14.3	14.3	14.2	14.1	14.2	14.1	14.0	14.0	14.0	13.9	14.0	1973	14.1
1974	13.8	13.7	13.9	13.9	13.9	13.8	13.9	14.0	13.9	13.8	13.8	13.8	1974	13.8
1975	14.0	14.0	14.0	14.0	14.0	14.0	13.9	13.9	13.9	13.8	13.7	13.8	1975	13.9
1976	13.9	13.8	13.8	13.9	13.8	13.9	13.9	13.9	13.9	13.7	13.9	14.0	1976	13.9
1977	14.1	14.1	14.2	14.2	14.2	14.2	14.1	14.1	14.1	14.0	14.1	14.0	1977	14.1
1978	14.1	14.1	14.1	14.0	14.0	14.0	14.0	13.9	14.0	14.0	14.1	14.0	1978	14.0
1979	14.0	13.8	14.1	14.0	14.1	14.1	14.1	14.2	14.2	14.2	14.2	14.4	1979	14.1
1980	14.3	14.3	14.2	14.2	14.3	14.2	14.2	14.1	14.1	14.1	14.2	14.1	1980	14.2

(a)

(b)

Temperatura global mensal agregada para temperatura global anual entre 1971 e 1980.

Dimensionalidade

Univariada

- Uma variável observada ao longo do tempo.
- Estrutura simples, frequentemente um vetor com índice temporal.
- Boa para introduzir conceitos e métodos básicos.

Multivariada

- Duas ou mais variáveis observadas no tempo.
- Permite estudar relações, dependências e causas prováveis.
- Aumenta a complexidade de modelagem e interpretação.

value
13.8
13.9
14.1
13.8
13.9
13.9
14.1
14.0
14.1
14.2

(a)

time	value
1971	13.8
1972	13.9
1973	14.1
1974	13.8
1975	13.9
1976	13.9
1977	14.1
1978	14.0
1979	14.1
1980	14.2

(b)

time	global temperature	crude oil production
1971	13.8	2491
1972	13.9	2634
1973	14.1	2870
1974	13.8	2875
1975	13.9	2740
1976	13.9	2966
1977	14.1	3069
1978	14.0	3108
1979	14.1	3229
1980	14.2	3111

(c)

Vetor univariado, série com coluna temporal e série multivariada.

Famílias de métodos de detecção

Regressão

Ajusta um modelo ao comportamento esperado da série e detecta eventos como desvios nos resíduos. Exemplos: ARIMA, regressão local, redes neurais.

Clustering

Agrupa subsequências por similaridade e isola padrões pouco frequentes como candidatos a evento. Útil quando não há rótulos disponíveis.

Classificação

Aprende a distinguir instantes normais de eventos a partir de dados rotulados. Requer anotações de treinamento e generaliza bem quando o padrão de evento é estável.

Estatísticos e baseados em domínio

Aplicam limiares, testes de hipótese ou conhecimento especialista. Interpretáveis e eficientes, mas dependem de suposições sobre a distribuição.

Custo computacional: O custo computacional — tempo de execução, memória e escalabilidade — varia significativamente entre famílias e deve ser considerado na escolha do método, especialmente em cenários online ou com séries longas e multivariadas.

Teoria, dados e aprendizado

Theory-driven

- Parte de hipóteses e modelos do domínio.
- Mais interpretável quando o processo é bem conhecido.
- Exemplo: modelos físicos, regras clínicas, limites operacionais.

Data-driven

- Aprende padrões diretamente dos dados.
- Inclui KNN, K-Means, SVM, redes neurais, Conv1D e LSTM.
- Depende de volume, qualidade e representatividade dos dados.

Cenários de detecção

Offline

Identifica eventos após a coleta completa da série.

- Permite uso de contexto futuro
- Suporta algoritmos custosos
- Admite múltiplas passagens pelos dados

Online

Detecta eventos à medida que novas observações chegam.

- Não pode olhar para o futuro
- Exige baixa latência
- Pouco ajuste manual
- Atualização contínua do modelo

Predição

Estima a ocorrência futura de eventos a partir do histórico.

- Combina modelagem temporal
- Critérios de alerta antecipado

$\langle \dots, x_{t-2}, x_{t-1}, x_t, x_{t+1}, \dots \rangle \Rightarrow$ decidir sobre x_t antes de x_{t+1}

Avaliação de detecção de eventos

A avaliação compara a saída do algoritmo com um conjunto de eventos de referência (*ground truth*). As métricas usuais — **precisão, revocação, F1-score** e **AUC-ROC** — medem o equilíbrio entre detecções corretas e falsas.

Eventos intervalares exigem cuidado adicional: é preciso definir critérios de **tolerância temporal, sobreposição mínima** e **atraso aceitável** entre o evento real e a detecção.




A escolha da métrica deve refletir o **custo assimétrico dos erros** no domínio de aplicação.

Como podemos organizar o tema

O deck percorre cinco grandes blocos, do fundamento formal ao problema aplicado:

- **Séries temporais** — definição, estrutura e formalização básica
- **Tipos de eventos** — anomalias, change points, motifs e discords
- **Estrutura dos dados** — granularidade e dimensionalidade
- **Métodos e cenários** — famílias de detecção, offline, online e predição
- **Avaliação** — métricas, tolerância temporal e custo computacional

Referências Bibliográficas



Event Detection in Time Series

Ogasawara, E.; Salles, R.; Porto, F.;
Pacitti, E. Springer Nature Switzerland,
2025.

Time Series Analysis: With Applications in R

Cryer, J. D.; Chan, K.-S. Springer, 2008.

Data Mining: Concepts and Techniques

Han, J.; Pei, J.; Tong, H. Morgan
Kaufmann, 4^a ed., 2022.