

Event Detection in Time Series



Introdução a Detecção de Eventos em Séries Temporais

Anomalias, pontos de mudança, motivos e discords — conceitos, formalização e métodos de detecção em séries temporais.

Eduardo Ogasawara

eduardo.ogasawara@cefet-rj.br

<https://eic.cefet-rj.br/~eogasawara>

O que é uma Série Temporal?

Uma série temporal X é uma sequência de n observações $\langle x_1, x_2, x_3, \dots, x_n \rangle$, onde x_1 e x_n representam, respectivamente, as observações mais antigas e mais recentes. Uma observação específica é referenciada como x_t , indexada no tempo por t ($t \in \{1, \dots, n\}$).

Classificações

Univariada vs. Multivariada: uma ou múltiplas variáveis por observação.

Baixa vs. Alta frequência: observações diárias/anuais vs. múltiplas por dia.

Offline vs. Online: análise retrospectiva vs. detecção em tempo real.

Componente Temporal (TC)

O TC para x_t pode se referir à própria observação x_t , à sua tendência instantânea $tr(x_t)$ ou à sua volatilidade instantânea $v(x_t)$. Sob a hipótese autorregressiva, o TC esperado a partir das k observações anteriores é:

$$ep(tc(x_t), k) = E(tc(x_t) \mid tc(x_{t-1}), \dots, tc(x_{t-k}))$$

E a partir das k observações seguintes:

$$ef(tc(x_t), k) = E(tc(x_t) \mid tc(x_{t+1}), \dots, tc(x_{t+k}))$$

O que são Eventos em Séries Temporais?

Eventos em séries temporais são instantes ou intervalos onde as observações mudam de forma considerada importante para análise ou tomada de decisão. A interpretação de um evento varia significativamente entre domínios.

Meteorologia

Intervalos de chuva intensa ou tempestades severas.

Economia

Quedas ou ganhos abruptos em mercados financeiros.

Indústria

Falhas de máquinas, violações de segurança, picos de tráfego de rede.

Saúde

Diagnóstico médico, surtos de doenças, detecção de arritmias.

Em teoria da informação, eventos são intervalos marcados por mudanças significativas de entropia — segmentos que contêm mais informação do que os demais.

Formalização de Eventos Pontuais

$$e(X, k, \sigma) = \{t \mid |tc(x_t) - ep(tc(x_t), k)| > \sigma \vee |tc(x_t) - ef(tc(x_t), k)| > \sigma \vee |ep(tc(x_t), k) - ef(tc(x_t), k)| > \sigma\}$$

Três Tipos Principais

- **Anomalias:** observações que diferem significativamente das típicas
- **Pontos de Mudança:** mudanças significativas na tendência ou volatilidade
- **Motifs:** sequências aproximadamente repetidas na série

Estrutura de Dados para Séries Temporais e Eventos

Séries temporais e eventos podem ser representados em diversas estruturas de dados, dependendo do contexto e propósito da análise.

Granularidade

Eventos Pontuais: observações individuais interpretadas como eventos em relação ao restante da série. Representados em estrutura de dados com timestamp.

Eventos Intervalares: ocorrem ao longo de um período definido, registrados com tempo de início e fim. Exemplos: chuva diária contínua, alto consumo de energia elétrica.

Dimensionalidade

Univariada: uma única variável por observação. Representada como vetor. Exemplo: Série de Temperatura Global Anual (YGT).

Multivariada: múltiplas variáveis por observação. Representada como matriz ou tabela. Exemplo: temperatura, umidade e velocidade do vento por hora.

Uma estrutura comum é uma tabela onde cada linha representa um instante de tempo e cada coluna representa uma variável. Uma coluna adicional pode indicar a presença e o tipo de evento.

Taxonomia de Eventos em Séries Temporais

A taxonomia organiza os principais conceitos associados à detecção de eventos em cinco grandes categorias, fornecendo um contexto estruturado para os métodos da literatura.

Tipo de Evento

Anomalias, Pontos de Mudança, Motifs e Discords — cada um com características e métodos distintos.

Estrutura de Dados

Granularidade (pontual vs. intervalar) e Dimensionalidade (univariada vs. multivariada).

Método de Detecção

Regressão, Classificação, Clustering, Estatístico e Baseado em Domínio.

Cenário de Detecção

Offline (retrospectivo), Online (tempo real) e Predição (eventos futuros).

Avaliação

Acurácia (precisão, recall, F1, AUC-ROC) e Recursos Computacionais.

Os métodos de detecção são especializados: a maioria identifica apenas um tipo específico de evento. Quando detectam múltiplos tipos, geralmente combinam anomalias e pontos de mudança.

Anomalias

Definição

Anomalias são observações que não se conformam às típicas da série temporal. Uma anomalia em x_t ocorre quando o TC escapa do valor esperado tanto antes quanto depois do instante t , segundo o limiar σ :

$$a(X, k, \sigma) = \{t \mid |tc(x_t) - ep(tc(x_t), k)| > \sigma \wedge |tc(x_t) - ef(tc(x_t), k)| > \sigma\}$$

Anomalias de Ruído

O tipo mais simples. Correspondem a variações anormais no componente residual da série. Seja $\hat{X}$ uma estimativa de X pelo modelo α , com $\hat{x}_t = \alpha(x_t)$, o resíduo é $\omega_t = x_t - \hat{x}_t$. Anomalias são identificadas por testes de distribuição estatística (sdt) sobre W :

$$na(X) = sdt(W), \quad \omega_t = x_t - \hat{x}_t$$

Anomalias vs. Outliers: anomalias são eventos que se pretende detectar; outliers são observações indesejadas que se pretende descartar. A distinção é sutil — ambos representam desvios, mas com propósitos analíticos diferentes.

Detecção Paramétrica (Gaussiana)

$$sdt(W) = \{t \mid \omega_t \notin [\bar{W} - 3 \cdot sd(W), \bar{W} + 3 \cdot sd(W)]\}$$

Assume distribuição Gaussiana. Observações além de ± 3 desvios-padrão são anomalias.

Detecção Não-Paramétrica (Box Plot)

$$sdt(W) = \{t \mid \omega_t \notin [Q_1(W) - 1.5 \cdot IQR(W), Q_3(W) + 1.5 \cdot IQR(W)]\}$$

Não assume distribuição específica. Usa quartis e distância interquartil (IQR). Mais robusto para distribuições assimétricas.

Pontos de Mudança

Definição

Pontos de mudança são intervalos de tempo onde há uma mudança significativa nas propriedades estatísticas da série — média, variância, correlação ou outros parâmetros. Representam uma transição entre diferentes estados do processo gerador.

$$cp(X, k, \sigma) = \{t \mid (|tc(x_t) - ep(tc(x_t), k)| > \sigma \vee |tc(x_t) - ef(tc(x_t), k)| > \sigma) \vee |ep(tc(x_t), k) - ef(tc(x_t), k)| > \sigma\}$$

Diferença-chave em relação a anomalias: o TC segue o esperado antes OU depois de t , mas não em ambos simultaneamente.

Exemplo: na Série de Temperatura Global Anual (YGT), pontos de mudança detectados pelo teste de Chow revelam regimes climáticos distintos — tendências significativamente diferentes antes e depois de cada ponto.

Relação com Concept Drift

Em séries multivariadas D , onde $X \subset D$ é preditor de $Y \in D$, a detecção de pontos de mudança equivale a um teste de hipótese de concept drift:

$$H_0 : \forall t, k (t \neq k) \mid \mathbb{P}_{n(t)} \approx \mathbb{P}_{n(k)}$$

$$H_A : \forall t \exists k (t \neq k) \mid \mathbb{P}_{n(t)} \neq \mathbb{P}_{n(k)}$$

H_0 caracteriza a ausência de drift; H_A nega H_0 . $\mathbb{P}_{n(t)}$ é a função de densidade de probabilidade para D nas observações vizinhas de t (ex.: janela deslizante contendo t).

Motifs e Discords

Motifs

Motifs são subsequências aproximadamente repetidas em uma série temporal. Correspondem a padrões recorrentes com forma distintiva. Dado uma sequência q e uma série X , q é um motif em X se e somente se q ocorre em X pelo menos σ vezes.

São úteis para identificar tendências, padrões sazonais e outliers. Tornam-se mais interessantes quando as sequências fornecem mais informação do que as observações típicas.

Métodos de Descoberta

A abordagem direta (força bruta) tem complexidade $O(n^2)$. Métodos baseados em indexação com SAX (Symbolic Aggregate approXimation) e hashing melhoram o tempo computacional. O estado da arte usa Matrix Profile para computação eficiente.

Discords

Discords são sequências que não se repetem na série temporal — as mais isoladas de todas as demais. São significativamente diferentes do restante das observações.

Exemplo: em um eletrocardiograma (MIT-BIH), as batidas cardíacas regulares formam motifs. Batidas irregulares (arritmias) podem ser interpretadas como:

- Motifs raros: três subsequências similares e incomuns
- Discords: três subsequências significativamente diferentes entre si

Distinção Fundamental

Motifs → similaridade (repetição). Discords → isolamento (singularidade). A mesma subsequência pode ser classificada diferentemente dependendo do critério adotado.

Métodos de Detecção de Eventos

Os métodos de detecção de eventos adotam cinco grupos gerais e podem ser classificados como orientados a teoria ou orientados a dados.

Regressão

Modela a série e detecta desvios em relação ao modelo ajustado. Base para anomalias de ruído (ex.: ARIMA).

Classificação

Requer dados rotulados (supervisionado). Distingue observações típicas de eventos. Ex.: SVM, redes neurais.

Clustering

Agrupa observações similares. Eventos são pontos distantes dos clusters típicos. Não requer rótulos (não-supervisionado).

Estatístico

Testes de hipótese e análise de distribuição. Ex.: teste de Chow para pontos de mudança, box plot para anomalias.

Baseado em Domínio

Usa conhecimento especializado do domínio. Ex.: métodos tempo-frequência para séries sísmicas, modelos de postura corporal para detecção de quedas.

Orientados a Teoria

Baseados em princípios estabelecidos. Predominam nos grupos estatístico e de domínio. Incorporam explicitamente construtos teóricos.

Orientados a Dados (ML)

Criados pela análise de grandes séries temporais. Principais métodos: KNN-CAD, K-Means, NNET, SVM, ELM, Conv1D, LSTM. Aprendizado supervisionado, semi-supervisionado ou não-supervisionado.

Cenários de Detecção

Os cenários de detecção caracterizam as condições em que os métodos são aplicados, determinando requisitos de gerenciamento de dados, recursos computacionais e restrições dos algoritmos.

Offline

Eventos descobertos após a coleta completa da série. Análise retrospectiva em duas etapas: (1) pré-processamento da série; (2) aplicação do método de análise. Permite validação adicional para confirmar eventos reais vs. falsos positivos.

Online

Eventos descobertos em tempo real, conforme as observações são coletadas. Requer monitoramento contínuo e restrições computacionais para reações em tempo real. Exemplo: manutenção preditiva — detectar mudanças em máquinas antes de falhas.

Predição

Previsão de eventos futuros com base em séries históricas. Usa métodos estatísticos, ML ou deep learning (ARIMA a LSTM). Aplicações: finanças, saúde (previsão de surtos, desfechos de pacientes).

Desafio do Online: diferentemente do offline, os dados não são divididos em conjuntos estáticos de treino/teste. Quando os fluxos de sensores são numerosos ou de alta velocidade, a operação não-supervisionada e automatizada é necessária. Há um tradeoff entre detecção precoce e falsos positivos.

Avaliação de Métodos de Detecção

A avaliação determina a eficácia dos algoritmos de detecção, comparando a saída do método com dados de referência (ground truth) rotulados por especialistas.

Métricas de Acurácia

- **Precisão:** razão entre eventos verdadeiramente positivos e total de eventos detectados.
- **Recall:** razão entre eventos verdadeiramente positivos e total de eventos reais.
- **F1-Score:** média ponderada de precisão e recall.
- **AUC-ROC:** capacidade do algoritmo de discriminar entre eventos positivos e negativos.

Saídas dos métodos: scores (grau de anomalia por instância) ou rótulos (típico vs. anômalo).




Recursos Computacionais

- **Complexidade de Tempo:** tempo necessário para executar o algoritmo dado o tamanho da entrada.
- **Complexidade de Espaço:** quantidade de memória requerida.
- **Complexidade Computacional:** requisitos totais de recursos (tempo, memória, outros).

Estratégias para gerenciar complexidade: otimização do algoritmo, processamento paralelo e técnicas de redução de dados.

Desafio: benchmarking e comparação de desempenho são difíceis. Métricas padrão de classificação funcionam para eventos pontuais, mas eventos intervalares requerem extensões de Precisão e Recall que consideram tolerância temporal.

Referências Bibliográficas



Event Detection in Time Series

Ogasawara, E.; Salles, R.; Porto, F.; Pacitti, E. Springer Nature Switzerland, 2025.

Time Series Analysis: With Applications in R

Cryer, J. D.; Chan, K.-S. Springer, 2008.

Data Mining: Concepts and Techniques

Han, J.; Pei, J.; Tong, H. Morgan Kaufmann, 4^a ed., 2022.