

Fundamentos de Análise de Séries Temporais



Eduardo Ogasawara

eogasawara@cefet-rj.br | <https://eic.cefet-rj.br/~eogasawara>



Objetivos do capítulo

1. Entender os componentes fundamentais de uma série temporal.
2. Reconhecer estacionaridade, não estacionaridade e seus efeitos.
3. Aplicar pré-processamento e predição como base para detecção de eventos.

Por que este capítulo sustenta event detection

Anomalias dependem da noção de comportamento esperado.

Change points dependem da ideia de mudança de regime.

Motifs dependem de janelas, normalização e similaridade entre subsequências.

Mapa do capítulo

01

Componentes

Tendência, sazonalidade e resíduo.

03

Pré-processamento

Agregação, transformação, janelas, normalização e divisão.

02

Estacionaridade

Hipóteses, diagnóstico e testes.

04

Predição

Modelos estatísticos, ML, LLMs e grafos.

Série como composição de componentes

- Uma série temporal pode ser estudada como combinação de tendência, sazonalidade e resíduo.
- Separar componentes ajuda a interpretar estrutura e ruído.
- Muitos detectores de eventos operam sobre um componente específico.

$$x_t = \beta_t + \pi_t + \omega_t$$

Tendência

- Representa o movimento de longo prazo da série.
- Pode ser crescente, decrescente ou aproximadamente estável.
- Em detecção de eventos, tendência ajuda a separar desvio local de mudança persistente.

Sazonalidade

- Representa padrões que se repetem em períodos fixos.
- Pode ocorrer em ciclos diários, semanais, mensais ou anuais.
- Ignorar sazonalidade pode transformar comportamento esperado em falso evento.


Resíduo ou ruído

É a parte não explicada por tendência e sazonalidade.

Quando o modelo está adequado, o resíduo tende a se comportar como ruído.

Anomalias por resíduo procuram valores extremos nessa componente.

Decomposição da temperatura global



A série é separada em tendência, sazonalidade e resíduo.

O que é estacionaridade



Uma série estacionária mantém propriedades estatísticas estáveis ao longo do tempo.



Muitos modelos assumem que média, variância e dependência temporal não mudam.



Quando a hipótese falha, inferência e previsão podem se tornar enganosas.

Média, variância e autocovariância

Média constante

O nível esperado não depende do tempo.

Variância constante

A dispersão não muda ao longo da série.


Autocovariância

Depende da defasagem, não do instante absoluto.

Tipos de não estacionaridade

- Tendência determinística desloca a média ao longo do tempo.
- Quebras estruturais produzem mudanças de nível.
- Heteroscedasticidade altera a variância.
- Raiz unitária produz comportamento difference stationary.

Estacionaridade e não estacionaridade




Exemplos: estacionária, trend stationary, level stationary, heteroscedástica e difference stationary.

ACF: intuição

- A autocorrelação mede quanto a série se relaciona com versões defasadas dela mesma.
- Em séries estacionárias, a ACF tende a cair rapidamente.
- Em séries não estacionárias, a dependência pode persistir por muitos lags.

ACF como diagnóstico visual



A ACF ajuda a visualizar dependência temporal e indícios de não estacionaridade.

Testes estatísticos de estacionaridade

- ADF e Phillips-Perron testam presença de raiz unitária.
- Breusch-Pagan avalia heteroscedasticidade.
- Nenhum teste cobre todos os tipos de não estacionaridade; eles devem ser combinados com diagnóstico visual.

Impacto na detecção de eventos

- Não estacionaridade pode parecer anomalia.
- Mudanças de nível podem ser confundidas com outliers persistentes.
- Sazonalidade não tratada pode gerar falsos positivos periódicos.
- Pré-processamento adequado reduz essas ambiguidades.

Por que pré-processar séries temporais



Pré-processamento melhora a qualidade dos dados antes da modelagem.



Em séries temporais, ele também corrige escala, frequência, tendência e dependência temporal.



É uma etapa decisiva para que detectores vejam eventos, não artefatos.

Principais tarefas

- Limpeza: valores ausentes, erros e ruídos.
- Transformação: tendência, variância, decomposição e diferenciação.
- Janelas, normalização e divisão temporal para modelagem e avaliação.


Ponte para modelagem e detecção

- A mesma série pode gerar resultados diferentes dependendo do pré-processamento.
- Modelos estatísticos e de ML são sensíveis a escala e estacionaridade.
- Detectores de eventos herdam essas escolhas.

Agregação temporal

- Agrupa observações em uma frequência mais baixa.
- Reduz ruído e simplifica a análise.
- Também pode remover detalhes importantes para eventos curtos.

Frequência e granularidade



A agregação temporal muda o nível de frequência usado na análise.

Formalização da agregação



Uma série X pode ser agregada em blocos de tamanho m .

Cada valor agregado representa a média do bloco correspondente.

No exemplo mensal para anual, $m = 12$.

$$y_j = \text{média de } x \text{ entre } m(j-1)+1 \text{ e } m \cdot j$$

MGT para YGT



Temperatura global mensal agregada em temperatura global anual.

Ganho e perda de informação

Ganho

- Menos ruído local.
- Visualização mais simples.
- Modelagem mais estável em alguns cenários.

Perda

- Eventos curtos podem desaparecer.
- Picos e variações locais são suavizados.
- A escolha da escala altera a interpretação.

Extração de tendência

- Extrair tendência estima o movimento de longo prazo.
- Regressão linear captura tendência monotônica simples.
- Média móvel suaviza flutuações e acompanha variações graduais.

Regressão linear e média móvel



Regressão linear

- Assume uma forma global simples.
- Boa para tendência aproximadamente linear.
- Facilita interpretação.

Média móvel

- Usa vizinhança local.
- Suaviza ruído de curto prazo.
- Depende do tamanho da janela.

Tendência na YGT



Extração de tendência por regressão linear e média móvel.

Estabilização de variância

Algumas séries mudam sua variância ao longo do tempo.

Transformações reduzem heteroscedasticidade.

Isso torna resíduos e erros mais comparáveis ao longo da série.

Log transform e Box-Cox



Log transform

- Reduz amplitude de valores altos.
- Útil para crescimento multiplicativo.
- Exige valores positivos.

Box-Cox

- Família de transformações parametrizada.
- Escolhe λ para estabilizar variância.
- Mais flexível que log simples.

Exemplo de estabilização



Transformação logarítmica e Box-Cox aplicadas à YGT.


Detrending

- Remove uma tendência determinística estimada.
- Permite analisar desvios em torno da tendência.
- É útil quando a tendência é parte esperada do processo.

Differencing

- Substitui valores por diferenças entre observações sucessivas.
- Ajuda a remover tendência estocástica e raiz unitária.
- Muda a interpretação da série: de nível para variação.

Detrending vs differencing



Comparação entre remoção de tendência, diferença simples e mudança percentual.

Decomposição no domínio da frequência



Transformações de frequência representam a série por componentes periódicos.



A FFT identifica frequências relevantes no sinal.



Filtrar frequências pode separar estrutura periódica e resíduo.

FFT: intuição

- A série é vista como combinação de ondas.
- Frequências dominantes explicam padrões periódicos.
- O resíduo aparece depois de reconstruir a série com os harmônicos escolhidos.


Exemplo com FFT

Decomposição da YGT por FFT, periodograma, reconstrução e resíduo.

Decomposição tempo-frequência

- Nem todo padrão periódico é constante ao longo do tempo.
- Métodos tempo-frequência analisam quando certas escalas aparecem.
- Wavelets e EMD lidam melhor com sinais não estacionários.

Wavelet




DWT separa componentes associadas a tendência/sazonalidade e resíduo.


EMD: decomposição adaptativa

- EMD decompõe a série em funções de modo intrínseco.
- É adaptativa: as componentes são extraídas do próprio sinal.
- Pode separar tendência e flutuações locais sem impor base fixa.

Exemplo com EMD



(a) temperature and EMD trend



(c) residual (sum of IMFs)

EMD aplicada à YGT: componente residual de tendência e primeira IMF.


Sliding windows

Janelas deslizantes transformam a série em subsequências.

São base para previsão, classificação, motivos e anomalias intervalares.

A escolha do tamanho da janela define a escala temporal observada.

Subsequências e janelas deslizantes



Uma série pode ser decomposta em janelas que se deslocam ao longo do tempo.

Normalização

- Normalização coloca valores em escalas comparáveis.
- É essencial para métodos baseados em distância e ML.
- Sem normalização, amplitude pode dominar forma e similaridade.

Min-Max, decimal scaling e Z-Score

Escala fixa

Min-Max coloca valores em faixa definida.

Decimal scaling ajusta ordem de grandeza.

Útil para entrada de modelos.


Padronização

Z-Score remove média e divide pelo desvio.

Produz média zero e variância um.

Muito usado em comparação de subsequências.

Exemplo de normalização






Comparação visual de técnicas de normalização em série temporal.

Divisão treino/teste em séries temporais


- Em séries temporais, a ordem dos dados precisa ser preservada.
- Treino deve ocorrer antes do teste.
- Embaralhar dados cria vazamento de futuro e avaliação irrealista.

Cross-validation temporal



Exemplos de divisão treino/teste e validação temporal com previsão step-ahead.

Cross-validation com sliding window



Treino e teste com janelas deslizantes de tamanho três.

Erros comuns de avaliação

- Embaralhar observações temporais.
- Normalizar usando informação do conjunto de teste.
- Escolher hiperparâmetros olhando o futuro.
- Comparar modelos em protocolos temporais diferentes.

Processo geral de predição

(1) Data preprocessing

(2) Model training

(3) Model prediction

(4) Data postprocessing

(5) Model evaluation

Pipeline de predição: aquisição, pré-processamento, modelagem, predição, pós-processamento e avaliação.

Métricas de predição

- **MSE** mede erro quadrático médio.
- **sMAPE** mede erro percentual simétrico.
- **RSS** mede soma dos resíduos ao quadrado.
- **R²** mede proporção da variância explicada pelo modelo.


Modelos estatísticos

- Modelam estrutura temporal com hipóteses explícitas.
- Incluem ARIMA, modelos estruturais, espaço de estados, suavização exponencial e GARCH.
- São importantes como baseline e como fonte de resíduos para detecção de eventos.

ARIMA: intuição

- Combina autoregressão, diferenciação e média móvel.
- Modela dependência temporal e pode lidar com não estacionaridade por differencing.
- Resíduos de ARIMA são úteis para detectar anomalias por desvio do esperado.

Exemplo com ARIMA



(a) ARIMA(1, 1, 3) four-step-ahead prediction

Modelo ARIMA ajustado no treino e previsão quatro passos à frente.

Modelos estruturais, suavização e GARCH

- Modelos estruturais separam tendência, ciclo e erro.
- Espaço de estados permite estimar componentes latentes.
- Suavização exponencial acompanha nível, tendência e sazonalidade.
- GARCH modela variância condicional e volatilidade.


Modelos estatísticos na detecção de eventos

- Predições geram valores esperados.
- Resíduos medem desvio entre observado e esperado.
- Mudanças nos parâmetros ou resíduos podem indicar eventos.
- Esses modelos ajudam a formalizar o que seria comportamento típico.

Limitações


- Hipóteses estatísticas podem falhar em séries reais.
- Mudanças de regime podem invalidar modelos treinados no passado.
- Séries multivariadas e não lineares podem exigir modelos mais flexíveis.

ML com sliding windows



Modelos de ML usam valores defasados como entrada para prever a próxima observação.

Redes neurais, Conv1D e LSTM



(a) LSTM four-step-ahead prediction

Exemplo de LSTM com quatro entradas para previsão quatro passos à frente.

LLMs para séries temporais



Séries temporais podem ser normalizadas, discretizadas e tratadas como sequências de tokens.



Modelos pré-treinados podem gerar previsões probabilísticas.





A promessa é reaproveitar aprendizado sequencial com pouco dado rotulado.

Modelos baseados em grafos e fechamento

- Grafos representam dependências entre múltiplas séries ou variáveis.
- STGNNs combinam dependência temporal e espacial por message passing.
- Tudo neste capítulo prepara a detecção de eventos: esperado, desvio, janela, escala, regime e previsão.

Referências Bibliográficas



Event Detection in Time Series

Ogasawara, E.; Salles, R.; Porto, F.;
Pacitti, E. Springer Nature Switzerland,
2025.

Time Series Analysis: With Applications in R

Cryer, J. D.; Chan, K.-S. Springer, 2008.

Data Mining: Concepts and Techniques

Han, J.; Pei, J.; Tong, H. Morgan
Kaufmann, 4^a ed., 2022.