

Detecção de Anomalias em Séries Temporais: Métodos e Limiares

Anomalia não é apenas sujeira nos dados

Em **outlier analysis**, o valor extremo costuma ser tratado como ruído a remover.

Em **anomaly detection**, o valor atípico é o **objeto de interesse**.

Exemplos em que a anomalia carrega informação:

- Fraudes
- Falhas de sistema
- Surtos epidemiológicos
- Incidentes de segurança
- Eventos raros

Formalização mínima: uma anomalia é um evento raro $a \in S$ tal que $P(a)$ é baixa e a informação de a é alta — isto é, $I(a) = -\log P(a) \gg 0$.

Taxonomia de anomalias

- **Tipo:** pontual ou sequencial
- **Circunstância:** contextual ou fora de contexto
- **Dimensão:** univariada ou multivariada
- **Interpretação:** supervisionada, semissupervisionada ou não supervisionada
- **Forma:** como o detector opera (regressão, classificação, agrupamento...)

A taxonomia organiza tipo, circunstância, dimensão, interpretação e forma de aprendizado.



Anomalias pontuais e sequenciais

Anomalias pontuais

- Uma única observação difere significativamente do restante da série.
- A decisão depende do contexto local e do modelo do comportamento típico.
- É a forma mais direta de anomalia, mas não necessariamente a mais fácil de detectar.

Anomalias sequenciais

- Uma subsequência inteira apresenta comportamento incomum.
- O ponto isolado pode parecer aceitável, mas a sequência completa revela o evento.
- Exige comparar janelas, formas ou representações temporais.



Exemplo com temperatura semanal: anomalia pontual no painel (a) e sequência anômala no painel (b).

Anomalias contextuais e fora de contexto

Contextuais

- A observação não é estranha por si só.
- Ela se torna anômala quando considerada no contexto temporal.
- Exemplo: 26°C pode ser comum no verão, mas anômalo no inverno.

Fora de contexto

- O valor é atípico independentemente do instante em que ocorre.
- A explicação não depende fortemente da vizinhança temporal.
- Esse caso se aproxima da noção clássica de outlier estatístico.

Univariada vs multivariada

Univariada

Uma variável é analisada ao longo do tempo.

A anomalia aparece como valor ou sequência atípica naquela série.

Métodos são mais simples e interpretáveis.

Multivariada


A anomalia pode surgir da combinação entre variáveis.

Cada variável isolada pode parecer normal.

Relações entre dimensões passam a importar.

Exemplo: anomalia multivariada com PCA

O exemplo mostra anomalias capturadas pela relação entre variáveis, não apenas por valores extremos individuais.



Séries rotuladas e não rotuladas

Rotuladas

Cada observação pode indicar presença ou ausência de anomalia.

Permite avaliação e aprendizado supervisionado.

Rótulos podem ser incompletos ou temporalmente imprecisos.

Não rotuladas

Não há indicação direta do que é anomalia.

A detecção depende de hipótese estatística, distância ou raridade.

É o caso mais comum em aplicações reais.

Cenários de aprendizado

Supervisionado

- Usa observações com rótulos de típico/anômalo.
- A anomalia é tratada como classe a ser prevista.
- O problema central é a escassez e a imperfeição dos rótulos.

Semissupervisionado

- Treina o modelo apenas com dados típicos.
- Novas observações são anômalas quando não se ajustam ao padrão aprendido.
- É comum quando a classe anômala é rara ou difícil de rotular.

Não supervisionado

- Não requer rótulos para treinamento.
- Assume que observações típicas são mais frequentes ou mais densas.
- É flexível, mas exige cuidado maior na interpretação dos alertas.

Quando usar cada cenário de aprendizado

Mais rótulos

- Supervisionado quando os rótulos são confiáveis.
- Útil em operação online depois de uma fase de treinamento.
- Permite otimizar métricas como F1.


Menos rótulos

- Semissupervisionado quando há exemplos típicos confiáveis.
- Não supervisionado quando quase não há rótulo.
- Exige análise posterior dos alarmes.

Exemplo-base para comparar métodos

A mesma série é usada para contrastar famílias de detectores.

O objetivo é entender a hipótese operacional de cada família, não ranquear algoritmos.



Série sintética do Harbinger: região de treinamento e teste permitem comparar famílias de detectores.

Janela deslizante: transformar tempo em atributos

Uma **janela de tamanho p** usa observações passadas como atributos.

O **alvo** é a próxima observação da série.

A cada instante, a janela avança uma posição e produz outro exemplo de treino ou teste.

$x_{t-p}, \dots, x_{t-2}, x_{t-1}$ x_t

ENTRADA: série $X = x_1, \dots, x_n$, tamanho de janela p

PRÉ-CONDIÇÃO: $n > p$

PASSO 1 — Para t de $p+1$ até n :

atributos $\leftarrow x_{t-p}, \dots, x_{t-1}$

alvo $\leftarrow x_t$

adicionar (atributos, alvo) ao conjunto D

PASSO 2 — Dividir D em:

D_{treino} (instantes anteriores)

D_{teste} (instantes posteriores)

preservando ordem temporal

SAÍDA: D_{treino} e D_{teste} prontos

para regressão supervisionada

PÓS-CONDIÇÃO: nenhum dado futuro vaza para o treino

Anomalias por Regressão

Ideia central

Um modelo aprende o comportamento esperado da série. A anomalia é o desvio entre o observado x_t e o estimado $\hat{x}_t$.

$$\omega_t = \text{distance}(x_t, \hat{x}_t)$$

Janela deslizante

Observações passadas $\langle x_{t-p}, \dots, x_{t-1} \rangle$ formam os atributos; x_t é o alvo. A cada instante a janela avança uma posição.

$$[x_{t-4}, x_{t-3}, x_{t-2}, x_{t-1}] \rightarrow x_t$$

Exemplo tabular

Com $p = 5$, uma linha do conjunto de treino contém quatro defasagens e um alvo. O cuidado é preservar ordem temporal: treino antes, teste depois.

Os termos defasados $x_{t-4}, \dots, x_{t-1}$ predizem x_t ; a diferença entre previsão e observação vira resíduo.



t	x_{t-4}	x_{t-3}	x_{t-2}	x_{t-1}	$\hat{x}_t$	x_t
5	v_1	v_2	v_3	v_4	$\hat{v}_5$	v_5
6	v_2	v_3	v_4	v_5	$\hat{v}_6$	v_6
7	v_3	v_4	v_5	v_6	$\hat{v}_7$	v_7
8	v_4	v_5	v_6	v_7	$\hat{v}_8$	v_8
9	v_5	v_6	v_7	v_8	$\hat{v}_9$	v_9
10	v_6	v_7	v_8	v_9	$\hat{v}_{10}$	v_{10}
11	v_7	v_8	v_9	v_{10}	$\hat{v}_{11}$	v_{11}
12	v_8	v_9	v_{10}	v_{11}	$\hat{v}_{12}$	v_{12}
13	v_9	v_{10}	v_{11}	v_{12}	$\hat{v}_{13}$	v_{13}
14	v_{10}	v_{11}	v_{12}	v_{13}	$\hat{v}_{14}$	v_{14}

(a)

Do erro ao escore de anomalia

Depois da previsão, calcula-se uma distância entre x_t e $\hat{x}_t$.

Esse valor é o **escore de desvio** do modelo.

Quanto maior o escore, maior a evidência de que o comportamento observado não foi esperado pelo modelo.

$$\omega_t = \text{distance}(x_t, \hat{x}_t)$$

ENTRADA: série $X = x_1, \dots, x_n$, modelo M treinado,

função $\text{distance}(\cdot, \cdot)$

PRÉ-CONDIÇÃO: M foi treinado apenas com dados típicos

PASSO 1 — Para cada instante t no teste:

$\hat{x}_t \leftarrow M.\text{prever}(x_{t-p}, \dots, x_{t-1})$

$\omega_t \leftarrow \text{distance}(x_t, \hat{x}_t)$

PASSO 2 — Construir série de escores

$W = \omega_1, \dots, \omega_n$

PASSO 3 — Calcular limiar τ a partir de W
(gaussiano, boxplot ou EVT)

PASSO 4 — Marcar t como anômalo se $\omega_t > \tau$

SAÍDA: conjunto de instantes anômalos $A \subseteq \{1, \dots, n\}$

PÓS-CONDIÇÃO: A contém apenas instantes do teste

Escolhas de distância

Erro absoluto

- Mantém a escala original da série.
- É fácil de explicar para o domínio.
- Menos agressivo com erros muito grandes.

Erro quadrático

- Amplifica erros grandes.
- É comum em regressão e otimização.
- Pode aumentar a sensibilidade a picos.

Como decidir o limiar

O modelo gera uma série de resíduos $W = \langle \omega_1, \dots, \omega_n \rangle$. A detecção depende de separar resíduos típicos de resíduos extremos.

Limiar gaussiano

- Assume que os resíduos típicos seguem aproximadamente uma distribuição gaussiana.
- Simples, mas frágil quando a distribuição é assimétrica, multimodal ou não estacionária.

$$\omega_t > \text{média}(W) + 3 \cdot \text{sd}(W)$$

Limiar por boxplot

- Não exige assumir uma distribuição específica para os resíduos.
- Usa quartis e distância interquartil.
- No caso de regressão, normalmente interessa o limite superior dos erros.

$$\omega_t > Q3(W) + 1,5 \cdot IQR(W)$$

Teoria de valores extremos

- Modela especificamente a cauda da distribuição dos erros.
- Útil quando os eventos relevantes são raros e extremos.
- O limiar u é escolhido pelo método POT (Peaks Over Threshold).

$$P(\omega > u + y \mid \omega > u) \approx \left(1 + \frac{\xi \cdot y}{\beta}\right)^{-1/\xi}$$

u : limiar de excedência; ξ : índice de cauda; β : escala

Seguidores de tendência

Modelos seguidores suavizam ou decompõem a série para estimar o comportamento esperado.

Exemplos: média móvel, splines, FFT, wavelet, EMD, REMD e FBIAD.

A anomalia aparece quando a observação se afasta da curva seguida pelo modelo.

Fórmula geral: Uma anomalia é detectada quando

$$|x_t - \hat{f}(t)| > \tau$$

onde $\hat{f}(t)$ é a curva estimada pelo seguidor e τ é o limiar de detecção.

- **Limitação:** Seguidores suaves podem não capturar anomalias de curta duração, pois a suavização atenua desvios pontuais antes que eles superem o limiar.

Modelos estatísticos de regressão

ARIMA e regressão linear modelam a série com hipóteses estatísticas explícitas.

São bons quando há estrutura temporal interpretável, como autocorrelação, tendência ou sazonalidade.

A leitura do resíduo costuma ser direta: o que sobrou depois do modelo.


Distinção entre os modelos:

ARIMA: estrutura autorregressiva e de médias móveis — resíduo ε_t é ruído branco.

Regressão linear: $x_t = \beta_0 + \beta_1 \cdot t + \dots + \varepsilon_t$ — resíduo ε_t é o desvio da tendência.

- **Limitação:** Ambos assumem estacionariedade ou tendência linear; mudanças de regime podem gerar falsos positivos.

ARIMA como detector por desvio



O modelo ajustado estima a série; resíduos altos ao redor das anomalias sustentam a detecção.

Anomalia: $|\varepsilon_t| > \tau$

ENTRADA: série $X = x_1, \dots, x_n$, ordens (p, d, q) , limiar τ

PRÉ-CONDIÇÃO: série estacionária após d diferenciações

PASSO 1 — Ajustar **ARIMA**(p, d, q) em X_{treino}

PASSO 2 — Para cada instante t no teste:

$\hat{x}_t \leftarrow \text{ARIMA.prever}(t)$

$\varepsilon_t \leftarrow x_t - \hat{x}_t$

PASSO 3 — Construir $W = \varepsilon_1, \dots, \varepsilon_n$

PASSO 4 — Calcular τ

(gaussiano: $\text{média}(W) + 3 \cdot \text{sd}(W)$)

PASSO 5 — Marcar t como anômalo se $|\varepsilon_t| > \tau$

SAÍDA: instantes anômalos A

PÓS-CONDIÇÃO: resíduos de treino devem ser ruído branco

Regressores de aprendizado de máquina

A janela deslizante permite usar modelos supervisionados gerais.

Exemplos: KNN, SVM, Random Forest, XGBoost, MLP e ELM.

O detector continua sendo baseado no erro entre previsão e observação.

KNN e SVM: baseados em distância/margem — bons para padrões locais.

Random Forest e XGBoost: ensemble de árvores — capturam não-linearidades.

MLP e ELM: redes neurais rasas — aproximadores universais.

 **Cuidado:** Todos dependem da janela deslizante para transformar a série em atributos tabulares.

Regressores profundos

Conv1D e LSTM exploram padrões temporais em sequências.

DeepAnT usa redes convolucionais para prever a próxima janela e detectar desvios.

Telemanom e detectores LSTM usam erro de previsão para localizar comportamento inesperado.

 **Limitação:** Requerem mais dados de treino e são mais difíceis de interpretar que modelos estatísticos.

Conv1D: captura padrões locais via filtros convolucionais.

LSTM: captura dependências de longo prazo via memória recorrente.

DeepAnT: usa Conv1D para prever a próxima janela e compara com o observado.

Métodos recentes e híbridos

- Triple Exponential Smoothing incorpora nível, tendência e sazonalidade.
- Median Method usa a mediana da janela contextual como previsão robusta.
- Métodos híbridos e ensembles combinam modelos para reduzir fragilidades individuais.
- Transformers e modelos de fundação (ex.: Anomaly Transformer, PatchTST) aplicam atenção para capturar dependências de longo alcance.

⚠ Métodos mais complexos não garantem melhor detecção — a escolha deve considerar interpretabilidade, custo computacional e disponibilidade de dados rotulados.

O que muda entre os tipos de regressão

Muda o modelo esperado

ARIMA, média móvel, spline, RF, XGBoost, LSTM.

Cada um captura uma forma diferente de padrão temporal.

Modelo ruim gera resíduo ruim.

Permanece a lógica

Prever x_t .

Calcular erro.

Comparar erro com uma referência de normalidade.

Muda o limiar

Gaussiano (paramétrico): assume distribuição normal dos resíduos.

Boxplot (não paramétrico): baseado em quartis, sem suposição de distribuição.

EVT (cauda): modela extremos raros com teoria de valores extremos.

Cuidados práticos

- A janela p controla quanta memória temporal o modelo recebe.
- Treinar com anomalias pode fazer o modelo aprender o evento como se fosse normal.
- Mudança de regime pode parecer anomalia para um modelo não adaptativo.
- Normalização e escala afetam diretamente o erro.
- Validação temporal: nunca use dados futuros para estimar o limiar — o limiar deve ser calculado apenas sobre o conjunto de treino.

A qualidade do detector depende tanto do modelo de previsão quanto da estratégia de limiarização e da integridade da divisão treino/teste.

Classificação: anomalia como classe

- Um classificador aprende a separar observações típicas e anômalas.
- Durante o treinamento, os rótulos precisam estar disponíveis.
- Durante o teste, o modelo prediz o rótulo das novas observações.
- O desbalanceamento de classes é o principal desafio — anomalias são raras por definição.

Classificação binária: típico (0) vs anômalo (1).
Classificação multiclasse: tipo de anomalia como classe.
One-class classification: treina apenas com dados típicos (ex.: One-Class SVM).

Janela deslizante

Na etapa de treino, a janela tem rótulo; na etapa de teste, o modelo prediz a presença de anomalia.

t	x_{t-4}	x_{t-3}	x_{t-2}	x_{t-1}	x_t	$\hat{e}_t$	e_t
5	v_1	v_2	v_3	v_4	v_5	$\hat{b}_5$	b_5
6	v_2	v_3	v_4	v_5	v_6	$\hat{b}_6$	b_6
7	v_3	v_4	v_5	v_6	v_7	$\hat{b}_7$	b_7
8	v_4	v_5	v_6	v_7	v_8	$\hat{b}_8$	b_8
9	v_5	v_6	v_7	v_8	v_9	$\hat{b}_9$	b_9
10	v_6	v_7	v_8	v_9	v_{10}	$\hat{b}_{10}$	b_{10}
11	v_7	v_8	v_9	v_{10}	v_{11}	$\hat{b}_{11}$	b_{11}
12	v_8	v_9	v_{10}	v_{11}	v_{12}	$\hat{b}_{12}$	b_{12}

(a)


t	x_{t-4}	x_{t-3}	x_{t-2}	x_{t-1}	x_t	$\hat{e}_t$
13	v_9	v_{10}	v_{11}	v_{12}	v_{13}	$\hat{b}_{13}$
14	v_{10}	v_{11}	v_{12}	v_{13}	v_{14}	$\hat{b}_{14}$

(b)

Exemplo com SVM

Desafio da classificação

- Anomalias são raras, gerando forte desbalanceamento de classes.
- Rótulos humanos podem perder eventos ou marcar o instante com atraso.
- A classe aprendida pode não representar anomalias futuras ainda não vistas.



O SVM detecta parte das anomalias no teste; o exemplo também evidencia falso negativo.


Agrupamento: anomalia como distância

- Observações típicas formam grupos ou regiões densas.
- Anomalias aparecem longe dos representantes ou fora dos grupos.
- A abordagem é naturalmente não supervisionada.
- Exemplos: K-Means (centróides), DBSCAN (densidade), LOF (fator de outlier local).

Fórmula geral do score de anomalia:

$$\text{score}(x_t) = \min_k \text{dist}(x_t, c_k)$$

onde c_k são os representantes (centróides) dos clusters.




t	x_{t-4}	x_{t-3}	x_{t-2}	x_{t-1}	x_t	$\ddot{r}_c$	d_t
5	v_1	v_2	v_3	v_4	v_5	$\ddot{r}_1$	d_5
6	v_2	v_3	v_4	v_5	v_6	$\ddot{r}_1$	d_6
7	v_3	v_4	v_5	v_6	v_7	$\ddot{r}_1$	d_7
8	v_4	v_5	v_6	v_7	v_8	$\ddot{r}_2$	d_8
9	v_5	v_6	v_7	v_8	v_9	$\ddot{r}_2$	d_9
10	v_6	v_7	v_8	v_9	v_{10}	$\ddot{r}_1$	d_{10}
11	v_7	v_8	v_9	v_{10}	v_{11}	$\ddot{r}_1$	d_{11}
12	v_8	v_9	v_{10}	v_{11}	v_{12}	$\ddot{r}_2$	d_{12}
13	v_9	v_{10}	v_{11}	v_{12}	v_{13}	$\ddot{r}_2$	d_{13}
14	v_{10}	v_{11}	v_{12}	v_{13}	v_{14}	$\ddot{r}_2$	d_{14}

$\ddot{r}_t$	x_{t-4}	x_{t-3}	x_{t-2}	x_{t-1}	x_t
$\ddot{r}_1$	$\ddot{v}_{1,4}$	$\ddot{v}_{1,3}$	$\ddot{v}_{1,2}$	$\ddot{v}_{1,1}$	$\ddot{v}_{1,0}$
$\ddot{r}_2$	$\ddot{v}_{2,4}$	$\ddot{v}_{2,3}$	$\ddot{v}_{2,2}$	$\ddot{v}_{2,1}$	$\ddot{v}_{2,0}$

Janela deslizante

Cada janela é associada a um grupo; a distância ao representante apoia a detecção.

Exemplo com K-Means



Sequências distantes dos centróides são marcadas como anômalas.

$$\text{score}(x_t) = \min_k \text{dist}(x_t, c_k)$$

ENTRADA: série $X = x_1, \dots, x_n$, número de clusters k , limiar τ

PRÉ-CONDIÇÃO: janela deslizante já aplicada;

X_{treino} representa comportamento típico

PASSO 1 — Aplicar **K-Means**(k) sobre X_{treino}

→ centróides $C = \{c_1, \dots, c_k\}$

PASSO 2 — Para cada instante t no teste:

$$\text{score}(x_t) \leftarrow \min_{j=1..k} \text{dist}(x_t, c_j)$$

PASSO 3 — Calcular τ a partir dos escores de treino

(ex.: percentil 95)

PASSO 4 — Marcar x_t como anômalo se $\text{score}(x_t) > \tau$

SAÍDA: instantes anômalos A

PÓS-CONDIÇÃO: k e a métrica de distância devem ser validados no domínio

Limitações do agrupamento



A escolha de k e da métrica de distância afeta diretamente a detecção.



Escala e normalização podem mudar quais pontos parecem distantes.



Dados com anomalias no treinamento podem formar grupos espúrios.

Métodos estatísticos

Assumem que observações típicas ocupam regiões de alta probabilidade.

Anomalias aparecem em regiões de baixa probabilidade.

Podem usar modelos paramétricos, testes de hipótese ou perfis não paramétricos.


Exemplos: histograma (não paramétrico), KDE (kernel density estimation), distribuição gaussiana (paramétrico), mistura de gaussianas (GMM).

Fórmula geral do score de anomalia:

$$\text{score}(x_t) = -\log P(x_t \mid \theta)$$

onde θ são os parâmetros do modelo estatístico.

Exemplo com histograma



Bins raros → baixa frequência → alta anomalia

$$score(x_t) = \frac{1}{freq(bin(x_t))}$$

ENTRADA: série $X = x_1, \dots, x_n$, número de bins B , limiar τ

PRÉ-CONDIÇÃO: X_{treino} representa comportamento típico

PASSO 1 — Construir histograma H com B bins sobre X_{treino}

PASSO 2 — Para cada bin b :

$$freq(b) \leftarrow contagem(b) / |X_{treino}|$$

PASSO 3 — Para cada instante t **no** teste:

$$b \leftarrow bin(x_t)$$

$$score(x_t) \leftarrow 1 / freq(b) \text{ [ou } \infty \text{ se } freq(b) = 0]$$

PASSO 4 — Marcar x_t como anômalo se $score(x_t) > \tau$

SAÍDA: instantes anômalos A

PÓS-CONDIÇÃO: bins com $freq = 0$ são sempre anômalos

Métodos espectrais

- Projetam os dados em um espaço de menor dimensão.
- A estrutura principal da série deve ser preservada na projeção.
- Anomalias aparecem como observações mal representadas ou mal reconstruídas.
- Exemplos: PCA, SVD, autoencoder linear — cada um define uma forma diferente de projeção e reconstrução.

Erro de reconstrução como score de anomalia:

$$score(x_t) = \|x_t - P \cdot P^\top \cdot x_t\|^2$$

onde **P** são os componentes principais retidos.

Autoencoder: arquitetura


Função de perda de treinamento:

$$L = \|x - AE(x)\|^2 = \|x - D(E(x))\|^2$$


onde **E** é o encoder e **D** é o decoder.

- O encoder comprime x em uma representação latente $z = E(x)$ de dimensão menor.
- O decoder reconstrói $\hat{x} = D(z)$; a diferença $\|x - \hat{x}\|^2$ é o erro de reconstrução.

A forma de ampulheta força a rede a aprender uma representação compacta dos padrões típicos.



Autoencoder: erro de reconstrução



Sequências mal reconstruídas produzem erro alto e são marcadas como anômalas.

$$\text{score}(x_t) = \|x_t - AE(x_t)\|^2$$

ENTRADA: série $X = x_1, \dots, x_n$, janela p , limiar τ

PRÉ-CONDIÇÃO: AE treinado apenas com dados típicos (X_{treino})

PASSO 1 — Treinar AE em X_{treino} minimizando $\|x - AE(x)\|^2$

PASSO 2 — Para cada janela $x_t = x_{t-p}, \dots, x_t$ no teste:

$$\hat{x}_t \leftarrow AE(x_t)$$

$$\text{score}(x_t) \leftarrow \|x_t - \hat{x}_t\|^2$$

PASSO 3 — Calcular τ a partir dos escores de treino

(ex.: percentil 95 ou gaussiano)

PASSO 4 — Marcar x_t como anômalo se $\text{score}(x_t) > \tau$

SAÍDA: instantes anômalos A

PÓS-CONDIÇÃO: AE não deve ter visto anomalias no treino

Teoria da informação

Anomalias são raras e aumentam a informação ou a entropia da amostra.

A pergunta passa a ser: que subconjunto muda mais a informação da série?

Compressão e complexidade de Kolmogorov podem servir como aproximações práticas.

buscar $A \subset S$ que maximize $|I(S) - I(S - A)|$

Limitação

- Complexidade de Kolmogorov é incomputável; na prática usa-se compressão (gzip, LZ77) como aproximação.

Aplicação

- Útil para detectar anomalias sequenciais onde a estrutura interna da subsequência muda.

Anomalias de volatilidade

A anomalia não está necessariamente no nível da série, mas em sua variabilidade.

ARCH e GARCH modelam a volatilidade instantânea.

Esse caso é central em risco financeiro e em séries com variação não linear.

Anomalia de nível: x_t foge da média esperada.

Anomalia de volatilidade: σ_t foge do padrão de variância esperado.

- ARCH modela a variância como função dos resíduos passados; GARCH adiciona a variância passada como preditor.

Volatilidade anômala: formalização

A característica temporal passa a ser a volatilidade $v(xt)$.

O evento ocorre quando a volatilidade foge do esperado antes e depois de t .

$$va(X,k,\sigma) = \{t : |v(xt) - ep(v(xt),k)| > \sigma \wedge |v(xt) - ef(v(xt),k)| > \sigma\}$$

Parâmetros

k

Tamanho da janela de contexto passado e futuro

σ

Limiar de desvio para caracterizar a anomalia

$ep(v(xt),k)$


Volatilidade esperada nos k instantes anteriores a t

$ef(v(xt),k)$

Volatilidade esperada nos k instantes posteriores a t

- A condição bilateral (passado **E** futuro) reduz falsos positivos em transições de regime.

Exemplo com GARCH



Picos de volatilidade fora do intervalo de confiança do GARCH são marcados como anômalos.

Modelo GARCH:

$$\sigma_t^2 = \alpha_0 + \alpha_1 \cdot \varepsilon_{t-1}^2 + \beta_1 \cdot \sigma_{t-1}^2$$

Anomalia: $|\varepsilon_t| > k \cdot \sigma_t$

ENTRADA: série $X = x_1, \dots, x_n$, ordens (p, q) do GARCH, fator k

PRÉ-CONDIÇÃO: série com heterocedasticidade condicional
(teste ARCH significativo)

PASSO 1 — Ajustar GARCH(p, q) em X_{treino}

→ parâmetros α, β

PASSO 2 — Para cada instante t no teste:

$$\sigma_t^2 \leftarrow \alpha_0 + \sum \alpha_i \cdot \varepsilon_{t-i}^2 + \sum \beta_j \cdot \sigma_{t-j}^2$$

$$\varepsilon_t \leftarrow x_t - \mu_t \quad [\text{resíduo da média}]$$

PASSO 3 — Calcular volatilidade normalizada:

$$z_t \leftarrow \varepsilon_t / \sigma_t$$

PASSO 4 — Marcar t como anômalo se $|z_t| > k$

[ex.: $k = 3$]

SAÍDA: instantes anômalos A com volatilidade extrema


PÓS-CONDIÇÃO: resíduos padronizados z_t devem ser
i.i.d. no treino

Valores extremos

Valores extremos são raros, mas relevantes para decisão.

A distribuição completa pode ser inadequada para modelar apenas a cauda.

A teoria de valores extremos trata os extremos como um processo próprio.



$$M_n = \max\{x_1, x_2, \dots, x_n\}$$




Teorema de Fisher-Tippett-Gnedenko:

- O máximo normalizado M_n converge para uma das três distribuições de valor extremo: **Gumbel** ($\xi = 0$), **Fréchet** ($\xi > 0$) ou **Weibull** ($\xi < 0$), dependendo da cauda da distribuição original.
- Na prática, usa-se a distribuição **GEV (Generalized Extreme Value)** que unifica os três casos.

Exemplo:

Extração de valores extremos por Peak over Threshold em dados de precipitação de 2019 a 2022.

Referências Bibliográficas



Event Detection in Time Series

Ogasawara, E.; Salles, R.; Porto, F.;
Pacitti, E. Springer Nature Switzerland,
2025.

Time Series Analysis: With Applications in R

Cryer, J. D.; Chan, K.-S. Springer, 2008.

Data Mining: Concepts and Techniques

Han, J.; Pei, J.; Tong, H. Morgan
Kaufmann, 4^a ed., 2022.