Detecção de Anomalias em Séries Temporais: Métodos e Limiares

CEFET/RJ

Eduardo Ogasawara

eogasawara@cefet-rj.br | https://eic.cefet-rj.br/~eogasawara

Anomalia não é apenas sujeira nos dados

Em **outlier analysis**, o valor extremo costuma ser tratado como ruído a remover.

Em **anomaly detection**, o valor atípico é o **objeto de interesse**.

Exemplos em que a anomalia carrega informação:

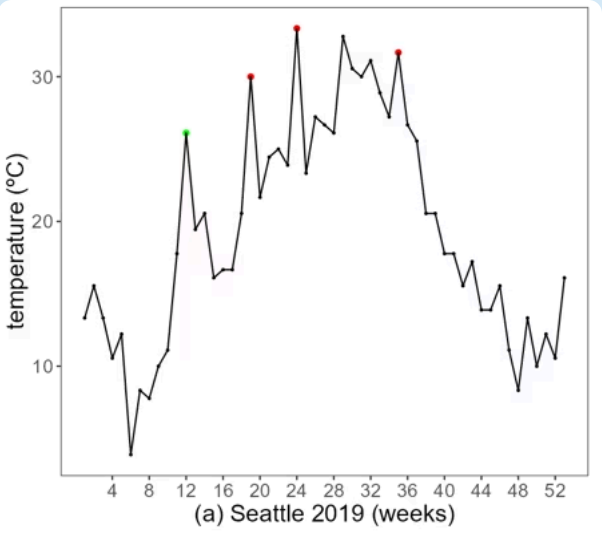
- Fraudes
- Falhas de sistema
- Surtos epidemiológicos
- Incidentes de segurança
- Eventos raros

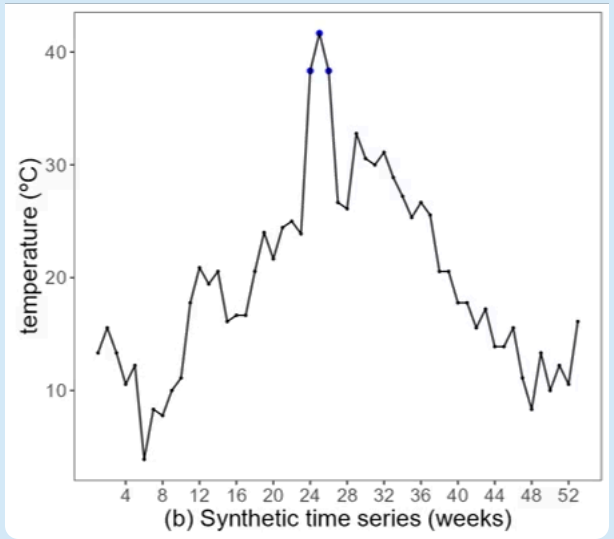
> Formalização mínima: uma anomalia é um evento raro $a \in S$ tal que $P(a)$ é baixa e a informação de a é alta — isto é, $I(a) = -\log P(a) \gg 0$.

Taxonomia de anomalias

- **Tipo:** pontual ou sequencial
- **Circunstância:** contextual ou fora de contexto
- **Dimensão:** univariada ou multivariada
- **Interpretação:** supervisionada, semissupervisionada ou não supervisionada
- **Forma:** como o detector opera (regressão, classificação, agrupamento...)

A taxonomia organiza tipo, circunstância, dimensão, interpretação e forma de aprendizado.





Anomalias pontuais e sequenciais

Anomalias pontuais

- Uma única observação difere significativamente do restante da série.
- A decisão depende do contexto local e do modelo do comportamento típico.
- É a forma mais direta de anomalia, mas não necessariamente a mais fácil de detectar.

Anomalias sequenciais

- Uma subsequência inteira apresenta comportamento incomum.
- O ponto isolado pode parecer aceitável, mas a sequência completa revela o evento.
- Exige comparar janelas, formas ou representações temporais.

Exemplo com temperatura semanal: anomalia pontual no painel (a) e sequência anômala no painel (b).

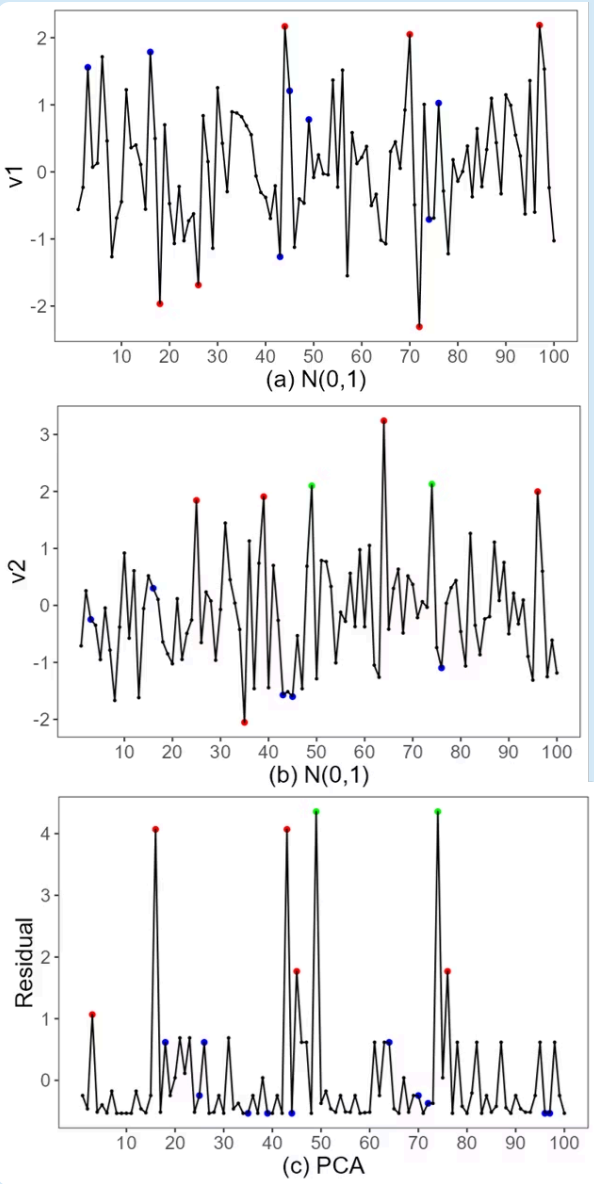
Anomalias contextuais e fora de contexto

Contextuais

- A observação não é estranha por si só.
- Ela se torna anômala quando considerada no contexto temporal.
- Exemplo: 26°C pode ser comum no verão, mas anômalo no inverno.

Fora de contexto

- O valor é atípico independentemente do instante em que ocorre.
- A explicação não depende fortemente da vizinhança temporal.
- Esse caso se aproxima da noção clássica de outlier estatístico.



Univariada vs multivariada

Univariada

Uma variável é analisada ao longo do tempo.

A anomalia aparece como valor ou sequência atípica naquela série.

Métodos são mais simples e interpretáveis.

Multivariada

A anomalia pode surgir da combinação entre variáveis.

Cada variável isolada pode parecer normal.

Relações entre dimensões passam a importar.

Exemplo: anomalia multivariada com PCA

O exemplo mostra anomalias capturadas pela relação entre variáveis, não apenas por valores extremos individuais.

Séries rotuladas e não rotuladas

Rotuladas

Cada observação pode indicar presença ou ausência de anomalia.

Permite avaliação e aprendizado supervisionado.

Rótulos podem ser incompletos ou temporalmente imprecisos.

Não rotuladas

Não há indicação direta do que é anomalia.

A detecção depende de hipótese estatística, distância ou raridade.

É o caso mais comum em aplicações reais.

Cenários de aprendizado

Supervisionado

- Usa observações com rótulos de típico/anômalo.
- A anomalia é tratada como classe a ser prevista.
- O problema central é a escassez e a imperfeição dos rótulos.

Semissupervisionado

- Treina o modelo apenas com dados típicos.
- Novas observações são anômalas quando não se ajustam ao padrão aprendido.
- É comum quando a classe anômala é rara ou difícil de rotular.

Não supervisionado

- Não requer rótulos para treinamento.
- Assume que observações típicas são mais frequentes ou mais densas.
- É flexível, mas exige cuidado maior na interpretação dos alertas.

Quando usar cada cenário de aprendizado

Mais rótulos

- Supervisionado quando os rótulos são confiáveis.
- Útil em operação online depois de uma fase de treinamento.
- Permite otimizar métricas como F1.

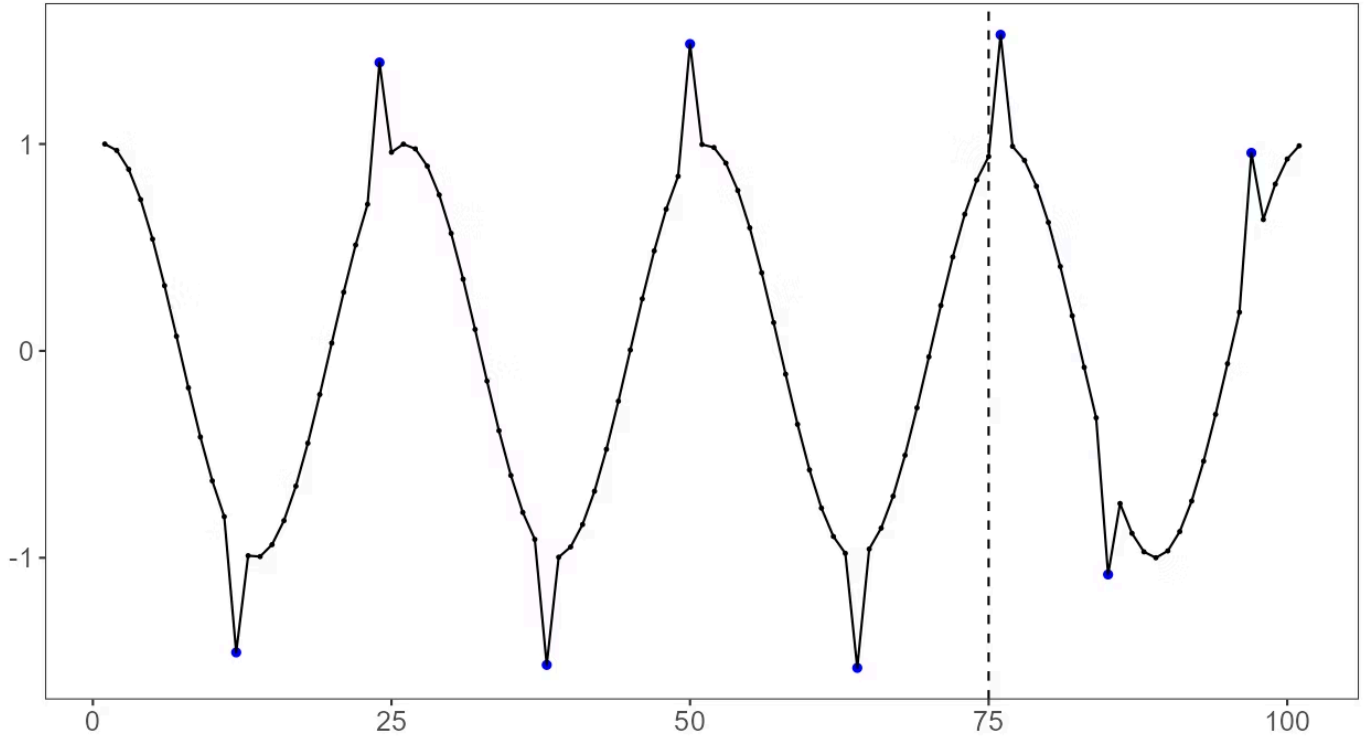
Menos rótulos

- Semissupervisionado quando há exemplos típicos confiáveis.
- Não supervisionado quando quase não há rótulo.
- Exige análise posterior dos alarmes.

Exemplo-base para comparar métodos

A mesma série é usada para contrastar famílias de detectores.

O objetivo é entender a hipótese operacional de cada família, não ranquear algoritmos.



Série sintética do Harbinger: região de treinamento e teste permitem comparar famílias de detectores.

Janela deslizante: transformar tempo em atributos

Uma **janela de tamanho p** usa observações passadas como atributos.

O **alvo** é a próxima observação da série.

A cada instante, a janela avança uma posição e produz outro exemplo de treino ou teste.

> $x_{t-p}, \ldots, x_{t-2}, x_{t-1} \quad x_t$

ENTRADA: série $X = x_1, \ldots, x_n$, tamanho de janela p
PRÉ-CONDIÇÃO: $n > p$

PASSO 1 — Para t de $p+1$ até n:
  atributos ← $x_{t-p}, \ldots, x_{t-1}$
  alvo ← x_t
  adicionar (atributos, alvo) ao conjunto D
PASSO 2 — Dividir D em:
  Dtreino (instantes anteriores)
  Dteste (instantes posteriores)
  preservando ordem temporal

SAÍDA: Dtreino e Dteste prontos
    para regressão supervisionada
PÓS-CONDIÇÃO: nenhum dado futuro vaza para o treino

Anomalias por Regressão

Ideia central

Um modelo aprende o comportamento esperado da série. A anomalia é o desvio entre o observado xt e o estimado x̂t.

> ωt = distance(xt, x̂t)

Janela deslizante

Observações passadas ⟨xt−p, ..., xt−1⟩ formam os atributos; xt é o alvo. A cada instante a janela avança uma posição.

> [xt−4, xt−3, xt−2, xt−1] → xt

Exemplo tabular

Com p = 5, uma linha do conjunto de treino contém quatro defasagens e um alvo. O cuidado é preservar ordem temporal: treino antes, teste depois.

Os termos defasados xt−4,...,xt−1 predizem xt; a diferença entre previsão e observação vira resíduo.



t	x_{t-4}	x_{t-3}	x_{t-2}	x_{t-1}	$\hat{x}_t$	x_t
5	v_1	v_2	v_3	v_4	$\hat{v}_5$	v_5
6	v_2	v_3	v_4	v_5	$\hat{v}_6$	v_6
7	v_3	v_4	v_5	v_6	$\hat{v}_7$	v_7
8	v_4	v_5	v_6	v_7	$\hat{v}_8$	v_8
9	v_5	v_6	v_7	v_8	$\hat{v}_9$	v_9
10	v_6	v_7	v_8	v_9	$\hat{v}_{10}$	v_{10}
11	v_7	v_8	v_9	v_{10}	$\hat{v}_{11}$	v_{11}
12	v_8	v_9	v_{10}	v_{11}	$\hat{v}_{12}$	v_{12}
13	v_9	v_{10}	v_{11}	v_{12}	$\hat{v}_{13}$	v_{13}
14	v_{10}	v_{11}	v_{12}	v_{13}	$\hat{v}_{14}$	v_{14}

(a)

Do erro ao escore de anomalia

Depois da previsão, calcula-se uma distância entre x_t e $\hat{x}_t$.

Esse valor é o **escore de desvio** do modelo.

Quanto maior o escore, maior a evidência de que o comportamento observado não foi esperado pelo modelo.

> **$\omega_t = \text{distance}(x_t, \hat{x}_t)$**

ENTRADA: série $X = [x_1, \ldots, x_n]$, modelo M treinado,
função $\text{distance}(\cdot,\cdot)$
PRÉ-CONDIÇÃO: M foi treinado apenas com dados típicos

PASSO 1 — Para cada instante t no teste:
$\hat{x}_t \leftarrow M.\text{prever}([x_{t-p}, \ldots, x_{t-1}])$
$\omega_t \leftarrow \text{distance}(x_t, \hat{x}_t)$
PASSO 2 — Construir série de escores
$W = [\omega_1, \ldots, \omega_n]$
PASSO 3 — Calcular limiar τ a partir de W
(gaussiano, boxplot ou EVT)
PASSO 4 — Marcar t como anômalo se $\omega_t > \tau$

SAÍDA: conjunto de instantes anômalos $A \subseteq \{1, \ldots, n\}$
PÓS-CONDIÇÃO: A contém apenas instantes do teste

Escolhas de distância

Erro absoluto

- Mantém a escala original da série.
- É fácil de explicar para o domínio.
- Menos agressivo com erros muito grandes.

Erro quadrático

- Amplifica erros grandes.
- É comum em regressão e otimização.
- Pode aumentar a sensibilidade a picos.

Como decidir o limiar

O modelo gera uma série de resíduos W = ⟨ω1, ..., ωn⟩. A detecção depende de separar resíduos típicos de resíduos extremos.

Limiar gaussiano

- Assume que os resíduos típicos seguem aproximadamente uma distribuição gaussiana.
- Simples, mas frágil quando a distribuição é assimétrica, multimodal ou não estacionária.

$$\omega_t > \text{média}(W) + 3 \cdot \text{sd}(W)$$

Limiar por boxplot

- Não exige assumir uma distribuição específica para os resíduos.
- Usa quartis e distância interquartil.
- No caso de regressão, normalmente interessa o limite superior dos erros.

$$\omega_t > Q3(W) + 1{,}5 \cdot IQR(W)$$

Teoria de valores extremos

- Modela especificamente a cauda da distribuição dos erros.
- Útil quando os eventos relevantes são raros e extremos.
- O limiar u é escolhido pelo método POT (Peaks Over Threshold).

$$P(\omega > u + y \mid \omega > u) \approx \left(1 + \frac{\xi \cdot y}{\beta}\right)^{-1/\xi}$$

u: limiar de excedência; ξ: índice de cauda; β: escala

Seguidores de tendência

Modelos seguidores suavizam ou decompõem a série para estimar o comportamento esperado.

Exemplos: média móvel, splines, FFT, wavelet, EMD, REMD e FBIAD.

A anomalia aparece quando a observação se afasta da curva seguida pelo modelo.

> **Fórmula geral:** Uma anomalia é detectada quando
>
> $$|x_t - \hat{f}(t)| > \tau$$
>
> onde $\hat{f}(t)$ é a curva estimada pelo seguidor e τ é o limiar de detecção.

- **Limitação:** Seguidores suaves podem não capturar anomalias de curta duração, pois a suavização atenua desvios pontuais antes que eles superem o limiar.

Modelos estatísticos de regressão

ARIMA e regressão linear modelam a série com hipóteses estatísticas explícitas.

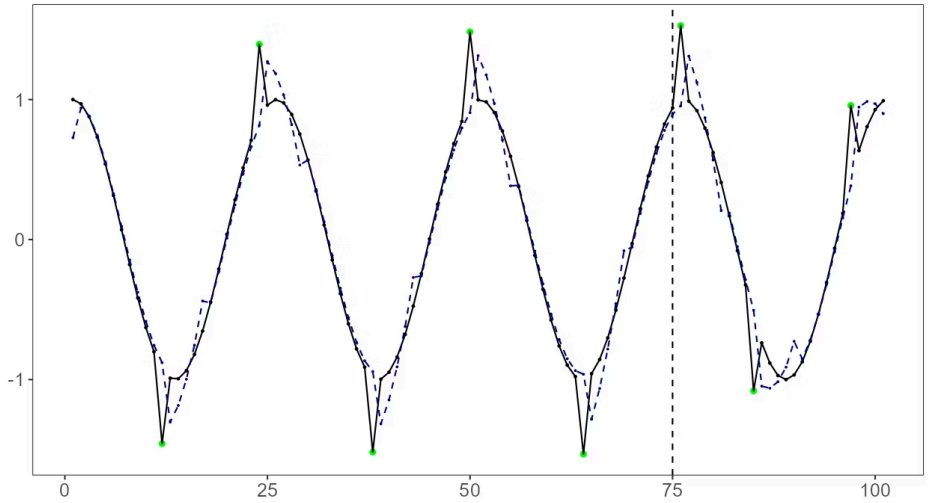
São bons quando há estrutura temporal interpretável, como autocorrelação, tendência ou sazonalidade.

A leitura do resíduo costuma ser direta: o que sobrou depois do modelo.

> **Distinção entre os modelos:**
>
> **ARIMA:** estrutura autorregressiva e de médias móveis — resíduo ε_t é ruído branco.
>
> **Regressão linear:** $x_t = \beta_0 + \beta_1 \cdot t + \ldots + \varepsilon_t$ — resíduo ε_t é o desvio da tendência.

- **Limitação:** Ambos assumem estacionariedade ou tendência linear; mudanças de regime podem gerar falsos positivos.

ARIMA como detector por desvio



O modelo ajustado estima a série; resíduos altos ao redor das anomalias sustentam a detecção.

Anomalia: $|\varepsilon_t| > \tau$

ENTRADA: série X = x1, ..., xn , ordens (p,d,q), limiar τ
PRÉ-CONDIÇÃO: série estacionária após d diferenciações

PASSO 1 — Ajustar ARIMA(p,d,q) em X_treino
PASSO 2 — Para cada instante t no teste:
  x̂t ← ARIMA.prever(t)
  εt ← xt − x̂t
PASSO 3 — Construir W = ε1, ..., εn
PASSO 4 — Calcular τ
  (gaussiano: média(W) + 3·sd(W))
PASSO 5 — Marcar t como anômalo se |εt| > τ

SAÍDA: instantes anômalos A
PÓS-CONDIÇÃO: resíduos de treino devem ser ruído branco

Regressores de aprendizado de máquina

A janela deslizante permite usar modelos supervisionados gerais.

Exemplos: KNN, SVM, Random Forest, XGBoost, MLP e ELM.

O detector continua sendo baseado no erro entre previsão e observação.

> **KNN e SVM:** baseados em distância/margem — bons para padrões locais.
>
> **Random Forest e XGBoost:** ensemble de árvores — capturam não-linearidades.
>
> **MLP e ELM:** redes neurais rasas — aproximadores universais.

⚠ **Cuidado:** Todos dependem da janela deslizante para transformar a série em atributos tabulares.

Regressores profundos

Conv1D e LSTM exploram padrões temporais em sequências.

DeepAnT usa redes convolucionais para prever a próxima janela e detectar desvios.

Telemanom e detectores LSTM usam erro de previsão para localizar comportamento inesperado.

⚠️ **Limitação:** Requerem mais dados de treino e são mais difíceis de interpretar que modelos estatísticos.

Conv1D: captura padrões locais via filtros convolucionais.

LSTM: captura dependências de longo prazo via memória recorrente.

DeepAnT: usa Conv1D para prever a próxima janela e compara com o observado.

Métodos recentes e híbridos

- Triple Exponential Smoothing incorpora nível, tendência e sazonalidade.
- Median Method usa a mediana da janela contextual como previsão robusta.
- Métodos híbridos e ensembles combinam modelos para reduzir fragilidades individuais.
- Transformers e modelos de fundação (ex.: Anomaly Transformer, PatchTST) aplicam atenção para capturar dependências de longo alcance.

⚠ Métodos mais complexos não garantem melhor detecção — a escolha deve considerar interpretabilidade, custo computacional e disponibilidade de dados rotulados.

O que muda entre os tipos de regressão

Muda o modelo esperado

ARIMA, média móvel, spline, RF, XGBoost, LSTM.

Cada um captura uma forma diferente de padrão temporal.

Modelo ruim gera resíduo ruim.

Permanece a lógica

Prever xt.

Calcular erro.

Comparar erro com uma referência de normalidade.

Muda o limiar

Gaussiano (paramétrico): assume distribuição normal dos resíduos.

Boxplot (não paramétrico): baseado em quartis, sem suposição de distribuição.

EVT (cauda): modela extremos raros com teoria de valores extremos.

Cuidados práticos

- A janela p controla quanta memória temporal o modelo recebe.
- Treinar com anomalias pode fazer o modelo aprender o evento como se fosse normal.
- Mudança de regime pode parecer anomalia para um modelo não adaptativo.
- Normalização e escala afetam diretamente o erro.
- Validação temporal: nunca use dados futuros para estimar o limiar — o limiar deve ser calculado apenas sobre o conjunto de treino.

> A qualidade do detector depende tanto do modelo de previsão quanto da estratégia de limiarização e da integridade da divisão treino/teste.

Classificação: anomalia como classe

- Um classificador aprende a separar observações típicas e anômalas.
- Durante o treinamento, os rótulos precisam estar disponíveis.
- Durante o teste, o modelo prediz o rótulo das novas observações.
- O desbalanceamento de classes é o principal desafio — anomalias são raras por definição.

> **Classificação binária:** típico (0) vs anômalo (1).
> **Classificação multiclasse:** tipo de anomalia como classe.
> **One-class classification:** treina apenas com dados típicos (ex.: One-Class SVM).

Janela deslizante

Na etapa de treino, a janela tem rótulo; na etapa de teste, o modelo prediz a presença de anomalia.

f_1

t	x_{t-4}	x_{t-3}	x_{t-2}	x_{t-1}	x_t	$\hat{e}_t$	e_t
5	v_1	v_2	v_3	v_4	v_5	$\hat{b}_5$	b_5
6	v_2	v_3	v_4	v_5	v_6	$\hat{b}_6$	b_6
7	v_3	v_4	v_5	v_6	v_7	$\hat{b}_7$	b_7
8	v_4	v_5	v_6	v_7	v_8	$\hat{b}_8$	b_8
9	v_5	v_6	v_7	v_8	v_9	$\hat{b}_9$	b_9
10	v_6	v_7	v_8	v_9	v_{10}	$\hat{b}_{10}$	b_{10}
11	v_7	v_8	v_9	v_{10}	v_{11}	$\hat{b}_{11}$	b_{11}
12	v_8	v_9	v_{10}	v_{11}	v_{12}	$\hat{b}_{12}$	b_{12}

(a)

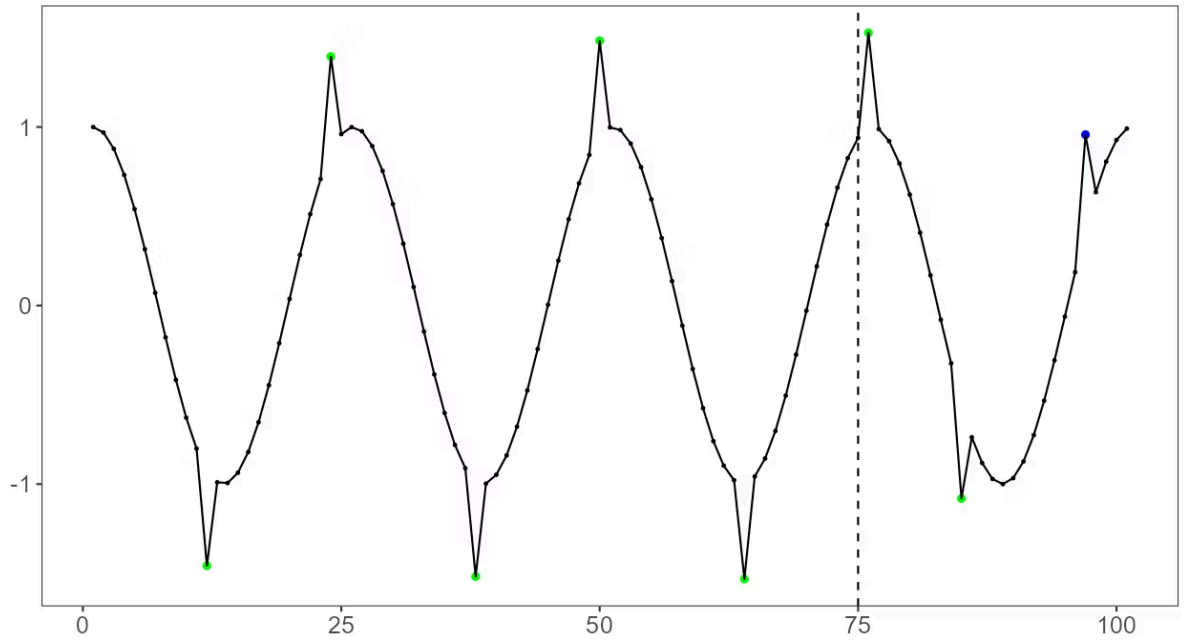
t	x_{t-4}	x_{t-3}	x_{t-2}	x_{t-1}	x_t	$\hat{e}_t$
13	v_9	v_{10}	v_{11}	v_{12}	v_{13}	$\hat{b}_{13}$
14	v_{10}	v_{11}	v_{12}	v_{13}	v_{14}	$\hat{b}_{14}$

(b)

Exemplo com SVM

Desafio da classificação

- Anomalias são raras, gerando forte desbalanceamento de classes.
- Rótulos humanos podem perder eventos ou marcar o instante com atraso.
- A classe aprendida pode não representar anomalias futuras ainda não vistas.



O SVM detecta parte das anomalias no teste; o exemplo também evidencia falso negativo.

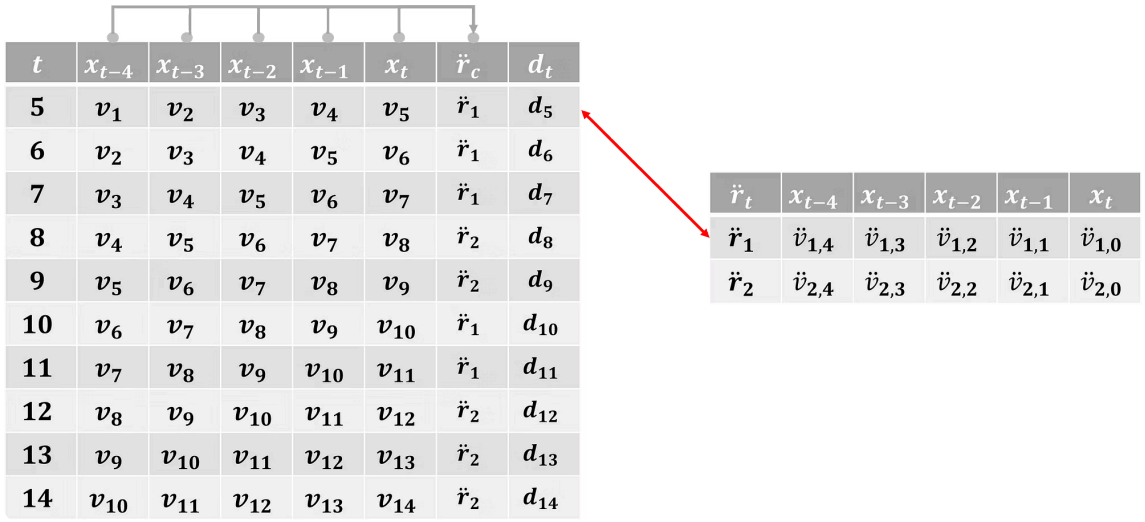
Agrupamento: anomalia como distância

- Observações típicas formam grupos ou regiões densas.
- Anomalias aparecem longe dos representantes ou fora dos grupos.
- A abordagem é naturalmente não supervisionada.
- Exemplos: K-Means (centróides), DBSCAN (densidade), LOF (fator de outlier local).

Fórmula geral do score de anomalia:

$$\text{score}(x_t) = \min_k \text{dist}(x_t, c_k)$$

onde *ck* são os representantes (centróides) dos clusters.



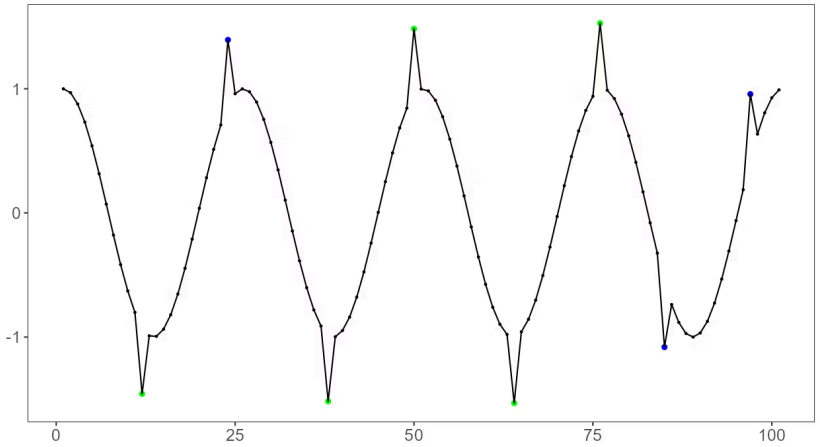
t	x_{t-4}	x_{t-3}	x_{t-2}	x_{t-1}	x_t	$\ddot{r}_c$	d_t
5	v_1	v_2	v_3	v_4	v_5	$\ddot{r}_1$	d_5
6	v_2	v_3	v_4	v_5	v_6	$\ddot{r}_1$	d_6
7	v_3	v_4	v_5	v_6	v_7	$\ddot{r}_1$	d_7
8	v_4	v_5	v_6	v_7	v_8	$\ddot{r}_2$	d_8
9	v_5	v_6	v_7	v_8	v_9	$\ddot{r}_2$	d_9
10	v_6	v_7	v_8	v_9	v_{10}	$\ddot{r}_1$	d_{10}
11	v_7	v_8	v_9	v_{10}	v_{11}	$\ddot{r}_1$	d_{11}
12	v_8	v_9	v_{10}	v_{11}	v_{12}	$\ddot{r}_2$	d_{12}
13	v_9	v_{10}	v_{11}	v_{12}	v_{13}	$\ddot{r}_2$	d_{13}
14	v_{10}	v_{11}	v_{12}	v_{13}	v_{14}	$\ddot{r}_2$	d_{14}

$\ddot{r}_t$	x_{t-4}	x_{t-3}	x_{t-2}	x_{t-1}	x_t
$\ddot{r}_1$	$\ddot{v}_{1,4}$	$\ddot{v}_{1,3}$	$\ddot{v}_{1,2}$	$\ddot{v}_{1,1}$	$\ddot{v}_{1,0}$
$\ddot{r}_2$	$\ddot{v}_{2,4}$	$\ddot{v}_{2,3}$	$\ddot{v}_{2,2}$	$\ddot{v}_{2,1}$	$\ddot{v}_{2,0}$

Janela deslizante

Cada janela é associada a um grupo; a distância ao representante apoia a detecção.

Exemplo com K-Means



Sequências distantes dos centróides são marcadas como anômalas.

$$\text{score}(x_t) = \min_k \text{dist}(x_t, c_k)$$

ENTRADA: série X = x1, ..., xn , número de clusters k, limiar τ
PRÉ-CONDIÇÃO: janela deslizante já aplicada;
Xtreino representa comportamento típico

PASSO 1 — Aplicar K-Means(k) sobre Xtreino
→ centróides C = {c1, ..., ck}
PASSO 2 — Para cada instante t no teste:
score(xt) ← min_{j=1..k} dist(xt, cj)
PASSO 3 — Calcular τ a partir dos escores de treino
(ex.: percentil 95)
PASSO 4 — Marcar xt como anômalo se score(xt) > τ

SAÍDA: instantes anômalos A
PÓS-CONDIÇÃO: k e a métrica de distância devem ser
validados no domínio

Limitações do agrupamento

- A escolha de k e da métrica de distância afeta diretamente a detecção.
- Escala e normalização podem mudar quais pontos parecem distantes.
- Dados com anomalias no treinamento podem formar grupos espúrios.

Métodos estatísticos

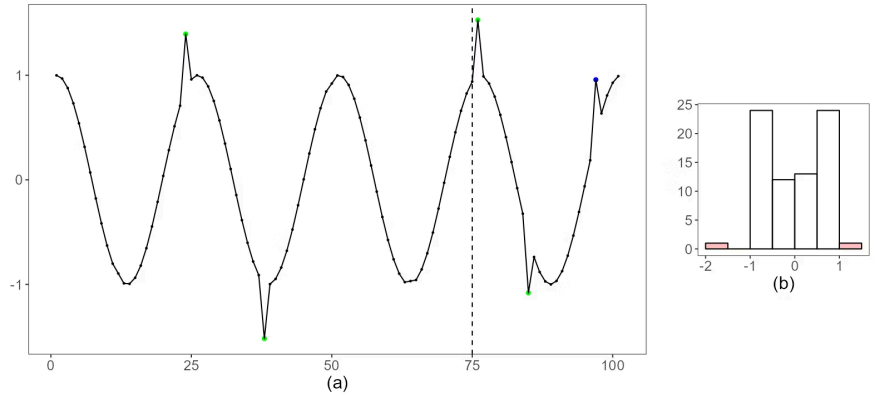
- Assumem que observações típicas ocupam regiões de alta probabilidade.
- Anomalias aparecem em regiões de baixa probabilidade.
- Podem usar modelos paramétricos, testes de hipótese ou perfis não paramétricos.
- Exemplos: histograma (não paramétrico), KDE (kernel density estimation), distribuição gaussiana (paramétrico), mistura de gaussianas (GMM).

Fórmula geral do score de anomalia:

$$\text{score}(x_t) = -\log P(x_t \mid \theta)$$

onde θ são os parâmetros do modelo estatístico.

Exemplo com histograma



Bins raros → baixa frequência → alta anomalia

$$score(x_t) = \frac{1}{freq(bin(x_t))}$$

ENTRADA: série X = x1, ..., xn , número de bins B, limiar τ
PRÉ-CONDIÇÃO: Xtreino representa comportamento típico

PASSO 1 — Construir histograma H com B bins sobre Xtreino
PASSO 2 — Para cada bin b:
freq(b) ← contagem(b) / |Xtreino|
PASSO 3 — Para cada instante t no teste:
b ← bin(xt)
score(xt) ← 1 / freq(b) [ou ∞ se freq(b) = 0]
PASSO 4 — Marcar xt como anômalo se score(xt) > τ

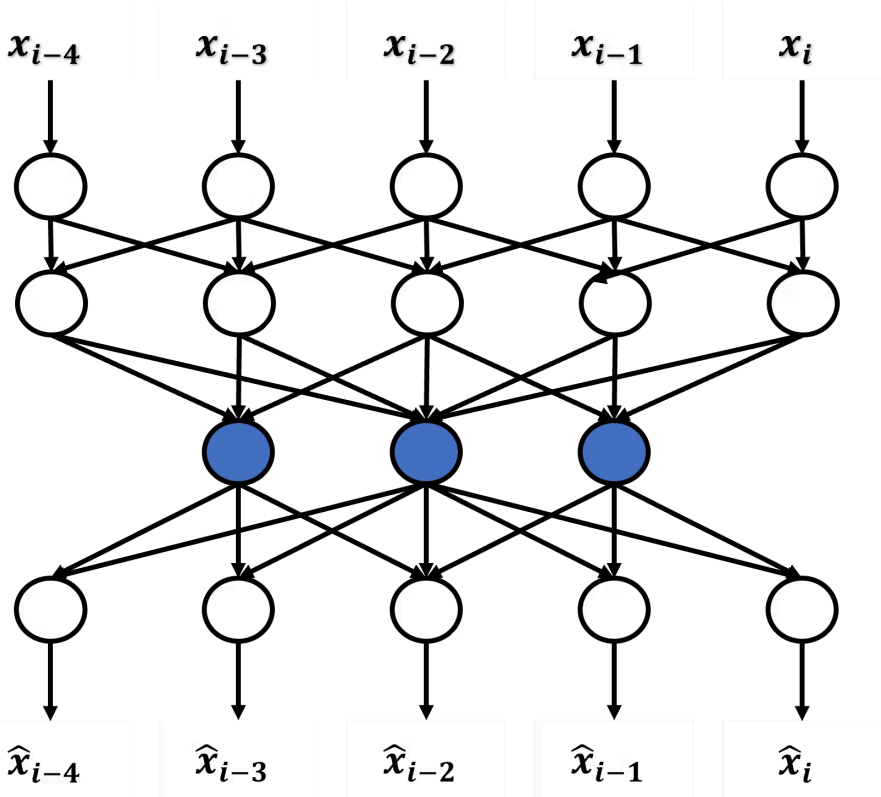
SAÍDA: instantes anômalos A
PÓS-CONDIÇÃO: bins com freq = 0 são sempre anômalos

Métodos espectrais

- Projetam os dados em um espaço de menor dimensão.
- A estrutura principal da série deve ser preservada na projeção.
- Anomalias aparecem como observações mal representadas ou mal reconstruídas.
- Exemplos: PCA, SVD, autoencoder linear — cada um define uma forma diferente de projeção e reconstrução.

> Erro de reconstrução como score de anomalia:
>
> $$score(x_t) = \|x_t - P \cdot P^\top \cdot x_t\|^2$$
>
> onde **P** são os componentes principais retidos.

Autoencoder: arquitetura



Função de perda de treinamento:

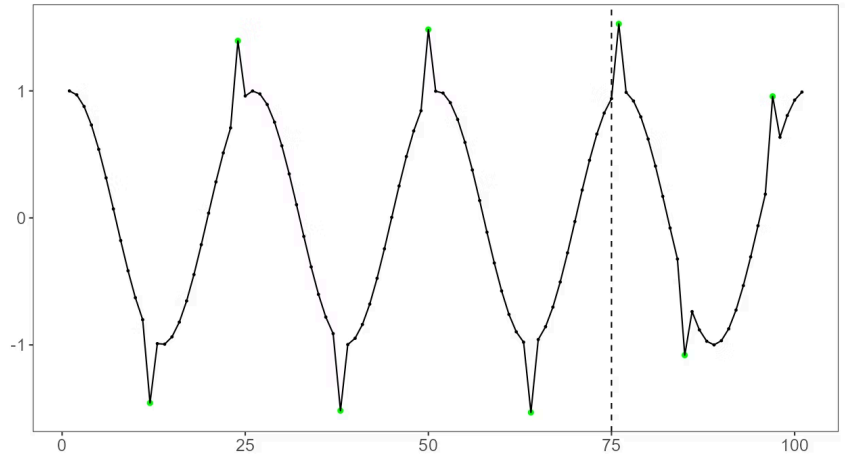
$$L = \|x - AE(x)\|^2 = \|x - D(E(x))\|^2$$

> onde **E** é o encoder e **D** é o decoder.

- O encoder comprime x em uma representação latente $z = E(x)$ de dimensão menor.
- O decoder reconstrói $\hat{x} = D(z)$; a diferença $\|x - \hat{x}\|^2$ é o erro de reconstrução.

A forma de ampulheta força a rede a aprender uma representação compacta dos padrões típicos.

Autoencoder: erro de reconstrução



Sequências mal reconstruídas produzem erro alto e são marcadas como anômalas.

$$score(x_t) = \|x_t - AE(x_t)\|^2$$

ENTRADA: série X = x1, ..., xn , janela p, limiar τ

PRÉ-CONDIÇÃO: AE treinado apenas com dados típicos (Xtreino)

PASSO 1 — Treinar AE em Xtreino minimizando $||x - AE(x)||^2$

PASSO 2 — Para cada janela xt = xt−p, ..., xt no teste:

$\hat{x}t \leftarrow AE(xt)$

$score(xt) \leftarrow ||xt - \hat{x}t||^2$

PASSO 3 — Calcular τ a partir dos escores de treino

(ex.: percentil 95 ou gaussiano)

PASSO 4 — Marcar xt como anômalo se score(xt) > τ

SAÍDA: instantes anômalos A

PÓS-CONDIÇÃO: AE não deve ter visto anomalias no treino

Teoria da informação

Anomalias são raras e aumentam a informação ou a entropia da amostra.

A pergunta passa a ser: que subconjunto muda mais a informação da série?

Compressão e complexidade de Kolmogorov podem servir como aproximações práticas.

> buscar $A \subset S$ que maximize $|I(S) - I(S - A)|$

⚠️ Limitação

- Complexidade de Kolmogorov é incomputável; na prática usa-se compressão (`gzip`, `LZ77`) como aproximação.

✅ Aplicação

- Útil para detectar anomalias sequenciais onde a estrutura interna da subsequência muda.

Anomalias de volatilidade

A anomalia não está necessariamente no nível da série, mas em sua variabilidade.

ARCH e GARCH modelam a volatilidade instantânea.

Esse caso é central em risco financeiro e em séries com variação não linear.

> **Anomalia de nível:** x_t foge da média esperada.
>
> **Anomalia de volatilidade:** σ_t foge do padrão de variância esperado.

- ARCH modela a variância como função dos resíduos passados; GARCH adiciona a variância passada como preditor.

Volatilidade anômala: formalização

A característica temporal passa a ser a volatilidade v(xt).

O evento ocorre quando a volatilidade foge do esperado antes e depois de t.

$$va(X,k,\sigma) = \{t : |v(xt)-ep(v(xt),k)|>\sigma \wedge |v(xt)-ef(v(xt),k)|>\sigma\}$$

Parâmetros

k

Tamanho da janela de contexto passado e futuro

σ

Limiar de desvio para caracterizar a anomalia

ep(v(xt),k)

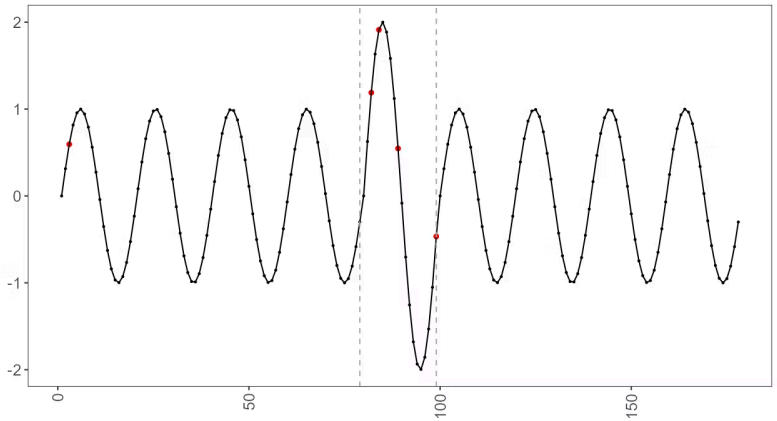
Volatilidade esperada nos *k* instantes anteriores a t

ef(v(xt),k)

Volatilidade esperada nos *k* instantes posteriores a t

- A condição bilateral (passado **E** futuro) reduz falsos positivos em transições de regime.

Exemplo com GARCH



Picos de volatilidade fora do intervalo de confiança do GARCH são marcados como anômalos.

Modelo GARCH:

$$\sigma_t^2 = \alpha_0 + \alpha_1 \cdot \varepsilon_{t-1}^2 + \beta_1 \cdot \sigma_{t-1}^2$$

Anomalia: $|\varepsilon_t| > k \cdot \sigma_t$

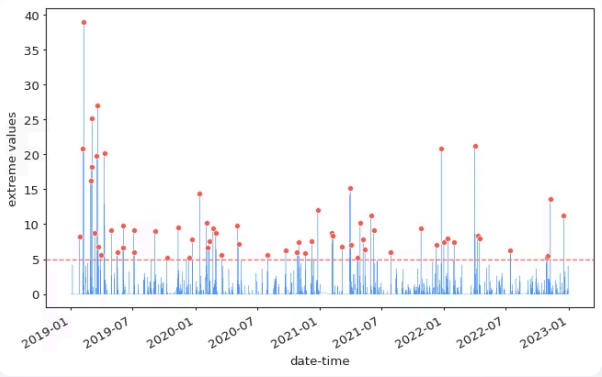
ENTRADA: série X = x1, ..., xn , ordens (p,q) do GARCH, fator k
PRÉ-CONDIÇÃO: série com heterocedasticidade condicional
(teste ARCH significativo)

PASSO 1 — Ajustar GARCH(p,q) em X_treino
→ parâmetros α, β
PASSO 2 — Para cada instante t no teste:
$\sigma^2 t \leftarrow \alpha 0 + \Sigma\, \alpha i \cdot \varepsilon^2 t{-}i + \Sigma\, \beta j \cdot \sigma^2 t{-}j$
$\varepsilon t \leftarrow xt - \mu t$ [resíduo da média]
PASSO 3 — Calcular volatilidade normalizada:
$zt \leftarrow \varepsilon t / \sigma t$
PASSO 4 — Marcar t como anômalo se $|zt| > k$
[ex.: k = 3]

SAÍDA: instantes anômalos A com volatilidade extrema

PÓS-CONDIÇÃO: resíduos padronizados zt devem ser
i.i.d. no treino

Valores extremos



Valores extremos são raros, mas relevantes para decisão.

A distribuição completa pode ser inadequada para modelar apenas a cauda.

A teoria de valores extremos trata os extremos como um processo próprio.

$$\mathbf{Mn = max\{x1, x2, ..., xn\}}$$

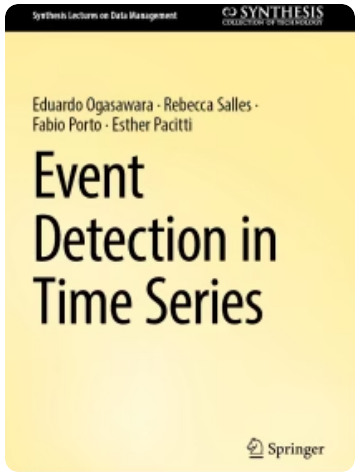
Teorema de Fisher-Tippett-Gnedenko:

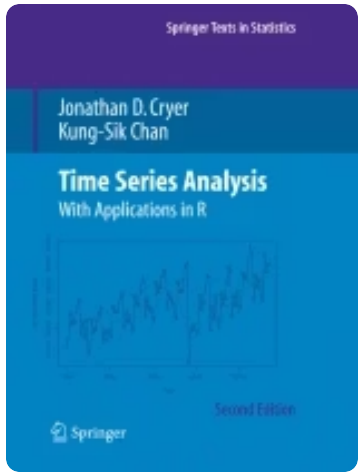
- O máximo normalizado M_n converge para uma das três distribuições de valor extremo: **Gumbel** ($\xi = 0$), **Fréchet** ($\xi > 0$) ou **Weibull** ($\xi < 0$), dependendo da cauda da distribuição original.
- Na prática, usa-se a distribuição **GEV (Generalized Extreme Value)** que unifica os três casos.

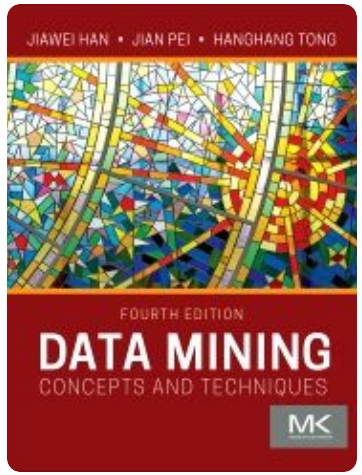
Exemplo:

Extração de valores extremos por Peak over Threshold em dados de precipitação de 2019 a 2022.

Referências Bibliográficas







Event Detection in Time Series

Ogasawara, E.; Salles, R.; Porto, F.; Pacitti, E. Springer Nature Switzerland, 2025.

Time Series Analysis: With Applications in R

Cryer, J. D.; Chan, K.-S. Springer, 2008.

Data Mining: Concepts and Techniques

Han, J.; Pei, J.; Tong, H. Morgan Kaufmann, 4ª ed., 2022.