CEFET/RJ

Avaliação de Métodos de Detecção

Eduardo Ogasawara
eduardo.ogasawara@cefet-rj.br
https://eic.cefet-rj.br/~eogasawara

Por que Avaliar?

- Avaliar a qualidade dos métodos de detecção é essencial.
- • Permite comparar diferentes abordagens de forma objetiva.
- • Fundamental para aplicações críticas e sensíveis a erro.

Matriz de confusão

- A matriz de confusão organiza os acertos e erros de um método em quatro categorias:
  - Verdadeiros Positivos (VP)
  - Falsos Positivos (FP)
  - Verdadeiros Negativos (VN)
  - Falsos Negativos (FN)
- A base para cálculo de métricas como precisão, revocação e F1

		Detected events		
		yes	no	Total
Known events	yes	TP	FN	P
	no	FP	TN	N
	Total	P'	N'	$P + N$

Métricas Clássicas

- Precisão: proporção de verdadeiros positivos entre os detectados.
- Revocação: proporção de verdadeiros positivos entre os eventos reais
- F1-Score: harmônica entre precisão e revocação

Metric	Formula
accuracy, recognition rate	$\frac{TP+TN}{P+N}$
error rate, misclassification rate	$\frac{FP+FN}{P+N}$
precision	$\frac{TP}{TP+FP}$
recall, sensitivity, true positive rate	$\frac{TP}{P}$
F_1, F-score, harmonic mean of precision and recall	$\frac{2 \times precision \times recall}{precision + recall}$
specificity, true negative rate	$\frac{TN}{N}$
fallout, false positive rate	$\frac{FP}{N}$
F_β, where β is a non-negative real number	$\frac{(1+\beta^2) \times precision \times recall}{beta^2 \times precision + recall}$

Curva ROC e AUC

- A curva ROC representa a relação entre taxa de verdadeiros positivos e taxa de falsos positivos em diferentes limiares.
- A área sob a curva (AUC) indica a capacidade de separação do classificador. Quanto maior a AUC, melhor o desempenho.

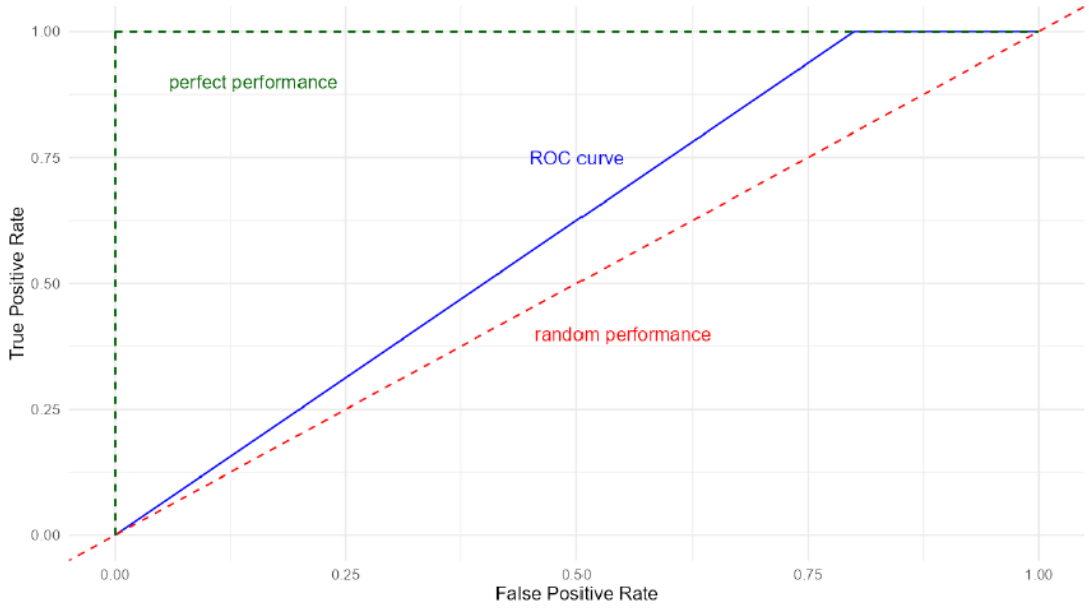

Tolerância Temporal

- Métodos de pontuação tradicionais, como precisão e revocação, não são suficientes para avaliar o desempenho da detecção de eventos online
- Eles não incorporam o tempo e não recompensam a detecções próximas
  - Verdadeiros positivos são recompensados
- Todos os outros resultados são "severamente" e igualmente punidos

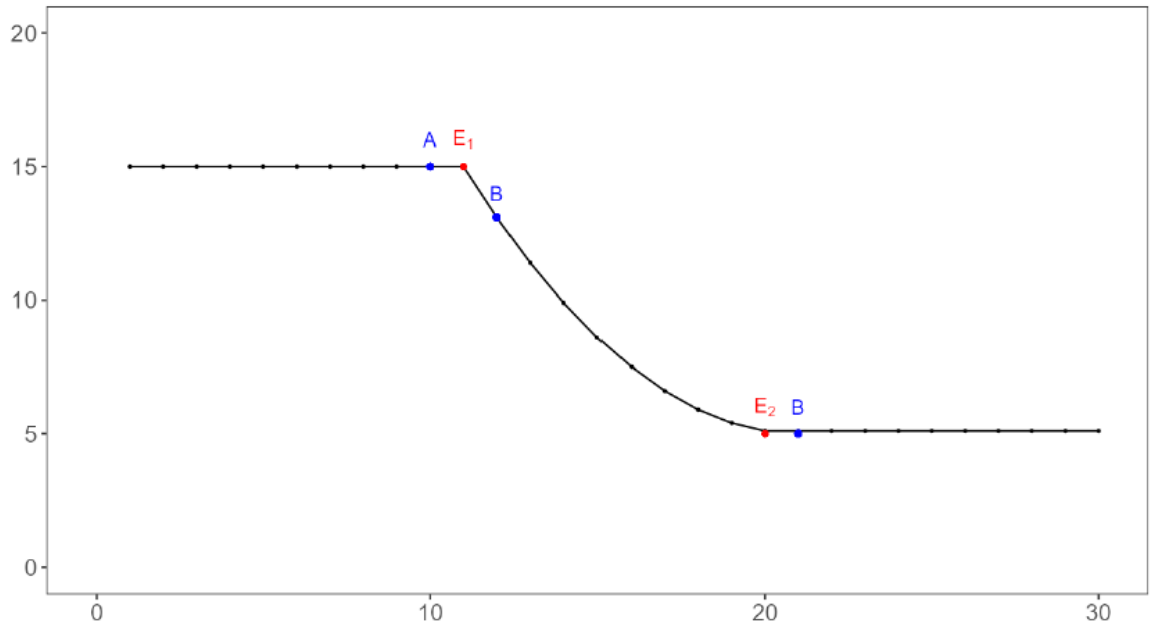

Fig. 6.2 Example regarding the problem of evaluating the detection of events at time 11 (E_1) and 20 (E_2). Method A and B detect an event at times 10 and 12 concerning E_1. Method B was the only method that detected an event close to E_2.

Avaliação contínua em fluxo de dados

- Em ambientes de detecção online, a avaliação também deve ser feita em tempo real:
  - Monitoramento contínuo da precisão, F1, revocação
  - Avaliação com janelas deslizantes (ex: últimos N eventos)
  - Detecção de queda de desempenho ao longo do tempo (ex: por drift)
  - Essencial para adaptação dinâmica de modelos

Outros Critérios Relevantes

- Latência de detecção.
- • Falsos positivos e falsos negativos.
- • Eficiência computacional (tempo e memória).
- • Generalização para diferentes domínios e séries.

Softed

- SoftED introduz uma avaliação mais realista para eventos em séries temporais:
  - Detection Consistency: mede a persistência e regularidade da detecção
  - Detection Mapping: avalia se o evento foi detectado de forma coerente ao longo do tempo
- Penaliza menos as pequenas imprecisões temporais, e mais a inconsistência

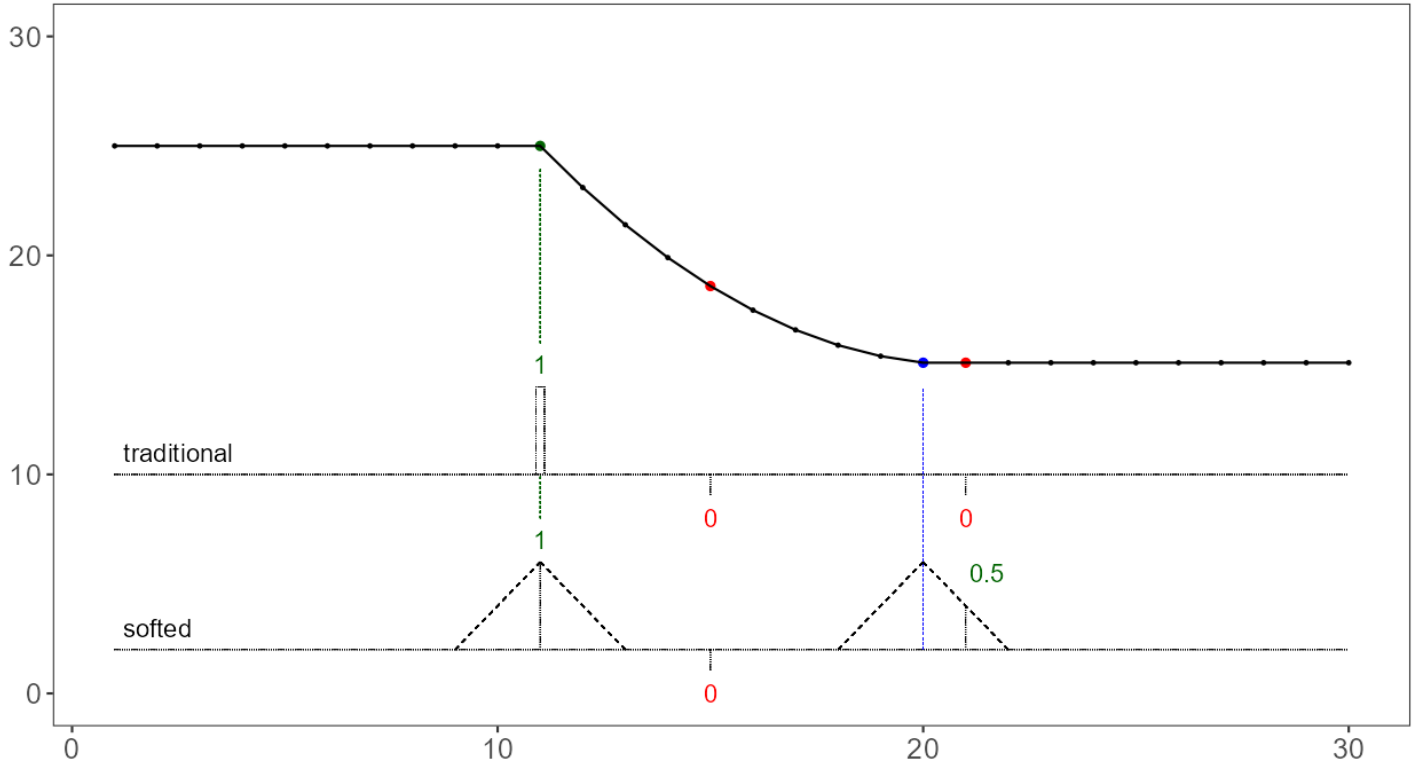

Resumo do Capítulo

- Avaliação é fundamental para validar a eficácia dos métodos
- Métricas clássicas (precisão, revocação, F1) são amplamente usadas
- Tolerância temporal torna a avaliação mais realista
- Também devem ser considerados aspectos como latência e eficiência

Referências

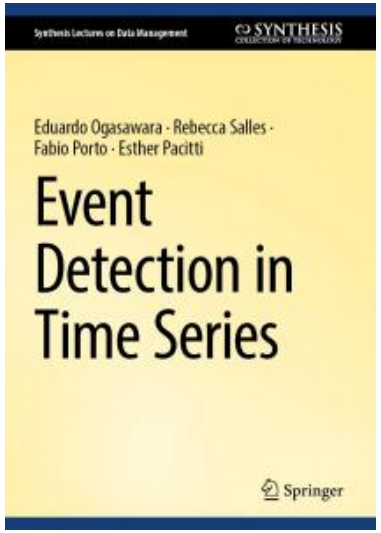

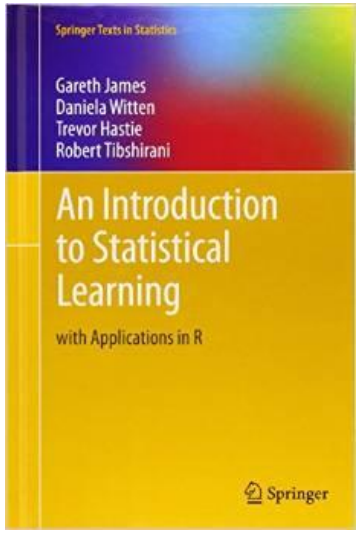

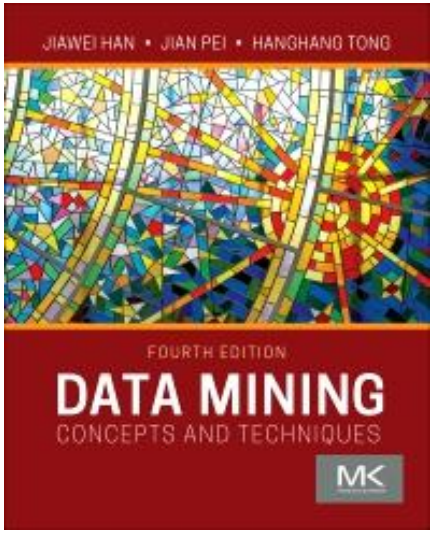

[1] Ogasawara, E.; Salles, R.; Porto, F.; Pacitti, E. Event Detection in Time Series. 1. ed. Cham: Springer Nature Switzerland, 2025.

[2] Cryer, J. D.; Chan, K.-S. Time Series Analysis: With Applications in R. Springer Science & Business Media, 2008.

[3] Han, J.; Pei, J.; Tong, H. Data Mining: Concepts and Techniques. 4th edition ed. Cambridge, MA: Morgan Kaufmann, 2022.

[4] James, G. M.; Witten, D.; Hastie, T.; Tibshirani, R. An Introduction to Statistical Learning: With Applications in R. [s.l.] Springer Nature, 2021.