



# Introdução a Detecção de Eventos em Séries Temporais

Anomalias, pontos de mudança, motivos e discords — conceitos, formalização e métodos de detecção em séries temporais.

**Eduardo Ogasawara**

[eduardo.ogasawara@cefet-rj.br](mailto:eduardo.ogasawara@cefet-rj.br)

<https://eic.cefet-rj.br/~eogasawara>

# O que é uma Série Temporal?

Uma série temporal  $X$  é uma sequência de  $n$  observações  $\langle x_1, x_2, x_3, \dots, x_n \rangle$ , onde  $x_1$  e  $x_n$  representam, respectivamente, as observações mais antigas e mais recentes. Uma observação específica é referenciada como  $x_t$ , indexada no tempo por  $t$  ( $t \in \{1, \dots, n\}$ ).

## Classificações

**Univariada vs. Multivariada:** uma ou múltiplas variáveis por observação.

**Baixa vs. Alta frequência:** observações diárias/anuais vs. múltiplas por dia.

**Offline vs. Online:** análise retrospectiva vs. detecção em tempo real.

## Componente Temporal (TC)

O TC para  $x_t$  pode se referir à própria observação  $x_t$ , à sua tendência instantânea  $tr(x_t)$  ou à sua volatilidade instantânea  $v(x_t)$ . Sob a hipótese autorregressiva, o TC esperado a partir das  $k$  observações anteriores é:

$$ep(tc(x_t), k) = E(tc(x_t) \mid tc(x_{t-1}), \dots, tc(x_{t-k}))$$

E a partir das  $k$  observações seguintes:

$$ef(tc(x_t), k) = E(tc(x_t) \mid tc(x_{t+1}), \dots, tc(x_{t+k}))$$

# O que são Eventos em Séries Temporais?

Eventos em séries temporais são instantes ou intervalos onde as observações mudam de forma considerada importante para análise ou tomada de decisão. A interpretação de um evento varia significativamente entre domínios.

---

## Meteorologia

Intervalos de chuva intensa ou tempestades severas.

---

## Economia

Quedas ou ganhos abruptos em mercados financeiros.

---

## Indústria

Falhas de máquinas, violações de segurança, picos de tráfego de rede.

---

## Saúde

Diagnóstico médico, surtos de doenças, detecção de arritmias.

Em teoria da informação, eventos são intervalos marcados por mudanças significativas de entropia — segmentos que contêm mais informação do que os demais.

## Formalização de Eventos Pontuais

$$e(X, k, \sigma) = \{t \mid |tc(x_t) - ep(tc(x_t), k)| > \sigma \vee |tc(x_t) - ef(tc(x_t), k)| > \sigma \vee |ep(tc(x_t), k) - ef(tc(x_t), k)| > \sigma\}$$

## Três Tipos Principais

- **Anomalias:** observações que diferem significativamente das típicas
- **Pontos de Mudança:** mudanças significativas na tendência ou volatilidade
- **Motifs:** sequências aproximadamente repetidas na série

# Estrutura de Dados para Séries Temporais e Eventos

Séries temporais e eventos podem ser representados em diversas estruturas de dados, dependendo do contexto e propósito da análise.

## Granularidade

**Eventos Pontuais:** observações individuais interpretadas como eventos em relação ao restante da série. Representados em estrutura de dados com timestamp.

**Eventos Intervalares:** ocorrem ao longo de um período definido, registrados com tempo de início e fim. Exemplos: chuva diária contínua, alto consumo de energia elétrica.

## Dimensionalidade

**Univariada:** uma única variável por observação. Representada como vetor. Exemplo: Série de Temperatura Global Anual (YGT).

**Multivariada:** múltiplas variáveis por observação. Representada como matriz ou tabela. Exemplo: temperatura, umidade e velocidade do vento por hora.

Uma estrutura comum é uma tabela onde cada linha representa um instante de tempo e cada coluna representa uma variável. Uma coluna adicional pode indicar a presença e o tipo de evento.

# Taxonomia de Eventos em Séries Temporais

A taxonomia organiza os principais conceitos associados à detecção de eventos em cinco grandes categorias, fornecendo um contexto estruturado para os métodos da literatura.

## Tipo de Evento

Anomalias, Pontos de Mudança, Motifs e Discords — cada um com características e métodos distintos.

## Estrutura de Dados

Granularidade (pontual vs. intervalar) e Dimensionalidade (univariada vs. multivariada).

## Método de Detecção

Regressão, Classificação, Clustering, Estatístico e Baseado em Domínio.

## Cenário de Detecção

Offline (retrospectivo), Online (tempo real) e Predição (eventos futuros).

## Avaliação

Acurácia (precisão, recall, F1, AUC-ROC) e Recursos Computacionais.

Os métodos de detecção são especializados: a maioria identifica apenas um tipo específico de evento. Quando detectam múltiplos tipos, geralmente combinam anomalias e pontos de mudança.

# Anomalias

## Definição

Anomalias são observações que não se conformam às típicas da série temporal. Uma anomalia em  $x_t$  ocorre quando o TC escapa do valor esperado tanto antes quanto depois do instante  $t$ , segundo o limiar  $\sigma$ :

$$a(X, k, \sigma) = \{t \mid |tc(x_t) - ep(tc(x_t), k)| > \sigma \wedge |tc(x_t) - ef(tc(x_t), k)| > \sigma\}$$

## Anomalias de Ruído

O tipo mais simples. Correspondem a variações anormais no componente residual da série. Seja  $\hat{X}$  uma estimativa de  $X$  pelo modelo  $\alpha$ , com  $\hat{x}_t = \alpha(x_t)$ , o resíduo é  $\omega_t = x_t - \hat{x}_t$ . Anomalias são identificadas por testes de distribuição estatística ( $sdt$ ) sobre  $W$ :

$$na(X) = sdt(W), \quad \omega_t = x_t - \hat{x}_t$$

**Anomalias vs. Outliers:** anomalias são eventos que se pretende detectar; outliers são observações indesejadas que se pretende descartar. A distinção é sutil — ambos representam desvios, mas com propósitos analíticos diferentes.

## Detecção Paramétrica (Gaussiana)

$$sdt(W) = \{t \mid \omega_t \notin [\bar{W} - 3 \cdot sd(W), \bar{W} + 3 \cdot sd(W)]\}$$

Assume distribuição Gaussiana. Observações além de  $\pm 3$  desvios-padrão são anomalias.

## Detecção Não-Paramétrica (Box Plot)

$$sdt(W) = \{t \mid \omega_t \notin [Q_1(W) - 1.5 \cdot IQR(W), Q_3(W) + 1.5 \cdot IQR(W)]\}$$

Não assume distribuição específica. Usa quartis e distância interquartil (IQR). Mais robusto para distribuições assimétricas.

# Pontos de Mudança

## Definição

Pontos de mudança são intervalos de tempo onde há uma mudança significativa nas propriedades estatísticas da série — média, variância, correlação ou outros parâmetros. Representam uma transição entre diferentes estados do processo gerador.

$$cp(X, k, \sigma) = \{t \mid (|tc(x_t) - ep(tc(x_t), k)| > \sigma \vee |tc(x_t) - ef(tc(x_t), k)| > \sigma) \vee |ep(tc(x_t), k) - ef(tc(x_t), k)| > \sigma\}$$

Diferença-chave em relação a anomalias: o TC segue o esperado antes OU depois de  $t$ , mas não em ambos simultaneamente.

Exemplo: na Série de Temperatura Global Anual (YGT), pontos de mudança detectados pelo teste de Chow revelam regimes climáticos distintos — tendências significativamente diferentes antes e depois de cada ponto.

## Relação com Concept Drift

Em séries multivariadas  $D$ , onde  $X \subset D$  é preditor de  $Y \in D$ , a detecção de pontos de mudança equivale a um teste de hipótese de concept drift:

$$H_0 : \forall t, k \ (t \neq k) \mid \mathbb{P}_{n(t)} \approx \mathbb{P}_{n(k)}$$

$$H_A : \forall t \exists k \ (t \neq k) \mid \mathbb{P}_{n(t)} \neq \mathbb{P}_{n(k)}$$

$H_0$  caracteriza a ausência de drift;  $H_A$  nega  $H_0$ .  $\mathbb{P}_{n(t)}$  é a função de densidade de probabilidade para  $D$  nas observações vizinhas de  $t$  (ex.: janela deslizante contendo  $t$ ).

# Motifs e Discords

## Motifs

Motifs são subsequências aproximadamente repetidas em uma série temporal. Correspondem a padrões recorrentes com forma distintiva. Dado uma sequência  $q$  e uma série  $X$ ,  $q$  é um motif em  $X$  se e somente se  $q$  ocorre em  $X$  pelo menos  $\sigma$  vezes.

São úteis para identificar tendências, padrões sazonais e outliers. Tornam-se mais interessantes quando as sequências fornecem mais informação do que as observações típicas.

## Métodos de Descoberta

A abordagem direta (força bruta) tem complexidade  $O(n^2)$ . Métodos baseados em indexação com SAX (Symbolic Aggregate approXimation) e hashing melhoram o tempo computacional. O estado da arte usa Matrix Profile para computação eficiente.

## Discords

Discords são sequências que não se repetem na série temporal — as mais isoladas de todas as demais. São significativamente diferentes do restante das observações.

Exemplo: em um eletrocardiograma (MIT-BIH), as batidas cardíacas regulares formam motifs. Batidas irregulares (arritmias) podem ser interpretadas como:

- Motifs raros: três subsequências similares e incomuns
- Discords: três subsequências significativamente diferentes entre si

## Distinção Fundamental

Motifs → similaridade (repetição). Discords → isolamento (singularidade). A mesma subsequência pode ser classificada diferentemente dependendo do critério adotado.



# Métodos de Detecção de Eventos

Os métodos de detecção de eventos adotam cinco grupos gerais e podem ser classificados como orientados a teoria ou orientados a dados.

## Regressão

Modela a série e detecta desvios em relação ao modelo ajustado. Base para anomalias de ruído (ex.: ARIMA).

## Classificação

Requer dados rotulados (supervisionado). Distingue observações típicas de eventos. Ex.: SVM, redes neurais.

## Clustering

Agrupa observações similares. Eventos são pontos distantes dos clusters típicos. Não requer rótulos (não-supervisionado).

## Estatístico

Testes de hipótese e análise de distribuição. Ex.: teste de Chow para pontos de mudança, box plot para anomalias.

## Baseado em Domínio

Usa conhecimento especializado do domínio. Ex.: métodos tempo-frequência para séries sísmicas, modelos de postura corporal para detecção de quedas.

## Orientados a Teoria

Baseados em princípios estabelecidos. Predominam nos grupos estatístico e de domínio. Incorporam explicitamente construtos teóricos.

## Orientados a Dados (ML)

Criados pela análise de grandes séries temporais. Principais métodos: KNN-CAD, K-Means, NNET, SVM, ELM, Conv1D, LSTM. Aprendizado supervisionado, semi-supervisionado ou não-supervisionado.

# Cenários de Detecção

Os cenários de detecção caracterizam as condições em que os métodos são aplicados, determinando requisitos de gerenciamento de dados, recursos computacionais e restrições dos algoritmos.

---

## Offline

Eventos descobertos após a coleta completa da série. Análise retrospectiva em duas etapas: (1) pré-processamento da série; (2) aplicação do método de análise. Permite validação adicional para confirmar eventos reais vs. falsos positivos.

---

## Online

Eventos descobertos em tempo real, conforme as observações são coletadas. Requer monitoramento contínuo e restrições computacionais para reações em tempo real. Exemplo: manutenção preditiva — detectar mudanças em máquinas antes de falhas.

---

## Predição

Previsão de eventos futuros com base em séries históricas. Usa métodos estatísticos, ML ou deep learning (ARIMA a LSTM). Aplicações: finanças, saúde (previsão de surtos, desfechos de pacientes).

**Desafio do Online:** diferentemente do offline, os dados não são divididos em conjuntos estáticos de treino/teste. Quando os fluxos de sensores são numerosos ou de alta velocidade, a operação não-supervisionada e automatizada é necessária. Há um tradeoff entre detecção precoce e falsos positivos.

# Avaliação de Métodos de Detecção

A avaliação determina a eficácia dos algoritmos de detecção, comparando a saída do método com dados de referência (ground truth) rotulados por especialistas.

## Métricas de Acurácia

- **Precisão:** razão entre eventos verdadeiramente positivos e total de eventos detectados.
- **Recall:** razão entre eventos verdadeiramente positivos e total de eventos reais.
- **F1-Score:** média ponderada de precisão e recall.
- **AUC-ROC:** capacidade do algoritmo de discriminar entre eventos positivos e negativos.

Saídas dos métodos: scores (grau de anomalia por instância) ou rótulos (típico vs. anômalo).




## Recursos Computacionais

- **Complexidade de Tempo:** tempo necessário para executar o algoritmo dado o tamanho da entrada.
- **Complexidade de Espaço:** quantidade de memória requerida.
- **Complexidade Computacional:** requisitos totais de recursos (tempo, memória, outros).

Estratégias para gerenciar complexidade: otimização do algoritmo, processamento paralelo e técnicas de redução de dados.

**Desafio:** benchmarking e comparação de desempenho são difíceis. Métricas padrão de classificação funcionam para eventos pontuais, mas eventos intervalares requerem extensões de Precisão e Recall que consideram tolerância temporal.

# Referências Bibliográficas



---

## Event Detection in Time Series

Ogasawara, E.; Salles, R.; Porto, F.; Pacitti, E. Springer Nature Switzerland, 2025.

---

## Time Series Analysis: With Applications in R

Cryer, J. D.; Chan, K.-S. Springer, 2008.

---

## Data Mining: Concepts and Techniques

Han, J.; Pei, J.; Tong, H. Morgan Kaufmann, 4<sup>a</sup> ed., 2022.