



Representação de Eventos em Séries Temporais

Explore como diferentes representações de dados de séries temporais moldam fundamentalmente os eventos que podemos detectar e como os definimos.

Eduardo Ogasawara

eduardo.ogasawara@cefet-rj.br

<https://eic.cefet-rj.br/~eogasawara>

Representação de séries temporais

Uma série temporal observada ao longo do tempo pode ser transformada em diferentes formas de representação. Tradicionalmente tratada como sequência de valores numéricos, em mineração temporal a série pode ser convertida em outro espaço representacional.

Exemplos incluem representações vetoriais, simbólicas, espectrais e probabilísticas. Essa transformação é fundamental porque determina o tipo de informação que conseguimos extrair e quais eventos podem ser detectados.

A função de representação $\mathcal{R}$ pode atuar sobre a série inteira ou sobre uma janela deslizante, não se limitando a um único valor X_t :

Representação global — atua sobre toda a série:

$$Z = \mathcal{R}(X)$$

Representação local — atua sobre uma janela deslizante de tamanho w :

$$Z_t = \mathcal{R}(X_{t:t+w-1})$$

Onde X denota a série completa, $X_{t:t+w-1}$ é o subsequência de t a $t + w - 1$, $\mathcal{R}$ é a função de representação, e Z (ou Z_t) é o espaço de representações resultante.

Representações Globais e Locais

Representação Global

Utiliza toda a série temporal para análise, capturando padrões gerais e tendências de longo prazo.

$$\mathcal{R}_G(X_t)$$

Representação Local

Usa apenas partes específicas da série, essencial para detectar eventos que ocorrem em trechos temporais específicos.

$$\mathcal{R}_L(X_{t:t+w})$$

Muitos eventos se manifestam localmente, enquanto outros alteram a estrutura global da série — a escolha entre representação global e local depende do tipo de evento que se deseja detectar. Enquanto modelos clássicos analisam a série como um todo, eventos geralmente aparecem em janelas específicas do tempo, onde w representa o tamanho da janela temporal.

Embeddings Temporais

Cada instante t é transformado em um vetor z_t construído a partir de valores defasados. A sequência desses vetores forma uma **trajetória geométrica** no espaço multidimensional, codificando o comportamento *típico* da série — e é o que se afasta dela que caracteriza um evento.

$$\mathbf{z}_t = (x_t, x_{t-\tau}, x_{t-2\tau}, \dots, x_{t-(m-1)\tau})$$

Onde m é a dimensão do embedding e τ é o atraso temporal.

ENTRADA: x (série temporal de comprimento T), m (dimensão), τ (atraso)

PRÉ-CONDIÇÃO: $T > m \cdot \tau$

PASSO 1 — Para cada instante t de $(m-1) \cdot \tau + 1$ até T :

$$z_t \leftarrow (x_t, x_{t-\tau}, x_{t-2\tau}, \dots, x_{t-(m-1)\tau})$$

PASSO 2 — Formar a matriz de embeddings:

$$\Phi \leftarrow [z_{(m-1)\tau+1}, z_{(m-1)\tau+2}, \dots, z_T]$$

PASSO 3 — Definir comportamento típico:

$$\mu \leftarrow \text{média das linhas de } \Phi$$

$$\Sigma \leftarrow \text{covariância das linhas de } \Phi$$

SAÍDA: Φ (matriz de embeddings), μ , Σ

PÓS-CONDIÇÃO: desvios em z_t em relação ao comportamento típico identificam candidatos a evento

Representação e Conceito de Evento

Múltiplas Perspectivas

A mesma série pode ter representações completamente diferentes, cada uma revelando aspectos distintos dos dados.

Resultados Distintos

Representações diferentes geram conjuntos diferentes de eventos detectados.

Dependência Metodológica

O conjunto de eventos detectados depende fundamentalmente da representação escolhida.

$$\mathcal{R}_1(X_t) \neq \mathcal{R}_2(X_t)$$

Representar uma série é, na prática, escolher um ponto de vista. Cada representação enfatiza certos aspectos dos dados e ignora outros. Por isso, a própria definição de evento depende da forma como a série é representada.

$$\mathcal{E}(\mathcal{R}_1) \neq \mathcal{E}(\mathcal{R}_2)$$

O que conta como evento depende da representação escolhida, do modelo de tipicidade adotado e do objetivo analítico — representações diferentes podem gerar conjuntos de eventos distintos sobre os mesmos dados.

Conceito de Tipicidade Temporal

Representar uma série é definir o que é esperado: a tipicidade é o comportamento que o modelo antecipa, e um evento é tudo aquilo que se destaca dessa expectativa. Sem um modelo de referência que estabeleça o típico, o próprio conceito de evento deixa de existir.

De forma geral, a tipicidade é o valor esperado da série dado um modelo M ; quando o modelo incorpora a informação passada $\mathcal{F}_{t-1}$, essa noção se refina como predição condicional temporal:

$$\hat{X}_t = \mathbb{E}[X_t \mid \mathcal{F}_{t-1}, M]$$

Onde $\mathcal{F}_{t-1}$ é a filtração que captura toda a informação acumulada até o instante anterior. Diferentes modelos geram diferentes noções de tipicidade — e, portanto, diferentes conjuntos de eventos.

Evento como Desvio Estatístico

O resíduo R_t mede o afastamento da série em relação ao comportamento esperado pelo modelo; um evento ocorre quando esse desvio supera um limiar τ .

$$R_t = X_t - \hat{X}_t$$
$$E_t = \begin{cases} 1, & |R_t| > \tau \\ 0, & \text{caso contrário} \end{cases}$$

ENTRADA: x (série observada), $\hat{x}$ (série prevista pelo modelo)

PRÉ-CONDIÇÃO: x e $\hat{x}$ com mesmo comprimento T

PASSO 1 — Calcular resíduos:

PARA t de 1 até T :

$R_t \leftarrow x_t - \hat{x}_t$

PASSO 2 — Definir limiar τ :

// Opção A: τ fornecido como parâmetro externo

// Opção B: $\tau \leftarrow k \cdot \text{desvio_padrão}(R)$, k tipicamente 2 ou 3

PASSO 3 — Aplicar critério de detecção:

PARA t de 1 até T :

SE $|R_t| > \tau$:

$E_t \leftarrow 1$ // evento detectado

SENÃO:

$E_t \leftarrow 0$

SAÍDA: E (vetor binário de eventos), R (resíduos)

PÓS-CONDIÇÃO: instantes com $E_t = 1$ são
candidatos a evento

Evento como Ruptura Estrutural


Ao contrário de um desvio pontual, uma ruptura estrutural indica que o próprio processo mudou — os parâmetros antes e depois do evento são distintos, e essa mudança persiste.

Em termos práticos, isso significa que o modelo ajustado antes do evento deixa de explicar bem o comportamento da série após ele. A ruptura pode se manifestar como mudança persistente na média (nível da série), na variância (amplitude das flutuações) ou na estrutura de dependência temporal (autocorrelação).

$$\theta_1 \neq \theta_2$$

Eventos estruturais não são detectáveis por simples limiares sobre resíduos — exigem testes de mudança de regime ou métodos de segmentação.

Ruptura estrutural: dois regimes ($\theta_1 \neq \theta_2$)



Ruído, Sinal e Evento

Sinal Estruturado

Componente S_t com padrões sistemáticos e previsíveis

Ruído Aleatório

Componente ε_t com flutuações estocásticas naturais

Componente de Evento

Componente δ_t com perturbações estruturadas significativas

$$X_t = S_t + \varepsilon_t + \delta_t$$

A série pode ser decomposta em sinal, ruído e evento. Ruído é flutuação aleatória sem estrutura — δ_t , ao contrário, representa uma perturbação estruturada associada a um evento: ela não é aleatória, mas sim um desvio com padrão, duração ou magnitude que a distingue do ruído natural. Essa distinção é fundamental para não confundir variação natural com fenômenos relevantes.

Tipologia de Eventos

Eventos se classificam em quatro categorias; cada uma será tratada em aula específica.

Eventos Estatísticos

Desvios em medidas estatísticas

Eventos Estruturais

Mudanças no processo gerador

Eventos Geométricos

Alterações na trajetória no espaço de estados

Eventos de Padrão

Aparição ou desaparecimento de padrões

Essas categorias não são mutuamente exclusivas em todos os casos — elas organizam diferentes formas de representar e detectar eventos, e um mesmo fenômeno pode ser descrito por mais de uma delas dependendo da representação adotada.

Arquitetura da Detecção de Eventos

A detecção de eventos é um pipeline sequencial em que cada etapa condiciona a seguinte — a escolha da representação e do modelo determina o que conta como evento.

série → representação → tipicidade → score → evento

ENTRADA: x (série temporal bruta), R (função de representação),
 M (modelo de tipicidade), τ (limiar de score)

PRÉ-CONDIÇÃO: R e M compatíveis com o domínio de x ;
se R for local com janela w , o número de posições
avaliadas é $T - w + 1$, não necessariamente T

PASSO 1 — Representação:

$Z \leftarrow R(x)$ // Z pode ser global ou uma sequência de janelas locais

PASSO 2 — Modelo de tipicidade:

$\hat{Z} \leftarrow M(Z)$ // estima o comportamento esperado em Z

PASSO 3 — Score de desvio:

PARA cada posição t avaliável:

$s_t \leftarrow d(Z_t, \hat{Z}_t)$ // d é uma função de distância ou resíduo

PASSO 4 — Detecção de evento:

PARA cada posição t avaliável:

SE $s_t > \tau$:

$E_t \leftarrow 1$




SENÃO:

$E_t \leftarrow 0$

SAÍDA: E (vetor de indicadores de evento), s (scores de desvio)

PÓS-CONDIÇÃO: E depende das escolhas de R , M e τ

Referências Bibliográficas



Event Detection in Time Series

Ogasawara, E.; Salles, R.; Porto, F.; Pacitti, E.
Springer Nature Switzerland, 2025.

Time Series Analysis: With Applications in R

Cryer, J. D.; Chan, K.-S. Springer, 2008.

Data Mining: Concepts and Techniques

Han, J.; Pei, J.; Tong, H. Morgan Kaufmann, 4^a ed., 2022.