

# Representação de Eventos em Séries Temporais

Explore como diferentes representações de dados de séries temporais moldam fundamentalmente os eventos que podemos detectar e como os definimos.

**Eduardo Ogasawara**

[eduardo.ogasawara@cefet-rj.br](mailto:eduardo.ogasawara@cefet-rj.br)

<https://eic.cefet-rj.br/~eogasawara>

# Representação de séries temporais

Uma série temporal observada ao longo do tempo pode ser transformada em diferentes formas de representação. Tradicionalmente tratada como sequência de valores numéricos, em mineração temporal a série pode ser convertida em outro espaço representacional.

Exemplos incluem representações vetoriais, simbólicas, espectrais e probabilísticas. Essa transformação é fundamental porque determina o tipo de informação que conseguimos extrair e quais eventos podem ser detectados.

$$\mathcal{R}(X_t) \rightarrow Z$$

Onde  $X_t$  é o valor da série no instante  $t$ ,  $\mathcal{R}$  é a função de representação, e  $Z$  é o espaço de representações.

# Representações Globais e Locais

## Representação Global

Utiliza toda a série temporal para análise, capturando padrões gerais e tendências de longo prazo.

$$\mathcal{R}_G(X_t)$$

## Representação Local

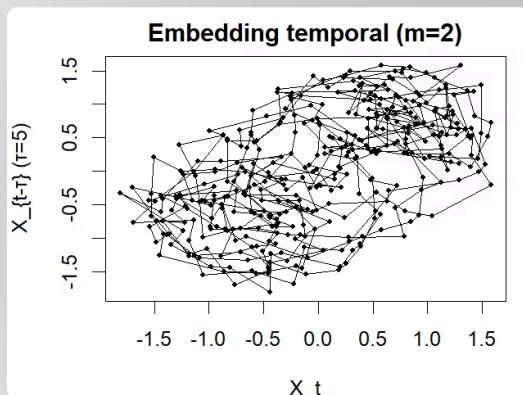
Usa apenas partes específicas da série, essencial para detectar eventos que ocorrem em trechos temporais específicos.

$$\mathcal{R}_L(X_{t:t+w})$$

Eventos são fenômenos que ocorrem em trechos específicos da série, exigindo representações locais. Enquanto modelos clássicos analisam a série como um todo, eventos geralmente aparecem em janelas específicas do tempo, onde  $w$  representa o tamanho da janela temporal.

# Embeddings Temporais

Uma série temporal pode ser representada em um espaço de estados, onde cada ponto é construído a partir de valores defasados da série. O conjunto desses pontos forma uma trajetória no espaço de estados.



01

## Coleta de Valores Defasados

Valores da série em diferentes momentos temporais são coletados.

02

## Construção do Vetor

Os valores defasados formam um vetor de embedding multidimensional.

03

## Trajetória no Espaço

A sequência de vetores cria uma trajetória geométrica que revela padrões.

$$\mathbf{X}_t = (X_t, X_{t-\tau}, X_{t-2\tau}, \dots, X_{t-(m-1)\tau})$$

Onde  $\mathbf{X}_t$  é o vetor de embedding no instante  $t$ ,  $m$  é a dimensão do embedding, e  $\tau$  é o atraso temporal. A série deixa de ser vista como sequência unidimensional e passa a ser interpretada como trajetória geométrica.

# Representação e Conceito de Evento

## Múltiplas Perspectivas

A mesma série pode ter representações completamente diferentes, cada uma revelando aspectos distintos dos dados.

## Resultados Distintos

Representações diferentes geram conjuntos diferentes de eventos detectados.

## Dependência Metodológica

O conjunto de eventos detectados depende fundamentalmente da representação escolhida.

$$\mathcal{R}_1(X_t) \neq \mathcal{R}_2(X_t)$$

Representar uma série é, na prática, escolher um ponto de vista. Cada representação enfatiza certos aspectos dos dados e ignora outros. Por isso, a própria definição de evento depende da forma como a série é representada.

NORMALIDADE

# Conceito de Normalidade Temporal

A normalidade depende de um modelo ou referência estabelecida. Pode ser definida por modelos estatísticos ou empíricos. Sem uma definição clara de normalidade, não existe conceito de evento.

## Modelo de Referência

Estabelece o comportamento esperado da série temporal através de padrões históricos ou teóricos.

## Valor Esperado

Define o comportamento normal como a expectativa condicional dado o modelo.

## Base para Eventos

Eventos são definidos como desvios significativos em relação a essa referência de normalidade.

$$N_t = \mathbb{E}[X_t | M]$$

Onde  $N_t$  é o comportamento normal no instante  $t$ ,  $\mathbb{E}[\cdot]$  é o valor esperado, e  $M$  é o modelo ou representação da série.

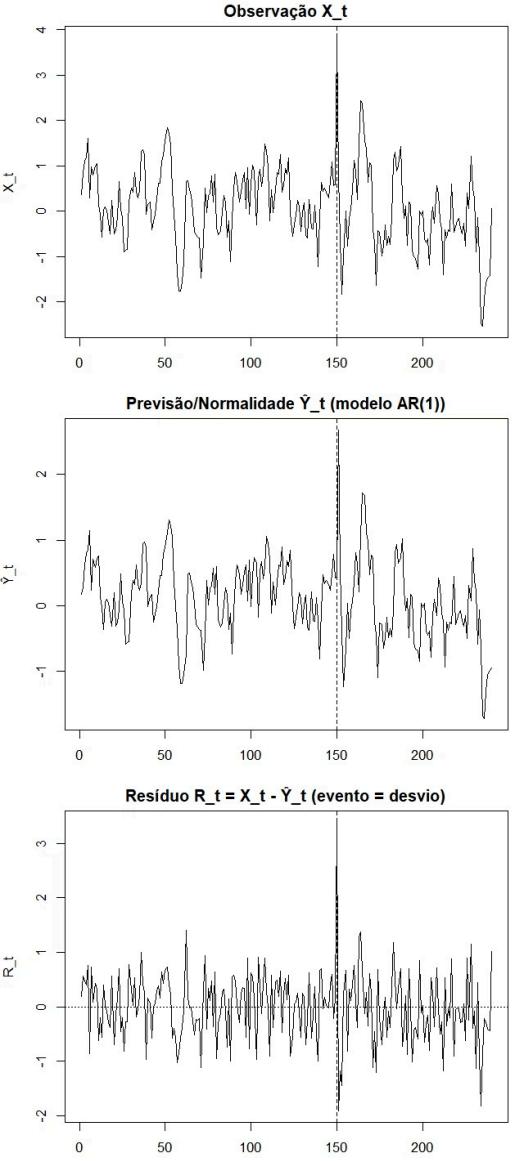
# Normalidade como Modelo Temporal

Um modelo define o comportamento esperado da série através de previsão condicional. A normalidade é dada pela previsão baseada em informações passadas. Diferentes modelos geram diferentes noções de normalidade.

$$\hat{X}_t = \mathbb{E}[X_t | \mathcal{F}_{t-1}, M]$$

Onde  $\hat{X}_t$  é o valor previsto no instante  $t$ ,  $\mathcal{F}_{t-1}$  é a informação disponível até  $t - 1$ , e  $M$  é o modelo temporal.

A normalidade é formalizada como previsão. Se o modelo descreve bem a série, então o comportamento normal é aquilo que ele prevê. Eventos aparecem quando a série se afasta sistematicamente dessa previsão.



# Resíduos Temporais

1

## Observação

Valor real medido na série temporal

2

## Previsão

Valor esperado pelo modelo

3

## Resíduo

Diferença não explicada pelo modelo

$$R_t = X_t - \hat{X}_t$$

O resíduo  $R_t$  é a diferença entre o valor observado  $X_t$  e o valor previsto  $\hat{X}_t$ . Resíduos representam a parte não explicada pelo modelo.

Se o modelo captura bem o comportamento normal, os resíduos deveriam ser aleatórios. Quando aparecem padrões, rupturas ou valores extremos nos resíduos, isso sugere a presença de eventos.

# Evento como Desvio Estatístico

Um evento é definido como um desvio significativo em relação à normalidade. O critério depende de um limiar estatístico, que pode ser definido por desvio padrão ou quantis da distribuição.



## Limiar Estatístico

Define o ponto de corte para considerar um desvio como significativo



## Detecção Binária

Classifica cada instante como evento ou não-evento



## Decisão Metodológica

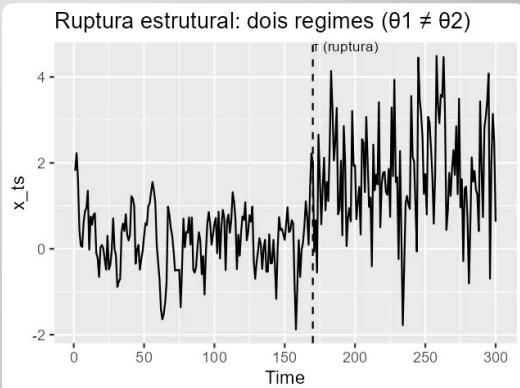
A escolha do limiar é crucial e depende do contexto

$$E_t = \begin{cases} 1, & |R_t| > \tau \\ 0, & \text{caso contrário} \end{cases}$$

Onde  $E_t$  é o indicador de evento,  $R_t$  é o resíduo, e  $\tau$  é o limiar estatístico. Nesta visão, evento é um conceito estatístico: ocorre quando o desvio em relação à normalidade é grande o suficiente.

# Evento como Ruptura Estrutural

Um evento pode representar uma mudança no processo gerador da série. Antes e depois do evento, os parâmetros do modelo são diferentes, caracterizando uma ruptura estrutural.



## Regime Anterior

Parâmetros  $\theta_1$  governam o processo

## Novo Regime

Parâmetros  $\theta_2$  definem novo comportamento



## Ponto de Ruptura

Momento de transição estrutural

$$\theta_1 \neq \theta_2$$

O evento não é apenas um ponto extremo, mas uma mudança no próprio mecanismo que gera a série. Essa visão inclui change points e mudanças de regime, representando alterações fundamentais no processo temporal.

# Dependência da Representação

## Representação Influencia Eventos

O conjunto de eventos detectados depende fundamentalmente da representação escolhida para analisar a série temporal.

Representações diferentes geram conjuntos completamente diferentes de eventos, mesmo analisando os mesmos dados brutos.

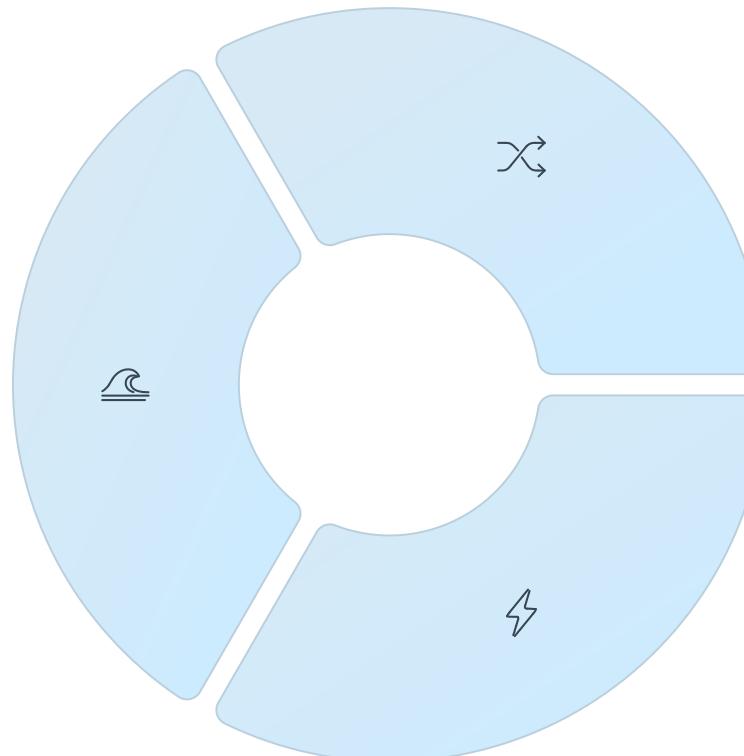
$$\mathcal{E}(\mathcal{R}_1) \neq \mathcal{E}(\mathcal{R}_2)$$

Onde  $\mathcal{E}(\mathcal{R})$  representa o conjunto de eventos sob a representação  $\mathcal{R}$ .

- ❑ **Implicação Epistemológica:** Não existe evento absoluto. O que é considerado evento depende do espaço onde a série é analisada. Isso reforça o caráter epistemológico da detecção de eventos.

# Ruído, Sinal e Evento

**Sinal Estruturado**  
Componente  $S_t$  com padrões sistemáticos e previsíveis



## Ruído Aleatório

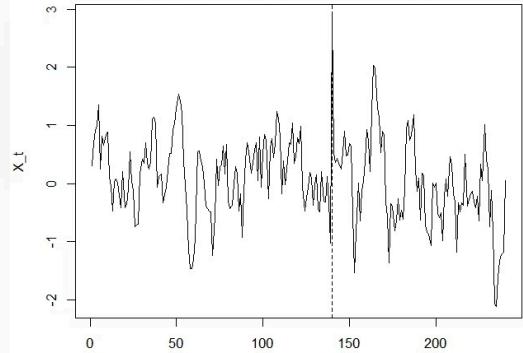
Componente  $\varepsilon_t$  com flutuações estocásticas naturais

## Componente de Evento

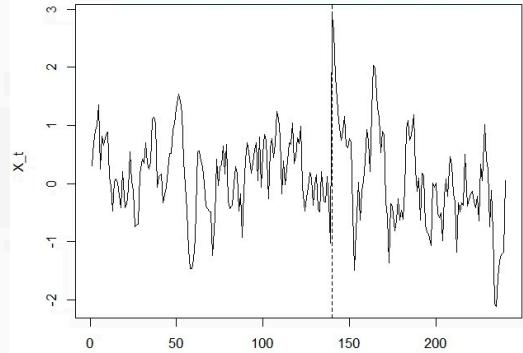
Componente  $\delta_t$  com perturbações estruturadas significativas

A série pode ser decomposta em sinal, ruído e evento. Ruído é flutuação aleatória, enquanto evento é uma alteração estruturada. Essa distinção é fundamental para não confundir variação natural com fenômenos relevantes.

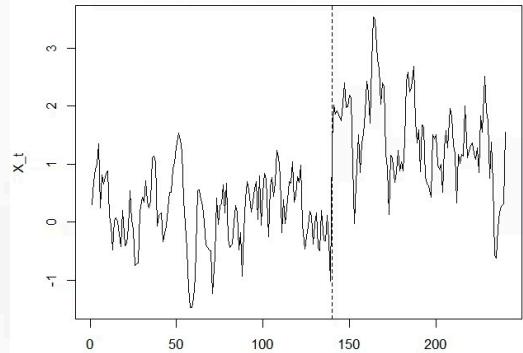
Outlier Aditivo (AO): afeta um único ponto



Outlier Inovacional (IO): choque que se propaga



Mudança de Nível (LS): alteração permanente após t0



# Outliers em Séries Temporais

Outlier é uma observação atípica isolada que se destaca significativamente do padrão geral. Existem diferentes tipos de outliers temporais, e nem todo outlier representa um evento estrutural.

1

## Outlier Aditivo

Afeta apenas uma observação específica sem impactar valores subsequentes

2

## Outlier Inovacional

Afeta a observação e propaga efeitos para valores futuros

3

## Mudança de Nível

Altera permanentemente o nível da série após o ponto de ocorrência

$$|R_t| \gg \sigma_R$$

Onde  $R_t$  é o resíduo e  $\sigma_R$  é o desvio padrão dos resíduos. Outliers são casos extremos, mas podem não representar mudanças estruturais. Eventos, em sentido amplo, podem envolver padrões mais complexos do que observações isoladas.

# Change Points e Eventos

Change point é uma mudança nos parâmetros do processo gerador da série. Eventos podem ser locais ou globais, e change points representam uma classe particular de eventos estruturais.

## Regime Inicial

Parâmetros  $\theta_1$  até o instante  $\tau$

## Regime Posterior

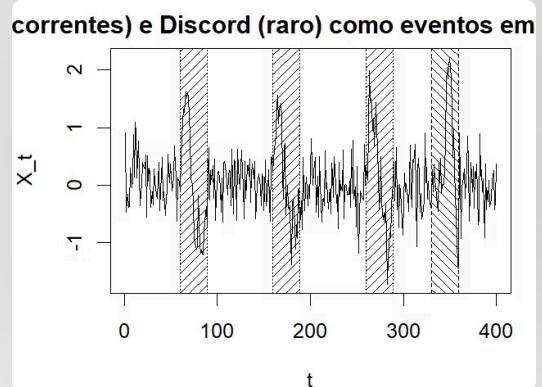
Parâmetros  $\theta_2$  após o instante  $\tau$

$$\theta(t) = \begin{cases} \theta_1, & t \leq \tau \\ \theta_2, & t > \tau \end{cases}$$

Change points representam mudanças globais na série, enquanto eventos podem ser mais localizados. Assim, change points são uma classe particular de eventos que afetam o comportamento de longo prazo da série.

# Motifs, Discords e Eventos

## Padrões Temporais



**Motifs** são padrões recorrentes que aparecem frequentemente na série temporal.

**Discords** são padrões raros que se destacam por sua singularidade.

Eventos podem ser interpretados como padrões raros ou discords no conjunto de subsequências.

$$\text{discord} = \arg \max_s \min_{u \neq s} d(s, u)$$

Onde  $s$  e  $u$  são subsequências, e  $d(\cdot, \cdot)$  é uma medida de distância. Nesta abordagem, eventos são vistos como padrões incomuns no conjunto de subsequências. Isso conecta detecção de eventos com mineração de padrões temporais.

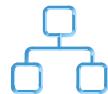
# Tipologia de Eventos

Eventos podem ser classificados em diferentes categorias, cada uma capturando aspectos distintos de anomalias temporais.



## Eventos Estatísticos

Desvios significativos em medidas estatísticas como média, variância ou distribuição



## Eventos Estruturais

Mudanças nos parâmetros ou regime do processo gerador da série



## Eventos Geométricos

Alterações na trajetória ou forma da série no espaço de estados



## Eventos de Padrão

Aparição ou desaparecimento de padrões específicos na série temporal

$$\mathcal{E} = \mathcal{E}_{stat} \cup \mathcal{E}_{struct} \cup \mathcal{E}_{geom} \cup \mathcal{E}_{pattern}$$

Essa taxonomia mostra que event detection é um problema multifacetado. Diferentes métodos capturam diferentes tipos de eventos.

# Arquitetura da Detecção de Eventos

A detecção de eventos é um processo em múltiplos níveis, onde cada nível influencia o tipo de evento detectável. Não é uma etapa única, mas uma cadeia de decisões metodológicas.

## Série Temporal Bruta

Dados observados no domínio temporal original

## Representação

Transformação dos dados em espaço adequado

## Modelo de Normalidade

Definição do comportamento esperado

## Detecção de Evento

Identificação de desvios significativos

série → representação → modelo → evento

Cada escolha metodológica molda o resultado final. A arquitetura revela que eventos emergem de um processo de construção teórica e não são propriedades intrínsecas dos dados.

# Fundamentos Teóricos



Transformações, representações e modelos definem eventos. Eventos não surgem diretamente dos dados, mas de uma combinação estruturada desses três elementos fundamentais.

$$\mathcal{E} = f(\mathcal{T}, \mathcal{R}, \mathcal{M})$$

Onde  $\mathcal{T}$  representa transformações,  $\mathcal{R}$  representa representações, e  $\mathcal{M}$  representa modelos. Esta visão formaliza o papel do arcabouço teórico na detecção de eventos.

A fórmula expressa que eventos são funções das escolhas metodológicas, não descobertas neutras nos dados.

# Normalidade e Conceito de Evento

O conceito de evento depende fundamentalmente da definição de normalidade. Primeiro definimos o que é comportamento normal; depois, definimos o que é desvio.

Portanto, o conceito de evento emerge diretamente da noção de normalidade estabelecida pelo modelo ou referência escolhida.



## Definir Normalidade

Estabelecer modelo de referência

## Identificar Desvios

Comparar observações com normalidade

## Classificar Eventos

Determinar significância dos desvios

normalidade  $\Rightarrow$  evento

A relação de implicação mostra que eventos são conceitos derivados, não primitivos. Sem normalidade, não há evento.

# Métodos como Instâncias de Definições

Cada método de detecção assume uma representação específica e um modelo particular. Métodos diferentes detectam eventos diferentes porque incorporam escolhas teóricas distintas.



## Métodos Estatísticos

Baseados em distribuições e testes de hipótese



## Métodos de Aprendizado

Utilizam modelos adaptativos e redes neurais



## Métodos Geométricos

Analisam trajetórias no espaço de estados

$$\text{método}_i = g_i(\mathcal{T}, \mathcal{R}, \mathcal{M})$$

Onde  $g_i$  representa o método de detecção de eventos. Algoritmos não são neutros: cada um incorpora escolhas teóricas implícitas. Por isso, métodos distintos produzem resultados distintos ao analisar os mesmos dados.

# Referências Bibliográficas

Uma coleção cuidadosamente selecionada de obras fundamentais que abordam análise de séries temporais e mineração de dados.



## Event Detection in Time Series

**Ogasawara, E.; Salles, R.; Porto, F.; Pacitti, E.**  
(2025). Publicação recente da Springer Nature Switzerland que explora técnicas avançadas de detecção de eventos em séries temporais.

## Time Series Analysis: With Applications in R

**Cryer, J. D.; Chan, K.-S.** (2008). Obra clássica da Springer que combina fundamentação teórica sólida com implementações práticas.

## Data Mining: Concepts and Techniques

**Han, J.; Pei, J.; Tong, H.** (2022). Quarta edição publicada pela Morgan Kaufmann que consolida conceitos fundamentais e técnicas avançadas de mineração de dados