




Anomalias em Séries Temporais

Definição, formalização e detecção de anomalias em séries temporais.

Eduardo Ogasawara

eduardo.ogasawara@cefet-rj.br

<https://eic.cefet-rj.br/~eogasawara>

Comportamento Típico e Anomalia


A noção de anomalia nasce da noção de comportamento típico. Um modelo temporal define o que é esperado, e a previsão condicional estabelece o comportamento esperado para cada instante.

O resíduo r_t mede o desvio entre o observado e o esperado. Uma anomalia ocorre quando esse desvio não é compatível com o que o próprio modelo considera típico.

Formalmente, a série $X = \{x_t\}$ contém um conjunto de eventos $\mathcal{E}$, e as anomalias formam um subconjunto: $\mathcal{A} \subset \mathcal{E}$.

$$\hat{x}_t = \mathbb{E}[x_t \mid \mathcal{F}_{t-1}, \mathcal{M}], \quad r_t = x_t - \hat{x}_t$$

Onde $\mathcal{M}$ é o modelo temporal, $\mathcal{F}_{t-1}$ é a informação disponível até $t-1$, $\hat{x}_t$ é o valor esperado, e r_t é o resíduo.



Ruído, Evento e Anomalia

É fundamental distinguir três conceitos que frequentemente se confundem na análise de séries temporais:

Ruído

A variabilidade esperada e inerente ao processo, representada por ε_t . Não é um desvio — é o comportamento normal do sistema, presente em qualquer instante.

Evento

A componente adicional associada a uma perturbação, representada por δ_t . É um termo extra que representa perturbação estruturada sobre o processo, além do ruído esperado.

Anomalia

Um caso particular de evento onde o desvio resultante é estatisticamente significativo no contexto do modelo.

$$x_t = S_t + \varepsilon_t, \quad x_t = S_t + \varepsilon_t + \delta_t$$

Onde S_t é o sinal estruturado, ε_t é o ruído aleatório, e δ_t é a perturbação associada ao evento. Toda anomalia é evento, mas nem todo evento é anomalia. A distinção entre ε_t e δ_t é o que separa variabilidade esperada de perturbação detectável.

Outliers e Anomalias Temporais

A distinção entre outliers clássicos e anomalias temporais é crucial para a análise correta de séries temporais.

Outlier Clássico

Compara x_t com uma média μ e desvio padrão σ globais, assumindo independência entre observações.


$$|x_t - \mu| > k\sigma$$

Anomalia Temporal

Considera a dependência temporal. O "típico" em t depende do histórico e do modelo, usando resíduos para medir desvios.

$$|r_t| > \lambda\sigma_r$$

Em séries temporais, a abordagem clássica é inadequada porque ignora a estrutura de dependência. A definição temporal primeiro explica o esperado naquele instante e só depois mede o desvio.



Detecção de Anomalia Estrutural Local

A Ideia Central

O processo tem parâmetros típicos θ_0 . Uma anomalia estrutural local é uma quebra temporária em $[\tau_1, \tau_2]$ após a qual o processo retorna ao regime original — diferente de uma mudança estrutural persistente.

$$\theta(t) \approx \begin{cases} \theta_0, & t \notin [\tau_1, \tau_2] \\ \theta'_0 \neq \theta_0, & t \in [\tau_1, \tau_2] \end{cases}$$

❗ Esta é uma detecção **offline**: a janela $\{x_{t-w}, \dots, x_{t+w}\}$ usa passado e futuro. Em uso **online**, use apenas janela passada $\{x_{t-w}, \dots, x_{t-1}\}$.

w é a largura da janela de teste. δ é o limiar de divergência de parâmetros. Quando o fenômeno não reverte, aproxima-se de mudança estrutural global: $X_t \sim F_{\theta_1} \rightarrow F_{\theta_2}$.

ENTRADA: x_{train} (período de referência sem anomalias), x (série completa),
 w (largura de janela), δ (limiar de divergência)

PRÉ-CONDIÇÃO: x_{train} é um período considerado normal; $T > 2w$;
estimador de parâmetros θ disponível; detecção offline

PASSO 1 — Estimação do regime de referência

$\theta_0 \leftarrow \text{estimar_parâmetros}(x_{\text{train}})$

// usar período de treinamento limpo evita contaminar θ_0 com as próprias anomalias

PASSO 2 — Varredura por janela deslizante (offline)

PARA t de $w+1$ até $T-w$:

janela $\leftarrow \{x_{t-w}, \dots, x_{t+w}\}$

$\theta_t \leftarrow \text{estimar_parâmetros}(\text{janela})$

PASSO 3 — Teste de divergência

$A \leftarrow \emptyset$

PARA t de $w+1$ até $T-w$:

SE $\text{divergência}(\theta_t, \theta_0) > \delta$:

$A \leftarrow A \cup \{t\}$

PASSO 4 — Verificação de reversão

PARA cada intervalo $[\tau_1, \tau_2] \subseteq A$:

SE $\theta(t) \approx \theta_0$ para $t > \tau_2$:

// processo retorna ao regime de referência

classificar como anomalia estrutural local

SENÃO:

// processo permanece no novo regime

classificar como mudança estrutural global

SAÍDA: A particionado em anomalias locais e mudanças globais

PÓS-CONDIÇÃO: anomalias locais satisfazem $\theta(t) \rightarrow \theta_0$ após τ_2 ; mudanças globais persistem

Detecção por Limiar Estatístico

A Ideia Central

Uma anomalia ocorre quando o resíduo r_t supera λ desvios padrão da variabilidade típica. O modelo define o esperado; o limiar define o inaceitável.

$$r_t = x_t - \hat{x}_t, \quad |r_t| > \lambda \sigma_r$$

λ controla a sensibilidade: valores menores detectam mais, com risco de falsos positivos. α controla a raridade: $\mathbb{P}(|R_t| > |r_t|) < \alpha$.

- ❑ σ_r estimado no treinamento — em uso preditivo, não usar resíduos futuros para estimar a variabilidade típica.

ENTRADA: x_{train} (período de treinamento), x_{test} (período de teste), M (modelo ajustado), λ (sensibilidade)
PRÉ-CONDIÇÃO: M estimado sobre x_{train} ; σ_r calculado nos resíduos de treinamento; resíduos aproximadamente estacionários

PASSO 1 — Estimação da variabilidade típica (treinamento)

PARA t em x_{train} :

$$\hat{x}_t \leftarrow E[x_t \mid F_{\{t-1\}}, M]$$

$$r_t \leftarrow x_t - \hat{x}_t$$

$$\sigma_r \leftarrow \text{desvio_padrão}(\{r_t : t \in x_{\text{train}}\})$$

PASSO 2 — Geração dos resíduos de teste

PARA t em x_{test} :

$$\hat{x}_t \leftarrow E[x_t \mid F_{\{t-1\}}, M]$$

$$r_t \leftarrow x_t - \hat{x}_t$$

PASSO 3 — Classificação

$$A \leftarrow \emptyset$$

PARA t em x_{test} :

$$\text{SE } |r_t| > \lambda \cdot \sigma_r:$$

$$A \leftarrow A \cup \{t\}$$

SAÍDA: A (conjunto de instantes anômalos no período de teste)

PÓS-CONDIÇÃO: sob resíduos padronizados aproximadamente $N(0,1)$, λ controla a taxa esperada de alarmes — a afirmação só vale se resíduos forem independentes e bem calibrados

Detecção por Densidade Condicional

A Ideia Central

O comportamento esperado é a distribuição condicional p_t , estimada a partir do contexto C_t . Se o valor observado cai numa região de baixa densidade sob p_t , é anômalo.

$$x_t \mid C_t \sim p_t, \quad p_t(x_t) < \varepsilon$$

p_t pode ser estimada por kernel, mistura de gaussianas ou outro estimador não-paramétrico. ε é o limiar de baixa densidade — sua escala depende do estimador usado.

ENTRADA: x (série temporal), k (largura de janela de contexto), ε (limiar de densidade)

PRÉ-CONDIÇÃO: comprimento $T > k$; estimador de densidade não-paramétrico disponível; ε calibrado na escala **do** estimador

PASSO 1 — Construção **do** contexto e estimação de **p_t**

PARA t de $k+1$ até T :

$C_t \leftarrow \{x_{\{t-k\}}, \dots, x_{\{t-1\}}\}$

p_t $\leftarrow$ estimar_densidade(C_t)

// C_t exclui x_t para evitar vazamento de informação

PASSO 2 — Avaliação da densidade no ponto observado

PARA t de $k+1$ até T :

score_t $\leftarrow p_t(x_t)$

PASSO 3 — Classificação

$A \leftarrow \emptyset$

PARA t de $k+1$ até T :

SE **score_t** $< \varepsilon$:

$A \leftarrow A \cup \{t\}$

SAÍDA: A (conjunto de instantes anômalos)

PÓS-CONDIÇÃO: anomalias correspondem a regiões de baixa probabilidade condicional sob **p_t** ; ε deve ser validado empiricamente

Dependência da Representação

O que conta como anomalia depende da representação, do modelo e do objetivo analítico — não é uma propriedade absoluta do dado.

$$\mathcal{A}(\mathcal{R}) = \{t \mid \text{score}(\mathcal{R}(X), t) > \tau\}$$

Valores brutos

→ sem anomalia detectada

Resíduos do modelo

→ anomalia detectada

Componente de volatilidade

→ anomalia diferente

$$\mathcal{A}(\mathcal{R}_1) \neq \mathcal{A}(\mathcal{R}_2)$$

Escolher a representação é escolher o que pode ser anômalo.

Três Níveis de Formalização

A síntese organiza a noção de anomalia em três "portas de entrada" complementares que formam um conjunto unificado. A união $\mathbf{A} = \mathbf{A}_{stat} \cup \mathbf{A}_{dist} \cup \mathbf{A}_{struct}$ é uma organização conceitual — as classes não são necessariamente disjuntas.

Estatístico

Desvio raro nos resíduos, medido por limiar λ sobre σ_r .

$$|r_t| > \lambda \sigma_r$$

Critério: limiar sobre desvio padrão dos resíduos de treinamento.

Distribucional

Ocorrência improvável sob distribuição condicional p_t estimada no contexto C_t .

$$p_t(x_t) < \varepsilon$$

Critério: densidade local — ε calibrado na escala do estimador.

Estrutural

Divergência temporária de parâmetros em $[\tau_1, \tau_2]$, com retorno ao regime θ_0 .


$$\theta(t) \neq \theta_0 \text{ em } [\tau_1, \tau_2]$$

Critério: divergência(θ_t, θ_0) > δ , verificada por janela deslizando offline.


$$\mathcal{A} = \mathcal{A}_{stat} \cup \mathcal{A}_{dist} \cup \mathcal{A}_{struct}$$

Mudar o critério muda o conjunto de anomalias detectadas.


(a) Anomalia no valor: x_t



(b) Anomalia na tendência: $tr(x_t)$



(c) Anomalia na volatilidade: $v(x_t)$



Anomalias e Componentes Temporais

Anomalias podem ocorrer em diferentes componentes — não apenas no valor observado.

Componente Valor

Desvio direto em x_t , com tendência e volatilidade típicas.

Componente Tendência

Desvio em $tendência_t$: nível típico, mas inclinação anômala. $tendência_t$ é a componente de tendência extraída da série.

Componente Volatilidade

Desvio em $volatilidade_t$: explosão de variância com nível e tendência normais. $volatilidade_t$ mede a dispersão local do processo.

Tipos de Anomalias por Natureza

Três manifestações distintas segundo escopo temporal e contexto.

Anomalias Pontuais

Desvios isolados em um único instante de tempo.

Anomalias Coletivas

Sequências que, em conjunto, constituem comportamento anômalo.

Anomalias Contextuais

Valores anômalos apenas em relação ao entorno temporal. Em avaliação offline, o contexto pode incluir vizinhança anterior e posterior:

$C_t = \{x_{t-k}, \dots, x_{t-1}, x_{t+1}, \dots, x_{t+k}\} \setminus \{x_t\}$. O mesmo valor pode ser típico em um regime e anômalo em outro: $x_t \not\sim p(C_t)$.

C_t exclui x_t para evitar que o ponto avaliado defina seu próprio contexto.

A tipicidade é sempre condicionada ao contexto — o limiar e a interpretação do evento dependem da vizinhança temporal.

Desafios na Detecção de Anomalias

Quatro tensões metodológicas que afetam qualquer sistema de detecção.

Definição de Comportamento Típico

O que é "normal" em processos não-estacionários e com múltiplos regimes?

Escolha de Representação

Qual transformação preserva a informação relevante para a detecção?

Sensibilidade vs Especificidade

Como detectar anomalias reais sem gerar excessivos falsos positivos?

Adaptação Temporal

Como ajustar modelos conforme o processo evolui ao longo do tempo?

Síntese: Anomalia como Escolha Metodológica

A síntese final explicita que a anomalia é um conceito relativo, dependente de múltiplas escolhas metodológicas. Detectar anomalias não é simplesmente "procurar pontos estranhos", mas formalizar a *tipicidade* e decidir o que constitui desvio relevante.

Representação

Como transformar a série temporal original

Modelo

Como definir a tipicidade no espaço escolhido — via resíduos, densidade ou parâmetros.

Contexto

Qual vizinhança C_t (ou janela W) o detector considera a cada instante.

Tempo

Quando avaliar e como adaptar critérios

$$\mathcal{A} = f(\mathcal{R}, \mathcal{M}, \mathcal{C}, t)$$

f representa a regra de detecção — não uma função matemática única universal, mas a composição de quatro decisões: representação, modelo de tipicidade, contexto e tempo de avaliação.

Arquitetura do Pipeline de Detecção

A detecção de anomalias pode ser formulada como um mapeamento estruturado $\mathcal{D} : \mathcal{R}(X) \rightarrow \mathcal{A}$. O detector não opera sobre os dados brutos, mas sobre uma representação transformada — e o pipeline abaixo detalha cada etapa dessa cadeia.

Pré-processamento

$\mathcal{T}$ transforma X_t em $X_t^{(prep)}$: limpeza e normalização dos dados.

Representação

$\mathcal{R}$ produz Z_t : extração de características relevantes para modelagem.

Modelagem

$\mathcal{M}$ gera $\hat{Z}_t$: comportamento esperado sob normalidade.

Detecção

$\mathcal{D}$ aplica a regra de decisão e identifica $\mathcal{A}$ (conjunto de anomalias): instantes ou subsequências que desviam do comportamento típico.

$$\mathcal{D} : \mathcal{R}(X) \rightarrow \mathcal{A}$$

Checklist Operacional do Detector

O detector opera em três etapas encadeadas — modelar o esperado, calcular o score e decidir — e exige decisões explícitas em sete dimensões:

Representação

Qual sinal extrair dos dados brutos

Modelo de Tipicidade

Como definir o comportamento típico esperado

Score

Como medir o desvio entre observado e esperado: $s_t = g(R(X), t)$

Limiar

Qual nível de desvio classifica como anomalia:
 $a_t = \mathbb{I}(s_t > \tau)$

Janela / Contexto

Qual contexto temporal W o detector considera a cada instante

Modo de Operação

Restrição de informação disponível: offline (série completa), online (sequencial) ou preditivo (horizonte futuro)

Avaliação

Como medir acerto, falso alarme, anomalia perdida e atraso

$$a_t = \mathbb{I}(s_t > \tau)$$

onde $s_t = g(\mathcal{R}(X), t)$ é o score de desvio e τ é o limiar de decisão.

Detecção Estatística de Anomalias

A normalidade é modelada por uma distribuição condicional $p_{\theta}(x_t | \mathcal{F}_{t-1})$, conhecida ou estimada a partir do histórico. O detector mede o quanto cada observação é improvável sob esse modelo e decide com base em um limiar.

$$p_{\theta}(x_t | \mathcal{F}_{t-1})$$

$$s_t = \phi(x_t, p_{\theta,t}), \quad a_t = \mathbb{I}(s_t > \tau)$$

$p_{\theta,t}$: distribuição condicional estimada no instante t ;
 ϕ : função de score (ex: resíduo padronizado, CUSUM, razão de verossimilhança); τ : limiar de decisão.

ENTRADA: série $X = \{x_1, \dots, x_T\}$, limiar τ

PRÉ-CONDIÇÃO: $p_{\{\theta,t\}}$ estimada ou conhecida a partir de dados históricos

PASSO 1 — Para cada $t = 1, \dots, T$:

PASSO 2 — Calcular score: $s_t = \phi(x_t, p_{\{\theta,t\}})$

PASSO 3 — Se $s_t > \tau$: marcar x_t como anomalia ($a_t = 1$)

PASSO 4 — Senão: classificar como normal ($a_t = 0$)

SAÍDA: conjunto $A = \{t : a_t = 1\}$

PÓS-CONDIÇÃO: cada ponto classificado segundo desvio estatístico de $p_{\{\theta,t\}}$

Detecção Baseada em Modelos Temporais

Um modelo temporal f aprende a dinâmica normal da série usando p defasagens. O score é o erro de previsão: quanto maior o erro, mais improvável é a observação. A avaliação só é possível a partir de $t = p+1$, após a janela inicial de treinamento.

$$x_t = f(x_{t-1}, \dots, x_{t-p}) + \varepsilon_t$$

$$s_t = |x_t - \hat{x}_t|, \quad a_t = \mathbb{I}(s_t > \tau)$$

f : modelo preditivo (AR, ARIMA, rede neural); p : ordem — número de defasagens; ε_t : ruído; τ : limiar sobre o erro de previsão. Avaliação inicia em $t = p+1$.

ENTRADA: série $X = \{x_1, \dots, x_T\}$, ordem p , limiar τ

PRÉ-CONDIÇÃO: modelo f treinado em dados históricos normais

PASSO 1 — Para cada $t = p+1, \dots, T$:

PASSO 2 — Prever: $\hat{x}_t = f(x_{t-1}, \dots, x_{t-p})$

PASSO 3 — Calcular erro: $g_t = |x_t - \hat{x}_t|$

PASSO 4 — Se $g_t > \tau$: marcar x_t como anomalia ($a_t = 1$)

PASSO 5 — Senão: classificar como normal ($a_t = 0$)

SAÍDA: conjunto $A = \{t : a_t = 1\}$

PÓS-CONDIÇÃO: anomalias correspondem a erros de previsão acima do limiar

Detecção Baseada em Distância

A normalidade é definida por similaridade estrutural: uma subsequência é anômala se não encontra vizinhos próximos na própria série. Não há modelo probabilístico — apenas distância entre padrões. Uma zona de exclusão evita comparação com subsequências sobrepostas quase idênticas.

$$\mathcal{S} = \{s_i = X_{i:i+w-1} : i = 1, \dots, T - w + 1\}$$

$$s_i = \min_{j: |i-j| > w} d(s_i, s_j)$$

$$a_i = \mathbb{I}(s_i > \tau)$$

w : tamanho da janela de subsequência; i, j : índices de subsequências em $\mathcal{S}$; $d(\cdot, \cdot)$: métrica de distância (ex: Euclidiana, DTW); $|i - j| > w$: zona de exclusão que evita comparação com subsequências sobrepostas; τ : limiar de isolamento.

ENTRADA: série $X = \{x_1, \dots, x_T\}$, janela w , limiar τ

PRÉ-CONDIÇÃO: métrica $d(\cdot, \cdot)$ definida; $w < T$

PASSO 1 — Extrair $S = \{X_{t:t+w-1} : t = 1, \dots, T-w+1\}$

PASSO 2 — Para cada subsequência $s_i \in S$:

PASSO 3 — Calcular $s_i = \min_{j: |i-j| > w} d(s_i, s_j)$

PASSO 4 — Se $s_i > \tau$: marcar s_i como anomalia ($a_i = 1$)

PASSO 5 — Senão: classificar como padrão normal ($a_i = 0$)

SAÍDA: conjunto A de subsequências anômalas (discords)

PÓS-CONDIÇÃO: anomalias são subsequências sem vizinhos próximos em S

Detecção com Aprendizado de Máquina

A tipicidade é aprendida implicitamente: o modelo f_θ aprende a representação normal diretamente dos dados, sem especificação explícita de uma distribuição. O score é o erro de reconstrução ou predição no espaço transformado.

$$Z_t = \mathcal{R}(X_{t-w+1:t}), \quad s_t = |Z_t - \hat{Z}_t|, \quad a_t = \mathbb{I}(s_t > \tau)$$

f_θ : modelo aprendido (autoencoder, LSTM, VAE); Z_t : representação da janela; $\hat{Z}_t$: reconstrução esperada; τ : limiar sobre o erro. A força do paradigma está em capturar padrões complexos e não-lineares.

ENTRADA: X_{train} (dados normais), X_{test} (série de teste), w (janela), τ (limiar)
PRÉ-CONDIÇÃO: f_θ treinado em X_{train} com dados sem anomalias; $w < T_{\text{test}}$

PASSO 1 — Treinamento (representação normal)

PARA cada janela $W_i = X_{\{i:i+w-1\}}$ em X_{train} :

$\hat{Z}_i \leftarrow f_\theta(W_i)$ // reconstrução ou previsão

atualizar θ via $\min ||W_i - \hat{Z}_i||$

PASSO 2 — Scoring no período de teste

PARA t de w até T_{test} :

$Z_t \leftarrow \mathcal{R}(X_{\{t-w+1:t\}})$ // extração da janela

$\hat{Z}_t \leftarrow f_\theta(Z_t)$ // reconstrução pelo modelo

$s_t \leftarrow |Z_t - \hat{Z}_t|$ // erro de reconstrução

PASSO 3 — Classificação

$A \leftarrow \emptyset$

PARA t de w até T_{test} :

SE $s_t > \tau$:

$A \leftarrow A \cup \{t\}$

SAÍDA: A (conjunto de instantes anômalos)

PÓS-CONDIÇÃO: anomalias correspondem a janelas mal reconstruídas por f_θ ; τ deve ser calibrado nos resíduos de X_{train}

Síntese dos Paradigmas de Detecção

Estatístico

Tipicidade definida por distribuição probabilística conhecida ou estimada

Baseado em Modelos

Tipicidade expressa através de previsão temporal explícita

Baseado em Distância

Tipicidade determinada por similaridade de padrões na série

Aprendizado

Tipicidade aprendida implicitamente via representação e erro

Todos os paradigmas executam a mesma operação: produzir um score s_t e aplicar um limiar τ para identificar anomalias. Diferem em como definem tipicidade ($\mathcal{M}$) e representação ($\mathcal{R}$). A janela/contexto $\mathcal{C}$ é parte integrante da operação do detector, não apenas um parâmetro técnico.

$$\mathcal{D} = f(\mathcal{R}, \mathcal{M}, g, \tau, \mathcal{C})$$

f representa a regra operacional do detector — não uma função universal única, mas a composição das escolhas de $\mathcal{R}$, $\mathcal{M}$, g , τ e $\mathcal{C}$.

Cenários, Janela e Arquitetura

O detector não opera sobre a série inteira — ele usa um contexto W . O cenário temporal determina a restrição de informação disponível; a arquitetura determina como W é atualizado.

Offline

Série completa $X_{1:T}$ disponível. Permite calibração global com toda a informação.

Online

Dados chegam sequencialmente. Decisões tomadas à medida que observações aparecem.

Preditivo

Estima $\mathbb{P}(a_{t+h} = 1 | \mathcal{F}_t)$: probabilidade de anomalia futura dado o histórico $\mathcal{F}_t$ até t , com horizonte h .

Batch

Contexto fixo. Processamento completo da janela de uma só vez.

Streaming

Contexto deslizante. Atualização incremental; W define também memória e custo computacional.

Híbrida

Contexto adaptativo. Combina processamento completo e incremental.

Tamanho da Janela w — Janela Pequena


Reação rápida, mas pode confundir ruído com anomalia — sensível a variações locais.

Tamanho da Janela w — Janela Grande

Decisão estabilizada, mas aumenta latência e pode diluir desvios curtos.

Mudar w altera o que conta como "recente" e pode modificar o conjunto de anomalias detectadas.

Trade-offs na Detecção de Anomalias



A função de custo formaliza os compromissos operacionais do detector através de pesos que refletem prioridades da aplicação.

Não existe detector ótimo universal — cada aplicação requer um ponto de operação específico. Sensibilidade compete com precisão (FN vs FP), latência compete com robustez, e complexidade compete com interpretabilidade.

A função de custo $\mathcal{L}(\mathcal{D}) = \alpha \cdot FP + \beta \cdot FN + \gamma \cdot \bar{\Delta}t$ penaliza falsos positivos, falsos negativos e atraso médio de detecção $\bar{\Delta}t$ (média dos atrasos sobre todos os eventos). Pesos diferentes definem detectores "melhores" para objetivos diferentes: um sistema de alerta crítico prioriza β alto; um sistema de monitoramento contínuo pode tolerar mais FP.

Avaliação: Acerto e Pontualidade

Avaliar um detector significa entender quatro tipos de resultado possíveis — e, em séries temporais, também o quão rápido a detecção ocorre.

Acerto (*True Positive*)

Anomalia real detectada corretamente.

Falso Alarme (*False Positive*)

Alerta disparado sem anomalia real.

Evento Perdido (*False Negative*)

Anomalia real não detectada.

Atraso (*Latency*)

Detecção correta, mas tardia.

Precisão e revocação comparam os conjuntos $\hat{A}$ e A , mas exigem uma regra de correspondência temporal — a interseção exata pode ser injusta quando uma detecção ligeiramente deslocada ainda é útil.


Atraso de Detecção

$\Delta t = \max(0, t_{\text{det}} - t_{\text{real}})$ mede o tempo entre a anomalia real e sua detecção.

Métrica com Penalização Temporal


$Q = F_1 \cdot P(\Delta t)$, onde $P(\Delta t) = e^{-\lambda \Delta t}$ é uma escolha de penalização — não uma métrica universal.

Referências Bibliográficas




Event Detection in Time Series

Ogasawara, E.; Salles, R.; Porto, F.; Pacitti, E.
Springer Nature Switzerland, 2025.



Time Series Analysis: With Applications in R

Cryer, J. D.; Chan, K.-S. Springer, 2008.



Data Mining: Concepts and Techniques

Han, J.; Pei, J.; Tong, H. Morgan Kaufmann, 4^a ed., 2022.