



Detecção de Anomalias em Séries Temporais



Eduardo Ogasawara

eogasawara@cefet-rj.br | <https://eic.cefet-rj.br/~eogasawara>



Objetivos do capítulo

1

Distinguir anomalias de outliers e de outros eventos temporais.

2

Classificar anomalias por tipo, contexto, dimensão, interpretação e aprendizado.

3

Entender as principais famílias de métodos e suas limitações práticas.


Anomalia não é apenas sujeira nos dados

Em outlier analysis, o valor extremo costuma ser tratado como ruído a remover.

Em anomaly detection, o valor atípico é o objeto de interesse.

Fraudes, falhas, surtos, incidentes e eventos raros são exemplos em que a anomalia carrega informação.

Taxonomia de anomalias



A taxonomia organiza tipo, circunstância, dimensão, interpretação e forma de aprendizado.

Anomalias pontuais



Uma única observação difere significativamente do restante da série.



A decisão depende do contexto local e do modelo do comportamento típico.



É a forma mais direta de anomalia, mas não necessariamente a mais fácil de detectar.



Anomalias sequenciais

Uma subsequência inteira apresenta comportamento incomum.

O ponto isolado pode parecer aceitável, mas a sequência completa revela o evento.

Exige comparar janelas, formas ou representações temporais.

Ponto vs sequência no exemplo de Seattle



Exemplo com temperatura semanal: anomalia pontual no painel (a) e sequência anômala no painel (b).

Anomalias contextuais

A observação não é estranha por si só.

Ela se torna anômala quando considerada no contexto temporal.

Exemplo: 26°C pode ser comum no verão, mas anômalo no inverno.

Anomalias fora de contexto

- O valor é atípico independentemente do instante em que ocorre.
- A explicação não depende fortemente da vizinhança temporal.
- Esse caso se aproxima da noção clássica de outlier estatístico.

Univariada vs multivariada

Univariada

Uma variável é analisada ao longo do tempo.

A anomalia aparece como valor ou sequência atípica naquela série.

Métodos são mais simples e interpretáveis.


Multivariada

A anomalia pode surgir da combinação entre variáveis.

Cada variável isolada pode parecer normal.

Relações entre dimensões passam a importar.

Anomalia multivariada com PCA



O exemplo mostra anomalias capturadas pela relação entre variáveis, não apenas por valores extremos individuais.

Séries rotuladas e não rotuladas

Rotuladas

Cada observação pode indicar presença ou ausência de anomalia.

Permite avaliação e aprendizado supervisionado.

Rótulos podem ser incompletos ou temporalmente imprecisos.

Não rotuladas

Não há indicação direta do que é anomalia.

A detecção depende de hipótese estatística, distância ou raridade.

É o caso mais comum em aplicações reais.

Aprendizado supervisionado

- Usa observações com rótulos de típico/anômalo.
- A anomalia é tratada como classe a ser prevista.
- O problema central é a escassez e a imperfeição dos rótulos.

Aprendizado semissupervisionado

- Treina o modelo apenas com dados típicos.
- Novas observações são anômalas quando não se ajustam ao padrão aprendido.
- É comum quando a classe anômala é rara ou difícil de rotular.

Aprendizado não supervisionado



Não requer rótulos para treinamento.



Assume que observações típicas são mais frequentes ou mais densas.



É flexível, mas exige cuidado maior na interpretação dos alertas.

Quando usar cada cenário de aprendizado


Mais rótulos

- Supervisionado quando os rótulos são confiáveis.
- Útil em operação online depois de uma fase de treinamento.
- Permite otimizar métricas como F1.

Menos rótulos

- Semissupervisionado quando há exemplos típicos confiáveis.
- Não supervisionado quando quase não há rótulo.
- Exige análise posterior dos alarmes.

Exemplo-base para comparar métodos



Série sintética do Harbinger: região de treinamento e teste permitem comparar famílias de detectores.

Como ler os exemplos dos métodos



A mesma série é usada para contrastar famílias de detectores.



Nem todo método encontra o mesmo tipo de anomalia.



O objetivo é entender a hipótese operacional de cada família, não ranquear algoritmos.

Anomalias por Regressão

Complemento do Capítulo 3 - Janelas deslizantes, resíduos e famílias de modelos



t	x_{t-4}	x_{t-3}	x_{t-2}	x_{t-1}	$\hat{x}_t$	x_t
5	v_1	v_2	v_3	v_4	$\hat{v}_5$	v_5
6	v_2	v_3	v_4	v_5	$\hat{v}_6$	v_6
7	v_3	v_4	v_5	v_6	$\hat{v}_7$	v_7
8	v_4	v_5	v_6	v_7	$\hat{v}_8$	v_8
9	v_5	v_6	v_7	v_8	$\hat{v}_9$	v_9
10	v_6	v_7	v_8	v_9	$\hat{v}_{10}$	v_{10}
11	v_7	v_8	v_9	v_{10}	$\hat{v}_{11}$	v_{11}
12	v_8	v_9	v_{10}	v_{11}	$\hat{v}_{12}$	v_{12}
13	v_9	v_{10}	v_{11}	v_{12}	$\hat{v}_{13}$	v_{13}
14	v_{10}	v_{11}	v_{12}	v_{13}	$\hat{v}_{14}$	v_{14}

(a)

Por que este complemento existe

O deck principal apresentou regressão como desvio entre observado e estimado.

Aqui abrimos a caixa: como a janela deslizante vira exemplo supervisionado, como o erro vira escore e que famílias de regressão podem ser usadas.

A ideia é dar intuição operacional antes de entrar em ARIMA, redes ou modelos de tendência.

Ideia central

Um modelo aprende o comportamento esperado da série.

Para cada instante t , o modelo produz uma estimativa $\hat{x}_t$.

A anomalia é caracterizada por erro, resíduo ou distância incomum entre x_t e $\hat{x}_t$.

Janela deslizante: transformar tempo em atributos

Uma janela de tamanho p usa observações passadas como atributos.

O alvo é a próxima observação da série.

A cada novo instante, a janela anda uma posição e produz outro exemplo de treino ou teste.

$\langle x_{t-p}, \dots, x_{t-2}, x_{t-1} \rangle \rightarrow x_t$

Regressão por janela deslizante

Os termos defasados $x_{t-4}, \dots, x_{t-1}$ predizem x_t ; a diferença entre previsão e observação vira resíduo.

Exemplo tabular da janela

Com $p = 5$, uma linha do conjunto de treino contém quatro defasagens e um alvo.

A série temporal passa a ser vista como problema de regressão supervisionada.

O cuidado é preservar ordem temporal: treino antes, teste depois.

[x_{t-4} , x_{t-3} , x_{t-2} , x_{t-1}] $\rightarrow$ x_t

Do erro ao escore de anomalia

Depois da previsão, calcula-se uma distância entre x_t e $\hat{x}_t$.

Esse valor é o escore de desvio do modelo.

Quanto maior o escore, maior a evidência de que o comportamento observado não foi esperado pelo modelo.

$$\omega_t = \text{distance}(x_t, \hat{x}_t)$$

Escolhas de distância

Erro absoluto

- Mantém a escala original da série.
- É fácil de explicar para o domínio.
- Menos agressivo com erros muito grandes.

Erro quadrático

- Amplifica erros grandes.
- É comum em regressão e otimização.
- Pode aumentar a sensibilidade a picos.

Como decidir o limiar

O modelo gera uma série de resíduos $W = \langle \omega_1, \dots, \omega_n \rangle$.

A detecção depende de separar resíduos típicos de resíduos extremos.

Essa separação pode ser paramétrica, não paramétrica ou baseada em valores extremos.

Limiar gaussiano

Assume que os resíduos típicos seguem aproximadamente uma distribuição gaussiana.

Resíduos muito distantes da média são marcados como anomalias.

É simples, mas frágil quando a distribuição é assimétrica, multimodal ou não estacionária.

$$w_t > \text{média}(W) + 3 \cdot \text{sd}(W)$$

Limiar por boxplot

- Não exige assumir uma distribuição específica para os resíduos.
- Usa quartis e distância interquartil.
- No caso de regressão, normalmente interessa o limite superior dos erros.

$$\omega_t > Q3(W) + 1,5 \cdot IQR(W)$$

Teoria de valores extremos para resíduos

- Modela especificamente a cauda da distribuição dos erros.
- É útil quando os eventos relevantes são raros e extremos.
- Pode ser mais adequada em detecção online, pois evita uma hipótese simples para toda a distribuição.

Seguidores de tendência

Modelos seguidores suavizam ou decompõem a série para estimar o comportamento esperado.

Exemplos: média móvel, splines, FFT, wavelet, EMD, REMD e FBIAD.

A anomalia aparece quando a observação se afasta da curva seguida pelo modelo.


Modelos estatísticos de regressão

ARIMA e regressão linear modelam a série com hipóteses estatísticas explícitas.

São bons quando há estrutura temporal interpretável, como autocorrelação, tendência ou sazonalidade.

A leitura do resíduo costuma ser direta: o que sobrou depois do modelo.

ARIMA como detector por desvio



O modelo ajustado estima a série; resíduos altos ao redor das anomalias sustentam a detecção.

Regressores de aprendizado de máquina

A janela deslizante permite usar modelos supervisionados gerais.

Exemplos: KNN, SVM, Random Forest, XGBoost, MLP e ELM.

O detector continua sendo baseado no erro entre previsão e observação.

Regressores profundos

Conv1D e LSTM exploram padrões temporais em sequências.

DeepAnT usa redes convolucionais para prever a próxima janela e detectar desvios.

Telemanom e detectores LSTM usam erro de previsão para localizar comportamento inesperado.

Métodos recentes e híbridos



Triple Exponential Smoothing incorpora nível, tendência e sazonalidade.



Median Method usa a mediana da janela contextual como previsão robusta.



Métodos híbridos e ensembles combinam modelos para reduzir fragilidades individuais.

O que muda entre os tipos de regressão

Muda o modelo esperado

ARIMA, média móvel, spline, RF, XGBoost, LSTM.

Cada um captura uma forma diferente de padrão temporal.

Modelo ruim gera resíduo ruim.

Permanece a lógica

Prever x_t .

Calcular erro.

Comparar erro com uma referência de normalidade.

Cuidados práticos

- A janela p controla quanta memória temporal o modelo recebe.
- Treinar com anomalias pode fazer o modelo aprender o evento como se fosse normal.
- Mudança de regime pode parecer anomalia para um modelo não adaptativo.
- Normalização e escala afetam diretamente o erro.

Mensagem principal

Métodos por regressão detectam anomalias indiretamente: primeiro modelam o esperado, depois analisam o desvio.

A janela deslizante é o mecanismo que transforma série temporal em exemplos preditivos.

A diferença entre os métodos está no modelo usado para prever e no critério usado para declarar o erro anômalo.

Classificação: anomalia como classe



Um classificador aprende a separar observações típicas e anômalas.



Durante o treinamento, os rótulos precisam estar disponíveis.



Durante o teste, o modelo prediz o rótulo das novas observações.

Classificação com janela deslizante



t	x_{t-4}	x_{t-3}	x_{t-2}	x_{t-1}	x_t	$\hat{e}_t$	e_t
5	v_1	v_2	v_3	v_4	v_5	$\hat{b}_5$	b_5
6	v_2	v_3	v_4	v_5	v_6	$\hat{b}_6$	b_6
7	v_3	v_4	v_5	v_6	v_7	$\hat{b}_7$	b_7
8	v_4	v_5	v_6	v_7	v_8	$\hat{b}_8$	b_8
9	v_5	v_6	v_7	v_8	v_9	$\hat{b}_9$	b_9
10	v_6	v_7	v_8	v_9	v_{10}	$\hat{b}_{10}$	b_{10}
11	v_7	v_8	v_9	v_{10}	v_{11}	$\hat{b}_{11}$	b_{11}
12	v_8	v_9	v_{10}	v_{11}	v_{12}	$\hat{b}_{12}$	b_{12}


(a)

t	x_{t-4}	x_{t-3}	x_{t-2}	x_{t-1}	x_t	$\hat{e}_t$
13	v_9	v_{10}	v_{11}	v_{12}	v_{13}	$\hat{b}_{13}$
14	v_{10}	v_{11}	v_{12}	v_{13}	v_{14}	$\hat{b}_{14}$

(b)

Na etapa de treino, a janela tem rótulo; na etapa de teste, o modelo prediz a presença de anomalia.

Exemplo com SVM



O SVM detecta parte das anomalias no teste; o exemplo também evidencia falso negativo.

Desafio da classificação

- Anomalias são raras, gerando forte desbalanceamento de classes.
- Rótulos humanos podem perder eventos ou marcar o instante com atraso.
- A classe aprendida pode não representar anomalias futuras ainda não vistas.

Agrupamento: anomalia como distância

- Observações típicas formam grupos ou regiões densas.
- Anomalias aparecem longe dos representantes ou fora dos grupos.
- A abordagem é naturalmente não supervisionada.


Agrupamento com janela deslizante

t	x_{t-4}	x_{t-3}	x_{t-2}	x_{t-1}	x_t	$\ddot{r}_c$	d_t
5	v_1	v_2	v_3	v_4	v_5	$\ddot{r}_1$	d_5
6	v_2	v_3	v_4	v_5	v_6	$\ddot{r}_1$	d_6
7	v_3	v_4	v_5	v_6	v_7	$\ddot{r}_1$	d_7
8	v_4	v_5	v_6	v_7	v_8	$\ddot{r}_2$	d_8
9	v_5	v_6	v_7	v_8	v_9	$\ddot{r}_2$	d_9
10	v_6	v_7	v_8	v_9	v_{10}	$\ddot{r}_1$	d_{10}
11	v_7	v_8	v_9	v_{10}	v_{11}	$\ddot{r}_1$	d_{11}
12	v_8	v_9	v_{10}	v_{11}	v_{12}	$\ddot{r}_2$	d_{12}
13	v_9	v_{10}	v_{11}	v_{12}	v_{13}	$\ddot{r}_2$	d_{13}
14	v_{10}	v_{11}	v_{12}	v_{13}	v_{14}	$\ddot{r}_2$	d_{14}

$\ddot{r}_t$	x_{t-4}	x_{t-3}	x_{t-2}	x_{t-1}	x_t
$\ddot{r}_1$	$\ddot{v}_{1,4}$	$\ddot{v}_{1,3}$	$\ddot{v}_{1,2}$	$\ddot{v}_{1,1}$	$\ddot{v}_{1,0}$
$\ddot{r}_2$	$\ddot{v}_{2,4}$	$\ddot{v}_{2,3}$	$\ddot{v}_{2,2}$	$\ddot{v}_{2,1}$	$\ddot{v}_{2,0}$

Cada janela é associada a um grupo; a distância ao representante apoia a detecção.

Exemplo com K-Means



Sequências distantes dos centroides são marcadas como anômalas.

Limitações do agrupamento



A escolha de k e da métrica de distância afeta diretamente a detecção.



Escala e normalização podem mudar quais pontos parecem distantes.





Dados com anomalias no treinamento podem formar grupos espúrios.

Métodos estatísticos

- Assumem que observações típicas ocupam regiões de alta probabilidade.
- Anomalias aparecem em regiões de baixa probabilidade.
- Podem usar modelos paramétricos, testes de hipótese ou perfis não paramétricos.

Exemplo com histograma




Bins raros ou fora do intervalo típico indicam candidatos a anomalia.

Métodos espectrais


- Projetam os dados em um espaço de menor dimensão.
- A estrutura principal da série deve ser preservada na projeção.
- Anomalias aparecem como observações mal representadas ou mal reconstruídas.

Autoencoder: arquitetura



A forma de ampulheta força a rede a aprender uma representação compacta dos padrões típicos.

Autoencoder: erro de reconstrução



Sequências mal reconstruídas produzem erro alto e são marcadas como anômalas.

Teoria da informação

Anomalias são raras e aumentam a informação ou a entropia da amostra.

A pergunta passa a ser: que subconjunto muda mais a informação da série?

Compressão e complexidade de Kolmogorov podem servir como aproximações práticas.

buscar $A \subset S$ que maximize $|I(S) - I(S - A)|$

Anomalias de volatilidade

A anomalia não está necessariamente no nível da série, mas em sua variabilidade.

ARCH e GARCH modelam a volatilidade instantânea.

Esse caso é central em risco financeiro e em séries com variação não linear.


Volatilidade anômala: formalização

A característica temporal passa a ser a volatilidade $v(xt)$.

O evento ocorre quando a volatilidade foge do esperado antes e depois de t .

$$va(X,k,\sigma) = \{t : |v(xt) - ep(v(xt),k)| > \sigma \wedge |v(xt) - ef(v(xt),k)| > \sigma\}$$

Exemplo com GARCH



A região entre as linhas tracejadas tem aumento de volatilidade; o detector encontra anomalias internas e um falso positivo.

Valores extremos


Valores extremos são raros, mas relevantes para decisão.

A distribuição completa pode ser inadequada para modelar apenas a cauda.

A teoria de valores extremos trata os extremos como um processo próprio.

$$M_n = \max\{x_1, x_2, \dots, x_n\}$$

Chuva extrema no Rio de Janeiro



Extração de valores extremos por Peak over Threshold em dados de precipitação de 2019 a 2022.

Mensagens principais



Anomalias são eventos de interesse, não necessariamente erros a remover.



Tipo, contexto, dimensão e rótulos determinam o desenho do detector.






Cada família de método carrega uma hipótese: erro, classe, distância, probabilidade, reconstrução ou informação.



Os tópicos avançados mostram que nem toda anomalia aparece no nível da observação.

Referências Bibliográficas



Event Detection in Time Series

Ogasawara, E.; Salles, R.; Porto, F.;
Pacitti, E. Springer Nature Switzerland,
2025.

Time Series Analysis: With Applications in R

Cryer, J. D.; Chan, K.-S. Springer, 2008.

Data Mining: Concepts and Techniques

Han, J.; Pei, J.; Tong, H. Morgan
Kaufmann, 4^a ed., 2022.