

Pontos de Mudança e Desvio de Conceitos



Eduardo Ogasawara

eogasawara@cefet-rj.br | <https://eic.cefet-rj.br/~eogasawara>



Por que detectar mudanças importa

Modelos de previsão e descoberta de padrões só são válidos enquanto o processo observado permanece semelhante.

Mudanças afetam controle, monitoramento, alerta e adaptação de modelos.

O instante da mudança pode ser tão importante quanto a existência da mudança.

Change point vs concept drift

Change point

Localizar o instante ou intervalo em que a dinâmica da série muda.

Concept drift

Monitorar mudanças que afetam a relação entre dados e modelo ao longo do tempo.

Na prática

Change point enfatiza segmentação; drift enfatiza validade e adaptação do modelo.


O que é um change point

É uma observação que marca transição entre dinâmicas distintas da série.

A mudança pode envolver distribuição, tendência, média, variância, volatilidade ou autocorrelação.

Quando a mudança é gradual, o ponto exato pode ser ambíguo.

Exemplo sintético com quatro change points



A série é dividida em cinco segmentos, com mudanças de volatilidade, tendência e regime.

Segmentos e dinâmicas distintas

Cada segmento pode ser interpretado como uma dinâmica temporal própria.

A detecção busca fronteiras que tornam os segmentos internamente mais homogêneos.

O problema é separar mudanças reais de flutuações locais ou ruído.

Tipos de mudança

Mudanças bruscas

Transição abrupta entre regimes.

Ponto de mudança mais fácil de localizar.

Comum em falhas, intervenções e quebras estruturais.

Mudanças graduais

Transição distribuída em um intervalo.

O instante exato é menos evidente.

Pode envolver tendência, deriva ou volatilidade.

Offline vs online

Offline

A série já foi coletada.

O objetivo é explicar quando as dinâmicas mudaram.

Pode usar informação antes e depois da mudança.

Online

As observações chegam em fluxo.

A decisão precisa ser rápida.

Há trade-off entre atraso e falso alarme.

Número de change points


Conhecido

- O problema é localizar m mudanças.
- Mais comum em análise offline controlada.
- Permite formular busca por melhores partições.

Desconhecido

- O método precisa decidir quantos segmentos existem.
- Superdetecção gera falsos positivos.
- Subdetecção gera falsos negativos.

Taxonomia de change point detection



Os métodos se organizam por busca via segmentação, regressão ou janelas deslizantes.

Busca por segmentação



Procura partições que tornem cada segmento internamente coerente.



Pode minimizar distância dentro dos segmentos ou maximizar diferença entre segmentos.



Quando o número de segmentos cresce, é preciso penalizar soluções muito fragmentadas.

Busca por regressão

Avalia breakpoints por meio de modelos ajustados aos segmentos.

Um bom breakpoint reduz erro ou melhora a qualidade de ajuste.

Chow Test e GFT são exemplos dessa família.

Busca por janelas deslizantes

Analisa subsequências de tamanho fixo ao longo da série.

Dentro da janela, testa-se se há diferença relevante entre antes e depois de um candidato.

SCP e Change Finder seguem essa intuição.

AMOC: intuição

AMOC procura uma única mudança em toda a série.

Cada candidato k divide X em dois segmentos.

A pergunta é se os dois segmentos explicam melhor os dados do que um único regime.

$$X_{1:n} \rightarrow X_{1:k} + X_{k+1:n}$$

AMOC: hipótese nula e alternativa

H0: sem mudança

A série é explicada por uma única distribuição.

Há um único conjunto de parâmetros θ_0 .

H1: mudança em k

Os segmentos antes e depois de k têm distribuições diferentes.

Cada segmento tem seus próprios parâmetros θ_1 e θ_2 .

AMOC: razão de verossimilhança

Compara o melhor ajuste com uma distribuição única contra o melhor ajuste dividido em dois segmentos.

O k ótimo maximiza o ganho de verossimilhança.

A decisão depende de um limiar para rejeitar a hipótese de ausência de mudança.

$$\lambda = 2 \cdot \left(\max_k ML(X, k) - ML(X) \right)$$

BinSeg: AMOC recursivo



Aplica AMOC para encontrar uma primeira mudança.



Depois repete o processo recursivamente nos segmentos gerados.



É guloso, eficiente e frequentemente útil como aproximação prática.

PELT: segmentação eficiente

- Busca uma segmentação ótima usando programação dinâmica.
- Usa penalização para evitar excesso de change points.
- Assume que os pontos de mudança crescem de forma controlada com o tamanho da série.

Chow Test: mudança estrutural

Parte de um modelo de regressão linear.

Testa se os parâmetros permanecem estáveis ou mudam ao longo do tempo.

É especialmente útil quando mudança significa quebra estrutural no modelo.

$$y_t = \beta_t x_t + \omega_t$$

Chow Test: estatística F

Ajusta um modelo para toda a série e modelos separados antes/depois do candidato.

Compara RSS e ESS para avaliar se a divisão reduz erro de forma significativa.

Um F alto indica evidência de mudança estrutural.

$$F = \frac{(RSS - ESS)}{ESS / (n - 2r)}$$

GFT/CUSUM: resíduos acumulados


Ajusta um modelo e acompanha flutuações acumuladas dos resíduos.

Sob estabilidade, o processo acumulado fica dentro de limites esperados.

Sob mudança, o processo tende a apresentar pico próximo ao change point.

$$W_n^0(u) = \frac{1}{\hat{\sigma}\sqrt{n}} \cdot \sum \hat{\omega}_i$$

SCP: estratégia com janela deslizante



Compara o ajuste de uma regressão única com regressões separadas antes e depois do candidato.

Change Finder: duas fases

1

Primeiro ajusta um modelo autoregressivo e identifica outliers nos resíduos.

2

Depois aplica média móvel aos resíduos para dar inércia ao sinal.

3

Uma segunda modelagem dos resíduos suavizados permite marcar change points.

Comparação dos detectores de change point

Verde indica acerto, azul indica evento perdido e vermelho indica detecção incorreta.

O que é concept drift



É uma mudança no conceito aprendido ou monitorado ao longo do tempo.



Afeta a validade de modelos em ambientes dinâmicos.



É central em cenários online, streaming e aprendizado adaptativo.

Conceito como distribuição

Considere dados D organizados em batches.

O conceito em um batch é representado pela distribuição associada aos dados observados.

Mudança de conceito significa mudança estatisticamente relevante nessa distribuição.


$$\text{concept}(SD_i) = p(\chi_i)$$


Drift como mudança entre distribuições

Entre batches consecutivos, o drift aparece quando as distribuições deixam de ser equivalentes.

A diferença pode ocorrer nos dados de entrada, na relação $X \rightarrow Y$ ou no erro do modelo.

$$p(\chi_i) \neq p(\chi_{i+1})$$

Taxonomia de concept drift



A taxonomia organiza tipos de drift, tipos de detector, métodos e formas de tratamento.

Drift real vs virtual

Virtual drift

A distribuição dos dados de entrada muda.

A relação com a variável-alvo pode permanecer válida.

Pode afetar representatividade e amostragem.





Real drift

A relação entre entrada e saída muda.

O modelo perde validade preditiva.

Normalmente exige adaptação ou retreinamento.

Tipos de drift



Drifts podem ser abruptos, incrementais, graduais ou recorrentes.

Detectar mudança vs adaptar modelo

Detectar drift responde se o conceito mudou.

Adaptar o modelo responde o que fazer depois da mudança.

Um detector sensível demais causa falso alarme; um detector conservador reage tarde.

Tipos de detector de drift

Baseados em erro

Monitoram queda de desempenho do modelo.

DDM, HDDM, CUSUM e ECDD seguem essa linha.

Dependem de rótulo ou feedback.


Baseados em distribuição

Comparam batches, janelas ou amostras.

MCDD, KLD, KSWIN, Page-Hinkley e ADWIN são exemplos.


Podem atuar antes do impacto no erro.

Tratamento de drift



Baseline não reage, passive atualiza continuamente e active atualiza após detecção.

Framework geral de drift detection



O framework combina dados em fluxo, monitoramento, detecção e eventual adaptação do modelo.

Quando atualizar o modelo

- Atualização contínua pode acompanhar mudanças, mas também absorver ruído.
- Atualização após alarme reduz custo, mas depende de boa detecção.
- A escolha depende de latência aceitável, custo de retreinamento e risco de falso alarme.

DDM e HDDM



DDM monitora a taxa de erro de um classificador ao longo do fluxo.



Aumento persistente do erro indica que o modelo deixou de representar o conceito atual.



HDDM usa desigualdades estatísticas para controlar detecção com limites probabilísticos.

Hoeffding bound: intuição

- Fornece um limite para diferenças esperadas entre estimativas amostrais.
- Se a diferença observada ultrapassa o limite, há evidência estatística de mudança.
- É útil em fluxo porque permite decisão incremental.

$$\Pr(|\bar{x} - E[x]| \geq \varepsilon) \leq 2 \exp(-2n\varepsilon^2)$$

CUSUM: evidência acumulada

Acumula desvios sucessivos em relação ao comportamento esperado.

Quando a soma acumulada ultrapassa um limiar, sinaliza mudança.

É simples, incremental e sensível a mudanças persistentes.

$$z_t = \max(0, z_{t-1} + \omega_t - \delta)$$

ECDD e MCDD

ECDD

Usa EWMA para suavizar a taxa de erro.

Detecta quando o seguidor se afasta do limite de controle.

Dá inércia ao monitoramento.

MCDD

Compara batches recentes e anteriores.

Avalia média e variância de variáveis preditoras.

Pode usar testes paramétricos ou não paramétricos.

Page-Hinkley e KSWIN

Page-Hinkley

- Variação do CUSUM.
- Acumula diferenças em relação à média corrente.
- Funciona bem para mudanças abruptas de média.

KSWIN

- Usa teste Kolmogorov-Smirnov.
- Compara distribuições de duas janelas.
- Não exige suposição paramétrica forte.

KLD: divergência entre distribuições

- Compara uma distribuição antiga P com uma distribuição recente Q.
- Mede o excesso de surpresa ao usar a distribuição esperada para explicar os dados atuais.
- Drift é indicado quando a divergência ultrapassa um limiar.

$$D_{KL}(P\|Q) = \sum P(x_i) \cdot \ln \left(\frac{P(x_i)}{Q(x_i)} \right)$$

ADWIN: janela adaptativa

- Mantém uma janela de tamanho variável sobre o fluxo.
- Divide a janela em partes antiga e recente para testar diferença estatística.
- Quando detecta mudança, descarta a parte antiga e mantém o conceito recente.

Comparação dos detectores de drift

Métodos baseados em erro e distribuição reagem a aspectos diferentes do mesmo processo.

Séries multivariadas e espaço-temporais



Mais dimensões aumentam a dificuldade de localizar e explicar mudanças.



Mudanças podem surgir nas relações entre variáveis, não apenas em cada série isolada.



Dados espaço-temporais adicionam dependência espacial, mobilidade e padrões regionais.

Métodos espectrais

PCA e autoencoders reduzem dimensionalidade e capturam representações compactas.




Drifts podem aparecer como mudança na reconstrução ou no espaço latente.

Esses métodos são promissores para séries multivariadas, não estacionárias e em fluxo.

Desafios práticos

- **Atraso:** detectar cedo o suficiente para agir.
- **Falso alarme:** evitar adaptação desnecessária.
- **Custo:** manter monitoramento e retreinamento viáveis.
- **Interpretação:** explicar que tipo de mudança ocorreu.

Referências Bibliográficas



Event Detection in Time Series

Ogasawara, E.; Salles, R.; Porto, F.;
Pacitti, E. Springer Nature Switzerland,
2025.

Time Series Analysis: With Applications in R

Cryer, J. D.; Chan, K.-S. Springer, 2008.

Data Mining: Concepts and Techniques

Han, J.; Pei, J.; Tong, H. Morgan
Kaufmann, 4^a ed., 2022.