

Detecção de Pontos de Mudança

Esta apresentação explora as complexidades da detecção de pontos de mudança, abordando diversos métodos de detecção.

Eduardo Ogasawara

eduardo.ogasawara@cefet-rj.br

<https://eic.cefet-rj.br/~eogasawara>

Definição

A detecção de pontos de mudança é um problema fundamental de estimação em séries temporais. Dada uma série observada, buscamos identificar os instantes onde a estrutura estatística dos dados muda significativamente.

Formalmente, definimos os instantes $\tau_1 < \tau_2 < \dots < \tau_k$ como pontos de mudança se os parâmetros do processo gerador diferem entre segmentos consecutivos. O conjunto $C = \{\tau_1, \dots, \tau_k\}$ particiona a série em $k+1$ segmentos estatisticamente homogêneos.

A estrutura que muda pode ser a média, a variância, a autocorrelação ou a distribuição completa dos dados — dependendo do modelo adotado para cada segmento.

Mudanças persistentes no processo gerador também aparecem em cenários online como drift. Neste curso, change points serão tratados aqui como mudanças estruturais localizáveis na série, enquanto drift será retomado na aula de detecção online, onde a ênfase está em fluxo, adaptação, latência e atualização da referência.

Teste de Hipóteses para Mudança Estrutural

Visão Estatística

Detectar mudança equivale a rejeitar a hipótese de estabilidade estrutural através de testes formais.

A detecção pode ser formulada como um teste de hipóteses: sob a hipótese nula, os parâmetros do processo não mudam ao longo do tempo. Sob a hipótese alternativa, existe pelo menos um instante onde os parâmetros sofrem ruptura.

$$H_0 : \theta(t) = \theta_0 \text{ para todo } t$$

$$H_1 : \exists \tau \text{ tal que } \theta(\tau) \neq \theta(\tau - 1)$$

Segmentação Ótima

A detecção de pontos de mudança pode ser transformada em um problema de otimização. Toda segmentação induz um custo total que combina o custo de ajuste do segmento $\mathcal{C}(\cdot)$ com uma penalização pela complexidade do modelo.

Custo por Segmento

Mede quão bem o modelo ajusta cada trecho da série através do custo de ajuste $\mathcal{C}(\cdot)$

Penalização

Controla o número de mudanças para evitar complexidade excessiva

Objetivo

Minimizar o custo total penalizado

Segmentações com muitos pontos ajustam melhor os dados, mas são mais complexas. A penalização β controla esse trade-off:

$$J(\mathcal{C}) = \sum_{i=0}^k \mathcal{C}(X_{\tau_i:\tau_{i+1}}) + \beta k$$

Estatísticas de Mudança

O coração de qualquer método de detecção é uma estatística que mede a discrepância entre segmentos. Construímos um "termômetro" que compara os dados antes e depois de cada tempo t .

A função ϕ pode representar diferença de médias, razão de verossimilhança ou divergência entre distribuições. A decisão ocorre quando o score ultrapassa o limiar de detecção h (reservando τ exclusivamente para indicar a localização do ponto de mudança):

$$S_t = \phi(X_{1:t}, X_{t+1:T})$$

$$S_t > h$$

Pipeline de Detecção

Representação

Transformar a série em uma forma adequada para análise

Cálculo de Score

Computar uma estatística que mede discrepância entre segmentos

Regra de Decisão

Identificar pontos de mudança quando o score ultrapassa o limiar

Todo método de detecção segue uma arquitetura comum com três etapas fundamentais. Primeiro transformamos a série em uma representação adequada, depois calculamos uma estatística de mudança, e finalmente aplicamos uma regra de decisão para identificar os pontos.

Essa decomposição ajuda a comparar métodos diferentes: alguns modificam a representação (trabalhando com resíduos ou embeddings), outros mudam a estatística de discrepância, e outros ajustam a regra de decisão.

Famílias de Métodos

Família	Ideia Central	Evidência Usada	Quando Aplicar
Testes Estatísticos	Comparam modelos com e sem quebra via estatística formal	Resíduos de regressão ou verossimilhança	Ponto de mudança suspeito é conhecido ou testado pontualmente
Acumuladores Sequenciais	Acumulam evidência incremental até ultrapassar um limiar	Resíduos ou desvios da média ao longo do tempo	Detecção online em tempo real com baixa latência
Otimização / Segmentação	Buscam a partição global que minimiza custo penalizado	Custo de ajuste por segmento + penalização	Número de mudanças desconhecido, análise offline
Modelos Probabilísticos	Tratam mudanças como variáveis latentes do modelo	Distribuição a posteriori sobre segmentações	Incerteza sobre localização das mudanças é relevante
Aprendizado de Máquina	Detectam ruptura como aumento persistente do erro de previsão do modelo treinado	Erro de previsão em representação aprendida	Séries complexas sem modelo paramétrico claro

Teste de Chow

Ideia Central

Se dois modelos separados ajustam muito melhor do que um único modelo, há evidência de quebra estrutural.

$$F = \frac{(RSS_T - RSS_1 - RSS_2)/k}{(RSS_1 + RSS_2)/(T - 2k)}$$

Sob H_0 , $F \sim F(k, T-2k)$. **RSS_T** é o resíduo do modelo completo; **RSS_1** e **RSS_2** são os resíduos de cada subsegmento; **k** é o número de parâmetros.

ENTRADA: série x , modelo de regressão, candidato τ

PRÉ-CONDIÇÃO: τ especificado a priori; resíduos homocedásticos

PASSO 1 — Ajuste dos três modelos

Ajustar modelo completo $\rightarrow$ **RSS_T**

Ajustar modelo em $x_{\{1:\tau\}} \rightarrow$ **RSS_1**

Ajustar modelo em $x_{\{\tau+1:T\}} \rightarrow$ **RSS_2**

PASSO 2 — Cálculo da estatística

$$F \leftarrow \frac{[(RSS_T - RSS_1 - RSS_2) / k]}{[(RSS_1 + RSS_2) / (T - 2k)]}$$

PASSO 3 — Regra de decisão

SE $F > F_{\{\alpha\}}(k, T-2k)$:

REJEITAR H_0 : há quebra estrutural em τ

SAÍDA: decisão sobre quebra em τ

PÓS-CONDIÇÃO: τ deve ser fixado antes do teste —
busca exaustiva sobre τ invalida o nível nominal α

CUSUM

Ideia Central

Acumula resíduos padronizados de um modelo de referência. Se a soma deriva persistentemente de zero, há mudança estrutural.

$$C_t = \sum_{i=1}^t \frac{\hat{e}_i}{\hat{\sigma}}$$

C_t cruza a banda crítica $\pm b\sqrt{T}$ para sinalizar quebra. A variante de quadrados detecta mudanças na variância.

ENTRADA: série x , modelo de referência M , limiar b

PRÉ-CONDIÇÃO: M ajustado no período estável inicial

PASSO 1 — Ajuste do modelo de referência

$\hat{\sigma} \leftarrow$ desvio padrão dos resíduos de M

PASSO 2 — Acumulação dos resíduos

$C_0 \leftarrow 0$

PARA t de 1 até T :

$\hat{e}_t \leftarrow x_t - \hat{y}_t$ // resíduo do modelo

$C_t \leftarrow C_{t-1} + \hat{e}_t / \hat{\sigma}$

PASSO 3 — Regra de decisão

SE $|C_t| > b \cdot \sqrt{T}$:

SINALIZAR mudança em t

REINICIAR $C_t \leftarrow 0$ // opcional: reset após detecção

SAÍDA: instantes t onde mudança foi sinalizada

PÓS-CONDIÇÃO: sob estabilidade estrutural, a estatística permanece dentro da banda crítica $\pm b \cdot \sqrt{T}$; cruzamentos persistentes indicam mudança.

Teste de Page-Hinkley

Ideia Central

Detecta desvio sustentado da média acumulando a diferença entre observações e a média de referência μ_0 estimada em período estável inicial, descontada uma tolerância δ .

$$m_t = \sum_{i=1}^t (x_i - \mu_0 - \delta)$$

$$PH_t = m_t - \min_{1 \leq i \leq t} m_i$$

δ absorve flutuações normais; λ controla sensibilidade.
Método online — $O(1)$ por observação.

ENTRADA: série x , tolerância δ , limiar λ

PRÉ-CONDIÇÃO: $\delta > 0, \lambda > 0$

PASSO 1 — Inicialização

$m_0 \leftarrow 0$; $\min_m \leftarrow 0$; $\mu_0 \leftarrow$ média da janela de referência (período pré-mudança)

PASSO 2 — Atualização incremental

PARA t de 1 até T :

$m_t \leftarrow m_{t-1} + (x_t - \mu_0 - \delta)$

$\min_m \leftarrow \min(\min_m, m_t)$

$PH_t \leftarrow m_t - \min_m$

PASSO 3 — Regra de decisão

SE $PH_t > \lambda$:

SINALIZAR mudança em t

REINICIAR $m, \min_m, \bar{x}$

SAÍDA: instantes t onde mudança foi sinalizada

PÓS-CONDIÇÃO: atraso de detecção cresce com λ

Razão de Verossimilhança

Ideia Central

Compara quão mais provável é a série com dois modelos distintos do que com um único: se a melhoria for grande, há mudança.

$$\Lambda(\tau) = 2 \left[\ell(\hat{\theta}_1, \hat{\theta}_2 \mid \tau) - \ell(\hat{\theta} \mid \text{sem quebra}) \right]$$

Sob H_0 , $\Lambda(\tau) \sim \chi^2(p)$ assintoticamente. Para τ desconhecido, usa-se $\sup_{\tau} \Lambda(\tau)$, que requer correção do p-valor (cota de Davies).

ENTRADA: série x , família de modelos, candidato τ (ou grade de candidatos)

PRÉ-CONDIÇÃO: modelo identificável; amostra suficiente em cada segmento

PASSO 1 — Ajuste do modelo irrestrito

Estimar $\hat{\theta}$ na série completa $\rightarrow \ell(\hat{\theta})$

PASSO 2 — Ajuste do modelo com quebra em τ

Estimar $\hat{\theta}_1$ em $x_{\{1:\tau\}}$ e $\hat{\theta}_2$ em $x_{\{\tau+1:T\}}$

Calcular $\ell(\hat{\theta}_1, \hat{\theta}_2 \mid \tau)$

PASSO 3 — Estatística e decisão

$\Lambda(\tau) \leftarrow 2 \cdot [\ell(\hat{\theta}_1, \hat{\theta}_2 \mid \tau) - \ell(\hat{\theta})]$

SE τ fixo: comparar $\Lambda(\tau)$ com $\chi^2_{\alpha}(p)$

SE τ livre: $\tau^* \leftarrow \operatorname{argmax}_{\tau} \Lambda(\tau)$; aplicar cota de Davies

SAÍDA: τ^* e decisão sobre quebra estrutural

PÓS-CONDIÇÃO: generaliza o Teste de Chow para qualquer família de modelos

Programação Dinâmica para Segmentação

Ideia Central

Encontra a partição globalmente ótima minimizando custo de ajuste penalizado pelo número de cortes.

$$V(t) = \min_{1 \leq s < t} [V(s) + \mathcal{C}(s+1, t) + \beta]$$

β controla o trade-off entre ajuste e complexidade. BIC sugere $\beta = p \cdot \log T$; PELT reduz complexidade de $\mathbf{O}(T^2)$ para $\mathbf{O}(T)$ via poda.

ENTRADA: série x , função de custo $\mathcal{C}(\cdot, \cdot)$, penalização β

PRÉ-CONDIÇÃO: $\mathcal{C}(s, t)$ computável em $\mathbf{O}(1)$ após pré-processamento

PASSO 1 — Inicialização

$V(0) \leftarrow 0$; $cp(0) \leftarrow []$

PASSO 2 — Recursão (PELT)

PARA t de 1 até T :

 candidatos $\leftarrow \{s \in \text{admissíveis} : s < t\}$

 PARA cada s em candidatos:

$\text{custo}(s) \leftarrow V(s) + \mathcal{C}(s+1, t) + \beta$

$s^* \leftarrow \text{argmin } \text{custo}(s)$

$V(t) \leftarrow \text{custo}(s^*)$

$cp(t) \leftarrow cp(s^*) \cup \{s^*\}$

 PODAR candidatos segundo a regra de PELT

PASSO 3 — Recuperação dos pontos

RETORNAR $cp(T)$

SAÍDA: conjunto ótimo de pontos de mudança

PÓS-CONDIÇÃO: solução globalmente ótima para o β dado

Detecção Bayesiana (BOCPD)

Ideia Central

Trata pontos de mudança como variáveis latentes e mantém uma distribuição sobre o comprimento do segmento atual (run-length r_t).

$$P(r_t \mid x_{1:t}) \propto \sum_{r_{t-1}} P(x_t \mid r_{t-1}, x^{(r)}) P(r_t \mid r_{t-1}) P(r_{t-1} \mid x_{1:t-1})$$

ENTRADA: série x , hazard rate h , modelo preditivo

PRÉ-CONDIÇÃO: $h \in (0,1)$; modelo com atualização conjugada

PASSO 1 — Inicialização

$P(r_0 = 0) \leftarrow 1$

PASSO 2 — Atualização recursiva

PARA t de 1 até T :

$\pi(r) \leftarrow P(x_t \mid r, x^{(r)}) \cdot P(r_{t-1} = r \mid x_{1:t-1})$

$P(r_t = r+1) \leftarrow \pi(r) \cdot (1 - h)$ // segmento continua

$P(r_t = 0) \leftarrow \sum_r \pi(r) \cdot h$ // mudança ocorre

NORMALIZAR $P(r_t)$

PASSO 3 — Decisão

SE $P(r_t = 0) > \text{limiar}$: SINALIZAR mudança em t

SAÍDA: $P(r_t)$ para todo t ; instantes de mudança detectados

PÓS-CONDIÇÃO: incerteza sobre localização explicitamente quantificada

Change Points via HMM

Ideia Central

Modela a série como alternância entre K regimes ocultos. Uma mudança estrutural é uma transição de estado latente z_t .

$$P(z_t \mid z_{t-1}) = A_{z_{t-1}, z_t}$$

$$P(x_t \mid z_t) = \mathcal{N}(x_t; \mu_{z_t}, \Sigma_{z_t})$$

Viterbi recupera a sequência de estados mais provável; Baum-Welch (EM) estima A, μ, Σ . Transições $z_t^* \neq z_{t-1}^*$ indicam mudança de regime. Como o mesmo estado pode ser revisitado, o HMM não representa apenas rupturas permanentes — é adequado para séries com regimes recorrentes.

ENTRADA: série x , número de estados K

PRÉ-CONDIÇÃO: K definido a priori; parâmetros inicializados (e.g., K-means)

// BAUM-WELCH (estimação de parâmetros)

PASSO 1 — E-step: Forward-Backward

PARA t de 1 até T :

$\alpha_t(k) \leftarrow P(x_{1:t}, z_t=k)$ // forward

$\beta_t(k) \leftarrow P(x_{t+1:T} \mid z_t=k)$ // backward

$\gamma_t(k) \leftarrow \alpha_t(k) \cdot \beta_t(k) / P(x)$ // suavização

PASSO 2 — M-step: atualização

$A_{\{ij\}} \leftarrow \sum_t \xi_t(i,j) / \sum_t \gamma_t(i)$

$\mu_k \leftarrow \sum_t \gamma_t(k) \cdot x_t / \sum_t \gamma_t(k)$

REPETIR até convergência

// VITERBI (decodificação)

PASSO 3 — Sequência ótima

$z^* \leftarrow \operatorname{argmax}_{\{z\}} P(z \mid x, A, \mu, \Sigma)$

SAÍDA: sequência z^* ; pontos de mudança onde $z_t^* \neq z_{t-1}^*$

PÓS-CONDIÇÃO: mesmo regime pode reaparecer ao longo da série

Change Points via Machine Learning

Ideia Central

Treina um modelo no comportamento típico da série. Quando o erro de previsão agregado em janela aumenta persistentemente, há mudança de regime.

$$S_t = \frac{1}{w} \sum_{i=t-w+1}^t \|x_i - f(x_{i-1}, \dots, x_{i-p})\|$$

S_t excedendo o limiar h (derivado da distribuição de erros de referência) sinaliza mudança. O score em janela evita confundir anomalias pontuais com rupturas estruturais. A abordagem é agnóstica ao modelo gerador — captura mudanças em estruturas não-lineares e de alta ordem.

ENTRADA: série x , modelo f , tamanho de janela w , limiar h

PRÉ-CONDIÇÃO: f treinado em janela de referência estável

PASSO 1 — Estimação do limiar de referência

Calcular erros $e_i = \|x_i - f(x_{i-1:i-p})\|$ na janela de referência

$h \leftarrow$ percentil alto da distribuição de $\{e_i\}$

PASSO 2 — Monitoramento online

PARA t de w até T :

$S_t \leftarrow$ média de $e_{\{t-w+1\}}, \dots, e_t$

PASSO 3 — Regra de decisão

SE $S_t > h$:

SINALIZAR mudança em t


SAÍDA: instantes t onde mudança foi sinalizada

PÓS-CONDIÇÃO: w controla sensibilidade — janelas maiores reduzem falsos positivos mas aumentam atraso

Comparação entre Detectores

AMOC e Chow test são projetados para detectar uma única quebra — retornam apenas o ponto de maior evidência. PELT e BinSeg permitem múltiplas quebras, com sensibilidades distintas controladas pela penalização.

GFT, SCP e CFETS são métodos alternativos com comportamentos intermediários. Os pontos azuis marcam o início de cada segmento; verdes indicam detecções próximas à mudança real; vermelhos indicam detecções adicionais ou tardias.



Detecção Offline vs Online

A diferença fundamental está na **disponibilidade da informação** no momento da decisão.

Modo Offline

Toda a série está disponível — é possível olhar para frente e para trás ao mesmo tempo, permitindo encontrar a segmentação **globalmente ótima**.




Modo Online

Dados chegam incrementalmente — decisões são tomadas em tempo real, sem acesso ao futuro, exigindo estatísticas que **atualizam a cada nova observação**.

Uma consequência inerente ao modo online é o atraso de detecção: há sempre um intervalo entre a ocorrência da mudança e o momento em que a estatística cruza o limiar h .

Em cenários offline, mudanças persistentes costumam ser modeladas como pontos de mudança localizáveis na série. Em cenários online, esse mesmo fenômeno pode manifestar-se como drift — uma degradação gradual do modelo de referência. A detecção de drift, com ênfase em fluxo, adaptação e atualização incremental, será retomada na aula de detecção online.

Referências Bibliográficas



Event Detection in Time Series

Ogasawara, E.; Salles, R.; Porto, F.; Pacitti, E.
Springer Nature Switzerland, 2025.

Time Series Analysis: With Applications in R

Cryer, J. D.; Chan, K.-S. Springer, 2008.

Data Mining: Concepts and Techniques

Han, J.; Pei, J.; Tong, H. Morgan Kaufmann, 4^a ed., 2022.