



Eventos em Séries Temporais

Uma série temporal é entendida como um processo cujo comportamento é descrito por um modelo. Quando o comportamento observado diverge de forma relevante do comportamento esperado, define-se um evento.

Eduardo Ogasawara

eduardo.ogasawara@cefet-rj.br

<https://eic.cefet-rj.br/~eogasawara>

REPRESENTAÇÃO AVANÇADA

Componentes Temporais Instantâneos

Em vez de analisar apenas os valores observados, define-se um conjunto de componentes temporais instantâneos. O comportamento esperado é modelado nesse espaço, permitindo definir eventos como desvios nos componentes, e não apenas nos valores brutos da série.

$$tc(x_t) \in \{x_t, tr(x_t), v(x_t)\}$$

$$ep(tc(x_t), k) = \mathbb{E}(tc(x_t) | tc(x_{t-1}), \dots, tc(x_{t-k}))$$

Valor Observado

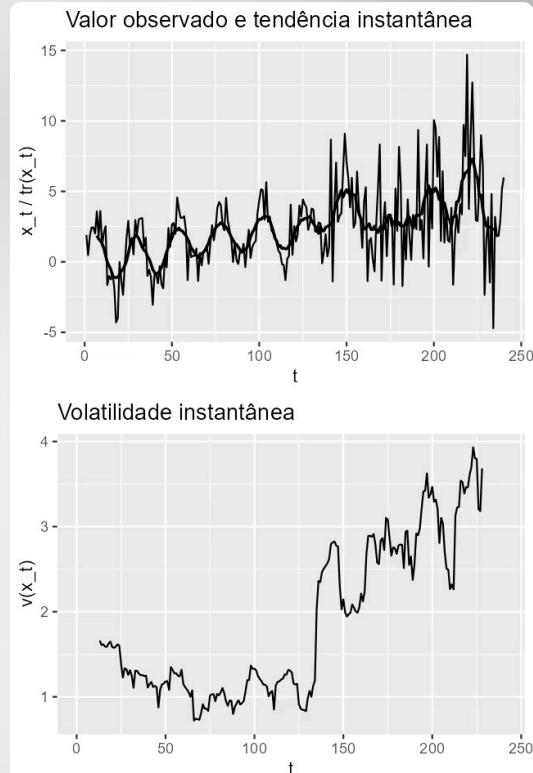
$$x_t$$

Tendência Instantânea

$$tr(x_t)$$

Volatilidade Instantânea

$$v(x_t)$$



Evento como Desvio Temporal

Um evento ocorre quando o componente temporal observado diverge do comportamento esperado pelo modelo. Essa definição permite unificar diferentes tipos de eventos como casos particulares de desvios temporais.

Observed Component

Actual temporal signal measured from system

Expected Component

Model-predicted temporal behavior baseline

A função de desvio generaliza tipos de eventos e permite a unificação de diferentes classes sob uma mesma estrutura conceitual.

$$tc(x_t) \not\approx ep(tc(x_t), k)$$

$$e_t = f(tc(x_t), ep(tc(x_t), k))$$

- **Definição formal:** $tc(x_t)$ é o componente temporal observado, $ep(tc(x_t), k)$ é a expectativa do componente temporal, e_t é o evento no tempo t , e $f(\cdot)$ é a função de desvio.

Natureza dos Eventos

Eventos podem ser caracterizados pela natureza da perturbação que introduzem no processo. Perturbações sistemáticas definem eventos determinísticos, enquanto perturbações com distribuição distinta do ruído definem eventos estocásticos.

Determinístico

Estrutura sistemática e previsível

Estocástico

Perturbação aleatória com distribuição distinta

$$x_t = S_t + \varepsilon_t + \delta_t$$

$$\delta_t \sim G, \quad \varepsilon_t \sim F, \quad G \neq F$$

Onde S_t é o componente estrutural, ε_t é o ruído do processo, δ_t é o componente do evento, e F, G são distribuições de probabilidade distintas.

Eventos Observáveis e Latentes

Eventos Observáveis

Visíveis diretamente na série temporal original

Eventos Latentes

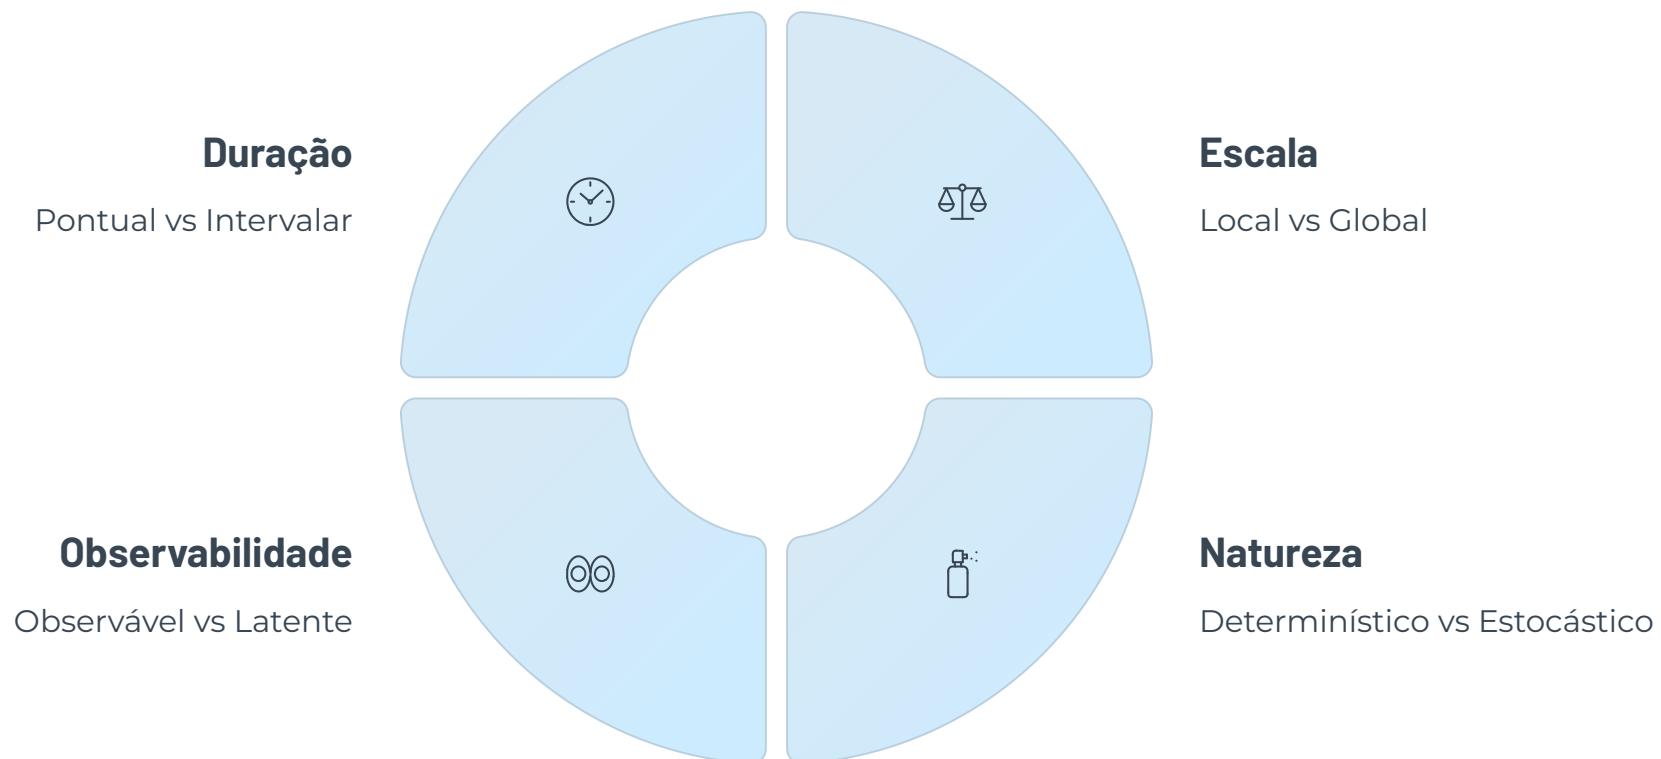
Visíveis apenas em representações transformadas como resíduos, decomposições ou modelos de estado

$$e_t \in \mathcal{E}(X_t) \quad \text{ou} \quad e_t \in \mathcal{E}(\mathcal{R}(X_t))$$

Nem todos os eventos são diretamente observáveis nos valores da série. Alguns só emergem em representações transformadas, evidenciando o papel fundamental da representação temporal na detecção de eventos.

Tipologia Formal de Eventos

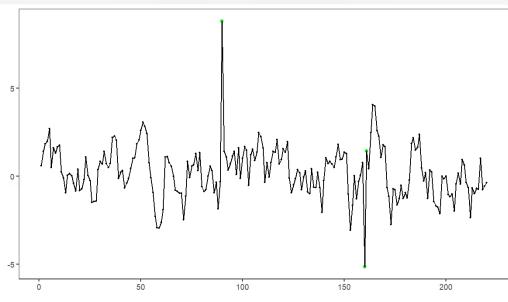
A tipologia de eventos resulta da combinação de múltiplos critérios. Essa classificação mostra que eventos não são entidades únicas, mas objetos definidos em várias dimensões conceituais.



$$\mathcal{E} = \mathcal{E}_{dur} \times \mathcal{E}_{esc} \times \mathcal{E}_{nat} \times \mathcal{E}_{obs}$$

Anomalias

Anomalias são eventos caracterizados por desvios abruptos em relação ao comportamento esperado pelo modelo. Elas são identificadas por resíduos cuja magnitude ultrapassa um limiar definido por critérios estatísticos.



Desvio Pontual

Significativo e localizado

Espaço Residual

Definida nos resíduos

Evento Local

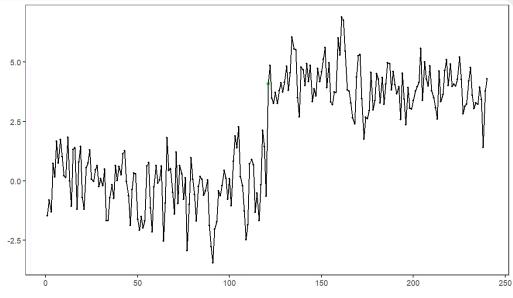
Instantâneo no tempo

Limiar Estatístico

Critério de detecção

$$r_t = x_t - \hat{x}_t, \quad |r_t| > \tau$$

Pontos de Mudança



Pontos de mudança correspondem a instantes em que os parâmetros do processo gerador de dados se alteram de forma persistente, caracterizando transições entre regimes temporais distintos.

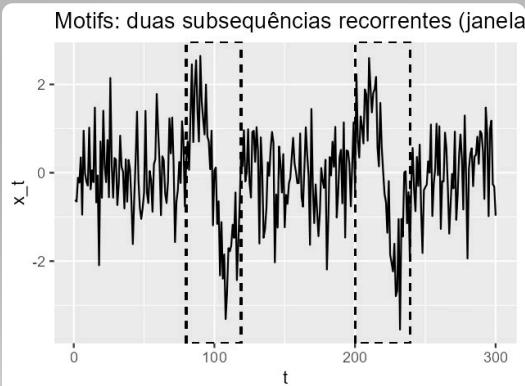
Representam mudanças estruturais no processo, com alteração persistente de parâmetros e transição entre regimes. São eventos globais que afetam o comportamento futuro da série.

$$x_t \sim F_{\theta(t)}$$

$$\theta(t) = \begin{cases} \theta_1, & t \leq \tau, \\ \theta_2, & t > \tau, \end{cases} \quad \theta_1 \neq \theta_2$$

Motifs

Motifs correspondem a padrões que se repetem ao longo da série. Eles são definidos pela similaridade entre subsequências, caracterizando eventos intervalares associados à recorrência estrutural.



01

Padrões Recorrentes

Identificação de estruturas que se repetem

02

Subsequências Similares

Baseados em métricas de distância

03

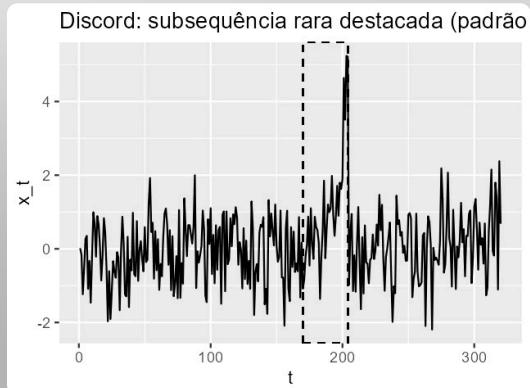
Eventos Intervalares

Recorrência ao longo do tempo

$$d(s_i, s_j) < \epsilon$$

Onde s_i, s_j são subsequências da série, $d(\cdot, \cdot)$ é uma métrica de distância, e ϵ é o limiar de similaridade.

Discords



Padrões Raros

Discords representam subsequências que são muito diferentes das demais. Eles são definidos como padrões raros, caracterizando eventos intervalares que se destacam pela ausência de similaridade.

$$D(s) = \min_{u \neq s} d(s, u), \quad s^* = \arg \max_s D(s)$$

Onde s é uma subsequência, $D(s)$ é a distância mínima de s às demais subsequências, e s^* é a subsequência discord.

Distância Máxima

Definidos por afastamento

Atípicos

Eventos intervalares raros

Opostos aos Motifs

Ausência de similaridade

Unificação das Classes de Eventos

As principais classes de eventos podem ser organizadas em um conjunto unificado. Cada classe corresponde a uma forma específica de estrutura temporal, revelando diferentes tipos de desvios e padrões.

Anomalias

Desvios pontuais significativos

Pontos de Mudança

Rupturas estruturais persistentes

Motifs

Padrões recorrentes similares

Discords

Padrões raros e atípicos

$$\mathcal{E} = \mathcal{E}_{anom} \cup \mathcal{E}_{cp} \cup \mathcal{E}_{motif} \cup \mathcal{E}_{discord}$$

Cenários de Detecção

A forma como os dados são observados define o cenário de detecção. Cada cenário impõe restrições computacionais e conceituais distintas, influenciando os métodos utilizados.



Detecção Offline

Série completa disponível para análise retrospectiva



Detecção Online

Fluxo contínuo de dados em tempo real



Detecção Preditiva

Antecipação de eventos futuros

$$\mathbb{P}(e_{t+h} = 1 \mid \mathcal{F}_t)$$

Onde e_{t+h} é o evento futuro, \mathcal{F}_t é a informação disponível no tempo t , e $\mathbb{P}(\cdot)$ é a probabilidade.

Classes de Métodos

Os métodos de detecção podem ser interpretados como funções que transformam representações temporais em eventos. Cada classe corresponde a uma forma distinta de modelar tipicidade e desvio.



Métodos Estatísticos

Baseados em distribuições e testes de hipótese



Baseados em Distância

Utilizam métricas de similaridade e dissimilaridade



Baseados em Modelos

Constroem modelos preditivos do processo



Aprendizado de Máquina

Redes neurais e algoritmos de aprendizado

$$\mathcal{D} : \mathcal{R}(X_t) \longrightarrow \mathcal{E}$$

Avaliação da Detecção

A avaliação de métodos de detecção exige métricas que comparem eventos detectados com eventos reais. Além disso, o tempo de detecção é fundamental, pois eventos possuem natureza temporal.

Métricas de Conjunto

$$\text{Precision} = \frac{|\hat{\mathcal{E}} \cap \mathcal{E}|}{|\hat{\mathcal{E}}|}$$

$$\text{Recall} = \frac{|\hat{\mathcal{E}} \cap \mathcal{E}|}{|\mathcal{E}|}$$

Tempo de Detecção

$$\Delta t = t_{det} - t_{real}$$



Precisão

Proporção de eventos detectados que são reais



Recall

Proporção de eventos reais que foram detectados

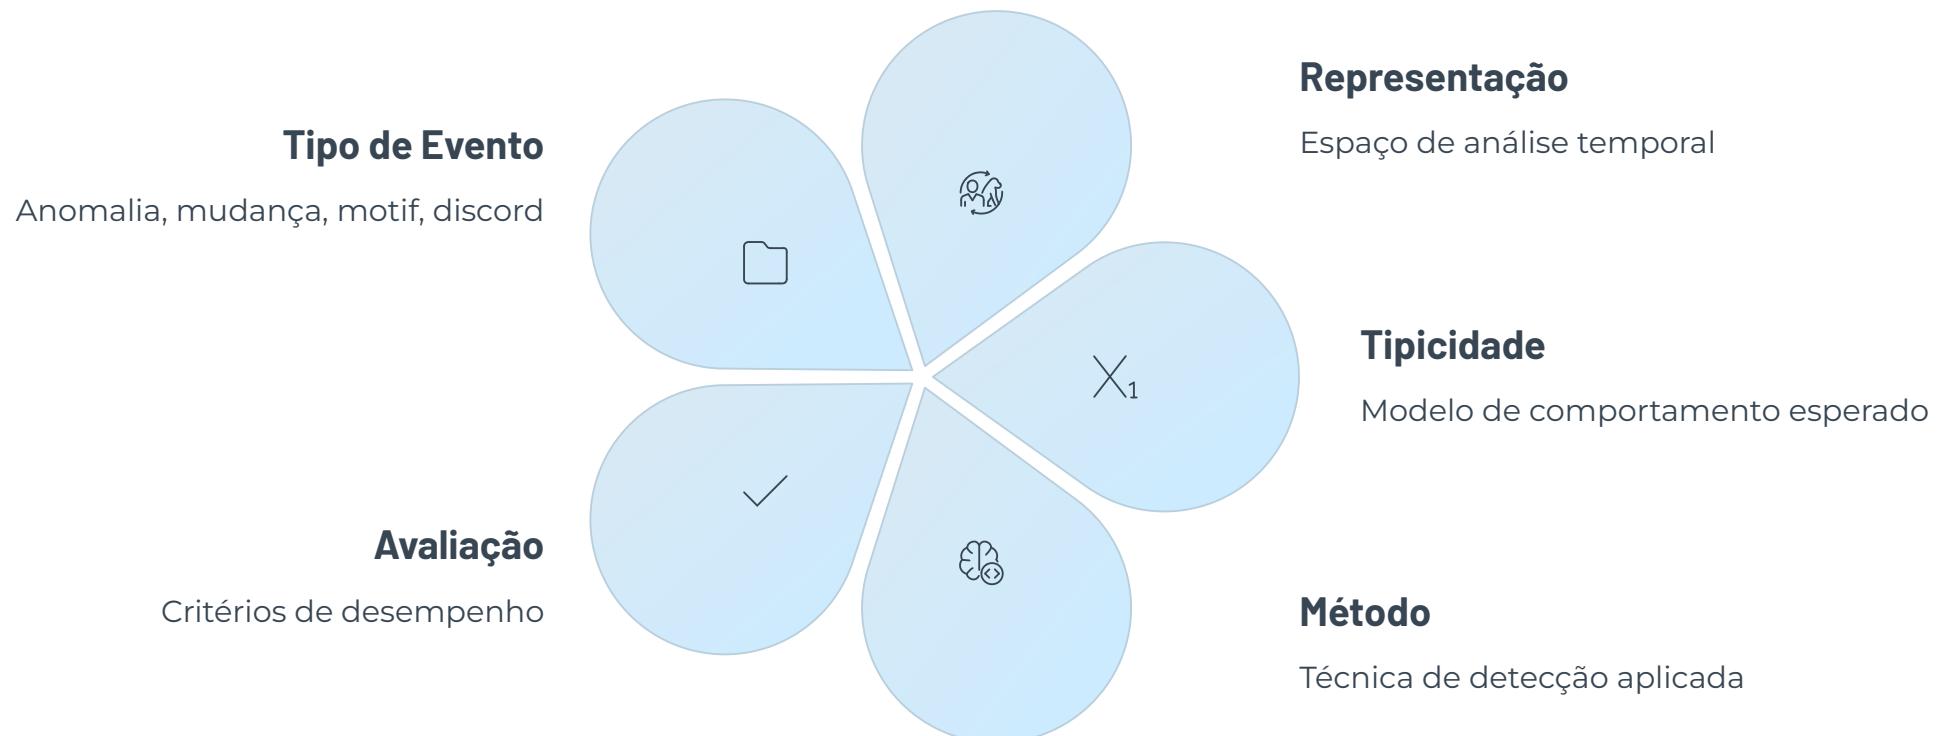


Latência

Diferença temporal entre ocorrência e detecção

Taxonomia da Detecção de Eventos

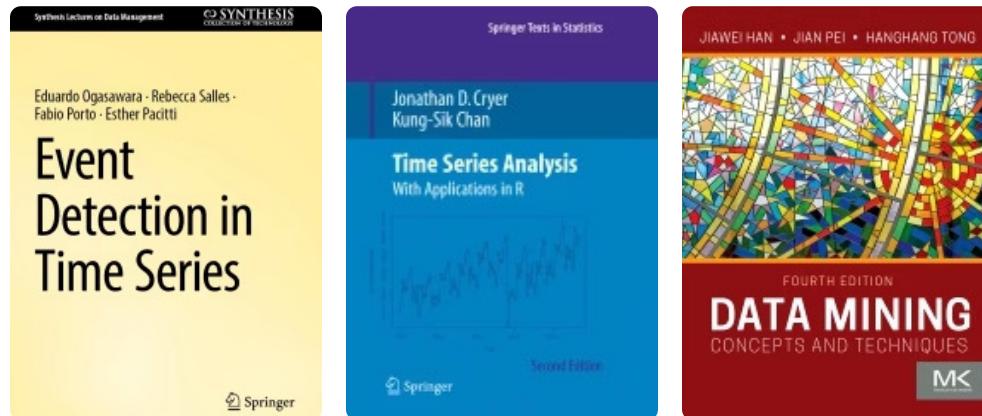
A detecção de eventos pode ser formalizada como um problema multidimensional. Cada dimensão representa uma escolha conceitual que define a forma como eventos são modelados e detectados.



$$\text{Event Detection} = (\mathcal{E}, \mathcal{R}, \mathcal{M}, \mathcal{D}, \mathcal{A})$$

Referências Bibliográficas

Uma coleção cuidadosamente selecionada de obras fundamentais que abordam análise de séries temporais e mineração de dados.



Event Detection in Time Series

Ogasawara, E.; Salles, R.; Porto, F.; Pacitti,

E. (2025). Publicação recente da Springer Nature Switzerland que explora técnicas avançadas de detecção de eventos em séries temporais.

Time Series Analysis: With Applications in R

Cryer, J. D.; Chan, K.-S. (2008). Obra clássica da Springer que combina fundamentação teórica sólida com implementações práticas.

Data Mining: Concepts and Techniques

Han, J.; Pei, J.; Tong, H. (2022). Quarta edição publicada pela Morgan Kaufmann que consolida conceitos fundamentais e técnicas avançadas de mineração de dados.