



Eventos em Séries Temporais

Uma série temporal é entendida como um processo cujo comportamento é descrito por um modelo. Quando o comportamento observado diverge de forma relevante do comportamento esperado, define-se um evento.

Eduardo Ogasawara

eduardo.ogasawara@cefet-rj.br

<https://eic.cefet-rj.br/~eogasawara>

Evento como Desvio Temporal

A Ideia Central

Um evento ocorre quando o componente temporal analisado diverge do valor esperado pelo modelo. A função de desvio $f(\cdot)$ unifica diferentes classes de eventos sob uma mesma estrutura formal.

$$\text{componente}_t \not\approx \text{esperado}_t$$

$$\text{score}_t = f(\text{componente}_t, \text{esperado}_t)$$

- componente_t = $tc(x_t)$ é o componente temporal analisado (valor, tendência ou volatilidade);
esperado_t = $ep(tc(x_t), k)$ é o valor esperado para esse componente dado o histórico de ordem k; score_t = e_t é o desvio observado no instante t; $f(\cdot)$ é a função de desvio.

Detecção Genérica de Evento

ENTRADA: x (série temporal), k (ordem da expectativa)

PRÉ-CONDIÇÃO: modelo de expectativa ep definido para tc

PASSO 1 — Transformação e detecção (para cada t)

PARA t de k+1 até T:

componente_t ← tc(x_t)

esperado_t ← ep(componente_{t-1}, ..., componente_{t-k})

score_t ← f(componente_t, esperado_t)

SE score_t significativo:

registrar evento em t

SAÍDA: conjunto de eventos $E = \{(t, \text{score}_t) \mid \text{score}_t \text{ significativo}\}$

PÓS-CONDIÇÃO: cada score_t representa um desvio classificável

Natureza dos Eventos

Eventos podem ser caracterizados pela natureza da perturbação que introduzem no processo. Perturbações sistemáticas definem eventos determinísticos; perturbações que alteram a distribuição do comportamento observado em relação ao ruído usual definem eventos estocásticos.

Determinístico

Perturbação com estrutura sistemática e previsível

Estocástico

Perturbação que altera a distribuição observada em relação ao ruído usual do processo

$$x_t = S_t + \varepsilon_t + \delta_t$$

$$\delta_t \sim G, \quad \varepsilon_t \sim F, \quad G \neq F$$

Onde S_t é o componente estrutural, $\varepsilon_t \sim F$ é o ruído usual do processo, e $\delta_t \sim G$ é a componente associada ao evento, com $G \neq F$.

Eventos Observáveis e Latentes

Eventos Observáveis

Visíveis diretamente na série temporal original

Eventos Latentes

Visíveis apenas em representações transformadas como resíduos, decomposições ou modelos de estado

$$e_t \in \mathcal{E}(X) \quad (\text{observável}) \quad \text{ou} \quad e_t \in \mathcal{E}(\mathcal{R}(X)) \quad (\text{latente})$$

Eventos observáveis emergem diretamente nos valores de X . Eventos latentes só se tornam visíveis em representações transformadas $\mathcal{R}(X)$, como resíduos, decomposições ou espaços de estado.

Tipologia Formal de Eventos

Eventos em séries temporais são classificados segundo quatro critérios independentes. Cada critério define um eixo de variação que, combinado, determina a natureza do evento observado.

Intensidade

Fraca vs. Forte

Persistência

Transitório vs. Persistente

Extensão Temporal

Pontual vs. Intervalar

Estrutura

Aleatória vs. Sistemática

Anomalias

A Ideia Central

Uma anomalia é um desvio pontual nos resíduos do modelo. O resíduo r_t é comparado a um limiar τ : se sua magnitude o ultrapassa, o instante t é classificado como anomalia.

$$r_t = x_t - \hat{x}_t, \quad |r_t| > \tau$$

τ pode ser estimado como múltiplo do desvio padrão dos resíduos em dados de treinamento (ex: 3σ). Anomalias são eventos locais, pontuais e de baixa persistência — mesmo quando têm causa sistemática.

Detecção de Anomalias por Limiar Residual

ENTRADA: x (série temporal, comprimento T), k (defasagem), τ (limiar)

PRÉ-CONDIÇÃO: modelo preditivo ajustado em dados de treinamento; $\tau > 0$

PASSO 1 — Previsão e resíduo (evita histórico insuficiente)

PARA t de $k+1$ até T :

$\hat{x}_t \leftarrow \text{modelo.prever}(x_{\{t-k\}}, \dots, x_{\{t-1\}})$

$r_t \leftarrow x_t - \hat{x}_t$

PASSO 2 — Detecção

$\text{anomalias} \leftarrow \{\}$

PARA t de $k+1$ até T :

SE $|r_t| > \tau$:

$\text{anomalias} \leftarrow \text{anomalias} \cup \{t\}$

SAÍDA: conjunto de instantes anômalos

PÓS-CONDIÇÃO: cada t em anomalias satisfaz $|r_t| > \tau$

Pontos de Mudança

A Ideia Central

Um ponto de mudança é um instante τ em que os parâmetros do processo gerador se alteram de forma persistente. A série passa de um regime θ_1 para um regime θ_2 distinto.

$$x_t \sim F_{\theta(t)}$$
$$\theta(t) = \begin{cases} \theta_1, & t \leq \tau, \\ \theta_2, & t > \tau, \end{cases} \quad \theta_1 \neq \theta_2$$

Pontos de mudança são eventos pontuais, persistentes e de estrutura sistemática.

Detecção de Ponto de Mudança

ENTRADA: x (série temporal de comprimento T)

PRÉ-CONDIÇÃO: função de custo C definida (ex: variância intra-segmento)

PASSO 1 — Custo sem divisão

$C_{\text{total}} \leftarrow C(x_1, \dots, x_T)$

PASSO 2 — Varredura por ganho de segmentação

$\text{melhor_ganho} \leftarrow 0$

PARA τ de 1 até $T-1$:

$C_{\text{esq}} \leftarrow C(x_1, \dots, x_\tau)$

$C_{\text{dir}} \leftarrow C(x_{\tau+1}, \dots, x_T)$

$\text{ganho}_\tau \leftarrow C_{\text{total}} - (C_{\text{esq}} + C_{\text{dir}})$

SE $\text{ganho}_\tau > \text{melhor_ganho}$:

$\text{melhor_ganho} \leftarrow \text{ganho}_\tau$

$\tau^* \leftarrow \tau$

PASSO 3 — Validação

SE $\text{melhor_ganho} > \text{limiar}$:

registrar ponto de mudança em τ^*

SAÍDA: instante τ^* de ruptura estrutural

PÓS-CONDIÇÃO: $\theta(t \leq \tau^*) \neq \theta(t > \tau^*)$

Motifs

A Ideia Central

Motifs são pares de subsequências similares que se repetem ao longo da série. A similaridade é medida por uma métrica de distância d : se $d(s_i, s_j) < \epsilon$, o par forma um motif.

$$d(s_i, s_j) < \epsilon$$

Motifs são eventos intervalares, recorrentes e de estrutura sistemática. O comprimento m é um parâmetro de entrada. A formulação abaixo é didática — implementações eficientes usam estruturas como Matrix Profile.

Busca de Motifs por Força Bruta (formulação didática)

ENTRADA: x (série temporal), m (comprimento), ϵ (limiar)

PRÉ-CONDIÇÃO: $m < T/2$, $\epsilon > 0$, $d(\cdot, \cdot)$ definida

PASSO 1 — Extração de subsequências

$S \leftarrow \{s_i = x[i : i+m-1] \mid i = 1, \dots, T-m+1\}$

PASSO 2 — Busca por pares similares (com zona de exclusão)

$\text{motifs} \leftarrow \{\}$

PARA cada par (s_i, s_j) com $|i - j| \geq m$:

SE $d(s_i, s_j) < \epsilon$:

$\text{motifs} \leftarrow \text{motifs} \cup \{(i, j)\}$

PASSO 3 — Seleção do motif principal

$\text{motif}^* \leftarrow \text{par}(i, j) \text{ com menor } d(s_i, s_j)$

SAÍDA: conjunto de pares motif e motif principal

PÓS-CONDIÇÃO: todo par em motifs satisfaz $d < \epsilon$ e $|i-j| \geq m$

Discords

A Ideia Central

Um discord é a subsequência mais isolada de todas as demais. Define-se $D(s)$ como a menor distância de s a qualquer outra subsequência não sobreposta: o discord é aquele com maior $D(s)$.

$$D(s) = \min_{|i-j| \geq m} d(s, u), \quad s^* = \arg \max_s D(s)$$

Discords são eventos intervalares, atípicos e de baixa recorrência — o oposto complementar dos motifs. A formulação abaixo é didática.

Busca de Discord por Força Bruta (formulação didática)

ENTRADA: x (série temporal), m (comprimento)

PRÉ-CONDIÇÃO: $m < T$, $d(\cdot, \cdot)$ definida

PASSO 1 — Extração de subsequências

$S \leftarrow \{s_i = x[i : i+m-1] \mid i = 1, \dots, T-m+1\}$

PASSO 2 — Distância mínima com zona de exclusão

PARA cada s_i em S :

$D(s_i) \leftarrow \min\{d(s_i, s_j) \mid |i - j| \geq m\}$

PASSO 3 — Seleção do discord

$s^* \leftarrow \operatorname{argmax}\{D(s_i) \mid s_i \text{ em } S\}$

PASSO 4 — Validação

SE $D(s^*) > \text{limiar}$:

registrar s^* como discord

SAÍDA: subsequência discord s^* e sua distância $D(s^*)$

PÓS-CONDIÇÃO: s^* é a subsequência mais isolada segundo d e os parâmetros escolhidos

Unificação das Classes de Eventos


Anomalias, pontos de mudança, motifs e discords são todos eventos — mas definidos por representações e critérios distintos. O que os unifica é a noção de desvio em relação a um comportamento esperado.

Classe	Intensidade	Persistência	Extensão Temporal	Estrutura
Anomalia	Forte	Transitória	Pontual	Aleatória
Ponto de Mudança	Variável	Persistente	Pontual	Sistemática
Motif	Variável	Recorrente	Intervalar	Sistemática
Discord	Forte	Transitório	Intervalar	Aleatória

$$\mathcal{E} = \mathcal{E}_{anom} \cup \mathcal{E}_{cp} \cup \mathcal{E}_{motif} \cup \mathcal{E}_{discord}$$


Nota: as classes acima são formas complementares de representar fenômenos temporais. Na prática, podem se sobrepor ou depender do objetivo analítico — um mesmo instante pode ser anomalia em uma representação e ponto de mudança em outra.

Referências Bibliográficas




Event Detection in Time Series

Ogasawara, E.; Salles, R.; Porto, F.; Pacitti, E.
Springer Nature Switzerland, 2025.



Time Series Analysis: With Applications in R

Cryer, J. D.; Chan, K.-S. Springer, 2008.



Data Mining: Concepts and Techniques

Han, J.; Pei, J.; Tong, H. Morgan Kaufmann, 4^a ed., 2022.