




Anomalias em Séries Temporais

Nesta apresentação, exploraremos o fascinante mundo das anomalias em séries temporais, entendendo o que são e como detectá-las.

Eduardo Ogasawara

eduardo.ogasawara@cefet-rj.br

<https://eic.cefet-rj.br/~eogasawara>

Comportamento Típico e Anomalia


A noção de anomalia nasce da noção de comportamento típico. Um modelo temporal define o que é esperado, e a previsão condicional estabelece o comportamento esperado para cada instante.

O resíduo r_t mede o desvio entre o observado e o esperado. Uma anomalia ocorre quando esse desvio não é compatível com o que o próprio modelo considera típico.

Formalmente, a série $X = \{x_t\}$ contém um conjunto de eventos $\mathcal{E}$, e as anomalias formam um subconjunto: $\mathcal{A} \subset \mathcal{E}$.

$$\hat{x}_t = \mathbb{E}[x_t \mid \mathcal{F}_{t-1}, \mathcal{M}], \quad r_t = x_t - \hat{x}_t$$

Onde $\mathcal{M}$ é o modelo temporal, $\mathcal{F}_{t-1}$ é a informação disponível até $t-1$, $\hat{x}_t$ é o valor esperado, e r_t é o resíduo.



Ruído, Evento e Anomalia

É fundamental distinguir três conceitos que frequentemente se confundem na análise de séries temporais:

Ruído

A variabilidade esperada e inerente ao processo, representada por ε_t . Não é um desvio — é o comportamento normal do sistema, presente em qualquer instante.

Evento

A componente adicional associada a uma perturbação, representada por δ_t . É um termo extra que representa perturbação estruturada sobre o processo, além do ruído esperado.

Anomalia

Um caso particular de evento onde o desvio resultante é estatisticamente significativo no contexto do modelo.

$$x_t = S_t + \varepsilon_t, \quad x_t = S_t + \varepsilon_t + \delta_t$$

Onde S_t é o sinal estruturado, ε_t é o ruído aleatório, e δ_t é a perturbação associada ao evento. Toda anomalia é evento, mas nem todo evento é anomalia. A distinção entre ε_t e δ_t é o que separa variabilidade esperada de perturbação detectável.

Outliers e Anomalias Temporais

A distinção entre outliers clássicos e anomalias temporais é crucial para a análise correta de séries temporais.

Outlier Clássico

Compara x_t com uma média μ e desvio padrão σ globais, assumindo independência entre observações.


$$|x_t - \mu| > k\sigma$$

Anomalia Temporal

Considera a dependência temporal. O "típico" em t depende do histórico e do modelo, usando resíduos para medir desvios.

$$|r_t| > \lambda\sigma_r$$

Em séries temporais, a abordagem clássica é inadequada porque ignora a estrutura de dependência. A definição temporal primeiro explica o esperado naquele instante e só depois mede o desvio.



Detecção de Anomalia Estrutural Local

A Ideia Central

O processo tem parâmetros típicos θ_0 . Uma anomalia estrutural local é uma quebra temporária em $[\tau_1, \tau_2]$ após a qual o processo retorna ao regime original — diferente de uma mudança estrutural persistente.

$$\theta(t) \approx \begin{cases} \theta_0, & t \notin [\tau_1, \tau_2] \\ \theta'_0 \neq \theta_0, & t \in [\tau_1, \tau_2] \end{cases}$$

❗ Esta é uma detecção **offline**: a janela $\{x_{t-w}, \dots, x_{t+w}\}$ usa passado e futuro. Em uso **online**, use apenas janela passada $\{x_{t-w}, \dots, x_{t-1}\}$.

w é a largura da janela de teste. δ é o limiar de divergência de parâmetros. Quando o fenômeno não reverte, aproxima-se de mudança estrutural global: $X_t \sim F_{\theta_1} \rightarrow F_{\theta_2}$.

ENTRADA: x_{train} (período de referência sem anomalias), x (série completa),
 w (largura de janela), δ (limiar de divergência)

PRÉ-CONDIÇÃO: x_{train} é um período considerado normal; $T > 2w$;
estimador de parâmetros θ disponível; detecção offline

PASSO 1 — Estimação do regime de referência

$\theta_0 \leftarrow \text{estimar_parâmetros}(x_{\text{train}})$

// usar período de treinamento limpo evita contaminar θ_0 com as próprias anomalias

PASSO 2 — Varredura por janela deslizante (offline)

PARA t de $w+1$ até $T-w$:

janela $\leftarrow \{x_{t-w}, \dots, x_{t+w}\}$

$\theta_t \leftarrow \text{estimar_parâmetros}(\text{janela})$

PASSO 3 — Teste de divergência

$A \leftarrow \emptyset$

PARA t de $w+1$ até $T-w$:

SE $\text{divergência}(\theta_t, \theta_0) > \delta$:

$A \leftarrow A \cup \{t\}$

PASSO 4 — Verificação de reversão

PARA cada intervalo $[\tau_1, \tau_2] \subseteq A$:

SE $\theta(t) \approx \theta_0$ para $t > \tau_2$:

// processo retorna ao regime de referência

classificar como anomalia estrutural local

SENÃO:

// processo permanece no novo regime

classificar como mudança estrutural global

SAÍDA: A particionado em anomalias locais e mudanças globais

PÓS-CONDIÇÃO: anomalias locais satisfazem $\theta(t) \rightarrow \theta_0$ após τ_2 ; mudanças globais persistem

Detecção por Limiar Estatístico

A Ideia Central

Uma anomalia ocorre quando o resíduo r_t supera λ desvios padrão da variabilidade típica. O modelo define o esperado; o limiar define o inaceitável.

$$r_t = x_t - \hat{x}_t, \quad |r_t| > \lambda \sigma_r$$

λ controla a sensibilidade: valores menores detectam mais, com risco de falsos positivos. α controla a raridade: $\mathbb{P}(|R_t| > |r_t|) < \alpha$.

- ❑ σ_r estimado no treinamento — em uso preditivo, não usar resíduos futuros para estimar a variabilidade típica.

ENTRADA: x_{train} (período de treinamento), x_{test} (período de teste), M (modelo ajustado), λ (sensibilidade)
PRÉ-CONDIÇÃO: M estimado sobre x_{train} ; σ_r calculado nos resíduos de treinamento; resíduos aproximadamente estacionários

PASSO 1 — Estimação da variabilidade típica (treinamento)

PARA t em x_{train} :

$\hat{x}_t \leftarrow E[x_t \mid F_{t-1}, M]$

$r_t \leftarrow x_t - \hat{x}_t$

$\sigma_r \leftarrow \text{desvio_padrão}(\{r_t : t \in x_{\text{train}}\})$

PASSO 2 — Geração dos resíduos de teste

PARA t em x_{test} :

$\hat{x}_t \leftarrow E[x_t \mid F_{t-1}, M]$

$r_t \leftarrow x_t - \hat{x}_t$

PASSO 3 — Classificação

$A \leftarrow \emptyset$

PARA t em x_{test} :

SE $|r_t| > \lambda \cdot \sigma_r$:

$A \leftarrow A \cup \{t\}$

SAÍDA: A (conjunto de instantes anômalos no período de teste)

PÓS-CONDIÇÃO: sob resíduos padronizados aproximadamente $N(0,1)$, λ controla a taxa esperada de alarmes — a afirmação só vale se resíduos forem independentes e bem calibrados

Detecção por Densidade Condicional

A Ideia Central

O comportamento esperado é a distribuição condicional p_t , estimada a partir do contexto C_t . Se o valor observado cai numa região de baixa densidade sob p_t , é anômalo.

$$x_t \mid C_t \sim p_t, \quad p_t(x_t) < \varepsilon$$

p_t pode ser estimada por kernel, mistura de gaussianas ou outro estimador não-paramétrico. ε é o limiar de baixa densidade — sua escala depende do estimador usado.

ENTRADA: x (série temporal), k (largura de janela de contexto), ε (limiar de densidade)

PRÉ-CONDIÇÃO: comprimento $T > k$; estimador de densidade não-paramétrico disponível; ε calibrado na escala do estimador

PASSO 1 — Construção do contexto e estimação de p_t

PARA t de $k+1$ até T :

$C_t \leftarrow \{x_{t-k}, \dots, x_{t-1}\}$

$p_t \leftarrow \text{estimar_densidade}(C_t)$

// C_t exclui x_t para evitar vazamento de informação

PASSO 2 — Avaliação da densidade no ponto observado

PARA t de $k+1$ até T :

$\text{score}_t \leftarrow p_t(x_t)$

PASSO 3 — Classificação

$A \leftarrow \emptyset$

PARA t de $k+1$ até T :

SE $\text{score}_t < \varepsilon$:

$A \leftarrow A \cup \{t\}$

SAÍDA: A (conjunto de instantes anômalos)

PÓS-CONDIÇÃO: anomalias correspondem a regiões de baixa probabilidade condicional sob p_t ; ε deve ser validado empiricamente

Dependência da Representação

O que conta como anomalia depende da representação, do modelo e do objetivo analítico — não é uma propriedade absoluta do dado.

$$\mathcal{A}(\mathcal{R}) = \{t \mid \text{score}(\mathcal{R}(X), t) > \tau\}$$

Valores brutos

→ sem anomalia detectada

Resíduos do modelo

→ anomalia detectada

Componente de volatilidade

→ anomalia diferente

$$\mathcal{A}(\mathcal{R}_1) \neq \mathcal{A}(\mathcal{R}_2)$$

Escolher a representação é escolher o que pode ser anômalo.

Três Níveis de Formalização

A síntese organiza a noção de anomalia em três "portas de entrada" complementares que formam um conjunto unificado. A união $\mathbf{A} = \mathbf{A}_{stat} \cup \mathbf{A}_{dist} \cup \mathbf{A}_{struct}$ é uma organização conceitual — as classes não são necessariamente disjuntas.

Estatístico

Desvio raro nos resíduos, medido por limiar λ sobre σ_r .

$$|r_t| > \lambda \sigma_r$$

Critério: limiar sobre desvio padrão dos resíduos de treinamento.

Distribucional

Ocorrência improvável sob distribuição condicional p_t estimada no contexto C_t .

$$p_t(x_t) < \varepsilon$$

Critério: densidade local — ε calibrado na escala do estimador.

Estrutural

Divergência temporária de parâmetros em $[\tau_1, \tau_2]$, com retorno ao regime θ_0 .


$$\theta(t) \neq \theta_0 \text{ em } [\tau_1, \tau_2]$$

Critério: divergência(θ_t, θ_0) $> \delta$, verificada por janela deslizando offline.


$$\mathcal{A} = \mathcal{A}_{stat} \cup \mathcal{A}_{dist} \cup \mathcal{A}_{struct}$$

Mudar o critério muda o conjunto de anomalias detectadas.


(a) Anomalia no valor: x_t



(b) Anomalia na tendência: $tr(x_t)$



(c) Anomalia na volatilidade: $v(x_t)$



Anomalias e Componentes Temporais

Anomalias podem ocorrer em diferentes componentes — não apenas no valor observado.

Componente Valor

Desvio direto em x_t , com tendência e volatilidade típicas.

Componente Tendência

Desvio em $tendência_t$: nível típico, mas inclinação anômala. $tendência_t$ é a componente de tendência extraída da série.

Componente Volatilidade

Desvio em $volatilidade_t$: explosão de variância com nível e tendência normais. $volatilidade_t$ mede a dispersão local do processo.

Tipos de Anomalias por Natureza

Três manifestações distintas segundo escopo temporal e contexto.

Anomalias Pontuais

Desvios isolados em um único instante de tempo.

Anomalias Coletivas

Sequências que, em conjunto, constituem comportamento anômalo.

Anomalias Contextuais

Valores anômalos apenas em relação ao entorno temporal. Em avaliação offline, o contexto pode incluir vizinhança anterior e posterior:

$C_t = \{x_{t-k}, \dots, x_{t-1}, x_{t+1}, \dots, x_{t+k}\} \setminus \{x_t\}$. O mesmo valor pode ser típico em um regime e anômalo em outro: $x_t \not\sim p(C_t)$.

C_t exclui x_t para evitar que o ponto avaliado defina seu próprio contexto.

A tipicidade é sempre condicionada ao contexto — o limiar e a interpretação do evento dependem da vizinhança temporal.

Desafios na Detecção de Anomalias

Quatro tensões metodológicas que afetam qualquer sistema de detecção.

Definição de Comportamento Típico

O que é "normal" em processos não-estacionários e com múltiplos regimes?

Escolha de Representação

Qual transformação preserva a informação relevante para a detecção?

Sensibilidade vs Especificidade

Como detectar anomalias reais sem gerar excessivos falsos positivos?

Adaptação Temporal

Como ajustar modelos conforme o processo evolui ao longo do tempo?

Anomalias como Fenômenos Temporais

A síntese final explicita que a anomalia é um conceito relativo, dependente de múltiplas escolhas metodológicas. Detectar anomalias não é simplesmente "procurar pontos estranhos", mas formalizar a *tipicidade* e decidir o que constitui desvio relevante.

Representação

Como transformar a série temporal original

Modelo

Como definir a tipicidade no espaço escolhido — via resíduos, densidade ou parâmetros.

Contexto

Como incorporar informação temporal local


Tempo

Quando avaliar e como adaptar critérios

$$\mathcal{A} = f(\mathcal{R}, \mathcal{M}, \mathcal{C}, t)$$


f representa a regra de detecção — não uma função matemática única universal, mas a composição de quatro decisões: representação, modelo de tipicidade, contexto e tempo de avaliação.

Referências Bibliográficas




Event Detection in Time Series

Ogasawara, E.; Salles, R.; Porto, F.; Pacitti, E.
Springer Nature Switzerland, 2025.



Time Series Analysis: With Applications in R

Cryer, J. D.; Chan, K.-S. Springer, 2008.



Data Mining: Concepts and Techniques

Han, J.; Pei, J.; Tong, H. Morgan Kaufmann, 4^a ed., 2022.