



# Descoberta de Motifs em Séries Temporais



Eduardo Ogasawara

[eogasawara@cefet-rj.br](mailto:eogasawara@cefet-rj.br) | <https://eic.cefet-rj.br/~eogasawara>



# Por que motivos importam

Motifs revelam padrões recorrentes que ajudam a explicar a estrutura da série temporal — e aparecem em domínios críticos do mundo real.



## Saúde

Padrões em ECG, EEG e sinais fisiológicos revelam estados clínicos recorrentes.



## Clima e Sensores

Ciclos climáticos e falhas em sensores aparecem como motivos repetidos.



## Finanças

Padrões de preço e volume recorrentes podem antecipar comportamentos de mercado.



A ausência de um motivo esperado também pode sinalizar comportamento anômalo.

# Motif discovery vs anomaly detection

## Motif Discovery

- Procura repetição: subsequências similares que aparecem mais de uma vez.
- Resultado: conjunto de padrões recorrentes com suporte  $\geq \sigma$ .
- Exemplo: batimento cardíaco normal que se repete no ECG.

## Anomaly Detection (Discords)

- Procura raridade ou desvio: subsequências incomuns ou isoladas.
- Resultado: subsequências sem vizinhos próximos (alto valor em M).
- Exemplo: arritmia que não se encaixa em nenhum padrão recorrente.

Os dois problemas se conectam: o que não é motif pode ser discord.

# Motif: definição, ocorrência e formalização

- Um motif é uma subsequência recorrente em uma série temporal.
- A subsequência não precisa ser conhecida previamente — é descoberta ao varrer a série.
- Extraímos de  $X$  todas as janelas deslizantes  $W$  de tamanho  $p$ .
- As ocorrências de  $q$  são as janelas suficientemente similares a  $q$  (distância  $\leq \varepsilon$  ou similaridade  $\geq$  limiar).
- $q$  é motif quando o número de ocorrências atinge o suporte mínimo  $\sigma$ .

$p$  = word size;  $\varepsilon$  = limiar de distância;  $\sigma$  = suporte mínimo;  $W$  = conjunto de janelas

## Formalização

$$occurs(q, X) = \{w_i \mid w_i \in W \wedge dist(w_i, q) \leq \varepsilon\}$$

$$motif(q, X) \Leftrightarrow |occurs(q, X)| \geq \sigma$$

A **exclusion zone** impede contar janelas vizinhas sobrepostas como ocorrências distintas:  $|i - j| > ez$ , com  $ez = p/2$ .

$ez$  = exclusion zone;  $|i - j|$  = distância temporal entre janelas

# Taxonomia de motif discovery

## Dimensões da taxonomia

### Representação

Como a série é reduzida ou codificada antes da busca. Exemplos: PAA (agregação), SAX (simbólica), z-score (normalização).

### Similaridade

Qual função mede proximidade entre subsequências. Exemplos: Euclidiana (lock-step), DTW (elástica), Hamming (simbólica), MINDIST (lower bound SAX).

### Método de busca

Como os candidatos são gerados e verificados. Exemplos: brute-force (exato), index-based (PAA/SAX), random projection (probabilístico), Matrix Profile (estrutural).

A descoberta depende de indexação, função de similaridade e método de busca.

# Métodos de descoberta: visão geral

- Comparar todas as subsequências diretamente é caro:  **$O(n^2)$  pares**.
- Indexação reduz dimensionalidade, discretiza valores ou organiza candidatos.
- O objetivo é acelerar a busca preservando padrões relevantes.
- A escolha do método depende do tamanho da série, da distância e do suporte desejado.

---

## Brute-force

Compara tudo com tudo. Exato, mas  $O(n^2 \cdot p)$ . Referência de correteude.

---

## Random Projection

Usa amostragem e colisões para identificar candidatos prováveis.

---

## Index-based

Reduz e discretiza via PAA/SAX. Agrupa candidatos simbolicamente.

---

## Matrix Profile

Estrutura todas as distâncias nearest-neighbor. Revela motifs e discords em uma única passagem.

# Normalização: escala e métodos

- Duas subsequências podem ter a mesma forma em escalas diferentes.
- Sem normalização, amplitude e deslocamento dominam a distância.
- A normalização torna a comparação focada na forma do padrão.
- Z-score é o padrão em motif discovery: produz média zero e variância um.

$$z(x_t) = \frac{x_t - \mu}{\sigma}$$

$\mu$  = média da janela;  $\sigma$  = desvio padrão da janela

---

## Z-Score

Produz média zero e variância um. Padrão em motif discovery e Matrix Profile.

---

## Min-Max

Escala valores para [0, 1]. Útil quando a amplitude relativa importa.

---

## Normalizações adaptativas

Lidam melhor com não estacionaridade local. Aplicadas janela a janela em vez de globalmente.

# PAA: intuição e formalização

- Reduz a série por médias em segmentos de tamanho igual.
- O sinal fica mais compacto e menos sensível ao ruído local.
- É uma ponte natural para métodos simbólicos como SAX.

$$x'_j = \frac{n}{n'} \sum_{i=\frac{n}{n'}(j-1)+1}^{\frac{n}{n'}j} x_i$$

$n$  = tamanho original;  $n'$  = número de segmentos;  $p$  = word size

ENTRADA: série  $X$  de tamanho  $n$ , número de segmentos  $n'$

PRÉ-CONDIÇÃO:  $n$  divisível por  $n'$ ;  $X$  normalizada (z-score)

PASSO 1 — Calcular tamanho do segmento:  $\text{seg} = n / n'$

PASSO 2 — Para  $j$  de 1 até  $n'$ :

$\text{início} = (j-1) * \text{seg} + 1$

$\text{fim} = j * \text{seg}$

$x'[j] = \text{média}(X[\text{início} .. \text{fim}])$

PASSO 3 — Retornar  $X' = [x'[1], x'[2], \dots, x'[n']]$

SAÍDA: série reduzida  $X'$  de tamanho  $n'$

PÓS-CONDIÇÃO: cada  $x'[j]$  representa a média do  $j$ -ésimo segmento de  $X$

# SAX: representação simbólica

- Transforma valores numéricos em símbolos de um alfabeto de tamanho  $\alpha$ .
- Breakpoints  $\beta$  dividem a distribuição normal em  $\alpha$  faixas equiprováveis.
- Cada segmento PAA recebe o símbolo da faixa em que cai.
- Janelas de tamanho  $p$  viram palavras simbólicas de comprimento  $n'$ .

$$x_t \in [\beta_{k-1}, \beta_k] \rightarrow \text{símbolo } a_k$$

$\alpha$  = tamanho do alfabeto;  $\beta$  = breakpoints;  $n'$  = word size

ENTRADA: série  $X$  de tamanho  $n$ , word size  $n'$ , alfabeto  $\alpha$

PRÉ-CONDIÇÃO:  $X$  normalizada (z-score); breakpoints  $\beta$  pré-calculados

PASSO 1 — Aplicar PAA:  $X' = \text{PAA}(X, n')$

PASSO 2 — Para  $j$  de 1 até  $n'$ :

Para  $k$  de 1 até  $\alpha$ :

Se  $x'[j] \in [\beta_{k-1}, \beta_k]$ :

símbolo $[j] = a_k$

parar busca

PASSO 3 — Palavra = concatenar(símbolo $[1..n']$ )

PASSO 4 — Repetir para cada janela deslizante de  $X$

SAÍDA: sequência de palavras simbólicas

PÓS-CONDIÇÃO: cada palavra representa uma janela de tamanho  $p$  de  $X$

# SAX: propriedades e distância MINDIST

- SAX preserva a estrutura de vizinhança: palavras próximas correspondem a subsequências próximas.
- MINDIST é um lower bound da distância Euclidiana entre subsequências originais.
- Permite descartar candidatos sem calcular a distância numérica completa.
- Quanto maior o alfabeto  $\alpha$ , menor o erro de aproximação.


$$MINDIST(\hat{q}, \hat{q}') = \sqrt{\frac{p}{n'}} \sum_{i=1}^{n'} dist(\hat{q}_i, \hat{q}'_i)$$

$p$  = tamanho da janela;  $n'$  = word size;  $dist$  = tabela de distâncias entre símbolos

**Tabela de distâncias simbólicas ( $\alpha = 4$ )**

|   | a    | b    | c    | d    |
|---|------|------|------|------|
| a | 0    | 0    | 0.67 | 1.34 |
| b | 0    | 0    | 0    | 0.67 |
| c | 0.67 | 0    | 0    | 0    |
| d | 1.34 | 0.67 | 0    | 0    |

Valores baseados nos breakpoints da distribuição normal padrão para  $\alpha=4$ .



# Similaridade: medidas e escolha

- Motif discovery depende de decidir quando duas subsequências são parecidas.
- A escolha da medida de distância muda quais padrões serão considerados motifs.
- Não há medida universal: a escolha depende do fenômeno e das distorções esperadas.
- Medidas lock-step comparam ponto a ponto com alinhamento rígido.
- Medidas elásticas permitem desalinhamento temporal e variações de ritmo.

---

## Lock-step

Compara posições correspondentes diretamente. Simples e eficiente. Exemplos: Euclidiana, Hamming. Sensível a deslocamentos temporais.

---

## Elástica

Permite alinhar pontos fora de ordem. Captura similaridade de forma mesmo com variações de ritmo. Exemplo clássico: DTW.

---

"A escolha entre lock-step e elástica é uma das decisões mais impactantes no pipeline de motif discovery."

# Distância Euclidiana

- Compara duas sequências de mesmo tamanho ponto a ponto.
- É simples, rápida e amplamente usada em motif discovery.
- Funciona bem quando as subsequências estão alinhadas no tempo.
- Sensível a diferenças de amplitude — requer normalização prévia.

$$EDist(q, q') = \sqrt{\sum_{i=1}^p (q_i - q'_i)^2}$$

p = tamanho das sequências; q<sub>i</sub>, q'<sub>i</sub> = valores nas posições correspondentes

## Propriedades

---

### Complexidade

O(p) por par de subsequências. Permite early-abandon para poda eficiente.

### Lower bound

LB\_Keogh e LB\_Kim são lower bounds da Euclidiana usados para poda em buscas indexadas.

### Limitação

---

Não tolera deslocamentos temporais. Duas sequências com a mesma forma mas defasadas terão distância alta.

# Distância de Hamming

- Conta posições diferentes entre sequências simbólicas de mesmo tamanho.
- É natural para palavras SAX: mede quantas letras diferem.
- Mede quantas substituições seriam necessárias para igualar as sequências.
- Usada para agrupar candidatos a motif no pipeline index-based.

$$HDist(q, q') = \sum_{i=1}^p HItem(q_i, q'_i)$$

$$HItem(x, y) = \begin{cases} 0 & \text{se } x = y \\ 1 & \text{caso contrário} \end{cases}$$

$p$  = word size;  $q_i, q'_i$  = símbolos nas posições correspondentes

## Propriedades e uso

---

### Complexidade

$O(p)$  por par. Muito eficiente para palavras SAX curtas.

### Agrupamento

Janelas com  $HDist \leq h$  são candidatas ao mesmo motif. Controla o trade-off entre recall e precisão.

## Limitação

---

Ignora a magnitude da diferença entre símbolos. MINDIST corrige isso usando a tabela de distâncias simbólicas.

# DTW: intuição e motivação

- Dynamic Time Warping permite alinhar sequências que evoluem em ritmos diferentes.
- O método procura um caminho de menor custo em uma matriz de alinhamento.
- É útil quando a forma importa mais do que o alinhamento exato no tempo.
- Cada ponto de uma sequência pode ser alinhado a um ou mais pontos da outra.
- A restrição de Sakoe-Chiba (banda  $w$ ) limita o desvio máximo de alinhamento.

## Construir matriz de custo

Cada célula  $(i, j)$  recebe o custo de alinhar  $q[i]$  com  $q'[j]$ .

## Encontrar caminho ótimo

Programação dinâmica encontra o caminho de menor custo da célula  $(1,1)$  até  $(p,p)$ .

## Calcular distância

A distância DTW é a raiz do custo acumulado no caminho ótimo.

DTW é mais robusto que a Euclidiana para séries com variações de ritmo, mas tem custo  $O(p^2)$  por par.

# DTW: programação dinâmica

- A matriz acumula o menor custo para alinhar prefixos das duas sequências.
- Cada célula depende de três vizinhos já calculados.
- O custo final é a distância elástica entre as sequências.
- Restrição de Sakoe-Chiba (banda  $w$ ) limita o desvio máximo de alinhamento.

$$dtw_{i,j} = custo(q_i, q'_j) + \min(dtw_{i-1,j}, dtw_{i,j-1}, dtw_{i-1,j-1})$$

$p$  = tamanho das sequências;  $w$  = largura da banda de restrição

ENTRADA: sequências  $q$  e  $q'$  de tamanho  $p$ , banda  $w$

PRÉ-CONDIÇÃO:  $q$  e  $q'$  normalizadas;  $w \geq 0$

PASSO 1 — Inicializar matriz  $DTW[0..p][0..p]$  com  $\infty$

$$DTW[0][0] = 0$$

PASSO 2 — Para  $i$  de 1 até  $p$ :

Para  $j$  de  $\max(1, i-w)$  até  $\min(p, i+w)$ :

$$custo = (q[i] - q'[j])^2$$


$$DTW[i][j] = custo + \min(DTW[i-1][j], DTW[i][j-1], DTW[i-1][j-1])$$

PASSO 3 — Retornar  $\sqrt{DTW[p][p]}$

SAÍDA: distância DTW entre  $q$  e  $q'$

PÓS-CONDIÇÃO: valor  $\geq 0$ ; igual a zero se  $q = q'$

# Exemplo visual de DTW



(a)

$$\min(|2 - 3| + 2, |2 - 3| + 1, 2|2 - 3| + 1) = 2$$

(b)

DTW entre duas sequências pequenas, mostrando matriz de custo e cálculo por programação dinâmica.

# Lower bounds e poda

## Lower bounds

Estimam um limite inferior da distância real. Se o limite já supera  $\epsilon$ , o par é descartado sem calcular a distância completa. Exemplos: LB\_Keogh (DTW), LB\_Yi, LB\_Kim.

## Early-abandon

Interrompe o cálculo ponto a ponto assim que o acumulado excede  $\epsilon^2$ .  
Compatível com distância Euclidiana e DTW.

## Poda por indexação

Índices simbólicos (SAX) ou estruturas de dados (iSAX, R-tree) eliminam regiões inteiras do espaço de busca antes de qualquer cálculo de distância.

Combinar lower bounds com early-abandon pode reduzir o custo prático em ordens de magnitude.

# Brute-force discovery: intuição

## Brute-force discovery

- Extraí todas as subsequências de tamanho  $p$  da série.
- Compara cada subsequência com todas as demais (exceto exclusion zone).
- Conta ocorrências: janelas com distância abaixo de  $\epsilon$ .
- É exato, mas complexidade  $O(n^2)$  vezes o custo da distância.

$p$  = word size;  $\epsilon$  = limiar de distância;  $\sigma$  = suporte mínimo; ez = exclusion zone

ENTRADA: série  $X$  de tamanho  $n$ , tamanho  $p$ , limiar  $\epsilon$ , suporte  $\sigma$   
PRÉ-CONDIÇÃO:  $X$  normalizada; ez =  $p/2$  (exclusion zone padrão)

PASSO 1 —  $W$  = extrair todas as janelas de  $X$  de tamanho  $p$

PASSO 2 —  $\text{motifs} = \{\}$

PASSO 3 — Para cada  $w_i$  em  $W$ :

    ocorrências = 0

    Para cada  $w_j$  em  $W$ ,  $|i - j| > \text{ez}$ :

        Se  $\text{dist}(w_i, w_j) \leq \epsilon$ :

            ocorrências += 1

    Se ocorrências  $\geq \sigma$ :

$\text{motifs.adicionar}(w_i)$

PASSO 4 — Retornar motifs

SAÍDA: conjunto de subsequências motif

PÓS-CONDIÇÃO: cada motif ocorre  $\geq \sigma$  vezes com distância  $\leq \epsilon$

# Brute-force: algoritmo e complexidade

## Brute-force: complexidade e otimizações

- Complexidade total:  $O(n^2 \cdot p)$  para distância Euclidiana.
- Com DTW, o custo por par é  $O(p^2)$ , elevando para  $O(n^2 \cdot p^2)$ .
- Early-abandon reduz o custo prático sem alterar a exatidão.
- Normalização prévia é essencial para comparações significativas.

$n$  = tamanho da série;  $p$  = tamanho da janela

**ENTRADA:** sequências  $w_i$  e  $w_j$  de tamanho  $p$ , limiar  $\epsilon$

**PRÉ-CONDIÇÃO:**  $w_i$  e  $w_j$  normalizadas

PASSO 1 — acumulado = 0

PASSO 2 — Para  $t$  de 1 até  $p$ :

    acumulado +=  $(w_i[t] - w_j[t])^2$

    Se acumulado  $> \epsilon^2$ :

        Retornar  $\infty$  (abandono antecipado)

PASSO 3 — Retornar  $\sqrt{\text{acumulado}}$

**SAÍDA:** distância Euclidiana ou  $\infty$  se excede  $\epsilon$

**PÓS-CONDIÇÃO:** resultado  $\infty$  descarta o par sem custo total

# Index-based discovery: PAA/SAX

## Teoria

- Evita comparar diretamente todas as subsequências numéricas.
- Usa PAA e SAX para representar janelas como palavras simbólicas.
- Janelas com a mesma palavra (ou palavras próximas) são candidatas a motif.
- Grupos com suporte suficiente são verificados numericamente.

$p$  = word size;  $\alpha$  = alfabeto;  $\sigma$  = suporte mínimo;  $\varepsilon$  = limiar de verificação

## Pseudocódigo

ENTRADA: série  $X$ , tamanho  $p$ , alfabeto  $\alpha$ , suporte  $\sigma$ , limiar  $\varepsilon$

PRÉ-CONDIÇÃO:  $X$  normalizada (z-score)

PASSO 1 —  $W$  = extrair janelas deslizantes de  $X$  de tamanho  $p$

PASSO 2 — Para cada  $w_i$  em  $W$ :

$X'_i = \text{PAA}(w_i, n')$

palavra $_i = \text{SAX}(X'_i, \alpha)$

PASSO 3 — Agrupar janelas por palavra simbólica

PASSO 4 — Para cada grupo com  $|\text{grupo}| \geq \sigma$ :

Verificar numericamente:  $\text{dist}(w_i, w_j) \leq \varepsilon$

Se confirmado: registrar como motif candidato

PASSO 5 — Retornar motifs confirmados

SAÍDA: conjunto de motifs com suporte  $\geq \sigma$

PÓS-CONDIÇÃO: falsos positivos eliminados na verificação numérica

# Index-based: agrupamento e verificação

## Index-based: agrupamento e verificação

- Janelas simbólicas iguais ou próximas (distância de Hamming  $\leq h$ ) são agrupadas.
- Grupos com suporte suficiente ( $|\text{grupo}| \geq \sigma$ ) são candidatos a motif.
- A verificação numérica elimina falsos positivos introduzidos pela discretização.
- O índice simbólico pode ser uma hash table ou trie sobre palavras SAX.

$h$  = limiar de Hamming;  $\sigma$  = suporte mínimo;  $\varepsilon$  = limiar numérico de verificação

## Agrupamento simbólico (pseudocódigo)

ENTRADA: palavras SAX {palavra\_i}, suporte  $\sigma$ , Hamming  $h$ , limiar  $\varepsilon$

PRÉ-CONDIÇÃO: palavras calculadas para todas as janelas

PASSO 1 — índice = `hash_table()`

PASSO 2 — Para cada (i, palavra\_i):

    índice[palavra\_i].`adicionar`(i)

PASSO 3 — candidatos = {}

PASSO 4 — Para cada (chave\_a, grupo\_a) em índice:

    Para cada (chave\_b, grupo\_b) em índice:

        Se `HDist`(chave\_a, chave\_b)  $\leq h$ :

            candidatos.`unir`(grupo\_a  $\cup$  grupo\_b)


PASSO 5 — Para cada grupo em candidatos com  $|\text{grupo}| \geq \sigma$ :

    Verificar numericamente pares do grupo com  $\text{dist} \leq \varepsilon$

SAÍDA: motifs confirmados

PÓS-CONDIÇÃO: falsos positivos eliminados; falsos negativos possíveis

# Motifs detectados com SAX



*Index-Based Discovery encontra motifs em batimentos regulares no ECG.*

# Random projection: intuição e algoritmo

- Projetar reduz a dimensão considerada na comparação.
- Subsequências similares tendem a colidir nas mesmas projeções aleatórias.
- Uma matriz de colisões acumula evidência probabilística de similaridade.
- Motifs são selecionados entre candidatos com suporte alto na matriz.

Parâmetros:  $n'$  = word size SAX;  $r$  = número de posições projetadas;  $iter$  = iterações;  $\sigma$  = suporte mínimo

ENTRADA: série X, word size  $n'$ , posições  $r$ , iterações  $iter$ , suporte  $\sigma$

PRÉ-CONDIÇÃO: X normalizada; palavras SAX calculadas

PASSO 1 — Calcular palavras SAX para todas as janelas de X

PASSO 2 — Colisões = matriz  $n \times n$  inicializada com zeros

PASSO 3 — Para  $t$  de 1 até  $iter$ :

proj = escolher  $r$  posições aleatórias de  $[1..n']$

bucket = {}

Para cada janela  $w_i$ :

chave = projetar(palavra <sub>$i$</sub> , proj)

bucket[chave].adicionar( $i$ )

Para cada grupo em bucket:

Para cada par ( $i, j$ ) no grupo,  $|i-j| > \epsilon$ :

Colisões[ $i$ ][ $j$ ] += 1

PASSO 4 — Candidatos = pares com Colisões[ $i$ ][ $j$ ]  $\geq \sigma$

PASSO 5 — Verificar candidatos numericamente

SAÍDA: motifs confirmados por colisão e verificação

PÓS-CONDIÇÃO: pares com alta colisão têm alta probabilidade de ser motif

# Random projection: análise probabilística

- A probabilidade de colisão de duas palavras similares aumenta com o número de iterações.
- Subsequências com distância de Hamming pequena colidem com alta probabilidade.
- Subsequências distantes raramente colidem — o método tem baixa taxa de falsos positivos.
- A verificação numérica final elimina os falsos positivos restantes.

$$P(\text{colisão}) = \left( \frac{\alpha - HDist}{\alpha} \right)^r$$

$r$  = posições projetadas;  $\alpha$  = tamanho do alfabeto;  $HDist$  = distância de Hamming

## Interpretação da matriz de colisões

### Alta colisão

Par  $(i, j)$  com  $\text{Colisões}[i][j]$  alto  $\rightarrow$  candidato forte a motif.  
Verificar numericamente.

### Baixa colisão

Par  $(i, j)$  com  $\text{Colisões}[i][j]$  baixo  $\rightarrow$  provavelmente não é motif. Descartar sem verificação.

### Suporte mínimo $\sigma$

Threshold sobre a matriz de colisões. Controla o trade-off entre recall e custo de verificação.

# Early-abandon e lower bounds

- Early-abandon interrompe o cálculo quando o erro parcial já excede  $\epsilon$ .
- Economiza tempo evitando completar comparações que não podem virar match.
- Lower bounds estimam um limite inferior da distância real sem calcular a distância completa.
- Se o lower bound já supera  $\epsilon$ , o par é descartado sem custo adicional.
- LB\_Keogh é o lower bound clássico para DTW: usa envelope de largura  $w$ .

$$LB\_Keogh(q, q') \leq DTW(q, q')$$

$w$  = largura da banda Sakoe-Chiba;  $\epsilon$  = limiar de distância

## LB\_Keogh (pseudocódigo)

ENTRADA: sequência  $q$ , envelope  $(U, L)$  de  $q'$ , limiar  $\epsilon$

PRÉ-CONDIÇÃO:  $U[t] = \max(q'[t-w..t+w])$ ;  $L[t] = \min(q'[t-w..t+w])$

PASSO 1 —  $lb = 0$

PASSO 2 — Para  $t$  de 1 até  $p$ :

Se  $q[t] > U[t]$ :

$lb += (q[t] - U[t])^2$

Senão se  $q[t] < L[t]$ :

$lb += (q[t] - L[t])^2$

Se  $lb > \epsilon^2$ :

Retornar  $\infty$  (poda antecipada)

PASSO 3 — Retornar  $\sqrt{lb}$

SAÍDA: lower bound de  $DTW(q, q')$  ou  $\infty$  se excede  $\epsilon$

PÓS-CONDIÇÃO:  $LB\_Keogh \leq DTW$  real; nunca superestima

# Matrix Profile: intuição e algoritmo

- Para cada subsequência, guarda a distância até sua subsequência mais parecida (nearest neighbor).
- O vetor **M** guarda a menor distância; o índice **I** guarda a posição do vizinho.
- Em self-join, uma **exclusion zone** evita matches triviais próximos da diagonal.
- Distâncias baixas → **motifs**; distâncias altas → **discords**.

$$M[i] = \min_{j, |i-j| > ez} z\text{-norm-dist}(w_i, w_j)$$

$p$  = tamanho da janela;  $ez$  = exclusion zone (padrão  $p/2$ );  
 $n$  = tamanho da série

ENTRADA: série  $X$  de tamanho  $n$ , tamanho de janela  $p$

PRÉ-CONDIÇÃO:  $n > 2p$ ;  $ez = \text{floor}(p/2)$

PASSO 1 —  $W$  = extrair todas as janelas de  $X$  de tamanho  $p$

PASSO 2 —  $M$  = vetor de tamanho  $(n-p+1)$  inicializado com  $\infty$

$I$  = vetor de tamanho  $(n-p+1)$  inicializado com  $-1$

PASSO 3 — Para cada par  $(i, j)$ ,  $|i - j| > ez$ :

$d = \text{z-norm-dist}(W[i], W[j])$

Se  $d < M[i]$ :  $M[i] = d$ ;  $I[i] = j$

Se  $d < M[j]$ :  $M[j] = d$ ;  $I[j] = i$

PASSO 4 — Retornar  $(M, I)$

SAÍDA: Matrix Profile  $M$  e índice  $I$

PÓS-CONDIÇÃO:  $M[i]$  = distância ao vizinho mais próximo de  $W[i]$

$I[i]$  = posição desse vizinho

# Matrix Profile: definição formal

- $M$  é um vetor de tamanho  $(n - p + 1)$ .
- $M[i]$  = distância z-normalizada de  $W[i]$  ao seu nearest neighbor (excluindo exclusion zone).
- $I[i]$  = posição do nearest neighbor de  $W[i]$ .
- Em self-join, a exclusion zone evita matches triviais:  $|i - j| \leq ez$ .
- Em AB-join, compara duas séries distintas  $X$  e  $Y$ .

$$M[i] = \min_{j: |i-j| > ez} \|z(W_i) - z(W_j)\|_2$$

$z(\cdot)$  = z-normalização;  $ez = \text{floor}(p/2)$ ;  $p$  = tamanho da janela

## Propriedades

### Compleitude

Contém informação suficiente para encontrar todos os motifs e discords de ordem  $k$  sem recalculer distâncias.


### Incrementalidade

Pode ser atualizado à medida que novos dados chegam (SWAMP para streaming).

### Generalidade

Funciona com qualquer medida de distância que admita z-normalização. Extensível para múltiplas dimensões (mSTAMP).

# Motifs detectados com Matrix Profile



Matrix Profile com STAMP também encontra motifs em batimentos regulares no ECG.

# Matrix Profile também revela discords

- O mesmo vetor **M** que revela motifs também aponta subsequências isoladas.
- Isso acontece porque **M** mede a distância ao vizinho mais próximo.
- Se até o vizinho mais próximo está longe, a subsequência é candidata a discord.
- Motifs e discords são leituras opostas do mesmo vetor **M**.

"Uma única passagem pelo Matrix Profile revela tanto os padrões mais comuns quanto os mais raros da série."

- Não é necessário rodar dois algoritmos separados.
- A ordem de busca (motifs primeiro, discords depois) pode ser ajustada conforme o objetivo.
- Discords de ordem  $k$  são encontrados iterativamente, excluindo regiões já selecionadas.

---

## **$\min(M) \rightarrow$ Motif**

Subsequência com vizinho mais próximo. Padrão recorrente.

---

## **$\max(M) \rightarrow$ Discord**

Subsequência mais isolada. Candidata a anomalia.

# Menores valores: motifs

- Um valor baixo em  $M[i]$  indica que existe uma subsequência muito parecida com  $W[i]$ .
- O motif de ordem 1 é o par  $(i, j)$  com menor valor em  $M$ .
- Motifs de ordem  $k$  são encontrados iterativamente, excluindo regiões já selecionadas.
- Ocorrências adicionais podem ser buscadas a partir desses pares.

$$motif_1 = \arg \min_i M[i]$$

ez = exclusion zone; k = número de motifs desejados

ENTRADA: Matrix Profile  $M$ , índice  $l$ , exclusion zone  $ez$ ,  $k$  motifs

PRÉ-CONDIÇÃO:  $M$  e  $l$  calculados;  $ez = \text{floor}(p/2)$

PASSO 1 —  $M\_temp$  = cópia de  $M$

PASSO 2 —  $motifs = []$

PASSO 3 — Para  $t$  de 1 até  $k$ :

$i^* = \text{argmin}(M\_temp)$

$j^* = l[i^*]$

$motifs.adicionar((i^*, j^*))$

Para pos em  $[i^* - ez .. i^* + ez]$ :

$M\_temp[pos] = +\infty$  (excluir região)

Para pos em  $[j^* - ez .. j^* + ez]$ :

$M\_temp[pos] = +\infty$  (excluir região)

PASSO 4 — Retornar motifs

SAÍDA: lista de  $k$  pares de motifs em ordem crescente de distância

PÓS-CONDIÇÃO: cada par é o motif mais próximo na região restante

# Maiores valores: discords

## Discords por Matrix Profile

- Um valor alto em  $M$  indica que a subsequência não tem vizinhos próximos.
- O discord de ordem 1 é a subsequência com maior valor em  $M$ .
- Discords de ordem  $k$  são encontrados iterativamente, excluindo regiões já selecionadas.
- Essa leitura conecta motif discovery com detecção de anomalias intervalares.

$$discord_1 = \arg \max_i M[i]$$

$ez$  = exclusion zone;  $k$  = número de discords desejados

ENTRADA: Matrix Profile  $M$ , índice  $I$ , exclusion zone  $ez$ ,  $k$  discords

PRÉ-CONDIÇÃO:  $M$  e  $I$  calculados;  $ez = \text{floor}(p/2)$

PASSO 1 —  $M\_temp$  = cópia de  $M$

PASSO 2 —  $discords = []$

PASSO 3 — Para  $t$  de 1 até  $k$ :

$i^* = \text{argmax}(M\_temp)$

$discords.adicionar(i^*)$

    Para  $j$  em  $[i^* - ez .. i^* + ez]$ :

$M\_temp[j] = -\infty$  (excluir região)

    Para  $j$  tal que  $I[j] \in [i^* - ez .. i^* + ez]$ :

        recalcular  $M\_temp[j]$  sem  $i^*$

PASSO 4 — Retornar  $discords$

SAÍDA: lista de  $k$  posições de discords em ordem decrescente de isolamento

PÓS-CONDIÇÃO: cada discord é a subsequência mais isolada na região restante

# Conexão entre os eventos

## Motifs

Recorrência — subsequências que se repetem com distância  $\leq \epsilon$ .

Representam estados ou comportamentos típicos da série.

## Discords

Isolamento — subsequências sem vizinhos próximos (alto valor em M).

Representam anomalias ou eventos raros.

## Eventos intervalares

Ambos dependem de subsequência, distância e escala temporal. São a base para análise de eventos em séries temporais.

Matrix Profile unifica a descoberta de motifs e discords em uma única estrutura.

# Motifs multivariados

Podem ser tratados por redução de dimensionalidade, combinação de descobertas ou busca conjunta.

## Redução de dimensionalidade

PCA, autoencoders ou projeções reduzem as dimensões antes da busca. Perde relações entre variáveis se não for cuidadoso.

## Combinação de descobertas

Motifs são descobertos por dimensão e depois combinados por co-ocorrência temporal. Simples, mas ignora correlações cruzadas.

## Busca conjunta (mSTAMP)

Estende Matrix Profile para múltiplas dimensões simultaneamente. Captura relações entre variáveis sem explodir o espaço de busca.

Em muitos casos, motifs multivariados aparecem na interação entre variáveis — não em cada uma isoladamente.

# Tamanho variável de motivos

- Muitos métodos assumem tamanho fixo  $p$  — mas o tamanho real do padrão pode ser desconhecido.
- Buscar em múltiplos valores de  $p$  é custoso:  $O(n^2 \cdot |P|)$  para um conjunto  $P$  de tamanhos.
- **PMP** (Pan Matrix Profile) calcula Matrix Profile para todos os tamanhos de uma vez.
- **VALMOD** usa busca hierárquica para encontrar motivos de tamanho variável eficientemente.

$P$  = conjunto de tamanhos candidatos;  $p_{\min}$ ,  $p_{\max}$  = faixa de busca

## Estratégias

### Definir faixa $[p_{\min}, p_{\max}]$

Estabelecer os limites mínimo e máximo dos tamanhos candidatos a investigar.

### Calcular Matrix Profile para cada $p$

Usar PMP ou VALMOD para cobrir toda a faixa de tamanhos de forma eficiente.

### Selecionar motivos ótimos

Escolher motivos com menor distância normalizada pelo tamanho  $p$ .

# Ranking de motivos e ocorrências

Nem todo padrão recorrente é interessante. Motifs podem ser ranqueados por diferentes critérios para identificar os mais relevantes.

---

## Suporte

Número de ocorrências do motif. Motifs com mais ocorrências são mais representativos da série.

---

## Similaridade

Distância média entre as ocorrências. Motifs com menor distância interna são mais coesos.

---

## Entropia / Raridade

Motifs muito frequentes podem ser triviais. Raridade relativa pode indicar padrões mais informativos.

---

## Densidade

Distribuição temporal das ocorrências. Motifs concentrados em regiões específicas podem indicar regimes ou estados.

---

Padrões quase constantes ou trivialmente similares devem ser descartados mesmo com suporte alto.

# Big data e streaming

## Desafios

- Séries longas tornam comparação e armazenamento desafiadores.
- Streaming exige atualização incremental do Matrix Profile.
- Memória limitada impede manter toda a série em RAM.
- Paralelismo e computação distribuída são necessários para escala.

## Soluções

### iSAX

Índice hierárquico para séries longas em disco.

### SWAMP

Atualização incremental do Matrix Profile em streaming.

### mSTAMP

Matrix Profile multivariado com suporte a paralelismo.

### Disk-aware

Algoritmos que minimizam acesso a disco para séries que não cabem em memória.

# Novas estruturas e métodos

## STAMP, STOMP, SCRIMP, PMP e VALMOD

**STAMP**

Calcula Matrix Profile por pares aleatórios; suporta modo anytime.

**STOMP**

Explora localidade entre colunas adjacentes para reduzir custo;  $O(n^2)$  com constante menor.

**SCRIMP**

Amostra diagonais da matriz de distâncias; anytime e paralelizável.

**PMP**

Calcula Matrix Profile para múltiplos tamanhos de janela simultaneamente.




**VALMOD**

Busca motifs de tamanho variável sem fixar  $p$  a priori.

## Comparação dos algoritmos

| Algoritmo | Estratégia           | Anytime? | Tam. variável?      |
|-----------|----------------------|----------|---------------------|
| STAMP     | Pares aleatórios     | Sim      | Não                 |
| STOMP     | Diagonais locais     | Não      | Não                 |
| SCRIMP    | Diagonais amostradas | Sim      | Não                 |
| PMP       | Múltiplos $p$        | Sim      | Sim (via agregação) |
| VALMOD    | Busca hierárquica    | Não      | Sim                 |

# Referências Bibliográficas



---

## Event Detection in Time Series

Ogasawara, E.; Salles, R.; Porto, F.;  
Pacitti, E. Springer Nature Switzerland,  
2025.

---

## Time Series Analysis: With Applications in R

Cryer, J. D.; Chan, K.-S. Springer, 2008.

---

## Data Mining: Concepts and Techniques

Han, J.; Pei, J.; Tong, H. Morgan  
Kaufmann, 4<sup>a</sup> ed., 2022.