



Motifs e Discords em Séries Temporais

Um motif é um padrão que aparece várias vezes na série temporal. Diferente de anomalias ou pontos de mudança, motifs representam eventos de recorrência, não de ruptura.

Eduardo Ogasawara

eduardo.ogasawara@cefet-rj.br

<https://eic.cefet-rj.br/~eogasawara>

Motifs versus Outros Eventos

Enquanto anomalias buscam desvios e change points identificam rupturas, motifs capturam regularidades recorrentes. São perspectivas complementares na análise temporal.

Anomalias (A)

Eventos raros que representam desvios locais do padrão esperado. Definidas por $|r_t| > \tau$, onde o resíduo excede um limiar.

Change Points (C)

Representam rupturas entre regimes, definidas por $\theta_1 \neq \theta_2$. Segmentam a série em diferentes fases.

Motifs (M)

Eventos frequentes que representam similaridade entre janelas. Definidos por $d(X_{i:i+v}, X_{j:j+v}) < \epsilon$, onde a distância entre subsequências é menor que um limiar.

O sistema completo de eventos temporais é $E = A \cup C \cup M \cup D$, onde D representa Discords — padrões únicos que não se repetem.

Definição Formal de Motif

Seja q uma sequência de tamanho p e W o conjunto de janelas deslizantes de tamanho p obtidas da série X . O conjunto de ocorrências de q em X é o conjunto de janelas $w_i \in W$ similares a q .

Ocorrências

Definição formal do conjunto de ocorrências de q em X :

$$\text{occurs}(q, X) = \{w_i\} \mid \forall w_i \in W, w_i \approx q$$

Motif com Suporte σ

q é um motif em X com suporte σ se e somente se ocorre em X pelo menos σ vezes:

$$\text{motif}(q, X) \iff |\text{occurs}(q, X)| \geq \sigma$$

O tamanho p de q é também chamado de *word size*.

Matches Triviais

As ocorrências em $\text{occurs}(q, X)$ devem ter sobreposição mínima. Usa-se uma *exclusion zone* (50–80%) para evitar matches triviais entre janelas vizinhas. O **1-motif** é a subsequência mais frequente; o **k-motif** é o k-ésimo mais frequente.

Escolhendo w : Uma Decisão de Escala

O tamanho da janela w não é apenas um parâmetro técnico — ele define **o que pode ser visto**. Mudar w muda o conceito de motif: $\mathcal{M}(w) \neq \mathcal{M}(w')$ em geral.

w Pequeno

Padrões locais e finos — como um pico de batimento cardíaco ou um gesto rápido. Alta resolução, muitas janelas, custo computacional elevado.

w Grande

Estruturas completas e globais — como um ciclo diário de temperatura ou uma tendência de mercado. Menos janelas, padrões mais abstratos.

- ❏ O analista deve escolher w com base no fenômeno que deseja detectar. Não há valor certo — há a escala certa para a pergunta certa.

Escala Temporal dos Motifs

Motifs Locais

Aparecem em uma região específica $X_{t_0:t_1}$, sugerindo padrões típicos de um regime ou fase particular.

Motifs Globais

Aparecem ao longo de toda a série $X_{1:T}$, revelando regularidade estrutural que se repete consistentemente no processo.

Motifs nos Componentes Temporais

Motifs podem aparecer no sinal bruto ou em séries transformadas — qualquer componente ou derivada da série original é um domínio válido de busca.

Motifs de Valor (M_{val})

Padrões recorrentes no nível observado x_t .
Ex.: uma forma de preço recorrente no sinal bruto, antes de qualquer transformação.

Motifs de Tendência (M_{trend})

Padrões em $tr(x_t)$: subidas/descidas similares que se repetem no componente de tendência extraído.

Motifs de Volatilidade (M_{vol})

Padrões em $v(x_t)$: períodos de alta/baixa variância recorrentes na série de resíduos ou em medidas de volatilidade.

O conjunto completo é a união: $\mathbf{M} = \mathbf{M}_{val} \cup \mathbf{M}_{trend} \cup \mathbf{M}_{vol}$. Esta abordagem conecta motifs com a engenharia de features temporais.

Estrutura Conceitual dos Motifs

Motifs emergem de três escolhas fundamentais que definem o procedimento operacional. Não existe "motif universal" - tudo depende destas definições.

Subsequências ($\mathcal{S}$)

Definir as janelas de análise

Distância (d)

Escolher métrica de similaridade

Janela (w)

Determinar escala temporal

Limiar (ϵ)

Controlar o critério de agrupamento

O resultado é sintetizado como: $\mathcal{M} = f(\mathcal{S}, d, w, \epsilon)$, onde f representa o procedimento de detecção e agrupamento. Trocar qualquer um desses elementos muda fundamentalmente o resultado.

Motifs e Sazonalidade

Sazonalidade é repetição com período fixo T_s , tipicamente ligada ao calendário. Motifs podem ser buscados diretamente no componente sazonal π_t .

Periodicidade

Em uma série periódica com período T_s , janelas separadas por T_s tendem a ser similares: $X_{t:t+w-1} \approx X_{t+T_s:t+T_s+w-1}$. Motifs capturam essa repetição localmente.

Isolar o componente sazonal permite interpretar motifs como padrões recorrentes associados diretamente à sazonalidade.

Decomposição Sazonal

A série pode ser decomposta em $x_t = \beta_t + \pi_t + \omega_t$, onde π_t é o componente sazonal de período T_s .

Similaridade entre Subsequências

A Métrica d

Motifs dependem fundamentalmente de uma noção de distância d entre subsequências. A métrica escolhida determina o que conta como 'mesmo padrão'. Mudar a métrica muda fundamentalmente quais padrões serão considerados recorrentes.

Distância Euclidiana

Compara valor a valor na mesma posição.

$$d_E(s_i, s_j) = \sqrt{\sum (s_i^{(k)} - s_j^{(k)})^2}$$

DTW

Dynamic Time Warping permite desalinhamento temporal entre padrões similares.

Correlação

$d_{corr}(s_i, s_j) = 1 - \rho(s_i, s_j)$. Foca na forma, não no nível absoluto.

Escolha de Métrica para Detecção de Motifs

ENTRADA: s_i, s_j (subsequências de comprimento w),

tipo_métrica $\in \{\text{euclidiana}, \text{dtw}, \text{correlação}\}$

PRÉ-CONDIÇÃO: $|s_i| = |s_j| = w$

PASSO 1 — Distância Euclidiana

SE tipo = euclidiana:

$$d \leftarrow \sqrt{\sum_k (s_i[k] - s_j[k])^2}$$

PASSO 2 — Dynamic Time Warping

SE tipo = dtw:

$$\text{DTW}[0,0] \leftarrow 0$$

PARA $i = 1..w, j = 1..w$:

$$\text{custo} \leftarrow (s_i[i] - s_j[j])^2$$

$$\text{DTW}[i,j] \leftarrow \text{custo} + \min(\text{DTW}[i-1,j], \\ \text{DTW}[i,j-1], \\ \text{DTW}[i-1,j-1])$$

$$d \leftarrow \sqrt{\text{DTW}[w,w]}$$

PASSO 3 — Correlação

SE tipo = correlação:

$$d \leftarrow 1 - \rho(s_i, s_j)$$

SAÍDA: d (distância entre s_i e s_j)

PÓS-CONDIÇÃO: $d \geq 0$; $d = 0$ sse $s_i = s_j$ (para Euclidiana e DTW)

Definição Matemática de Motif

Um motif pode ser definido como o par mais próximo de subsequências ou como um grupo de subsequências mutuamente similares — a escolha depende do algoritmo e da aplicação.

Definição por Par

O par (s_i, s_j) com menor distância $d(s_i, s_j)$ na série, excluindo sobreposições triviais.

Definição por Grupo

$\mathcal{M}_k = \{s \in \mathcal{S} \mid d(s, s') < \varepsilon, \text{ para algum } s' \in \mathcal{M}_k\}$ — conjunto de subsequências mutuamente próximas segundo ε .

Encontrando Motifs

Visão Geral dos Métodos

Os métodos de descoberta de motifs organizam-se em cinco grupos principais, diferindo em custo computacional e estratégia de busca:

Brute-Force

Exaustivo, $O(n^2)$. Compara todos os pares de subsequências. Exato e completo.

Index-Based

Usa PAA + SAX para indexar a série. Aproximado, $O(n \cdot \log n)$.

Random-Projection

Reduz dimensionalidade por projeção aleatória. Probabilístico.

Early-Abandon (EAD)

Otimiza Brute-Force abandonando cálculos quando distância parcial excede ϵ .

Matrix Profile (STAMP)

Estado da arte para busca par a par. $O(n^2 \cdot \log n)$ com FFT.

Detecção de Motifs por Janela Deslizante

ENTRADA: X (série temporal de comprimento T),

w (tamanho da janela), d (métrica), ϵ (limiar)

PRÉ-CONDIÇÃO: $T > w \geq 1, \epsilon > 0$

PASSO 1 — Extração de janelas

$S \leftarrow \{ X_{[t:t+w-1]} \mid t = 1, \dots, T-w+1 \}$

PASSO 2 — Cálculo de distâncias

PARA cada par $(s_i, s_j) \in S \times S, i \neq j$:

SE $|i - j| < w$: continuar # excluir sobreposição trivial

$D[i,j] \leftarrow d(s_i, s_j)$

PASSO 3 — Agrupamento por proximidade

PARA cada $s_i \in S$:

SE $D[i,j] < \epsilon$ PARA algum s_j :

adicionar (s_i, s_j) ao mesmo grupo M_k

SAÍDA: conjunto de motifs $\{ M_1, M_2, \dots, M_k \}$

PÓS-CONDIÇÃO: cada M_k é um par ou grupo de subsequências

recorrentes segundo a regra de similaridade adotada

(complete-linkage não é garantido)

Indexação de Séries Temporais

Pré-processamento para Busca Eficiente

Antes de buscar motivos, a série é normalizada e comprimida para reduzir custo computacional. As duas técnicas centrais são PAA e SAX, frequentemente aplicadas em sequência.

Z-Score

Normalização padrão: média zero e variância um. Garante comparabilidade entre séries de escalas diferentes. Pré-condição para a maioria dos métodos.

PAA – Piecewise Aggregate Approximation

Reduz n observações para n' calculando a média de segmentos iguais. Complexidade $O(n + k)$. Fórmula: $x'_j = (n/n') \cdot \sum x_t$ para t de $n'(j-1)+1$ até $n' \cdot j$.

SAX – Symbolic Aggregation Approximation

Discretiza os valores em símbolos de um alfabeto de tamanho m usando limiares da distribuição Gaussiana. Complexidade $O(n + m \cdot \log m)$. Permite busca exata por string matching.

Pré-processamento: Z-Score $\rightarrow$ PAA $\rightarrow$ SAX

ENTRADA: X (série de comprimento n), n' (tamanho PAA),
 m (tamanho do alfabeto SAX)

PRÉ-CONDIÇÃO: $n > n' \geq 1$, $m \geq 2$

PASSO 1 — Normalização Z-Score

$X' \leftarrow \text{zscore}(X)$

X' com média 0 e variância 1

PASSO 2 — PAA: redução dimensional

PARA $j = 1$ até n' :

$x'_j \leftarrow (n/n') \cdot \sum X'_t$, $t = n'(j-1)+1 \dots n' \cdot j$

Complexidade: $O(n + k)$

PASSO 3 — SAX: discretização simbólica

Definir limiares $\beta_1 < \beta_2 < \dots < \beta_{m-1}$ (Gaussiana)

PARA cada x'_j em X'_{PAA} :

$y_j \leftarrow a_k$ tal que $x'_j \in [\beta_{k-1}, \beta_k]$

Complexidade: $O(n + m \cdot \log m)$

SAÍDA: Y (série simbólica de comprimento n')

PÓS-CONDIÇÃO: $Y \in \{a_1, \dots, a_m\}^{n'}$, pronta para busca por string matching

Brute-Force Discovery

Busca Exaustiva

O método mais simples e exato. Compara todos os pares possíveis de subsequências da série normalizada. Garante cobertura completa, mas tem custo $O(n^2)$ vezes a complexidade da função de distância. Adequado para séries curtas ou word sizes pequenos.

Parâmetros

X: série temporal; q: word size (tamanho da subsequência); σ : suporte mínimo (número mínimo de ocorrências); ϵ : limiar de distância.

Complexidade

$O(n^2) \times O(\text{dist})$. Para distância Euclidiana: $O(n^2 \cdot p)$. Exato — não há aproximação. Inviável para séries longas com word sizes grandes.

Algoritmo 5.1 — Brute-Force Discovery

ENTRADA: X (série temporal), q (word size), σ (suporte mínimo), ϵ (limiar)

PRÉ-CONDIÇÃO: $|X| > q \geq 1, \sigma \geq 1, \epsilon > 0$

procedure BruteForce(X, q, σ , ϵ):

$X' \leftarrow \text{zscore}(X)$

 motifs $\leftarrow \emptyset$

 PARA i $\leftarrow 1$ até $|X'| - q$:

 p $\leftarrow \text{subseq}(X', i, q)$

 occurrences $\leftarrow \{i\}$

 PARA j $\leftarrow i + 1$ até $|X'| - q$:

$p' \leftarrow \text{subseq}(X', j, q)$

 SE $\text{dist}(p, p') < \epsilon$:

 occurrences $\leftarrow \text{occurrences} \cup \{j\}$

 SE $|\text{occurrences}| \geq \sigma$:

 motifs $\leftarrow \text{motifs} \cup \{ p, \text{occurrences} \}$

 retornar motifs

SAÍDA: conjunto de motifs com suas ocorrências

PÓS-CONDIÇÃO: todo motif q tem $|\text{occurs}(q, X)| \geq \sigma$ e $\text{dist} < \epsilon$ entre ocorrências

Index-Based Discovery

Busca Aproximada por Indexação

Em vez de calcular distâncias exatas entre todas as subsequências, a série é indexada com PAA + SAX. A busca por motifs torna-se uma operação de agrupamento simbólico — muito mais eficiente. Representante: EMMA (Enumeration of Motifs Through Matrix Approximation).

Parâmetros

X: série temporal; a: tamanho do alfabeto SAX; k: número de segmentos PAA; q: word size; σ : suporte mínimo.

Complexidade

$O(n \cdot \log n)$. Aproximado — tolera erros introduzidos pela discretização PAA/SAX. Adequado para séries longas onde Brute-Force é inviável.

Algoritmo 5.2 — Index-Based Discovery

ENTRADA: X (série temporal), a (alfabeto SAX),
k (segmentos PAA), q (word size), σ (suporte mínimo)
PRÉ-CONDIÇÃO: $|X| > q \geq 1, \sigma \geq 1$

```
procedure IndexBased(X, a, k, q,  $\sigma$ ):  
  X'  $\leftarrow$  zscore(X)  
  Y  $\leftarrow$  PAA(X', k)    # redução dimensional  
  Y'  $\leftarrow$  SAX(Y, a)    # discretização simbólica  
  W  $\leftarrow$  sw(Y', q)    # sliding window sobre Y'  
  motifs  $\leftarrow$  group_by_having(W,  $\sigma$ )  
  retornar motifs
```

SAÍDA: motifs com ocorrências $\geq \sigma$
PÓS-CONDIÇÃO: motifs agrupados por igualdade simbólica em Y'
Complexidade: $O(n \cdot \log n)$

Random-Projection Discovery

Busca Probabilística por Projeção Aleatória

Reduz a dimensionalidade das janelas por projeção aleatória de q colunas, usando Hamming Distance com tolerância ext — inspirado em princípios genéticos de mutação em sequências de DNA. O resultado é probabilístico: o algoritmo é executado múltiplas vezes e uma collision matrix acumula os candidatos mais frequentes.

Parâmetros

X : série temporal; q : word size; ext : tolerância Hamming (número de posições que podem diferir); σ : suporte mínimo.

Collision Matrix

A cada execução, posições com matches incrementam a collision matrix. Após múltiplas iterações, os índices com maior contagem são os candidatos a motif. A propriedade é probabilística — não há garantia de completude.

Complexidade

Sub-quadrática. Pode ser aplicado diretamente a séries numéricas, acelerando casos onde subsequências claramente não são motifs.

Algoritmo 5.3 — Random-Projection Discovery

ENTRADA: X (série temporal), q (word size),
 ext (tolerância Hamming), σ (suporte mínimo)
PRÉ-CONDIÇÃO: $|X| > q \geq 1$, $ext \geq 0$, $\sigma \geq 1$

```
procedure RandomProjection( $X$ ,  $q$ ,  $ext$ ,  $\sigma$ ):  
   $Y \leftarrow \text{index}(X)$       # Z-Score + SAX  
   $W \leftarrow \text{sw}(Y, q + ext)$  # janela alargada com tolerância  
   $W' \leftarrow \text{project}(W, q)$   # projeção aleatória de  $q$  colunas  
  motifs  $\leftarrow \text{group\_by\_having}(W', \sigma)$   
  retornar motifs
```

```
# Para motifs longos: repetir com collision matrix  
procedure RandomProjectionMulti( $X$ ,  $q$ ,  $ext$ ,  $\sigma$ ,  $R$ ):  
   $C \leftarrow \text{zeros}(|X|)$       # collision matrix  
  PARA  $r \leftarrow 1$  até  $R$ :  
     $W' \leftarrow \text{RandomProjection\_step}(X, q, ext)$   
    PARA cada par  $(i, j)$  com match em  $W'$ :  
       $C[i] \leftarrow C[i] + 1$   
       $C[j] \leftarrow C[j] + 1$   
  motifs  $\leftarrow$  índices com  $C[i] \geq \sigma$   
  retornar motifs
```

SAÍDA: motifs (probabilístico)
PÓS-CONDIÇÃO: resultado converge com R iterações
Complexidade: sub-quadrática; resultado probabilístico

Early-Abandon Distance (EAD)

Otimização do Brute-Force por Abandono Antecipado

O EAD otimiza o Brute-Force abandonando o cálculo da distância assim que a distância parcial acumulada já excede o limiar ϵ . Para a distância Euclidiana, em vez de aplicar a raiz quadrada ao final, eleva-se ϵ ao quadrado e verifica-se a soma parcial componente a componente.

Vantagem 1 – Verificação mais rápida

Evita o cálculo da raiz quadrada: compara a soma parcial $\sum(p[k]-p'[k])^2$ com ϵ^2 a cada componente. Se exceder, abandona imediatamente.

Vantagem 2 – Redução do espaço de busca

Evita matches triviais entre janelas vizinhas, reduzindo o número de pares efetivamente comparados. Economias empíricas significativas em dados reais.

Complexidade

Mesma complexidade assintótica do Brute-Force: $O(n^2)$. Porém, com ganhos práticos expressivos — o abandono antecipado reduz drasticamente o número de operações executadas.

ENTRADA: X (série temporal), q (word size), σ (suporte mínimo), ϵ (limiar)

PRÉ-CONDIÇÃO: $|X| > q \geq 1, \sigma \geq 1, \epsilon > 0$

procedure EAD(X, q, σ, ϵ):

$X' \leftarrow \text{zscore}(X)$

$\epsilon^2 \leftarrow \epsilon * \epsilon$ # evita raiz quadrada no loop

$\text{motifs} \leftarrow \emptyset$

PARA $i \leftarrow 1$ até $|X'| - q$:

$p \leftarrow \text{subseq}(X', i, q)$

$\text{occurrences} \leftarrow \{i\}$

 PARA $j \leftarrow i + 1$ até $|X'| - q$:

$p' \leftarrow \text{subseq}(X', j, q)$

$\text{soma} \leftarrow 0$

$\text{abandonar} \leftarrow \text{falso}$

 PARA $k \leftarrow 1$ até q : # abandono antecipado

$\text{soma} \leftarrow \text{soma} + (p[k] - p'[k])^2$

 SE $\text{soma} > \epsilon^2$:

$\text{abandonar} \leftarrow \text{verdadeiro}$

 parar

 SE NÃO abandonar:

$\text{occurrences} \leftarrow \text{occurrences} \cup \{j\}$

 SE $|\text{occurrences}| \geq \sigma$:

$\text{motifs} \leftarrow \text{motifs} \cup \{ p, \text{occurrences} \}$

retornar motifs

SAÍDA: conjunto de motifs com suas ocorrências

PÓS-CONDIÇÃO: equivalente ao Brute-Force, com menor custo prático

Complexidade: $O(n^2)$ — ganhos empíricos expressivos por abandono antecipado

Matrix Profile – STAMP

Estado da Arte em Busca Par a Par

O Matrix Profile (MP) é uma estrutura de dados que armazena, para cada subsequência de tamanho q , a distância z -normalizada à sua subsequência mais similar na série. O MP é um vetor $M \in \mathbb{R}^{n-q+1}$ e o MP Index $I \in \mathbb{R}^{n-q+1}$ registra a posição do melhor match.

STAMP – Scalable Time Series Anytime Matrix Profile

Algoritmo original do MP. Usa MASS (Mueen's Algorithm for Similarity Search) com FFT para calcular perfis de distância eficientemente. Complexidade: $O(n^2 \cdot \log n)$. Anytime: produz boa aproximação mesmo interrompido antes do fim.

SCRIMP

Refinamento do STAMP. Complexidade $O(n^2)$ — elimina o fator $\log n$. Também anytime. Ambos convergem para o MP exato.

Discords via MP

Os maiores valores do MP identificam discords — subsequências mais distantes de qualquer vizinho. MP unifica descoberta de motifs e anomalias em uma única estrutura.

Leitura do MP para Discords e Motifs

Picos em M (valores altos) → discords: subsequências sem par próximo.
Vales em M (valores baixos) → motifs: subsequências com forte correspondência. O MP unifica ambas as tarefas em uma única estrutura — sem necessidade de dois algoritmos separados.

Algoritmo 5.4 — STAMP

ENTRADA: X (série principal), X' (série secundária, nil = self-join),

q (word size)

PRÉ-CONDIÇÃO: $|X| > q \geq 1$

procedure STAMP(X , $X' = \text{nil}$, q):

$Y' \leftarrow Y \leftarrow \text{zscore}(X)$

SE $X' \neq \text{nil}$:

$Y' \leftarrow \text{zscore}(X')$

$M \leftarrow [+ \infty, \dots, + \infty]$ # MP inicializado com infinito

$I \leftarrow [0, \dots, 0]$ # MP Index inicializado com zeros

PARA $i \leftarrow 1$ até $|Y'| - q$:

$\text{seq} \leftarrow \text{subseq}(Y', i, q)$

$D_i \leftarrow \text{MASS}(\text{seq}, Y)$ # perfil de distância via FFT

$M, I \leftarrow \text{eleMin}(M, I, D_i, i:(i+q-1))$

eleMin ignora exclusion zone quando $Y = Y'$

retornar $\{M, I\}$

SAÍDA: M (Matrix Profile), I (MP Index)

PÓS-CONDIÇÃO: $M[i] = \min$ distância z -norm de $\text{subseq}(Y, i, q)$ a qualquer outra

Complexidade: $O(n^2 \cdot \log n)$ — SCRIMP melhora para $O(n^2)$

Definição de Discord

Um discord é uma subsequência "isolada" que se destaca das demais na série temporal. Diferente de uma anomalia pontual, o discord é definido no espaço de subsequências, não em um único ponto.

Considere a série X . Um discord é uma subsequência cuja forma é muito diferente das outras subsequências extraídas da mesma série. Ele mede raridade comparando janelas temporais entre si, revelando padrões temporais excepcionais.

Anomalias Pontuais vs Discords

Anomalia Pontual

Desvio grande em um único instante. Detectada quando o resíduo $|r_t|$ excede um limiar h .

Discord

Desvio grande de uma janela inteira em relação a outras janelas. Envolve distância $d(X_{i:i+w}, X_{j:j+w})$ entre subsequências.

A diferença fundamental está na unidade do evento: anomalia pontual olha para um ponto; discord olha para um trecho completo. Discords podem ser vistos como anomalias coletivas, pois o padrão inteiro da janela é raro.

Medindo Isolamento e Definição de Discord

Para cada subsequência s_i , encontramos seu vizinho mais próximo — a janela mais similar na série. A distância mínima $D(s_i) = \min_{j \neq i} d(s_i, s_j)$ mede o quão longe está até a correspondência mais próxima. Janelas muito sobrepostas ($|i - j| < w$) devem ser ignoradas na comparação para evitar matches triviais. O discord é a janela que, mesmo comparada ao seu par mais similar, permanece a mais diferente:

$$s^* = \arg \max_{s_i \in S} D(s_i).$$

Extrair janelas de tamanho w

O espaço S contém todas as subsequências

$$s_t = X_{t:t+w-1} \text{ da série}$$

Encontrar o vizinho mais próximo de cada janela

$$\text{Calcular } D(s_i) = \min_{j \neq i} d(s_i, s_j) \text{ para todo } s_i \in S$$

Top- k Discords

As k janelas com maior $D(s_i)$: não é o ponto mais extremo, mas o trecho cuja forma não se repete na série

Se até o vizinho mais próximo está distante, a janela não tem par — ela é um discord.

Detecção Baseada em Distância

A Ideia Central

Cada janela é tratada como um ponto no espaço de subsequências. O score de isolamento $g(s_i)$ é a distância ao vizinho mais próximo. Janelas sem par próximo são discords.

$$g(s_i) = \min_{j \neq i} d(s_i, s_j)$$

g grande $\rightarrow$ janela isolada $\rightarrow$ discord. O limiar τ define o corte.

ENTRADA: série X , tamanho de janela w , limiar τ

PRÉ-CONDIÇÃO: série comparável na escala escolhida; $w \ll T$

PASSO 1 — Extração de janelas

$$S \leftarrow \{ X_{t:t+w-1} \mid t = 1, \dots, T-w+1 \}$$

PASSO 2 — Cálculo do score de isolamento

PARA cada $s_i \in S$:

$$g(s_i) \leftarrow \min_{j : |i-j| \geq w} d(s_i, s_j) \leftarrow \text{exclui sobreposição trivial}$$

PASSO 3 — Detecção

$$\text{discords} \leftarrow \{ s_i \in S \mid g(s_i) > \tau \}$$

PASSO 4 — Ranking (opcional)

$$s^* \leftarrow \operatorname{argmax}_{s_i \in S} g(s_i) \leftarrow \text{discord principal}$$

SAÍDA: conjunto discords, discord principal s^*

PÓS-CONDIÇÃO: s^* é a janela mais isolada da série

Discords via Matrix Profile

O Método Estado da Arte

O Matrix Profile M armazena, para cada subsequência s_i de tamanho w , a distância z -normalizada à sua vizinha mais próxima (excluindo a exclusion zone). Discords são as subsequências com maior valor em M — as mais isoladas da série.

$$s^* = \arg \max_i M[i]$$

Pseudocódigo

1. Construir o Matrix Profile M com STAMP ou SCRIMP
2. Identificar $i^* = \operatorname{argmax} M[i]$
3. Retornar $s_{\{i^*\}}$ como o **top-1** discord
4. Para **top-k**: mascarar exclusion zone em torno de i^* e repetir

Vantagem

A detecção de discords é gratuita após a construção do MP: argmax de M é $O(T)$. O mesmo MP usado para motifs (argmin) detecta discords (argmax) sem reprocessamento.

Abordagem por Clustering

A Ideia Central

Subsequências são tratadas como pontos em espaço vetorial.
Regiões densas formam clusters (motifs); pontos que não pertencem a nenhum cluster são discords.

$$s_i \in \text{discord} \iff s_i \notin \bigcup_k C_k$$

O que sobra fora dos grupos densos é raro — e candidato a discord.

ENTRADA: série X , tamanho de janela w , parâmetros do clustering (k ou ϵ)

PRÉ-CONDIÇÃO: distância $d(\cdot, \cdot)$ definida sobre subsequências

PASSO 1 — Extração de janelas

$$S \leftarrow \{X_{t:t+w-1} \mid t = 1, \dots, T-w+1\}$$

PASSO 2 — Clustering sobre S

$$\{C_1, C_2, \dots, C_k\} \leftarrow \text{Cluster}(S)$$

← DBSCAN: pontos fora de clusters são discords diretos

← k-means: sempre atribui pontos; discords = grande dist. ao centróide

PASSO 3 — Identificação de discords

PARA cada $s_i \in S$:

SE $s_i \notin \bigcup_k C_k$ ← critério DBSCAN

OU $\text{dist}(s_i, \text{centróide mais próximo}) > \theta$ ← critério k-means

marcar s_i como discord

PASSO 4 — Ranking (opcional)

ordenar discords por $\text{dist}(s_i, \text{centróide mais próximo}) \downarrow$

SAÍDA: conjunto de discords ordenados por isolamento

PÓS-CONDIÇÃO: clusters densos correspondem a motifs; outliers a discords

Abordagem Probabilística

A Ideia Central

Em vez de medir distância, medimos quão improvável é o padrão. A janela é representada como vetor Z_t ; um modelo de densidade aprende as regiões típicas. Discords ocorrem onde a probabilidade é baixa.

$$Z_t = R(X_{t:t+w-1}), \quad \text{discord se } p(Z_t) < h_p$$

Raridade é definida pelo modelo, não por distância a vizinhos. O limiar h_p controla a sensibilidade.

ENTRADA: série X , tamanho de janela w , limiar h_p , representação $R(\cdot)$

PRÉ-CONDIÇÃO: modelo de densidade $p(\cdot)$ treinável sobre vetores de $\mathbb{R}^d$

PASSO 1 — Extração e representação

PARA cada t de 1 até $T-w+1$:

$Z_t \leftarrow R(X_{t:t+w-1}) \leftarrow \text{ex: média, FFT, autoencoder}$

PASSO 2 — Estimação de densidade

$p(\cdot) \leftarrow \text{AjustarModelo}(\{Z_1, \dots, Z_{T-w+1}\})$

$\leftarrow \text{ex: KDE, GMM, normalizing flow}$

PASSO 3 — Detecção

PARA cada Z_t :

SE $p(Z_t) < h_p$:

marcar $X_{t:t+w-1}$ como discord

PASSO 4 — Ranking (opcional)

ordenar discords por $p(Z_t) \uparrow \leftarrow \text{menor prob = mais raro}$

SAÍDA: conjunto de discords ordenados por raridade probabilística

PÓS-CONDIÇÃO: discords são janelas em regiões de baixa densidade aprendida

Complexidade Computacional

$O(T^2)$ Abordagem Ingênua

Comparar todas as janelas entre si via brute-force. Inviável para séries longas; custo $O(T^2)$ vezes a complexidade da distância.

STAMP – $O(n^2 \cdot \log n)$

Estado da arte para motifs e discords. Usa MASS (Mueen's Algorithm for Similarity Search) para calcular o Matrix Profile completo. Discords são identificados como argmax do vetor M — sem custo adicional após o MP estar construído.

SCRIMP – $O(n^2)$

Versão anytime do Matrix Profile: produz resultados aproximados rapidamente e refina progressivamente. Permite detectar discords em séries muito longas com orçamento de tempo limitado.

Na prática, STAMP e SCRIMP são os métodos estado da arte para detecção de discords via Matrix Profile. O custo dominante é a construção do MP — a detecção de discords (argmax de M) é $O(T)$ após isso.

Avaliação Formal de Discords

Avaliamos detectores comparando os discords estimados $\hat{D}$ com os reais D . Como discords são janelas, usamos uma tolerância temporal δ para definir quando uma detecção conta como acerto.

Precisão

Dos discords detectados, quantos eram realmente raros?

Revocação




Dos discords reais, quantos foram encontrados?

F1-Score

Equilíbrio entre precisão e revocação.

Na prática, a escolha de δ e do limiar τ afeta diretamente os resultados — não existe avaliação sem definir o que conta como acerto.

Referências Bibliográficas



Event Detection in Time Series

Ogasawara, E.; Salles, R.; Porto, F.; Pacitti, E.
Springer Nature Switzerland, 2025.

Time Series Analysis: With Applications in R

Cryer, J. D.; Chan, K.-S. Springer, 2008.

Data Mining: Concepts and Techniques

Han, J.; Pei, J.; Tong, H. Morgan Kaufmann, 4^a ed., 2022.