




Formulação do Problema de Detecção

Transformando séries temporais em decisões estruturadas sobre anomalias.

Eduardo Ogasawara

eduardo.ogasawara@cefet-rj.br

<https://eic.cefet-rj.br/~eogasawara>

Conceito Formal de Detecção

A detecção de eventos ou anomalias em séries temporais pode ser formulada como um mapeamento estruturado. O detector não opera sobre os dados brutos, mas sobre uma representação transformada.

Entrada

Série temporal $\mathbf{X} = \{\mathbf{x}_t\}_{t=1}^T$:
sequência de observações no tempo.

Representação

$\mathbf{R}(\mathbf{X})$ transforma os dados brutos no espaço
onde eventos ou anomalias serão buscados.

Detector

$\mathbf{D}$ mapeia a representação para o conjunto $\mathbf{E}$
de eventos (ou $\mathbf{A}$ de anomalias)
identificados.

$$\mathcal{D} : \mathcal{R}(X) \rightarrow \mathcal{E}$$

onde $\mathbf{E}$ denota o conjunto de eventos detectados, incluindo anomalias como caso particular.

Arquitetura do Pipeline de Detecção

Pré-processamento

$\mathcal{T}$ transforma X_t em $X_t^{(prep)}$: limpeza e normalização dos dados.

Representação

$\mathcal{R}$ produz Z_t : extração de características relevantes para modelagem.

Modelagem

$\mathcal{M}$ gera $\hat{Z}_t$: comportamento esperado sob normalidade.

Detecção

$\mathcal{D}$ aplica a regra de decisão e identifica $\mathcal{E}$ (conjunto de eventos ou anomalias).

Da Observação à Decisão

O detector opera em três etapas encadeadas: modela o comportamento esperado, mede o desvio e decide se o desvio é relevante.

Modelar o Esperado

O modelo de tipicidade $\mathcal{M}$ define o comportamento normal esperado: x_t segue o padrão típico sob H_0 ; H_1 indica evidência de desvio.

Calcular o Score

$s_t = g(\mathcal{R}(X), t)$ quantifica o desvio considerando a representação, a janela e o histórico disponível.

Decidir

$E_t = \mathbb{I}(s_t > \tau)$: se o score supera o limiar τ , o instante t é classificado como evento ou anomalia.

$$E_t = \mathbb{I}(s_t > \tau)$$

Checklist Operacional do Detector

Projetar um detector exige decisões explícitas em sete dimensões. Cada escolha afeta o que é detectado e como.

Representação

Qual sinal extrair dos dados brutos

Modelo de Tipicidade

Como definir o comportamento típico esperado

Score

Como medir o desvio entre observado e esperado: $s_t = g(R(X), t)$

Limiar

Qual nível de desvio classifica como evento ou anomalia: $E_t = \mathbb{I}(s_t > \tau)$

Janela / Contexto

Qual contexto temporal W o detector considera a cada instante

Modo de Operação

Restrição de informação disponível: offline (série completa), online (sequencial) ou preditivo (horizonte futuro)

Avaliação

Como medir acerto, falso alarme, evento perdido e atraso

Detecção Estatística de Anomalias

A normalidade é modelada por uma distribuição condicional $p_{\theta}(x_t \mid \mathcal{F}_{t-1})$, conhecida ou estimada a partir do histórico. O detector mede o quanto cada observação é improvável sob esse modelo e decide com base em um limiar.

$$p_{\theta}(x_t \mid \mathcal{F}_{t-1})$$

$$s_t = \phi(x_t, p_{\theta,t}), \quad E_t = \mathbb{I}(s_t > \tau)$$

$p_{\theta,t}$: distribuição condicional estimada no instante t ;
 ϕ : função de score (ex: resíduo padronizado, CUSUM, razão de verossimilhança); τ : limiar de decisão.

ENTRADA: série $X = \{x_1, \dots, x_T\}$, limiar τ

PRÉ-CONDIÇÃO: $p_{\{\theta,t\}}$ estimada ou conhecida a partir de dados históricos

PASSO 1 — Para cada $t = 1, \dots, T$:

PASSO 2 — Calcular score: $s_t = \phi(x_t, p_{\{\theta,t\}})$

PASSO 3 — Se $s_t > \tau$: marcar x_t como anomalia ($E_t = 1$)

PASSO 4 — Senão: classificar como normal ($E_t = 0$)

SAÍDA: conjunto $A = \{t : E_t = 1\}$

PÓS-CONDIÇÃO: cada ponto classificado segundo desvio estatístico de $p_{\{\theta,t\}}$

Detecção Baseada em Modelos Temporais

Um modelo temporal f aprende a dinâmica normal da série usando p defasagens. O score é o erro de previsão: quanto maior o erro, mais improvável é a observação. A avaliação só é possível a partir de $t = p+1$, após a janela inicial de treinamento.

$$x_t = f(x_{t-1}, \dots, x_{t-p}) + \varepsilon_t$$

$$s_t = |x_t - \hat{x}_t|, \quad E_t = \mathbb{I}(s_t > \tau)$$

f : modelo preditivo (AR, ARIMA, rede neural); p : ordem — número de defasagens; ε_t : ruído; τ : limiar sobre o erro de previsão. Avaliação inicia em $t = p+1$.

ENTRADA: série $X = \{x_1, \dots, x_T\}$, ordem p , limiar τ

PRÉ-CONDIÇÃO: modelo f treinado em dados históricos normais

PASSO 1 — Para cada $t = p+1, \dots, T$:

PASSO 2 — Prever: $\hat{x}_t = f(x_{t-1}, \dots, x_{t-p})$

PASSO 3 — Calcular erro: $g_t = |x_t - \hat{x}_t|$

PASSO 4 — Se $g_t > \tau$: marcar x_t como anomalia ($E_t = 1$)

PASSO 5 — Senão: classificar como normal ($E_t = 0$)

SAÍDA: conjunto $A = \{t : E_t = 1\}$

PÓS-CONDIÇÃO: anomalias correspondem a erros de previsão acima do limiar

Detecção Baseada em Distância

A normalidade é definida por similaridade estrutural: uma subsequência é anômala se não encontra vizinhos próximos na própria série. Não há modelo probabilístico — apenas distância entre padrões. Uma zona de exclusão evita comparação com subsequências sobrepostas quase idênticas.

$$\mathcal{S} = \{s_i = X_{i:i+w-1} : i = 1, \dots, T - w + 1\}$$

$$s_i = \min_{j: |i-j| > w} d(s_i, s_j)$$

$$E_i = \mathbb{I}(s_i > \tau)$$

w : tamanho da janela de subsequência; i, j : índices de subsequências em $\mathcal{S}$; $d(\cdot, \cdot)$: métrica de distância (ex: Euclidiana, DTW); $|i - j| > w$: zona de exclusão que evita comparação com subsequências sobrepostas; τ : limiar de isolamento.

ENTRADA: série $X = \{x_1, \dots, x_T\}$, janela w , limiar τ

PRÉ-CONDIÇÃO: métrica $d(\cdot, \cdot)$ definida; $w < T$

PASSO 1 — Extrair $S = \{X_{t:t+w-1} : t = 1, \dots, T-w+1\}$

PASSO 2 — Para cada subsequência $s_i \in S$:

PASSO 3 — Calcular $s_i = \min_{j: |i-j| > w} d(s_i, s_j)$

PASSO 4 — Se $s_i > \tau$: marcar s_i como anomalia ($E_i = 1$)

PASSO 5 — Senão: classificar como padrão normal ($E_i = 0$)

SAÍDA: conjunto A de subsequências anômalas (discords)

PÓS-CONDIÇÃO: anomalias são subsequências sem vizinhos próximos em S

Detecção com Aprendizado de Máquina

A tipicidade é aprendida implicitamente: o modelo f_θ aprende a representação normal diretamente dos dados, sem especificação explícita de uma distribuição. A representação considera janela ou histórico: $Z_t = \mathcal{R}(X_{t-w+1:t})$ ou $Z = \mathcal{R}(X)$, conforme o caso.

O score de anomalia é derivado do erro de reconstrução ou predição no espaço transformado: $s_t = |Z_t - \hat{Z}_t|$. Quando uma observação não é bem reconstruída ou prevista, isso indica desvio do padrão aprendido.

A decisão segue o padrão geral: $E_t = \mathbb{I}(s_t > \tau)$. A força do paradigma está em capturar padrões complexos e não-lineares que modelos explícitos não conseguem representar.

$$Z_t = \mathcal{R}(X_{t-w+1:t}), \quad s_t = |Z_t - \hat{Z}_t|, \quad E_t = \mathbb{I}(s_t > \tau)$$

Síntese dos Paradigmas de Detecção

Estatístico

Tipicidade definida por distribuição probabilística conhecida ou estimada

Baseado em Modelos

Tipicidade expressa através de previsão temporal explícita

Baseado em Distância

Tipicidade determinada por similaridade de padrões na série

Aprendizado

Tipicidade aprendida implicitamente via representação e erro

Todos os paradigmas executam a mesma operação: produzir um score s_t e aplicar um limiar τ . Diferem em como definem tipicidade ($\mathcal{M}$) e representação ($\mathcal{R}$). A janela/contexto $\mathcal{W}$ é parte integrante da operação do detector, não apenas um parâmetro técnico.

$$\mathcal{D} = f(\mathcal{R}, \mathcal{M}, g, \tau, \mathcal{W})$$

f representa a regra operacional do detector — não uma função universal única, mas a composição das escolhas de $\mathcal{R}$, $\mathcal{M}$, g , τ e $\mathcal{W}$.

Cenários, Janela e Arquitetura

O detector não opera sobre a série inteira — ele usa um contexto W . O cenário temporal determina a restrição de informação disponível; a arquitetura determina como W é atualizado.

Offline

Série completa $X_{1:T}$ disponível. Permite calibração global com toda a informação.

Online

Dados chegam sequencialmente. Decisões tomadas à medida que observações aparecem.

Preditivo

Estima $\mathbb{P}(E_{t+h} = 1 | \mathcal{F}_t)$: probabilidade de evento futuro dado o histórico $\mathcal{F}_t$ até t , com horizonte h .

Batch

Contexto fixo. Processamento completo da janela de uma só vez.


Streaming

Contexto deslizante. Atualização incremental; W define também memória e custo computacional.


Híbrida

Contexto adaptativo. Combina processamento completo e incremental.

(a) Janela pequena ($w=20$): reage rápido (mais



(b) Janela grande ($w=120$): estabiliza (maior rob



A Janela como Contexto do Detector

A janela de tamanho w define o contexto sobre o qual o detector opera: $X_{t-w+1:t}$. Não é apenas um parâmetro técnico — ela define o que conta como "recente". Mudar w pode alterar o conjunto de eventos detectados, pois muda o que é considerado desvio relevante.


Janela Pequena

Reação rápida, mas pode confundir ruído com anomalia

Janela Grande

Decisão estabilizada, mas aumenta latência e pode diluir desvios curtos

Trade-offs na Detecção de Anomalias



Não existe detector ótimo universal — cada aplicação requer um ponto de operação específico. Sensibilidade compete com precisão (FN vs FP), latência compete com robustez, e complexidade compete com interpretabilidade.

A função de custo $\mathcal{L}(\mathcal{D}) = \alpha \cdot FP + \beta \cdot FN + \gamma \cdot \bar{\Delta}t$ penaliza falsos positivos, falsos negativos e atraso médio de detecção $\bar{\Delta}t$ (média dos atrasos sobre todos os eventos). Pesos diferentes definem detectores "melhores" para objetivos diferentes: um sistema de alerta crítico prioriza β alto; um sistema de monitoramento contínuo pode tolerar mais FP.

A função de custo formaliza os compromissos operacionais do detector através de pesos que refletem prioridades da aplicação.

Avaliação: Acerto e Pontualidade

Avaliar um detector significa entender quatro tipos de resultado possíveis — e, em séries temporais, também o quão rápido a detecção ocorre.

Acerto (*True Positive*)

Anomalia real detectada corretamente.

Falso Alarme (*False Positive*)

Alerta disparado sem anomalia real.

Evento Perdido (*False Negative*)




Anomalia real não detectada.

Atraso (*Latency*)

Detecção correta, mas tardia.

Precisão e revocação comparam os conjuntos $\hat{A}$ e A , mas exigem uma regra de correspondência temporal: a interseção exata pode ser injusta em séries temporais, onde uma detecção ligeiramente deslocada ainda é útil. O atraso $\Delta t = \max(0, t_{\text{det}} - t_{\text{real}})$ adiciona uma dimensão temporal: $Q = F_1 \cdot P(\Delta t)$, onde $P(\Delta t) = e^{-\lambda \Delta t}$ é uma escolha de penalização — não uma métrica universal. A avaliação completa será aprofundada em aula específica.

Referências Bibliográficas



Event Detection in Time Series

Ogasawara, E.; Salles, R.; Porto, F.; Pacitti, E.
Springer Nature Switzerland, 2025.

Time Series Analysis: With Applications in R

Cryer, J. D.; Chan, K.-S. Springer, 2008.

Data Mining: Concepts and Techniques

Han, J.; Pei, J.; Tong, H. Morgan Kaufmann, 4^a ed., 2022.