

Descoberta de Motifs em Séries Temporais



Eduardo Ogasawara

eogasawara@cefet-rj.br | <https://eic.cefet-rj.br/~eogasawara>



Por que motivos importam

Motivos revelam padrões recorrentes que ajudam a explicar a estrutura da série.

Em saúde, clima, finanças e sensores, padrões repetidos podem representar estados ou comportamentos relevantes.

A ausência de motivos esperados também pode sinalizar comportamento anômalo.

Motif discovery vs anomaly detection

Motif discovery procura repetição: subsequências similares que aparecem mais de uma vez.

Anomaly detection procura raridade ou desvio: observações ou subsequências incomuns.

Os dois problemas se conectam porque o que não se parece com nada pode ser um discord.

O que é um motif

- Um motif é uma subsequência recorrente em uma série temporal.
- A subsequência não precisa ser conhecida previamente.
- O método descobre o padrão ao varrer a série e comparar janelas.

Ocorrências de uma sequência

Considere uma sequência q de tamanho p .

Extraímos de X todas as janelas deslizantes W também de tamanho p .

As ocorrências de q são as janelas suficientemente similares a q .

Formalização de ocorrência

A relação $w_i \approx q$ depende da medida de similaridade adotada.

Na prática, isso significa distância abaixo de um limiar ou similaridade acima de um corte.

$$occurs(q, X) = \{w_i \mid w_i \in W \wedge w_i \approx q\}$$

Formalização de motif

Uma sequência q é motif quando aparece vezes suficientes na série.

O suporte σ define o número mínimo de ocorrências.


O tamanho p da sequência também é chamado de word size.

$$\text{motif}(q, X) \Leftrightarrow |\text{occurs}(q, X)| \geq \sigma$$

Motifs triviais e exclusion zone

- Janelas vizinhas tendem a ser muito parecidas por sobreposição.
- Essas ocorrências triviais podem inflar artificialmente o suporte.
- A exclusion zone impede contar matches muito próximos no tempo.

Taxonomia de motif discovery



A descoberta depende de indexação, função de similaridade e método de busca.

Por que indexar séries temporais

- Comparar todas as subsequências diretamente pode ser caro.
- Indexação reduz dimensionalidade, discretiza valores ou organiza candidatos.
- O objetivo é acelerar a busca preservando padrões relevantes.

Normalização: por que escala importa

Duas subsequências podem ter a mesma forma em escalas diferentes.

Sem normalização, amplitude e deslocamento podem dominar a distância.

A normalização torna a comparação mais focada na forma do padrão.

Z-Score, Min-Max e adaptações

Z-Score

Produz média zero e variância um.

Min-Max

Escala valores para uma faixa definida, como $[0, 1]$.

Normalizações adaptativas

Lidam melhor com não estacionaridade local.

PAA: intuição

- Piecewise Aggregate Approximation reduz a série por médias em segmentos.
- O sinal fica mais compacto e menos sensível ao ruído local.
- É uma ponte natural para métodos simbólicos como SAX.

PAA: formalização

X é particionada em segmentos de mesmo tamanho.

Cada valor de X' representa a média de um segmento da série original.

A transformação reduz n observações para n' observações.

x'_j = média dos valores de X no segmento j

SAX: intuição

- SAX transforma valores numéricos em símbolos.
- Valores em intervalos semelhantes recebem a mesma letra.
- Isso permite buscar padrões como palavras, usando agrupamento e matching simbólico.

SAX: alfabeto simbólico



O tamanho do alfabeto define quantas faixas serão usadas.

Breakpoints β separam os intervalos de discretização.

Com word size definido, cada janela vira uma palavra simbólica.


$$x_t \in [\beta_{k-1}, \beta_k] \rightarrow \text{símbolo } a_k$$

ECG: normalização, PAA e SAX



Exemplo de batimento cardíaco normalizado, agregado por PAA e discretizado com limiares SAX.

Similaridade é o centro do problema

- Motif discovery depende de decidir quando duas subsequências são parecidas.
- A escolha da medida de distância muda quais padrões serão considerados motifs.
- Não há medida universal: a escolha depende do fenômeno e das distorções esperadas.

Lock-step vs medidas elásticas

- Lock-step compara ponto a ponto, mantendo alinhamento rígido.
- Medidas elásticas permitem desalinhamento temporal e variações de ritmo.
- DTW é o exemplo clássico de medida elástica.

Distância Euclidiana



Compara duas sequências de mesmo tamanho ponto a ponto.



É simples, rápida e amplamente usada.



Funciona bem quando as subsequências estão alinhadas no tempo.

Euclidiana: formalização

Dadas duas sequências q e q' de tamanho p .

A distância soma diferenças ponto a ponto ao quadrado.

Quanto menor o valor, maior a similaridade.

$$EDist(q, q') = \sqrt{\sum_{i=1}^p (q_i - q'_i)^2}$$

Distância de Hamming

- Conta posições diferentes entre sequências de mesmo tamanho.
- É natural para sequências simbólicas, como palavras SAX.
- Mede quantas substituições seriam necessárias para igualar as sequências.

Hamming: formalização

Cada posição contribui zero se os símbolos são iguais.

Cada posição contribui um se os símbolos são diferentes.

$$HDist(q, q') = \sum HItem(q_i, q'_i)$$

$$HItem(x, y) = 0 \text{ se } x = y; 1 \text{ caso contrário}$$

DTW: intuição

Dynamic Time Warping permite alinhar sequências que evoluem em ritmos diferentes.

O método procura um caminho de menor custo em uma matriz de alinhamento.


É útil quando a forma importa mais do que o alinhamento exato no tempo.

DTW: programação dinâmica

- A matriz acumula o menor custo para alinhar prefixos das duas sequências.
- Cada célula depende de vizinhos já calculados.
- O custo final representa a distância elástica entre as sequências.

$$dtw_{i,j} = custo(q_i, q'_j) + \min(dtw_{i-1,j}, dtw_{i,j-1}, dtw_{i-1,j-1})$$

Exemplo visual de DTW



(a)

$$\min(|2 - 3| + 2, |2 - 3| + 1, 2|2 - 3| + 1) = 2$$

(b)

DTW entre duas sequências pequenas, mostrando matriz de custo e cálculo por programação dinâmica.

Lower bounds e poda



Lower bounds estimam um limite inferior da distância real.



Se o limite inferior já é alto demais, a comparação completa pode ser descartada.



Essa ideia reduz custo em buscas com muitas subsequências candidatas.

Famílias de métodos de descoberta



Brute-force

Compara tudo com tudo.



Index-based

Reduz e discretiza para acelerar a busca.



Random Projection

Usa amostragem e colisões para candidatos prováveis.



Matrix Profile

Estrutura distâncias para revelar motifs e discords.

Brute-force discovery: intuição

- Extrai todas as subsequências de tamanho q .
- Compara cada subsequência com todas as demais.
- É exato, mas o custo cresce rapidamente com o tamanho da série.

Brute-force: algoritmo e complexidade

- Normaliza a série.
- Para cada subsequência, verifica quais outras estão abaixo de ϵ .
- Se o número de ocorrências atinge σ , registra um motif.
- A complexidade é $O(n^2)$ vezes o custo da distância.


Index-based discovery: intuição

- Evita comparar diretamente todas as subsequências numéricas.
- Usa PAA e SAX para representar janelas como palavras.
- Motifs aparecem como palavras ou grupos simbólicos recorrentes.

Index-based: PAA/SAX e agrupamento

- A série é normalizada, agregada e discretizada.
- Janelas simbólicas iguais ou próximas são agrupadas.
- Grupos com suporte suficiente viram candidatos a motif.

Motifs detectados com SAX



Index-Based Discovery encontra motifs em batimentos regulares no ECG.

Random projection: intuição

- Projetar reduz a dimensão considerada na comparação.
- Subsequências similares tendem a colidir nas mesmas projeções.
- O método troca busca exaustiva por evidência probabilística de similaridade.

Random projection: colisões e suporte

- Executa projeções múltiplas sobre janelas simbólicas.
- Uma matriz de colisões acumula candidatos recorrentes.
- Motifs são selecionados entre candidatos com suporte alto.

Early-abandon distance

- Interrompe o cálculo de distância quando o erro parcial já excede ϵ .
- Economiza tempo evitando completar comparações que não podem virar match.
- Mantém a lógica do brute-force, mas reduz custo prático.

Matrix Profile: intuição



Para cada subsequência, guarda a distância até sua subsequência mais parecida.



Distâncias baixas indicam padrões recorrentes.




Distâncias altas indicam subsequências isoladas ou incomuns.

Matrix Profile: vetor e índice

- O vetor M guarda a menor distância encontrada para cada subsequência.
- O índice I guarda onde está a subsequência mais parecida.
- Em self-join, uma exclusion zone evita matches triviais próximos da diagonal.

Motifs detectados com Matrix Profile



Matrix Profile com STAMP também encontra motifs em batimentos regulares no ECG.

Matrix Profile também revela discords

O mesmo vetor que revela motifs também aponta subsequências isoladas.

Isso acontece porque o Matrix Profile mede a distância ao vizinho mais próximo.

Se até o vizinho mais próximo está longe, a subsequência é candidata a discord.

Menores valores: motifs

- Um valor baixo em M indica que existe uma subsequência muito parecida.
- Pares com baixa distância são candidatos naturais a motifs.
- Ocorrências adicionais podem ser buscadas a partir desses pares.

Maiores valores: discords

- Um valor alto em M indica isolamento.
- A subsequência não tem vizinhos próximos no restante da série.
- Essa leitura conecta motif discovery com detecção de anomalias intervalares.

Conexão com o tutorial de eventos

Motifs descrevem recorrência.

Discords descrevem isolamento.

Ambos são eventos intervalares e dependem de subsequência, distância e escala temporal.

Motifs multivariados

Podem ser tratados por redução de dimensionalidade, combinação de descobertas ou busca conjunta.

A dificuldade é capturar relações entre dimensões sem explodir o espaço de busca.

Em muitos casos, motifs aparecem na interação entre variáveis.

Tamanho variável de motivos

- Muitos métodos assumem tamanho fixo q .
- Na prática, o tamanho do padrão pode ser desconhecido.
- Métodos de tamanho variável buscam em faixas ou concatenam motivos menores.

Ranking de motivos e ocorrências

- Nem todo padrão recorrente é interessante.
- Motifs podem ser ranqueados por suporte, similaridade, entropia, raridade ou densidade das ocorrências.
- Padrões triviais ou quase constantes podem ser descartados.

Big data e streaming

- Séries longas tornam comparação e armazenamento desafiadores.
- iSAX, SWAMP, mSTAMP e algoritmos disk-aware atacam escala e memória.
- Em streaming, o método precisa atualizar candidatos sem recomputar tudo.



Novas estruturas e métodos

STAMP e SCRIMP calculam Matrix Profile com estratégias eficientes e anytime.

STOMP explora localidade para reduzir custo.

AAMP calcula Matrix Profile com distância Euclidiana não normalizada.

Referências Bibliográficas



Event Detection in Time Series

Ogasawara, E.; Salles, R.; Porto, F.;
Pacitti, E. Springer Nature Switzerland,
2025.

Time Series Analysis: With Applications in R

Cryer, J. D.; Chan, K.-S. Springer, 2008.

Data Mining: Concepts and Techniques

Han, J.; Pei, J.; Tong, H. Morgan
Kaufmann, 4^a ed., 2022.