

Motif Discovery em Séries Temporais



Eduardo Ogasawara

eogasawara@cefet-rj.br | <https://eic.cefet-rj.br/~eogasawara>



CAPÍTULO 5

Objetivos do capítulo

- Definir motifs como subsequências recorrentes e inicialmente desconhecidas.
- Entender por que indexação e similaridade determinam a qualidade da descoberta.
- Comparar métodos clássicos e modernos para encontrar motifs em séries temporais.

CAPÍTULO 5

Por que motivos importam

Motivos revelam padrões recorrentes que ajudam a explicar a estrutura da série.

Em saúde, clima, finanças e sensores, padrões repetidos podem representar estados ou comportamentos relevantes.

A ausência de motivos esperados também pode sinalizar comportamento anômalo.

CAPÍTULO 5

Motif discovery vs anomaly detection

Motif discovery procura repetição: subsequências similares que aparecem mais de uma vez.

Anomaly detection procura raridade ou desvio: observações ou subsequências incomuns.

Os dois problemas se conectam porque o que não se parece com nada pode ser um discord.

CAPÍTULO 5

O que é um motif

- Um motif é uma subsequência recorrente em uma série temporal.
- A subsequência não precisa ser conhecida previamente.
- O método descobre o padrão ao varrer a série e comparar janelas.

CAPÍTULO 5

Ocorrências de uma sequência

Considere uma sequência q de tamanho p .

Extraímos de X todas as janelas deslizantes W também de tamanho p .

As ocorrências de q são as janelas suficientemente similares a q .

Formalização de ocorrência

A relação $w_i \approx q$ depende da medida de similaridade adotada.

Na prática, isso significa distância abaixo de um limiar ou similaridade acima de um corte.

$$occurs(q, X) = \{w_i \mid w_i \in W \wedge w_i \approx q\}$$

Formalização de motif

Uma sequência q é motif quando aparece vezes suficientes na série.

O suporte σ define o número mínimo de ocorrências.

O tamanho p da sequência também é chamado de word size.


$$\text{motif}(q, X) \Leftrightarrow |\text{occurs}(q, X)| \geq \sigma$$

CAPÍTULO 5

Motifs triviais e exclusion zone

- Janelas vizinhas tendem a ser muito parecidas por sobreposição.
- Essas ocorrências triviais podem inflar artificialmente o suporte.
- A exclusion zone impede contar matches muito próximos no tempo.

Taxonomia de motif discovery



A descoberta depende de indexação, função de similaridade e método de busca.

Por que indexar séries temporais

- Comparar todas as subsequências diretamente pode ser caro.
- Indexação reduz dimensionalidade, discretiza valores ou organiza candidatos.
- O objetivo é acelerar a busca preservando padrões relevantes.

Normalização: por que escala importa

Duas subsequências podem ter a mesma forma em escalas diferentes.

Sem normalização, amplitude e deslocamento podem dominar a distância.

A normalização torna a comparação mais focada na forma do padrão.

Z-Score, Min-Max e adaptações

Z-Score

Produz média zero e variância um.

Min-Max

Escala valores para uma faixa definida, como $[0, 1]$.

Normalizações adaptativas

Lidam melhor com não estacionaridade local.

CAPÍTULO 5

PAA: intuição

- Piecewise Aggregate Approximation reduz a série por médias em segmentos.
- O sinal fica mais compacto e menos sensível ao ruído local.
- É uma ponte natural para métodos simbólicos como SAX.

PAA: formalização

X é particionada em segmentos de mesmo tamanho.

Cada valor de X' representa a média de um segmento da série original.

A transformação reduz n observações para n' observações.

x'_j = média dos valores de X no segmento j

SAX: intuição

- SAX transforma valores numéricos em símbolos.
- Valores em intervalos semelhantes recebem a mesma letra.
- Isso permite buscar padrões como palavras, usando agrupamento e matching simbólico.

SAX: alfabeto simbólico


O tamanho do alfabeto define quantas faixas serão usadas.

Breakpoints β separam os intervalos de discretização.

Com word size definido, cada janela vira uma palavra simbólica.

$$x_t \in [\beta_{k-1}, \beta_k] \rightarrow \text{símbolo } a_k$$

ECG: normalização, PAA e SAX



Exemplo de batimento cardíaco normalizado, agregado por PAA e discretizado com limiares SAX.

Similaridade é o centro do problema

- Motif discovery depende de decidir quando duas subsequências são parecidas.
- A escolha da medida de distância muda quais padrões serão considerados motifs.
- Não há medida universal: a escolha depende do fenômeno e das distorções esperadas.

Lock-step vs medidas elásticas

- Lock-step compara ponto a ponto, mantendo alinhamento rígido.
- Medidas elásticas permitem desalinhamento temporal e variações de ritmo.
- DTW é o exemplo clássico de medida elástica.

Distância Euclidiana



Compara duas sequências de mesmo tamanho ponto a ponto.



É simples, rápida e amplamente usada.



Funciona bem quando as subsequências estão alinhadas no tempo.

Euclidiana: formalização

Dadas duas sequências q e q' de tamanho p .

A distância soma diferenças ponto a ponto ao quadrado.

Quanto menor o valor, maior a similaridade.

$$EDist(q, q') = \sqrt{\sum_{i=1}^p (q_i - q'_i)^2}$$

Distância de Hamming

- Conta posições diferentes entre sequências de mesmo tamanho.
- É natural para sequências simbólicas, como palavras SAX.
- Mede quantas substituições seriam necessárias para igualar as sequências.

Hamming: formalização

Cada posição contribui zero se os símbolos são iguais.

Cada posição contribui um se os símbolos são diferentes.

$$HDist(q, q') = \sum HItem(q_i, q'_i)$$

$$HItem(x, y) = 0 \text{ se } x = y; 1 \text{ caso contrário}$$

DTW: intuição

Dynamic Time Warping permite alinhar sequências que evoluem em ritmos diferentes.

O método procura um caminho de menor custo em uma matriz de alinhamento.


É útil quando a forma importa mais do que o alinhamento exato no tempo.

DTW: programação dinâmica

- A matriz acumula o menor custo para alinhar prefixos das duas sequências.
- Cada célula depende de vizinhos já calculados.
- O custo final representa a distância elástica entre as sequências.

$$dtw_{i,j} = custo(q_i, q'_j) + \min(dtw_{i-1,j}, dtw_{i,j-1}, dtw_{i-1,j-1})$$

Exemplo visual de DTW



DTW entre duas sequências pequenas, mostrando matriz de custo e cálculo por programação dinâmica.

Lower bounds e poda



Lower bounds estimam um limite inferior da distância real.



Se o limite inferior já é alto demais, a comparação completa pode ser descartada.



Essa ideia reduz custo em buscas com muitas subsequências candidatas.

Famílias de métodos de descoberta



Brute-force

Compara tudo com tudo.



Index-based

Reduz e discretiza para acelerar a busca.



Random Projection

Usa amostragem e colisões para candidatos prováveis.



Matrix Profile

Estrutura distâncias para revelar motifs e discords.

Brute-force discovery: intuição

- Extrai todas as subsequências de tamanho q .
- Compara cada subsequência com todas as demais.
- É exato, mas o custo cresce rapidamente com o tamanho da série.

Brute-force: algoritmo e complexidade

- Normaliza a série.
- Para cada subsequência, verifica quais outras estão abaixo de ϵ .
- Se o número de ocorrências atinge σ , registra um motif.
- A complexidade é $O(n^2)$ vezes o custo da distância.


Index-based discovery: intuição

- Evita comparar diretamente todas as subsequências numéricas.
- Usa PAA e SAX para representar janelas como palavras.
- Motifs aparecem como palavras ou grupos simbólicos recorrentes.

Index-based: PAA/SAX e agrupamento

- A série é normalizada, agregada e discretizada.
- Janelas simbólicas iguais ou próximas são agrupadas.
- Grupos com suporte suficiente viram candidatos a motif.

Motifs detectados com SAX



Index-Based Discovery encontra motifs em batimentos regulares no ECG.

Random projection: intuição

- Projetar reduz a dimensão considerada na comparação.
- Subsequências similares tendem a colidir nas mesmas projeções.
- O método troca busca exaustiva por evidência probabilística de similaridade.

Random projection: colisões e suporte

- Executa projeções múltiplas sobre janelas simbólicas.
- Uma matriz de colisões acumula candidatos recorrentes.
- Motifs são selecionados entre candidatos com suporte alto.

Early-abandon distance

- Interrompe o cálculo de distância quando o erro parcial já excede ϵ .
- Economiza tempo evitando completar comparações que não podem virar match.
- Mantém a lógica do brute-force, mas reduz custo prático.

Matrix Profile: intuição



Para cada subsequência, guarda a distância até sua subsequência mais parecida.



Distâncias baixas indicam padrões recorrentes.




Distâncias altas indicam subsequências isoladas ou incomuns.

Matrix Profile: vetor e índice

- O vetor M guarda a menor distância encontrada para cada subsequência.
- O índice I guarda onde está a subsequência mais parecida.
- Em self-join, uma exclusion zone evita matches triviais próximos da diagonal.

Motifs detectados com Matrix Profile



Matrix Profile com STAMP também encontra motifs em batimentos regulares no ECG.

CAPÍTULO 5

Matrix Profile também revela discords

O mesmo vetor que revela motifs também aponta subsequências isoladas.

Isso acontece porque o Matrix Profile mede a distância ao vizinho mais próximo.

Se até o vizinho mais próximo está longe, a subsequência é candidata a discord.

Menores valores: motifs

- Um valor baixo em M indica que existe uma subsequência muito parecida.
- Pares com baixa distância são candidatos naturais a motifs.
- Ocorrências adicionais podem ser buscadas a partir desses pares.

Maiores valores: discords

- Um valor alto em M indica isolamento.
- A subsequência não tem vizinhos próximos no restante da série.
- Essa leitura conecta motif discovery com detecção de anomalias intervalares.

CAPÍTULO 5

Conexão com o tutorial de eventos

Motifs descrevem recorrência.

Discords descrevem isolamento.

Ambos são eventos intervalares e dependem de subsequência, distância e escala temporal.

CAPÍTULO 5

Motifs multivariados

Podem ser tratados por redução de dimensionalidade, combinação de descobertas ou busca conjunta.

A dificuldade é capturar relações entre dimensões sem explodir o espaço de busca.

Em muitos casos, motifs aparecem na interação entre variáveis.

Tamanho variável de motifs

- Muitos métodos assumem tamanho fixo q .
- Na prática, o tamanho do padrão pode ser desconhecido.
- Métodos de tamanho variável buscam em faixas ou concatenam motifs menores.

Ranking de motivos e ocorrências

- Nem todo padrão recorrente é interessante.
- Motifs podem ser ranqueados por suporte, similaridade, entropia, raridade ou densidade das ocorrências.
- Padrões triviais ou quase constantes podem ser descartados.

Big data e streaming

- Séries longas tornam comparação e armazenamento desafiadores.
- iSAX, SWAMP, mSTAMP e algoritmos disk-aware atacam escala e memória.
- Em streaming, o método precisa atualizar candidatos sem recomputar tudo.

Novas estruturas e métodos

STAMP e SCRIMP calculam Matrix Profile com estratégias eficientes e anytime.

STOMP explora localidade para reduzir custo.

AAMP calcula Matrix Profile com distância Euclidiana não normalizada.

Mensagens principais

- Motifs são subsequências recorrentes descobertas por busca em janelas.
- Indexação e similaridade definem o que será considerado parecido.
- Métodos variam do brute-force exato a estruturas modernas como Matrix Profile.
- Matrix Profile cria uma ponte natural entre motifs e discords.