



Detecção Online de Eventos



Eduardo Ogasawara

eogasawara@cefet-rj.br | <https://eic.cefet-rj.br/~eogasawara>



Por que o cenário online muda o problema

No offline, a série completa está disponível para análise.

No online, observações chegam continuamente e a decisão precisa ser tomada no fluxo.

O método precisa equilibrar rapidez, precisão, memória e capacidade de adaptação.

Três cenários de eventos

Offline detection

Reconhecer eventos passados.

Online detection

Detectar eventos enquanto eles acontecem.

Online prediction

Antecipar eventos antes que ocorram.

Detecção offline



A série já foi coletada antes da análise.



O algoritmo pode olhar para passado e futuro em torno de um candidato a evento.



É adequada para auditoria, explicação retrospectiva e benchmark de métodos.

Detecção online

- As observações chegam em sequência.
- O detector precisa decidir usando apenas o que já chegou.
- A decisão deve ser rápida o suficiente para permitir reação operacional.

Predição online

O objetivo é prever a ocorrência futura de um evento.

É uma forma antecipatória de event detection.

A utilidade depende de emitir alerta antes que a ação deixe de ser possível.

Treino e teste no cenário tradicional

- A série é dividida em treino e teste de forma estática.
- O modelo é ajustado com dados passados e avaliado em dados mais recentes.
- Validação temporal e ajuste de hiperparâmetros ocorrem antes da implantação.

Treino e teste no cenário streaming



Cada batch pode treinar ou atualizar o modelo para o próximo batch.




A ordem temporal é parte do protocolo experimental.




Esse desenho imita a operação de um sistema que aprende com o fluxo.

Treinamento e teste: tradicional vs streaming



(a)



(b)

No streaming, o batch i é usado para construir ou atualizar o modelo avaliado no batch i+1.

O que é online detection

É a identificação de eventos conforme as observações chegam.

O detector processa a série sequencialmente.

Todo aprendizado, atualização e decisão ocorre durante a execução.

Formalização do fluxo temporal

A série online é um fluxo contínuo de entradas.

Em t , o modelo usa observações anteriores para decidir sobre o comportamento atual.

A decisão precisa ocorrer antes que o fluxo avance demais.

$\langle \dots, x_{t-2}, x_{t-1}, x_t, x_{t+1}, x_{t+2}, \dots \rangle$

Não dá para olhar para o futuro

No online, usar observações futuras viola o cenário operacional.

Alguns eventos só ficam claros depois de algumas observações.

Isso cria uma tensão inevitável entre decisão imediata e confirmação confiável.

Early detection

Detectar cedo pode evitar falhas, perdas ou danos.

O valor do alerta depende do tempo disponível para agir.

Em sistemas críticos, atraso pequeno pode ser a diferença entre prevenção e diagnóstico tardio.

Rapidez vs falso positivo

Detector sensível

Reage rapidamente.

Pode antecipar eventos importantes.

Tende a gerar mais falsos positivos.

Detector conservador

Exige mais evidência.

Reduz alarmes indevidos.

Pode detectar tarde ou perder eventos.

Fast data e sistemas críticos

Fast data envolve grande volume, alta velocidade e mudança em intervalos curtos.

Redes, IoT, indústria, saúde e segurança exigem monitoramento contínuo.

A solução precisa operar sob restrições de tempo, memória e confiabilidade.

Modelos estáticos vs dinâmicos

Estáticos

- Treinados antes da implantação.
- Permanecem inalterados durante a execução.
- Funcionam quando a distribuição é estável.

Dinâmicos

- São atualizados com novos dados.
- Podem acompanhar mudanças no fluxo.
- Exigem política de memória e adaptação.

Por que offline não migra diretamente



Métodos offline podem depender da série completa.



O custo computacional pode ser incompatível com fluxo contínuo.



A presença de drift muda a noção de comportamento típico.



Métricas offline podem ignorar atraso temporal da detecção.

Por que memória vira problema



Em fluxo contínuo, guardar todas as observações pode ser inviável.



Mesmo quando armazenamento é possível, reprocessar tudo pode ser caro demais.



A política de memória define o que o modelo lembra e o que esquece.

Full-memory

- Mantém todas as observações ou batches vistos até o momento.
- Preserva histórico completo.
- Tende a ser impraticável para fluxos longos, rápidos ou de alta dimensão.

No-memory


- O modelo é atualizado incrementalmente sem armazenar histórico bruto.
- É leve em memória.
- Pode esquecer detalhes úteis ou sofrer com atualizações ruidosas.

Windowed memory


- Mantém apenas uma janela recente de observações ou batches.
- Equilibra memória, adaptação e contexto temporal.
- A escolha do tamanho da janela controla o quanto o modelo lembra.

Gerenciamento de memória


(a) full memory



(b) no memory



(c) windowed memory



Full-memory, no-memory e windowed memory definem estratégias diferentes de retenção do histórico.

Retreinamento por batches recentes



O modelo pode ser reconstruído usando apenas batches recentes.



Isso ajuda a acompanhar mudanças no processo.



O custo é descartar parte do histórico e depender da representatividade da janela.

Aprendizado incremental

- O modelo é atualizado a cada exemplo ou batch.
- A nova versão depende da versão anterior e dos dados recém-chegados.
- É adequado para fluxo, mas precisa lidar com ruído, drift e esquecimento.

Não estacionaridade em fluxos temporais

O processo gerador pode mudar ao longo do tempo.

O que era típico ontem pode deixar de ser típico hoje.

Essa mudança afeta diretamente detectores treinados no passado.

Concept drift no cenário online

Concept drift ocorre quando o conceito aprendido muda no fluxo.

Modelos precisam reconhecer que a definição de comportamento típico evoluiu.

Isso aproxima detecção online de change point detection e adaptação de modelo.

Dilema estabilidade-plasticidade

Estabilidade: resistir a variações irrelevantes e ruído.

Plasticidade: adaptar-se rapidamente a mudanças reais.

Um bom sistema online precisa equilibrar as duas forças.

Active learning para drift

- O sistema tenta detectar drift antes de adaptar o modelo.
- A atualização ocorre quando há evidência de mudança.
- Reduz adaptações desnecessárias, mas depende da qualidade do detector de drift.

Passive learning para drift

- O modelo é atualizado continuamente, independentemente de alarme de drift.
- Pode acompanhar mudanças graduais.
- Pode absorver ruído ou eventos raros como se fossem parte do comportamento normal.

Online prediction

- Vai além de detectar eventos passados ou em andamento.
- Busca prever se um evento ocorrerá em uma janela futura.
- É útil quando o objetivo é mitigação, prevenção ou alerta antecipado.

Predição por classificação

- Extrai sequências e atributos de observações anteriores.
- O modelo prevê rótulos de evento para novas observações.
- É adequada quando há rótulos confiáveis para treinar o classificador.

Problemas com classificação online



Instâncias rotuladas escassas

Muitos fluxos têm poucas instâncias rotuladas.



Forte desbalanceamento

Eventos são raros, gerando forte desbalanceamento.



Rotulação cara e imprecisa

Obter rótulos por especialistas pode ser caro, lento ou impreciso.

Predição por regressão

- Usa o histórico $X = \langle x_1, \dots, x_t \rangle$ para prever valores futuros.
- A detecção de eventos é aplicada sobre a série prevista.
- Essa abordagem pode funcionar sem rótulos diretos de evento.

Detectar eventos na série prevista

01

Primeiro prevê-se uma sequência futura.

02

Depois aplica-se um detector sobre a previsão.

03

O alerta antecipa eventos esperados pelo comportamento projetado da série.

Online multivariate anomaly detection



Fluxos multivariados têm alta dimensionalidade e relações que mudam no tempo.



A anomalia pode surgir de combinações entre variáveis.



Métodos online precisam ser leves, adaptativos e robustos a drift.

Métodos distance-based

- Monitoram distâncias entre observações no fluxo.
- COD acompanha outliers baseados em distância continuamente.
- CPOD usa core points para resumir regiões locais e reduzir custo.

Métodos tree-based

Particionam o espaço de dados para isolar observações anômalas.

HS-Tree atualiza uma estrutura hierárquica em ambientes não estacionários.

RRCF usa árvores com cortes aleatórios para detecção escalável em tempo real.

Métodos projection-based

- Reduzem dimensionalidade por projeções aleatórias.
- LODA projeta dados em subespaços unidimensionais e usa histogramas.
- XStream adapta projeções e modelos conforme novas observações chegam.

Latência e viés temporal

Não basta saber se o detector acertou.

É preciso medir quando ele detectou em relação ao evento real.

Detecções antecipadas, atrasadas e alarmes persistentes têm impactos diferentes.




Métodos híbridos

Uma série pode conter anomalias, change points e motifs.

Detectores especializados capturam evidências diferentes.

Combinar métodos pode dar uma visão mais completa dos eventos no fluxo.

Referências Bibliográficas



Event Detection in Time Series

Ogasawara, E.; Salles, R.; Porto, F.;
Pacitti, E. Springer Nature Switzerland,
2025.

Time Series Analysis: With Applications in R

Cryer, J. D.; Chan, K.-S. Springer, 2008.

Data Mining: Concepts and Techniques

Han, J.; Pei, J.; Tong, H. Morgan
Kaufmann, 4^a ed., 2022.