




Detecção Online de Eventos em Séries Temporais

Change Points, Concept Drift e Métodos de Detecção em Streaming

Eduardo Ogasawara

eduardo.ogasawara@cefet-rj.br

<https://eic.cefet-rj.br/~eogasawara>

Detecção Temporal: Modos de Operação

A detecção de mudanças pode ocorrer em dois paradigmas fundamentais, definidos pelo acesso — ou não — a observações futuras.

Detecção Offline

Toda a série temporal está disponível de uma vez. O algoritmo pode **olhar para frente**, utilizando observações futuras para identificar mudanças passadas. Permite a divisão clássica em conjuntos de treino e teste, e é adequada para análises retrospectivas.

$$X = (x_1, x_2, \dots, x_T)$$

A série completa com T observações está disponível para análise global.

Detecção Online

As observações chegam sequencialmente em um fluxo contínuo. O algoritmo **não pode olhar para frente** — apenas o passado e o presente são conhecidos. Opera de forma não supervisionada ou semi-supervisionada. A detecção precoce é desejável, mas há um **tradeoff** entre rapidez na detecção e taxa de falsos positivos. No cenário de *streaming*, o lote i é usado para prever o lote $i+1$, e os instantes de tempo devem ser considerados.

$$X_t = (x_1, x_2, \dots, x_t)$$

A cada instante t , apenas as observações acumuladas até o presente estão disponíveis.

Latência de Detecção

Evento Real

Ocorre no instante τ

Detecção

Identificado em $\hat{\tau}$

Atraso

Latência de k observações

A latência de detecção é uma característica inerente ao paradigma online. Como os algoritmos precisam **inspecionar observações recentes acumuladas** antes de determinar se um evento ocorreu, há sempre um atraso entre o instante real do evento τ e o instante em que ele é identificado $\hat{\tau}$. A chegada de novos dados em tempo real impõe essa espera inevitável.

$$\Delta t = \hat{\tau} - \tau \geq k$$

A classificação precisa do tipo de evento só é possível após uma janela mínima de k observações. Isso exige um equilíbrio delicado entre a **urgência na detecção** e a **acurácia na classificação** — tensão que se torna ainda mais crítica em séries temporais com *concept drift* ou padrões evolutivos em contextos de *streaming*.

Restrições do Paradigma Online

Memória Limitada

Armazenar toda a série histórica é inviável. Soluções práticas mantêm apenas uma fração dos dados observados.

Tempo de Processamento

Cada observação deve ser processada à medida que chega — fluxos rápidos podem mudar em segundos ou milissegundos.

Sem Supervisão

Não é possível dividir em conjuntos estáticos de treino e teste nem acessar observações futuras; o algoritmo opera sem supervisão ou com supervisão parcial.

Estabilidade-Plasticidade

O dilema central: adaptar-se a mudanças relevantes sem ser perturbado por variações irrelevantes ou ruído transitório.

Diferentemente do paradigma offline, essas restrições definem os limites estruturais fundamentais da detecção de mudanças em tempo real.

Janela Deslizante

Em aprendizado de fluxo contínuo, o algoritmo precisa decidir **quanta memória histórica manter**. Existem três estratégias fundamentais:

Memória Total

Considera **todas** as observações acumuladas. Oferece contexto máximo, mas torna-se inviável à medida que o fluxo cresce.

Sem Memória

Processa apenas o **exemplo atual**, descartando tudo. Extremamente eficiente, mas incapaz de capturar tendências ou padrões ao longo do tempo.

Memória em Janela ✓

Mantém apenas as **observações mais recentes**. Equilibra contexto, velocidade e escalabilidade — ideal para fluxos de dados.

Definição Formal

A janela deslizante de tamanho w no instante t é definida como:

$$W_t = (x_{t-w+1}, \dots, x_t)$$

A cada novo dado x_t , a observação mais antiga x_{t-w} é descartada. Janelas maiores capturam mais contexto; janelas menores reagem mais rápido a mudanças.

Pseudocódigo

ENTRADA: x (série temporal), w (tamanho da janela)

PRÉ-CONDIÇÃO: $w \geq 1, t \geq w$

PASSO 1 — Inicialização

$W \leftarrow (x_1, x_2, \dots, x_w)$

PASSO 2 — Atualização a cada novo x_t

PARA t de $w+1$ até T :

$W \leftarrow (x_{t-w+1}, \dots, x_t)$ descarta x_{t-w} , inclui x_t

estatística $\leftarrow f(W)$ ex: média, variância

SAÍDA: sequência de estatísticas sobre W_t

PÓS-CONDIÇÃO: apenas os w valores mais recentes são retidos

Estatísticas Incrementais

Recalcular estatísticas do zero a cada nova observação é inviável em tempo real. O paradigma incremental atualiza a estimativa atual usando apenas o valor anterior e a nova observação.

$$\mu_t = \mu_{t-1} + (x_t - \mu_{t-1})/t$$

O termo $(x_t - \mu_{t-1})$ é o erro de predição — a correção aplicada a cada passo. Atualização em tempo $O(1)$, memória constante.

ENTRADA: x (fluxo de observações)

PRÉ-CONDIÇÃO: $t \geq 1$, μ_0 inicializado (ex: $\mu_0 = x_1$)

PASSO 1 — Inicialização

$\mu_0 \leftarrow x_1$

$\sigma^2_0 \leftarrow 0$

PASSO 2 — Para cada nova observação x_t ($t \geq 2$):

$\delta \leftarrow x_t - \mu_{t-1}$ erro de predição

$\mu_t \leftarrow \mu_{t-1} + \delta / t$ média incremental

$\sigma^2_t \leftarrow \sigma^2_{t-1} + \delta \cdot (x_t - \mu_t)$ variância incremental (Welford)

SAÍDA: sequência de estimativas (μ_t, σ^2_t) para cada t

PÓS-CONDIÇÃO: estimativas equivalentes ao cálculo em lote, sem armazenar histórico

Modelos Adaptativos

Teoria

Em cenários online, os parâmetros do modelo não podem ser estáticos. A cada nova observação, θ_t é ajustado incrementalmente para acompanhar mudanças graduais no processo.

$$\theta_t = \theta_{t-1} + \eta \cdot \nabla L(x_t, \theta_{t-1})$$

Onde η é a taxa de aprendizado e ∇L é o gradiente da função de perda.

Pseudocódigo

ENTRADA: x (fluxo de observações), θ_0 (parâmetros iniciais), η (taxa de aprendizado)

PRÉ-CONDIÇÃO: modelo inicializado com dados históricos ou prior

PASSO 1 — Para cada nova observação x_t :

$s_t \leftarrow \text{score}(x_t, \theta_{t-1})$ desvio em relação ao modelo atual

PASSO 2 — Decisão

SE $s_t > \tau$: emitir alerta de mudança

PASSO 3 — Atualização do modelo

$\theta_t \leftarrow \theta_{t-1} + \eta \cdot \nabla L(x_t, \theta_{t-1})$

SAÍDA: sequência de alertas e parâmetros θ_t atualizados

PÓS-CONDIÇÃO: modelo reflete o comportamento recente do processo

Score de Detecção

A cada instante t , o algoritmo computa um score que mede o desvio da observação atual em relação à referência corrente. Se o score ultrapassa o limiar, uma mudança é sinalizada.

$$s_t = d(x_t, \mu_{t-1})$$

Alerta se $s_t > \tau$

Onde d é uma função de discrepância (ex: distância, log-verossimilhança) e τ controla o equilíbrio entre sensibilidade e falsos alarmes.

ENTRADA: x (fluxo de observações), τ (limiar de detecção)

PRÉ-CONDIÇÃO: referência μ_0 estimada com dados iniciais

PASSO 1 — Para cada nova observação x_t :

$s_t \leftarrow d(x_t, \mu_{t-1})$ calcula o score de desvio

PASSO 2 — Decisão

SE $s_t > \tau$:

emitir alerta no instante t

(opcional) reiniciar referência $\mu_t \leftarrow x_t$

PASSO 3 — Atualização da referência

$\mu_t \leftarrow \mu_{t-1} + (x_t - \mu_{t-1}) / t$

SAÍDA: instantes de alerta detectados

PÓS-CONDIÇÃO: referência μ_t reflete o histórico acumulado até t

Tipicidade Adaptativa

Na detecção online, o que é "normal" muda com o tempo. A distribuição de referência P_t evolui à medida que novos dados chegam — tornando a tipicidade um alvo móvel.

$$\text{typ}(x_t) = P_t(x_t)$$

Uma observação x_t é considerada atípica se sua probabilidade sob a referência atual P_t for baixa. Tipicidade baixa dispara um sinal de detecção.

- ❑ A tensão central da detecção online: o modelo deve se adaptar a mudanças legítimas no processo, mas ainda assim sinalizar mudanças anômalas — com informação parcial e em tempo real.

Mudança Temporal: Change Points e Concept Drift

O livro distingue dois fenômenos centrais de mudança em séries temporais, cada um com paradigma e métodos próprios.

Change Points

Mudança na dinâmica da série (distribuição ou autocorrelação). Pode ser abrupta ou gradual. Detectada **offline** (toda a série disponível) ou **online** (o mais rápido possível).

Concept Drift

Monitoramento online de mudanças em séries em streaming. Formalmente: $p(\chi_i) \neq p(\chi_{i+1})$ entre lotes consecutivos. Classificado como **virtual** (mudança em X ou Y sem alterar o conceito χ) ou **real** (mudança no conceito χ).

Tipos de Drift

Abrupto — mudança brusca entre lotes.

Incremental — transição suave.

Gradual — alternância até estabilizar no novo conceito.

Recorrente — retorno periódico ao conceito anterior.

Distinguir esses fenômenos é essencial para escolher o método de detecção e a abordagem de tratamento adequados.

Métodos Online: Visão Comparativa

Os métodos de detecção diferem pela forma como definem tipicidade e identificam mudanças. A tabela resume as sete principais famílias — estatísticos sequenciais, probabilísticos, aprendizado online, distribuição, distância, árvore e projeção —, com exemplos de detectores representativos.

Família	Ideia Central	Quando Usar	Principal Limitação
Estatísticos Sequenciais (CUSUM, EWMA, Page-Hinkley)	Acumulam evidência estatística ao longo do tempo	Mudanças persistentes de nível ou média	Sensível à escolha do limiar; assume estacionariedade prévia
Probabilísticos	Modelam a distribuição dos dados e detectam desvios de probabilidade	Dados com distribuição conhecida ou estimável	Custo de atualização do modelo
Aprendizado Online (DDM, HDDM, ECDD)	Modelo preditivo adaptativo; evento = erro de previsão elevado	Séries com padrões complexos e não-estacionários	Risco de adaptação ao evento (esquecimento)
Distribuição (ADWIN, KSWIN, KLD, MCDD)	Comparam distribuições entre lotes consecutivos	Detecção de virtual drift e mudanças em X	Requerem definição de tamanho de lote
Distância (COD, CPOD)	Monitoramento contínuo de distâncias entre observações no fluxo	Eventos raros e bem separados do histórico	Custo quadrático sem aproximações; dificuldade em alta dimensão
Árvore (HS-Tree, RRCF)	Particionamento hierárquico do espaço de dados com atualização incremental	Streams multivariados em ambientes não estacionários	Complexidade de implementação e ajuste de hiperparâmetros
Projeção (LODA, XStream)	Redução de dimensionalidade via projeções aleatórias para detecção eficiente	Streams de alta dimensionalidade com restrição computacional	Perda de informação pela redução dimensional

Modelos Probabilísticos Online

Nos métodos probabilísticos, eventos são interpretados como mudanças nos parâmetros do modelo probabilístico. A detecção online acompanha a evolução desses parâmetros ao longo do tempo.

Distribuição Temporal

Observações seguem F_{θ_t} com parâmetros variáveis

Parâmetros Dinâmicos

θ_t evolui conforme o processo temporal

Inferência Incremental

Atualização contínua do modelo

Aprendizado de Máquina Online

No aprendizado online, os dados chegam em fluxo contínuo — sem divisão estática entre treino e teste, e sem possibilidade de antecipar observações futuras. O modelo preditivo se ajusta continuamente, identificando eventos quando o erro de previsão cresce além do esperado: $e_t = |x_t - \hat{x}_t|$. Detectores adaptativos distinguem **drift gradual** (ajuste progressivo do modelo) de **ruptura abrupta** (reset necessário).

Modelos Estáticos

Treinados em grandes amostras e aplicados diretamente ao fluxo, sem atualização durante a execução

Modelos Dinâmicos

Inicializados em uma amostra e atualizados incrementalmente à medida que novos dados chegam

Aprendizado Ativo

Detecta concept drift explicitamente e adapta o modelo somente quando uma mudança é identificada

Aprendizado Passivo

Atualiza o modelo a cada nova entrada, independentemente de drift — mais fluido, porém menos sensível a rupturas

- ❏ O dilema estabilidade-plasticidade: o modelo deve permanecer adaptável a mudanças significativas, mas estável diante de variações irrelevantes.

Predição Online de Eventos

A predição online vai além da detecção: em vez de identificar eventos passados ou em curso, ela antecipa eventos futuros dentro de uma janela de tempo, permitindo respostas proativas antes que o impacto ocorra.

Predição por Classificação

Sequências e features extraídas de observações anteriores são analisadas para deduzir padrões temporais. O modelo aprendido é aplicado a novas observações para prever rótulos de eventos. Desafio: necessidade de *rótulos* e *dados desbalanceados* (eventos anômalos são raros).

Predição por Regressão

A série histórica $X = (x_1, \dots, x_t)$ é usada para prever sequências futuras $\hat{X} = (x_{t+1}, \dots, x_{t+h})$. Eventos são então identificados na série predita $\hat{X}$ por métodos de detecção supervisionados ou não supervisionados. Não requer rótulos.

$$\hat{X} = (x_{t+1}, \dots, x_{t+h})$$

Janela de Predição

A predição online foca em determinar se um evento-alvo ocorrerá dentro de uma janela futura de tamanho h . Combina modelos de séries temporais com métodos de detecção de eventos.

Métodos de predição online ainda estão em estágio inicial de maturidade, mas oferecem capacidade antecipatória única para mitigar riscos em sistemas críticos.

Métodos Baseados em Distância, Árvore e Projeção

Três grandes categorias de métodos detectam anomalias em séries multivariadas online: baseados em **distância**, em **árvores** de particionamento e em **projeção** dimensional. Cada abordagem equilibra custo computacional, adaptabilidade e precisão de forma distinta.

Distância

Monitoramento contínuo das distâncias entre observações. **COD**: rastreia distâncias em tempo real. **CPOD**: resume regiões locais via pontos-núcleo, reduzindo custo computacional.

Árvore

Particionamento do espaço de dados para isolar anomalias. **HS-Tree**: estrutura hierárquica com atualizações incrementais, adequada a ambientes não estacionários. **RRCF**: cortes aleatórios multidimensionais em ensemble escalável.

Projeção

Redução de dimensionalidade para detecção eficiente. **LODA**: projeções aleatórias em subespaços 1D com histogramas. **XStream**: ajusta-se dinamicamente às características evolutivas do fluxo de dados.

A escolha do método depende da dimensionalidade dos dados, do volume do fluxo e da exigência de tempo real: métodos de distância são intuitivos mas podem sofrer com alta dimensionalidade; árvores escalam bem; projeções são as mais leves computacionalmente.

CUSUM Sequencial

Ideia Central

Acumula desvios positivos em relação à média esperada.

Quando a soma ultrapassa o limiar h , uma mudança de nível é detectada.

$$C_t^+ = \max(0, C_{t-1}^+ + (x_t - \mu_0) - k)$$

k: parâmetro de sensibilidade (filtra ruído). **h**: limiar de detecção. **μ_0** : média esperada sob normalidade.

CUSUM — Soma Cumulativa para Detecção de Mudança

ENTRADA: x (série temporal), μ_0 (média esperada), k (sensibilidade), h (limiar)

PRÉ-CONDIÇÃO: série estacionária antes do evento; $k > 0$, $h > 0$

PASSO 1 — Inicialização

$C^+ \leftarrow 0$

PASSO 2 — Atualização incremental

PARA CADA nova observação x_t :

$C^+ \leftarrow \max(0, C^+ + (x_t - \mu_0) - k)$

PASSO 3 — Decisão

SE $C^+ > h$:

DETECTAR evento no instante t

$C^+ \leftarrow 0$ ← reset após detecção

SAÍDA: instante t de detecção (ou nenhum)

PÓS-CONDIÇÃO: $C^+ = 0$ após cada detecção; custo $O(1)$ por passo

Média Móvel Exponencial (EWMA)

Ideia Central

Pondera observações recentes com maior peso. A média exponencial z_t suaviza a série e detecta mudanças graduais quando se afasta da banda de controle.

$$z_t = \lambda \cdot x_t + (1 - \lambda) \cdot z_{t-1}$$

$\lambda \in (0,1]$: fator de suavização. λ próximo de 1 reage rápido; λ próximo de 0 suaviza mais. **L**: largura da banda de controle.

EWMA — Média Móvel Exponencialmente Ponderada

ENTRADA: x (série temporal), λ (suavização), μ_0 (média), σ (desvio), L (banda)

PRÉ-CONDIÇÃO: $0 < \lambda \leq 1$; processo estacionário antes do evento

PASSO 1 — Inicialização

$$z \leftarrow \mu_0$$

PASSO 2 — Atualização incremental

PARA CADA nova observação x_t :

$$z \leftarrow \lambda \cdot x_t + (1 - \lambda) \cdot z$$

PASSO 3 — Banda de controle

$$\sigma_z \leftarrow \sigma \cdot \sqrt{\lambda / (2 - \lambda)}$$

$$LCI \leftarrow \mu_0 - L \cdot \sigma_z$$

$$LCS \leftarrow \mu_0 + L \cdot \sigma_z$$

PASSO 4 — Decisão

SE $z < LCI$ OU $z > LCS$:

DETECTAR evento no instante t

SAÍDA: instante t de detecção (ou nenhum)

PÓS-CONDIÇÃO: z retém memória de toda a série; custo $O(1)$ por passo

Page-Hinkley

Ideia Central

Monitora o desvio acumulado da média corrente. Detecta shift persistente de média quando a diferença entre o máximo histórico e o valor atual ultrapassa o limiar λ .

$$M_t = \sum_{i=1}^t (x_i - \bar{x}_t - \delta) PH_t = M_t^* - M_t$$

δ : magnitude mínima de mudança a detectar. **λ** : limiar de detecção.

M_t^* : máximo histórico de M_t .

Page-Hinkley — Detecção de Shift de Média

ENTRADA: x (série temporal), δ (magnitude mínima), λ (limiar)

PRÉ-CONDIÇÃO: processo estacionário antes do evento; $\delta > 0, \lambda > 0$

PASSO 1 — Inicialização

soma $\leftarrow$ 0; M_max $\leftarrow$ 0; n $\leftarrow$ 0; x_bar $\leftarrow$ 0

PASSO 2 — Atualização incremental

PARA CADA nova observação x_t :

n $\leftarrow$ n + 1

x_bar $\leftarrow$ x_bar + (x_t - x_bar) / n $\leftarrow$ média online

soma $\leftarrow$ soma + (x_t - x_bar - δ)

M_max $\leftarrow$ max(M_max, soma)

PASSO 3 — Estatística PH

PH_t $\leftarrow$ M_max - soma

PASSO 4 — Decisão

SE PH_t > λ :

DETECTAR evento no instante t

REINICIAR estado

SAÍDA: instante t de detecção (ou nenhum)

PÓS-CONDIÇÃO: média atualizada online; custo $O(1)$ por passo

Pipeline de Detecção Online

A detecção online pode ser vista como um pipeline modular onde cada etapa transforma incrementalmente os dados brutos em decisões sobre eventos temporais.

1. Ingestão de Dados

Observações x_t chegam sequencialmente, uma a uma, em fluxo contínuo

2. Gerenciamento de Memória

Define o que reter: memória completa, sem memória ou janela deslizante

3. Atualização Incremental

Estatísticas e parâmetros do modelo são atualizados a cada nova observação com custo $O(1)$

4. Cálculo do Score

Computa uma medida de desvio S_t em relação à referência atual

5. Decisão

Compara o score ao limiar: $S_t > \theta \rightarrow$ evento detectado e alarme emitido

6. Adaptação

Após detecção, atualiza o modelo ou referência para lidar com concept drift

Cada família de métodos instancia esse pipeline de forma diferente, mas a estrutura modular é sempre a mesma.

Latência versus Precisão: o Trade-off Central

Detectar cedo reduz o atraso de resposta, mas aumenta o risco de falsos positivos — e alarmes frequentes e imprecisos tendem a ser ignorados. Esse é o trade-off fundamental de qualquer sistema de detecção online.

Velocidade vs. Acurácia

Métodos rápidos reagem a qualquer desvio; métodos lentos exigem evidência acumulada.

- **Baixa latência:** menor atraso $\Delta t = \hat{\tau} - \tau$, mas mais falsos positivos e risco de alarmes ignorados
- **Alta precisão:** menos alarmes falsos, mas o evento pode já ter causado impacto irreversível

Inadequação das Métricas Clássicas

Precisão, recall e acurácia são insuficientes no cenário online.

- Não capturam **quando** a detecção ocorreu, apenas **se** ocorreu
- Uma detecção correta com grande atraso pode ser tão problemática quanto uma detecção errada

Viés Temporal e Métricas Adequadas

Métricas devem contabilizar acurácia e tempo decorrido.

- **Viés temporal:** tendência sistemática de antecipar ou atrasar detecções em relação ao evento real
- Detecções precoces geram alarmes falsos; detecções tardias impedem respostas a tempo

A calibração do limiar θ controla o trade-off velocidade–precisão, mas a avaliação rigorosa exige métricas que integrem acurácia e viés temporal.

Complexidade Computacional em Streaming

Em streaming, cada nova observação deve ser processada imediatamente — sem rever o histórico completo e, frequentemente, sem sequer armazená-lo. O requisito central é duplo: custo por passo aproximadamente constante ($O(1)$) e uso de memória limitado a uma fração dos dados totais.

Métodos Batch (inviáveis)

Reprocessam toda a série a cada nova observação. Custo $O(n)$ ou $O(n^2)$ por passo e demanda de memória irrestrita. Impraticável em tempo real, onde dados chegam em milissegundos.

Métodos Incrementais (viáveis)

Atualizam apenas estatísticas suficientes (média, variância, contagem) a cada nova observação. Custo $O(1)$ por passo e memória constante. Plenamente escaláveis para fluxos contínuos de alto volume.

Janela Deslizante (compromisso)




Mantêm uma janela de tamanho fixo w . Custo $O(w)$ por passo. Reduzem o atraso de detecção preservando adaptabilidade, sem exigir o histórico completo.

Alta Dimensionalidade (desafio)

Métodos baseados em distância incorrem em custo quadrático em espaços de alta dimensão. Abordagens baseadas em árvores ou projeções oferecem melhor escalabilidade para streams multivariados.

A escolha do método deve equilibrar acurácia de detecção, viabilidade de memória e custo computacional por observação — não apenas desempenho estatístico isolado.

Referências Bibliográficas



Event Detection in Time Series

Ogasawara, E.; Salles, R.; Porto, F.; Pacitti, E.
Springer Nature Switzerland, 2025.

Time Series Analysis: With Applications in R

Cryer, J. D.; Chan, K.-S. Springer, 2008.

Data Mining: Concepts and Techniques

Han, J.; Pei, J.; Tong, H. Morgan Kaufmann, 4^a ed., 2022.