



Métricas de Avaliação de Eventos

Medir a correspondência entre eventos reais e detectados ao longo do tempo é crucial para a validação de algoritmos.

Eduardo Ogasawara

eduardo.ogasawara@cefet-rj.br

<https://eic.cefet-rj.br/~eogasawara>

Introdução

Avaliar detecção de eventos significa medir a correspondência entre dois conjuntos temporais — eventos reais e eventos detectados. O ponto de partida é o paradigma clássico de classificação binária, que conta acertos e erros por amostra.

Considere dois conjuntos de instantes de evento:

$$\mathcal{E} = \{\tau_1, \dots, \tau_n\}, \quad \hat{\mathcal{E}} = \{\hat{\tau}_1, \dots, \hat{\tau}_m\}$$

Onde:

- $\mathcal{E}$ representa eventos reais
- $\hat{\mathcal{E}}$ representa eventos detectados
- τ_i é o instante do i-ésimo evento real
- $\hat{\tau}_j$ é o instante do j-ésimo evento detectado
- n é o número de eventos reais
- m é o número de eventos detectados

TP – Verdadeiro Positivo

Evento real corretamente detectado.

FP – Falso Positivo

Detecção sem evento real correspondente.

FN – Falso Negativo

Evento real não detectado.

TN – Verdadeiro Negativo

Não-evento corretamente ignorado.

Este paradigma pressupõe rótulos exatos por amostra — o problema surge quando aplicamos isso ao tempo contínuo.

O Que Conta Como Acerto?

Um evento real ocorre em $t=10$; o detector marca $t=12$. Isso é um acerto ou um erro? A coincidência exata entre τ_i e $\hat{\tau}_j$ é rara na prática — $\tau_i \neq \hat{\tau}_j$ **quase sempre** — e isso, por si só, não implica erro absoluto.

Coincidência Exata é Rara

Exigir precisão absoluta transforma detecções úteis em falsos positivos, penalizando sistemas que funcionam bem na prática.

A Avaliação Depende de uma Regra

Sem um critério de tolerância temporal, TP, FP e FN ficam indefinidos — a métrica não existe sem uma fronteira de aceitação.

Diferentes Regras, Diferentes Resultados

A mesma detecção pode ser TP com $\delta=3s$ e FP com $\delta=1s$. A escolha da janela de tolerância determina o resultado.

A questão central não é se houve detecção, mas **o que conta como próximo o suficiente**.

Precision, Recall e F_1

Fórmulas das Métricas

$$\text{Precision} = \frac{TP}{TP + FP}$$

$$\text{Recall} = \frac{TP}{TP + FN}$$

$$F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

⚠ TP, FP e FN só podem ser contados depois que uma regra de correspondência temporal estiver definida. Sem ela, as métricas acima ficam indefinidas ou inconsistentes.

❏ A resposta exige uma regra de tolerância temporal — e diferentes escolhas de δ produzem valores completamente diferentes de Precision, Recall e F_1 .

Definições

- **TP (True Positive):** detecção correta — um evento real foi detectado dentro do critério temporal
- **FP (False Positive):** alarme falso — detecção sem evento real correspondente
- **FN (False Negative):** evento perdido — evento real sem detecção correspondente

-
- **Precision:** fração de detecções que são corretas
 - **Recall:** fração de eventos reais que foram detectados
 - **F_1 :** média harmônica entre Precision e Recall

Correspondência e Contagem com Tolerância

Define-se uma regra de *matching* onde acerto significa estar dentro de uma janela de tolerância δ .

Função de Correspondência

$$M(\tau_i, \hat{\tau}_j) = \begin{cases} 1, & \text{se } |\tau_i - \hat{\tau}_j| \leq \delta \\ 0, & \text{caso contrário} \end{cases}$$

δ é a "régua" da avaliação — controla o que conta como acerto. **TP** = pares aceitos; **FP** = detecções sem par; **FN** = eventos sem cobertura.

Contagem com Tolerância

$$\begin{aligned} \text{TP} &= \sum_{i,j} M(\tau_i, \hat{\tau}_j) \\ \text{FP} &= |\hat{E}| - \text{TP} \quad \text{FN} = |E| - \text{TP} \end{aligned}$$

ENTRADA: $E = \{\tau_1, \dots, \tau_n\}$ (eventos reais)
 $\hat{E} = \{\hat{\tau}_1, \dots, \hat{\tau}_m\}$ (eventos detectados)
 δ (tolerância)
PRÉ-CONDIÇÃO: E e $\hat{E}$ ordenados cronologicamente, $\delta > 0$

PASSO 1 — Inicialização
 $\text{pareados_E} \leftarrow$ conjunto vazio
 $\text{pareados_}\hat{E} \leftarrow$ conjunto vazio

PASSO 2 — Matching
PARA CADA τ_i em E :
 PARA CADA $\hat{\tau}_j$ em $\hat{E}$ (não pareado):
 SE $|\tau_i - \hat{\tau}_j| \leq \delta$:
 adicionar (i, j) a pareados_E e $\text{pareados_}\hat{E}$
 parar busca para τ_i

PASSO 3 — Contagem
 $\text{TP} \leftarrow |\text{pareados_E}|$
 $\text{FP} \leftarrow |\hat{E}| - \text{TP}$
 $\text{FN} \leftarrow |E| - \text{TP}$

SAÍDA: TP, FP, FN
PÓS-CONDIÇÃO: cada evento real e cada detecção participam de no máximo um par

❑ Esta abordagem de matching com tolerância δ é a base do **SoftED** (Soft Evaluation for Event Detection), uma métrica formal que estende as métricas clássicas para o contexto temporal — introduzindo flexibilidade sem perder interpretabilidade.

Erro Temporal de Detecção

Além de contar acertos, mede-se o deslocamento no tempo. O erro é contínuo (positivo ou negativo) e o MAE_τ resume a magnitude média.

Erro por Evento

$$\Delta\tau_i = \hat{\tau}_i - \tau_i$$

Erro Médio Absoluto

$$MAE_\tau = \frac{1}{|\mathcal{E}|} \sum_i |\Delta\tau_i|$$

MAE_τ conversa diretamente com latência e precisão temporal — complementa F_1 ao revelar o quanto a detecção se deslocou no tempo.

ENTRADA: $E = \{\tau_1, \dots, \tau_n\}$ (eventos reais)

$\hat{E} = \{\hat{\tau}_1, \dots, \hat{\tau}_n\}$ (eventos detectados, já pareados)

PRÉ-CONDIÇÃO: $|E| = |\hat{E}|$ (apenas pares TP considerados)

τ_i e $\hat{\tau}_i$ correspondem ao mesmo evento

PASSO 1 — Cálculo dos erros individuais

PARA i de 1 até n :

$\Delta\tau_i \leftarrow \hat{\tau}_i - \tau_i$

PASSO 2 — Erro médio absoluto

soma $\leftarrow 0$

PARA i de 1 até n :

soma $\leftarrow$ soma + $|\Delta\tau_i|$

$MAE_\tau \leftarrow$ soma / n

PASSO 3 — Diagnóstico (opcional)

erro_max $\leftarrow \max(|\Delta\tau_i|)$

erro_min $\leftarrow \min(|\Delta\tau_i|)$

SAÍDA: $MAE_\tau, \{\Delta\tau_i\}$

PÓS-CONDIÇÃO: $MAE_\tau \geq 0$

$\Delta\tau_i > 0 \rightarrow$ detecção tardia

$\Delta\tau_i < 0 \rightarrow$ detecção antecipada

❗ Nota: o MAE_τ é uma extensão didática que complementa as métricas clássicas — não faz parte do SoftED formal (Seção 7.2 do livro). É útil para diagnosticar a magnitude do deslocamento temporal nas detecções corretas.

Métricas como Função de tolerância δ

A qualidade de um detector **não é um número único** — ela depende da tolerância δ . Variar δ muda a régua de avaliação e, portanto, os valores de TP, FP, FN, Precision, Recall e F_1 .

$$F_1(\delta), \quad \delta \in [0, \delta_{\max}]$$

Um δ pequeno é **exigente** (menos acertos, Recall cai); um δ grande é **permissivo** (mais acertos, Recall sobe). A curva $F_1(\delta)$ revela a robustez real do detector ao longo de toda a faixa de tolerância — mais honesta que um único valor.

ENTRADA: E (eventos reais), $\hat{E}$ (eventos detectados)

$\Delta = \{\delta_1, \delta_2, \dots, \delta_k\}$ (grade de tolerâncias)

PRÉ-CONDIÇÃO: Δ ordenado crescentemente, $\delta_i > 0$

PASSO 1 — Inicialização

curva $\leftarrow$ lista vazia

PASSO 2 — Varredura de tolerâncias

PARA CADA δ em Δ :

TP, FP, FN $\leftarrow$ Matching($E, \hat{E}, \delta$) algoritmo anterior

Precision $\leftarrow$ TP / (TP + FP)

Recall $\leftarrow$ TP / (TP + FN)

$F_1 \leftarrow 2 \cdot$ Precision $\cdot$ Recall / (Precision + Recall)

adicionar (δ , Precision, Recall, F_1) a curva

PASSO 3 — Análise da curva

$\delta_{\text{ótimo}} \leftarrow \delta$ que maximiza F_1 em curva

SAÍDA: curva $F_1(\delta)$, $\delta_{\text{ótimo}}$

PÓS-CONDIÇÃO: curva é monotonicamente não-decrescente em Recall conforme δ cresce

Avaliação como Problema Contínuo

A avaliação de eventos em séries temporais não é um problema binário simples. O desempenho de um detector não existe no vácuo — ele depende de $\mathcal{E}$ (eventos reais), $\hat{\mathcal{E}}$ (eventos detectados) e δ (tolerância temporal). Juntos, esses três elementos definem o que significa detectar bem.

$$Q = f(\mathcal{E}, \hat{\mathcal{E}}, \delta)$$

O tempo entra na avaliação não como ruído a ser ignorado, mas como **variável de controle da qualidade**. Mudar δ é mudar o próprio critério de sucesso.

Não há métrica neutra

Todo F_1 reportado pressupõe uma tolerância δ . Sem especificá-la, o número não diz nada.

Escolher δ é uma decisão científica

Não é um detalhe técnico. É uma escolha que define o que "boa detecção" significa para o seu problema.

Escolher δ não é um detalhe de implementação — é uma decisão científica que molda o significado de desempenho.

Limitações do Modelo Pontual

$$\tau_i \in \mathbb{T}$$

Onde τ_i representa o instante do i -ésimo evento e $\mathbb{T}$ é o conjunto de instantes de tempo considerados.

$$\tau_i \neq \hat{\tau}_j$$

A simples diferença entre instantes não resolve adequadamente o caso intervalar.

Quando o modelo pontual falha

Eventos com duração significativa (surto, falhas prolongadas, regimes anômalos). Comparar apenas instantes distorce o que significa acertar na detecção.

Limitação Crítica

Um detector pode acertar quase toda a duração do evento e ainda assim "errar" o instante exato. Critérios de sobreposição são essenciais para avaliação intervalar.

Representação de Eventos Temporais

Eventos podem ser representados de três formas distintas. A escolha da representação muda fundamentalmente a avaliação e a detecção.

Pontual

Instante único no tempo: $e_i = \tau_i$

Simples, mas ignora duração.

Intervalar

Duração explícita:

$$e_i = [t_i^{start}, t_i^{end}]$$

Conjuntos: $\mathcal{E} = \{e_1, \dots, e_n\}$ e $\hat{\mathcal{E}} = \{\hat{e}_1, \dots, \hat{e}_m\}$

Estrutural (Padrão)

Subsequência com forma:

$e_i = X_{t:t+w}$, onde w é o tamanho da janela.

IoU Temporal: Interseção, União e Pontuação

O IoU mede a qualidade da sobreposição entre um evento real e um detectado. É construído em dois passos: interseção e união.

Interseção

$$\text{intersec}(e_i, \hat{e}_j) = \max\left(0, \min(\text{end}_i, \text{end}_j) - \max(\text{start}_i, \text{start}_j)\right)$$

União

$$|e_i \cup \hat{e}_j| = \max(\text{end}_i, \text{end}_j) - \min(\text{start}_i, \text{start}_j)$$

IoU

$$\text{IoU}(e_i, \hat{e}_j) = \frac{\text{intersec}(e_i, \hat{e}_j)}{|e_i \cup \hat{e}_j|}$$

Resultado entre 0 (sem sobreposição) e 1 (coincidência perfeita), independente da duração dos eventos.

IoU Temporal

ENTRADA: $e_i = (s_i, e_i)$, $\hat{e}_j = (\hat{s}_j, \hat{e}_j)$ — par de intervalos

PRÉ-CONDIÇÃO: $s_i \leq e_i$ e $\hat{s}_j \leq \hat{e}_j$ (intervalos válidos)

PASSO 1 — Interseção

overlap_start $\leftarrow \max(s_i, \hat{s}_j)$

overlap_end $\leftarrow \min(e_i, \hat{e}_j)$

intersec $\leftarrow \max(0, \text{overlap_end} - \text{overlap_start})$

PASSO 2 — União

union_start $\leftarrow \min(s_i, \hat{s}_j)$

union_end $\leftarrow \max(e_i, \hat{e}_j)$

union $\leftarrow \text{union_end} - \text{union_start}$

PASSO 3 — IoU

SE union = 0 ENTÃO

IoU $\leftarrow 0$

SENÃO

IoU $\leftarrow \text{intersec} / \text{union}$

SAÍDA: IoU $\in [0, 1]$

PÓS-CONDIÇÃO: IoU = 1 sse $s_i = \hat{s}_j$ e $e_i = \hat{e}_j$

Métricas Intervalares: Matching por Sobreposição Mínima

Uma detecção é aceita como correta se o IoU com o evento real superar um limiar mínimo θ . Isso define TP, FN e FP no contexto intervalar.

Verdadeiro Positivo (TP)

Existe $\hat{e}_j$ tal que

$$IoU(e_i, \hat{e}_j) \geq \theta$$

Falso Negativo (FN)

Evento real e_i sem nenhuma detecção com $IoU \geq \theta$.

Falso Positivo (FP)

Detecção $\hat{e}_j$ sem evento real correspondente com $IoU \geq \theta$.

☐ Valores típicos de θ : **0.3**, **0.5** ou **0.7**.

Matching Intervalar por IoU

ENTRADA: $\mathcal{E} = \{e_1, \dots, e_n\}$, $\hat{\mathcal{E}} = \{\hat{e}_1, \dots, \hat{e}_m\}$, limiar θ

PRÉ-CONDIÇÃO: todos os intervalos são válidos ($start \leq end$)

PASSO 1 — Inicialização

matched_real $\leftarrow$ conjunto vazio

matched_detected $\leftarrow$ conjunto vazio

PASSO 2 — Matching guloso por IoU decrescente

PARA cada par $(e_i, \hat{e}_j)$ ordenado por $IoU(e_i, \hat{e}_j)$ decrescente:

SE $IoU(e_i, \hat{e}_j) \geq \theta$

E $e_i \notin \text{matched_real}$

E $\hat{e}_j \notin \text{matched_detected}$ ENTÃO

matched_real $\leftarrow$ matched_real $\cup \{e_i\}$

matched_detected $\leftarrow$ matched_detected $\cup \{\hat{e}_j\}$

PASSO 3 — Contagem

TP $\leftarrow |\text{matched_real}|$

FN $\leftarrow n - \text{TP}$

FP $\leftarrow m - \text{TP}$

SAÍDA: TP, FN, FP

PÓS-CONDIÇÃO: Precisão = $\text{TP}/(\text{TP}+\text{FP})$, Recall = $\text{TP}/(\text{TP}+\text{FN})$



Granularidade Muda a Avaliação

A resolução temporal escolhida não é neutra — ela altera diretamente os resultados da avaliação.

Granularidade Grossa (ex: horas)

Intervalos parecem se sobrepor mesmo quando há grande distância real. IoU artificialmente **alto**.

Granularidade Fina (ex: milissegundos)

Pequenos desalinhamentos eliminam a sobreposição. IoU artificialmente **baixo**.

Ambiguidade de Fronteira

O instante exato de início ou fim de um evento raramente é preciso. A granularidade amplifica essa incerteza.

Sempre reporte a granularidade temporal usada na avaliação.

Síntese: Três Níveis de Avaliação

A avaliação de detecção de eventos evolui em três níveis de riqueza e realismo.

Nível 1 – Pontual

Eventos como instantes. Simples, mas ignora duração. Adequado para eventos instantâneos.

Nível 2 – Intervalar

Eventos como intervalos $[s, e]$. Matching por IoU com limiar θ . Mais realista para eventos com duração.

Nível 3 – Avaliação Temporal Rica

Incorpora granularidade, ambiguidade de fronteira e qualidade da sobreposição. Avaliação mais completa e honesta.

Escolher o nível certo depende da natureza do evento e do contexto de aplicação.

Os Três Pilares da Avaliação Científica

A avaliação científica de detectores de eventos repousa sobre três pilares fundamentais — sem eles, qualquer comparação entre detectores D_1 e D_2 carece de validade experimental.

Benchmark

A estrutura formal que define os dados, os eventos de referência e as condições de teste. Sem um benchmark compartilhado, os detectores são testados em mundos diferentes.

Ground Truth

O conjunto de eventos rotulados que serve de referência para medir acertos e erros. A qualidade e a confiabilidade do ground truth determinam o teto da validade da avaliação.

Protocolo Experimental

As regras que governam divisão treino/teste, validação cruzada e otimização de hiperparâmetros. Um protocolo uniforme garante que as diferenças de desempenho reflitam os detectores, não as condições de teste.

❏ A comparação justa entre D_1 e D_2 só é possível quando os três pilares são compartilhados.

Benchmark em Detecção de Eventos

Um benchmark é uma estrutura formal de validação que torna a comparação repetível e científica. Qualquer pesquisador pode testar diferentes detectores no mesmo benchmark e obter resultados comparáveis.

Essa formalização é essencial para transformar avaliação subjetiva em processo científico robusto.

Componentes do Benchmark

$$\mathcal{B} = (\mathcal{X}, \mathcal{E}, \mathcal{M})$$

- $\mathcal{B}$ = benchmark completo
- $\mathcal{X}$ = conjunto de séries temporais
- $\mathcal{E}$ = eventos anotados (ground truth)
- $\mathcal{M}$ = conjunto de métricas de avaliação

Ground Truth: O Problema Metodológico Central

O ground truth não é um dado — é uma construção. Toda avaliação depende de rótulos que foram produzidos por humanos, sensores ou modelos, e essa origem introduz incerteza sistemática que contamina qualquer métrica calculada sobre ele.

Subjetividade da Rotulagem

Anotadores diferentes discordam sobre onde um evento começa e termina. O inter-annotator agreement raramente é perfeito, e essa variância é raramente reportada.

Viés de Observação

O que foi rotulado depende de quem observou, quando e com qual instrumento. Eventos não observados são silenciosamente tratados como ausentes.

Propagação do Erro

Métricas como precisão e recall são calculadas contra um ground truth imperfeito. Um detector "pior" pode estar, na verdade, detectando eventos reais que o ground truth perdeu.

"Um benchmark com ground truth de baixa qualidade não mede o desempenho do detector — mede a distância entre o detector e os erros do anotador."

Protocolo Experimental de Avaliação Comparativa

A Ideia Central

O protocolo define as regras do jogo antes de qualquer detector ser executado. Sem um protocolo fixo, diferenças de desempenho entre D_1 e D_2 podem refletir as condições de teste, não os detectores.

$$\text{Protocolo} = (\text{split}, k\text{-fold}, \lambda^*)$$

- split: proporção treino/teste (e.g., 80/20)
- k-fold: número de folds na validação cruzada
- λ^* : hiperparâmetros otimizados antes da avaliação final

Protocolo Experimental — Avaliação Comparativa

ENTRADA: X (série temporal), E (ground truth), D_1, D_2 (detectores), k (folds)
PRÉ-CONDIÇÃO: X e E compartilham o mesmo índice temporal; $|\varphi| < 1$ se modelo AR

PASSO 1 — Divisão temporal

$(X_{\text{treino}}, X_{\text{teste}}) \leftarrow \text{split_temporal}(X, \text{razão}=0.8)$

$(E_{\text{treino}}, E_{\text{teste}}) \leftarrow \text{split_temporal}(E, \text{razão}=0.8)$

PASSO 2 — Otimização de hiperparâmetros (por detector)

PARA cada detector D_i em $\{D_1, D_2\}$:

$\lambda^*_i \leftarrow \text{argmin}_{\lambda} \text{erro_kfold}(D_i, X_{\text{treino}}, E_{\text{treino}}, k)$

PASSO 3 — Avaliação no conjunto de teste

PARA cada detector D_i em $\{D_1, D_2\}$:

$\hat{E}_i \leftarrow D_i(X_{\text{teste}}, \lambda^*_i)$

$(P_i, R_i, F1_i) \leftarrow \text{calcular_métricas}(\hat{E}_i, E_{\text{teste}})$

PASSO 4 — Comparação

SE $F1_1 > F1_2$: reportar D_1 superior

SENÃO SE $F1_1 \approx F1_2$: aplicar teste de significância estatística

SAÍDA: ranking de detectores com métricas e intervalo de confiança

PÓS-CONDIÇÃO: X_{teste} nunca visto durante otimização de hiperparâmetros


Tipos de Benchmark: Comparativo

A escolha do tipo de benchmark determina o que pode ser afirmado sobre o desempenho do detector. Cada abordagem tem trade-offs fundamentais.

Tipo	Como funciona	Vantagens	Limitações
Sintético	Eventos gerados por modelo controlável $(x_t = f_{\theta}(t) + \varepsilon_t)$	Ground truth perfeito; diagnósticos limpos; reproduzível	Baixo realismo; pode não capturar complexidade de dados reais
Real	Séries observadas em domínios reais (finanças, biomédico, redes, industrial)	Alta validade ecológica; testa condições que importam na prática	Ground truth incompleto ou incerto; difícil de controlar variáveis
Híbrido	Eventos sintéticos inseridos em séries reais $(x_t = x_t^{\text{real}} + e_t^{\text{sint}})$	Combina realismo com controle; ground truth parcialmente conhecido	Inserção artificial pode não refletir eventos naturais; complexidade de construção


 **Benchmarks sintéticos** são ideais para diagnóstico; **reais** para validação; **híbridos** para calibração de robustez.

Referências Bibliográficas




Event Detection in Time Series

Ogasawara, E.; Salles, R.; Porto, F.; Pacitti, E.
Springer Nature Switzerland, 2025.



Time Series Analysis: With Applications in R

Cryer, J. D.; Chan, K.-S. Springer, 2008.



Data Mining: Concepts and Techniques

Han, J.; Pei, J.; Tong, H. Morgan Kaufmann, 4^a ed., 2022.