

Avaliação de Detecção de Eventos em Séries Temporais



Eduardo Ogasawara

eogasawara@cefet-rj.br | <https://eic.cefet-rj.br/~eogasawara>



Avaliar eventos temporais não é classificar pontos

O eixo central desta apresentação: avaliar detecção de eventos não é o mesmo que classificar instantes independentes.

1 A posição temporal da detecção importa

Uma detecção próxima pode ser útil mesmo sem coincidir exatamente.

2 Eventos têm naturezas distintas

Podem ser pontuais, intervalares, antecipáveis ou detectáveis apenas com atraso.

3 Métricas clássicas ignoram a estrutura temporal

Precisamos de abordagens específicas para séries temporais.

O problema do acerto exato

Métricas clássicas tratam cada instante como independente — e isso tem consequências sérias para a avaliação de detectores.

Instantes independentes

Métricas clássicas tratam cada instante como independente, sem considerar vizinhança temporal.

Penalidade dupla

Um erro de uma unidade no tempo gera simultaneamente um falso positivo e um falso negativo.

Detectores úteis descartados

Isso pode eliminar detectores operacionalmente valiosos em aplicações reais.

Eventos como classe positiva

Rotulagem por instante

Cada instante da série é rotulado como **evento (positivo)** ou **não evento (negativo)**.

Eventos: classe positiva

Eventos são a classe positiva — **raros**, mas de **alto interesse**.

Observações típicas: classe negativa

Observações típicas são a classe negativa — **dominantes em volume**, mas de menor interesse direto.

📌 Essa assimetria de classes é central para entender por que **accuracy** pode ser enganosa.

Matriz de confusão

TP – Verdadeiro Positivo

Evento real corretamente detectado.

TN – Verdadeiro Negativo

Não evento corretamente ignorado.

FP – Falso Positivo

Alarme disparado onde não havia evento real.

FN – Falso Negativo

Evento real não detectado pelo método.

 TP e TN são acertos. FP e FN são erros com consequências distintas.

Accuracy e Error Rate

Accuracy

Proporção total de acertos sobre todas as observações.

$$\text{accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

Error Rate

Complemento da accuracy.

$$\text{error rate} = 1 - \text{accuracy} = \frac{FP + FN}{TP + TN + FP + FN}$$

Limitação em eventos raros

- Em séries com poucos eventos, acertar todos os não eventos já garante alta accuracy.
- O método pode ter recall zero e ainda assim apresentar accuracy elevada.
- Accuracy sozinha não é suficiente para avaliar detectores de eventos.

Precision: exatidão das detecções

Precision mede, entre tudo que o detector marcou como evento, qual fração era evento real.

$$\text{precision} = \frac{TP}{TP + FP}$$

Parâmetros

- **TP** = detecções corretas
- **FP** = alarmes indevidos

Quando importa

- Alarmes indevidos têm custo alto (ex: parada de produção desnecessária).
- Precision baixa indica excesso de falsos positivos.

Interpretação

Precision = 1 significa que toda detecção foi um evento real. Precision = 0 significa que nenhuma detecção foi correta.

Recall: completude dos eventos

Recall mede, entre todos os eventos reais, qual fração foi detectada pelo método.

$$\text{recall} = \frac{TP}{P} \quad \text{onde } P = TP + FN$$

Parâmetros

- **TP** = eventos detectados
- **FN** = eventos perdidos
- **P** = total de eventos reais

Quando importa

- Perder um evento é mais grave que emitir alarme extra (ex: falha crítica de equipamento).
- Recall baixo indica que muitos eventos passaram despercebidos.

Interpretação

Recall = 1 significa que todos os eventos foram detectados.

Recall = 0 significa que nenhum evento foi encontrado.

F1 e $F\beta$

F1 – Média harmônica

Combina precision e recall de forma equilibrada.

$$F1 = \frac{2 \cdot \text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}}$$

$F\beta$ – Versão ponderada

Permite pesar recall mais ($\beta > 1$) ou menos ($\beta < 1$) que precision.

$$F_{\beta} = \frac{(1 + \beta^2) \cdot \text{precision} \cdot \text{recall}}{\beta^2 \cdot \text{precision} + \text{recall}}$$

Interpretação de β

- **$\beta = 1$** → F1: peso igual para precision e recall.
- **$\beta = 2$** → recall tem o dobro do peso de precision.
- **$\beta = 0.5$** → precision tem o dobro do peso de recall.

Quando usar $F\beta$

Quando o custo de perder eventos (FN) e o custo de alarmes falsos (FP) são assimétricos.

Specificity e Fallout

Specificity (True Negative Rate)

Mede a capacidade de reconhecer não eventos corretamente.

$$\text{specificity} = \frac{TN}{TN + FP}$$

Alta specificity indica poucos falsos positivos.

Fallout (False Positive Rate)

Mede a proporção de não eventos incorretamente marcados como evento.

$$\text{fallout} = \frac{FP}{TN + FP} = 1 - \text{specificity}$$

Fallout alto indica excesso de alarmes em períodos normais.

📌 Specificity e fallout são complementares e fundamentais para construir a curva ROC.

Algoritmo: Avaliação hard ponto a ponto

Definição

Avalia cada instante da série de forma independente, comparando o rótulo real com a decisão do detector.

Fórmulas

$$TP = \sum \mathbb{I}[real(t) = 1 \wedge det(t) = 1]$$

$$FP = \sum \mathbb{I}[real(t) = 0 \wedge det(t) = 1]$$

$$FN = \sum \mathbb{I}[real(t) = 1 \wedge det(t) = 0]$$

$$TN = \sum \mathbb{I}[real(t) = 0 \wedge det(t) = 0]$$

Parâmetros

- $real(t)$ = rótulo real no instante $t \in \{0,1\}$
- $det(t)$ = decisão do detector no instante $t \in \{0,1\}$
- T = conjunto de todos os instantes

Pseudocódigo

ENTRADA: série de rótulos reais $R[1..n]$, série de detecções $D[1..n]$

PRÉ-CONDIÇÃO: $|R| = |D| = n$; $R[t], D[t] \in \{0, 1\}$ para todo t

PASSO 1 — Inicializar contadores

$TP \leftarrow 0$; $FP \leftarrow 0$; $FN \leftarrow 0$; $TN \leftarrow 0$

PASSO 2 — Percorrer cada instante t de 1 até n

SE $R[t] = 1$ E $D[t] = 1 \rightarrow TP \leftarrow TP + 1$

SE $R[t] = 0$ E $D[t] = 1 \rightarrow FP \leftarrow FP + 1$

SE $R[t] = 1$ E $D[t] = 0 \rightarrow FN \leftarrow FN + 1$

SE $R[t] = 0$ E $D[t] = 0 \rightarrow TN \leftarrow TN + 1$

PASSO 3 — Calcular métricas

$precision \leftarrow TP / (TP + FP)$ [se $TP+FP > 0$, senão 0]

$recall \leftarrow TP / (TP + FN)$ [se $TP+FN > 0$, senão 0]

$F1 \leftarrow 2 \cdot precision \cdot recall / (precision + recall)$

SAÍDA: $TP, FP, FN, TN, precision, recall, F1$

PÓS-CONDIÇÃO: $TP + FP + FN + TN = n$

Exemplo concreto (10 observações)

Série com 10 instantes, 5 eventos reais ($R = [0,1,1,1,1,1,0,0,0,0]$). Detector emite 2 detecções ($D = [0,0,1,0,0,0,0,1,0,0]$).

Resultado: $TP=1 \cdot TN=4 \cdot FP=1 \cdot FN=4$. $Accuracy=0,5 \cdot precision=0,5 \cdot recall=0,2 \cdot F1=0,28$.

Interpretação: recall baixo revela que 4 dos 5 eventos passaram despercebidos.

Score de evento vs rótulo binário

Rótulo binário


- O detector emite evento ou não evento para cada instante.
- Avaliação direta com matriz de confusão.
- Não permite variar o limiar de decisão.

Score contínuo

- O detector emite um grau de evidência de evento (score) para cada instante.
- O limiar de decisão pode variar, gerando diferentes pares (precision, recall) ou (fallout, recall).
- Permite construir curvas ROC e Precision-Recall.

📌 A escolha entre rótulo e score afeta diretamente quais métricas de avaliação são aplicáveis.


ROC, AUC e AUC-PR



Curva ROC

Plota recall (TPR) vs fallout (FPR) para todos os limiares.

AUC-ROC: área sob a curva ROC. Valor 1 = perfeito; 0.5 = aleatório.



Curva Precision-Recall

Plota precision vs recall para todos os limiares.

AUC-PR: mais informativa que ROC quando eventos são raros.

Não é afetada pelo grande volume de verdadeiros negativos.

Por que métricas clássicas falham em séries temporais

Ignoram a ordem temporal

Tratam cada instante como independente, sem considerar vizinhança.

Penalizam detecções vizinhas

Uma detecção próxima ao evento é tratada como erro total.

Não capturam dimensões essenciais

Atraso, antecipação, persistência e cobertura temporal são ignorados em aplicações reais.

📌 Isso motiva métricas com tolerância temporal e avaliação orientada a eventos.

O problema do instante exato

Fronteira temporal imprecisa

Eventos reais podem não ter fronteira temporal perfeitamente definida — o instante rotulado é uma aproximação.

Efeito vs causa

Um detector pode marcar o efeito do evento em vez do instante rotulado, o que pode ser operacionalmente correto.

Rigidez excessiva

Exigir igualdade exata entre detecção e rótulo descarta detectores úteis e ignora a incerteza inerente à rotulagem.

📌 Esses problemas motivam o uso de tolerância temporal na avaliação.

Near miss não é erro total

Uma detecção muito próxima pode ser operacionalmente útil — mas a avaliação hard não faz essa distinção.

Avaliação hard

Trata near miss exatamente como erro distante. Não diferencia uma detecção a 1 instante do evento de uma detecção a 100 instantes. Resultado: detectores operacionalmente úteis são penalizados injustamente.

O que precisamos

Uma métrica que recompense detecções próximas de forma controlada, penalizando progressivamente detecções mais distantes. Esse é o ponto de partida para métricas com tolerância temporal.

Efeito antecipado ou atrasado

Sinais antecipados

Alguns eventos apresentam sinais precursoros antes do instante oficial — detectar cedo pode ser valioso.

Efeitos propagados

Outros eventos só ficam observáveis depois que seus efeitos se propagam — a detecção necessariamente ocorre com atraso.

Distinção necessária

A avaliação precisa distinguir atraso útil (inerente ao fenômeno) de erro irrelevante (falha do método).

Imprecisão em labels humanos

1 Fontes de rótulo

Rótulos podem ser definidos por especialistas, sensores ou registros externos — cada fonte tem seu próprio grau de incerteza.

2 Imprecisão na marcação

A marcação pode ter atraso, arredondamento ou incerteza temporal — o ground truth não é pontual perfeito.

3 Tolerância como solução

Tolerância temporal na avaliação acomoda a imprecisão inerente ao processo de rotulagem.

Time Tolerance

Definição

Time tolerance k define uma janela temporal ao redor de cada evento.

Detecções dentro da janela são consideradas próximas ao evento.

Efeito na avaliação

A avaliação deixa de ser apenas hard (acerto ou erro).

A distância temporal passa a influenciar o escore da detecção.

Parâmetro k

- $k = 0$ → avaliação hard clássica (sem tolerância).
- $k > 0$ → janela de tolerância de k instantes ao redor do evento.
- Escolha de k depende do domínio e da aplicação.

Impacto

Com tolerância, detecções próximas recebem crédito parcial em vez de penalidade total.

Algoritmo: Aplicação de tolerância temporal

Definição

Expande cada evento real em uma janela de tolerância de k instantes. Detecções dentro da janela são consideradas acertos.

Fórmula da janela

$$W(ej, k) = [ej - k, ej + k]$$

Critério de acerto com tolerância

$$hit(tdi, ej, k) = \mathbb{I}[|tdi - ej| \leq k]$$

Parâmetros

- ej = instante do evento j
- k = janela de tolerância (em instantes)
- tdi = instante da detecção i

Pseudocódigo

ENTRADA: eventos $E[1..m]$, detecções $D[1..p]$, tolerância $k \geq 0$

PRÉ-CONDIÇÃO: E e D são listas de instantes; $k \in \mathbb{N}$

PASSO 1 — Para cada evento ej em E

 Criar janela $W(ej) \leftarrow \{t : |t - ej| \leq k\}$

PASSO 2 — Para cada detecção tdi em D

 Verificar se $tdi \in W(ej)$ para algum ej em E

 SE sim $\rightarrow$ marcar tdi como candidata a TP para ej mais próximo

 SE não $\rightarrow$ marcar tdi como FP

PASSO 3 — Para cada evento ej em E

 SE alguma detecção candidata existe para ej

$\rightarrow ej$ é coberto (contribui para TP)

 SENÃO

$\rightarrow ej$ não detectado (contribui para FN)

PASSO 4 — Calcular métricas com os contadores resultantes

SAÍDA: lista de associações ($tdi \rightarrow ej$), TP, FP, FN

PÓS-CONDIÇÃO: cada tdi associada a no máximo um ej

Detecção próxima ao evento



Recompensa controlada

A proximidade temporal deve ser recompensada de forma proporcional — quanto mais próxima, maior o crédito.



Penalidade progressiva


Detecções muito distantes do evento não devem receber crédito — a penalidade cresce com a distância.



Janela de tolerância

Fora da janela de tolerância k , a detecção é tratada como erro total, sem crédito parcial.

Hard evaluation vs Soft evaluation



A avaliação hard exige coincidência exata; a avaliação soft considera grau de associação temporal.

Hard evaluation

- Cada instante é acerto ou erro — sem gradação.
- Detecção fora do instante exato = FP + FN simultâneos.
- Simples de calcular, mas rígida demais para eventos temporais.

Soft evaluation

- A proximidade temporal influencia o escore da detecção.
- Detecções próximas recebem crédito parcial proporcional à distância.
- Mais alinhada à utilidade operacional real do detector.

Exemplo: Métodos A e B

Dois métodos detectam próximo de E1; apenas B detecta próximo de E2. Na avaliação hard: A e B têm o mesmo recall se ambos acertam E1 exatamente — mas B é claramente superior por cobrir E2. Na avaliação soft: B recebe maior TPs por cobrir dois eventos, refletindo sua superioridade real.

SoftED: intuição



Flexibilização das métricas clássicas

SoftED adapta precision, recall e F1 para considerar tolerância temporal, mantendo o mesmo vocabulário interpretável.



Crédito proporcional à proximidade

Cada detecção recebe um peso entre 0 e 1 baseado na distância ao evento mais próximo dentro da janela de tolerância.



Compatibilidade com métricas clássicas

Quando $k = 0$, SoftED se reduz à avaliação hard clássica — é uma generalização, não uma substituição.

Função de pertinência temporal

Definição

A função $\mu_{ej}(t)$ mede a proximidade temporal entre uma detecção no instante t e o evento e_j .

$$\mu_{e_j}(t_{d_i}) \in [0, 1], \quad \mu_{e_j}(e_j) = 1$$

Comportamento

- Valor máximo (1) no instante exato do evento.
- Decresce monotonicamente com a distância temporal.
- Cai para zero fora da janela de tolerância k .





Formas possíveis da função

- **Linear:** decaimento proporcional à distância.
- **Gaussiana:** decaimento suave centrado no evento.
- **Retangular:** crédito total dentro da janela, zero fora (equivalente a hard com tolerância).

Parâmetros

e_j = instante do evento; k = janela de tolerância; t_{d_i} = instante da detecção i .

SoftED mapping



SoftED mapeia detecções a eventos usando pertinência temporal e restrições de associação.

Algoritmo: SoftED mapping

Definição

Associa cada detecção ao evento mais próximo dentro da janela de tolerância, calculando a pertinência temporal. Aplica as restrições de unicidade.

Função de pertinência

$$\mu_{e_j}(t_{d_i}) = \max(0, 1 - |t_{d_i} - e_j|/k)$$

Restrições

- Cada detecção → no máximo 1 evento.
- Cada evento → no máximo 1 detecção representativa (a de maior μ).

Parâmetros

- k = janela de tolerância
- $\mu \in [0,1]$ = pertinência temporal

Pseudocódigo

ENTRADA: eventos $E[1..m]$, detecções $D[1..p]$, tolerância k

PRÉ-CONDIÇÃO: $k > 0$; E e D são listas de instantes

PASSO 1 — Calcular pertinências

Para cada par (td_i, ej) :

SE $|td_i - ej| \leq k \rightarrow \mu[i][j] \leftarrow 1 - |td_i - ej| / k$

SENÃO $\rightarrow \mu[i][j] \leftarrow 0$

PASSO 2 — Associar cada detecção ao evento mais próximo

Para cada td_i em D :

$j^* \leftarrow \text{argmax}_j \mu[i][j]$

SE $\mu[i][j^*] > 0 \rightarrow$ associar td_i a ej^*

SENÃO $\rightarrow$ td_i é FP (sem evento próximo)

PASSO 3 — Resolver conflitos (múltiplas detecções por evento)

Para cada evento ej com múltiplas detecções associadas:

Manter apenas a detecção com maior $\mu[i][j]$ (representativa)

Demais detecções $\rightarrow$ reclassificar como FP

PASSO 4 — Calcular TPs, FNs, FPs soft

$TPs \leftarrow \sum \mu[i^*][j]$ para cada par representativo (i^*, j)

$FNs \leftarrow |E| - TPs$

$FPs \leftarrow$ número de detecções não representativas

SAÍDA: mapeamento detecção $\rightarrow$ evento, TPs, FNs, FPs soft

PÓS-CONDIÇÃO: $TPs + FNs = |E|$; cada evento tem ≤ 1 detecção representativa

Restrições do SoftED



Uma detecção, um evento

Uma detecção não deve ser recompensada por vários eventos ao mesmo tempo — cada detecção é associada ao evento mais próximo dentro da janela.



Um evento, uma detecção representativa

Várias detecções não devem acumular crédito pelo mesmo evento — apenas a detecção com maior pertinência representa o evento.



Garantia de consistência

Essas restrições garantem que TPs, FPs e FNs soft somem corretamente e que as métricas permaneçam interpretáveis.

TP, FP, TN e FN em versão soft

TPs soft

Soma das pertinências temporais das detecções representativas de cada evento. $TPs \in [0, |E|]$ onde $|E|$ é o número de eventos.

FNs soft

Mede eventos não cobertos: $FNs = |E| - TPs$. Eventos sem detecção representativa contribuem com 1 para FNs.

FPs soft

Detecções sem associação a nenhum evento (fora de toda janela de tolerância). $FPs = |D| - \text{número de detecções representativas}$.

TNs soft

Instantes sem evento e sem detecção. Calculado como total de instantes - $(TPs + FPs + FNs)$.



As versões soft preservam a relação: $TPs + FNs = |E|$ (total de eventos reais).

Soft precision, recall e F1

Fórmulas soft

Soft Precision

$$\text{soft_precision} = \frac{TP_s}{TP_s + FP_s}$$

Soft Recall

$$\text{soft_recall} = \frac{TP_s}{TP_s + FN_s} = \frac{TP_s}{|E|}$$

Soft F1

$$\text{soft_F1} = \frac{2 \cdot \text{soft_precision} \cdot \text{soft_recall}}{\text{soft_precision} + \text{soft_recall}}$$

Propriedades

- As fórmulas são idênticas às clássicas — apenas TP, FP, FN são substituídos pelas versões soft.
- A escala permanece em $[0, 1]$ e interpretável.
- Quando $k = 0$, $\text{soft_precision} = \text{precision}$ e $\text{soft_recall} = \text{recall}$ (redução ao caso hard).

Vantagem

A proximidade temporal passa a influenciar o resultado sem alterar o vocabulário de avaliação.

Algoritmo: Cálculo de métricas soft

Definição

Calcula soft precision, soft recall e soft F1 a partir dos valores TPs, FPs e FNs obtidos pelo SoftED mapping.

Fórmulas

$$soft_{precision} = TPs / (TPs + FPs)$$

$$soft_{recall} = TPs / |E|$$

$$soft_{F1} = 2 \cdot sp \cdot sr / (sp + sr)$$

Propriedades

- $TPs \in [0, |E|]$ — valor fracionário.
- Quando $k = 0 \rightarrow$ reduz ao caso hard.
- sp = soft precision; sr = soft recall.

Pseudocódigo

ENTRADA: TPs (soft), FPs (soft), $|E|$ = número de eventos reais

PRÉ-CONDIÇÃO: $TPs \geq 0$; $FPs \geq 0$; $|E| > 0$ (obtidos pelo algoritmo SoftED mapping)

PASSO 1 — Calcular soft precision

SE $TPs + FPs > 0$:

$soft_precision \leftarrow TPs / (TPs + FPs)$

SENÃO:

$soft_precision \leftarrow 0$ [nenhuma detecção emitida]

PASSO 2 — Calcular soft recall

SE $|E| > 0$:

$soft_recall \leftarrow TPs / |E|$

SENÃO:

$soft_recall \leftarrow 1$ [sem eventos, recall trivialmente 1]

PASSO 3 — Calcular soft F1

SE $soft_precision + soft_recall > 0$:

$soft_F1 \leftarrow 2 \cdot soft_precision \cdot soft_recall$
 $/ (soft_precision + soft_recall)$

SENÃO:

$soft_F1 \leftarrow 0$

PASSO 4 — (Opcional) Calcular soft $F\beta$

$soft_F\beta \leftarrow (1 + \beta^2) \cdot soft_precision \cdot soft_recall$
 $/ (\beta^2 \cdot soft_precision + soft_recall)$

SAÍDA: $soft_precision$, $soft_recall$, $soft_F1$, $soft_F\beta$

PÓS-CONDIÇÃO: todos os valores $\in [0, 1]$

SoftED vs métricas hard

Hard evaluation

- Exige coincidência exata entre detecção e evento.
- Near miss = FP + FN simultâneos.
- Resultado: penaliza detectores úteis e subestima desempenho real.

SoftED

- Recompensa detecção próxima com crédito proporcional à pertinência temporal.
- Near miss = crédito parcial, não penalidade total.
- Resultado: avaliação mais alinhada à utilidade operacional do detector.

☐ A diferença entre hard e soft é mais pronunciada quando eventos são raros e detecções são próximas mas não exatas.

Por que SoftED preserva interpretabilidade

Mesmo vocabulário

O resultado continua em precision, recall e F1 — não exige aprender novas métricas ou escalas.

Generalização consistente

A métrica é uma extensão das clássicas: $k = 0$ reproduz exatamente a avaliação hard, sem quebra de compatibilidade.

Comparação direta

É possível comparar avaliação hard e soft no mesmo experimento, quantificando o impacto da tolerância temporal.

Relação com Harbinger

Disponibilidade

SoftED está implementado no pacote Harbinger, disponível para uso direto em experimentos.

Comparação integrada

Permite comparar avaliação hard e soft no mesmo fluxo experimental, sem necessidade de implementação manual.

Ponte teoria-prática

É a conexão direta entre os conceitos de tolerância temporal apresentados neste tutorial e a experimentação prática.

Eventos pontuais vs intervalares

Eventos pontuais

Ocorrem em um único instante temporal.

Avaliação: verificar se o instante foi detectado (com ou sem tolerância).

Exemplo: pico de tensão, falha instantânea de sensor.

Eventos intervalares

Têm início, fim e duração — formam um segmento temporal.

Avaliação: considerar cobertura, atraso de detecção e sobreposição entre segmento real e detectado.

Exemplo: período de degradação de equipamento, episódio de anomalia prolongada.

- ❏ Métricas para eventos intervalares precisam lidar com cobertura parcial, início tardio e extensão exagerada da detecção.

Ponto a ponto pode distorcer

Dominância por duração

Um evento longo tem muitos pontos e pode dominar a métrica, inflando artificialmente o desempenho.

Cobertura parcial

Uma pequena detecção dentro de um intervalo pode ser suficiente em algumas aplicações, mas insuficiente em outras que exigem cobertura completa.

Necessidade de métricas orientadas a segmento

Avaliar intervalos ponto a ponto ignora a semântica do evento como unidade — é preciso métricas que tratem o segmento como um todo.

Point-Adjusted F-score (PA)

Definição

Se qualquer ponto dentro do segmento real é detectado, todo o segmento é considerado detectado (TP).

Fórmula de ajuste

Para cada segmento real S_j : se $\exists t_{di} \in S_j$ tal que $\text{detector}(t_{di}) = 1$, então todos os pontos de S_j são marcados como TP.

Parâmetros

S_j = segmento real j ; t_{di} = instante de detecção i .

Vantagens

- Generoso para detecções parciais — basta uma detecção no segmento.
- Simples de calcular e interpretar.

Limitações

- Pode superestimar desempenho quando a cobertura importa.
- Não penaliza detecções que cobrem apenas uma fração mínima do evento.
- Não considera o atraso da detecção dentro do segmento.

Delay-thresholded Point-Adjusted F-score (PA-k)

Definição

Extensão do PA que adiciona uma janela máxima de atraso k .

O evento só conta como detectado se houver detecção nos primeiros k passos do segmento.

Fórmula

Para cada segmento S_j com início em t_s : o evento é TP apenas se $\exists t_{di} \in [t_s, t_s+k]$ tal que $\text{detector}(t_{di}) = 1$.

Parâmetros

k = janela máxima de atraso; t_s = início do segmento real.

Quando usar

- Cenários em que detectar tarde não resolve o problema (ex: alertas de segurança).
- Quando há custo operacional associado ao atraso da detecção.

Limitações

- Ainda não penaliza detecções que cobrem apenas o início do segmento.
- A escolha de k é sensível ao domínio.

Segment-wise F-score

Definição

Cada segmento real é tratado como uma unidade indivisível.

Basta uma detecção dentro do segmento para gerar um verdadeiro positivo.

Diferença do PA

No PA, todos os pontos do segmento são marcados como TP. No segment-wise, o segmento inteiro conta como 1 TP — não há inflação por duração.

Vantagens

- Não penaliza fortemente a extensão exagerada de um intervalo detectado.
- Trata eventos de durações diferentes de forma equânime.

Limitações

- Não avalia cobertura parcial — uma detecção mínima equivale a cobertura total.
- Não considera atraso dentro do segmento.

Range-based F-score

Definição

Avalia cobertura parcial de eventos reais e detecções usando sobreposição de intervalos.

Componentes

$$\text{recall_local}(S_j, D_j) = \frac{|S_j \cap D_j|}{|S_j|}$$

$$\text{precision_local}(S_j, D_j) = \frac{|S_j \cap D_j|}{|D_j|}$$

Parâmetros

S_j = segmento real j ; D_j = segmento detectado associado; $|\cdot|$ = duração do intervalo.

Vantagens

- Captura cobertura parcial — uma detecção que cobre 70% do evento recebe crédito proporcional.
- Penaliza detecções excessivamente longas via precision local.
- Mais informativa que PA e segment-wise para eventos intervalares.

Limitações

- Mais complexa de calcular e interpretar.
- Requer associação entre segmentos reais e detectados.

Algoritmo: Avaliação de eventos intervalares por range-based

Definição

Avalia cobertura parcial entre segmentos reais e detectados usando sobreposição de intervalos. Calcula recall e precision locais por par de segmentos.

Fórmulas

$$\text{recall_local}(S_j, D_j) = \frac{|S_j \cap D_j|}{|S_j|}$$

$$\text{precision_local}(S_j, D_j) = \frac{|S_j \cap D_j|}{|D_j|}$$

$F1_range$ = média harmônica de recall_local e precision_local

Parâmetros

- S_j = segmento real $j = [s_start, s_end]$
- D_j = segmento detectado associado a S_j
- $|\cdot|$ = duração do intervalo (número de instantes)

Pseudocódigo

ENTRADA: segmentos reais $S[1..m]$, segmentos detectados $D[1..p]$

PRÉ-CONDIÇÃO: cada segmento é um intervalo [início, fim]; $\text{início} \leq \text{fim}$

PASSO 1 — Associar cada segmento real ao segmento detectado com maior sobreposição

Para cada S_j em S :

Para cada D_i em D :

$\text{overlap}[j][i] \leftarrow |S_j \cap D_i| \quad [= \max(0, \min(S_j.\text{fim}, D_i.\text{fim}) - \max(S_j.\text{ini}, D_i.\text{ini}) + 1)]$

$i^* \leftarrow \text{argmax}_i \text{overlap}[j][i]$

SE $\text{overlap}[j][i^*] > 0 \rightarrow$ associar S_j a D_{i^*}

SENÃO $\rightarrow S_j$ não detectado ($\text{recall_local} = 0$)

PASSO 2 — Calcular métricas locais para cada par (S_j, D_{i^*})

$\text{recall_local}[j] \leftarrow |S_j \cap D_{i^*}| / |S_j|$

$\text{precision_local}[j] \leftarrow |S_j \cap D_{i^*}| / |D_{i^*}|$

PASSO 3 — Agregar métricas globais

$\text{recall_global} \leftarrow \text{média}(\text{recall_local}[j])$ para todo j

$\text{precision_global} \leftarrow \text{média}(\text{precision_local}[j])$ para todo j

PASSO 4 — Calcular F1 range-based

$F1_range \leftarrow 2 \cdot \text{precision_global} \cdot \text{recall_global} / (\text{precision_global} + \text{recall_global})$

SAÍDA: recall_global , precision_global , $F1_range$

PÓS-CONDIÇÃO: todos os valores $\in [0, 1]$

Avaliação online é diferente

Visão parcial da série

O detector não vê a série completa — processa batches sequenciais e toma decisões com informação limitada.

Detecção dinâmica

A decisão sobre um instante pode mudar conforme novos batches chegam — o detector pode rever sua avaliação.

Tempo como dimensão de desempenho

O momento da detecção é parte essencial do desempenho — detectar cedo tem valor diferente de detectar tarde.

❏ Métricas offline não capturam essas dimensões — avaliação online exige métricas específicas como detection probability e detection lag.

Tipos de detecção online

Antecipada

Detecção ocorre antes do evento — pode indicar sinal precursor. Útil em aplicações preventivas, mas pode ser FP se o evento não ocorrer.

Tardia

Detecção ocorre depois do evento — em online detection, pode ser inútil operacionalmente se a janela de ação já passou.

Inconsistente

O método muda sua decisão conforme a janela evolui — detecta em um batch e revoga em outro. Indica instabilidade do detector.

Exemplo: Métodos A e B em avaliação online

Conforme novas observações chegam em batches, o Método A detecta o evento com atraso de 3 batches (**tardia**), enquanto o Método B detecta na primeira oportunidade (lag=0) mas revoga a decisão no batch seguinte (**inconsistente**). A imagem do experimento mostra como detection probability e lag divergem entre os dois métodos.

Detection Probability

Definição

Mede a probabilidade de uma observação ser detectada ao longo das oportunidades disponíveis — considera todos os batches em que a observação esteve disponível.

Fórmula

$$P_{det}(o_i) = \frac{\text{número de batches em que } o_i \text{ foi detectada}}{\text{número de batches em que } o_i \text{ estava disponível}}$$

Interpretação

P_det = 1 significa que a observação foi detectada em todos os batches disponíveis.

P_det = 0 significa que nunca foi detectada.

📌 Detection probability captura a consistência da detecção ao longo do tempo, não apenas se houve detecção.

Detection Lag

Definição

Mede o atraso entre a primeira disponibilidade da observação e sua primeira detecção.

Fórmula

$\text{lag}(o_i)$ = primeiro batch em que o_i foi detectada — primeiro batch em que o_i estava disponível

Unidades

Pode ser expresso em número de batches ou em número de observações.

Interpretação

- **lag = 0** → detecção imediata na primeira oportunidade.
- **lag > 0** → atraso na detecção — quanto maior, mais tarde o método reagiu.
- **lag = ∞** (ou indefinido) → observação nunca detectada.

Importância

Quanto menor o lag, mais cedo o método reagiu ao evento — essencial em aplicações de tempo real.

Algoritmo: Cálculo de detection lag em avaliação online

Definição

Mede o atraso entre a primeira disponibilidade de uma observação e sua primeira detecção ao longo dos batches sequenciais.

Fórmula

$$\text{lag}(oi) = b_{det}(oi) - b_{avail}(oi)$$

Parâmetros

- oi = observação de interesse (evento)
- $b_{avail}(oi)$ = primeiro batch em que oi estava disponível
- $b_{det}(oi)$ = primeiro batch em que oi foi detectada
- $\text{lag} = \infty$ se oi nunca foi detectada

Unidades

Expresso em número de batches ou número de observações.

Pseudocódigo

ENTRADA: observação de interesse oi , sequência de batches $B[1..T]$,
decisões do detector $\text{det}[b][t]$ para cada batch b e instante t
PRÉ-CONDIÇÃO: oi é um evento real; B é ordenado cronologicamente

PASSO 1 — Identificar primeiro batch de disponibilidade

$b_{avail} \leftarrow$ primeiro b tal que $oi \in B[b]$

SE b_{avail} não existe $\rightarrow$ ERRO: oi nunca disponível

PASSO 2 — Identificar primeiro batch de detecção

$b_{det} \leftarrow \infty$ [inicializar como não detectado]

Para b de b_{avail} até T :

SE $\text{det}[b][oi] = 1$:

$b_{det} \leftarrow b$

PARAR

PASSO 3 — Calcular lag

SE $b_{det} < \infty$:

$\text{lag}(oi) \leftarrow b_{det} - b_{avail}$

SENÃO:

$\text{lag}(oi) \leftarrow \infty$ [observação nunca detectada]

PASSO 4 — (Opcional) Agregar lag médio sobre todos os eventos

$\text{lag_medio} \leftarrow$ média($\text{lag}(oi)$) para oi com $\text{lag} < \infty$

SAÍDA: $\text{lag}(oi)$ para cada observação, lag_medio

PÓS-CONDIÇÃO: $\text{lag}(oi) \geq 0$ para toda oi detectada

Batch size, memória e janela de avaliação



Batch size

Altera a granularidade da avaliação — batches menores permitem detecção mais rápida, mas com menos contexto disponível.



Memória parcial

Limita quanto da série histórica o detector pode usar — afeta a capacidade de detectar padrões de longa duração.



Janela de avaliação

Define o horizonte temporal considerado para calcular detection probability e lag — janelas maiores capturam mais oportunidades de detecção.

📄 A combinação de batch size, memória e janela de avaliação define o protocolo experimental online e afeta diretamente as métricas.

Qualidade dos benchmarks

Influência na conclusão

A escolha do benchmark influencia fortemente a conclusão sobre um método — benchmarks ruins podem inverter o ranking de desempenho.

Benchmarks ruins favorecem métodos simples

Anomalias triviais, densidade irreal de eventos ou ground truth mal rotulado podem fazer métodos simples parecerem superiores.

Critérios de qualidade

Um bom benchmark deve ter: eventos não triviais, densidade realista, labels precisos e diversidade de padrões temporais.

Problemas comuns em benchmarks

Anomalias triviais

Favorecem métodos simples demais — qualquer detector básico acerta, sem discriminar qualidade real.

Ground truth mal rotulado

Compromete qualquer métrica — erros nos labels contaminam toda a avaliação.

Densidade irreal de eventos

Altera precision e recall de forma artificial — muitos eventos inflam recall; poucos eventos inflam precision.

Concentração temporal

Muitas anomalias no fim da série podem enviesar a avaliação — o detector pode aprender o padrão de distribuição dos labels.

Benchmarks recentes

UCR Anomaly Archive

Reúne séries temporais curadas para avaliação de detecção de anomalias. Foco em qualidade dos labels e diversidade de padrões.


TimeEval

Toolkit para comparação sistemática de algoritmos de detecção de anomalias em séries temporais. Suporta múltiplas métricas e protocolos de avaliação.

Avanços recentes


Benchmarks modernos discutem qualidade de labels, eventos intervalares, métricas com tolerância temporal e protocolos de avaliação online.

Referências Bibliográficas




Event Detection in Time Series

Ogasawara, E.; Salles, R.; Porto, F.;
Pacitti, E. Springer Nature Switzerland,
2025.



Time Series Analysis: With Applications in R

Cryer, J. D.; Chan, K.-S. Springer, 2008.



Data Mining: Concepts and Techniques

Han, J.; Pei, J.; Tong, H. Morgan
Kaufmann, 4^a ed., 2022.