

Tendências em Detecção de Eventos em Séries Temporais

Um panorama da área, uma proposta de arcabouço unificado baseado em tipicidade temporal, e uma agenda de pesquisa para os próximos anos.

Eduardo Ogasawara

eduardo.ogasawara@cefet-rj.br

<https://eic.cefet-rj.br/~eogasawara>

Introdução

A detecção de eventos em séries temporais abrange três subáreas principais — **anomaly detection**, **change point detection** e **motif discovery** — que se desenvolveram de forma independente, com comunidades, terminologias e benchmarks distintos. Este trabalho propõe que essas subáreas compartilham fundamentos comuns e que uma perspectiva unificada é viável.

Múltiplas Definições

Não há consenso sobre o conceito de evento: cada subárea opera com definições próprias, frequentemente incompatíveis entre si.

Diversidade de Contextos

Dados e aplicações variam amplamente — de sensores industriais a registros clínicos —, tornando difícil generalizar abordagens.

Ausência de Métricas

Faltam critérios universais de avaliação: benchmarks são específicos por subárea e raramente comparáveis entre si.

Fragmentação do Campo

Anomaly detection, change point detection e motif discovery cresceram em silos: comunidades distintas, vocabulários divergentes e baixa transferência de conhecimento entre as áreas.

Fragmentação da Área

O campo de detecção de eventos em séries temporais se desenvolveu de forma fragmentada. Cada subárea cresceu com sua própria comunidade, terminologia e benchmarks — sem um vocabulário unificador.

Anomalias

Comunidade consolidada desde a estatística clássica. Foco em desvios pontuais. Métricas próprias (precision, recall sobre pontos). Literatura dominante em volume.

Change Points

Comunidade com raízes em controle de processos e econometria. Foco em rupturas estruturais. Métricas próprias (detecção de segmentos). Crescimento forte desde os anos 1980.

Motifs

Comunidade mais recente, ligada à mineração de dados temporais. Foco em padrões recorrentes. Métricas próprias (similaridade de subsequências). Expansão acelerada com machine learning.

Interseções Entre Subáreas

As subáreas se sobrepõem por conceitos e métodos compartilhados. As fronteiras não são rígidas — uma mesma técnica ou aplicação pode ser classificada em mais de uma subárea.

Par de Subáreas	Tipo de Relação	Mecanismo Compartilhado	Evidência Empírica (Scopus)
Anomalia × Change Point	Forte sobreposição	Ruptura abrupta manifesta-se como desvio extremo; desvio persistente sinaliza mudança de regime.	Maior sobreposição do campo; ~30–40% dos artigos de change point citam literatura de anomalias
Anomalia × Motifs	Relação estrutural	Motifs definem tipicidade estrutural; anomalias são os desvios em relação a esses padrões recorrentes.	Sobreposição relevante; motifs surgem frequentemente em pipelines de detecção de anomalias
Change Point × Motifs	Relação indireta	Change points operam em nível macro (regime do sinal); motifs em nível micro (recorrências dentro de um regime).	Menor sobreposição; objetivos distintos limitam co-citação direta
Event Detection × (todas)	Eixo integrador	Unifica as três subáreas sob vocabulário comum orientado a eventos.	Termo 'event detection' aparece como hiperônimo em buscas que recuperam as três subáreas simultaneamente

Arquitetura da Área: Event Detection como Eixo Integrador

O campo pode ser organizado em três núcleos fundamentais. Event detection atua como visão integradora, unificando anomalias, change points e motifs como componentes centrais, i.e., uma arquitetura pedagógica que ajuda a posicionar métodos, problemas e aplicações.

Event Detection

Visão integradora: detectar ocorrências relevantes em sinais temporais. Termo recupera publicações das três subáreas simultaneamente na Scopus — é o hiperônimo que unifica o campo.

Anomalias

Desvios pontuais em relação ao comportamento esperado. Subárea mais consolidada: maior volume absoluto de publicações, raízes na estatística clássica, crescimento exponencial a partir dos anos 2000. Métodos amplamente estabelecidos.

Change Points

Rupturas estruturais que alteram o regime do sinal. Crescimento forte a partir de 1980, impulsionado por aplicações em monitoramento e controle de processos. Métodos amadurecidos e amplamente usados.

Motifs

Padrões recorrentes que definem tipicidade temporal. Subárea mais recente: menor volume absoluto, mas crescimento acelerado com a expansão da mineração de dados temporais e machine learning.

As subáreas são especializadas mas não isoladas — event detection fornece o vocabulário e o propósito que as conecta.

Implicações para a Área

Campo Fragmentado mas Conectado

As subáreas têm comunidades, termos e benchmarks próprios, mas compartilham ferramentas e problemas fundamentais. A fragmentação é real — e reconhecê-la é o primeiro passo para superá-la.

Convergência Metodológica

Técnicas surgem em subáreas diferentes mas resolvem problemas similares. Padronizar avaliações e reconhecer essa convergência evita retrabalho e abre espaço para síntese entre anomalias, change points e motifs.

Event Detection como Eixo Integrador

Event detection atua como síntese prática — um vocabulário que integra o que antes era tratado separadamente. O campo está maduro para uma visão unificada que reconheça tanto as especificidades quanto as conexões entre suas subáreas.

Série Temporal como Processo Estruturado

Uma série temporal não é apenas uma lista de números. É uma sequência indexada no tempo onde cada observação é gerada por uma distribuição cujos parâmetros podem variar, induzindo a dinâmica do processo.

$$x_t \sim F_{\theta_t}$$

Onde x_t é a observação no instante t , F_{θ_t} é a distribuição das observações, e θ_t representa os parâmetros que podem mudar ao longo do tempo.

Tipicidade Temporal

A tipicidade é definida localmente no tempo: ela reflete o comportamento esperado de x_t sob a distribuição vigente no instante t , e pode variar à medida que os parâmetros do processo mudam.

Definição no Instante

A tipicidade em t é definida por $x_t \sim F_{\theta_t}$

Referência Dinâmica

Se θ_t muda, a referência do que é esperado muda junto

Base para Eventos

Eventos são definidos em relação a essa referência temporal

Evento em Séries Temporais

Um evento corresponde a uma alteração na referência de tipicidade em um dado instante. Sua definição é temporal e depende de como a tipicidade é modelada.

O conjunto genérico de instantes de evento pode ser escrito como:

$$\mathcal{E} = \{t : \text{a tipicidade em } t \text{ é alterada}\}$$

Esta definição geral permite que diferentes classes de eventos — anomalias, change points, motifs, discords, drift — sejam tratadas como casos particulares da mesma estrutura conceitual.

Generalidade

Qualquer situação em que a noção de tipicidade é alterada pode ser enquadrada como evento nesta teoria

Dimensões do Evento Temporal

Para comparar e classificar eventos, precisamos de um vocabulário descritivo. Três dimensões fundamentais caracterizam qualquer evento temporal:

Intensidade

Tamanho do desvio no instante. Pode ser medida pelo erro de previsão: $I_t = |x_t - \hat{x}_t|$

Persistência

Quanto tempo o efeito dura. Quantos instantes o comportamento anômalo se mantém

Estrutura

Quão organizado ou complexo é o padrão. Distingue padrões sistemáticos de ruído aleatório

Arquitetura Geral de Detecção

Todo detector transforma dados brutos em eventos por meio de quatro operadores encadeados.

$$X_t \xrightarrow{\mathcal{R}} Z_t \xrightarrow{\mathcal{M}} \theta_t \xrightarrow{\mathcal{S}} S_t \xrightarrow{\mathcal{D}} \mathcal{E}_t$$

- $\mathcal{R}$: representação dos dados
- $\mathcal{M}$: modelagem da tipicidade
- $\mathcal{S}$: cálculo do score de discrepância
- $\mathcal{D}$: decisão de evento

ENTRADA: x (série temporal de comprimento T), w (tamanho da janela)

PRÉ-CONDIÇÃO: série indexada no tempo, $w \geq 1$

PASSO 1 — Representação

PARA t de 1 até T :

$Z_t \leftarrow \mathcal{R}(x_{\{t-w:t\}})$ # transforma janela em representação

PASSO 2 — Modelagem

PARA t de 1 até T :

$\theta_t \leftarrow \mathcal{M}(Z_{\{1:t\}})$ # estima tipicidade até t

PASSO 3 — Score

PARA t de 1 até T :

$S_t \leftarrow \varphi(Z_{\{t-w:t\}}, \theta_t)$ # mede discrepância observado vs esperado

PASSO 4 — Decisão

PARA t de 1 até T :

$E_t \leftarrow 1$ se $S_t > \tau$, senão 0

SAÍDA: E (sequência de eventos identificados)

PÓS-CONDIÇÃO: $E_t = 1$ indica evento no instante t

Função Universal de Discrepância

Toda detecção se reduz a medir o quanto o observado se afasta do esperado. O score S_t quantifica essa distância; o limiar τ converte o score em decisão.

$$S_t = \phi(X_{t-w:t}, \theta_t)$$

$$\mathcal{E}_t = \mathbf{1}[S_t > \tau]$$

- S_t : score de discrepância
- $X_{t-w:t}$: janela observada de tamanho w
- θ_t : referência de tipicidade
- τ : limiar de decisão (fixo ou adaptativo)

Diferentes escolhas de ϕ e θ_t instanciam diferentes classes de detectores.

ENTRADA: x (série temporal), w (janela), τ (limiar),
 ϕ (função de discrepância), θ (modelo de tipicidade)

PRÉ-CONDIÇÃO: $\phi \geq 0$, $\tau > 0$, $w \geq 1$

PASSO 1 — Inicialização

Ajustar θ_0 com os primeiros w pontos de x

PASSO 2 — Loop temporal

PARA t de $w+1$ até T :

Atualizar referência de tipicidade

$\theta_t \leftarrow \text{atualizar}(\theta_{t-1}, x_t)$

Calcular score de discrepância

$S_t \leftarrow \phi(x_{t-w:t}, \theta_t)$

Declarar evento

SE $S_t > \tau$:

$E_t \leftarrow 1$

SENÃO:

$E_t \leftarrow 0$

SAÍDA: S (sequência de scores), E (sequência de eventos)

PÓS-CONDIÇÃO: $E_t = 1 \implies S_t > \tau$

Modelos como Construtores de Tipicidade

Um modelo define uma referência de comportamento esperado para a série — é essa referência que torna a discrepância mensurável. Modelos diferentes induzem referências distintas e, conseqüentemente, sensibilidades distintas a diferentes tipos de evento.

Médias Móveis

Referência local por suavização — o esperado é a média dos valores recentes

ARIMA e similares

Referência paramétrica — o esperado segue uma estrutura estocástica estimada

Redes Neurais

Referência por representação aprendida — o esperado emerge de padrões latentes nos dados

Equivalência entre Detectores

Dois detectores são **equivalentes** se induzem a mesma ordenação de scores sobre os dados — independentemente de seus nomes ou implementações.

$$\phi_1(X_t) \sim \phi_2(X_t) \iff \text{rank}(\phi_1) = \text{rank}(\phi_2)$$

Exemplo: um detector baseado em log-verossimilhança e outro em distância de Mahalanobis são equivalentes se seus scores marcam os mesmos instantes como evento.

Implicações do Arcabouço

O arcabouço geral para detecção de eventos revela algumas implicações práticas e teóricas relevantes:

Definição Dependente de Escolhas Metodológicas

A noção de evento varia conforme as decisões de modelagem adotadas pelo analista

Influência da Representação dos Dados

A forma como os dados são representados determina quais eventos se tornam detectáveis

Papel do Modelo de Referência

O modelo escolhido define o critério de tipicidade e, consequentemente, o limiar de detecção

Sensibilidade ao Contexto de Análise

Alterações no contexto de aplicação podem modificar o conjunto de instantes classificados como eventos

$$\mathcal{E}_t = f(X_t, \mathcal{R}, \mathcal{M})$$

Consequências para Seleção de Métodos

A escolha do método de detecção deve ser vista como uma otimização sob contexto, não como busca por um "melhor detector universal".

Objetivo

Detectar rápido, explicar, ou prever? Cada objetivo favorece diferentes métodos

Seleção como otimização:

$$\mathcal{D}^* = \arg \max_{\mathcal{D}} U(\mathcal{D} \mid \mathcal{C})$$

Onde $\mathcal{D}^*$ é o detector escolhido, $U(\cdot)$ é a utilidade, e $\mathcal{C}$ representa o contexto completo.

Escala Temporal

Janela de observação e frequência de amostragem importam

Restrições Computacionais

Tempo real versus processamento em lote afeta a escolha

Contexto do Fenômeno

Natureza do processo governa a utilidade do detector

Ambiguidade na Definição de Evento

A escolha de como representar eventos determina o tipo de método possível. Assim, comparar detectores sem alinhar a definição de evento é conceitualmente incorreto.

Se duas definições de evento são distintas, os detectores associados não são equivalentes:

$$\mathcal{E}_1 \neq \mathcal{E}_2$$

Definição dos símbolos:

- $\mathcal{E}_1, \mathcal{E}_2$ = diferentes definições de evento

Evento como Ponto

Momento específico no tempo

Evento como Intervalo

Período com duração definida

Evento como Padrão

Sequência recorrente

Complexidade da Avaliação

Avaliar detectores exige lidar com tempo, duração e incerteza. O problema da avaliação não é apenas técnico, mas conceitual: o que significa "acertar" um evento?

Métricas Insuficientes

Abordagens clássicas não capturam a complexidade temporal

Tolerância Temporal

Necessidade de considerar janelas de tempo

Eventos Intervalares

Duração complica a análise de acurácia

Falta de Generalização

Muitos detectores são calibrados para um tipo de dado ou aplicação. Isso revela que a maioria dos métodos embute hipóteses implícitas sobre o fenômeno analisado.

Eficácia Específica

Métodos funcionam bem em domínios particulares

Queda de Desempenho

Performance reduzida em outros contextos

Dependência do Domínio

Hipóteses implícitas limitam aplicabilidade

Escala e Multivariância

A detecção de eventos precisa lidar simultaneamente com volumes crescentes de dados ($T \rightarrow \infty$) e dimensionalidade crescente ($d \rightarrow \infty$), sendo que eventos raramente emergem de uma única variável — eles surgem de interações complexas entre variáveis e modalidades.

$$T \rightarrow \infty, \quad d \rightarrow \infty$$

Definição dos símbolos:

- T = comprimento da série temporal
- d = número de variáveis

Séries Longas

Volume temporal crescente impõe limites computacionais

Streaming Contínuo

Processamento em tempo real exige algoritmos escaláveis

Alta Dimensionalidade

Múltiplas variáveis simultâneas aumentam a complexidade

Interações Complexas

Eventos emergem de padrões não-lineares entre variáveis

Desafios do Paradigma Online

No online, a detecção ocorre sob informação parcial. O detector precisa equilibrar rapidez, adaptação e custo computacional, redefinindo os limites do problema.

Latência Inevitável

Decisões com informação incompleta

Adaptação ao Drift

Mudanças contínuas no sistema

Restrições Computacionais

Limites de memória e tempo

Multiescala Temporal

A mesma série pode revelar eventos diferentes dependendo da escala temporal. Isso mostra que a definição de evento é intrinsecamente multiescala.

$$\mathcal{E}(w_1) \neq \mathcal{E}(w_2)$$

Definição dos símbolos:


- w_1, w_2 = escalas temporais distintas
- $\mathcal{E}(w)$ = eventos na escala w

Escala Fina

Eventos de curta duração

Escala Ampla

Padrões de longa duração



Ausência de Teoria Unificada

O campo carece de uma estrutura teórica que conecte definições, métodos e métricas. A construção de uma teoria geral de eventos aparece como desafio central.

Falta de Frameworks Integradores

Ausência de estruturas que unifiquem diferentes abordagens

Métodos Ad Hoc

Desenvolvimento isolado sem base teórica comum

Necessidade de Teoria Geral

Urgência de um paradigma unificador para o campo

Taxonomia Consolidada de Eventos

Cada classe de evento funciona como uma lente distinta sobre a dinâmica temporal: juntas, iluminam o mesmo fenômeno a partir de ângulos complementares — desvio local, ruptura estrutural, recorrência e deriva contínua.

$$\mathcal{E} = \mathcal{A} \cup \mathcal{C} \cup \mathcal{M} \cup \mathcal{D}_{dyn}$$

Anomalias

Capturam desvios pontuais em relação ao comportamento esperado, sinalizando irregularidades locais na série temporal ($\mathcal{A}$).

Change Points

Identificam rupturas estruturais que demarcam a transição entre regimes distintos de geração de dados ($\mathcal{C}$).

Motifs

Revelam padrões recorrentes que se manifestam ao longo do tempo, codificando a regularidade latente do processo ($\mathcal{M}$).

Drift/Online

Rastreiam mudanças graduais e contínuas em ambientes de streaming, onde o conceito subjacente evolui sem interrupção abrupta ($\mathcal{D}_{dyn}$).

Reunidas, as quatro classes formam um vocabulário unificado para a interpretação temporal — permitindo descrever qualquer evento relevante em uma série como desvio, ruptura, padrão ou deriva.

Agenda de Pesquisa

O que aprendemos

- Conceito de evento permanece ambíguo entre subáreas
- Ausência de métricas universais dificulta comparação
- Modelos generalizam mal entre domínios
- Escala e dimensionalidade crescentes exigem novas abordagens
- Falta um arcabouço teórico comum

$$\text{Event Detection} = f(\text{dados}, \text{modelo}, \text{contexto})$$

Para onde ir

As direções abertas para pesquisa refletem a maturidade crescente do campo e a necessidade de integrar métodos, teoria e interpretação.

Consolidar e validar o arcabouço unificado proposto

Esta apresentação propõe um primeiro arcabouço teórico baseado em tipicidade temporal — um passo concreto em direção à unificação do campo. O desafio seguinte é validá-lo empiricamente em benchmarks diversificados, estendê-lo ao contexto multivariado e integrá-lo com métricas de avaliação independentes de domínio.

Escalar para dados multimodais e multivariados

Enfrentar o desafio de detectar eventos em fluxos de dados heterogêneos, de alta dimensão e em tempo real.

Desenvolver métricas de avaliação independentes de domínio




Criar protocolos de benchmark que permitam comparar métodos de forma justa, independentemente do contexto de aplicação.

Integrar explicabilidade e causalidade

Ir além da detecção para compreender por que um evento ocorre, articulando inferência causal e interpretabilidade dos modelos.

A detecção de eventos pode ser vista como uma linguagem científica para interpretar o tempo — ela conecta estatística, aprendizado de máquina e conhecimento de domínio em uma prática investigativa comum.

Referências Bibliográficas



Event Detection in Time Series

Ogasawara, E.; Salles, R.; Porto, F.; Pacitti, E.
Springer Nature Switzerland, 2025.

Time Series Analysis: With Applications in R

Cryer, J. D.; Chan, K.-S. Springer, 2008.

Data Mining: Concepts and Techniques

Han, J.; Pei, J.; Tong, H. Morgan Kaufmann, 4^a ed., 2022.