

Detecção de Eventos em Séries Temporais: Desafios e Futuro



Eduardo Ogasawara

eogasawara@cefet-rj.br | <https://eic.cefet-rj.br/~eogasawara>



Uma área ampla, ativa e em construção

Esta apresentação desloca a pergunta central: deixamos de perguntar apenas *como detectar* e passamos a investigar *o que ainda falta resolver*. O campo abrange métodos estatísticos, mineração de dados, aprendizado de máquina e sistemas de monitoramento em tempo real — crescendo em múltiplas direções simultaneamente. O que emerge dessa visão panorâmica não é fragmentação, mas organização em subáreas complementares, cada uma com suas próprias hipóteses, métricas e desafios em aberto.

Detecção de Anomalias

Procura desvios e comportamentos raros em relação ao padrão esperado da série temporal.

Detecção de Pontos de Mudança

Localiza transições entre regimes distintos, identificando onde o comportamento da série se altera estruturalmente.

Descoberta de Motifs

Descobre padrões recorrentes e, indiretamente, discords — subsequências que se afastam dos motifs mais frequentes.

Mapa sistemático da produção

Consultas realizadas no Scopus em 29 de novembro de 2023, restritas a **time series**, abrangem quatro subáreas: **event detection**, **anomaly**, **change point/concept drift** e **motif**. O volume e o perfil de cada área revelam prioridades distintas da comunidade científica.

Anomaly Detection

Apresenta o **maior volume de publicações** entre as subáreas, refletindo alta demanda por identificação de comportamentos anômalos em séries temporais em domínios como saúde, finanças e indústria.


Change Point & Concept Drift

Formam uma **linha consolidada** com forte base estatística, reunindo trabalhos sobre detecção de mudanças estruturais e adaptação a distribuições não estacionárias ao longo do tempo.

Motif Discovery

Menor em volume, mas **central para padrões recorrentes**: identifica subsequências que se repetem em séries temporais, com aplicações em reconhecimento de comportamentos e compressão de dados.

Evolução das publicações



- Anomalias dominam a produção científica
- Change points crescem fortemente após os anos 1980
- Event detection se consolida como termo mais geral a partir dos anos 2000
- Motifs aparecem de forma mais recente e com ritmo estável

Número de publicações em escala logarítmica nas principais áreas de detecção de eventos.

Interseções entre áreas

Séries temporais reais frequentemente contêm anomalias, mudanças de regime e padrões recorrentes de forma simultânea — o que torna as fronteiras entre as áreas porosas e complementares.

Event detection ↔ Anomaly

Principal conexão da área geral: detecção de eventos frequentemente se apoia em métodos de anomalia para identificar ocorrências relevantes.

Anomaly ↔ Change point

Interseção expressiva, especialmente em séries não estacionárias, onde mudanças de regime podem ser indistinguíveis de anomalias estruturais.

Anomaly ↔ Motif

Encontro quando discords entram na discussão: subsequências incomuns (discords) são, ao mesmo tempo, anomalias e anti-motifs.

Uma visão unificada pode produzir detectores mais robustos e interpretações melhores.

Vocabulário das subáreas

Além da contagem de publicações, o vocabulário revela a identidade de cada subárea — métodos, aplicações e preocupações dominantes.

Event Detection

Sistemas, mineração de dados, aprendizado; foco operacional entre métodos e uso prático.

Change Point

Vocabulário estatístico forte; concept drift conecta mudança temporal com aprendizado adaptativo.

Anomaly Detection

Fortemente orientada por aplicações; sensores, clima, redes; anomalia depende do contexto.

Motif Discovery

Padrões, subsequências, discovery; lógica de descoberta de formas recorrentes, não classificação de pontos.

Desafios: escala e multivariabilidade

Séries Multivariadas

- Fontes modernas coletam muitas variáveis ao longo do tempo
- Eventos podem surgir da relação entre dimensões, não apenas de uma série isolada
- Dimensionalidade, dependência e interpretabilidade tornam o problema mais difícil

Escala e Big Data

- Sensores, redes sociais e sistemas industriais geram séries longas e rápidas
- Métodos tradicionais podem falhar em custo, memória ou latência
- Spark, Kafka e Flink aparecem como infraestrutura para workflows escaláveis

Desafios: detecção online e métricas

Detecção Online

- Em streaming, não há série completa para analisar.
- O detector precisa decidir no fluxo, com memória limitada e dados em mudança.
- Anomalias próximas a drift ou change points podem ser especialmente ambíguas.

Métricas para Eventos

- Ainda faltam métricas unificadas para eventos pontuais, intervalares e online.
- Tolerância temporal precisa ser tratada de forma consistente.
- Métricas devem evoluir quando novos dados chegam em streaming.

Desafios: explicabilidade e visão unificada

Explicabilidade

- Detectores complexos podem funcionar como caixas-pretas.
- Em saúde, finanças e segurança, explicar o evento é tão importante quanto detectá-lo.
- SHAP, LIME e visualização interativa podem inspirar soluções mais confiáveis.

Visão Unificada

- Anomalias, change points e motifs ainda são estudados como problemas separados.
- Séries reais frequentemente combinam os três tipos de evento.
- Um detector mais amplo deve integrar evidências de desvio, mudança e recorrência.

Tendências e oportunidades de pesquisa

Transfer Learning

- Modelos treinados em um domínio nem sempre generalizam para outro.
- Transfer learning pode reduzir dependência de rótulos no novo domínio.
- Adaptação em séries multivariadas ainda é pouco explorada.

Robustez Adversarial

- Pequenos ajustes nos dados podem enganar detectores.
- Modelos de ML precisam ser avaliados contra manipulação intencional.
- Robustez é requisito em decisões críticas.

Edge e Eficiência Energética

- IoT e wearables têm restrições fortes de energia e memória.
- Detectores precisam ser leves sem perder confiabilidade.
- Eficiência energética será requisito para implantação em larga escala.

LLMs e Séries como Tokens

- Séries discretizadas tratadas como sequências de tokens.
- Pré-treinamento em grandes coleções e ajuste fino por tarefa.
- Promessa para cenários com poucos rótulos.

Associação entre Eventos

- Eventos podem formar sequências e relações causais.
- Pequenas anomalias podem preceder change points relevantes.
- Aproxima detecção de mineração de sequências e raciocínio causal.

Métodos Híbridos

- Combinam anomalia, mudança e recorrência no mesmo fluxo.
- Vantagem: capturar fenômenos diferentes simultaneamente.
- Desafio: integrar saídas, métricas e explicações sem opacidade.

Lacunas e agenda prática


O que ainda falta

- Benchmarks representativos.
- Métricas temporais adequadas (ponto, intervalo, tolerância, atraso).
- Explicações compreensíveis para especialistas de domínio.
- Custo computacional compatível com operação contínua.

Agenda prática


1. Escolher claramente o tipo de evento (anomalia, mudança, motif).
2. Definir o cenário: offline, online ou preditivo.
3. Usar métrica coerente com o tipo de evento e tolerância temporal.
4. Combinar métodos quando a série tiver múltiplos tipos de evento.

Referências Bibliográficas




Event Detection in Time Series

Ogasawara, E.; Salles, R.; Porto, F.;
Pacitti, E. Springer Nature Switzerland,
2025.



Time Series Analysis: With Applications in R

Cryer, J. D.; Chan, K.-S. Springer, 2008.



Data Mining: Concepts and Techniques

Han, J.; Pei, J.; Tong, H. Morgan
Kaufmann, 4^a ed., 2022.