

Avaliação de Detecção de Eventos



Eduardo Ogasawara

eogasawara@cefet-rj.br | <https://eic.cefet-rj.br/~eogasawara>



CAPÍTULO 7

Objetivos do capítulo

- Revisar métricas clássicas usadas em detecção de eventos.
- Entender por que tempo, intervalo e atraso mudam a avaliação.
- Introduzir tolerância temporal, SoftED, avaliação intervalar e avaliação online.

CAPÍTULO 7

Avaliar eventos não é só classificar pontos

Em séries temporais, a posição da detecção importa.

Uma detecção próxima ao evento pode ser útil mesmo sem coincidir exatamente.

Eventos podem ser pontuais, intervalares, antecipáveis ou detectáveis apenas com atraso.

CAPÍTULO 7

O problema do acerto exato

Métricas clássicas tratam cada instante como independente.

Um erro de uma unidade no tempo pode virar falso positivo e falso negativo ao mesmo tempo.

Isso pode descartar detectores úteis em aplicações reais.

Eventos como classe positiva

- Em avaliação clássica, cada instante pode ser tratado como event=yes ou event=no.
- Eventos são a classe positiva.
- Observações típicas são a classe negativa.

Matriz de confusão

- **TP:** evento real corretamente detectado.
- **TN:** não evento corretamente ignorado.
- **FP:** alarme onde não havia evento.
- **FN:** evento real não detectado.

Accuracy e error rate

Accuracy mede a proporção total de acertos.

Error rate é o complemento da accuracy.

Em eventos raros, accuracy pode ser enganosa: acertar muitos não eventos pode esconder falhas nos eventos.

$$\text{accuracy} = \frac{TP + TN}{P + N}$$

Precision: exatidão das detecções

Precision pergunta: entre tudo que detectei como evento, quanto era evento real?

É sensível a falsos positivos.

Importa quando alarmes indevidos têm custo alto.

$$\text{precision} = \text{TP} / (\text{TP} + \text{FP})$$

Recall: completude dos eventos

Recall pergunta: entre os eventos reais, quantos foram detectados?

É sensível a falsos negativos.

Importa quando perder evento é mais grave que emitir alarme extra.

$$\text{recall} = \text{TP} / P$$

F1 e $F\beta$

F1 combina precision e recall por média harmônica.

$F\beta$ permite pesar recall mais ou menos que precision.

São úteis quando a avaliação precisa equilibrar alarme falso e evento perdido.

$$F1 = 2 \cdot \text{precision} \cdot \text{recall} / (\text{precision} + \text{recall})$$

Specificity e fallout

Specificity

Mede a capacidade de reconhecer não eventos.

Alta specificity indica poucos falsos positivos.

$$\text{specificity} = \text{TN} / N$$

Fallout

Mede a taxa de falsos positivos.

É o complemento operacional da specificity.

$$\text{fallout} = \text{FP} / N$$

Exemplo com dez observações

No exemplo do capítulo, há dez observações e cinco eventos reais.

O detector marca dois instantes como evento.

O resultado é $TP=1$, $TN=4$, $FP=1$ e $FN=4$.

$Accuracy=0,5$; $precision=0,5$; $recall=0,2$; $F1=0,28$.

CAPÍTULO 7



Score de evento vs rótulo binário

Alguns detectores produzem rótulo: evento ou não evento.

Outros produzem escore: grau de evidência de evento.

Com escore, o limiar de decisão pode variar e gerar curvas de avaliação.

ROC, AUC e AUC-PR



ROC resume tpr contra fpr; AUC-PR é útil em cenários desbalanceados comuns em detecção de eventos.

CAPÍTULO 7

Por que métricas clássicas falham

- Elas ignoram que a ordem temporal tem significado.
- Tratam uma detecção vizinha ao evento como erro total.
- Não avaliam atraso, antecipação, persistência ou cobertura temporal.

O problema do instante exato

Eventos reais podem não ter fronteira temporal perfeitamente definida.

Um detector pode marcar o efeito do evento em vez do instante rotulado.

Exigir igualdade exata entre detecção e rótulo pode ser rígido demais.

CAPÍTULO 7

Efeito antecipado ou atrasado

Alguns eventos apresentam sinais antes do instante oficial.

Outros só ficam observáveis depois que seus efeitos se propagam.

A avaliação precisa distinguir atraso útil de erro irrelevante.

Imprecisão em labels humanos

- Rótulos podem ser definidos por especialistas, sensores ou registros externos.
- A marcação pode ter atraso, arredondamento ou incerteza.
- Tolerância temporal ajuda quando o ground truth não é pontual perfeito.

CAPÍTULO 7

Near miss não é erro total

Uma detecção muito próxima pode ser operacionalmente útil.

Métricas hard não diferenciam quase acerto de erro distante.


Esse é o ponto de partida para métricas com tolerância temporal.

CAPÍTULO 7

Time tolerance

- Time tolerance permite considerar detecções próximas ao evento.
- A distância temporal passa a influenciar o score.
- A avaliação deixa de ser apenas hard: acerto ou erro.

Exemplo com métodos A e B



Métodos A e B detectam próximo de E_1 ; apenas B detecta próximo de E_2 .

Detecção próxima ao evento



A proximidade temporal precisa ser recompensada de forma controlada.




Detecções muito distantes ainda devem ser penalizadas.



O tamanho da janela de tolerância deve refletir o domínio da aplicação.

Hard evaluation vs soft evaluation



A avaliação hard exige coincidência exata; a avaliação soft considera grau de associação temporal.

SoftED: intuição



SoftED flexibiliza métricas clássicas usando tolerância temporal.



Cada detecção recebe grau de pertinência em relação a eventos reais.



Quanto mais próxima do evento, maior sua contribuição para o score.

Função de pertinência temporal





A função $\mu_{ej}(t)$ mede a proximidade entre uma detecção e o evento e_j .

O valor máximo ocorre no instante do evento.

Fora da janela de tolerância k , a pertinência cai para zero.

$\mu_{ej}(t_{di}) \in [0,1]$, controlada por uma tolerância k

SoftED mapping



SoftED mapeia detecções a eventos usando pertinência temporal e restrições de associação.

Restrições do SoftED



Uma detecção não deve ser recompensada por vários eventos ao mesmo tempo.



Várias detecções não devem inflar o escore de um único evento.



O problema pode ser visto como matching bipartido entre detecções e eventos.

TP, FP, TN e FN em versão soft



TPs

Soma pertinências temporais das detecções representativas.



FNs

Mede a parte dos eventos que não foi coberta pelas detecções.



FPs

Penaliza detecções associadas de forma fraca ou inexistente.

Soft precision, recall e F1

- As métricas clássicas podem ser recalculadas usando TP, FP, TN e FN soft.
- A escala permanece interpretável.
- A diferença é que a proximidade temporal passa a influenciar o resultado.

Por que SoftED preserva interpretabilidade



O resultado continua no mesmo vocabulário: precision, recall, F1.



A métrica continua penalizando falso positivo e falso negativo.



Mas deixa de tratar todo near miss como erro total.

SoftED vs métricas hard

Hard: exige coincidência exata entre detecção e evento.

SoftED: recompensa detecção próxima de acordo com a tolerância.

A escolha depende do quanto o domínio aceita imprecisão temporal.

CAPÍTULO 7

Relação com Harbinger

SoftED está disponível no Harbinger.

Isso permite comparar avaliação hard e soft no mesmo fluxo experimental.

É uma ponte prática entre teoria de avaliação e experimentação no tutorial.

Eventos pontuais vs intervalares

- Eventos pontuais ocorrem em um instante.
- Eventos intervalares têm início, fim e duração.
- Avaliar intervalos exige considerar cobertura, atraso e sobreposição.

Ponto a ponto pode distorcer

- Um evento longo pode dominar a métrica por ter muitos pontos.
- Uma pequena detecção dentro de um intervalo pode ser suficiente em algumas aplicações.
- Em outras, é necessário cobrir bem o intervalo completo.

Point-Adjusted F-score

- Se qualquer ponto dentro do segmento real é detectado, todo o segmento é considerado detectado.
- É generoso para detecções parciais.
- Pode superestimar desempenho quando a cobertura importa.

Delay-thresholded Point-Adjusted F-score

- Adiciona uma janela máxima de atraso.
- O evento só conta como detectado se houver detecção nos primeiros k passos.
- É mais alinhado a cenários em que detectar tarde não resolve o problema.

Segment-wise F-score

- Cada segmento real é tratado como uma unidade.
- Basta uma detecção no segmento para gerar verdadeiro positivo.
- Não penaliza fortemente a extensão exagerada de um intervalo detectado.





Range-based F-score

- Avalia cobertura parcial de eventos reais e detecções.
- Recall local mede quanto do evento foi coberto.
- Precision local mede quanto da detecção corresponde ao evento.

Avaliação online é diferente

- O detector não vê a série completa.
- A detecção pode mudar conforme novos batches chegam.
- O momento da detecção é parte essencial do desempenho.

Exemplo de avaliação online



Métodos A e B são avaliados conforme novas observações chegam, evidenciando atraso e inconsistência.

Antecipada, tardia e inconsistente

- Uma detecção pode ocorrer antes, durante ou depois do evento.
- Em online detection, detecções tardias podem ser inúteis.
- Um método também pode mudar sua decisão conforme a janela evolui.

Detection Probability



Mede a probabilidade de uma observação ser detectada ao longo das oportunidades disponíveis.



Compara a frequência de detecção com o número de vezes em que a observação esteve disponível.



Ajuda a distinguir detecção eventual de detecção consistente.

Detection Lag

Mede o atraso entre a primeira disponibilidade da observação e sua primeira detecção.

Quanto menor o lag, mais cedo o método reagiu.

Pode ser expresso em número de batches ou em número de observações.

Batch size, memória e janela de avaliação



Batch size altera a granularidade da avaliação.



Memória parcial limita quantas vezes uma observação pode ser reavaliada.



A janela de avaliação precisa refletir a operação real do sistema.

Qualidade dos benchmarks



A escolha do benchmark influencia fortemente a conclusão sobre um método.



Benchmarks ruins podem criar falsa sensação de progresso.



Avaliar o dataset é parte da avaliação do detector.

Problemas em benchmarks

- Anomalias triviais podem favorecer métodos simples demais.
- Densidade irreal de eventos altera precision e recall.
- Ground truth mal rotulado compromete qualquer métrica.
- Muitas anomalias no fim da série podem enviesar resultados.

Benchmarks recentes

- UCR Anomaly Archive reúne séries curadas para avaliação.
- TimeEval oferece toolkit para comparar algoritmos de anomalias em séries temporais.
- Benchmarks recentes também discutem qualidade de labels, eventos intervalares e métricas apropriadas.

Mensagens principais



Métricas clássicas são úteis, mas insuficientes para muitos eventos temporais.



Eventos intervalares exigem métricas de cobertura, segmento e atraso.



Tolerância temporal evita tratar near miss como erro total.



Avaliação online precisa medir consistência e tempo de reação.