

Harbinger com Ambiente Experimental



Eduardo Ogasawara

eogasawara@cefet-rj.br | <https://eic.cefet-rj.br/~eogasawara>



A trilha prática

Começamos com o contrato comum do pacote, inspecionamos dados, visualizamos séries, rodamos detectores e avaliamos resultados — conectando anomalias, change points, suavização, SAX e motifs.

Contrato e setup

Contrato comum do pacote, configuração do ambiente e carregamento dos dados.

Detectores de anomalia

Execução de detectores simples e avaliação de resultados sobre séries reais.

Change points e transformações

Detecção de change points, suavização e outras transformações de séries temporais.

Inspeção e visualização

Exploração dos dados, visualização de séries temporais e análise estatística inicial.

Avaliação hard/soft

Métricas de avaliação hard e soft para medir a qualidade dos detectores.

SAX, motifs e discords

Representação simbólica SAX, descoberta de motifs e identificação de discords.

Workflow recorrente

Carregar dados.

Escolher ou configurar um método.

Executar detecção.

Inspecionar estrutura de saída.

Plotar e avaliar contra rótulos quando existirem.

ENTRADA: série temporal dataset\$serie (e opcionalmente dataset\$event)

PRÉ-CONDIÇÃO: pacote harbinger carregado; dados sem NA

PASSO 1 — Instanciar o método: `model <- metodo(parametros)`

PASSO 2 — Ajustar (quando necessário): `model <- fit(model, dataset$serie)`

PASSO 3 — Detectar: `detection <- detect(model, dataset$serie)`

PASSO 4 — Visualizar: `har_plot(model, dataset$serie, detection, dataset$event)`

PASSO 5 — Avaliar (quando há rótulos): `evaluate(model, detection$event, dataset$event)`

SAÍDA: data.frame com colunas idx, event, type (e atributos extras por método)

PÓS-CONDIÇÃO: detection\$event é vetor lógico alinhado ao índice da série

Setup mínimo

Os exemplos usam uma semente comum para reprodutibilidade.

O pacote `harbinger` fornece detectores, avaliação e visualização.

`daltoolbox` aparece em exemplos que usam transformações e modelos auxiliares.

```
source(url("https://raw.githubusercontent.com/cefet-rj-dal/harbinger/master/examples/seed.R"))  
library(harbinger)  
library(daltoolbox)
```

Inspeção de dados: conheça antes de detectar

A escolha do detector depende da coleção: tamanho, canais, rótulos e estrutura. Inspecionar antes evita escolher algoritmo apenas pelo nome.




Estrutura da coleção

Tamanho, canais, rótulos e tipo (univariada ou multivariada).



Metadados separados

idx, event, type, seq e seqlen são separados dos sinais pelo helper.




Benchmark real

O tutorial usa o A1Benchmark como exemplo de coleção real.

```
data(A1Benchmark)
A1Benchmark <- loadfulldata(A1Benchmark)
info <- dataset_summary(A1Benchmark)
```

Benchmark Yahoo A1

Inspeção visual da primeira série de uma coleção rotulada.



```
data(A1Benchmark)
A1Benchmark <- loadfulldata(A1Benchmark)
a1_info <- show_dataset(A1Benchmark, "A1Benchmark")
## Dataset: A1Benchmark
## Number of series: 67
## Dataset type: univariate
## Signals in the first series: value
## Column plotted with har_plot(): value
## Plot preview length: 1000 observations
plot_dataset_preview(a1_info)
```

[harbinger/examples/datasets/01-benchmarks-yahoo_benchmarks.md at master · cefet-rj-dal/harbinger](#)

Séries univariadas e multivariadas

Univariada

Uma coluna de sinal.

Entrada direta para muitos detectores.

Boa para iniciar o workflow.

Multivariada

Várias colunas de sinal.

Requer escolher canais ou combinar dimensões.

A inspeção orienta a escolha.

Dados rotulados para o primeiro contato

O primeiro exemplo usa uma série pequena com rótulo de evento.

Isso permite entender entrada, saída e visualização sem discutir ainda um detector específico.

```
data(examples_anomalies)
dataset <- examples_anomalies$simple
head(dataset)
```

Visualização inicial e diagnóstico

Antes de detectar, visualizamos a série e os eventos conhecidos.

har_plot() como diagnóstico

Mais que estética


Revela tendência, bursts, mudança de nível e ruído antes de qualquer ajuste.

Primeira checagem

Use antes de ajustar janelas, limiares e detectores.

Eventos sobrepostos

Rótulos do ground truth aparecem junto com a detecção para comparação visual imediata.



Contrato comum do Harbinger

`harbinger()` representa o contrato comum do pacote.

Um método recebe uma série e retorna uma saída padronizada orientada a eventos.

Esse contrato facilita trocar detectores sem trocar todo o workflow.

ENTRADA: série temporal `dataset$serie`

PRÉ-CONDIÇÃO: método instanciado via `harbinger()`

PASSO 1 — Instanciar: `model <- harbinger()`

PASSO 2 — Detectar: `detection <- detect(model, dataset$serie)`

PASSO 3 — Inspecionar: `head(detection)`

```
# idx | event | type
#  1 | FALSE |
#  2 | FALSE |
# 42 | TRUE  | anomaly
```

SAÍDA: data.frame padronizado com `idx`, `event`, `type`

PÓS-CONDIÇÃO: interface `id`êntica para qualquer detector `do` pacote

Saída padronizada

Estrutura mínima

A saída sempre contém `idx` (índice), `event` (TRUE/FALSE) e `type` (tipo do evento). Detectores podem adicionar atributos extras.

Intercambiabilidade

A padronização permite trocar detectores sem mudar o código de avaliação e plotagem — a mesma interface funciona para qualquer detector do pacote.

```
idx | event | type  
1 | FALSE |  
2 | FALSE |  
42 | TRUE | anomaly
```

Primeiro detector de anomalia

`hanr_histogram()` é um baseline simples e interpretável.

A ideia é tratar valores em bins raros como anômalos.

Ele não modela dinâmica temporal, mas é útil como referência inicial.

Baseline simples

Não modela dinâmica temporal. Útil como referência inicial.

Parâmetro único

`density_threshold` controla o limiar de raridade dos bins.

Interpretável

Fácil de explicar: valores em bins raros são anômalos.

Histograma: configurar e detectar

O histograma divide a série em **bins de frequência** e marca como anomalia os pontos que caem em bins com densidade muito baixa.

Parâmetro principal: `density_threshold` — limiar de densidade abaixo do qual um ponto é considerado raro.

Use como **baseline interpretável** quando não há necessidade de modelagem temporal. Simples, rápido e transparente.

ENTRADA: série univariada `dataset$serie`

PRÉ-CONDIÇÃO: série numérica sem NA

PASSO 1 — Construir histograma de frequências da série

PASSO 2 — Calcular densidade de cada bin

PASSO 3 — Marcar como anomalia pontos em bins com densidade $< \text{density_threshold}$

PASSO 4 — Retornar índices marcados como `event = TRUE`


SAÍDA: detection com colunas `idx`, `event` (`TRUE/FALSE`), `type = "anomaly"`

PÓS-CONDIÇÃO: proporção de anomalias $\approx \text{density_threshold}$

```
model <- hanr_histogram(density_threshold = 0.05)
detection <- detect(model, dataset$serie)
head(detection)
```

Resultado do detector por histograma

Detecções do baseline sobre a série rotulada.



```
library(daltoolbox)
library(harbinger)
# Load example anomaly datasets
data(examples_anomalies)
# Select a simple anomaly dataset
dataset <- examples_anomalies$simple
head(dataset)
har_plot(harbinger(), dataset$serie, event = dataset$event)
model <- hanr_histogram(density_threshold = 0.05)
model <- fit(model, dataset$serie)
detection <- detect(model, dataset$serie)
print(detection |> dplyr::filter(event == TRUE))
evaluation <- evaluate(model, detection$event, dataset$event)
print(evaluation$confMatrix)
har_plot(model, dataset$serie, detection, dataset$event)
```

Avaliação do baseline: hard e soft

Quando há ground truth, a detecção pode ser comparada com os rótulos. A mesma detecção pode ser lida por avaliadores diferentes — isso separa o resultado do detector do critério de julgamento.

```
# Avaliação direta
evaluation <- evaluate(model, detection$event, dataset$event)
evaluation$confMatrix

# Comparando avaliadores
hard_result <- evaluate(har_eval(), detection$event, dataset$event)
soft_result <- evaluate(har_eval_soft(), detection$event, dataset$event)
```

O que retorna

Matriz de confusão (TP, FP, FN, TN) e métricas derivadas: precision, recall, F1.

Por que comparar

Hard e soft medem a mesma detecção com critérios diferentes. $F1_{\text{soft}} \geq F1_{\text{hard}}$ sempre.

Avaliação estrita e avaliação suave

Hard evaluation

Exige coincidência direta.

Útil para rótulos pontuais bem definidos.

```
har_eval()
```

Soft evaluation

Aceita desalinhamento temporal pequeno.

Mais adequada a eventos com imprecisão temporal.

```
har_eval_soft()
```

ENTRADA: `detection$event` (vetor lógico detectado), `dataset$event` (ground truth)

PRÉ-CONDIÇÃO: vetores de mesmo comprimento; alinhados por índice

PASSO 1 — Hard **evaluation** (`har_eval`):

Comparar `detection$event == dataset$event` ponto a ponto

Calcular TP, FP, FN, TN diretos

PASSO 2 — Soft **evaluation** (`har_eval_soft`):

Para cada evento detectado, verificar se há rótulo dentro de uma janela de tolerância temporal

Calcular TP, FP, FN com margem de desalinhamento

PASSO 3 — Calcular métricas: precision, recall, F1

SAÍDA: lista com `confMatrix`, precision, recall, F1

PÓS-CONDIÇÃO: $F1_{hard} \leq F1_{soft}$ (soft é mais permissiva)

Anomalia baseada em modelo

`har_arma()` modela o comportamento esperado da série.

Anomalias aparecem como resíduos grandes.

Esse exemplo conecta o Harbinger à teoria de modelos temporais.

Modelagem temporal

ARIMA captura autocorrelação e tendência da série.

Resíduos como sinal

Anomalias aparecem onde o modelo erra mais do que o esperado.

Mesmo workflow

`fit()`, `detect()` e `evaluate()` idênticos ao histograma.

ARIMA: ajustar, detectar e avaliar

Sobre o método

Modela o comportamento esperado da série temporal. Anomalias são identificadas como **resíduos grandes** em relação ao modelo ajustado.

Parâmetros principais

Ordem `p,d,q` selecionada automaticamente pelo detector.

Quando usar

Séries estacionárias ou com tendência e diferenciáveis; sem valores `NA`.

ENTRADA: série temporal `dataset$serie` com rótulos `dataset$event`

PRÉ-CONDIÇÃO: série estacionária ou diferenciável; sem `NA`

PASSO 1 — Ajustar modelo ARIMA à série (fit)

Selecionar ordem `p,d,q` automaticamente

PASSO 2 — Calcular resíduos: $e_t = x_t - \hat{x}_t$

PASSO 3 — Estimar limiar: $\text{threshold} = k * \text{sd}(e_t)$

PASSO 4 — Marcar como anomalia: $|e_t| > \text{threshold} \rightarrow \text{event} = \text{TRUE}$


PASSO 5 — Avaliar contra rótulos (evaluate)

SAÍDA: detection com `idx`, `event`, `type = "anomaly"`; métricas de avaliação


PÓS-CONDIÇÃO: resíduos `do` modelo ajustado disponíveis para diagnóstico

```
model <- hanr_arima()
model <- fit(model, dataset$serie)
detection <- detect(model, dataset$serie)
evaluate(model, detection$event, dataset$event)
```

Detecção por ARIMA



O modelo detecta anomalias a partir do desvio em relação ao comportamento esperado.



O resíduo explica por que o detector marcou determinados pontos.

Primeiro detector de change point

- `hcp_amoc()` procura uma mudança dominante.
- O alvo não é um ponto isolado raro, mas uma transição de regime.
- É uma entrada simples antes de métodos de múltiplas mudanças.

At Most One Change

Detecta no máximo uma mudança dominante de regime.

Mudança de nível


Identifica transição entre dois estados distintos da série.

Ponto de partida

Entrada simples antes de métodos de múltiplas mudanças como PELT ou BinSeg.

Série com change point rotulado

A visualização mostra a série antes de aplicar AMOC.



AMOC no Harbinger

O que é AMOC?


At Most One Change — detecta uma única mudança dominante de regime na série temporal.

Quando usar

Ideal para séries com **uma transição clara** entre dois estados distintos, sem múltiplas rupturas.

Resultado

O algoritmo marca o índice detectado como changepoint, indicando o ponto de maior custo mínimo de segmentação.



ENTRADA: série temporal `dataset$serie`

PRÉ-CONDIÇÃO: série numérica sem NA;

espera-se no máximo uma mudança

PASSO 1 — Para cada ponto de corte t em $[2, n-1]$:

Calcular custo de segmentar a série em

$[1..t]$ e $[t+1..n]$

(ex.: soma dos quadrados dos resíduos em cada segmento)

PASSO 2 — Selecionar t^* que minimiza o custo total

PASSO 3 — Marcar t^* como `event = TRUE`,

`type = "changepoint"`

SAÍDA: `detection` com `idx`, `event` (TRUE em t^*),

`type = "changepoint"`

PÓS-CONDIÇÃO: exatamente um ponto marcado como changepoint

```
model <- hcp_amoc()
detection <- detect(model, dataset$serie)
har_plot(model, dataset$serie, detection, dataset$event)
```

O gráfico ao lado mostra o changepoint detectado pelo AMOC sobre a série rotulada.

Transformações importam

- Antes de detectar, podemos transformar a série.
- Suavização revela padrões de baixa frequência e reduz variação local.
- A escolha da transformação muda o que o detector enxerga.

Moving average smoother

- `mas()` calcula média móvel.
- Janelas menores preservam detalhe.
- Janelas maiores produzem sinal mais suave.

ENTRADA: série temporal `dataset$serie`; ordem da janela (order)

PRÉ-CONDIÇÃO: série numérica sem NA; order ≥ 1

PASSO 1 — Para cada ponto t na série:

Calcular média dos pontos em $[t - \text{order}/2, t + \text{order}/2]$

PASSO 2 — Retornar série suavizada do mesmo comprimento

(bordas preenchidas com NA ou valor de borda)


SAÍDA: série suavizada (vetor numérico)

PÓS-CONDIÇÃO: variância local reduzida; tendência preservada

```
ma_5 <- mas(dataset$serie, order = 5)
```

```
ma_15 <- mas(dataset$serie, order = 15)
```

SAX e XSAX no workflow



Discretização Simbólica

Converte séries temporais contínuas em sequências de símbolos discretos, permitindo análise simbólica eficiente.

- **SAX**: usa um alfabeto compacto de tamanho α
- **XSAX**: permite codificação mais rica com α^2 símbolos

Parâmetro Principal

α = tamanho do alfabeto (ex: 8 para SAX, 16 para XSAX)

Quando Usar

- Pré-processamento para **motif discovery**
- Compressão de séries temporais
- Redução de dimensionalidade simbólica

ENTRADA: série temporal `dataset$serie`

PRÉ-CONDIÇÃO: série numérica normalizada; $\alpha \geq 2$

PASSO 1 — Normalizar a série (z-score)

PASSO 2 — Dividir em janelas de tamanho w (PAA)

Calcular média de cada janela

PASSO 3 — Mapear cada média para símbolo do alfabeto usando breakpoints da distribuição **normal**

(SAX: α símbolos; XSAX: α^2 símbolos)

PASSO 4 — Retornar série simbólica de comprimento n/w

SAÍDA: vetor de símbolos (`sax_series` ou `xsax_series`)

PÓS-CONDIÇÃO: série simbólica pronta para motif discovery

Motifs e discords

A trilha fecha com análise de padrões recorrentes.

Motif discovery pergunta quais subsequências se repetem.

Discords são subsequências isoladas em relação ao restante.

Motifs

Subsequências que se repetem com frequência $\geq$ suporte mínimo. Indicam padrões recorrentes no comportamento da série.

Marcados como `type = "motif"`.

Discords

Subsequências mais distantes do vizinho mais próximo. Indicam comportamentos raros ou anômalos.

Marcados como `type = "discord"`.

Detector simbólico de motivos

O que é `hmo_sax()`?

Conecta discretização SAX e busca por subsequências recorrentes na mesma chamada.

- **Motifs:** padrões que se repetem na série
- **Discords:** subsequências isoladas, distantes do vizinho mais próximo

Parâmetros principais

- **alpha:** tamanho do alfabeto simbólico
- **w:** tamanho da subsequência
- **suporte:** frequência mínima para classificar como motif

ENTRADA: série simbólica (saída de `trans_sax` ou `trans_xsax`)

PRÉ-CONDIÇÃO: série discretizada; suporte ≥ 1

PASSO 1 — Gerar todas as subsequências de tamanho `w`

PASSO 2 — Contar frequência de cada subsequência simbólica

PASSO 3 — Motifs: subsequências com frequência $\geq$ suporte

Marcar ocorrências como `event = TRUE`, `type = "motif"`

PASSO 4 — Discords: subsequências com frequência = 1

(mais distantes `do` vizinho mais próximo)




Marcar como `event = TRUE`, `type = "discord"`

SAÍDA: `detection` com `idx`, `event`, `type` ("motif" ou "discord")

PÓS-CONDIÇÃO: motifs e discords identificados na mesma chamada

```
model <- hmo_sax(8, 15, 3)
model <- fit(model, dataset$serie)
detection <- detect(model, dataset$serie)
```

Referências Bibliográficas



Event Detection in Time Series

Ogasawara, E.; Salles, R.; Porto, F.;
Pacitti, E. Springer Nature Switzerland,
2025.

Time Series Analysis: With Applications in R

Cryer, J. D.; Chan, K.-S. Springer, 2008.

Data Mining: Concepts and Techniques

Han, J.; Pei, J.; Tong, H. Morgan
Kaufmann, 4^a ed., 2022.