

Agenda de Pesquisa em Detecção de Eventos



Eduardo Ogasawara

eogasawara@cefet-rj.br | <https://eic.cefet-rj.br/~eogasawara>



CAPÍTULO 8

Objetivos do capítulo

- Sintetizar o panorama da pesquisa em detecção de eventos.
- Mostrar como anomalias, change points e motifs se conectam.
- Organizar desafios abertos e oportunidades de pesquisa.

CAPÍTULO 8

O papel do fechamento

Depois dos métodos, precisamos olhar para a área como um todo.

O capítulo identifica tendências, lacunas e temas emergentes.

A pergunta deixa de ser apenas como detectar e passa a ser o que ainda falta resolver.

Três áreas centrais

Anomaly detection

Procura desvios e comportamentos raros.

Change point detection

Localiza transições entre regimes.

Motif discovery

Descobre padrões recorrentes e, indiretamente, discords.

CAPÍTULO 8

Uma área ampla e ativa

Time series event detection envolve métodos estatísticos, mineração de dados, aprendizado de máquina e sistemas.

A produção científica cresce porque séries temporais aparecem em sensores, saúde, clima, indústria, finanças e segurança.

O campo não converge para um único problema: ele se organiza em subáreas complementares.

CAPÍTULO 8

Mapa sistemático da produção

O capítulo resume consultas no Scopus realizadas em 29 de novembro de 2023.

As buscas incluem documentos com restrição a time series.

As áreas analisadas são event detection, anomaly, change point/concept drift e motif.

CAPÍTULO 8


Produção por área

Anomaly detection é a subárea com maior volume de publicações.

Change point e concept drift formam uma linha consolidada, com base estatística forte.

Motif discovery é menor em volume, mas central para padrões recorrentes e subsequências.

Evolução das publicações



Número de publicações em escala logarítmica nas principais áreas de detecção de eventos.

CAPÍTULO 8

O que o gráfico mostra

- Anomalias dominam a produção científica.
- Change points crescem fortemente após os anos 1980.
- Event detection se consolida como termo mais geral a partir dos anos 2000.
- Motifs aparecem de forma mais recente e com ritmo estável.

Interseções entre áreas

- Event detection se conecta principalmente com anomaly detection.
- Anomaly e change point têm interseção expressiva.
- Anomaly e motif também se encontram, especialmente quando discords entram na discussão.

CAPÍTULO 8

Por que as interseções importam

Séries reais podem conter anomalias, mudanças de regime e padrões recorrentes ao mesmo tempo.

Métodos especializados veem partes diferentes do fenômeno.

Uma visão unificada pode produzir detectores mais robustos e interpretações melhores.

Word clouds como leitura qualitativa

Além da contagem de publicações, o vocabulário revela a identidade das subáreas.

Termos frequentes indicam métodos, aplicações e preocupações dominantes.

A comparação mostra que as subáreas compartilham o tema temporal, mas falam dialetos diferentes.

CAPÍTULO 8

Event detection: sistemas e mineração

- A área geral aparece associada a sistemas, mineração de dados e aprendizado.
- O foco tende a ser operacional: detectar ou prever eventos em aplicações.
- É o ponto de encontro entre métodos e uso prático.

CAPÍTULO 8

Anomaly detection: domínio e aplicação

A literatura de anomalias é fortemente orientada por aplicações.

Sensores, clima, redes e domínios específicos aparecem com frequência.

Isso reforça que anomalia depende muito do contexto.

CAPÍTULO 8

Change points: estatística e conceito

Change point detection carrega vocabulário estatístico forte.

Concept drift conecta mudança temporal com aprendizado adaptativo.

A subárea enfatiza transições de regime e estabilidade de modelos.

CAPÍTULO 8

Motifs: padrões e subsequências

Motif discovery fala em padrões, subsequências e discovery.


A lógica é menos classificar pontos e mais descobrir formas recorrentes.

Essa diferença de vocabulário ajuda a explicar por que motifs exigem métodos próprios.


Vocabulário das subáreas



(a)



(b)



(c)



(d)

Word clouds para event detection, anomaly, change point e motif.

Desafio: séries multivariadas

- Fontes modernas coletam muitas variáveis ao longo do tempo.
- Eventos podem surgir da relação entre dimensões, não apenas de uma série isolada.
- Dimensionalidade, dependência e interpretabilidade tornam o problema mais difícil.

Desafio: escala e big data



Sensores, redes sociais e sistemas industriais geram séries longas e rápidas.



Métodos tradicionais podem falhar em custo, memória ou latência.



Spark, Kafka e Flink aparecem como infraestrutura para workflows escaláveis.

Desafio: detecção online

- Em streaming, não há série completa para analisar.
- O detector precisa decidir no fluxo, com memória limitada e dados em mudança.
- Anomalias próximas a drift ou change points podem ser especialmente ambíguas.

CAPÍTULO 8

Desafio: métricas para eventos

Ainda faltam métricas unificadas para eventos pontuais, intervalares e online.

Tolerância temporal precisa ser tratada de forma consistente.

Métricas devem evoluir quando novos dados chegam em streaming.

Desafio: explicabilidade



Detectores complexos podem funcionar como caixas-pretas.



Em saúde, finanças e segurança, explicar o evento é tão importante quanto detectá-lo.



SHAP, LIME e visualização interativa podem inspirar soluções mais confiáveis.

Desafio: visão unificada

- Anomalias, change points e motifs ainda são estudados como problemas separados.
- Séries reais frequentemente combinam os três tipos de evento.
- Um detector mais amplo deve integrar evidências de desvio, mudança e recorrência.

Transfer learning e adaptação

- Modelos treinados em um domínio nem sempre generalizam para outro.
- Transfer learning pode reduzir dependência de rótulos no novo domínio.
- A adaptação em séries multivariadas ainda é pouco explorada.

CAPÍTULO 8

LLMs e séries como tokens

Modelos recentes podem tratar séries temporais discretizadas como sequências de tokens.

Isso abre espaço para pré-treinamento em grandes coleções e ajuste fino por tarefa.

A promessa é aproveitar representação aprendida quando há poucos rótulos.

Robustez contra ataques adversariais



Em segurança e finanças, pequenos ajustes nos dados podem enganar detectores.



Modelos de ML precisam ser avaliados contra manipulação intencional.



Robustez vira requisito quando o detector participa de decisão crítica.

Associação entre eventos

- Eventos podem formar sequências e relações causais.
- Pequenas anomalias podem preceder change points relevantes.
- Associar eventos aproxima detecção de mineração de sequências e raciocínio causal.

CAPÍTULO 8

Eficiência energética e edge

- IoT, wearables e edge computing têm restrições fortes de energia e memória.
- Detectores precisam ser leves sem perder confiabilidade.
- Eficiência energética será requisito para implantação em larga escala.

CAPÍTULO 8

Métodos híbridos e detectores amplos

Métodos híbridos podem combinar anomalia, mudança e recorrência.

A vantagem é capturar fenômenos diferentes no mesmo fluxo temporal.

O desafio é integrar saídas, métricas e explicações sem criar um sistema opaco.

CAPÍTULO 8

O que falta para aplicações reais

- Benchmarks representativos.
- Métricas temporais adequadas.
- Explicações compreensíveis para especialistas.
- Custo computacional compatível com operação contínua.

CAPÍTULO 8

Como os capítulos se conectam

- Capítulos 1 e 2 constroem o vocabulário e a base de séries temporais.
- Capítulos 3, 4 e 5 tratam anomalias, change points e motifs.
- Capítulos 6 e 7 levam o problema para online, predição e avaliação temporal.

CAPÍTULO 8

Agenda prática

1. Escolher claramente o tipo de evento.
2. Definir cenário: offline, online ou preditivo.
3. Usar métrica coerente com ponto, intervalo, tolerância e atraso.
4. Combinar métodos quando a série tiver múltiplos tipos de evento.

Mensagens finais

Detecção de eventos em séries temporais é uma área ativa e fragmentada.

A próxima geração de métodos precisa ser multivariada, online, explicável e avaliável temporalmente.

A visão unificada é o caminho para transformar métodos isolados em sistemas reais de monitoramento.