

Paradigmas de Detecção Temporal

Abordagens para identificar mudanças em dados ao longo do tempo.

Eduardo Ogasawara

eduardo.ogasawara@cefet-rj.br

<https://eic.cefet-rj.br/~eogasawara>

Detecção Temporal: Modos de Operação

Considere uma série temporal formada por observações sucessivas ao longo do tempo. A detecção pode ocorrer de duas formas fundamentais: offline, quando toda a série está disponível, ou online, quando os dados chegam progressivamente. A diferença central está no acesso ao futuro.

$$X = (x_1, x_2, \dots, x_T)$$

Onde x_t representa a observação no instante t e T é o número total de observações. Essa distinção muda completamente a lógica da detecção.

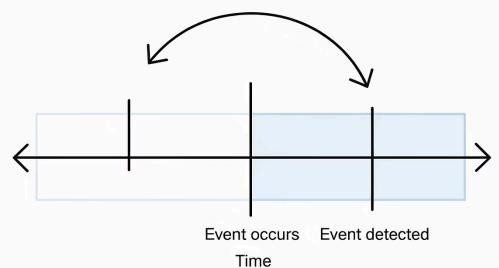
Série Temporal como Informação Crescente

No paradigma online, o processo é observado ao longo do tempo e o conjunto de dados cresce a cada instante. A informação disponível é sempre parcial, nunca completa.

$$X_t = (x_1, x_2, \dots, x_t)$$

Em vez de pensar na série como algo fechado, o paradigma online trata o tempo como acumulação de informação. Em cada instante, só conhecemos o passado e o presente, nunca o futuro.

Latência de Detecção



Evento Real

Ocorre no instante τ

Detecção

Identificado em $\hat{\tau}$

Atraso

Latência Δt

A latência de detecção é inevitável no paradigma online. Não é possível detectar um evento antes que ele aconteça, portanto sempre existe um atraso entre o instante real do evento e o instante em que o algoritmo o identifica.

$$\Delta t = \hat{\tau} - \tau$$

Restrições do Paradigma Online

Memória Limitada

O algoritmo não pode armazenar toda a série histórica de observações

Tempo de Processamento

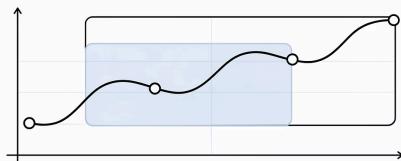
Cálculos complexos a cada passo são inviáveis em tempo real

Ausência de Futuro

Nunca há acesso às observações futuras, impondo limites estruturais

Diferentemente do offline, essas restrições definem os limites fundamentais da detecção em tempo real.

Janela Deslizante



A janela deslizante define quanto do passado o algoritmo consegue "lembrar". Em vez de usar toda a série, a detecção online opera sobre um recorte recente do tempo, controlando o horizonte de observação com memória limitada.

$$X_{t-w+1:t} = (x_{t-w+1}, \dots, x_t)$$

Onde w é o tamanho da janela e $X_{t-w+1:t}$ representa as observações dentro da janela no instante t . Essa estrutura é a base para a detecção online eficiente.

Estatísticas Incrementais

Em vez de recalcular estatísticas usando todos os dados, o paradigma online atualiza valores a cada nova observação. Isso permite eficiência computacional sem perder consistência estatística.

A média incremental exemplifica esse princípio:

$$\mu_t = \mu_{t-1} + \frac{x_t - \mu_{t-1}}{t}$$

Onde μ_t é a média até o instante t , μ_{t-1} é a média no instante anterior, e x_t é a observação atual. O cálculo é recursivo, sem necessidade de armazenar toda a série.

Vantagens

- Memória constante
- Tempo de processamento fixo
- Atualização em tempo real
- Precisão mantida

Modelos Adaptativos

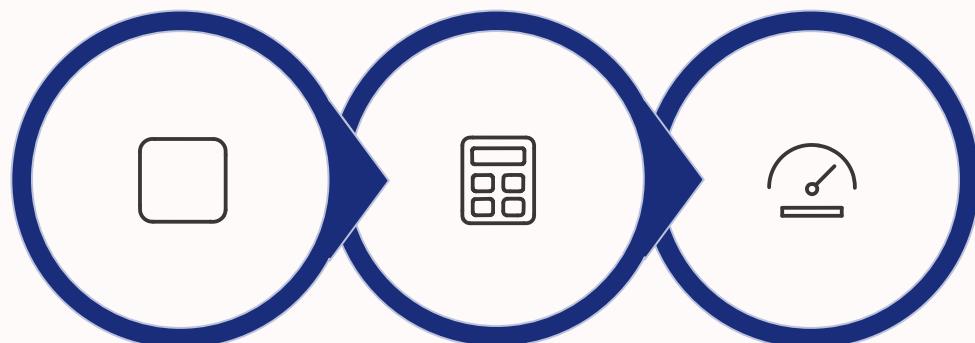


No paradigma online, os parâmetros do modelo não são fixos. Eles evoluem com o tempo, refletindo mudanças no comportamento do processo observado.

$$x_t = f_{\theta_t}(x_{t-1}, \dots, x_{t-p}) + \varepsilon_t$$

Onde f_{θ_t} é o modelo com parâmetros θ_t dependentes do tempo, p é o número de defasagens, e ε_t é o erro no instante t .

Score de Detecção

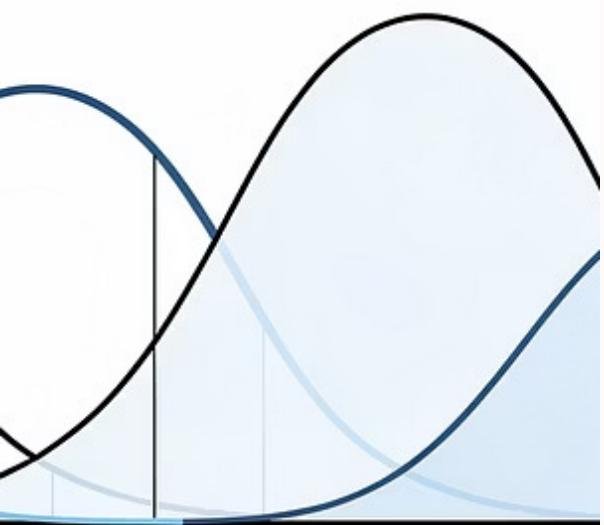


O processo de detecção transforma a janela temporal em uma decisão através do score.

O score transforma a série recente em um número que mede discrepância ou mudança. A decisão de detectar um evento depende da comparação desse valor com um limiar estabelecido.

$$S_t = \phi(X_{t-w+1:t})$$

Onde S_t é o score de detecção, ϕ é a função de discrepância, e $X_{t-w+1:t}$ é a janela temporal. Essa estatística resume o comportamento recente da série.



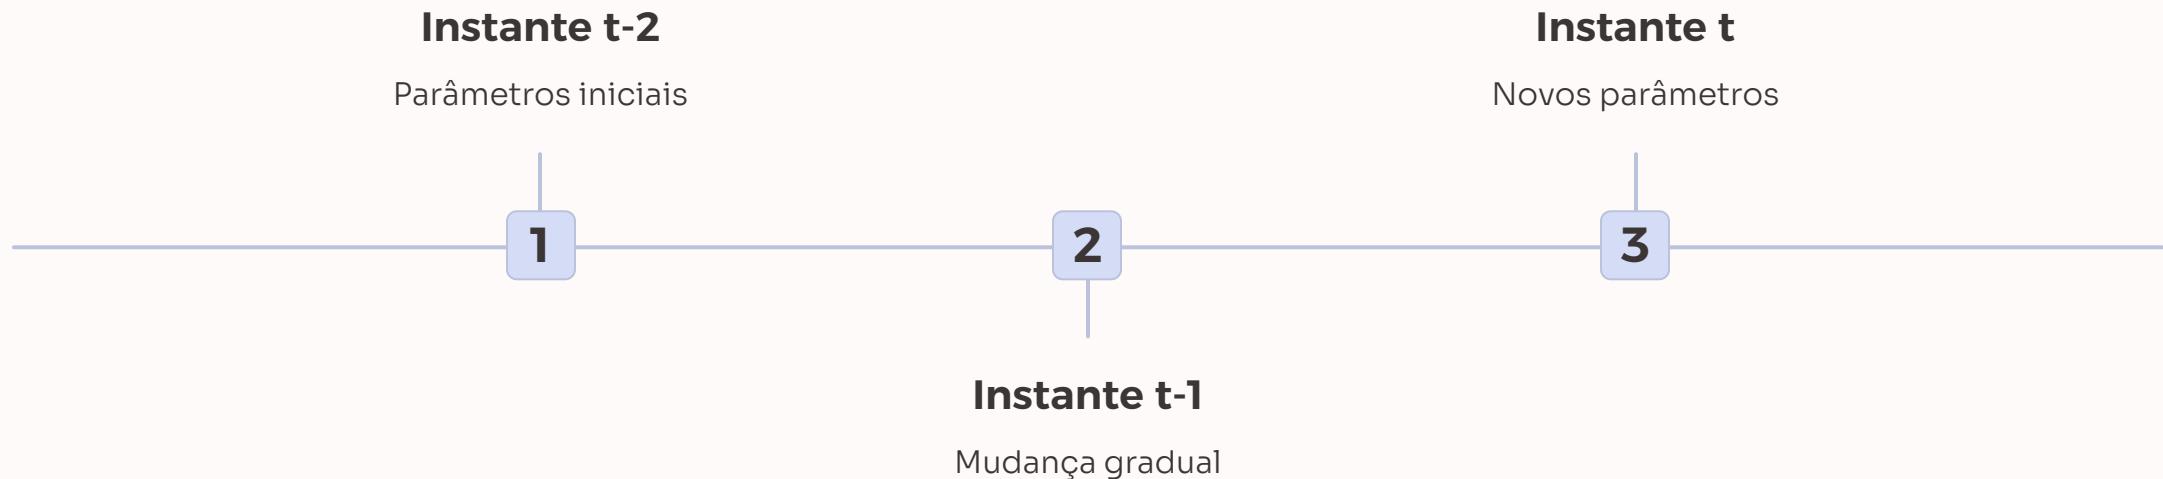
Tipicidade Adaptativa

No offline, a tipicidade é fixa. No online, ela muda com o tempo, porque os parâmetros do processo evoluem. Assim, o que é "típico" em um instante pode não ser em outro.

$$x_t \sim F_{\theta_t}$$

A distribuição das observações F_{θ_t} possui parâmetros dependentes do tempo. A tipicidade deixa de ser um conceito estático e passa a ser dinâmico, adaptando-se continuamente ao comportamento do processo.

Drift: Mudança Gradual



Drift representa uma evolução contínua do processo. Ao contrário dos change points, não há ruptura súbita, mas transformação progressiva do comportamento da série.

$$\theta_t \neq \theta_{t-1}$$

Os parâmetros variam continuamente ao longo do tempo, caracterizando mudança gradual em vez de abrupta.

Concept Drift

Concept drift não é apenas mudança na série, mas na relação entre variáveis explicativas e resposta. Isso afeta diretamente modelos de previsão online, sendo típico em sistemas preditivos.

$$P_t(Y | X) \neq P_{t-1}(Y | X)$$

A distribuição condicional $P_t(Y | X)$ muda ao longo do tempo, representando um fenômeno temporal que requer adaptação contínua dos modelos.

Regime Drift

Regime A

Parâmetros iniciais definem o primeiro regime operacional

Transição

Passagem gradual e suave entre estados

Regime B

Novos parâmetros estabelecem regime diferente

Regime drift descreve a passagem suave entre regimes do processo. Ele pode ser visto como uma versão contínua das mudanças estruturais abruptas, onde regimes são definidos por conjuntos de parâmetros que transitam gradualmente.

Drift versus Change Points

Change Points

Mudanças abruptas e instantâneas na estrutura

Drift

Mudanças contínuas e progressivas ao longo do tempo

Embora distintos, drift e change points não são completamente independentes. Ambos descrevem instabilidade temporal, mas em escalas e formas diferentes. São fenômenos relacionados que capturam diferentes aspectos da evolução temporal.

Drift versus Anomalias

Anomalias

Desvios pontuais que violam o padrão vigente em um instante específico

A diferença fundamental está entre o local e o sistêmico. Anomalias são eventos isolados, enquanto drift representa transformação contínua do sistema.

Drift

Mudança estrutural que modifica o próprio padrão ao longo do tempo

Relação

Drift altera o contexto em que as anomalias são definidas

Continuidade entre Offline e Online

O paradigma online pode ser visto como uma versão restrita do offline. A diferença não é conceitual, mas informacional: no online, só parte da informação está disponível.

$$\mathcal{F}_t \subset \mathcal{F}_T$$

A informação disponível no instante t , representada por \mathcal{F}_t , é sempre um subconjunto da informação total \mathcal{F}_T . Existe uma relação de inclusão que conecta os dois paradigmas, onde offline é o caso limite quando $t = T$.

Arquitetura da Detecção Online

01

Representação Incremental

Dados brutos transformados em estruturas eficientes para processamento contínuo

02

Cálculo de Estatísticas

Atualização recursiva de medidas sem armazenar histórico completo

03

Decisão de Eventos

Comparação com limiares e identificação de padrões relevantes

A detecção online pode ser vista como uma cadeia de transformações: dados → representação → score → decisão. Essa estrutura evidencia o caráter incremental do paradigma e a integração entre estatística e computação.

O Tempo como Fluxo

Tipicidade Dinâmica

Padrões evoluem continuamente

Eventos Contínuos

Processos emergentes no tempo

Modelos Adaptativos

Parâmetros em transformação

Integração

Estatística e computação unificadas

A síntese conceitual é que, no paradigma online, o tempo deixa de ser um objeto fechado e passa a ser um fluxo contínuo. Eventos deixam de ser fatos isolados e passam a ser processos que emergem ao longo do tempo, exigindo uma abordagem fundamentalmente diferente para sua detecção e análise.

Referências Bibliográficas

Uma coleção cuidadosamente selecionada de obras fundamentais que abordam análise de séries temporais e mineração de dados.



Event Detection in Time Series

Ogasawara, E.; Salles, R.; Porto, F.; Pacitti, E.

(2025). Publicação recente da Springer Nature Switzerland que explora técnicas avançadas de detecção de eventos em séries temporais.

Time Series Analysis: With Applications in R

Cryer, J. D.; Chan, K.-S. (2008). Obra clássica da Springer que combina fundamentação teórica sólida com implementações práticas.

Data Mining: Concepts and Techniques

Han, J.; Pei, J.; Tong, H. (2022). Quarta edição publicada pela Morgan Kaufmann que consolida conceitos fundamentais e técnicas avançadas de mineração de dados.