



Discord Analysis



Data Analytics Lab

dal.global@grupo.cefet-rj.br | <https://eic.cefet-rj.br/dal>



SAX – Symbolic Aggregate approXimation

O SAX converte séries temporais numéricas em sequências de caracteres (palavras simbólicas), tornando a busca por motivos — padrões repetitivos — muito mais eficiente. Em vez de comparar valores brutos, comparamos palavras de um alfabeto finito.

Como Funciona o SAX

01

Normalização Z

A subsequência é normalizada para média zero e desvio padrão unitário, eliminando dependências de escala e deslocamento.

02

PAA – Piecewise Aggregate Approximation

A série normalizada é dividida em **w** segmentos de igual comprimento. A média de cada segmento gera uma representação compacta com **w** valores.

03

Discretização Simbólica

Cada valor PAA é mapeado a uma letra do alfabeto usando *breakpoints* gaussianos, produzindo uma **palavra simbólica** de comprimento **w**.

Motivos são palavras simbólicas que se repetem com alta frequência. Com `hmo_sax(26, 3, 3)` — alfabeto de 26 letras e palavra de comprimento 3 — cada subsequência torna-se uma palavra de 3 letras. O motivo "QST" foi detectado 3 vezes, nos índices 25, 50 e 75.

Parâmetros Principais

Tamanho do Alfabeto (*a*)

Controla a resolução simbólica. Mais letras = distinções mais finas entre valores PAA. Exemplo: `a = 26`.

Comprimento da Palavra (*w*)

Controla a granularidade temporal. Palavras mais longas = padrões mais específicos. Exemplo: `w = 3`.

Ocorrências Mínimas

Número mínimo de repetições para que uma palavra simbólica seja considerada um motivo. Exemplo: `min_occurrences = 3`.

Referência: Lin, J., Keogh, E., Lonardi, S., Chiu, B. (2007). A symbolic representation of time series, with implications for streaming algorithms. *Data Mining and Knowledge Discovery*, 15, 107–144.

06 – Motif Discovery with SAX

SAX (Symbolic Aggregate approXimation) discretizes z-normalized subsequences into symbolic words using breakpoints from a Gaussian distribution. Motifs emerge as frequently repeated words.

```
# Carregar pacotes e dados
library(daltoolbox)
library(harbinger)
data(examples_motifs)
dataset <- examples_motifs$simple

# Visualizar série bruta
har_plot(harbinger(), dataset$serie)
```

```
# Configurar SAX
# arg1: tamanho do alfabeto (26)
# arg2: tamanho da palavra (3)
# arg3: mínimo de ocorrências (3)
model <- hmo_sax(26, 3, 3)

# Ajustar e detectar
model <- fit(model, dataset$serie)
detection <- detect(model, dataset$serie)

# Motifs detectados: palavra "QST"
# idx 25, 50, 75 → event = TRUE

# Avaliar
evaluation <- evaluate(model,
  detection$event, dataset$event)
print(evaluation$confMatrix)
## TRUE FALSE
## TRUE 3 0
## FALSE 0 98
```

Step by Step

- Use `hmo_sax(alphabet, word, min_occurrences)`
- Alphabet=26 letters, word length=3
- Detected motif: symbolic word "QST"
- Occurrences at indices 25, 50, and 75
- **Perfect result:** 3 TP, 0 FP, 0 FN, 98 TN

📌 **Key concept:** SAX converts numeric values into symbols — motifs become repeated words, enabling efficient similarity search in symbolic space.

XSAX – Representação Simbólica Estendida

O **XSAX** (Extended SAX) é uma extensão direta do SAX que substitui o alfabeto de letras por um alfabeto alfanumérico (dígitos 0–9 + letras A–Z), aumentando a resolução simbólica. O pipeline é idêntico ao SAX — z-normalização, PAA e mapeamento simbólico — mas com mais símbolos disponíveis para capturar variações de amplitude mais finas.

SAX

- **Alfabeto:** apenas letras (ex: a=26)
- **Palavra detectada:** "QST"
- **Resolução:** mais grosseira — intervalos de amplitude mais amplos por símbolo
- Ideal para padrões amplos e dados de baixa variação de amplitude

XSAX

- **Alfabeto:** dígitos + letras (ex: a=37: 0–9 e A–Z + 1)
- **Palavra detectada:** "0N0P0R" (cada segmento PAA gera 2 caracteres)
- **Resolução:** mais fina — distingue variações sutis de amplitude
- Ideal para séries com alta variabilidade de amplitude

Prefira o XSAX quando pequenas flutuações de amplitude são relevantes para a identificação de eventos ou motifs. Na mesma série sintética do exemplo SAX, o XSAX encontrou os mesmos índices (25, 50, 75), mas representou o motif com a palavra simbólica mais expressiva "0N0P0R" — preservando nuances que o alfabeto menor do SAX não consegue distinguir.

Referência: Ogasawara, E., Salles, R., Porto, F., Pacitti, E. *Event Detection in Time Series*. Springer, 2025. doi:10.1007/978-3-031-75941-3

07 – Motif Discovery with XSAX

XSAX extends SAX to a larger alphanumeric alphabet, enabling finer symbolic resolution. Motifs are frequent symbolic words or patterns with small symbolic distance.

```
# Carregar pacotes e dados
library(daltoolbox)
library(harbinger)
data(examples_motifs)
dataset <- examples_motifs$simple

# Visualizar série bruta
har_plot(harbinger(), dataset$serie)
```

```
# Configurar XSAX
# arg1: alfabeto estendido (37)
# arg2: tamanho da palavra (3)
# arg3: mínimo de ocorrências (3)
model <- hmo_xsax(37, 3, 3)

# Ajustar e detectar
model <- fit(model, dataset$serie)
detection <- detect(model, dataset$serie)

# Motif detectado: "ONOPOR"
# idx 25, 50, 75 → event = TRUE

# Avaliar
evaluation <- evaluate(model,
  detection$event, dataset$event)
print(evaluation$confMatrix)
## TRUE FALSE
## TRUE 3 0
## FALSE 0 98
```

Step by step

- Use `hmo_xsax(alphabet, word, min_occurrences)`
- Alphabet=37 (letters + digits), word length=3
- Detected motif: word "ONOPOR"
- Same indices as SAX: 25, 50, and 75
- **Perfect result:** 3 TP, 0 FP, 0 FN, 98 TN

📌 **Key concept:** XSAX uses a larger alphabet than standard SAX, capturing subtler pattern variations — useful when the series has high amplitude resolution.

Matrix Profile & STOMP – Descoberta de Discords

O **Matrix Profile** é uma estrutura de dados que armazena, para cada subsequência da série, a distância ao seu vizinho mais próximo. Isso permite descobrir eficientemente tanto **motifs** (padrões recorrentes) quanto **discords** (anomalias). O algoritmo **STOMP** computa esse perfil de forma escalável usando a técnica MASS.

01

Calcular Distâncias (MASS)

Para cada subsequência de comprimento w , calcule a distância a todas as outras subsequências usando o algoritmo MASS (Mueen's Algorithm for Similarity Search), com complexidade $O(n^2 \log n)$.

02

Construir o Matrix Profile

Para cada posição i , armazene a distância mínima ao vizinho mais próximo (excluindo correspondências triviais — subsequências adjacentes ou sobrepostas). O resultado é um vetor de distâncias do mesmo comprimento da série.

03

Identificar Discords

As posições com os **maiores** valores no Matrix Profile são os discords — as subsequências mais diferentes de qualquer outra na série, portanto as mais anômalas.

Motif vs. Discord

- **Motif:** posição com distância **mínima** → padrão mais repetido na série
- **Discord:** posição com distância **máxima** → padrão mais incomum ou único

Parâmetros (slide 08)

- $w=25$: tamanho da janela (comprimento da subsequência)
- $qtd=10$: número de top discords a recuperar
- **Dataset:** ECG mitdb102 (~7.200 pontos)
- **Resultado:** 4 discords encontrados (índices 2602, 3844, 4017, 6135), mas **0 coincidem** com os rótulos do ground-truth — 0 TP, 4 FP, 3 FN

❏ O Matrix Profile detecta subsequências **globalmente** anômalas — as mais diferentes de qualquer outra na série. Isso não garante alinhamento com eventos clinicamente rotulados, que podem não ser os mais incomuns do ponto de vista estatístico.

Referência: Yeh, C.-C. M., Zhu, Y., Ulanova, L., Begum, N., Ding, Y., Dau, H. A., ... & Keogh, E. (2016). Matrix Profile I/II: All-pairs similarity joins and scalable time series motif/discord discovery. *IEEE ICDM*.

08 – Discord Discovery with STOMP (hdis_mp)

Discords are maximally dissimilar subsequences — the inverse of motifs. The Matrix Profile identifies those with the greatest distance to their nearest neighbor. Dataset: ECG `mitdb102`.

```
# Carregar pacotes e dados
library(daltoolbox)
library(harbinger)
data(examples_motifs)

# Dataset ECG com anomalias anotadas
dataset <- examples_motifs$mitdb102

# Visualizar série
har_plot(harbinger(), dataset$serie)
```

```
# Definir modelo de discord (STOMP)
# w: tamanho da janela (25)
# qtd: número de discords (10)
model <- hdis_mp(mode = "stomp",
                 w = 25, qtd = 10)

# Ajustar e detectar
model <- fit(model, dataset$serie)
suppressMessages(
  detection <- detect(model, dataset$serie))

# Avaliar
evaluation <- evaluate(model,
                       detection$event, dataset$event)
print(evaluation$confMatrix)

## TRUE FALSE
## TRUE  0   4
## FALSE 3 7195
```

Step by Step

- Use `hdis_mp()` instead of `hmo_mp()`
- Dataset: ECG `mitdb102` (~7,200 points)
- Window=25, retrieve 10 discords
- 4 events detected at indices 2602, 3844, 4017, 6135
- 0 TP, 4 FP, 3 FN — discords do not align with ground-truth labels

📌 **Key concept:** Discord = the subsequence with the *greatest* distance to its nearest neighbor in the Matrix Profile. It inverts the motif logic: it seeks what is rare, not what repeats.

SAX para Discords – Raridade Simbólica

A representação SAX pode ser invertida para descoberta de discords: em vez de buscar as palavras simbólicas mais **frequentes** (motifs), buscamos as mais **raras**. Palavras raras → regiões incomuns → candidatas a discord.

Motif com SAX

- Busca palavras simbólicas mais **FREQUENTES**
- Alta frequência → padrão recorrente
- Poucos eventos detectados (alta precisão)

Discord com SAX (**hdis_sax**)

- Busca palavras simbólicas mais **RARAS** ou únicas
- Baixa frequência / alta entropia → anomalia candidata
- Muitos eventos detectados (alta sensibilidade)

Com **hdis_sax**(26, 25) no dataset ECG **mitdb102** (alfabeto=26, janela=25), foram detectados **121 discords** — muito mais do que os 4 detectados pelo **hdis_mp**. A alta sensibilidade captura inúmeras regiões localmente incomuns, mas a maioria não corresponde a anomalias clinicamente rotuladas (0 TP, 121 FP). A abordagem simbólica é sensível à variação local, não a anomalias globais.

hdis_sax

121 discords detectados

0 TP · 121 FP · 3 FN

Alta sensibilidade, baixa precisão

hdis_mp

4 discords detectados

0 TP · 4 FP · 3 FN

Baixa sensibilidade, maior precisão relativa

Referência: Lin, J., Keogh, E., Lonardi, S., Chiu, B. (2007). A symbolic representation of time series, with implications for streaming algorithms. *Data Mining and Knowledge Discovery*, 15, 107–144.

09 – Discord Discovery with SAX (hdis_sax)

SAX-based discord discovery identifies rare subsequences by discretizing the series and finding unique words with high entropy. Dataset: ECG `mitdb102`. Detects 121 discords.

```
# Carregar pacotes e dados
library(daltoolbox)
library(harbinger)
data(examples_motifs)

# Dataset ECG com anomalias
dataset <- examples_motifs$mitdb102

# Visualizar série bruta
har_plot(harbinger(), dataset$serie)
```

```
# Configurar SAX para discords
# arg1: alfabeto (26)
# arg2: tamanho da palavra/janela (25)
model <- hdis_sax(26, 25)

# Ajustar e detectar
model <- fit(model, dataset$serie)
detection <- detect(model, dataset$serie)
# 121 eventos detectados

# Avaliar
evaluation <- evaluate(model,
  detection$event, dataset$event)
print(evaluation$confMatrix)
## TRUE FALSE
## TRUE  0 121
## FALSE 3 7078
```

Step by Step

- Use `hdis_sax(alfabeto, window)` — no count parameter
- Alphabet=26, window=25 (symbolic word length)
- 121 discords detected — far more than the MP approach
- 0 TP, 121 FP, 3 FN — high sensitivity, low precision
- Symbolic discords capture local variation, not global anomalies

❏ **Key concept:** SAX-discord finds rare symbolic words — it detects many unusual regions, but may not align with clinically labeled anomalies.

Summary: Symbolic Methods & Discord Analysis

Motif Discovery – SAX

`hmo_sax(a, w, min)` — Use when looking for **repeated patterns** in a series. Converts subsequences into symbolic words using a Gaussian alphabet; motifs are the most frequent words. Fast and interpretable. Best for: synthetic or clean series.

Motif Discovery – XSAX

`hmo_xsax(a, w, min)` — Extension of SAX with a larger alphanumeric alphabet (digits + letters). Use when the series has **high amplitude variability** and finer symbolic resolution is needed. Same pipeline as SAX, richer representation.

Discord Discovery – Matrix Profile (STOMP)

`hdis_mp(mode="stomp", w, qtd)` — Use when looking for **globally anomalous subsequences** — those most different from any other in the series. Computes nearest-neighbor distances via MASS. Precise but may miss clinically labeled events.

Discord Discovery – SAX

`hdis_sax(a, w)` — Use when **high sensitivity** to local unusual regions is needed. Finds rare symbolic words; detects many discord candidates. High recall, low precision — useful as a first-pass anomaly scanner.

Additional Sources

Explore the resources below to dive deeper into Harbinger and time series event detection.



CRAN Package

cran.r-project.org/web/packages/harbinger



Event Detection Resources

eic.cefet-rj.br/~eogasawara/en/event-detection-in-time-series



DAL Toolbox

cran.r-project.org/web/packages/daltoolbox



Issues & Discussions

github.com/cefet-rj-dal/harbinger/issues

Open questions, report bugs, or suggest improvements directly in the repository.

References

Yeh, C.-C. M., et al. (2016). Matrix Profile I/II: All-pairs similarity joins and scalable time series motif/discord discovery. *IEEE ICDM*.

Tavenard, R., et al. (2020). tsmp: The Matrix Profile in R. *The R Journal*. doi:10.32614/RJ-2020-021

Lin, J., Keogh, E., Lonardi, S., Chiu, B. (2007). A symbolic representation of time series, with implications for streaming algorithms. *Data Mining and Knowledge Discovery*, 15, 107–144.

Ogasawara, E., Salles, R., Porto, F., Pacitti, E. Event Detection in Time Series. *Springer*, 2025. doi:10.1007/978-3-031-75941-3