

Harbinger

Uma estrutura unificada para detecção
de eventos em séries temporais

Eduardo Ogasawara
eduardo.ogasawara@cefet-rj.br
<https://eic.cefet-rj.br/~eogasawara>

Harbinger: Uma estrutura unificada para detecção de eventos em séries temporais



Harbinger is a framework for event detection in time series. It provides an integrated environment for anomaly detection, change point detection, and motif discovery. Harbinger offers a broad range of methods and functions for plotting and evaluating detected events.

For anomaly detection, methods are based on: - Machine learning model deviation: Conv1D, ELM, MLP, LSTM, Random Regression Forest, and SVM - Classification models: Decision Tree, KNN, MLP, Naive Bayes, Random Forest, and SVM - Clustering: k-means and DTW - Statistical techniques: ARIMA, FBIAD, GARCH

For change point detection, Harbinger includes: - Linear regression, ARIMA, ETS, and GARCH-based approaches - Classic methods such as AMOC, ChowTest, Binary Segmentation (BinSeg), GFT, and PELT

For motif discovery, it provides: - Methods based on Hashing and Matrix Profile

Harbinger also supports **multivariate time series analysis** and **event evaluation** using both traditional and soft computing metrics.

The architecture of Harbinger is based on **Experiment Lines** and is built on top of the [DAL Toolbox](#). This design makes it easy to extend and integrate new methods into the framework.

Por que uma estrutura unificada?

- Existem vários métodos, mas eles são focados em tipos específicos
- A escolha apropriada depende da natureza da série cronológica
- As aplicações do mundo real exigem comparação sistemática, combinação de detectores e avaliação rigorosa

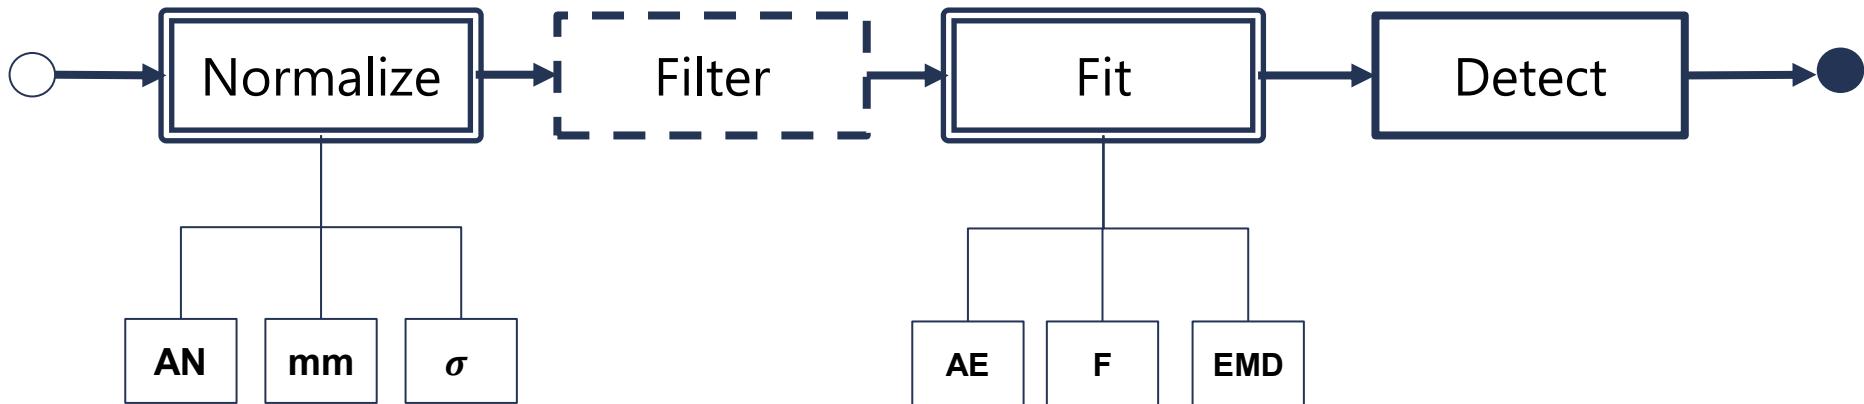
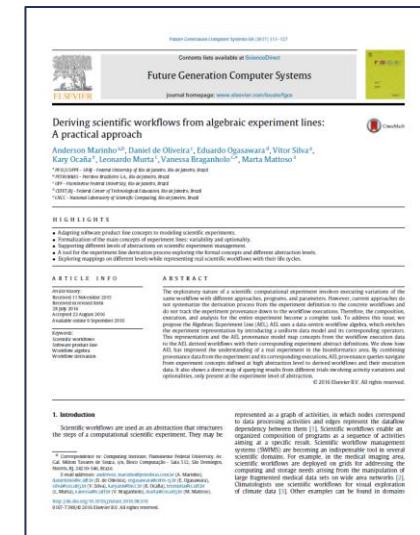
Anomalies	Change point	Motifs
Methods	50	10
Features		
Metrics		Hard (traditional) and Fuzzy
Models		Ensemble and Ensemble Fuzzy
Thresholds customization		Deviation, Filters, and Candidate selection
Visualization		Time Series, Comparison, Residuals, and thresholds

• 75

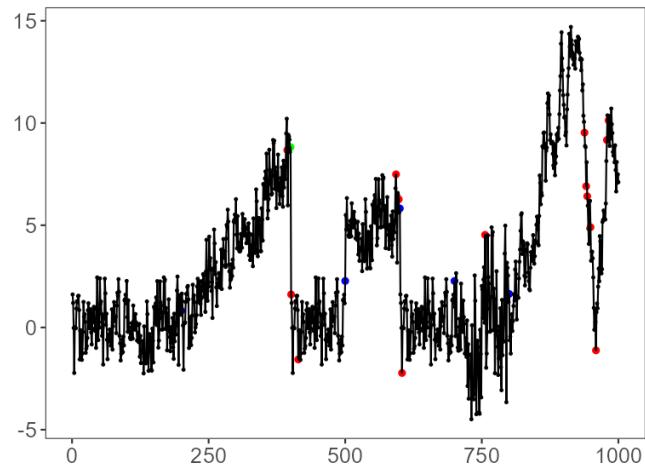
Harbinger: Um framework para integração e análise de métodos de detecção de eventos em séries temporais*
Rebecca Salles¹, Luciana Escobar¹, Laila Baroni¹, Roscio Zorrilla²,
Arthur Ziviani³, Vanicus Kreischer⁴, Flávia C. Delicato⁵, Paulo E. Pires⁶,
Luciano Maia⁷, Rafaeli Coutinho⁸, Laura Assis⁹, Eduardo Ogasawara¹⁰
¹CEPTEL/UFRJ - Centro Federal de Educação Tecnológica Celso Suckow da Fonseca
²LINCC - Laboratório Nacional de Computação Científica
³UFF - Universidade Federal Fluminense
⁴Pontifícia
ir@rebecca.salles.uol.com.br, lunesca.escobar@lincc.uff.br
{laila,roscio.zorrilla,vanicus.ziviani}@lincc.uff.br
{flaviam,rafaeli.coutinho,laura.assis}@ceptel.uff.br, luciano.maia@cpes.uff.br
{eduardo.ogasawara}@lincc.uff.br
Abstract. When analyzing time series, it is possible to observe significant changes in the behavior of its observations that frequently characterize the occurrence of events. These changes are often represented by abrupt or gradual pattern. In literature, there are several methods for event detection. However, the search for a suitable method for a time series is not a simple task, especially considering the variety of methods available. This work presents Harbinger, a framework for integration and analysis of event detection methods. Harbinger was evaluated with synthetic and real data, where it was possible to verify that the framework facilitates the selection of methods and the understanding of detected events.
Resumo. Ao analisar séries temporais, é possível observar mudanças significativas no comportamento das observações que frequentemente caracterizam a ocorrência de eventos. Essas mudanças são geralmente representadas por padrões de mudanças, ou padrões freqüentes. Na literatura existem diversos métodos para detecção de eventos. Entretanto, a busca por um método adequado para uma série temporal não é uma tarefa simples, especialmente considerando a variedade de métodos disponíveis. Esta trabalho apresenta o Harbinger, um framework para integração e análise de métodos de detecção de eventos. O Harbinger foi avaliado em dados sintéticos e reais, onde foi possível constatar que o framework facilita a seleção de métodos e a compreensão dos eventos detectados.
1. Introdução
No análise de séries temporais, frequentemente é possível observar a ocorrência de uma mudança significativa em seu comportamento em um certo ponto ou intervalo de tempo.
*Os autores agradecem à Pontifícia, FAPERJ, CAPES (Ed. 100) e CNPq pelo financiamento do projeto.

Arquitetura modular

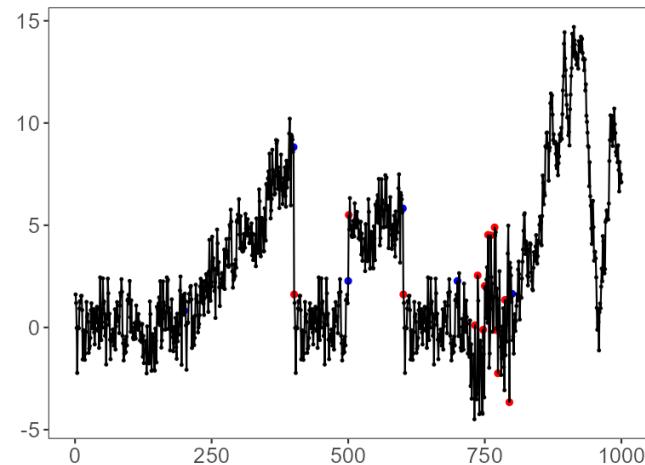
- Detecção, Avaliação, Combinação, Comparação
- Cada módulo pode ser usado sozinho ou integrado
- Interface rígida (baseada em álgebra de fluxo de trabalho e linhas de experimento)
- Construído sobre o DAL Toolbox
- <https://cran.r-project.org/web/packages/daltoolbox>
- Inspirado no Scikit-learn: funções fit() e detect()



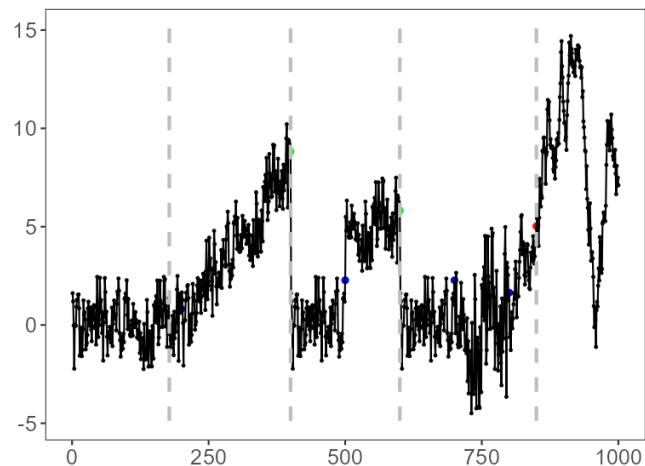
Visualização combinada de detectores em uma série temporal



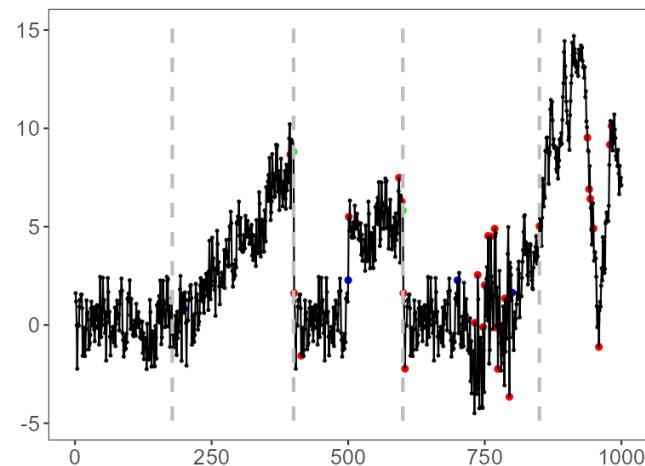
(a) FBIAD



(b) LSTM



(c) GFT



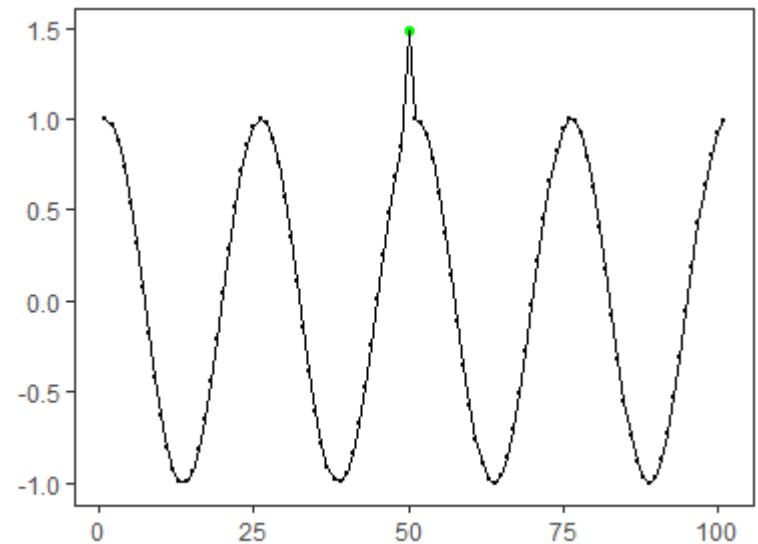
(d) Integrated View (FBIAD+LSTM+GFT)

Exemplo simples de detecção de anomalias

- O Harbinger vem com algumas séries de exemplos
- Séries temporais rotuladas
- Funções de plotagem
- Muitos detectores, como o ARIMA

```
library(daltoolbox)
library(harbinger)

data(examples_anomalies)
dataset <- examples_anomalies$simple
model <- hanr_arima()
# fitting the model
model <- fit(model, dataset$serie)
# making detections
detection <- detect(model, dataset$serie)
# plotting the results
har_plot(model(), dataset$serie, detection)
```



Entendendo a detecção

- Explorando detecções
- Visualizando os resíduos
- Avaliando os resultados

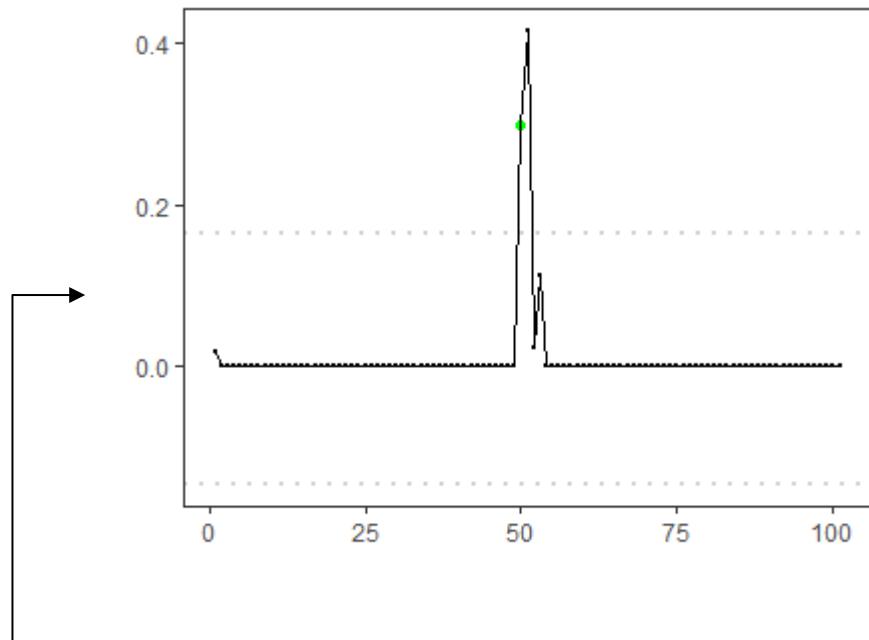
```
# filtering detected events
print(detection |>
      dplyr::filter(event==TRUE))

##   idx event    type
## 1  50  TRUE anomaly

# understating detected events
har_plot(model, attr(detection, "res"), detection,
          dataset$event, yline = attr(detection, "threshold"))

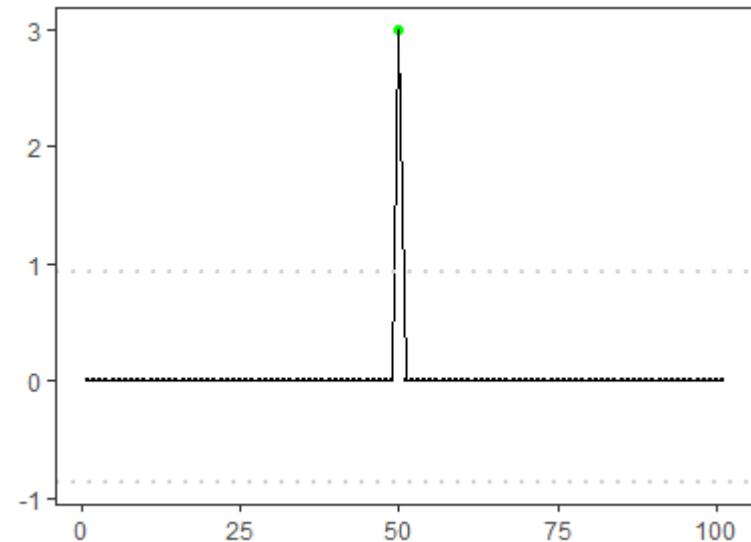
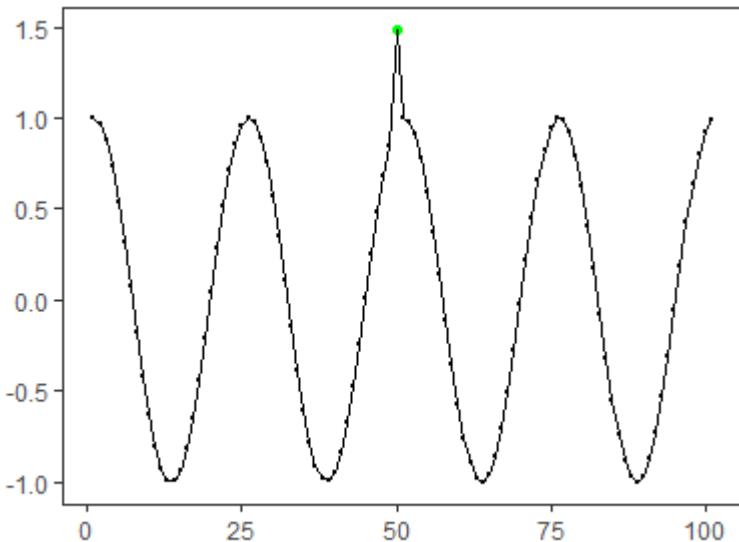
# evaluating detected events
evaluation <- evaluate(model, detection$event, dataset$event)
print(evaluation$confMatrix)

##           event
## detection TRUE FALSE
##   TRUE      1     0
##   FALSE      0    100
```



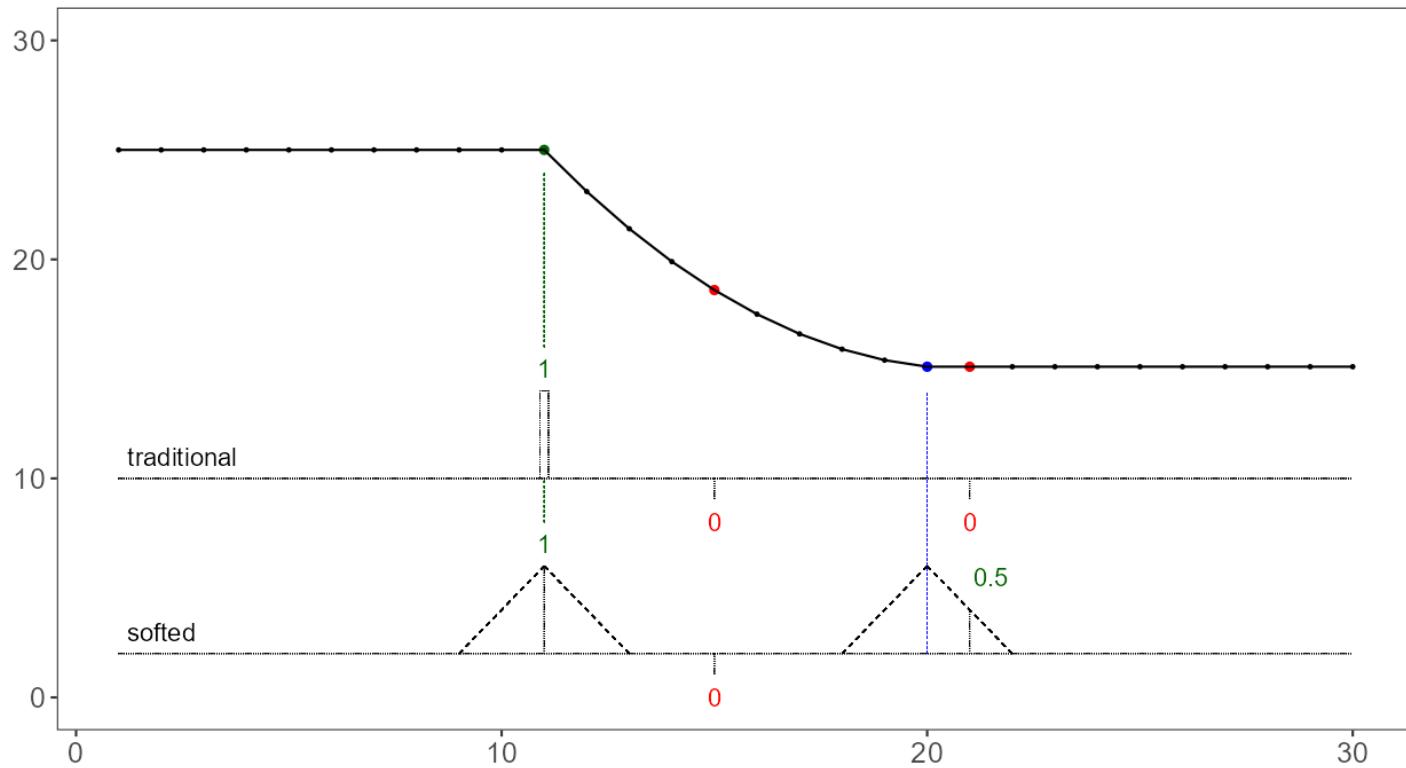
Comitê de modelos

```
model <- har_ensemble(hanr_fbiad(), hanr_arima(), hanr_emd())
model <- fit(model, dataset$serie)
detection <- detect(model, dataset$serie)
• har_plot(model, dataset$serie, detection, dataset$event)
• har_plot(model, attr(detection, "res"), detection,
dataset$event, yline = attr(detection, "threshold"))
```



Fuzificando eventos

- Ao contrário das métricas tradicionais, o SoftED tolera pequenos desalinhamentos temporais, mas impõe penalidades mais fortes em padrões de detecção fragmentados ou inconsistentes



Taxonomia da detecção de eventos em séries temporais



Harbinger

Uma estrutura unificada para detecção
de eventos em séries temporais

Eduardo Ogasawara
eduardo.ogasawara@cefet-rj.br
<https://eic.cefet-rj.br/~eogasawara>